

Clase 9 · Descomposición en valores singulares

Toda matriz es una rotación, un estiramiento y otra rotación

Contenido

1	Un círculo que se vuelve elipse	2
2	La descomposición en valores singulares	2
3	La geometría: la esfera se vuelve un elipsoide	9
4	Rango y los cuatro subespacios	11
5	La pseudoinversa y la solución de norma mínima	13
6	Aproximación de rango bajo	19
7	Componentes principales	21
8	★ Para ir más allá: el teorema de Eckart-Young	25
9	Resumen	29
10	Ejercicios	30

1. Un círculo que se vuelve elipse

Sea $A = \begin{pmatrix} 3 & 0 \\ 4 & 5 \end{pmatrix}$. Esta matriz no es simétrica y sus vectores propios no son perpendiculares, así que el teorema espectral de la Clase 8 no se le aplica. Pero siempre podemos mirar qué hace con el círculo unidad. Un vector unitario $x = (\cos t, \sin t)'$ va a $Ax = (3 \cos t, 4 \cos t + 5 \sin t)'$, y al recorrer todo el círculo la imagen es la elipse inclinada de la Figura 1.

¿Hay un par de direcciones **perpendiculares** del círculo que A lleve a las direcciones de los ejes de la elipse? Probemos con las diagonales $v_1 = \frac{1}{\sqrt{2}}(1, 1)'$ y $v_2 = \frac{1}{\sqrt{2}}(1, -1)'$:

$$Av_1 = \frac{1}{\sqrt{2}} \begin{pmatrix} 3 \\ 9 \end{pmatrix}, \quad Av_2 = \frac{1}{\sqrt{2}} \begin{pmatrix} 3 \\ -1 \end{pmatrix}.$$

Los dos vectores resultantes son perpendiculares: $3 \cdot 3 + 9 \cdot (-1) = 0$. Sus largos son $\|Av_1\| = \sqrt{90/2} = \sqrt{45} = 3\sqrt{5}$ y $\|Av_2\| = \sqrt{10/2} = \sqrt{5}$. Entonces A manda el par perpendicular v_1, v_2 al par perpendicular $3\sqrt{5}u_1, \sqrt{5}u_2$, con $u_1 = \frac{1}{\sqrt{10}}(1, 3)'$ y $u_2 = \frac{1}{\sqrt{10}}(3, -1)'$ unitarios: son los ejes de la elipse, de semiejes $3\sqrt{5} \approx 6,71$ y $\sqrt{5} \approx 2,24$.

Esta es la idea de la clase: **toda** matriz real $m \times n$ lleva una base ortonormal $v_1, \dots, v_n$ de $\mathbb{R}^n$ a un conjunto de vectores perpendiculares $\sigma_1 u_1, \dots, \sigma_n u_n$ de $\mathbb{R}^m$. Con ello A queda descrita por dos rotaciones (o reflexiones) y un estiramiento: $A = U\Sigma V'$. Esa factorización contiene el rango, los cuatro subespacios, la pseudo-inversa, la mejor aproximación de rango bajo y las componentes principales de una nube de datos.

2. La descomposición en valores singulares

Para una matriz A de $m \times n$ el producto $A'A$ es simétrico, semidefinido positivo (Clase 8: la forma cuadrática de $A'A$ es $\|Ax\|^2 \geq 0$) y de tamaño $n \times n$. Su teorema espectral es el motor de toda la clase. Primero, un hecho sobre su rango.




Figura 1: El círculo unidad (izquierda) y su imagen por $A = \begin{pmatrix} 3 & 0 \\ 4 & 5 \end{pmatrix}$ (derecha). Los puntos grises del círculo van a los puntos grises de la elipse. Las direcciones v_1, v_2 (rojo y ocre) son las únicas perpendiculares del círculo cuyas imágenes también son perpendiculares: $Av_1 = 3\sqrt{5}u_1$ y $Av_2 = \sqrt{5}u_2$.

Lema 2.1 ($A'A$ y A tienen el mismo espacio nulo). Para toda matriz A de $m \times n$, $N(A'A) = N(A)$, y por lo tanto $\text{rango}(A'A) = \text{rango } A$.

Borrador

Si $Ax = 0$ entonces $A'Ax = 0$. Al revés, si $A'Ax = 0$, multiplico por x' para obtener $\|Ax\|^2 = 0$. Con igual espacio nulo, la fórmula rango más nulidad da igual rango.

Demostración. Si $Ax = 0$, entonces $A'Ax = A'0 = 0$. Recíprocamente, si $A'Ax = 0$, entonces $0 = x'A'Ax = (Ax)'(Ax) = \|Ax\|^2$, de donde $Ax = 0$. Las dos matrices tienen n columnas y el mismo espacio nulo, y por la fórmula rango + nulidad = n (Clase 3) tienen el mismo rango. $\square$

Teorema 2.1 (Descomposición en valores singulares (SVD)). Sea A una matriz real de $m \times n$ y de rango r . Existen una matriz ortogonal U de $m \times m$, una matriz ortogonal V de $n \times n$ y números

$\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r > 0$ tales que

$$A = U\Sigma V', \quad \Sigma = \begin{pmatrix} \text{diag}(\sigma_1, \dots, \sigma_r) & 0 \\ 0 & 0 \end{pmatrix} (m \times n).$$

Los σ_i se llaman **valores singulares** de A (se escribe $\sigma_i = 0$ para $r < i \leq \min(m, n)$), las columnas u_i de U son los **vectores singulares izquierdos** y las columnas v_i de V , los **vectores singulares derechos**. Además $Av_i = \sigma_i u_i$ para $i \leq r$, $Av_i = 0$ para $i > r$, y

$$A = \sigma_1 u_1 v_1' + \sigma_2 u_2 v_2' + \dots + \sigma_r u_r v_r'.$$

Borrador

Diagonalizo $A'A = V\Lambda V'$ con el teorema espectral. Los σ_i son las raíces de los valores propios, y los v_i , sus vectores propios. Defino $u_i = Av_i/\sigma_i$: son unitarios y perpendiculares porque $v_i' A' A v_j = \lambda_j v_i' v_j$. Los completo a una base ortonormal de $\mathbb{R}^m$. Con eso $AV = U\Sigma$ columna por columna.

Demostración. Los v_i y los σ_i . Por el teorema espectral (Clase 8), $A'A = V\Lambda V'$ con V ortogonal y $\Lambda = \text{diag}(\lambda_1, \dots, \lambda_n)$, y ordenamos las columnas de V para que $\lambda_1 \geq \dots \geq \lambda_n$. Como $A'A$ es semidefinida positiva, todos los $\lambda_i \geq 0$; en concreto, $\lambda_i = v_i' A' A v_i = \|Av_i\|^2$. El número de λ_i no nulos es el rango de $A'A$ (Clase 8, corolario del teorema espectral), que por el Lema 2.1 es r . Luego $\lambda_1 \geq \dots \geq \lambda_r > 0 = \lambda_{r+1} = \dots = \lambda_n$. Definimos $\sigma_i = \sqrt{\lambda_i}$ para $i \leq r$.

Los v_i con $i > r$. Para $i > r$, $\|Av_i\|^2 = \lambda_i = 0$, así que $Av_i = 0$.

Los u_i con $i \leq r$. Para $i \leq r$ sea $u_i = Av_i/\sigma_i \in \mathbb{R}^m$. Su largo es $\|u_i\| = \|Av_i\|/\sigma_i = \sqrt{\lambda_i}/\sigma_i = 1$. Para $i \neq j$ (ambos $\leq r$), usando $A'Av_j = \lambda_j v_j$ y $v_i' v_j = 0$,

$$u_i \cdot u_j = \frac{(Av_i)'(Av_j)}{\sigma_i \sigma_j} = \frac{v_i'(A'Av_j)}{\sigma_i \sigma_j} = \frac{\lambda_j v_i' v_j}{\sigma_i \sigma_j} = 0.$$

Así $u_1, \dots, u_r$ son ortonormales. Por Gram-Schmidt (Clase 5) se completan con $u_{r+1}, \dots, u_m$ a una base ortonormal de $\mathbb{R}^m$, y $U = (u_1 \dots u_m)$ es ortogonal.

La igualdad. La columna i de $U\Sigma$ es $\sigma_i u_i = Av_i$ si $i \leq r$ y es $0 = Av_i$ si $i > r$. Es decir, $U\Sigma = AV$. Multiplicando por V' a la derecha y usando $VV' = I$, queda $A = U\Sigma V'$. La suma de matrices de rango uno sale de la multiplicación columna por fila: $U\Sigma V' = \sum_{i \leq r} \sigma_i u_i v_i'$, porque las columnas de $U\Sigma$ con $i > r$ son nulas. $\square$

El teorema da más información de la que aparenta.

Corolario 2.1 (Consecuencias inmediatas).

1. Los σ_i^2 son los valores propios de $A'A$ (con vectores propios v_i) y los r valores propios no nulos de AA' (con vectores propios u_i). Además $A'u_i = \sigma_i v_i$ para $i \leq r$.
2. Los valores singulares están determinados por A : cualquier factorización $A = U\Sigma V'$ con U, V ortogonales y Σ como en el teorema tiene los mismos σ_i .
3. Si A es simétrica semidefinida positiva, la SVD es el teorema espectral: $\sigma_i = \lambda_i$ y $u_i = v_i$.

Borrador

Todo sale de $A'A = V\Sigma' \Sigma V'$ y de la fórmula $Av_i = \sigma_i u_i$. Para AA' se escribe el mismo producto en el otro orden.

Demostración.

- (1) Ya vimos que $A'Av_i = \lambda_i v_i = \sigma_i^2 v_i$. Para $i \leq r$, $A'u_i = A'Av_i/\sigma_i = \sigma_i^2 v_i/\sigma_i = \sigma_i v_i$, y entonces $AA'u_i = \sigma_i Av_i = \sigma_i^2 u_i$. Esos son r valores propios no nulos de AA' ; no hay más, porque $\text{rango}(AA') = \text{rango}(A') = r$ (Lema 2.1 aplicado a A') y el rango de una simétrica es el número de valores propios no nulos.
- (2) Si $A = U\Sigma V'$, entonces $A'A = V\Sigma' U' U \Sigma V' = V(\Sigma' \Sigma) V'$, con $\Sigma' \Sigma$ diagonal de entradas σ_i^2 . Es una diagonalización de $A'A$, así que los σ_i^2 son sus valores propios y quedan determinados.
- (3) Si $A = Q\Lambda Q'$ con $\lambda_i \geq 0$ ordenados de mayor a menor, esa ya es una SVD con $U = V = Q$.

□

Los σ_i están determinados, pero los vectores no siempre: si dos valores singulares coinciden, hay libertad para elegir los vectores correspondientes (el Ejercicio 9.2 lo muestra), y en cualquier caso se puede cambiar el signo de u_i y v_i a la vez.

 Algoritmo: SVD a mano a partir de $A'A$

Entrada: A de $m \times n$. **Salida:** U, Σ, V con $A = U\Sigma V'$.

1. Calcular $G = A'A$ (matriz $n \times n$ simétrica).
2. Hallar los valores propios $\lambda_1 \geq \dots \geq \lambda_n \geq 0$ de G y vectores propios unitarios y perpendiculares v_i (Clase 8). Los $\sigma_i = \sqrt{\lambda_i}$; r es el número de $\sigma_i > 0$.
3. Para $i = 1, \dots, r$: $u_i = Av_i/\sigma_i$.
4. Completar $u_1, \dots, u_r$ a una base ortonormal de $\mathbb{R}^m$ con una base ortonormal del espacio nulo de A' (Gram-Schmidt).
5. Comprobar $Av_i = \sigma_i u_i$ para todo $i \leq r$.

Costo: a mano, solo para matrices chicas. En la práctica no se forma $A'A$: se reduce A a forma bidiagonal con reflexiones de Householder (Clase 5) y se itera sobre esa matriz; el costo es del orden de mn^2 para $m \geq n$, con una constante mayor que la de QR. **Cuándo falla:** formar $A'A$ eleva al cuadrado el número de condición (Clase 6) y los valores singulares pequeños pierden precisión: el error absoluto de un σ_i calculado así es del orden de $\varepsilon \sigma_1^2/\sigma_i$, con ε la precisión de máquina. Por eso los programas no usan este camino.

Ejemplo 2.1 (SVD de una matriz 2×2). Para $A = \begin{pmatrix} 3 & 0 \\ 4 & 5 \end{pmatrix}$: $A'A = \begin{pmatrix} 3 & 4 \\ 0 & 5 \end{pmatrix} \begin{pmatrix} 3 & 0 \\ 4 & 5 \end{pmatrix} = \begin{pmatrix} 25 & 20 \\ 20 & 25 \end{pmatrix}$, con $\tau = 50$ y $\Delta = 625 - 400 = 225$, es decir $\lambda^2 - 50\lambda + 225 = (\lambda - 45)(\lambda - 5)$. Los valores singulares son $\sigma_1 = \sqrt{45} = 3\sqrt{5}$ y $\sigma_2 = \sqrt{5}$. Los vectores propios de $A'A$: para $\lambda = 45$, $A'A - 45I = \begin{pmatrix} -20 & 20 \\ 20 & -20 \end{pmatrix}$ da $x_1 = x_2$, $v_1 = \frac{1}{\sqrt{2}}(1, 1)'$; para $\lambda = 5$, $x_1 = -x_2$, $v_2 = \frac{1}{\sqrt{2}}(1, -1)'$. Los

vectores izquierdos, como en la apertura:

$$u_1 = \frac{Av_1}{\sigma_1} = \frac{(3, 9)'}{\sqrt{2} \cdot 3\sqrt{5}} = \frac{1}{\sqrt{10}} \begin{pmatrix} 1 \\ 3 \end{pmatrix},$$

$$u_2 = \frac{Av_2}{\sigma_2} = \frac{(3, -1)'}{\sqrt{2} \cdot \sqrt{5}} = \frac{1}{\sqrt{10}} \begin{pmatrix} 3 \\ -1 \end{pmatrix}.$$

Entonces $A = U\Sigma V'$ con $U = \frac{1}{\sqrt{10}} \begin{pmatrix} 1 & 3 \\ 3 & -1 \end{pmatrix}$, $\Sigma = \text{diag}(3\sqrt{5}, \sqrt{5})$

y $V = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 & 1 \\ 1 & -1 \end{pmatrix}$. Comprobación con la suma de matrices de

rango uno: $\sigma_1 u_1 v_1' = \frac{3\sqrt{5}}{\sqrt{20}} \begin{pmatrix} 1 \\ 3 \end{pmatrix} (1 \quad 1) = \frac{3}{2} \begin{pmatrix} 1 & 1 \\ 3 & 3 \end{pmatrix}$ y $\sigma_2 u_2 v_2' =$

$$\frac{\sqrt{5}}{\sqrt{20}} \begin{pmatrix} 3 \\ -1 \end{pmatrix} (1 \quad -1) = \frac{1}{2} \begin{pmatrix} 3 & -3 \\ -1 & 1 \end{pmatrix}, y$$

$$\frac{3}{2} \begin{pmatrix} 1 & 1 \\ 3 & 3 \end{pmatrix} + \frac{1}{2} \begin{pmatrix} 3 & -3 \\ -1 & 1 \end{pmatrix} = \begin{pmatrix} \frac{3}{2} + \frac{3}{2} & \frac{3}{2} - \frac{3}{2} \\ \frac{3}{2} - \frac{1}{2} & \frac{3}{2} + \frac{1}{2} \end{pmatrix} = \begin{pmatrix} 3 & 0 \\ 4 & 5 \end{pmatrix} \checkmark$$

Ejemplo 2.2 (SVD de una matriz 3×3). Sea $A = \begin{pmatrix} 2 & 3 & 3 \\ 3 & 2 & 3 \\ 2 & 2 & 0 \end{pmatrix}$

(la usaremos otra vez como imagen). Sus columnas son $(2, 3, 2)'$, $(3, 2, 2)'$ y $(3, 3, 0)'$, y

$$A'A = \begin{pmatrix} 4+9+4 & 6+6+4 & 6+9+0 \\ 16 & 9+4+4 & 9+6+0 \\ 15 & 15 & 9+9+0 \end{pmatrix} = \begin{pmatrix} 17 & 16 & 15 \\ 16 & 17 & 15 \\ 15 & 15 & 18 \end{pmatrix}.$$

Probemos los vectores $w_1 = (1, 1, 1)'$, $w_2 = (1, 1, -2)'$ y $w_3 = (1, -1, 0)'$ (perpendiculares entre sí: $1 + 1 - 2 = 0$, $1 - 1 = 0$, $1 - 1 + 0 = 0$):

$$A'Aw_1 = \begin{pmatrix} 48 \\ 48 \\ 48 \end{pmatrix} = 48 w_1,$$

$$A'Aw_2 = \begin{pmatrix} 17+16-30 \\ 16+17-30 \\ 15+15-36 \end{pmatrix} = \begin{pmatrix} 3 \\ 3 \\ -6 \end{pmatrix} = 3 w_2,$$

$$A'Aw_3 = \begin{pmatrix} 1 \\ -1 \\ 0 \end{pmatrix} = 1 w_3.$$

Los valores propios son 48, 3, 1 (suman $52 = 17 + 17 + 18 = \text{tr}(A'A)$), de modo que $\sigma_1 = \sqrt{48} = 4\sqrt{3}$, $\sigma_2 = \sqrt{3}$, $\sigma_3 = 1$, y los vectores unitarios son $v_1 = \frac{1}{\sqrt{3}}(1, 1, 1)'$, $v_2 = \frac{1}{\sqrt{6}}(1, 1, -2)'$, $v_3 = \frac{1}{\sqrt{2}}(1, -1, 0)'$. Aplicamos A :

$$Av_1 = \frac{1}{\sqrt{3}} \begin{pmatrix} 8 \\ 8 \\ 4 \end{pmatrix},$$

$$Av_2 = \frac{1}{\sqrt{6}} \begin{pmatrix} 2+3-6 \\ 3+2-6 \\ 2+2-0 \end{pmatrix} = \frac{1}{\sqrt{6}} \begin{pmatrix} -1 \\ -1 \\ 4 \end{pmatrix},$$

$$Av_3 = \frac{1}{\sqrt{2}} \begin{pmatrix} 2-3 \\ 3-2 \\ 2-2 \end{pmatrix} = \frac{1}{\sqrt{2}} \begin{pmatrix} -1 \\ 1 \\ 0 \end{pmatrix}.$$

Sus largos son $\frac{\sqrt{144}}{\sqrt{3}} = 4\sqrt{3}$, $\frac{\sqrt{18}}{\sqrt{6}} = \sqrt{3}$ y 1, como debe ser. Dividiendo por σ_i :

$$u_1 = \frac{1}{3} \begin{pmatrix} 2 \\ 2 \\ 1 \end{pmatrix}, \quad u_2 = \frac{1}{3\sqrt{2}} \begin{pmatrix} -1 \\ -1 \\ 4 \end{pmatrix},$$

$$u_3 = \frac{1}{\sqrt{2}} \begin{pmatrix} -1 \\ 1 \\ 0 \end{pmatrix}.$$

Son perpendiculares: $u_1 \cdot u_2 \propto -2-2+4 = 0$, $u_1 \cdot u_3 \propto -2+2 = 0$, $u_2 \cdot u_3 \propto 1-1 = 0$. La suma de matrices de rango uno:

$$\sigma_1 u_1 v_1' = \frac{4}{3} \begin{pmatrix} 2 & 2 & 2 \\ 2 & 2 & 2 \\ 1 & 1 & 1 \end{pmatrix},$$

$$\sigma_2 u_2 v_2' = \frac{1}{6} \begin{pmatrix} -1 & -1 & 2 \\ -1 & -1 & 2 \\ 4 & 4 & -8 \end{pmatrix}, \quad \sigma_3 u_3 v_3' = \frac{1}{2} \begin{pmatrix} -1 & 1 & 0 \\ 1 & -1 & 0 \\ 0 & 0 & 0 \end{pmatrix}.$$

(Por ejemplo, $\sigma_2 u_2 v_2' = \frac{\sqrt{3}}{3\sqrt{2}\sqrt{6}}(-1, -1, 4)'(1, 1, -2) = \frac{1}{6}(-1, -1, 4)'(1, 1, -2)$.) La entrada (1, 1) de la suma es $\frac{8}{3} - \frac{1}{6} - \frac{1}{2} = \frac{16-1-3}{6} = 2$; la (1, 2), $\frac{8}{3} - \frac{1}{6} + \frac{1}{2} = 3$; la (1, 3), $\frac{8}{3} + \frac{1}{3} = 3$; la (3, 1), $\frac{4}{3} + \frac{4}{6} = 2$; la (3, 3), $\frac{4}{3} - \frac{8}{6} = 0$. Las demás se calculan igual y se recupera A completa $\checkmark$. Como control, $\det A = 2(0-6)-3(0-6)+3(6-4) = 12 = 4\sqrt{3} \cdot \sqrt{3} \cdot 1 = \sigma_1 \sigma_2 \sigma_3$.

3. La geometría: la esfera se vuelve un elipsoide

La apertura mostró un círculo que se vuelve elipse. En general, la SVD dice que A hace tres cosas seguidas: V' gira (o refleja) a las coordenadas de los v_i ; Σ estira cada coordenada i por σ_i (y aplasta a cero las coordenadas $i > r$), y U gira (o refleja) el resultado al espacio de llegada.

Teorema 3.1 (La imagen de la bola unidad). Sea $A = U\Sigma V'$ de rango r . La imagen de la bola unidad $\{x : \|x\| \leq 1\}$ es

$$\left\{ z_1 u_1 + \cdots + z_r u_r : \frac{z_1^2}{\sigma_1^2} + \cdots + \frac{z_r^2}{\sigma_r^2} \leq 1 \right\},$$

un elipsoide sólido de dimensión r dentro del espacio columna, con semiejes $\sigma_i u_i$. Si $r = n$, la imagen de la esfera $\|x\| = 1$ es su superficie, $\sum z_i^2 / \sigma_i^2 = 1$.

Borrador

Cambio de variable $y = V'x$ (no cambia el largo). En esas coordenadas, $Ax = \sum_{i \leq r} \sigma_i y_i u_i$. Pongo $z_i = \sigma_i y_i$ y la condición $\|y\| \leq 1$ pasa a ser la del elipsoide. Para la inclusión inversa construyo el x que corresponde a cada z .

Demostración. Sea $\|x\| \leq 1$ e $y = V'x$, de modo que $x = Vy$ y $\|y\| = \|x\| \leq 1$ (Clase 8, V ortogonal). Entonces $Ax = U\Sigma y = \sum_{i \leq r} \sigma_i y_i u_i$, porque $\Sigma y = (\sigma_1 y_1, \dots, \sigma_r y_r, 0, \dots, 0)'$. Con $z_i = \sigma_i y_i$, $\sum_{i \leq r} z_i^2 / \sigma_i^2 = \sum_{i \leq r} y_i^2 \leq \|y\|^2 \leq 1$. Recíprocamente, dado z con $\sum z_i^2 / \sigma_i^2 \leq 1$, sea $y_i = z_i / \sigma_i$ para $i \leq r$ y $y_i = 0$ para $i > r$; entonces $\|y\| \leq 1$, $x = Vy$ cumple $\|x\| \leq 1$ y $Ax = \sum z_i u_i$. Para $r = n$ no hay coordenadas $i > r$, $\|y\| = \|x\|$ y la igualdad $\|x\| = 1$ equivale a $\sum z_i^2 / \sigma_i^2 = 1$. $\square$

Corolario 3.1 (Amplificación máxima y mínima, determinante y condicionamiento). Para todo $x \in \mathbb{R}^n$,

$$\|Ax\| \leq \sigma_1 \|x\|,$$




Figura 2: La esfera unidad (izquierda) y su imagen por $A = \begin{pmatrix} 2 & 3 & 3 \\ 3 & 2 & 3 \\ 2 & 2 & 0 \end{pmatrix}$ (derecha), el elipsoide de semiejes $\sigma_1 = 4\sqrt{3} \approx 6,93$, $\sigma_2 = \sqrt{3} \approx 1,73$ y $\sigma_3 = 1$ en las direcciones u_1, u_2, u_3 del Ejemplo 2.2. Las flechas de la izquierda son los v_i , que A lleva a las flechas $\sigma_i u_i$.

con igualdad en $x = v_1$. Si $r = n$ (columnas independientes), también $\|Ax\| \geq \sigma_n \|x\|$, con igualdad en $x = v_n$. Si A es cuadrada, $|\det A| = \sigma_1 \sigma_2 \cdots \sigma_n$, y si además es invertible, el cociente $\kappa(A) = \sigma_1 / \sigma_n$ (el número de condición de la Clase 6) es la razón entre el semieje mayor y el menor del elipsoide imagen.

i Borrador

En las coordenadas $y = V'x$ el cuadrado $\|Ax\|^2$ es $\sum \sigma_i^2 y_i^2$, un promedio ponderado de los σ_i^2 (por $\|x\|^2$), que no sale del intervalo entre el menor y el mayor. El determinante sale de que las matrices ortogonales tienen determinante ± 1 .

Demostración. Con $y = V'x$, $\|Ax\|^2 = \|U\Sigma y\|^2 = \|\Sigma y\|^2 = \sum_{i \leq r} \sigma_i^2 y_i^2$, porque U conserva largos. Como $\sum_{i \leq n} y_i^2 = \|x\|^2$, esto es $\|x\|^2$ por un promedio ponderado de los σ_i^2 (pesos $y_i^2 / \|x\|^2 \geq 0$ que suman 1, con $\sigma_i = 0$ para $i > r$), así que está entre $\sigma_n^2 \|x\|^2$ y $\sigma_1^2 \|x\|^2$ (la misma idea que el cociente de Rayleigh, Clase 8). Para $x = v_1, y = e_1$ y el promedio vale σ_1^2 ; para $x = v_n$, vale σ_n^2 . Si A es

cuadrada, $|\det A| = |\det U| |\det \Sigma| |\det V'| = \sigma_1 \cdots \sigma_n$, porque el determinante de una matriz ortogonal es ± 1 (Clase 4). $\square$

El número $\sigma_1 = \max_{\|x\|=1} \|Ax\|$ se llama **norma espectral** de A y se escribe $\|A\|_2$; la Clase 10 la estudia junto con las demás normas matriciales. En el Ejemplo 2.1, $|\det A| = 15 = 3\sqrt{5} \cdot \sqrt{5}$ y $\kappa(A) = 3$; en el Ejemplo 2.2, $|\det A| = 12$ y $\kappa(A) = 4\sqrt{3} \approx 6,93$.

4. Rango y los cuatro subespacios

La SVD lee de un vistazo los cuatro subespacios de la Clase 3, y los entrega con bases **ortonormales**.

Proposición 4.1 (Bases ortonormales de los cuatro subespacios). Sea $A = U\Sigma V'$ de rango r . Entonces:

1. $u_1, \dots, u_r$ es una base ortonormal del espacio columna $C(A)$.
2. $u_{r+1}, \dots, u_m$ es una base ortonormal del espacio nulo izquierdo $N(A')$.
3. $v_1, \dots, v_r$ es una base ortonormal del espacio fila $C(A')$.
4. $v_{r+1}, \dots, v_n$ es una base ortonormal del espacio nulo $N(A)$.

Borrador

Escribo $Ax = \sum \sigma_i (v_i \cdot x) u_i$: eso dice que el espacio columna está generado por $u_1, \dots, u_r$, y que $Ax = 0$ exactamente cuando x es perpendicular a $v_1, \dots, v_r$. Los otros dos subespacios salen de aplicar lo mismo a $A' = V\Sigma'U'$.

Demostración. Espacio columna. Para todo x , $Ax = \sum_{i \leq r} \sigma_i (v'_i x) u_i \in \text{gen}(u_1, \dots, u_r)$. Recíprocamente, $u_i = A(v_i/\sigma_i) \in C(A)$ para $i \leq r$. Los u_i son ortonormales, por lo tanto independientes: forman una base de $C(A)$, de dimensión r .

Espacio nulo. Como $\{v_1, \dots, v_n\}$ es una base ortonormal, $x = \sum_i (v'_i x) v_i$, y $Ax = \sum_{i \leq r} \sigma_i (v'_i x) u_i$. Los u_i son independientes y $\sigma_i > 0$, así que $Ax = 0$ si y solo si $v'_i x = 0$ para $i = 1, \dots, r$, es decir, si y solo si $x = \sum_{i > r} (v'_i x) v_i \in \text{gen}(v_{r+1}, \dots, v_n)$. Esos $n - r$ vectores son ortonormales y forman una base de $N(A)$.

Los otros dos. $A' = V\Sigma'U'$ es una SVD de A' con los papeles de U y V intercambiados y el mismo rango r . Aplicando lo ya demostrado a A' : $C(A') = \text{gen}(v_1, \dots, v_r)$ y $N(A') = \text{gen}(u_{r+1}, \dots, u_m)$. $\square$

Las dos bases $\{u_1, \dots, u_r\}$ y $\{u_{r+1}, \dots, u_m\}$ son perpendiculares por ser parte de una misma base ortonormal: $C(A) \perp N(A')$ y $C(A') \perp N(A)$, que es la ortogonalidad de la Clase 3 con su demostración incluida.

Ejemplo 4.1 (Una matriz 2×2 de rango 1). Sea $M = \begin{pmatrix} 1 & 1 \\ 2 & 2 \end{pmatrix} = \begin{pmatrix} 1 \\ 2 \end{pmatrix} \begin{pmatrix} 1 & 1 \end{pmatrix}$. Entonces $M'M = \begin{pmatrix} 5 & 5 \\ 5 & 5 \end{pmatrix}$ tiene valores propios 10 y 0, con vectores propios $v_1 = \frac{1}{\sqrt{2}}(1, 1)'$ y $v_2 = \frac{1}{\sqrt{2}}(1, -1)'$. Luego $\sigma_1 = \sqrt{10}$ y $u_1 = Mv_1/\sigma_1 = \frac{(2,4)'}{\sqrt{2}\sqrt{10}} = \frac{1}{\sqrt{5}}(1, 2)'$. El vector u_2 se completa perpendicular a u_1 : $u_2 = \frac{1}{\sqrt{5}}(2, -1)'$. Entonces $M = \sqrt{10}u_1v_1'$ (comprobación: $\frac{\sqrt{10}}{\sqrt{10}}(1, 2)'(1, 1) = M$), y: $C(M) = \text{gen}(1, 2)$, $N(M') = \text{gen}(2, -1)$, $C(M') = \text{gen}(1, 1)$ y $N(M) = \text{gen}(1, -1)$.

Ejemplo 4.2 (Una matriz 3×3 de rango 2). Sea $B = \begin{pmatrix} 1 & 0 & -1 \\ 1 & 0 & -1 \\ -1 & -1 & -1 \end{pmatrix}$ (las dos primeras filas son iguales, rango $B = 2$).

Entonces $B'B = \begin{pmatrix} 3 & 1 & -1 \\ 1 & 1 & 1 \\ -1 & 1 & 3 \end{pmatrix}$ (las columnas de B son $(1, 1, -1)'$, $(0, 0, -1)'$ y $(-1, -1, -1)'$). Se verifica que

$$\begin{aligned} B'B \begin{pmatrix} 1 \\ 0 \\ -1 \end{pmatrix} &= \begin{pmatrix} 4 \\ 0 \\ -4 \end{pmatrix}, & B'B \begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix} &= \begin{pmatrix} 3 \\ 3 \\ 3 \end{pmatrix}, \\ B \begin{pmatrix} 1 \\ -2 \\ 1 \end{pmatrix} &= \begin{pmatrix} 1-1 \\ 1-1 \\ -1+2-1 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \\ 0 \end{pmatrix}, \end{aligned}$$

así que los valores propios de $B'B$ son 4, 3 y 0, y $\sigma_1 = 2$, $\sigma_2 = \sqrt{3}$

y $\sigma_3 = 0$, con

$$v_1 = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ 0 \\ -1 \end{pmatrix}, \quad v_2 = \frac{1}{\sqrt{3}} \begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix}, \quad v_3 = \frac{1}{\sqrt{6}} \begin{pmatrix} 1 \\ -2 \\ 1 \end{pmatrix}.$$

Los vectores izquierdos: $Bv_1 = \frac{1}{\sqrt{2}}(2, 2, 0)'$, luego $u_1 = Bv_1/2 = \frac{1}{\sqrt{2}}(1, 1, 0)'$. Y $Bv_2 = \frac{1}{\sqrt{3}}(0, 0, -3)'$, luego $u_2 = Bv_2/\sqrt{3} = (0, 0, -1)'$. El tercero se completa perpendicular a los dos: $u_3 = \frac{1}{\sqrt{2}}(1, -1, 0)'$. Entonces $B = 2u_1v_1' + \sqrt{3}u_2v_2'$:

$$\begin{aligned} & 2 \cdot \frac{1}{2} \begin{pmatrix} 1 \\ 1 \\ 0 \end{pmatrix} (1 \ 0 \ -1) + \sqrt{3} \cdot \frac{1}{\sqrt{3}} \begin{pmatrix} 0 \\ 0 \\ -1 \end{pmatrix} (1 \ 1 \ 1) \\ &= \begin{pmatrix} 1 & 0 & -1 \\ 1 & 0 & -1 \\ 0 & 0 & 0 \end{pmatrix} + \begin{pmatrix} 0 & 0 & 0 \\ 0 & 0 & 0 \\ -1 & -1 & -1 \end{pmatrix} = B \checkmark \end{aligned}$$

Los subespacios: $C(B) = \text{gen}\{(1, 1, 0)', (0, 0, 1)'\}$; $N(B') = \text{gen}\{(1, -1, 0)'\}$ (en efecto, $B'(1, -1, 0)' = (0, 0, 0)'$); $C(B') = \text{gen}\{(1, 0, -1)', (1, 1, 1)'\}$ (las filas de B son $(1, 0, -1)$ y $(-1, -1, -1)$, que generan lo mismo) y $N(B) = \text{gen}\{(1, -2, 1)'\}$.

5. La pseudoinversa y la solución de norma mínima

Una matriz que no es cuadrada, o que es singular, no tiene inversa. Pero la SVD permite invertir lo que se puede invertir: lleva u_i de vuelta a v_i dividiendo por σ_i , y manda a cero lo demás.

Definición 5.1 (Pseudoinversa). Si $A = U\Sigma V'$ tiene rango r , su **pseudoinversa** (de Moore–Penrose) es la matriz A^+ de $n \times m$,

$$A^+ = V\Sigma^+U' = \sum_{i=1}^r \frac{1}{\sigma_i} v_i u_i', \quad \Sigma^+ = \begin{pmatrix} \text{diag}(1/\sigma_1, \dots, 1/\sigma_r) & 0 \\ 0 & 0 \end{pmatrix} (n \times m).$$

Si A es cuadrada e invertible, $A^+ = V\Sigma^{-1}U' = A^{-1}$ (porque $A \cdot V\Sigma^{-1}U' = U\Sigma V'V\Sigma^{-1}U' = I$). Si A no es invertible, A^+ hace lo mejor posible, en un sentido preciso.¹

¹ La pseudoinversa fue definida por E. H. Moore en 1920 y redescubierta por Roger Penrose en 1955, quien la caracterizó con cuatro ecuaciones.

Teorema 5.1 (La pseudoinversa resuelve mínimos cuadrados con norma mínima). Para A de $m \times n$ y $b \in \mathbb{R}^m$, el vector $x^+ = A^+b$ es el de **menor norma** entre todos los vectores que minimizan $\|Ax - b\|$. Es el único minimizador que está en el espacio fila $C(A')$.

i Borrador

Paso a las coordenadas $y = V'x$ y $c = U'b$. El residuo $\|Ax - b\|^2$ se separa en una suma de cuadrados $(\sigma_i y_i - c_i)^2$ para $i \leq r$ más un término $\sum_{i>r} c_i^2$ que no depende de x . Se minimiza anulando los primeros, y la norma $\|x\|^2 = \|y\|^2$ se minimiza haciendo $y_i = 0$ para $i > r$.

Demostración. Sea $y = V'x$ y $c = U'b$. Como U conserva largos, $\|Ax - b\| = \|U(\Sigma y - c)\| = \|\Sigma y - c\|$ (pues $Ax = U\Sigma y$ y $b = Uc$), y

$$\|Ax - b\|^2 = \sum_{i=1}^r (\sigma_i y_i - c_i)^2 + \sum_{i=r+1}^m c_i^2.$$

El segundo término no depende de x . El primero es ≥ 0 y vale 0 exactamente cuando $y_i = c_i/\sigma_i$ para $i = 1, \dots, r$, sin restricción sobre $y_{r+1}, \dots, y_n$. Esos son los minimizadores. Entre ellos, $\|x\|^2 = \|y\|^2 = \sum_{i \leq r} c_i^2/\sigma_i^2 + \sum_{i>r} y_i^2$ es mínima si y solo si $y_i = 0$ para $i > r$. Ese minimizador es $y = \Sigma^+ c$, es decir, $x = Vy = V\Sigma^+ U'b = A^+b$. Por último, $x = Vy \in \text{gen}(v_1, \dots, v_r) = C(A')$ si y solo si $y_i = 0$ para $i > r$ (Proposición 4.1), lo que caracteriza a x^+ . $\square$

Un caso importante: si $r = n$ (columnas independientes), no hay coordenadas libres y x^+ es el único minimizador; la pseudoinversa es entonces la de los mínimos cuadrados de la Clase 6.

Proposición 5.1 (Propiedades de A^+).

1. $AA^+ = \sum_{i \leq r} u_i u_i'$ es la matriz de proyección sobre $C(A)$ y $A^+A = \sum_{i \leq r} v_i v_i'$ es la matriz de proyección sobre $C(A')$.
2. Si $r = n$, entonces $A^+ = (A'A)^{-1}A'$.

i Borrador

Al multiplicar A por A^+ se cancela $V'V = I$ y queda $U(\Sigma\Sigma^+)U'$ con $\Sigma\Sigma^+$ casi la identidad. Para la fórmula con $(A'A)^{-1}$ escribo $A'A$ con la SVD y simplifico.

Demostración.

- (1) $AA^+ = U\Sigma V'V\Sigma^+U' = U(\Sigma\Sigma^+)U'$, y $\Sigma\Sigma^+$ es la matriz diagonal $m \times m$ con 1 en las primeras r posiciones y 0 en el resto. Entonces $AA^+ = \sum_{i \leq r} u_i u_i'$, que por la Clase 6 es la proyección sobre la recta o el plano generado por los u_i ortonormales, es decir, sobre $\mathcal{C}(A)$ (Proposición 4.1). Igual para $A^+A = V(\Sigma^+\Sigma)V'$.
- (2) Si $r = n$, $A'A = V\Sigma'\Sigma V'$ con $\Sigma'\Sigma = \text{diag}(\sigma_1^2, \dots, \sigma_n^2)$ invertible, y $(A'A)^{-1}A' = V(\Sigma'\Sigma)^{-1}V'V\Sigma^+U' = V[(\Sigma'\Sigma)^{-1}\Sigma']U'$. La matriz entre corchetes es $\text{diag}(1/\sigma_1, \dots, 1/\sigma_n)$ completada con ceros, es decir, Σ^+ .

□

Ejemplo 5.1 (Pseudoinversa 2×2 de rango 1). Para $M = \begin{pmatrix} 1 & 1 \\ 2 & 2 \end{pmatrix}$ ($\sigma_1 = \sqrt{10}$, $u_1 = \frac{1}{\sqrt{5}}(1, 2)'$, $v_1 = \frac{1}{\sqrt{2}}(1, 1)'$):

$$M^+ = \frac{1}{\sigma_1} v_1 u_1' = \frac{1}{\sqrt{10}\sqrt{2}\sqrt{5}} \begin{pmatrix} 1 \\ 1 \end{pmatrix} (1 \ 2) = \frac{1}{10} \begin{pmatrix} 1 & 2 \\ 1 & 2 \end{pmatrix}.$$

Resolvamos $Mx = b$ para dos lados derechos (Figura 3). Con $b = (1, 2)' \in \mathcal{C}(M)$: el sistema $x_1 + x_2 = 1$ tiene infinitas soluciones $(1-s, s)'$, y la de norma mínima es $x^+ = M^+b = \frac{1}{10}(1+4, 1+4)' = (\frac{1}{2}, \frac{1}{2})'$, con $\|x^+\|^2 = \frac{1}{2}$ (cualquier otra, $\|(1-s, s)\|^2 = 1-2s+2s^2 \geq \frac{1}{2}$, con igualdad en $s = \frac{1}{2}$). Con $b = (1, 0)' \notin \mathcal{C}(M)$ no hay solución exacta; el residuo es $(x_1 + x_2 - 1)^2 + 4(x_1 + x_2)^2 = 5t^2 - 2t + 1$ con $t = x_1 + x_2$, mínimo en $t = \frac{1}{5}$, y entre las infinitas soluciones de $x_1 + x_2 = \frac{1}{5}$ la de norma mínima es $x^+ = M^+b = \frac{1}{10}(1, 1)' = (\frac{1}{10}, \frac{1}{10})'$, con residuo $\frac{4}{5}$.




Figura 3: Pseudoinversa de $M = \begin{pmatrix} 1 & 1 \\ 2 & 2 \end{pmatrix}$. **Izquierda:** $Mx = (1, 2)'$ tiene como soluciones la recta $x_1 + x_2 = 1$; la de menor norma es el pie $x^+ = (\frac{1}{2}, \frac{1}{2})'$ de la perpendicular desde el origen, que está sobre el espacio fila (la recta $x_2 = x_1$). **Derecha:** $Mx = (1, 0)'$ no tiene solución; las rectas $x_1 + x_2 = t$ son curvas de nivel del residuo, y el mínimo $(\frac{4}{5})$ se alcanza en toda la recta $x_1 + x_2 = \frac{1}{5}$. De ellas, $x^+ = (\frac{1}{10}, \frac{1}{10})'$ es la de norma mínima.

Ejemplo 5.2 (Matrices 3×2 y 2×3 (columnas o filas independientes)). Sea $T = \begin{pmatrix} 1 & 0 \\ 1 & 1 \\ 0 & 1 \end{pmatrix}$. Entonces $T'T = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}$ tiene valores propios 3 y 1 (Clase 8) con vectores propios $v_1 = \frac{1}{\sqrt{2}}(1, 1)'$ y $v_2 = \frac{1}{\sqrt{2}}(1, -1)'$. Los valores singulares son $\sigma_1 = \sqrt{3}$ y $\sigma_2 = 1$, y

$$u_1 = \frac{Tv_1}{\sqrt{3}} = \frac{(1, 2, 1)'}{\sqrt{2}\sqrt{3}} = \frac{1}{\sqrt{6}} \begin{pmatrix} 1 \\ 2 \\ 1 \end{pmatrix}, \quad u_2 = \frac{Tv_2}{\sqrt{2}} = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ 0 \\ -1 \end{pmatrix},$$

$$u_3 = \frac{1}{\sqrt{3}} \begin{pmatrix} 1 \\ -1 \\ 1 \end{pmatrix},$$

donde u_3 completa la base ($u_3 \cdot u_1 \propto 1 - 2 + 1 = 0$, $u_3 \cdot u_2 \propto 1 - 1 = 0$) y es una base de $N(T')$. Como $r = 2 = n$, por la Proposición 5.1,

$$T^+ = (T'T)^{-1}T' = \frac{1}{3} \begin{pmatrix} 2 & -1 \\ -1 & 2 \end{pmatrix} \begin{pmatrix} 1 & 1 & 0 \\ 0 & 1 & 1 \end{pmatrix} = \frac{1}{3} \begin{pmatrix} 2 & 1 & -1 \\ -1 & 1 & 2 \end{pmatrix}.$$

Con $b = (1, 2, 0)'$: $x^+ = T^+b = \frac{1}{3}(2 + 2, -1 + 2)' = (\frac{4}{3}, \frac{1}{3})'$, que cumple las ecuaciones normales: $T'Tx^+ = (\frac{8}{3} + \frac{1}{3}, \frac{4}{3} + \frac{2}{3})' = (3, 2)' = T'b \checkmark$.

La transpuesta $T' = \begin{pmatrix} 1 & 1 & 0 \\ 0 & 1 & 1 \end{pmatrix}$ (2×3) tiene $(T')^+ = (T^+)' = \frac{1}{3} \begin{pmatrix} 2 & -1 \\ 1 & 1 \\ -1 & 2 \end{pmatrix}$ (la SVD de T' es la de T con U y V intercambiados). Para $T'x = (1, 1)'$, esto es, $x_1 + x_2 = 1$ y $x_2 + x_3 = 1$, hay infinitas soluciones $(1 - s, s, 1 - s)'$ y la de norma mínima es $(T')^+(1, 1)' = \frac{1}{3}(2 - 1, 1 + 1, -1 + 2)' = \frac{1}{3}(1, 2, 1)'$, con $\|x^+\|^2 = \frac{2}{3}$. Directamente: $\|(1 - s, s, 1 - s)\|^2 = 2(1 - s)^2 + s^2$ es mínimo cuando $-4(1 - s) + 2s = 0$, es decir $s = \frac{2}{3}$, y da el mismo vector.

Ejemplo 5.3 (Pseudoinversa 3×3 de rango 2). Para la matriz B

del Ejemplo 4.2 ($\sigma_1 = 2, \sigma_2 = \sqrt{3}$):

$$\begin{aligned} B^+ &= \frac{1}{2}v_1u_1' + \frac{1}{\sqrt{3}}v_2u_2' \\ &= \frac{1}{4}\begin{pmatrix} 1 \\ 0 \\ -1 \end{pmatrix}\begin{pmatrix} 1 & 1 & 0 \end{pmatrix} + \frac{1}{3}\begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix}\begin{pmatrix} 0 & 0 & -1 \end{pmatrix} \\ &= \begin{pmatrix} \frac{1}{4} & \frac{1}{4} & -\frac{1}{3} \\ 0 & 0 & -\frac{1}{3} \\ -\frac{1}{4} & -\frac{1}{4} & -\frac{1}{3} \end{pmatrix}. \end{aligned}$$

Comprobación de que BB^+ es la proyección sobre $C(B) = \text{gen}\{(1, 1, 0)', (0, 0, 1)'\}$: la fila $(1, 0, -1)$ de B por las columnas de B^+ da $\frac{1}{4} + \frac{1}{4} = \frac{1}{2}$, $\frac{1}{2}$ y $-\frac{1}{3} + \frac{1}{3} = 0$; la fila $(-1, -1, -1)$ da $0, 0$ y $\frac{1}{3} + \frac{1}{3} + \frac{1}{3} = 1$. Entonces

$$BB^+ = \begin{pmatrix} \frac{1}{2} & \frac{1}{2} & 0 \\ \frac{1}{2} & \frac{1}{2} & 0 \\ 0 & 0 & 1 \end{pmatrix} \checkmark$$

El sistema $Bx = b$ con $b = (1, 1, -3)' = (1, 1, 0)' - 3(0, 0, 1)' \in C(B)$ tiene la solución de norma mínima $x^+ = B^+b = (\frac{1}{4} + \frac{1}{4} + 1, 1, -\frac{1}{4} - \frac{1}{4} + 1)' = (\frac{3}{2}, 1, \frac{1}{2})'$. Comprobación: $Bx^+ = (\frac{3}{2} - \frac{1}{2}, \frac{3}{2} - \frac{1}{2}, -\frac{3}{2} - 1 - \frac{1}{2})' = (1, 1, -3)'$, y $x^+ \perp N(B) = \text{gen}(1, -2, 1)'$ porque $\frac{3}{2} - 2 + \frac{1}{2} = 0$. Las otras soluciones son $x^+ + t(1, -2, 1)'$, todas de mayor norma. Por último, el vector $b = (1, -1, 0)'$ está en $N(B')$ y es perpendicular a $C(B)$: el mejor ajuste es 0, y en efecto las tres filas de B^+ por b dan $\frac{1}{4} - \frac{1}{4} = 0, 0$ y $-\frac{1}{4} + \frac{1}{4} = 0$: $B^+b = 0$.

Con esto se entiende por qué la solución de un sistema se calcula bien con la SVD aunque A sea singular o casi singular: se descartan los σ_i despreciables. La Clase 14 desarrolla esa idea (SVD truncada y Tikhonov).

6. Aproximación de rango bajo

La suma $A = \sigma_1 u_1 v'_1 + \cdots + \sigma_r u_r v'_r$ ordena la información de A por importancia: primero la pieza de rango uno que más amplifica, después la siguiente. Truncarla da la matriz de rango k más cercana a A .

Definición 6.1 (Truncamiento y normas). Para $0 \leq k \leq r$ sea $A_k = \sum_{i=1}^k \sigma_i u_i v'_i$ (con $A_0 = 0$), una matriz de rango k . Para una matriz M de $m \times n$, la **norma de Frobenius** es $\|M\|_F^2 = \sum_{i,j} m_{ij}^2 = \text{tr}(M'M)$ y la **norma espectral** es $\|M\|_2 = \max_{\|x\|=1} \|Mx\|$.

Proposición 6.1 (El error del truncamiento). $\|A - A_k\|_2 = \sigma_{k+1}$ y $\|A - A_k\|_F^2 = \sigma_{k+1}^2 + \cdots + \sigma_r^2$ (con $\sigma_{r+1} = 0$). En particular, $\|A\|_F^2 = \sigma_1^2 + \cdots + \sigma_r^2$.

Borrador

$A - A_k = \sum_{i>k} \sigma_i u_i v'_i$ ya está escrita en forma de SVD (vectores ortonormales y números positivos). Sus valores singulares son $\sigma_{k+1}, \dots, \sigma_r$, y su norma espectral es el mayor; la de Frobenius sale de la traza de $M'M$.

Demostración. Sea $M = A - A_k = \sum_{i=k+1}^r \sigma_i u_i v'_i$. Como $u'_i u_j = \delta_{ij}$, $M'M = \sum_{i,j>k} \sigma_i \sigma_j v_i (u'_i u_j) v'_j = \sum_{i>k} \sigma_i^2 v_i v'_i$, y entonces $M'M v_j = \sigma_j^2 v_j$ si $k < j \leq r$ y $M'M v_j = 0$ en los demás casos. Los valores propios de $M'M$ son $\sigma_{k+1}^2, \dots, \sigma_r^2$ y ceros, y su suma es la traza: $\|M\|_F^2 = \text{tr}(M'M) = \sigma_{k+1}^2 + \cdots + \sigma_r^2$ (la traza es la suma de los valores propios, Clase 7). Para la norma espectral, si $k = r$ entonces $M = 0$ y no hay nada que probar; si $k < r$, para todo x tenemos $Mx = \sum_{i>k} \sigma_i (v'_i x) u_i$ y, por ser u_i ortonormales y $\sigma_i \leq \sigma_{k+1}$ para $i > k$,

$$\|Mx\|^2 = \sum_{i>k} \sigma_i^2 (v'_i x)^2 \leq \sigma_{k+1}^2 \sum_{i=1}^n (v'_i x)^2 = \sigma_{k+1}^2 \|x\|^2,$$

donde la última igualdad dice que V es ortogonal ($\sum_i (v'_i x)^2 = \|V'x\|^2 = \|x\|^2$). Hay igualdad en $x = v_{k+1}$: $\|M v_{k+1}\| = \sigma_{k+1}$. Luego $\|M\|_2 = \sigma_{k+1}$. La última afirmación es el caso $k = 0$. $\square$

El teorema de Eckart–Young (sección ★) dice que A_k es, además, **la mejor** aproximación de rango $\leq k$ en las dos normas. Su tamaño relativo se mide con la fracción de “energía” $\|A_k\|_F^2 / \|A\|_F^2 = (\sigma_1^2 + \dots + \sigma_k^2) / (\sigma_1^2 + \dots + \sigma_r^2)$.

Ejemplo 6.1 (Una imagen de juguete de 3×3). Una imagen en tonos de gris es una matriz cuyas entradas son brillos. Tomemos la matriz A del Ejemplo 2.2 como una imagen de 3×3 píxeles con brillos entre 0 y 3 (Figura 4). Sus valores singulares son $4\sqrt{3}, \sqrt{3}, 1$, con $\sigma_1^2 + \sigma_2^2 + \sigma_3^2 = 48 + 3 + 1 = 52 = \|A\|_F^2$ (la suma de los cuadrados de las entradas: $4 + 9 + 9 + 9 + 4 + 9 + 4 + 4 + 0 = 52$ ✓). Con las piezas de rango uno del Ejemplo 2.2:

$$A_1 = \frac{4}{3} \begin{pmatrix} 2 & 2 & 2 \\ 2 & 2 & 2 \\ 1 & 1 & 1 \end{pmatrix} = \begin{pmatrix} \frac{8}{3} & \frac{8}{3} & \frac{8}{3} \\ \frac{8}{3} & \frac{8}{3} & \frac{8}{3} \\ \frac{4}{3} & \frac{4}{3} & \frac{4}{3} \end{pmatrix},$$

$$A_2 = A - \sigma_3 u_3 v_3' = A - \frac{1}{2} \begin{pmatrix} -1 & 1 & 0 \\ 1 & -1 & 0 \\ 0 & 0 & 0 \end{pmatrix} = \begin{pmatrix} \frac{5}{2} & \frac{5}{2} & 3 \\ \frac{5}{2} & \frac{5}{2} & 3 \\ \frac{2}{2} & \frac{2}{2} & 0 \end{pmatrix}.$$

El primer truncamiento conserva $\frac{48}{52} \approx 92,3\%$ de la energía y tiene error

$$A - A_1 = \frac{1}{3} \begin{pmatrix} -2 & 1 & 1 \\ 1 & -2 & 1 \\ 2 & 2 & -4 \end{pmatrix},$$

$$\|A - A_1\|_F^2 = \frac{4+1+1+1+4+1+4+4+16}{9} = 4 = \sigma_2^2 + \sigma_3^2 \checkmark$$

(y $\|A - A_1\|_2 = \sigma_2 = \sqrt{3}$). El segundo conserva $\frac{51}{52} \approx 98,1\%$ y $\|A - A_2\|_F^2 = \sigma_3^2 = 1$, $\|A - A_2\|_2 = 1$. La imagen casi completa cabe en una sola pieza $\sigma_1 u_1 v_1'$: un patrón “claro arriba, más oscuro abajo”.

El ahorro aparece en tamaños grandes. Una matriz de $m \times n$ guarda mn números; A_k solo necesita los k vectores u_i , los k vectores v_i y los k valores σ_i : $k(m + n + 1)$ números. Para una imagen de 1000×1000 píxeles y $k = 50$ son 100 050 números en lugar de 10^6 , y si los σ_i decaen rápido, la imagen apenas se distingue de la original. En un ejemplo de 3×3 no hay ahorro ($k = 1$ guarda 7 números en lugar de 9): la gracia es ver el mecanismo.




Figura 4: La imagen A del Ejemplo 2.2 como 3×3 píxeles (más claro = más brillo), sus aproximaciones de rango 1 y 2 y los valores singulares al cuadrado. La primera pieza $\sigma_1 u_1 v_1'$ ya reproduce 92 % de la energía.

7. Componentes principales

Una nube de n puntos $x_1, \dots, x_n$ en $\mathbb{R}^p$ ($p = 2$ o 3) se resume en la matriz de datos X de $n \times p$ cuyas filas son los x_i' . Supongamos los datos **centrados**: $x_1 + \dots + x_n = 0$ (a cada punto se le resta el promedio). La matriz de covarianzas muestral es $S = X'X/(n-1)$. La pregunta del análisis de componentes principales es: ¿en qué dirección está más dispersa la nube? ¿Cuál es la recta (o el plano) que mejor la resume?²

Proposición 7.1 (Componentes principales y SVD). Sea $X = U\Sigma V'$ la SVD de la matriz de datos centrados X de $n \times p$.

1. Para una dirección unitaria v , la suma de los cuadrados de las distancias de los puntos a la recta $\mathbb{R}v$ es $\|X\|_F^2 - \|Xv\|^2$. Es mínima en $v = v_1$, con valor $\sigma_2^2 + \dots + \sigma_p^2$.
2. Si $p = 3$, para un plano por el origen de normal unitaria n_0 , esa suma es $\|Xn_0\|^2$, y es mínima cuando $n_0 = v_3$, con valor σ_3^2 . Ese plano es $\text{gen}(v_1, v_2)$.
3. Las **puntuaciones** (coordenadas de los puntos en los ejes v_i) son las columnas de $XV = U\Sigma$, o sea $z_i = Xv_i = \sigma_i u_i$. Son perpendiculares entre sí ($z_i \cdot z_j = 0$ si $i \neq j$), y la varianza de las puntuaciones en el eje v_i es $\|z_i\|^2/(n-1) = \sigma_i^2/(n-1)$, un valor propio de S . La varianza total, $\text{tr } S$, es $(\sigma_1^2 + \dots + \sigma_p^2)/(n-1)$.

² Karl Pearson planteó en 1901 el problema de la recta y el plano que mejor se ajustan a un conjunto de puntos minimizando distancias perpendiculares; Harold Hotelling desarrolló en 1933 el análisis de componentes principales.

Borrador

La distancia de un punto a una recta sale del teorema de Pitágoras: largo al cuadrado menos el cuadrado de la proyección. Sumando sobre los puntos, minimizar la distancia es maximizar $\|Xv\|^2 = v'X'Xv$, que es un cociente de Rayleigh de $X'X$. Para el plano uso la normal. Las puntuaciones salen de $X'X = V\Sigma'V'$.

Demostración.

- (1) La proyección de x_i sobre la recta $\mathbb{R}v$ es $(x_i \cdot v)v$, y por Pitágoras la distancia d_i cumple $\|x_i\|^2 = (x_i \cdot v)^2 + d_i^2$. Sumando sobre i , $\sum d_i^2 = \sum \|x_i\|^2 - \sum (x_i \cdot v)^2 = \|X\|_F^2 - \|Xv\|^2$, porque Xv es el vector de entradas $x_i \cdot v$. Minimizar esto es maximizar $\|Xv\|^2 = v'X'Xv$, y como v es unitario, esto es el cociente de Rayleigh de $X'X$ en v , cuyo máximo es el mayor valor propio σ_1^2 , alcanzado en v_1 (Clase 8). El valor mínimo de la suma es $\|X\|_F^2 - \sigma_1^2 = \sigma_2^2 + \dots + \sigma_p^2$ por la Proposición 6.1.
- (2) La distancia de x_i al plano de normal unitaria n_0 es $|x_i \cdot n_0|$, luego la suma de cuadrados es $\|Xn_0\|^2 = n_0'X'Xn_0$, el cociente de Rayleigh de $X'X$ en n_0 , cuyo mínimo es el menor valor propio σ_3^2 , alcanzado en v_3 (Clase 8). El plano de normal v_3 es el perpendicular a v_3 , es decir, $\text{gen}(v_1, v_2)$.
- (3) $XV = U\Sigma V'V = U\Sigma$, cuya columna i es $\sigma_i u_i$. Entonces $z_i \cdot z_j = v_i'X'Xv_j = \sigma_j^2 v_i'v_j = 0$ si $i \neq j$, y $\|z_i\|^2 = \sigma_i^2$. La covarianza de las puntuaciones es $V'SV = \Sigma'\Sigma/(n-1)$, diagonal; y $\text{tr } S = \text{tr}(X'X)/(n-1) = \|X\|_F^2/(n-1)$.

□

Esto distingue a las componentes principales de la **regresión** de la Clase 6: los mínimos cuadrados ordinarios minimizan distancias *verticales* (en la dirección de y), mientras que la primera componente minimiza distancias *perpendiculares* a la recta. Son rectas distintas, como muestra el ejemplo.

Ejemplo 7.1 (Una nube de siete puntos en el plano). Sea X la matriz de 7×2 cuyas filas son los puntos $\pm(2, 1)$, $\pm(1, 2)$, $\pm(1, -1)$ y $(0, 0)$ (su suma es cero: está centrada). Entonces

$$X'X = \begin{pmatrix} 2(4 + 1 + 1) & 2(2 + 2 - 1) \\ 2(2 + 2 - 1) & 2(1 + 4 + 1) \end{pmatrix} = \begin{pmatrix} 12 & 6 \\ 6 & 12 \end{pmatrix},$$

$$S = \frac{X'X}{6} = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}.$$

Como en la Clase 8, S tiene valores propios 3 y 1 con vectores propios $v_1 = \frac{1}{\sqrt{2}}(1, 1)'$ y $v_2 = \frac{1}{\sqrt{2}}(1, -1)'$. Luego $X'X$ tiene valores propios 18 y 6: $\sigma_1 = 3\sqrt{2}$, $\sigma_2 = \sqrt{6}$. Las puntuaciones $z_1 = Xv_1$ y $z_2 = Xv_2$ de los tres primeros puntos y sus opuestos son

Punto	(2, 1)	(1, 2)	(1, -1)
$z_1 = x \cdot v_1$	$\frac{3}{\sqrt{2}}$	$\frac{3}{\sqrt{2}}$	0
$z_2 = x \cdot v_2$	$\frac{1}{\sqrt{2}}$	$-\frac{1}{\sqrt{2}}$	$\frac{2}{\sqrt{2}}$

(con signo contrario para $-x$, y 0 para el origen). Comprobación: $\|z_1\|^2 = 2(\frac{9}{2} + \frac{9}{2} + 0) = 18 = \sigma_1^2$ y $\|z_2\|^2 = 2(\frac{1}{2} + \frac{1}{2} + 2) = 6 = \sigma_2^2$. La primera componente explica $\frac{18}{24} = 75\%$ de la varianza total ($\text{tr } S = 4 = 3 + 1$). La suma de distancias perpendiculares a la recta $x_2 = x_1$ es $\sigma_2^2 = 6$; directamente, la distancia de (x_1, x_2) a esa recta es $|x_1 - x_2|/\sqrt{2}$, y $2(\frac{1}{2} + \frac{1}{2} + 2) = 6 \checkmark$.

La recta de MCO de x_2 sobre x_1 tiene pendiente $\sum x_1 x_2 / \sum x_1^2 = \frac{6}{12} = \frac{1}{2}$, distinta de la pendiente 1 de la primera componente. Su suma de cuadrados vertical es $\sum x_2^2 - \frac{1}{2} \sum x_1 x_2 = 12 - 3 = 9$, menor que la de la recta $x_2 = x_1$ ($\sum (x_2 - x_1)^2 = 12$); pero su suma de distancias perpendiculares es $\frac{9}{1+1/4} = 7,2 > 6$. Cada recta gana en la distancia que minimiza.

Ejemplo 7.2 (Una nube de siete puntos en el espacio). Sea X la matriz de 7×3 con filas $\pm(1, -2, -2)$, $\pm(2, 0, -2)$, $\pm(2, 0, 0)$ y

$(0, 0, 0)$. Entonces

$$\begin{aligned} X'X &= 2 \left[\begin{pmatrix} 1 & -2 & -2 \\ -2 & 4 & 4 \\ -2 & 4 & 4 \end{pmatrix} + \begin{pmatrix} 4 & 0 & -4 \\ 0 & 0 & 0 \\ -4 & 0 & 4 \end{pmatrix} + \begin{pmatrix} 4 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{pmatrix} \right] \\ &= \begin{pmatrix} 18 & -4 & -12 \\ -4 & 8 & 8 \\ -12 & 8 & 16 \end{pmatrix}. \end{aligned}$$

Probemos los vectores $p_1 = \frac{1}{3}(2, -1, -2)'$, $p_2 = \frac{1}{3}(2, 2, 1)'$ y $p_3 = \frac{1}{3}(1, -2, 2)'$, unitarios y perpendiculares entre sí (por ejemplo, $4 - 2 - 2 = 0$, $2 + 2 - 4 = 0$, $2 - 4 + 2 = 0$). Aplicando $X'X$ a $(2, -1, -2)'$:

$$\begin{pmatrix} 36 + 4 + 24 \\ -8 - 8 - 16 \\ -24 - 8 - 32 \end{pmatrix} = \begin{pmatrix} 64 \\ -32 \\ -64 \end{pmatrix} = 32 \begin{pmatrix} 2 \\ -1 \\ -2 \end{pmatrix}.$$

Del mismo modo $X'X(2, 2, 1)' = (36 - 8 - 12, -8 + 16 + 8, -24 + 16 + 16)' = (16, 16, 8)' = 8(2, 2, 1)'$ y $X'X(1, -2, 2)' = (18 + 8 - 24, -4 - 16 + 16, -12 - 16 + 32)' = (2, -4, 4)' = 2(1, -2, 2)'$. Así $\sigma_1^2 = 32$, $\sigma_2^2 = 8$, $\sigma_3^2 = 2$ (suman $42 = 18 + 8 + 16 = \text{tr } X'X$) y las componentes principales son $v_i = p_i$. Las puntuaciones de $(1, -2, -2)$, $(2, 0, -2)$ y $(2, 0, 0)$ son

$$\begin{aligned} (1, -2, -2) : \quad & \frac{1}{3}(2 + 2 + 4, 2 - 4 - 2, 1 + 4 - 4) = \frac{1}{3}(8, -4, 1), \\ (2, 0, -2) : \quad & \frac{1}{3}(4 + 4, 4 - 2, 2 - 4) = \frac{1}{3}(8, 2, -2), \\ (2, 0, 0) : \quad & \frac{1}{3}(4, 4, 2). \end{aligned}$$

La suma de cuadrados de la primera puntuación es $2 \cdot \frac{64+64+16}{9} = 32$, la de la segunda, $2 \cdot \frac{16+4+16}{9} = 8$ y la de la tercera, $2 \cdot \frac{1+4+4}{9} = 2$ ✓. Las varianzas ($n - 1 = 6$) son $\frac{16}{3}$, $\frac{4}{3}$, $\frac{1}{3}$, con total $7 = \text{tr } S$, y explican $\frac{16}{21} \approx 76,2\%$, $\frac{4}{21} \approx 19,0\%$ y $\frac{1}{21} \approx 4,8\%$. El plano que mejor se ajusta es el perpendicular a v_3 , con suma de distancias al cuadrado $\sigma_3^2 = 2$: los tres puntos dan $(x \cdot v_3)^2 = \frac{1}{9}$, $\frac{4}{9}$, $\frac{4}{9}$ y $2 \cdot \frac{9}{9} = 2$ ✓.

En la práctica los datos de p variables se resumen proyectando sobre las primeras k componentes: la matriz XV_kV_k' (con $V_k =$




Figura 5: Componentes principales. **Izquierda:** la nube del Ejemplo 7.1, con los dos ejes principales, las distancias perpendiculares a la primera componente y la recta de mínimos cuadrados (pendiente $\frac{1}{2}$). **Derecha:** la nube del Ejemplo 7.2, con los tres ejes principales (largos proporcionales a σ_i) y el plano $\text{gen}(v_1, v_2)$, el que mejor se ajusta a los puntos.

$(v_1 \cdots v_k)$) es exactamente $X_k = \sum_{i \leq k} \sigma_i u_i v_i'$, la aproximación de rango k de X . Es por eso que la reducción de dimensión y la compresión de imágenes son el mismo cálculo.

8. ★ Para ir más allá: el teorema de Eckart-Young

! ★ Para ir más allá

La Proposición 6.1 calcula el error del truncamiento A_k . ¿Podría otra matriz de rango $\leq k$ aproximar mejor a A ? No: A_k es **la mejor** en la norma espectral y en la de Frobenius. La demostración usa una sola idea (la misma de Courant-Fischer: un subespacio grande corta al núcleo de una matriz de rango chico) y, de pasada, da la distancia de una matriz invertible a las singulares.

Para enunciar el resultado hace falta caracterizar los valores singulares con el cociente de Rayleigh. Escribimos $\sigma_1(M) \geq \dots \geq$

$\sigma_n(M) \geq 0$ para los valores singulares de una matriz M de $m \times n$, es decir, las raíces de los n valores propios de $M'M$ ordenados de mayor a menor (los últimos son nulos si $\text{rango } M < n$). Ojo: en la Clase 8 los valores propios se ordenaron de menor a mayor, así que el j -ésimo mayor valor propio de $M'M$ es λ_{n-j+1} en esa notación.

Lema 8.1 (Cota inferior de un valor singular). *Sea M de $m \times n$. Si existe un subespacio $T \subseteq \mathbb{R}^n$ de dimensión j y un número $c \geq 0$ tales que $\|Mx\| \geq c\|x\|$ para todo $x \in T$, entonces $\sigma_j(M) \geq c$.*

i Borrador

Es la segunda forma de Courant–Fischer (Clase 8) para $M'M$, usando el subespacio T como candidato en el máximo.

Demostración. Sean $\mu_1 \leq \dots \leq \mu_n$ los valores propios de la simétrica $M'M$ (Clase 8), de modo que $\sigma_j(M)^2 = \mu_{n-j+1}$. Por la segunda igualdad del teorema de Courant–Fischer (Clase 8) con $k = n - j + 1$, y como $n - k + 1 = j$,

$$\mu_{n-j+1} = \max_{\dim S=j} \min_{x \in S, x \neq 0} \frac{x'M'Mx}{x'x} = \max_{\dim S=j} \min_{x \in S, x \neq 0} \frac{\|Mx\|^2}{\|x\|^2}.$$

Para $S = T$, el mínimo interior es $\geq c^2$, de modo que el máximo es $\geq c^2$ y $\sigma_j(M)^2 \geq c^2$. $\square$

Lema 8.2 (Una matriz de rango $\leq k$ no acerca a A más que $\sigma_{k+j}(A)$). *Sean A y B matrices de $m \times n$ con $\text{rango } B \leq k < n$. Entonces $\sigma_j(A - B) \geq \sigma_{k+j}(A)$ para $j = 1, \dots, n - k$.*

i Borrador

En el subespacio generado por los primeros $k + j$ vectores singulares de A , la matriz A amplifica al menos por σ_{k+j} . Ese subespacio corta al núcleo de B en un subespacio de dimensión $\geq j$, donde $A - B$ es igual a A . El Lema 8.1 concluye.

Demostración. Sea $A = U\Sigma V'$ y $W = (v_1 \cdots v_{k+j})$, de $n \times (k+j)$. Para $x = Wc$ con $c \in \mathbb{R}^{k+j}$, $\|x\| = \|c\|$ (columnas ortonormales) y $Ax = \sum_{i \leq k+j} \sigma_i c_i u_i$, de modo que, como $\sigma_i \geq \sigma_{k+j}$ para $i \leq k+j$,

$$\|Ax\|^2 = \sum_{i \leq k+j} \sigma_i^2 c_i^2 \geq \sigma_{k+j}^2 \|c\|^2 = \sigma_{k+j}^2 \|x\|^2.$$

La matriz BW de $m \times (k+j)$ tiene rango $\leq \text{rango } B \leq k$ (Clase 3: el rango de un producto no supera el de sus factores), así que su espacio nulo tiene dimensión $\geq (k+j) - k = j$ (rango más nulidad). Sea $T = \{Wc : BWc = 0\}$. Como W tiene columnas independientes, $\dim T = \dim N(BW) \geq j$. Para $x \in T$, $Bx = 0$ y entonces $\|(A-B)x\| = \|Ax\| \geq \sigma_{k+j}\|x\|$. Elegimos un subespacio de T de dimensión exactamente j y aplicamos el Lema 8.1 con $M = A - B$ y $c = \sigma_{k+j}(A)$. $\square$

Teorema 8.1 (Eckart–Young–Mirsky). Sea A de $m \times n$ y $0 \leq k < n$. Para toda matriz B de $m \times n$ con $\text{rango } B \leq k$,

$$\begin{aligned} \|A - B\|_2 &\geq \sigma_{k+1}(A) = \|A - A_k\|_2, \\ \|A - B\|_F^2 &\geq \sum_{i=k+1}^n \sigma_i(A)^2 = \|A - A_k\|_F^2. \end{aligned}$$

Borrador

La norma espectral de una matriz es su mayor valor singular, y su norma de Frobenius al cuadrado es la suma de los cuadrados de todos. El Lema 8.2 con $j = 1$ da la primera desigualdad y, sumando sobre j , la segunda. Los lados derechos son los de la Proposición 6.1.

Demostración. Si $k \geq r = \text{rango } A$, entonces $A_k = A$ y $\sigma_{k+1}(A) = 0$, y las desigualdades son triviales (las normas son ≥ 0). Sea entonces $k < r$.

Norma espectral. Para toda matriz M , $\|M\|_2 = \max_{\|x\|=1} \|Mx\|$ y $\|Mx\|^2 = x'M'Mx$ es el cociente de Rayleigh de $M'M$ cuando $\|x\| = 1$, cuyo máximo es el mayor valor propio (Clase 8): $\|M\|_2 = \sigma_1(M)$. El Lema 8.2 con $j = 1$ da $\|A - B\|_2 = \sigma_1(A - B) \geq \sigma_{k+1}(A)$. La igualdad $\|A - A_k\|_2 = \sigma_{k+1}$ es la Proposición 6.1.

Norma de Frobenius. $\|A - B\|_F^2 = \text{tr}((A - B)'(A - B))$ es la suma de los valores propios de $(A - B)'(A - B)$, es decir, $\sum_{j=1}^n \sigma_j(A - B)^2$. Todos los términos son ≥ 0 ; descartamos los últimos k y usamos el Lema 8.2 en los demás:

$$\|A - B\|_F^2 \geq \sum_{j=1}^{n-k} \sigma_j(A - B)^2 \geq \sum_{j=1}^{n-k} \sigma_{k+j}(A)^2 = \sum_{i=k+1}^n \sigma_i(A)^2.$$

La igualdad con $\|A - A_k\|_F^2$ es la Proposición 6.1. $\square$

Para $A = \begin{pmatrix} 3 & 0 \\ 4 & 5 \end{pmatrix}$ ($\sigma_1 = 3\sqrt{5} \approx 6,71$, $\sigma_2 = \sqrt{5} \approx 2,24$) y $k = 1$,

la mejor matriz de rango uno es $A_1 = \frac{3}{2} \begin{pmatrix} 1 & 1 \\ 3 & 3 \end{pmatrix}$ (Ejemplo 2.1)

y el error es $\sigma_2 = \sqrt{5}$ en la norma espectral y en la de Frobenius. Cualquier otra aproximación de rango uno es peor: si se conserva solo la primera columna, $B = \begin{pmatrix} 3 & 0 \\ 4 & 0 \end{pmatrix}$, entonces $A - B = \begin{pmatrix} 0 & 0 \\ 0 & 5 \end{pmatrix}$ y $\|A - B\|_2 = 5 > \sqrt{5}$; si se conserva solo la segunda fila, $B = \begin{pmatrix} 0 & 0 \\ 4 & 5 \end{pmatrix}$, $A - B = \begin{pmatrix} 3 & 0 \\ 0 & 0 \end{pmatrix}$ y el error es $3 > \sqrt{5}$.

Corolario 8.1 (Distancia a las matrices singulares). Si A es cuadrada $n \times n$ e invertible, la menor distancia espectral de A a una matriz singular es $\sigma_n = 1/\|A^{-1}\|_2$, alcanzada en $B = A - \sigma_n u_n v_n'$.

El corolario se demuestra en el Ejercicio 9.7: por eso un σ_n muy chico significa una matriz “casi singular” y un $\kappa(A) = \sigma_1/\sigma_n$ grande significa un sistema difícil de resolver (Clase 10).

En más dimensiones

Todo lo de esta clase vale para $m \times n$ con las mismas demostraciones: la existencia de la SVD, la imagen de la bola como elipsoide, las bases de los cuatro subespacios, la pseudoinversa, el truncamiento óptimo y las componentes principales. Con m y n grandes lo que cambia es el cálculo: se obtienen solo los primeros k valores singulares con métodos iterativos (Clase 10) o aleatorizados, sin formar $A'A$. Con matrices complejas la SVD es $A = U\Sigma V^*$ con U, V uni-

tarias (Clase 11). Para regularizar problemas mal condicionados, la SVD truncada y la regresión ridge (Tikhonov) son filtros sobre los σ_i (Clase 14). En dimensión infinita, la SVD se extiende a los operadores compactos entre espacios de Hilbert (Schmidt, Eckart-Young, Hilbert-Schmidt), y la descomposición de Karhunen-Loève de un proceso aleatorio es la versión continua de las componentes principales: el curso de Álgebra lineal pura lo desarrolla.

9. Resumen

- **SVD:** toda matriz real de $m \times n$ y rango r se escribe $A = U\Sigma V' = \sum_{i \leq r} \sigma_i u_i v_i'$, con U, V ortogonales y $\sigma_1 \geq \dots \geq \sigma_r > 0$ (Teorema 2.1). Los σ_i^2 son los valores propios de $A'A$ y de AA' (Corolario 2.1). A mano: diagonalizar $A'A$ y definir $u_i = Av_i/\sigma_i$.
- **Geometría:** A gira, estira por los σ_i y gira. La esfera (bola) unidad va a un elipsoide de semiejes $\sigma_i u_i$ (Teorema 3.1); $\sigma_n \|x\| \leq \|Ax\| \leq \sigma_1 \|x\|$, $|\det A| = \prod \sigma_i$ y $\kappa = \sigma_1/\sigma_n$ (Corolario 3.1).
- **Subespacios:** $u_{1..r}$ (columnas), $u_{r+1..m}$ (nulo izquierdo), $v_{1..r}$ (filas) y $v_{r+1..n}$ (nulo) son bases ortonormales (Proposición 4.1).
- **Pseudoinversa:** $A^+ = V\Sigma^+U'$; $x^+ = A^+b$ es la solución de mínimos cuadrados de menor norma (Teorema 5.1); AA^+ y A^+A proyectan sobre $C(A)$ y $C(A')$, y $A^+ = (A'A)^{-1}A'$ si las columnas son independientes (Proposición 5.1).
- **Rango bajo:** $A_k = \sum_{i \leq k} \sigma_i u_i v_i'$ tiene error $\|A - A_k\|_2 = \sigma_{k+1}$ y $\|A - A_k\|_F^2 = \sum_{i > k} \sigma_i^2$ (Proposición 6.1).
- **Componentes principales:** para datos centrados, v_1 es la recta de menor distancia perpendicular y $\text{gen}(v_1, v_2)$ el plano; la varianza en el eje v_i es $\sigma_i^2/(n-1)$ (Proposición 7.1). No coincide con la recta de MCO.
- ★ **Eckart-Young-Mirsky:** A_k es la mejor aproximación de rango $\leq k$ en las normas espectral y de Frobenius (Teorema 8.1); la distancia a las singulares es σ_n (Corolario 8.1).

10. Ejercicios

Ejercicio 9.1. Sea $A = \begin{pmatrix} 2 & 2 \\ -1 & 1 \end{pmatrix}$. (a) Calcula su SVD. (b) Describe la elipse imagen de la circunferencia unidad. (c) Calcula $\det A$, $\|A\|_2$ y $\kappa(A)$. (d) Calcula A^{-1} con la SVD y verifica con la fórmula 2×2 de la Clase 2.

Solución 9.1

(a) $A'A = \begin{pmatrix} 2 & -1 \\ 2 & 1 \end{pmatrix} \begin{pmatrix} 2 & 2 \\ -1 & 1 \end{pmatrix} = \begin{pmatrix} 5 & 3 \\ 3 & 5 \end{pmatrix}$, con $\tau = 10$, $\Delta = 16$ y $\lambda^2 - 10\lambda + 16 = (\lambda - 8)(\lambda - 2)$. Valores singulares $\sigma_1 = 2\sqrt{2}$ y $\sigma_2 = \sqrt{2}$. Para $\lambda = 8$: $\begin{pmatrix} -3 & 3 \\ 3 & -3 \end{pmatrix}$ da $v_1 = \frac{1}{\sqrt{2}}(1, 1)'$; para $\lambda = 2$: $v_2 = \frac{1}{\sqrt{2}}(1, -1)'$. Entonces $Av_1 = \frac{1}{\sqrt{2}}(4, 0)' = 2\sqrt{2}(1, 0)'$, luego $u_1 = (1, 0)'$; $Av_2 = \frac{1}{\sqrt{2}}(0, -2)' = \sqrt{2}(0, -1)'$, luego $u_2 = (0, -1)'$. Así $U = \begin{pmatrix} 1 & 0 \\ 0 & -1 \end{pmatrix}$, $\Sigma = \text{diag}(2\sqrt{2}, \sqrt{2})$, $V = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 & 1 \\ 1 & -1 \end{pmatrix}$. Comprobación: $2\sqrt{2}u_1v_1' = 2 \begin{pmatrix} 1 & 1 \\ 0 & 0 \end{pmatrix}$ y $\sqrt{2}u_2v_2' = \begin{pmatrix} 0 & 0 \\ -1 & 1 \end{pmatrix}$, cuya suma es $\begin{pmatrix} 2 & 2 \\ -1 & 1 \end{pmatrix} \checkmark$.

(b) Elipse de semiejes $2\sqrt{2} \approx 2,83$ en la dirección $(1, 0)$ y $\sqrt{2} \approx 1,41$ en la dirección $(0, -1)$, es decir, los ejes coordenados: $\frac{x^2}{8} + \frac{y^2}{2} = 1$.

(c) $\det A = 2 \cdot 1 - 2 \cdot (-1) = 4 = 2\sqrt{2} \cdot \sqrt{2} \checkmark$; $\|A\|_2 = \sigma_1 = 2\sqrt{2}$; $\kappa(A) = \frac{2\sqrt{2}}{\sqrt{2}} = 2$.

(d) $A^{-1} = V\Sigma^{-1}U' = \frac{1}{2\sqrt{2}}v_1u_1' + \frac{1}{\sqrt{2}}v_2u_2' = \frac{1}{2\sqrt{2}\sqrt{2}} \begin{pmatrix} 1 & 0 \\ 1 & 0 \end{pmatrix} + \frac{1}{\sqrt{2}\sqrt{2}} \begin{pmatrix} 0 & -1 \\ 0 & 1 \end{pmatrix} = \frac{1}{4} \begin{pmatrix} 1 & 0 \\ 1 & 0 \end{pmatrix} + \frac{1}{2} \begin{pmatrix} 0 & -1 \\ 0 & 1 \end{pmatrix} = \frac{1}{4} \begin{pmatrix} 1 & -2 \\ 1 & 2 \end{pmatrix}$. La fórmula de la Clase 2

da $\frac{1}{4} \begin{pmatrix} 1 & -2 \\ 1 & 2 \end{pmatrix}$ (intercambiar la diagonal, cambiar el signo de la otra y dividir por $\det = 4$) ✓. Además $\|A^{-1}\|_2 = 1/\sigma_2 = \frac{1}{\sqrt{2}}$.

Ejercicio 9.2. Sea $A = \begin{pmatrix} 1 & 1 & 0 \\ 0 & 1 & 1 \\ 1 & 0 & 1 \end{pmatrix}$. (a) Calcula $A'A$ y sus valores propios, y de ahí los valores singulares. (b) Encuentra una SVD completa. (c) Los valores singulares se repiten: ¿qué libertad hay para elegir los vectores? Muestra otro par (v_2, u_2) válido. (d) Describe la imagen de la esfera unidad y comprueba $|\det A| = \sigma_1 \sigma_2 \sigma_3$.

💡 Solución 9.2

- (a) Las columnas de A son $(1, 0, 1)'$, $(1, 1, 0)'$ y $(0, 1, 1)'$, cada una de largo al cuadrado 2, y dos columnas distintas tienen producto interno 1. Luego $A'A = \begin{pmatrix} 2 & 1 & 1 \\ 1 & 2 & 1 \\ 1 & 1 & 2 \end{pmatrix} = I + J$, que (Clase 8) tiene valores propios 4, 1, 1. Los valores singulares son $\sigma_1 = 2$, $\sigma_2 = \sigma_3 = 1$.
- (b) Para $\lambda = 4$: $v_1 = \frac{1}{\sqrt{3}}(1, 1, 1)'$ y $Av_1 = \frac{1}{\sqrt{3}}(2, 2, 2)' = 2v_1$, así que $u_1 = v_1$. Para $\lambda = 1$ el espacio propio es el plano $x_1 + x_2 + x_3 = 0$; elegimos la base ortonormal $v_2 = \frac{1}{\sqrt{2}}(1, -1, 0)'$ y $v_3 = \frac{1}{\sqrt{6}}(1, 1, -2)'$. Entonces $Av_2 = \frac{1}{\sqrt{2}}(1 - 1, 0 - 1, 1 - 0)' = \frac{1}{\sqrt{2}}(0, -1, 1)'$, luego $u_2 = \frac{1}{\sqrt{2}}(0, -1, 1)'$; y $Av_3 = \frac{1}{\sqrt{6}}(1 + 1, 1 - 2, 1 - 2)' = \frac{1}{\sqrt{6}}(2, -1, -1)'$, luego $u_3 = \frac{1}{\sqrt{6}}(2, -1, -1)'$. Son perpendiculares: $u_1 \cdot u_2 \propto 0 - 1 + 1 = 0$, $u_1 \cdot u_3 \propto 2 - 1 - 1 = 0$, $u_2 \cdot u_3 \propto 0 + 1 - 1 = 0$.
- (c) Cualquier par ortonormal del plano $x_1 + x_2 + x_3 = 0$ sirve como (v_2, v_3) , y $u_i = Av_i$ (con $\sigma = 1$) sale solo. Por ejemplo, $v'_2 = \frac{1}{\sqrt{2}}(1, 0, -1)'$ da $Av'_2 = \frac{1}{\sqrt{2}}(1, -1, 0)'$, es decir, $u'_2 = \frac{1}{\sqrt{2}}(1, -1, 0)'$ (de largo 1).

Los valores singulares están determinados; los vectores del valor repetido, no.

- (d) La imagen de la esfera unidad es un elipsoide con semieje 2 en la dirección $(1, 1, 1)$ y semiejes 1 y 1 en el plano perpendicular: un elipsoide **de revolución** alargado (un balón de rugby). $\det A = 1(1 - 0) - 1(0 - 1) + 0 = 2 = 2 \cdot 1 \cdot 1 \checkmark$ (con la definición por cofactores de la primera fila de la Clase 4).

Ejercicio 9.3. Sea $N = \begin{pmatrix} 2 & 4 \\ 1 & 2 \end{pmatrix}$. (a) Escribe N como producto de una columna por una fila, y de ahí su SVD y N^+ . (b) Resuelve $Nx = b$ con norma mínima para $b = (2, 1)'$ y describe todas las soluciones. (c) Para $b = (1, 3)'$, calcula la mejor aproximación Nx de b , el x^+ y el residuo. (d) Calcula N^+b para $b = (1, -2)'$ e interpreta.

💡 Solución 9.3

(a) $N = \begin{pmatrix} 2 \\ 1 \end{pmatrix} (1 \ 2)$, y $\|(2, 1)\| = \|(1, 2)\| = \sqrt{5}$. Entonces $\sigma_1 = \sqrt{5} \cdot \sqrt{5} = 5$, $u_1 = \frac{1}{\sqrt{5}}(2, 1)'$, $v_1 = \frac{1}{\sqrt{5}}(1, 2)'$ (y $\sigma_2 = 0$, con $u_2 = \frac{1}{\sqrt{5}}(1, -2)'$, $v_2 = \frac{1}{\sqrt{5}}(2, -1)'$). La pseudoinversa es $N^+ = \frac{1}{5}v_1u_1' = \frac{1}{25}\begin{pmatrix} 1 \\ 2 \end{pmatrix}\begin{pmatrix} 2 & 1 \end{pmatrix} = \frac{1}{25}\begin{pmatrix} 2 & 1 \\ 4 & 2 \end{pmatrix}$.

(b) $N^+b = \frac{1}{25}(4 + 1, 8 + 2)' = (\frac{1}{5}, \frac{2}{5})'$. Comprobación: $N(\frac{1}{5}, \frac{2}{5})' = (\frac{2}{5} + \frac{8}{5}, \frac{1}{5} + \frac{4}{5})' = (2, 1)'$ $\checkmark$. Como $N(N) = \text{gen}(2, -1)'$, las soluciones son $(\frac{1}{5}, \frac{2}{5})' + t(2, -1)'$, y la de norma mínima es $t = 0$: x^+ es perpendicular a $(2, -1)'$ ($\frac{2}{5} - \frac{2}{5} = 0$), de modo que $\|x^+ + t(2, -1)'\|^2 = \|x^+\|^2 + 5t^2$, con $\|x^+\|^2 = \frac{1}{25} + \frac{4}{25} = \frac{1}{5}$.

(c) $C(N) = \text{gen}(2, 1)'$. La proyección de $b = (1, 3)'$ es $\frac{b \cdot (2, 1)}{5}(2, 1)' = \frac{5}{5}(2, 1)' = (2, 1)'$. Es el mismo punto

que en (b), así que $x^+ = N^+(1, 3)' = \frac{1}{25}(2 + 3, 4 + 6)' = (\frac{1}{5}, \frac{2}{5})'$. El residuo es $b - (2, 1)' = (-1, 2)'$, de $\|\cdot\|^2 = 5$.

- (d) $N^+(1, -2)' = \frac{1}{25}(2 - 2, 4 - 4)' = (0, 0)'$. El vector $b = (1, -2)'$ es perpendicular a $C(N) = \text{gen}(2, 1)'$ ($2 - 2 = 0$), está en $N(N')$: la mejor aproximación de b por vectores de $C(N)$ es 0, y la solución de norma mínima de $Nx = 0$ es $x = 0$.

Ejercicio 9.4. Cuatro puntos del plano: $(3, 1)$, $(1, 3)$, $(-3, -1)$, $(-1, -3)$. (a) Calcula $X'X$, su SVD y las dos componentes principales. (b) Calcula las puntuaciones, las varianzas ($n - 1 = 3$) y la fracción explicada por la primera. (c) Calcula la suma de las distancias al cuadrado a la primera componente y compárala con σ_2^2 . (d) Compara con la recta de MCO de x_2 sobre x_1 y con la aproximación de rango uno X_1 .

Solución 9.4

- (a) $\sum x_1^2 = 9 + 1 + 9 + 1 = 20$ y $\sum x_1 x_2 = 3 + 3 + 3 + 3 = 12$, así que $X'X = \begin{pmatrix} 20 & 12 \\ 12 & 20 \end{pmatrix}$, con $\tau = 40$ y $\Delta = 400 - 144 = 256$, es decir $\lambda^2 - 40\lambda + 256 = (\lambda - 32)(\lambda - 8)$. Valores singulares $4\sqrt{2}$ y $2\sqrt{2}$; componentes principales $v_1 = \frac{1}{\sqrt{2}}(1, 1)'$ y $v_2 = \frac{1}{\sqrt{2}}(1, -1)'$.
- (b) Puntuaciones: $z_1 = Xv_1 = \frac{1}{\sqrt{2}}(4, 4, -4, -4)'$ y $z_2 = Xv_2 = \frac{1}{\sqrt{2}}(2, -2, -2, 2)'$. Comprobación: $\|z_1\|^2 = 4 \cdot 8 = 32$ y $\|z_2\|^2 = 4 \cdot 2 = 8$. Las varianzas son $\frac{32}{3}$ y $\frac{8}{3}$; la primera componente explica $\frac{32}{40} = 80\%$.
- (c) La distancia de (x_1, x_2) a la recta $x_2 = x_1$ es $|x_1 - x_2|/\sqrt{2}$: $\frac{2}{\sqrt{2}} = \sqrt{2}$ para los cuatro puntos, así que la suma de cuadrados es $4 \cdot 2 = 8 = \sigma_2^2 \checkmark$.
- (d) La pendiente de MCO es $\frac{12}{20} = \frac{3}{5}$, distinta de la pendiente 1 de la primera componente. Su suma de cua-

drados vertical es $\sum x_2^2 - \frac{3}{5} \sum x_1 x_2 = 20 - 7,2 = 12,8$.
 La aproximación de rango uno es $X_1 = X v_1 v_1' = z_1 v_1'$: cada punto se proyecta sobre la recta $x_2 = x_1$,
 $(3, 1) \mapsto (2, 2)$, $(1, 3) \mapsto (2, 2)$, $(-3, -1) \mapsto (-2, -2)$,
 $(-1, -3) \mapsto (-2, -2)$, con $\|X - X_1\|_F^2 = 8 = \sigma_2^2$ (Proposición 6.1).

Ejercicio 9.5. Considera la imagen de 3×3 píxeles $A =$

$\begin{pmatrix} 0 & 3 & 1 \\ 0 & 1 & 3 \\ 3 & 0 & 0 \end{pmatrix}$, cuyos valores singulares son 4, 3, 2. (a) Verifica que

$v_1 = \frac{1}{\sqrt{2}}(0, 1, 1)'$, $v_2 = (1, 0, 0)'$ y $v_3 = \frac{1}{\sqrt{2}}(0, 1, -1)'$ son vectores singulares derechos y calcula los u_i . (b) Escribe A_1 y A_2 . (c) Calcula $\|A - A_k\|_2$, $\|A - A_k\|_F$ y la fracción de energía de A_1 y A_2 .

(d) Comprueba el teorema de Eckart-Young con $B = \begin{pmatrix} 0 & 0 & 0 \\ 0 & 0 & 0 \\ 3 & 0 & 0 \end{pmatrix}$ (rango uno).

Solución 9.5

(a) $A'A = \begin{pmatrix} 9 & 0 & 0 \\ 0 & 10 & 6 \\ 0 & 6 & 10 \end{pmatrix}$ (las columnas son $(0, 0, 3)'$, $(3, 1, 0)'$ y $(1, 3, 0)'$). Entonces $A'Av_2 = 9v_2$; $A'A(0, 1, 1)' = (0, 16, 16)' = 16(0, 1, 1)'$; $A'A(0, 1, -1)' = (0, 4, -4)' = 4(0, 1, -1)'$. Los valores propios 16, 9, 4 dan $\sigma = 4, 3, 2$ (con v_1 para 16, v_2 para 9, v_3 para 4). Los vectores izquierdos: $Av_1 = \frac{1}{\sqrt{2}}(3 + 1, 1 + 3, 0)' = \frac{4}{\sqrt{2}}(1, 1, 0)'$, luego $u_1 = \frac{1}{\sqrt{2}}(1, 1, 0)'$; $Av_2 = (0, 0, 3)'$, luego $u_2 = (0, 0, 1)'$; $Av_3 = \frac{1}{\sqrt{2}}(3 - 1, 1 - 3, 0)' = \frac{2}{\sqrt{2}}(1, -1, 0)'$, luego $u_3 = \frac{1}{\sqrt{2}}(1, -1, 0)'$.

(b) $A_1 = 4u_1v_1' = 4 \cdot \frac{1}{2} \begin{pmatrix} 1 \\ 1 \\ 0 \end{pmatrix} \begin{pmatrix} 0 & 1 & 1 \end{pmatrix} = \begin{pmatrix} 0 & 2 & 2 \\ 0 & 2 & 2 \\ 0 & 0 & 0 \end{pmatrix}$ y

$$A_2 = A_1 + 3u_2v_2' = \begin{pmatrix} 0 & 2 & 2 \\ 0 & 2 & 2 \\ 3 & 0 & 0 \end{pmatrix}.$$

(c) $A - A_1 = \begin{pmatrix} 0 & 1 & -1 \\ 0 & -1 & 1 \\ 3 & 0 & 0 \end{pmatrix}$: $\|A - A_1\|_F^2 = 1 + 1 + 1 + 1 + 9 = 13 = 9 + 4$ y $\|A - A_1\|_2 = \sigma_2 = 3$. $A - A_2 = \begin{pmatrix} 0 & 1 & -1 \\ 0 & -1 & 1 \\ 0 & 0 & 0 \end{pmatrix}$: $\|A - A_2\|_F^2 = 4 = \sigma_3^2$ y $\|A - A_2\|_2 = \sigma_3 = 2$. La energía total es $\|A\|_F^2 = 0 + 9 + 1 + 0 + 1 + 9 + 9 = 29 = 16 + 9 + 4$. Fracciones: $A_1, \frac{16}{29} \approx 55,2\%$; $A_2, \frac{25}{29} \approx 86,2\%$.

(d) $A - B = \begin{pmatrix} 0 & 3 & 1 \\ 0 & 1 & 3 \\ 0 & 0 & 0 \end{pmatrix}$ tiene $(A - B)'(A - B) = \begin{pmatrix} 0 & 0 & 0 \\ 0 & 10 & 6 \\ 0 & 6 & 10 \end{pmatrix}$, de valores propios 16, 4, 0. Entonces $\|A - B\|_2 = 4 \geq \sigma_2 = 3$ y $\|A - B\|_F^2 = 20 \geq 13$, como dice el teorema (la mejor, A_1 , da 3 y 13).

Ejercicio 9.6. Sea $C = \begin{pmatrix} 1 & -1 & 0 \\ 0 & 1 & -1 \\ -1 & 0 & 1 \end{pmatrix}$, la matriz de diferencias alrededor de un triángulo: $Cx = (x_1 - x_2, x_2 - x_3, x_3 - x_1)'$. (a) Calcula $C'C$ y la SVD. (b) Da bases ortonormales de los cuatro subespacios. (c) Encuentra C^+ y úsala para resolver $Cx = b$ con norma mínima para $b = (1, 1, -2)'$. (d) Interpreta.

Solución 9.6

(a) Las columnas son $(1, 0, -1)'$, $(-1, 1, 0)'$ y $(0, -1, 1)'$; cada una tiene largo al cuadrado 2 y cada par tiene producto interno -1 . Luego

$$C'C = \begin{pmatrix} 2 & -1 & -1 \\ -1 & 2 & -1 \\ -1 & -1 & 2 \end{pmatrix} = 3I - J, \text{ que cumple}$$

$C'C(1, 1, 1)' = 0$ y $C'Cx = 3x$ si $x_1 + x_2 + x_3 = 0$. Valores propios 3, 3, 0, valores singulares $\sqrt{3}, \sqrt{3}, 0$ (rango 2). Con la base ortonormal del plano $x_1 + x_2 + x_3 = 0$ dada por $v_1 = \frac{1}{\sqrt{2}}(1, -1, 0)'$ y $v_2 = \frac{1}{\sqrt{6}}(1, 1, -2)'$, y $v_3 = \frac{1}{\sqrt{3}}(1, 1, 1)'$: $Cv_1 = \frac{1}{\sqrt{2}}(2, -1, -1)'$, $u_1 = \frac{Cv_1}{\sqrt{3}} = \frac{1}{\sqrt{6}}(2, -1, -1)'$; $Cv_2 = \frac{1}{\sqrt{6}}(0, 3, -3)'$, $u_2 = \frac{Cv_2}{\sqrt{3}} = \frac{1}{\sqrt{2}}(0, 1, -1)'$; y $u_3 = \frac{1}{\sqrt{3}}(1, 1, 1)'$ (perpendicular a los otros dos y en $N(C')$, porque $C'(1, 1, 1)' = 0$).

(b) $C(C) = \text{gen}(u_1, u_2) = \text{el plano } x_1 + x_2 + x_3 = 0$ (las diferencias suman cero); $N(C') = \text{gen}(u_3) = \text{gen}(1, 1, 1)'$; $C(C') = \text{gen}(v_1, v_2) = \text{el mismo plano } x_1 + x_2 + x_3 = 0$; $N(C) = \text{gen}(v_3) = \text{gen}(1, 1, 1)'$ (las constantes).

(c) Como los dos valores singulares no nulos son iguales, $\Sigma^+ = \frac{1}{\sqrt{3}} \text{diag}(1, 1, 0)$ y $C^+ = V\Sigma^+U' = \frac{1}{\sqrt{3}} \sum_{i \leq 2} v_i u_i'$. Como además $C' = V\Sigma'U' = \sqrt{3} \sum_{i \leq 2} v_i u_i'$, resulta

$$C^+ = \frac{1}{3}C' = \frac{1}{3} \begin{pmatrix} 1 & 0 & -1 \\ -1 & 1 & 0 \\ 0 & -1 & 1 \end{pmatrix}. \text{ Para } b = (1, 1, -2)'$$

($\in C(C)$, suma cero): $C'b = (1 + 2, -1 + 1, -1 - 2)' = (3, 0, -3)'$ y $x^+ = (1, 0, -1)'$. Comprobación: $Cx^+ = (1 - 0, 0 + 1, -1 - 1)' = (1, 1, -2)'$ ✓, y $x^+ \perp (1, 1, 1)'$ ($1 + 0 - 1 = 0$). Las demás soluciones son $x^+ + t(1, 1, 1)'$.

(d) x son los potenciales en los tres nodos y Cx son las diferencias de potencial en las tres aristas del triángulo; la matriz no ve las constantes. Dadas las diferencias (que deben sumar cero, ley de voltajes de Kirchhoff), el potencial se recupera salvo una constante, y x^+ es el de suma cero (promedio 0), el de menor norma.

Ejercicio 9.7 ★. (a) Demuestra el Corolario 8.1: si A es $n \times n$ inver-

tible, la menor distancia espectral de A a las matrices singulares es $\sigma_n(A)$, y vale $1/\|A^{-1}\|_2$. (b) Comprueba con $A = \begin{pmatrix} 3 & 0 \\ 4 & 5 \end{pmatrix}$ y con la matriz $\begin{pmatrix} 2 & 2 \\ -1 & 1 \end{pmatrix}$ del Ejercicio 9.1: halla la matriz singular más cercana en cada caso y su distancia.

 Solución 9.7 ★

(a) Una matriz B de $n \times n$ es singular si y solo si $\text{rango } B \leq n - 1$. Por el Teorema 8.1 con $k = n - 1$, $\|A - B\|_2 \geq \sigma_n(A)$ para toda B singular. La matriz $B^* = A_{n-1} = A - \sigma_n u_n v_n'$ tiene rango $n - 1$, es singular y $\|A - B^*\|_2 = \|\sigma_n u_n v_n'\|_2 = \sigma_n$ (Proposición 6.1). Entonces la menor distancia es exactamente σ_n . Falta $\sigma_n = 1/\|A^{-1}\|_2$: de $A = U\Sigma V'$, $A^{-1} = V\Sigma^{-1}U'$, y $(A^{-1})'A^{-1} = U\Sigma^{-2}U'$ tiene valores propios $1/\sigma_i^2$; el mayor es $1/\sigma_n^2$ y $\|A^{-1}\|_2 = 1/\sigma_n$ (la norma espectral es la raíz del mayor valor propio de $M'M$, por Rayleigh).

(b) Para $A = \begin{pmatrix} 3 & 0 \\ 4 & 5 \end{pmatrix}$, $\sigma_2 = \sqrt{5}$, $u_2 = \frac{1}{\sqrt{10}}(3, -1)'$, $v_2 = \frac{1}{\sqrt{2}}(1, -1)'$ (Ejemplo 2.1): $\sigma_2 u_2 v_2' = \frac{1}{2} \begin{pmatrix} 3 & -3 \\ -1 & 1 \end{pmatrix}$ y $B^* = A - \frac{1}{2} \begin{pmatrix} 3 & -3 \\ -1 & 1 \end{pmatrix} = \begin{pmatrix} \frac{3}{2} & \frac{3}{2} \\ \frac{5}{2} & \frac{5}{2} \end{pmatrix}$, que tiene $\det B^* = \frac{27}{4} - \frac{27}{4} = 0$. La distancia es $\sigma_2 = \sqrt{5} \approx 2,24$ (y $A^{-1} = \frac{1}{15} \begin{pmatrix} 5 & 0 \\ -4 & 3 \end{pmatrix}$ tiene $\|A^{-1}\|_2 = \frac{1}{\sqrt{5}}$).

Para $\begin{pmatrix} 2 & 2 \\ -1 & 1 \end{pmatrix}$, $\sigma_2 = \sqrt{2}$, $u_2 = (0, -1)'$ y $v_2 = \frac{1}{\sqrt{2}}(1, -1)'$ (Ejercicio 9.1): $\sigma_2 u_2 v_2' = \begin{pmatrix} 0 & 0 \\ -1 & 1 \end{pmatrix}$ y $B^* = \begin{pmatrix} 2 & 2 \\ 0 & 0 \end{pmatrix}$, singular, a distancia $\sqrt{2} \approx 1,41$. Comparación: anular la fila $(-1, 1)$ completa daría la misma matriz singular, pero anular la fila $(2, 2)$ da $\begin{pmatrix} 0 & 0 \\ -1 & 1 \end{pmatrix}$ a distancia $\|(2, 2)\| = 2\sqrt{2} > \sqrt{2}$, peor.