

Clase 3 · Mínimos cuadrados ordinarios

Derivación, geometría y el teorema de Frisch-Waugh-Lovell

Contenido

1	De la población a la muestra	2
2	Derivación del estimador	2
2.1	El caso de regresión simple	4
3	Geometría: proyección sobre el espacio columna	4
4	Bondad de ajuste: el R^2	6
4.1	El R^2 nunca baja	8
5	El teorema de Frisch-Waugh-Lovell	9
5.1	Tres corolarios que usarás siempre	11
6	★ Postgrado: leverage e influencia	12
7	Resumen	14
8	Ejercicios	14

1. De la población a la muestra

En la Clase 2 encontramos el mejor predictor lineal *poblacional*:

$$\beta = \arg \min_b \mathbb{E}[(y - x'b)^2] = (\mathbb{E}[xx'])^{-1} \mathbb{E}[xy].$$

El problema es que no conocemos la distribución de (y, x) , así que no podemos calcular esas esperanzas. Lo que sí tenemos es una muestra $\{(y_i, x_i)\}_{i=1}^n$. La idea más natural del mundo, llamada **principio de analogía**, es reemplazar cada esperanza poblacional por un promedio muestral:¹

$$\mathbb{E}[(y - x'b)^2] \rightsquigarrow \frac{1}{n} \sum_{i=1}^n (y_i - x_i'b)^2.$$

Minimizar esto último es lo que llamamos **mínimos cuadrados ordinarios** (MCO). Esta clase trata de lo que pasa en la muestra, con álgebra pura: todavía no hay probabilidades. Todo lo que probemos hoy es cierto para *cualquier* conjunto de números y y X , sean datos reales, simulados o inventados en una servilleta.

¹ Goldberger lo llamaba *analogy principle*. Si no sabes qué hacer, haz en la muestra lo que harías en la población. Es sorprendente cuántas veces este consejo ingenuo produce estimadores óptimos.

2. Derivación del estimador

Definimos la **suma de residuos al cuadrado** como función de un candidato $b \in \mathbb{R}^k$:

$$S(b) = \sum_{i=1}^n (y_i - x_i'b)^2 = (y - Xb)'(y - Xb).$$

Definición 2.1 (Estimador de MCO). El estimador de mínimos cuadrados ordinarios es $\hat{\beta} = \arg \min_{b \in \mathbb{R}^k} S(b)$. Definimos los **valores ajustados** $\hat{y} = X\hat{\beta}$ y los **residuos** $\hat{u} = y - X\hat{\beta}$.

Teorema 2.1 (Fórmula de MCO). Si $\text{rango}(X) = k$, entonces el minimizador de $S(b)$ existe, es único y

$$\hat{\beta} = (X'X)^{-1}X'y. \quad (1)$$

Además, los residuos satisfacen las **ecuaciones normales**

$$X'\hat{u} = 0. \quad (2)$$

Voy a demostrar esto de dos maneras. La primera es la que todos aprenden (cálculo). La segunda es la que yo prefiero (álgebra), porque demuestra de golpe que el mínimo es global y único.

i Borrador (vía cálculo)

Expando: $S(b) = y'y - b'X'y - y'Xb + b'X'Xb$. Como $y'Xb$ es un escalar, es igual a su transpuesta $b'X'y$. Así que $S(b) = y'y - 2b'X'y + b'X'Xb$. Con las derivadas matriciales de la Clase 1 ($\partial(a'b)/\partial b = a$ y $\partial(b'Ab)/\partial b = 2Ab$ para A simétrica):

$$\frac{\partial S}{\partial b} = -2X'y + 2X'Xb.$$

Igualo a cero: $X'Xb = X'y$. Como $X'X$ es invertible (rango completo), $b = (X'X)^{-1}X'y$. La hessiana es $2X'X \succ 0$, así que S es estrictamente convexa y el punto crítico es el mínimo global.

Esto está bien, pero apoyarse en “estrictamente convexa $\Rightarrow$ el punto crítico es mínimo global” es usar un teorema de análisis que no demostramos. Hay una ruta que no necesita nada: completar el cuadrado, como en la Clase 2.

Demostración. Sea $\hat{\beta} = (X'X)^{-1}X'y$, que existe porque $X'X$ es invertible (Clase 1: $\text{rango}(X'X) = \text{rango}(X) = k$). Sea $\hat{u} = y - X\hat{\beta}$. Primero verificamos las ecuaciones normales:

$$X'\hat{u} = X'y - X'X(X'X)^{-1}X'y = X'y - X'y = 0.$$

Ahora tomemos cualquier $b \in \mathbb{R}^k$. Sumando y restando $X\hat{\beta}$,

$$y - Xb = \hat{u} + X(\hat{\beta} - b).$$

Entonces

$$\begin{aligned} S(b) &= (\hat{u} + X(\hat{\beta} - b))'(\hat{u} + X(\hat{\beta} - b)) \\ &= \hat{u}'\hat{u} + 2(\hat{\beta} - b)'X'\hat{u} + (\hat{\beta} - b)'X'X(\hat{\beta} - b) \\ &= S(\hat{\beta}) + (\hat{\beta} - b)'X'X(\hat{\beta} - b). \end{aligned} \quad \begin{array}{l} (X'\hat{u} = 0) \\ (3) \end{array}$$

Como $X'X > 0$ (Clase 1), el último término es ≥ 0 , con igualdad si y solo si $b = \hat{\beta}$. Luego $S(b) \geq S(\hat{\beta})$ para todo b , con igualdad solo en $b = \hat{\beta}$. $\square$

La identidad Ecuación 3 es la versión muestral exacta de la que usamos para el mejor predictor lineal en la Clase 2. **Misma demostración, distinto producto interno.** Esa repetición no es casualidad, y la sección ★ de la Clase 2 explica por qué.

Qué dicen las ecuaciones normales

$X'\hat{u} = 0$ son k ecuaciones: $\sum_i x_{ij}\hat{u}_i = 0$ para cada regresor j . Es decir, **los residuos no están correlacionados en la muestra con ningún regresor.** Es la versión muestral de $E[xu] = 0$. Y, otra vez, no es un supuesto: es lo que *define* a $\hat{\beta}$.

2.1. El caso de regresión simple

Con $x_i = (1, z_i)'$, las dos ecuaciones normales son

$$\sum_{i=1}^n (y_i - \hat{\alpha} - \hat{\gamma}z_i) = 0, \quad \sum_{i=1}^n z_i(y_i - \hat{\alpha} - \hat{\gamma}z_i) = 0.$$

Dividiendo la primera por n : $\hat{\alpha} = \bar{y} - \hat{\gamma}\bar{z}$. Sustituyendo en la segunda y usando que $\sum_i z_i(y_i - \bar{y}) = \sum_i (z_i - \bar{z})(y_i - \bar{y})$ (porque $\sum_i \bar{z}(y_i - \bar{y}) = 0$), y lo mismo para z ,

$$\hat{\gamma} = \frac{\sum_{i=1}^n (z_i - \bar{z})(y_i - \bar{y})}{\sum_{i=1}^n (z_i - \bar{z})^2} = \frac{\widehat{\text{Cov}}(z, y)}{\widehat{\text{Var}}(z)}.$$

Es la fórmula poblacional “covarianza sobre varianza” de la Clase 2, con momentos muestrales. El principio de analogía funciona.

3. Geometría: proyección sobre el espacio columna

Sustituyendo Ecuación 1 en las definiciones,

$$\hat{y} = X\hat{\beta} = X(X'X)^{-1}X'y = Py, \quad \hat{u} = y - Py = My,$$

donde P y M son las matrices de proyección y aniquiladora de la Clase 1. Todo lo que sabemos de ellas se traduce en hechos sobre MCO:

Teorema 3.1 (Geometría de MCO). Si $\text{rango}(X) = k$:

1. $\hat{y} = Py \in \text{col}(X)$ y $\hat{u} = My \perp \text{col}(X)$.
2. $\hat{y}'\hat{u} = 0$: valores ajustados y residuos son ortogonales.
3. $y'y = \hat{y}'\hat{y} + \hat{u}'\hat{u}$.
4. $\hat{u} = Mu$ si $y = X\beta + u$ para algún β : los residuos son una transformación lineal de los errores.

Demostración.

- (1) $\hat{y} = X\hat{\beta}$ es una combinación lineal de las columnas de X . Para cualquier $Xc \in \text{col}(X)$, $(Xc)'\hat{u} = c'X'\hat{u} = 0$ por las ecuaciones normales.
- (2) Es (1) con $c = \hat{\beta}$.
- (3) Es la identidad de Pitágoras de la Clase 1 con $z = y$: $y = Py + My$ y los sumandos son ortogonales.
- (4) $\hat{u} = My = M(X\beta + u) = MX\beta + Mu = Mu$, porque $MX = 0$.

□




Figura 1: MCO proyecta y ortogonalmente sobre el plano generado por las columnas de X . El residuo es el cateto perpendicular.

La figura dice todo: $\hat{y}$ es el punto del plano $\text{col}(X)$ más cercano a y , y la línea más corta de un punto a un plano es la perpendicular. **MCO es “bajar la perpendicular”**. Nota que el dibujo vive en $\mathbb{R}^n$, el espacio de *observaciones* (cada eje es una persona), no en el diagrama de dispersión habitual donde cada eje es una variable. Acostumbrarse a pensar en este espacio es uno de los saltos conceptuales del curso.²

El punto (4) merece una pausa: los residuos $\hat{u}$ no son los errores u . Son Mu , una versión “aplastada” de los errores donde se eliminó toda componente en $\text{col}(X)$. Por eso $\hat{u}$ vive en un subespacio de dimensión $n - k$ y por eso, en la Clase 4, para estimar σ^2 dividiremos por $n - k$ y no por n .

² Si $n = 3.000$, el dibujo vive en $\mathbb{R}^{3000}$. Yo tampoco puedo imaginarme $\mathbb{R}^{3000}$. El truco, que usa todo el mundo, es imaginar $\mathbb{R}^3$ y decir “ n ” en voz alta con mucha seguridad.

4. Bondad de ajuste: el R^2

Supongamos ahora que X contiene una columna de unos. Entonces la primera ecuación normal dice $\iota' \hat{u} = \sum_i \hat{u}_i = 0$, y de ahí salen varias propiedades:

Lema 4.1 (Consecuencias de incluir una constante). Si $\iota \in \text{col}(X)$, entonces:

1. $\sum_i \hat{u}_i = 0$.
2. $\hat{y} = \bar{y}$: el promedio de los ajustados es el promedio de y .
3. La recta (hiperplano) de regresión pasa por las medias: $\bar{y} = \bar{x}' \hat{\beta}$.

Demostración.

- (1) Como $\iota \in \text{col}(X)$, por Teorema 3.1 (1), $\iota' \hat{u} = 0$.
- (2) $y = \hat{y} + \hat{u}$; promediando y usando (1), $\bar{y} = \bar{\hat{y}}$.
- (3) $\bar{y} = \frac{1}{n} \sum_i x_i' \hat{\beta} = \bar{x}' \hat{\beta}$ y se aplica (2).

□

Definimos las tres sumas de cuadrados:

$$\text{SCT} = \sum_i (y_i - \bar{y})^2, \quad \text{SCE} = \sum_i (\hat{y}_i - \bar{y})^2, \quad \text{SCR} = \sum_i \hat{u}_i^2,$$

total, explicada y de residuos.³

³ Las siglas cambian de libro en libro y de idioma en idioma (SST/SSE/SSR, TSS/ESS/RSS...) y algunos libros intercambian qué significa la E y la R. Es una fuente inagotable de confusión en pruebas. Mira siempre la definición, nunca la sigla.

Teorema 4.1 (Descomposición de la suma de cuadrados). Si $\iota \in \text{col}(X)$, entonces $SCT = SCE + SCR$.

i Borrador

En notación matricial, con M^0 la matriz que resta la media, $SCT = y' M^0 y = \|M^0 y\|^2$. Quiero descomponer $M^0 y$ en dos piezas ortogonales. Como $y = \hat{y} + \hat{u}$, tengo $M^0 y = M^0 \hat{y} + M^0 \hat{u}$. Pero $\hat{u}$ ya tiene media cero, así que $M^0 \hat{u} = \hat{u}$. Entonces $M^0 y = M^0 \hat{y} + \hat{u}$, y solo tengo que ver que $M^0 \hat{y} \perp \hat{u}$. $M^0 \hat{y} = \hat{y} - \bar{y}\iota$, y tanto $\hat{y}$ como ι son ortogonales a $\hat{u}$. ¡Listo!

Demostración. Sea $M^0 = I - \frac{1}{n}\iota\iota'$. Por Lema 4.1, $\iota'\hat{u} = 0$ y entonces $M^0 \hat{u} = \hat{u} - \frac{1}{n}\iota(\iota'\hat{u}) = \hat{u}$. Luego

$$M^0 y = M^0 \hat{y} + M^0 \hat{u} = M^0 \hat{y} + \hat{u}.$$

Los dos sumandos son ortogonales: $(M^0 \hat{y})'\hat{u} = \hat{y}'\hat{u} - \bar{y}\iota'\hat{u} = 0 - 0 = 0$, usando Teorema 3.1 (2) y Lema 4.1 (1). Por Pitágoras,

$$SCT = \|M^0 y\|^2 = \|M^0 \hat{y}\|^2 + \|\hat{u}\|^2 = \sum_i (\hat{y}_i - \bar{y})^2 + SCR = SCE + SCR,$$

donde en el último paso usamos $\bar{\hat{y}} = \bar{y}$. □

Definición 4.1 (Coeficiente de determinación). Si $\iota \in \text{col}(X)$ y $SCT > 0$,

$$R^2 = \frac{SCE}{SCT} = 1 - \frac{SCR}{SCT}.$$

Por Teorema 4.1, $0 \leq R^2 \leq 1$. Es el análogo muestral del cociente $\text{Var}(m(x))/\text{Var}(y)$ de la Clase 2 (pero para la proyección *lineal*). Hay una interpretación más:

Proposición 4.1 (R^2 es una correlación al cuadrado). Si $\iota \in \text{col}(X)$, $R^2 = \widehat{\text{Corr}}(y, \hat{y})^2$.

Demostración. Usando $\hat{y} = \bar{y}$, la covarianza muestral (sin dividir por n) entre y y $\hat{y}$ es

$$\sum_i (y_i - \bar{y})(\hat{y}_i - \bar{y}) = \sum_i (\hat{y}_i - \bar{y} + \hat{u}_i)(\hat{y}_i - \bar{y}) = \text{SCE} + \sum_i \hat{u}_i(\hat{y}_i - \bar{y}) = \text{SCE},$$

porque $\sum_i \hat{u}_i \hat{y}_i = 0$ y $\sum_i \hat{u}_i = 0$. Entonces

$$\widehat{\text{Corr}}(y, \hat{y})^2 = \frac{\text{SCE}^2}{\text{SCT} \cdot \text{SCE}} = \frac{\text{SCE}}{\text{SCT}} = R^2.$$

□

4.1. El R^2 nunca baja

Teorema 4.2 (Agregar regresores no reduce el R^2). Sean X_1 ($n \times k_1$) y $X = [X_1 \ X_2]$ ($n \times k$), ambas con la constante. Sean SCR_1 y SCR las sumas de residuos de regresar y sobre X_1 y sobre X . Entonces $\text{SCR} \leq \text{SCR}_1$, y por lo tanto $R^2 \geq R_1^2$.

Demostración. $\text{SCR} = \min_{b \in \mathbb{R}^k} \|y - Xb\|^2$. El candidato particular $b = (\hat{\beta}_1', 0')'$, donde $\hat{\beta}_1$ es el MCO de la regresión corta, da $Xb = X_1 \hat{\beta}_1$. Luego

$$\text{SCR} = \min_b \|y - Xb\|^2 \leq \|y - X_1 \hat{\beta}_1\|^2 = \text{SCR}_1.$$

Como SCT no depende de los regresores, $R^2 = 1 - \text{SCR}/\text{SCT} \geq 1 - \text{SCR}_1/\text{SCT} = R_1^2$. □

La demostración es de una línea y la moraleja es importante: **el R^2 premia agregar basura**. Agrega a tu regresión de salarios el número de letras del apellido de cada persona y el R^2 subirá (o, con suerte, quedará igual).⁴ Por eso existe el R^2 ajustado,

$$\bar{R}^2 = 1 - \frac{\text{SCR}/(n - k)}{\text{SCT}/(n - 1)},$$

que penaliza con los grados de libertad y puede bajar al agregar regresores. La razón de dividir por $n - k$ y $n - 1$ se verá en la Clase 4 (son los divisores que hacen insesgadas a las varianzas estimadas).

⁴ Esto no es un chiste: con $k = n$ regresores linealmente independientes, $\text{col}(X) = \mathbb{R}^n$, $\hat{y} = y$ y $R^2 = 1$. Ajuste perfecto, poder predictivo nulo.

5. El teorema de Frisch-Waugh-Lovell

Este es, para mí, el teorema más bonito del curso. Particionemos $X = [X_1 \ X_2]$ con X_1 de $n \times k_1$ y X_2 de $n \times k_2$, y el vector de MCO correspondiente $\hat{\beta} = (\hat{\beta}_1', \hat{\beta}_2')'$. La pregunta: **¿qué es $\hat{\beta}_1$ por sí solo?** La respuesta de todo curso de pregrado es “el efecto de X_1 manteniendo X_2 constante”. Pero ¿qué significa eso en una muestra donde nadie mantuvo nada constante? FWL da la respuesta precisa.

Sea $M_2 = I - X_2(X_2'X_2)^{-1}X_2'$ la aniquiladora de X_2 . Recuerda que M_2z son los residuos de regresar z sobre X_2 : lo que queda de z después de sacarle todo lo que X_2 puede explicar linealmente.

Teorema 5.1 (Frisch-Waugh-Lovell). Si $X = [X_1 \ X_2]$ tiene rango completo, entonces

$$\hat{\beta}_1 = (X_1'M_2X_1)^{-1}X_1'M_2y = (\tilde{X}_1'\tilde{X}_1)^{-1}\tilde{X}_1'\tilde{y},$$

donde $\tilde{X}_1 = M_2X_1$ y $\tilde{y} = M_2y$. Es decir, $\hat{\beta}_1$ se obtiene en tres pasos:

1. Regresar y sobre X_2 y guardar los residuos $\tilde{y}$.
2. Regresar cada columna de X_1 sobre X_2 y guardar los residuos $\tilde{X}_1$.
3. Regresar $\tilde{y}$ sobre $\tilde{X}_1$.

Además, los residuos de la regresión del paso 3 son idénticos a los residuos $\hat{u}$ de la regresión completa.

En palabras: **el coeficiente de X_1 en la regresión larga es el coeficiente de una regresión simple entre las “versiones limpias” de y y de X_1 , ya purgadas de X_2 .** Eso es lo que significa “controlar por X_2 ”.

Borrador

La regresión larga dice $y = X_1\hat{\beta}_1 + X_2\hat{\beta}_2 + \hat{u}$. Quiero aislar $\hat{\beta}_1$; la molestia es $X_2\hat{\beta}_2$. ¿Cómo me deshago de algo que está en el espacio columna de X_2 ? ¡Con M_2 , que lo aniquila!

Multiplifico todo por M_2 :

$$M_2 y = M_2 X_1 \hat{\beta}_1 + \underbrace{M_2 X_2}_{=0} \hat{\beta}_2 + M_2 \hat{u}.$$

¿Y qué es $M_2 \hat{u}$? $\hat{u}$ es ortogonal a todo $\text{col}(X)$, en particular a $\text{col}(X_2)$, así que proyectarlo sobre X_2 da cero: $P_2 \hat{u} = 0$ y $M_2 \hat{u} = \hat{u}$. Queda $\tilde{y} = \tilde{X}_1 \hat{\beta}_1 + \hat{u}$. Ahora multiplico por $\tilde{X}_1'$ y necesito que $\tilde{X}_1' \hat{u} = 0$. Pero $\tilde{X}_1' \hat{u} = X_1' M_2 \hat{u} = X_1' \hat{u} = 0$ (ecuaciones normales). Se despeja $\hat{\beta}_1$. Solo me falta verificar que $\tilde{X}_1' \tilde{X}_1$ es invertible.

Demostración. Por definición de MCO y de los residuos,

$$y = X_1 \hat{\beta}_1 + X_2 \hat{\beta}_2 + \hat{u}, \quad X_1' \hat{u} = 0, \quad X_2' \hat{u} = 0. \quad (4)$$

Paso 1: $M_2 \hat{u} = \hat{u}$. Como $X_2' \hat{u} = 0$, $P_2 \hat{u} = X_2 (X_2' X_2)^{-1} X_2' \hat{u} = 0$, así que $M_2 \hat{u} = \hat{u} - P_2 \hat{u} = \hat{u}$.

Paso 2: premultiplicar por M_2 . Como $M_2 X_2 = 0$ (Clase 1), Ecuación 4 da

$$M_2 y = M_2 X_1 \hat{\beta}_1 + \hat{u}. \quad (5)$$

Paso 3: premultiplicar por X_1' . Usando $X_1' \hat{u} = 0$,

$$X_1' M_2 y = X_1' M_2 X_1 \hat{\beta}_1.$$

Paso 4: invertibilidad. $X_1' M_2 X_1 = (M_2 X_1)' (M_2 X_1)$ porque M_2 es simétrica e idempotente. Si $(M_2 X_1)c = 0$ para algún c , entonces $X_1 c = P_2 X_1 c = X_2 d$ con $d = (X_2' X_2)^{-1} X_2' X_1 c$, es decir, $X_1 c - X_2 d = 0$. Como $[X_1 \ X_2]$ tiene rango completo, $c = 0$ (y $d = 0$). Luego $M_2 X_1$ tiene rango columna completo y $X_1' M_2 X_1$ es invertible (Clase 1). Despejando,

$$\hat{\beta}_1 = (X_1' M_2 X_1)^{-1} X_1' M_2 y.$$

Como $X_1' M_2 X_1 = \tilde{X}_1' \tilde{X}_1$ y $X_1' M_2 y = X_1' M_2 M_2 y = \tilde{X}_1' \tilde{y}$, esta es la fórmula de MCO de $\tilde{y}$ sobre $\tilde{X}_1$.

Paso 5: residuos. Por Ecuación 5, los residuos de la regresión del paso 3 son $\tilde{y} - \tilde{X}_1 \hat{\beta}_1 = \hat{u}$. $\square$

Compara con la Clase 1: allí, con la inversa particionada, vimos que el bloque (1, 1) de $(X'X)^{-1}$ es $(X_1'M_2X_1)^{-1}$. FWL lo “explica”: es la matriz $(\tilde{X}_1'\tilde{X}_1)^{-1}$ de la regresión de los residuos. Esto será crucial en la Clase 4.

5.1. Tres corolarios que usarás siempre

Corolario 5.1 (Incluir una constante es restar medias). *En la regresión de y sobre $[1 \ Z]$, el coeficiente de Z es el MCO de $(y - \bar{y})$ sobre las columnas de Z en desvíos respecto de sus medias.*

Demostración. Aplica FWL con $X_2 = 1$ y $X_1 = Z$. Como vimos en la Clase 1, $M_2 = M^0$, que resta la media. $\square$

Corolario 5.2 (Coeficiente individual como regresión simple). *En la regresión de y sobre $[x_j \ X_{-j}]$ (donde X_{-j} son los demás regresores, incluida la constante),*

$$\hat{\beta}_j = \frac{\sum_i \tilde{x}_{ij} y_i}{\sum_i \tilde{x}_{ij}^2},$$

donde $\tilde{x}_{ij}$ son los residuos de regresar x_j sobre X_{-j} .

Demostración. Por FWL con $X_1 = x_j$ (una columna), $\hat{\beta}_j = (\tilde{x}_j'\tilde{x}_j)^{-1}\tilde{x}_j'\tilde{y}$. Y $\tilde{x}_j'\tilde{y} = x_j'M_{-j}y = \tilde{x}_j'y$, porque M_{-j} es simétrica e idempotente. $\square$

Nota que **no hace falta purgar a y** : basta con purgar al regresor. Esto se usa en la Clase 4 para calcular la varianza de $\hat{\beta}_j$ y en la Clase 8 para entender la multicolinealidad.

Corolario 5.3 (Regresores ortogonales). *Si $X_1'X_2 = 0$, entonces $\hat{\beta}_1 = (X_1'X_1)^{-1}X_1'y$: el coeficiente de X_1 es el mismo en la regresión larga y en la corta (sin X_2).*

Demostración. Si $X_2'X_1 = 0$, entonces $P_2X_1 = X_2(X_2'X_2)^{-1}X_2'X_1 = 0$ y $M_2X_1 = X_1$. FWL da $\hat{\beta}_1 = (X_1'X_1)^{-1}X_1'y$. $\square$

Este último corolario es el germen del **sesgo por variable omitida** (Clase 8): omitir X_2 no cambia el coeficiente de X_1 *solo si* son ortogonales en la muestra. Si no lo son, omitir X_2 contamina $\hat{\beta}_1$.

6. ★ Postgrado: leverage e influencia

! ★ Postgrado

¿Cuánto depende $\hat{\beta}$ de una sola observación? Para responderlo, estudiamos la diagonal de P y una fórmula exacta para el cambio de $\hat{\beta}$ al borrar una observación.

Los elementos diagonales de P se llaman **leverages**:

$$h_{ii} = P_{ii} = x_i'(X'X)^{-1}x_i.$$

Por el Ejercicio 1.7, $0 \leq h_{ii} \leq 1$, y como $\text{tr}(P) = k$, se tiene $\sum_i h_{ii} = k$: el leverage promedio es k/n . Además, $\hat{y}_i = \sum_j P_{ij}y_j$, así que h_{ii} mide cuánto pesa y_i en su propio valor ajustado. Una observación con h_{ii} cerca de 1 “tira” de la regresión hacia sí misma.

Lema 6.1 (Sherman–Morrison). Si A es invertible y $1 - v'A^{-1}v \neq 0$, entonces

$$(A - vv')^{-1} = A^{-1} + \frac{A^{-1}vv'A^{-1}}{1 - v'A^{-1}v}.$$

Demostración. Multiplicamos $(A - vv')$ por el lado derecho propuesto. Sea $c = v'A^{-1}v$ (un escalar):

$$\begin{aligned} (A - vv')\left(A^{-1} + \frac{A^{-1}vv'A^{-1}}{1 - c}\right) &= I - vv'A^{-1} + \frac{vv'A^{-1} - v(v'A^{-1}v)v'A^{-1}}{1 - c} \\ &= I - vv'A^{-1} + \frac{(1 - c)vv'A^{-1}}{1 - c} = I. \end{aligned}$$

□

Teorema 6.1 (Efecto de borrar una observación). Sea $\hat{\beta}_{(i)}$ el MCO calculado sin la observación i . Si $h_{ii} < 1$,

$$\hat{\beta} - \hat{\beta}_{(i)} = \frac{(X'X)^{-1}x_i \hat{u}_i}{1 - h_{ii}}.$$

i Borrador

Sin la observación i , las sumas $X'X = \sum_j x_j x_j'$ y $X'y = \sum_j x_j y_j$ pierden un término: $X'_{(i)}X_{(i)} = X'X - x_i x_i'$ y $X'_{(i)}y_{(i)} = X'y - x_i y_i$. ¡Es exactamente la forma de Sherman-Morrison con $v = x_i$! Y $v' A^{-1} v = x_i' (X'X)^{-1} x_i = h_{ii}$. Luego aplico SM, multiplico, y hay que ser ordenado con el álgebra: aparecerán $x_i' \hat{\beta} = \hat{y}_i$ y $y_i - \hat{y}_i = \hat{u}_i$.

Demostración. Sea $A = X'X$. Por la identidad “productos como sumas de observaciones” de la Clase 1, $X'_{(i)}X_{(i)} = A - x_i x_i'$ y $X'_{(i)}y_{(i)} = X'y - x_i y_i$. Por Sherman-Morrison con $v = x_i$ (y $v' A^{-1} v = h_{ii} \neq 1$),

$$\hat{\beta}_{(i)} = \left(A^{-1} + \frac{A^{-1} x_i x_i' A^{-1}}{1 - h_{ii}} \right) (X'y - x_i y_i).$$

Expandimos, usando $A^{-1} X'y = \hat{\beta}$, $x_i' \hat{\beta} = \hat{y}_i$ y $x_i' A^{-1} x_i = h_{ii}$:

$$\begin{aligned} \hat{\beta}_{(i)} &= \hat{\beta} - A^{-1} x_i y_i + \frac{A^{-1} x_i \hat{y}_i}{1 - h_{ii}} - \frac{A^{-1} x_i h_{ii} y_i}{1 - h_{ii}} \\ &= \hat{\beta} - \frac{A^{-1} x_i}{1 - h_{ii}} \left[(1 - h_{ii}) y_i - \hat{y}_i + h_{ii} y_i \right] \\ &= \hat{\beta} - \frac{A^{-1} x_i (y_i - \hat{y}_i)}{1 - h_{ii}} = \hat{\beta} - \frac{(X'X)^{-1} x_i \hat{u}_i}{1 - h_{ii}}. \end{aligned}$$

□

La influencia de una observación es el producto de dos cosas: su residuo $\hat{u}_i$ (qué tan mal la ajusta la recta) y su leverage vía $1/(1 - h_{ii})$ (qué tan atípicos son sus regresores). Una observación con residuo chico y leverage alto puede ser igual de influyente que una con residuo grande. De aquí salen la distancia de Cook, los DFBETAS y, en la Clase 7, los estimadores de varianza robustos HC2 y HC3, que dividen $\hat{u}_i^2$ por $(1 - h_{ii})$ o $(1 - h_{ii})^2$.

Un corolario útil: el **error de predicción fuera de muestra** de la observación i (usando $\hat{\beta}_{(i)}$) es

$$y_i - x_i' \hat{\beta}_{(i)} = \hat{u}_i + \frac{x_i' (X'X)^{-1} x_i \hat{u}_i}{1 - h_{ii}} = \frac{\hat{u}_i}{1 - h_{ii}},$$

lo que permite calcular la validación cruzada *leave-one-out* de una regresión lineal sin reestimar n veces.

7. Resumen

- $\hat{\beta} = (X'X)^{-1}X'y$ minimiza la suma de residuos al cuadrado; el mínimo es global y único por completación de cuadrados (Teorema 2.1).
- Las ecuaciones normales $X'\hat{u} = 0$ dicen que los residuos son ortogonales a los regresores.
- $\hat{y} = Py$, $\hat{u} = My = Mu$: MCO es una proyección ortogonal (Teorema 3.1).
- Con constante: $SCT = SCE + SCR$, $R^2 \in [0, 1]$, y R^2 no baja al agregar regresores.
- FWL: $\hat{\beta}_1$ es la regresión de M_2y sobre M_2X_1 (Teorema 5.1). “Controlar por X_2 ” = “purgar de X_2 ”.

8. Ejercicios

Ejercicio 3.1. Con los datos $z = (1, 2, 3, 4)'$ e $y = (2, 3, 5, 6)'$, calcula $\hat{\alpha}$ y $\hat{\gamma}$ de la regresión de y sobre $(1, z)$, los residuos y el R^2 . Verifica las ecuaciones normales.

Solución 3.1

$\bar{z} = 2,5$, $\bar{y} = 4$. Desvíos: $z - \bar{z} = (-1,5; -0,5; 0,5; 1,5)$, $y - \bar{y} = (-2; -1; 1; 2)$. $\sum(z - \bar{z})(y - \bar{y}) = 3 + 0,5 + 0,5 + 3 = 7$ y $\sum(z - \bar{z})^2 = 5$. Así $\hat{\gamma} = 1,4$ y $\hat{\alpha} = 4 - 1,4 \cdot 2,5 = 0,5$. Ajustados: $(1,9; 3,3; 4,7; 6,1)$. Residuos: $(0,1; -0,3; 0,3; -0,1)$. Verificación: $\sum \hat{u}_i = 0$ y $\sum z_i \hat{u}_i = 0,1 - 0,6 + 0,9 - 0,4 = 0$. $SCR = 0,01 + 0,09 + 0,09 + 0,01 = 0,2$, $SCT = 10$, $R^2 = 0,98$.

Ejercicio 3.2. Demuestra que si se multiplica un regresor x_j por una constante $c \neq 0$, su coeficiente de MCO se divide por c y los demás coeficientes, los ajustados y el R^2 no cambian. (Pista: $\tilde{X} = XD$ con D diagonal invertible.)

 Solución 3.2

$\tilde{\beta} = (D'X'XD)^{-1}D'X'y = D^{-1}(X'X)^{-1}D'^{-1}D'X'y = D^{-1}\hat{\beta}$.
Con $D = \text{diag}(1, \dots, c, \dots, 1)$, solo la coordenada j se divide por c . $\tilde{X}\tilde{\beta} = XDD^{-1}\hat{\beta} = X\hat{\beta}$, así que ajustados, residuos y R^2 son iguales. Más en general: $\text{col}(XD) = \text{col}(X)$, y MCO solo depende del espacio columna.

Ejercicio 3.3. Da un ejemplo en que, sin constante en la regresión, el “ R^2 ” definido como $1 - \text{SCR}/\text{SCT}$ sea negativo.

 Solución 3.3

Tomemos $y = (3, 4, 5)'$ y un único regresor $x = (1, -1, 0)'$ sin constante. $\hat{\beta} = x'y/x'x = (3 - 4)/2 = -0,5$, $\hat{y} = (-0,5; 0,5; 0)$, $\hat{u} = (3,5; 3,5; 5)$, $\text{SCR} = 12,25 + 12,25 + 25 = 49,5$. $\text{SCT} = 1 + 0 + 1 = 2$. Así “ R^2 ” = $1 - 24,75 < 0$. La descomposición $\text{SCT} = \text{SCE} + \text{SCR}$ requiere la constante.

Ejercicio 3.4. Usa FWL para demostrar que el coeficiente de una tendencia lineal $t = (1, 2, \dots, n)'$ en la regresión de y sobre $(1, t, z)$ es el mismo que se obtiene al “destendenciar” y y z primero y luego regresar y destendenciada sobre z destendenciada... ¡Cuidado! ¿Qué coeficiente se obtiene así: el de t o el de z ?

 Solución 3.4

El enunciado tenía una trampa deliberada. Destendenciar significa aplicar M_2 con $X_2 = [1 \ t]$, y FWL dice que regresar M_2y sobre M_2z da el coeficiente **de** z en la regresión larga (no el de t). Este es el resultado original de Frisch y Waugh (1933): da lo mismo destendenciar las series antes de regresar que incluir la tendencia como regresor.

Ejercicio 3.5. Demuestra que la regresión de $\hat{u}$ (residuos de la regresión de y sobre X) sobre X tiene coeficientes cero y R^2 cero (si hay constante).

💡 Solución 3.5

Coeficientes: $(X'X)^{-1}X'\hat{u} = 0$ por las ecuaciones normales.
Ajustados: 0. Residuos: $\hat{u}$ mismo. $SCR = \hat{u}'\hat{u} = SCT$ (pues $\tilde{\hat{u}} = 0$), así que $R^2 = 0$.

Ejercicio 3.6 ★. Sea X con constante. Demuestra que $h_{ii} \geq 1/n$ para todo i . (Pista: $P - \frac{1}{n}u'$ es simétrica e idempotente, por el Ejercicio 1.6.)

💡 Solución 3.6 ★

Con $X_1 = \iota$, $P_1 = \frac{1}{n}u'$, y por el Ejercicio 1.6, $P - P_1$ es simétrica e idempotente, luego semidefinida positiva (Ejercicio 1.7). Su diagonal es no negativa: $h_{ii} - \frac{1}{n} \geq 0$.

Ejercicio 3.7 ★. Demuestra que la suma de los errores de predicción *leave-one-out* al cuadrado es $CV = \sum_i (\hat{u}_i / (1 - h_{ii}))^2$. ¿Por qué CV es siempre mayor o igual que SCR?

💡 Solución 3.7 ★

La fórmula sale directo del corolario al final de la sección de influencia. Como $0 \leq h_{ii} < 1$, $1/(1 - h_{ii})^2 \geq 1$, así que cada término es $\geq \hat{u}_i^2$. Interpretación: los residuos dentro de muestra son “demasiado optimistas” porque cada observación ayudó a elegir la recta que la ajusta.