

Clase 4 · MCO en muestras finitas

Insesgamiento, varianza y el teorema de Gauss–Markov

Contenido

1	De álgebra a estadística	2
2	Los supuestos clásicos	2
3	Insesgamiento	3
4	La varianza de MCO	4
4.1	La varianza de un coeficiente individual	4
5	El teorema de Gauss–Markov	6
6	Estimando σ^2	8
7	★ Postgrado: más allá de Gauss–Markov	10
7.1	Varianza incondicional	10
7.2	Un estimador sesgado que le gana a MCO	10
7.3	¿Hace falta “lineal”?	11
8	Resumen	11
9	Ejercicios	12

1. De álgebra a estadística

En la Clase 3, $\hat{\beta} = (X'X)^{-1}X'y$ era un número (bueno, un vector de números) calculado con datos fijos. Hoy cambiamos de perspectiva: los datos son **aleatorios**, así que $\hat{\beta}$ es una **variable aleatoria**. Si repitiéramos el muestreo, obtendríamos otro $\hat{\beta}$. Las preguntas naturales son:

- ¿En promedio, $\hat{\beta}$ le apunta al β correcto? (**Insesgamiento.**)
- ¿Cuánto varía de muestra en muestra? (**Varianza.**)
- ¿Hay otro estimador que varíe menos? (**Eficiencia.**)

Las respuestas de esta clase son “exactas”: valen para cualquier n , no solo para n grande. El precio es que necesitamos supuestos relativamente fuertes. En la Clase 7 veremos qué sobrevive cuando los relajamos y dejamos que $n \rightarrow \infty$.

2. Los supuestos clásicos

Supuestos del modelo de regresión lineal (RL)

- **RL1 (linealidad):** $y = X\beta + u$ para algún $\beta \in \mathbb{R}^k$.
- **RL2 (rango completo):** $\text{rango}(X) = k$ con probabilidad uno.
- **RL3 (exogeneidad estricta):** $\mathbb{E}[u | X] = 0$.
- **RL4 (errores esféricos):** $\text{Var}(u | X) = \mathbb{E}[uu' | X] = \sigma^2 I_n$, con $0 < \sigma^2 < \infty$.

Comentemos cada uno, porque cada palabra importa.

RL1 por sí solo no dice nada: *cualquier* y se puede escribir como $X\beta + u$ definiendo $u = y - X\beta$. El contenido está en RL1 *junto con* RL3: juntos dicen que $\mathbb{E}[y | X] = X\beta$, es decir, que la CEF es lineal. Por la Clase 2, esto hace que β sea a la vez el coeficiente de la CEF y el de la proyección lineal.

RL2 es lo que hace que $\hat{\beta}$ exista (Clase 1).

RL3 es fuerte: dice que el error de la observación i tiene media cero condicional en los regresores de **todas** las observaciones,

$\mathbb{E}[u_i \mid x_1, \dots, x_n] = 0$. De ahí lo de “estricta”. Con datos de corte transversal y muestreo aleatorio esto no es tan grave:

Lema 2.1 (Muestreo aleatorio y exogeneidad estricta). Si $\{(y_i, x_i)\}_{i=1}^n$ son independientes entre observaciones y $\mathbb{E}[u_i \mid x_i] = 0$ para cada i , entonces $\mathbb{E}[u \mid X] = 0$.

Demostración. Fijemos i . Como (u_i, x_i) es independiente de $\{x_j\}_{j \neq i}$ (porque $u_i = y_i - x_i' \beta$ es función de (y_i, x_i)), condicionar adicionalmente en los x_j de otras observaciones no cambia la esperanza condicional de u_i : $\mathbb{E}[u_i \mid X] = \mathbb{E}[u_i \mid x_i] = 0$. $\square$

En series de tiempo, en cambio, RL3 casi siempre falla: si $x_t = y_{t-1}$ (un rezago), entonces u_{t-1} afecta a $y_{t-1} = x_t$, y $\mathbb{E}[u_{t-1} \mid X] \neq 0$. Por eso la econometría de series de tiempo (Econometría 3) usa otras herramientas.¹

RL4 tiene dos partes. La diagonal, $\text{Var}(u_i \mid X) = \sigma^2$ para todo i , es **homocedasticidad**. Fuera de la diagonal, $\text{Cov}(u_i, u_j \mid X) = 0$ para $i \neq j$, es **no autocorrelación**. Relajar RL4 es el tema de la Clase 9.

¹ Mucha gente aprende esto de la peor manera: corre un AR(1) por MCO, pregunta si es insesgado, y descubre que no. MCO en un AR(1) está sesgado hacia abajo en muestras finitas (el sesgo de Hurwicz, de 1950). Consistente, sí; insesgado, no.

3. Insesgamiento

Todo empieza con una identidad que usaremos en todas las clases que quedan. Bajo RL1 y RL2,

$$\hat{\beta} = (X'X)^{-1}X'y = (X'X)^{-1}X'(X\beta + u) = \beta + (X'X)^{-1}X'u. \quad (1)$$

El estimador es el parámetro verdadero más un “error de muestreo” que es una combinación lineal de los errores. Toda la teoría de MCO consiste en estudiar ese segundo término.

Teorema 3.1 (MCO es insesgado). Bajo RL1–RL3, $\mathbb{E}[\hat{\beta} \mid X] = \beta$ y, en consecuencia, $\mathbb{E}[\hat{\beta}] = \beta$.

Demostración. Por Ecuación 1, y porque $(X'X)^{-1}X'$ es función de X (“lo conocido sale”, Clase 2),

$$\mathbb{E}[\hat{\beta} \mid X] = \beta + (X'X)^{-1}X' \mathbb{E}[u \mid X] = \beta + (X'X)^{-1}X' \cdot 0 = \beta.$$

Por la ley de esperanzas iteradas, $\mathbb{E}[\hat{\beta}] = \mathbb{E}[\mathbb{E}[\hat{\beta} \mid X]] = \mathbb{E}[\beta] = \beta$.² $\square$

² Técnicamente, para el paso incondicional necesitamos que $\mathbb{E}\|\hat{\beta}\| < \infty$. Casi todos los libros de pregrado se saltan este detalle, y casi todos los de postgrado lo mencionan en una nota al pie. Aquí está la mía.

Nota qué supuestos **no** se usaron: RL4. El insesgamiento no necesita homocedasticidad ni ausencia de autocorrelación. Sí necesita RL3 de manera crucial: si $\mathbb{E}[u \mid X] \neq 0$, el segundo término no se anula. Esa es la historia de las Clases 8 y 10.

4. La varianza de MCO

Teorema 4.1 (Matriz de varianzas de MCO). *Bajo RL1–RL4,*

$$\text{Var}(\hat{\beta} \mid X) = \sigma^2 (X'X)^{-1}.$$

Demostración. Por Teorema 3.1, $\hat{\beta} - \mathbb{E}[\hat{\beta} \mid X] = \hat{\beta} - \beta = (X'X)^{-1}X'u$. Llamemos $A = (X'X)^{-1}X'$, que es fija dado X . Por la fórmula de la varianza de una transformación lineal (Clase 1), condicionando en X ,

$$\text{Var}(\hat{\beta} \mid X) = A \text{Var}(u \mid X) A' = (X'X)^{-1}X'(\sigma^2 I_n)X(X'X)^{-1} = \sigma^2 (X'X)^{-1} \underbrace{X'X(X'X)^{-1}}_{=I_k} = \sigma^2 (X'X)^{-1}.$$

$\square$

Aquí sí se usó RL4, en el paso “ $\text{Var}(u \mid X) = \sigma^2 I$ ”. Sin RL4, el sándwich $(X'X)^{-1}X' \text{Var}(u \mid X)X(X'X)^{-1}$ no se simplifica, y la fórmula “de manual” $\sigma^2 (X'X)^{-1}$ es simplemente incorrecta. Guarda este sándwich: volverá en la Clase 7 como la varianza robusta de White.

4.1. La varianza de un coeficiente individual

La matriz $\sigma^2 (X'X)^{-1}$ es compacta pero opaca. ¿De qué depende la precisión de *un* coeficiente, $\hat{\beta}_j$? FWL da una respuesta muy iluminadora.

Teorema 4.2 (Varianza de $\hat{\beta}_j$). Supongamos RL1–RL4 y que X contiene una constante. Para un regresor no constante x_j , sean $SCT_j = \sum_i (x_{ij} - \bar{x}_j)^2$ y R_j^2 el R^2 de la regresión de x_j sobre los demás regresores (incluida la constante). Entonces

$$\text{Var}(\hat{\beta}_j | X) = \frac{\sigma^2}{SCT_j (1 - R_j^2)}.$$

i Borrador

FWL (Clase 3) dice que $\hat{\beta}_j = \tilde{x}_j' y / \tilde{x}_j' \tilde{x}_j$, donde $\tilde{x}_j$ son los residuos de regresar x_j sobre los demás. Esto es una combinación lineal de y con pesos $w = \tilde{x}_j / (\tilde{x}_j' \tilde{x}_j)$, así que su varianza es $\sigma^2 w' w = \sigma^2 / (\tilde{x}_j' \tilde{x}_j)$. Y $\tilde{x}_j' \tilde{x}_j$ es la suma de residuos al cuadrado de esa regresión auxiliar, que por definición de R^2 es $SCT_j (1 - R_j^2)$.

Demostración. Sea X_{-j} la matriz de los demás regresores (que contiene la constante) y $\tilde{x}_j = M_{-j} x_j$. Por FWL (Clase 3, corolario del coeficiente individual), $\hat{\beta}_j = w' y$ con $w = \tilde{x}_j / (\tilde{x}_j' \tilde{x}_j)$, un vector que depende solo de X . Por RL4,

$$\text{Var}(\hat{\beta}_j | X) = w' \text{Var}(y | X) w = w' \text{Var}(u | X) w = \sigma^2 w' w = \sigma^2 \frac{\tilde{x}_j' \tilde{x}_j}{(\tilde{x}_j' \tilde{x}_j)^2} = \frac{\sigma^2}{\tilde{x}_j' \tilde{x}_j}.$$

Ahora, $\tilde{x}_j' \tilde{x}_j$ es la SCR de la regresión auxiliar de x_j sobre X_{-j} , que tiene constante, así que su SCT es SCT_j y $SCR = SCT_j (1 - R_j^2)$ por definición de R_j^2 . $\square$

Esta fórmula es una joya pedagógica. La precisión de $\hat{\beta}_j$ depende de tres cosas, y solo de tres:

1. σ^2 : más ruido en y , menos precisión.
2. **SCT_j**: más variación en x_j , más precisión. (Crece con n , típicamente al ritmo de n .)
3. $1 - R_j^2$: si x_j es casi explicable por los demás regresores ($R_j^2 \approx 1$), casi no queda variación “propia” de x_j para identificar su efecto. Esto es la **multicolinealidad**, y $1/(1 - R_j^2)$ se llama **factor de inflación de varianza** (VIF). Volveremos a esto en la Clase 8.

Para el caso de regresión simple ($R_j^2 = 0$, pues el único otro regresor es la constante), $\text{Var}(\hat{y} | X) = \sigma^2 / \sum_i (z_i - \bar{z})^2$.

5. El teorema de Gauss–Markov

Llegamos al resultado más famoso de la econometría clásica. MCO es insesgado. Pero hay infinitos estimadores insesgados. ¿Por qué usar MCO?

Definición 5.1 (Estimador lineal insesgado). Un estimador $\tilde{\beta}$ es **lineal** (en y) si $\tilde{\beta} = Ay$ para alguna matriz A de $k \times n$ que depende solo de X . Es **insesgado** si $\mathbb{E}[\tilde{\beta} | X] = \beta$ para todo $\beta \in \mathbb{R}^k$.

MCO es lineal, con $A = (X'X)^{-1}X'$. Otros ejemplos: MCO usando solo la primera mitad de la muestra, o mínimos cuadrados ponderados con cualquier matriz de pesos fija (Clase 9).

Lema 5.1 (Caracterización). *Bajo RL1 y RL3, un estimador lineal $\tilde{\beta} = Ay$ es insesgado si y solo si $AX = I_k$.*

Demostración. $\mathbb{E}[Ay | X] = A(X\beta + \mathbb{E}[u | X]) = AX\beta$. Si $AX = I$, esto es β . Recíprocamente, si $AX\beta = \beta$ para todo β , tomando $\beta = e_j$ (el j -ésimo vector canónico) se obtiene que la columna j de AX es e_j , para todo j ; es decir, $AX = I$. $\square$

Teorema 5.1 (Gauss–Markov). *Bajo RL1–RL4, para todo estimador lineal insesgado $\tilde{\beta}$,*

$$\text{Var}(\tilde{\beta} | X) \geq \text{Var}(\hat{\beta} | X).$$

*Es decir, MCO es el **mejor estimador lineal insesgado** (MELL, o BLUE en inglés).*

Recuerda de la Clase 1 que “ $\geq$ ” significa que la diferencia es semi-definida positiva, lo que implica que **toda** combinación lineal $c'\beta$ se estima con menor varianza usando $c'\hat{\beta}$ que usando $c'\tilde{\beta}$.

Borrador

Tengo dos estimadores: $\hat{\beta} = A_0 y$ con $A_0 = (X'X)^{-1}X'$, y $\tilde{\beta} = Ay$. La idea es escribir A como “MCO más una desviación”: $A = A_0 + C$, con $C = A - A_0$. ¿Qué sé de C ? Ambos son insesgados, así que $AX = I$ y $A_0X = I$. Restando, $CX = 0$. Ahora calculo la varianza de $\tilde{\beta}$: $\sigma^2 AA' = \sigma^2(A_0 + C)(A_0 + C)'$. Expandiendo aparecen A_0A_0' (la varianza de MCO), CC' (algo semidefinido positivo) y los términos cruzados A_0C' y CA_0' . Si los cruzados se anulan, gané. $CA_0' = CX(X'X)^{-1}$, y $CX = 0$. ¡Se anulan!

Moraleja geométrica: la “desviación” C es ortogonal a MCO. Cualquier estimador lineal insesgado es MCO más ruido no correlacionado con MCO, y agregar ruido no correlacionado solo puede aumentar la varianza.

Demostración. Sean $A_0 = (X'X)^{-1}X'$ y $\tilde{\beta} = Ay$ lineal e insesgado. Definimos $C = A - A_0$. Por Lema 5.1, $AX = I$, y también $A_0X = (X'X)^{-1}X'X = I$, así que

$$CX = AX - A_0X = I - I = 0.$$

Por RL4 y la fórmula de la varianza de una transformación lineal,

$$\text{Var}(\tilde{\beta} | X) = A \text{Var}(y | X) A' = \sigma^2 AA' = \sigma^2(A_0 + C)(A_0 + C)'.$$

Expandimos:

$$(A_0 + C)(A_0 + C)' = A_0A_0' + A_0C' + CA_0' + CC'.$$

Calculamos cada pieza. Primero, $A_0A_0' = (X'X)^{-1}X'X(X'X)^{-1} = (X'X)^{-1}$. Segundo,

$$CA_0' = CX(X'X)^{-1} = 0 \cdot (X'X)^{-1} = 0,$$

y trasponiendo, $A_0C' = (CA_0')' = 0$. Luego

$$\text{Var}(\tilde{\beta} | X) = \sigma^2(X'X)^{-1} + \sigma^2CC' = \text{Var}(\hat{\beta} | X) + \sigma^2CC'.$$

Finalmente, $CC' \geq 0$, pues para cualquier d , $d'CC'd = \|C'd\|^2 \geq 0$. Por lo tanto $\text{Var}(\tilde{\beta} | X) - \text{Var}(\hat{\beta} | X) = \sigma^2CC' \geq 0$. $\square$

 Lo que Gauss–Markov NO dice

- **No** dice que MCO sea el mejor estimador. Dice que es el mejor entre los **lineales e insesgados**. Hay estimadores sesgados con menor error cuadrático medio (ver la sección ★) y, sin normalidad, puede haber estimadores no lineales mejores.
- **No** vale sin RL4. Con heterocedasticidad o autocorrelación, MCO sigue siendo insesgado pero deja de ser el mejor; el mejor es MCG (Clase 9).
- **No** dice nada si RL3 falla. Entonces MCO ni siquiera es insesgado.

6. Estimando σ^2

La fórmula $\sigma^2(X'X)^{-1}$ tiene un problema: no conocemos σ^2 . Por el principio de analogía, como $\sigma^2 = \mathbb{E}[u_i^2]$, estimaríamos con $\frac{1}{n} \sum u_i^2 \dots$ pero no observamos u_i , solo $\hat{u}_i$. El candidato ingenuo es $\hat{\sigma}^2 = \frac{1}{n} \sum \hat{u}_i^2$. Resulta que está sesgado.

Teorema 6.1 (Estimador insesgado de σ^2). *Bajo RL1–RL4, el estimador*

$$s^2 = \frac{\hat{u}'\hat{u}}{n-k} = \frac{1}{n-k} \sum_{i=1}^n \hat{u}_i^2$$

satisface $\mathbb{E}[s^2 | X] = \sigma^2$ y, por lo tanto, $\mathbb{E}[s^2] = \sigma^2$.

 Borrador

Sé que $\hat{u} = Mu$ (Clase 3) y que M es simétrica e idempotente. Entonces $\hat{u}'\hat{u} = u'M'Mu = u'Mu$, una forma cuadrática en u . Y para la esperanza de una forma cuadrática tengo la fórmula de la Clase 1: $\mathbb{E}[z'Az] = \text{tr}(A\Sigma) + \mu'A\mu$. Con $z = u$, $\mu = 0$ (por RL3), $\Sigma = \sigma^2 I$ (por RL4): $\mathbb{E}[u'Mu | X] = \sigma^2 \text{tr}(M) = \sigma^2(n-k)$. ¡Ese es el origen del $n-k$!

Demostración. Por la Clase 3, $\hat{u} = Mu$, y como M es simétrica e idempotente (Clase 1),

$$\hat{u}'\hat{u} = u'M'Mu = u'MMu = u'Mu.$$

Condicionando en X , M es fija. Aplicamos la fórmula de la esperanza de una forma cuadrática (Clase 1) con $\mathbb{E}[u \mid X] = 0$ (RL3) y $\text{Var}(u \mid X) = \sigma^2 I_n$ (RL4):

$$\mathbb{E}[u'Mu \mid X] = \text{tr}(M\sigma^2 I_n) + 0 = \sigma^2 \text{tr}(M) = \sigma^2(n - k),$$

donde la última igualdad es $\text{tr}(M) = n - k$ (Clase 1). Dividiendo por $n - k$, $\mathbb{E}[s^2 \mid X] = \sigma^2$. La versión incondicional sale de la LEI. $\square$

El estimador ingenuo $\hat{\sigma}^2 = \frac{n-k}{n}s^2$ tiene esperanza $\frac{n-k}{n}\sigma^2 < \sigma^2$: **subestima** la varianza del error. La intuición: MCO elige $\hat{\beta}$ para hacer los residuos lo más chicos posible, así que los residuos son sistemáticamente más chicos que los errores verdaderos. Hay que “devolverles” k grados de libertad.

Con s^2 en mano, el **error estándar** de $\hat{\beta}_j$ es

$$\text{ee}(\hat{\beta}_j) = \sqrt{s^2[(X'X)^{-1}]_{jj}},$$

y $s^2(X'X)^{-1}$ es un estimador insesgado de $\text{Var}(\hat{\beta} \mid X)$ (porque $(X'X)^{-1}$ es fija dado X). Nota, sin embargo, que $\text{ee}(\hat{\beta}_j)$ **no** es insesgado para $\sqrt{\text{Var}(\hat{\beta}_j \mid X)}$: la raíz cuadrada es cóncava y la desigualdad de Jensen lo sesga hacia abajo. Detalles así importan en la Clase 5, donde en lugar de preocuparnos por el sesgo del error estándar conoceremos la distribución exacta del estadístico t .

7. ★ Postgrado: más allá de Gauss–Markov

! ★ Postgrado

Tres observaciones que matizan el teorema de Gauss–Markov: la versión incondicional, el hecho de que un estimador sesgado puede ganarle a MCO en error cuadrático medio, y la discusión reciente sobre si “lineal” es necesario.

7.1. Varianza incondicional

Por la ley de varianza total en su versión matricial (misma demostración que en la Clase 2),

$$\text{Var}(\hat{\beta}) = \mathbb{E}[\text{Var}(\hat{\beta} | X)] + \text{Var}(\mathbb{E}[\hat{\beta} | X]) = \sigma^2 \mathbb{E}[(X'X)^{-1}] + \text{Var}(\beta) = \sigma^2 \mathbb{E}[(X'X)^{-1}].$$

Y si $\tilde{\beta}$ es lineal e insesgado condicional en X , lo mismo da $\text{Var}(\tilde{\beta}) = \mathbb{E}[\text{Var}(\tilde{\beta} | X)]$, así que

$$\text{Var}(\tilde{\beta}) - \text{Var}(\hat{\beta}) = \sigma^2 \mathbb{E}[CC'] \geq 0.$$

Gauss–Markov vale también incondicionalmente.

7.2. Un estimador sesgado que le gana a MCO

Consideremos el caso más simple: un único regresor sin constante, $y_i = \beta x_i + u_i$, bajo RL1–RL4. Sea $a = \sum_i x_i^2 = x'x$. El estimador **ridge** con parámetro $\lambda \geq 0$ es

$$\hat{\beta}_\lambda = \frac{x'y}{a + \lambda}.$$

Con $\lambda = 0$ es MCO. Para $\lambda > 0$ “encoge” la estimación hacia cero.

Teorema 7.1 (Ridge mejora a MCO en error cuadrático medio). *Si $\beta \neq 0$, el error cuadrático medio condicional $ECM(\lambda) = \mathbb{E}[(\hat{\beta}_\lambda - \beta)^2 | X]$ es estrictamente decreciente en $[0, \sigma^2/\beta^2]$. En particular, existe $\lambda > 0$ con $ECM(\lambda) < ECM(0) = \text{Var}(\hat{\beta} | X)$.*

Demostración. Como $x'y = a\beta + x'u$, se tiene $\mathbb{E}[\hat{\beta}_\lambda | X] = \frac{a\beta}{a+\lambda}$ y $\text{Var}(\hat{\beta}_\lambda | X) = \frac{\sigma^2 a}{(a+\lambda)^2}$. El sesgo es $\frac{a\beta}{a+\lambda} - \beta = -\frac{\lambda\beta}{a+\lambda}$. Luego

$$\text{ECM}(\lambda) = \text{varianza} + \text{sesgo}^2 = \frac{\sigma^2 a + \lambda^2 \beta^2}{(a + \lambda)^2}.$$

Derivando con la regla del cociente,

$$\text{ECM}'(\lambda) = \frac{2\lambda\beta^2(a + \lambda)^2 - 2(a + \lambda)(\sigma^2 a + \lambda^2 \beta^2)}{(a + \lambda)^4} = \frac{2[\lambda\beta^2(a + \lambda) - \sigma^2 a - \lambda^2 \beta^2]}{(a + \lambda)^3} = \frac{2a(\lambda\beta^2 - \sigma^2)}{(a + \lambda)^3}.$$

Para $0 \leq \lambda < \sigma^2/\beta^2$ el numerador es negativo, así que ECM es estrictamente decreciente ahí. $\square$

El mínimo se alcanza en $\lambda^* = \sigma^2/\beta^2$ y vale $\text{ECM}(\lambda^*) = \sigma^2/(a + \sigma^2/\beta^2) < \sigma^2/a$. Claro, λ^* depende de β y σ^2 , que no conocemos. En la práctica λ se elige por validación cruzada, y en dimensión $k \geq 3$ el estimador de James–Stein (1961) logra dominar a MCO *uniformemente* en β (bajo normalidad), un resultado que todavía hoy le parece a mucha gente un truco de magia.³

7.3. ¿Hace falta “lineal”?

Hansen (2022, *Econometrica*) presentó una versión de Gauss–Markov en la que se elimina la restricción de linealidad: bajo $\mathbb{E}[y | X] = X\beta$ y $\text{Var}(y | X) = \sigma^2 I$ para una clase amplia de distribuciones, MCO tiene varianza mínima entre **todos** los estimadores insesgados. Pötscher y Preinerstorfer (2022) respondieron que, en esa clase tan amplia de distribuciones, los estimadores insesgados resultan ser esencialmente lineales, de modo que el resultado “nuevo” es cercano al clásico. El debate es un buen recordatorio de que en optimalidad *la clase de modelos contra la que exigas insesgamiento* es tan importante como la clase de estimadores.

³ El “fenómeno de Stein” dice que para estimar tres o más medias normales independientes, conviene encogerlas todas hacia un punto común, aunque no tengan nada que ver entre sí. Estimar juntos el precio del té en China, la estatura media de los chilenos y el número de goles de un equipo mejora (en ECM total) si los encoges hacia un punto común. Efron y Morris escribieron un artículo precioso sobre esto en *Scientific American* (1977).

8. Resumen

- $\hat{\beta} = \beta + (X'X)^{-1}X'u$ (Ecuación 1). Toda la teoría de MCO parte de aquí.

- RL1–RL3 $\Rightarrow$ MCO insesgado (Teorema 3.1). No se necesita homocedasticidad.
- RL1–RL4 $\Rightarrow \text{Var}(\hat{\beta} \mid X) = \sigma^2(X'X)^{-1}$ (Teorema 4.1) y $\text{Var}(\hat{\beta}_j \mid X) = \sigma^2/[\text{SCT}_j(1 - R_j^2)]$ (Teorema 4.2).
- Gauss–Markov: MCO es el mejor estimador lineal insesgado (Teorema 5.1).
- $s^2 = \hat{u}'\hat{u}/(n - k)$ es insesgado; el $n - k$ viene de $\text{tr}(M)$ (Teorema 6.1).

9. Ejercicios

Ejercicio 4.1. En el modelo $y_i = \beta x_i + u_i$ (sin constante) bajo RL1–RL4, considera los estimadores $\hat{\beta} = \sum x_i y_i / \sum x_i^2$ (MCO) y $\tilde{\beta} = \bar{y}/\bar{x}$ (con $\bar{x} \neq 0$). Demuestra que ambos son lineales e insesgados, calcula sus varianzas y verifica directamente que $\text{Var}(\tilde{\beta} \mid X) \geq \text{Var}(\hat{\beta} \mid X)$.

Solución 4.1

$\tilde{\beta} = \sum_i y_i / \sum_i x_i$ es lineal con pesos $a_i = 1/\sum_j x_j$, y $\sum_i a_i x_i = 1$, así que es insesgado (Lema 5.1). $\text{Var}(\tilde{\beta} \mid X) = \sigma^2 \sum_i a_i^2 = n\sigma^2/(\sum x_i)^2$ y $\text{Var}(\hat{\beta} \mid X) = \sigma^2/\sum x_i^2$. La desigualdad $n/(\sum x_i)^2 \geq 1/\sum x_i^2$ equivale a $n \sum x_i^2 \geq (\sum x_i)^2$, que es Cauchy–Schwarz aplicada a $(1, \dots, 1)$ y $(x_1, \dots, x_n)$. Hay igualdad si y solo si todos los x_i son iguales.

Ejercicio 4.2. Bajo RL1–RL4, demuestra que $\text{Cov}(\hat{\beta}, \hat{u} \mid X) = 0$. ¿Implica esto independencia entre $\hat{\beta}$ y $\hat{u}$?

Solución 4.2

$\hat{\beta} - \beta = (X'X)^{-1}X'u$ y $\hat{u} = Mu$. Entonces $\text{Cov}(\hat{\beta}, \hat{u} \mid X) = \mathbb{E}[(X'X)^{-1}X'uu'M \mid X] = \sigma^2(X'X)^{-1}X'M = 0$, porque $X'M = (MX)' = 0$. No implica independencia en general; sí bajo normalidad, porque para vectores conjuntamente normales covarianza cero implica independencia. Ese es el punto de partida de la Clase 5.

Ejercicio 4.3. Supón que el verdadero modelo es $y = X\beta + u$ bajo RL1–RL4, pero el investigador multiplica todas las observaciones de y por 1.000 (cambia de miles de pesos a pesos). ¿Qué pasa con $\hat{\beta}$, s^2 y los errores estándar? ¿Y con los estadísticos $\hat{\beta}_j / \text{ee}(\hat{\beta}_j)$?

 Solución 4.3

$\hat{\beta}$ se multiplica por 1.000, los residuos también, s^2 por 10^6 y los errores estándar por 1.000. El cociente $\hat{\beta}_j / \text{ee}(\hat{\beta}_j)$ no cambia. Tiene sentido: la evidencia estadística de que $\beta_j \neq 0$ no puede depender de las unidades de medida.

Ejercicio 4.4. Demuestra que el valor ajustado en un punto x_0 , $\hat{y}_0 = x_0' \hat{\beta}$, es el mejor estimador lineal insesgado de $x_0' \beta$ bajo RL1–RL4, y calcula su varianza.

 Solución 4.4

Es el caso $c = x_0$ de Gauss–Markov: para cualquier $\tilde{\beta}$ lineal insesgado, $x_0' \tilde{\beta}$ es lineal insesgado para $x_0' \beta$ y $\text{Var}(x_0' \tilde{\beta} | X) = x_0' \text{Var}(\tilde{\beta} | X) x_0 \geq x_0' \text{Var}(\hat{\beta} | X) x_0$. (Faltaría ver que todo estimador lineal insesgado de $x_0' \beta$ es de la forma $x_0' \tilde{\beta}$; hazlo como extensión: si $a'y$ es insesgado para $x_0' \beta$ entonces $X'a = x_0$, y escribes $a = X(X'X)^{-1}x_0 + d$ con $X'd = 0$.) La varianza es $\sigma^2 x_0' (X'X)^{-1} x_0$.

Ejercicio 4.5. En la regresión simple con constante, demuestra que $\text{Var}(\hat{\alpha} | X) = \sigma^2 \frac{\sum z_i^2}{n \sum (z_i - \bar{z})^2}$ y que $\text{Cov}(\hat{\alpha}, \hat{\gamma} | X) = -\bar{z} \text{Var}(\hat{\gamma} | X)$. Interpreta el signo.

 Solución 4.5

$X'X = \begin{pmatrix} n & \sum z_i \\ \sum z_i & \sum z_i^2 \end{pmatrix}$, con determinante $n \sum z_i^2 - (\sum z_i)^2 = n \sum (z_i - \bar{z})^2$. Luego $(X'X)^{-1} = \frac{1}{n \sum (z_i - \bar{z})^2} \begin{pmatrix} \sum z_i^2 & -\sum z_i \\ -\sum z_i & n \end{pmatrix}$. La entrada (1, 1) por σ^2 da $\text{Var}(\hat{\alpha} | X)$ y la (1, 2) da $\text{Cov} = -\sigma^2 \bar{z} / \sum (z_i - \bar{z})^2 = -\bar{z} \text{Var}(\hat{\gamma} | X)$. Si $\bar{z} > 0$: una recta estimada más empinada que la verdadera (que pasa por $(\bar{z}, \bar{y})$) cruza el eje vertical más abajo, así que el intercepto queda

más bajo. Covarianza negativa.

Ejercicio 4.6 ★. Sin RL4, pero con $\text{Var}(u | X) = \Sigma$ (una matriz definida positiva que depende de X), calcula $\mathbb{E}[s^2 | X]$. Da un ejemplo en que $s^2(X'X)^{-1}$ subestime sistemáticamente la varianza de $\hat{\beta}_j$.

 Solución 4.6 ★

$\mathbb{E}[s^2 | X] = \text{tr}(M\Sigma)/(n - k)$. Ejemplo: regresión simple sin constante con $x = (1, \dots, 1, L)'$ y $\Sigma = \text{diag}(\sigma_1^2, \dots, \sigma_n^2)$ donde solo la última observación (la de regresor grande L) tiene varianza alta. La verdadera varianza es $\sum x_i^2 \sigma_i^2 / (\sum x_i^2)^2$, dominada por $L^2 \sigma_n^2$, mientras que s^2 promedia varianzas y la fórmula clásica usa $\bar{\sigma}^2 / \sum x_i^2$. Si L y σ_n^2 son grandes, la fórmula clásica subestima mucho. Moraleja: la heterocedasticidad es peligrosa cuando está correlacionada con x_i^2 . White (1980) lo formalizó; lo veremos en la Clase 7.

Ejercicio 4.7 ★. Bajo RL1–RL4 y errores normales, compara el error cuadrático medio de s^2 con el del estimador de máxima verosimilitud $\hat{\sigma}^2 = \hat{u}'\hat{u}/n$. (Usa que, bajo normalidad, $\text{Var}(s^2 | X) = 2\sigma^4/(n - k)$, que probaremos en la Clase 5.) ¿Cuál gana?

 Solución 4.7 ★

$\hat{\sigma}^2 = \frac{n-k}{n} s^2$, así que su sesgo es $-\frac{k}{n} \sigma^2$ y su varianza es $\frac{(n-k)^2}{n^2} \cdot \frac{2\sigma^4}{n-k} = \frac{2(n-k)\sigma^4}{n^2}$. Entonces

$$\text{ECM}(\hat{\sigma}^2) = \sigma^4 \frac{2(n-k) + k^2}{n^2}, \quad \text{ECM}(s^2) = \frac{2\sigma^4}{n-k}.$$

Con $m = n - k$, la desigualdad $\text{ECM}(\hat{\sigma}^2) < \text{ECM}(s^2)$ equivale a $(2m + k^2)m < 2(m + k)^2$, es decir, $k^2 m < 4mk + 2k^2$, o bien

$$m(k - 4) < 2k.$$

Si $k \leq 4$ esto vale siempre: el estimador sesgado gana. Si $k \geq 5$, gana solo cuando $n - k < 2k/(k - 4)$, es decir, en muestras muy pequeñas; para n moderado gana s^2 . Mora-

leja: incesgamiento y ECM mínimo son criterios distintos, y ninguno domina al otro en general.