

Clase 5 · Inferencia exacta bajo normalidad

Formas cuadráticas, χ^2 , t y F

Contenido

1	Del promedio a la distribución	1
2	La normal multivariada	2
3	Las distribuciones χ^2 , t y F	3
4	La distribución exacta de MCO	5
5	El test t	6
5.1	Tests e intervalos	7
6	El test F de restricciones lineales	8
6.1	La forma “restringido versus no restringido” . . .	10
7	★ Postgrado: mínimos cuadrados restringidos	11
8	Resumen	12
9	Ejercicios	12

1. Del promedio a la distribución

La Clase 4 nos dijo cuánto vale $\hat{\beta}$ *en promedio* y cuánto *varía*. Para hacer inferencia (tests, intervalos de confianza, valores p) necesi-

tamos más: necesitamos su **distribución**. ¿Con qué probabilidad $\hat{\beta}_2$ cae a más de dos errores estándar de β_2 ?

Hay dos caminos. El de esta clase: suponer que los errores son normales y obtener distribuciones **exactas**, válidas para cualquier n . El de las Clases 6 y 7: no suponer normalidad y obtener distribuciones **aproximadas**, válidas cuando n es grande. El primer camino es más antiguo, más elegante y, francamente, menos realista.¹ Pero sus resultados son la base de todo lo que reportan los programas estadísticos, y su maquinaria (formas cuadráticas de normales) es muy bonita.



Supuesto adicional

- **RL5 (normalidad):** $u | X \sim N(0, \sigma^2 I_n)$.

Nota que RL5 implica RL3 y RL4, así que “RL1–RL5” es lo mismo que “RL1, RL2 y RL5”.

¹ La distribución t fue descubierta por William Gosset en 1908 mientras trabajaba en la cervecería Guinness, estudiando la calidad de la cebada con muestras pequeñas. Guinness no permitía a sus empleados publicar, así que firmó como “Student”. Por eso es la “ t de Student”: la distribución más famosa de la estadística lleva el seudónimo de un cervecero.

2. La normal multivariada

Definición 2.1 (Normal multivariada). Un vector aleatorio $z \in \mathbb{R}^m$ tiene distribución **normal multivariada** con media μ y varianza Σ , $z \sim N(\mu, \Sigma)$, si para todo $a \in \mathbb{R}^m$ la variable escalar $a'z$ tiene distribución $N(a'\mu, a'\Sigma a)$. (Una normal con varianza cero es una constante.)

Esta definición, vía combinaciones lineales, no requiere que Σ sea invertible y hace que las demostraciones sean de una línea. Cuando $\Sigma \succ 0$, es equivalente a que z tenga la densidad conocida

$$f(z) = (2\pi)^{-m/2} \det(\Sigma)^{-1/2} \exp \left\{ -\frac{1}{2} (z - \mu)' \Sigma^{-1} (z - \mu) \right\}.$$

Usaremos tres propiedades.

Teorema 2.1 (Transformaciones lineales de normales). Si $z \sim N(\mu, \Sigma)$ y A ($p \times m$), c ($p \times 1$) son constantes, entonces $Az + c \sim N(A\mu + c, A\Sigma A')$.

Demostración. Sea $b \in \mathbb{R}^p$. Entonces $b'(Az + c) = (A'b)'z + b'c$. Por definición, $(A'b)'z \sim N(b'A\mu, b'A\Sigma A'b)$, y sumarle la constante $b'c$ desplaza la media. Luego $b'(Az + c) \sim N(b'(A\mu + c), b'(A\Sigma A')b)$ para todo b , que es la definición de $Az + c \sim N(A\mu + c, A\Sigma A')$. $\square$

Teorema 2.2 (En la normal, no correlación implica independencia). Sea $(z'_1, z'_2)'$ conjuntamente normal. Si $\text{Cov}(z_1, z_2) = 0$, entonces z_1 y z_2 son independientes.

Demostración. (Caso $\Sigma > 0$.) Si la covarianza cruzada es cero, $\Sigma = \text{diag}(\Sigma_{11}, \Sigma_{22})$ es diagonal por bloques. Entonces $\det \Sigma = \det \Sigma_{11} \det \Sigma_{22}$, $\Sigma^{-1} = \text{diag}(\Sigma_{11}^{-1}, \Sigma_{22}^{-1})$ y la forma cuadrática del exponente se separa:

$$(z - \mu)' \Sigma^{-1} (z - \mu) = (z_1 - \mu_1)' \Sigma_{11}^{-1} (z_1 - \mu_1) + (z_2 - \mu_2)' \Sigma_{22}^{-1} (z_2 - \mu_2).$$

La densidad conjunta es el producto de la densidad normal de z_1 por la de z_2 , lo que es la definición de independencia. (El caso singular se trata con funciones características; ver el Ejercicio 5.6.) $\square$

¡Conjuntamente!

El teorema exige que el vector (z_1, z_2) sea normal **conjuntamente**. Dos variables normales por separado y no correlacionadas pueden ser dependientes: si $z \sim N(0, 1)$ y $s = \pm 1$ con probabilidad $\frac{1}{2}$ independiente de z , entonces $w = sz$ también es $N(0, 1)$, $\text{Cov}(z, w) = \mathbb{E}[s] \mathbb{E}[z^2] = 0$, pero $|w| = |z|$. Son tan dependientes como se puede ser.

3. Las distribuciones χ^2 , t y F

Definición 3.1 (Distribuciones derivadas de la normal).

- Si $w_1, \dots, w_r$ son i.i.d. $N(0, 1)$, entonces $\sum_{j=1}^r w_j^2 \sim \chi_r^2$ (**chi-cuadrado** con r grados de libertad).
- Si $Z \sim N(0, 1)$ y $V \sim \chi_r^2$ son independientes, entonces $Z/\sqrt{V/r} \sim t_r$ (**t de Student** con r grados de libertad).

- Si $V_1 \sim \chi_{r_1}^2$ y $V_2 \sim \chi_{r_2}^2$ son independientes, entonces $\frac{V_1/r_1}{V_2/r_2} \sim F_{r_1, r_2}$ (**F de Fisher-Snedecor**).

Como $\mathbb{E}[w_j^2] = 1$ y $\text{Var}(w_j^2) = \mathbb{E}[w_j^4] - 1 = 3 - 1 = 2$, una χ_r^2 tiene media r y varianza $2r$. De la definición también sale que si $T \sim t_r$ entonces $T^2 \sim F_{1, r}$ (porque $Z^2 \sim \chi_1^2$).

La observación clave de toda la clase es que **ciertas formas cuadráticas de vectores normales son χ^2** . Hay dos versiones.

Lema 3.1 (Formas cuadráticas idempotentes). Si $z \sim N(0, I_m)$ y A es simétrica e idempotente con $\text{rango}(A) = r$, entonces $z'Az \sim \chi_r^2$.

Borrador

Si A fuera $\text{diag}(1, \dots, 1, 0, \dots, 0)$ con r unos, sería trivial: $z'Az = z_1^2 + \dots + z_r^2$, suma de r normales estándar independientes al cuadrado. Por el teorema espectral, toda simétrica idempotente es “así, en otra base”: $A = Q\Lambda Q'$ con Λ de ceros y unos. Solo necesito que el cambio de base $w = Q'z$ no arruine la normalidad estándar. Y no la arruina: la normal estándar es invariante a rotaciones, porque $\text{Var}(Q'z) = Q'IQ = I$.

Demostración. Por el teorema espectral y porque los valores propios de una idempotente son 0 o 1 (Clase 1), $A = Q\Lambda Q'$ con Q ortogonal y Λ diagonal con exactamente r unos (pues $r = \text{rango}(A)$ es el número de valores propios no nulos). Reordenando columnas de Q podemos suponer que $\Lambda = \text{diag}(I_r, 0)$. Sea $w = Q'z$. Por Teorema 2.1, $w \sim N(0, Q'IQ) = N(0, I_m)$, así que $w_1, \dots, w_m$ son i.i.d. $N(0, 1)$ (por Teorema 2.2, normales conjuntas no correlacionadas). Finalmente,

$$z'Az = z'Q\Lambda Q'z = w'\Lambda w = \sum_{j=1}^r w_j^2 \sim \chi_r^2.$$

□

Lema 3.2 (Forma cuadrática con la inversa de la varianza). Si $z \sim N(0, \Sigma)$ con Σ de $q \times q$ definida positiva, entonces $z' \Sigma^{-1} z \sim \chi_q^2$.

Demostración. Sea $w = \Sigma^{-1/2} z$, con $\Sigma^{-1/2}$ la raíz cuadrada inversa simétrica (Clase 1, sección ★). Por Teorema 2.1, $w \sim N(0, \Sigma^{-1/2} \Sigma \Sigma^{-1/2}) = N(0, I_q)$. Entonces $z' \Sigma^{-1} z = z' \Sigma^{-1/2} \Sigma^{-1/2} z = w' w = \sum_{j=1}^q w_j^2 \sim \chi_q^2$. $\square$

4. La distribución exacta de MCO

Teorema 4.1 (Distribución de $\hat{\beta}$ y s^2 bajo normalidad). Bajo RL1, RL2 y RL5, condicional en X :

1. $\hat{\beta} \sim N(\beta, \sigma^2 (X'X)^{-1})$.
2. $\frac{(n-k)s^2}{\sigma^2} \sim \chi_{n-k}^2$.
3. $\hat{\beta}$ y s^2 son independientes.

Borrador

Las tres cosas vienen de escribir todo en términos de $z = u/\sigma \sim N(0, I_n)$.

- (1) $\hat{\beta} = \beta + (X'X)^{-1} X' u$ es lineal en u , así que es normal, y la media y varianza ya las conozco de la Clase 4.
- (2) $(n-k)s^2/\sigma^2 = \hat{u}' \hat{u} / \sigma^2 = u' M u / \sigma^2 = z' M z$. M es simétrica, idempotente, de rango $n-k$. ¡Es Lema 3.1!
- (3) $\hat{\beta}$ depende de u solo a través de $(X'X)^{-1} X' u$, y s^2 solo a través de $M u$. Si $(X'X)^{-1} X' u$ y $M u$ no están correlacionados, como son conjuntamente normales, son independientes. La covarianza es $\sigma^2 (X'X)^{-1} X' M = 0$ porque $X' M = 0$. Esto ya lo vimos en el Ejercicio 4.2.

Demostración. Trabajamos condicional en X , de modo que X, P y M son constantes. Por RL5, $u \sim N(0, \sigma^2 I_n)$.

(1) $\hat{\beta} = \beta + (X'X)^{-1}X'u$ es una transformación lineal de u . Por Teorema 2.1, $\hat{\beta} \sim N(\beta, (X'X)^{-1}X'\sigma^2IX(X'X)^{-1}) = N(\beta, \sigma^2(X'X)^{-1})$.

(2) Sea $z = u/\sigma \sim N(0, I_n)$. Como $\hat{u} = Mu$ y M es simétrica idempotente,

$$\frac{(n-k)s^2}{\sigma^2} = \frac{\hat{u}'\hat{u}}{\sigma^2} = \frac{u'Mu}{\sigma^2} = z'Mz.$$

M es simétrica, idempotente y de rango $n-k$ (Clase 1), así que por Lema 3.1, $z'Mz \sim \chi_{n-k}^2$.

(3) Consideremos el vector apilado

$$\begin{pmatrix} (X'X)^{-1}X'u \\ Mu \end{pmatrix} = \begin{pmatrix} (X'X)^{-1}X' \\ M \end{pmatrix} u,$$

que es conjuntamente normal por Teorema 2.1. Su bloque de covarianza cruzada es

$$(X'X)^{-1}X'(\sigma^2I_n)M' = \sigma^2(X'X)^{-1}(MX)' = 0.$$

Por Teorema 2.2, $(X'X)^{-1}X'u$ y Mu son independientes. Como $\hat{\beta}$ es función del primero y $s^2 = (Mu)'(Mu)/(n-k)$ es función del segundo, $\hat{\beta}$ y s^2 son independientes.

□

De (2) sale de regalo la varianza de s^2 que usamos en el Ejercicio 4.7: $\text{Var}((n-k)s^2/\sigma^2) = 2(n-k)$, luego $\text{Var}(s^2 | X) = 2\sigma^4/(n-k)$.

5. El test t

Queremos testear $H_0 : \beta_j = \beta_j^0$ para un valor dado β_j^0 (típicamente cero). Si conociéramos σ^2 , usaríamos

$$Z = \frac{\hat{\beta}_j - \beta_j^0}{\sigma \sqrt{[(X'X)^{-1}]_{jj}}} \sim N(0, 1) \text{ bajo } H_0.$$

Pero no conocemos σ . Lo reemplazamos por s y la distribución cambia de normal a t .

Teorema 5.1 (Distribución del estadístico t). Bajo RL1, RL2, RL5 y $H_0 : \beta_j = \beta_j^0$,

$$t_j = \frac{\hat{\beta}_j - \beta_j^0}{\text{ee}(\hat{\beta}_j)} = \frac{\hat{\beta}_j - \beta_j^0}{s \sqrt{[(X'X)^{-1}]_{jj}}} \sim t_{n-k}.$$

Esto vale condicional en X y también incondicionalmente.

Demostración. Sea $v_{jj} = [(X'X)^{-1}]_{jj}$. Escribimos

$$t_j = \frac{(\hat{\beta}_j - \beta_j^0)/(\sigma \sqrt{v_{jj}})}{s/\sigma} = \frac{Z}{\sqrt{V/(n-k)}}, \quad Z = \frac{\hat{\beta}_j - \beta_j^0}{\sigma \sqrt{v_{jj}}}, \quad V = \frac{(n-k)s^2}{\sigma^2}.$$

Condicional en X y bajo H_0 :

- $Z \sim N(0, 1)$, por Teorema 4.1 (1): la coordenada j de $\hat{\beta}$ es $N(\beta_j, \sigma^2 v_{jj})$.
- $V \sim \chi_{n-k}^2$, por Teorema 4.1 (2).
- Z y V son independientes, por Teorema 4.1 (3): Z es función de $\hat{\beta}$ y V de s^2 .

Por definición, $t_j \sim t_{n-k}$ condicional en X . Como esta distribución condicional no depende de X , la distribución incondicional es la misma: para todo c , $P(t_j \leq c) = \mathbb{E}[P(t_j \leq c \mid X)] = \mathbb{E}[F_{t_{n-k}}(c)] = F_{t_{n-k}}(c)$. $\square$

El último paso es sutil y precioso: **el estadístico t es pivotal**. Su distribución no depende de ningún parámetro desconocido (β , σ^2) ni de X . Por eso podemos tabularla una vez y usarla siempre.

5.1. Tests e intervalos

Sea $c_{\alpha/2}$ el cuantil $1 - \alpha/2$ de la t_{n-k} . Entonces:

- **Test bilateral** de nivel α : rechazar $H_0 : \beta_j = \beta_j^0$ si $|t_j| > c_{\alpha/2}$. Bajo H_0 , la probabilidad de rechazar es **exactamente** α .

- **Intervalo de confianza** de nivel $1 - \alpha$: $\hat{\beta}_j \pm c_{\alpha/2} \text{ee}(\hat{\beta}_j)$. Contiene a β_j con probabilidad exactamente $1 - \alpha$, porque

$$P(\beta_j \in \hat{\beta}_j \pm c_{\alpha/2} \text{ee}(\hat{\beta}_j)) = P\left(\left|\frac{\hat{\beta}_j - \beta_j}{\text{ee}(\hat{\beta}_j)}\right| \leq c_{\alpha/2}\right) = 1 - \alpha.$$

- **Valor p**: $p = P(|T| \geq |t_j^{\text{obs}}|)$ con $T \sim t_{n-k}$. Es el menor nivel α al que se rechazaría.

Qué es (y qué no es) un intervalo de confianza

“Tengo 95 % de confianza en que $\beta_j \in [0,3; 0,9]$ ” **no** significa que $P(\beta_j \in [0,3; 0,9]) = 0,95$. El parámetro β_j es un número fijo: o está en el intervalo o no está. Lo aleatorio es el intervalo. El 95 % es una propiedad del **procedimiento**: si repites el muestreo muchas veces, el 95 % de los intervalos que construyas contendrá a β_j .¹

Ejemplo 5.1 (Un test t). En una regresión de $\log(\text{salario})$ sobre una constante, años de educación y experiencia con $n = 53$ observaciones, se obtiene $\hat{\beta}_{\text{educ}} = 0,082$ con $\text{ee} = 0,021$. Con $n - k = 50$ grados de libertad, $c_{0,025} \approx 2,009$. El estadístico para $H_0 : \beta_{\text{educ}} = 0$ es $t = 0,082/0,021 \approx 3,90 > 2,009$: se rechaza al 5 %. El intervalo al 95 % es $0,082 \pm 2,009 \cdot 0,021 = [0,040; 0,124]$: cada año de educación se asocia con un salario entre 4 % y 12 % mayor, aproximadamente.

6. El test F de restricciones lineales

Muchas hipótesis interesantes involucran varios coeficientes a la vez: “educación y experiencia no importan” ($\beta_2 = \beta_3 = 0$), “rendimientos constantes a escala” ($\beta_2 + \beta_3 = 1$), etc. Todas se escriben como

$$H_0 : R\beta = r,$$

¹Si quieres decir “la probabilidad de que β_j esté en el intervalo es 95 %”, tienes que volverte bayesiano, poner una distribución a priori sobre β_j y calcular un *intervalo de credibilidad*. Con una a priori plana y errores normales, el intervalo resultante es numéricamente el mismo. La filosofía, no.

con R una matriz $q \times k$ de rango q (las q restricciones no son redundantes) y $r \in \mathbb{R}^q$. Por ejemplo, con $k = 3$, " $\beta_2 = \beta_3 = 0$ " es $R = \begin{pmatrix} 0 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix}$, $r = (0, 0)'$, y " $\beta_2 + \beta_3 = 1$ " es $R = (0 \ 1 \ 1)$, $r = 1$.

Teorema 6.1 (Distribución del estadístico F). *Bajo RL1, RL2, RL5 y $H_0 : R\beta = r$ (con $\text{rango}(R) = q$),*

$$F = \frac{(R\hat{\beta} - r)' [R(X'X)^{-1}R']^{-1} (R\hat{\beta} - r)}{q s^2} \sim F_{q, n-k}.$$

Borrador

Mismo esquema que el test t : escribir F como cociente de dos χ^2 independientes divididas por sus grados de libertad. Numerador: $R\hat{\beta} - r$ es normal (lineal en $\hat{\beta}$), con media $R\beta - r = 0$ bajo H_0 y varianza $\sigma^2 R(X'X)^{-1}R'$. La forma cuadrática "vector por inversa de su varianza por vector" es χ_q^2 por Lema 3.2. Para usar ese lema necesito que $R(X'X)^{-1}R'$ sea invertible; eso sale de la Clase 1, porque $(X'X)^{-1} > 0$ y R' tiene rango columna q . Denominador: $(n - k)s^2/\sigma^2 \sim \chi_{n-k}^2$. Independencia: el numerador es función de $\hat{\beta}$, el denominador de s^2 . Los σ^2 se cancelan.

Demostración. Condicional en X . Sea $\Sigma_R = R(X'X)^{-1}R' \ (q \times q)$. Como $(X'X)^{-1} > 0$ y $R' \ (k \times q)$ tiene rango q , por las propiedades de las matrices definidas positivas (Clase 1), $\Sigma_R > 0$ y es invertible.

Por Teorema 4.1 (1) y Teorema 2.1, bajo H_0 ,

$$R\hat{\beta} - r = R(\hat{\beta} - \beta) \sim N(0, \sigma^2 \Sigma_R).$$

Por Lema 3.2,

$$V_1 = \frac{(R\hat{\beta} - r)' \Sigma_R^{-1} (R\hat{\beta} - r)}{\sigma^2} = (R\hat{\beta} - r)' (\sigma^2 \Sigma_R)^{-1} (R\hat{\beta} - r) \sim \chi_q^2.$$

Por Teorema 4.1 (2), $V_2 = (n - k)s^2/\sigma^2 \sim \chi_{n-k}^2$, y por (3), V_1 (función de $\hat{\beta}$) y V_2 (función de s^2) son independientes. Entonces

$$\frac{V_1/q}{V_2/(n - k)} = \frac{(R\hat{\beta} - r)' \Sigma_R^{-1} (R\hat{\beta} - r)/(q\sigma^2)}{s^2/\sigma^2} = F \sim F_{q, n-k}.$$

Como en el test t , la distribución no depende de X , así que también vale incondicionalmente. $\square$

Si $q = 1$ y $R = e'_j$, entonces $\Sigma_R = [(X'X)^{-1}]_{jj}$ y $F = t_j^2$: el test F de una restricción es el test t bilateral.

6.1. La forma “restringido versus no restringido”

Hay una forma equivalente del estadístico F que es mucho más fácil de calcular y de recordar. Sea $\tilde{\beta}$ el estimador de **mínimos cuadrados restringidos**: el que minimiza $S(b) = (y - Xb)'(y - Xb)$ sujeto a $Rb = r$. Sea $SCR_R = S(\tilde{\beta})$ su suma de residuos, y $SCR_{NR} = S(\hat{\beta}) = (n - k)s^2$ la del modelo sin restringir.

Teorema 6.2 (F con sumas de residuos).

$$F = \frac{(SCR_R - SCR_{NR})/q}{SCR_{NR}/(n - k)}.$$

La intuición es inmejorable: **imponer restricciones empeora el ajuste; el test F pregunta si lo empeora “demasiado”**. Si H_0 es cierta, imponerla debería costar poco. La demostración está en la sección ★.

Un caso particular importantísimo es el **test de significancia global**, $H_0 : \beta_2 = \dots = \beta_k = 0$ (todos menos la constante). El modelo restringido solo tiene constante, así que $SCR_R = SCT$, y dividiendo numerador y denominador por SCT,

$$F = \frac{R^2/(k - 1)}{(1 - R^2)/(n - k)}.$$

7. ★ Postgrado: mínimos cuadrados restringidos

! ★ Postgrado

Derivamos $\tilde{\beta}$ con multiplicadores de Lagrange y demostramos Teorema 6.2 usando la identidad de completación de cuadrados de la Clase 3.

Teorema 7.1 (Mínimos cuadrados restringidos). Si $\text{rango}(X) = k$ y $\text{rango}(R) = q$, el minimizador de $S(b)$ sujeto a $Rb = r$ es

$$\tilde{\beta} = \hat{\beta} - (X'X)^{-1}R'[R(X'X)^{-1}R']^{-1}(R\hat{\beta} - r).$$

i Borrador

La identidad de la Clase 3 dice $S(b) = S(\hat{\beta}) + (b - \hat{\beta})'X'X(b - \hat{\beta})$. Así que minimizar $S(b)$ sujeto a $Rb = r$ es minimizar la **distancia** $(b - \hat{\beta})'X'X(b - \hat{\beta})$ de b a $\hat{\beta}$ (medida con la métrica $X'X$) sobre el conjunto afín $\{b : Rb = r\}$. Es una proyección. Con Lagrange: $\mathcal{L} = (b - \hat{\beta})'X'X(b - \hat{\beta}) + 2\lambda'(Rb - r)$. Condición de primer orden: $2X'X(b - \hat{\beta}) + 2R'\lambda = 0$, así que $b = \hat{\beta} - (X'X)^{-1}R'\lambda$. Imponiendo $Rb = r$ despejo λ .

Demostración. Sea $A = X'X \succ 0$ y $\Sigma_R = RA^{-1}R' \succ 0$. Por la identidad de completación de cuadrados de MCO (Clase 3), para todo b ,

$$S(b) = S(\hat{\beta}) + (b - \hat{\beta})'A(b - \hat{\beta}). \quad (1)$$

Definamos $\tilde{\beta}$ como en el enunciado. Primero, es factible: $R\tilde{\beta} = R\hat{\beta} - RA^{-1}R'\Sigma_R^{-1}(R\hat{\beta} - r) = R\hat{\beta} - (R\hat{\beta} - r) = r$.

Ahora sea b cualquier punto factible ($Rb = r$) y escribamos $b - \hat{\beta} = (b - \tilde{\beta}) + (\tilde{\beta} - \hat{\beta})$. Entonces

$$(b - \hat{\beta})'A(b - \hat{\beta}) = (b - \tilde{\beta})'A(b - \tilde{\beta}) + (\tilde{\beta} - \hat{\beta})'A(\tilde{\beta} - \hat{\beta}) + 2(b - \tilde{\beta})'A(\tilde{\beta} - \hat{\beta}).$$

El término cruzado es cero: $A(\tilde{\beta} - \hat{\beta}) = -R'\Sigma_R^{-1}(R\hat{\beta} - r)$, así que

$$(b - \tilde{\beta})'A(\tilde{\beta} - \hat{\beta}) = -(Rb - R\tilde{\beta})'\Sigma_R^{-1}(R\hat{\beta} - r) = -(r - r)'\Sigma_R^{-1}(R\hat{\beta} - r) = 0.$$

Luego, para todo b factible, $(b - \hat{\beta})' A (b - \hat{\beta}) \geq (\tilde{\beta} - \hat{\beta})' A (\tilde{\beta} - \hat{\beta})$, con igualdad si y solo si $b = \tilde{\beta}$ (pues $A \succ 0$). Por Ecuación 1, $\tilde{\beta}$ es el único minimizador de S sobre el conjunto factible. $\square$

Demostración. (de Teorema 6.2). Por Ecuación 1 con $b = \tilde{\beta}$,

$$SCR_R - SCR_{NR} = (\tilde{\beta} - \hat{\beta})' X' X (\tilde{\beta} - \hat{\beta}).$$

Sustituyendo $\tilde{\beta} - \hat{\beta} = -A^{-1} R' \Sigma_R^{-1} (R\hat{\beta} - r)$,

$$(\tilde{\beta} - \hat{\beta})' A (\tilde{\beta} - \hat{\beta}) = (R\hat{\beta} - r)' \Sigma_R^{-1} \underbrace{R A^{-1} A A^{-1} R'}_{= \Sigma_R} \Sigma_R^{-1} (R\hat{\beta} - r) = (R\hat{\beta} - r)' \Sigma_R^{-1} (R\hat{\beta} - r).$$

Este es exactamente el numerador de F multiplicado por q . Como $s^2 = SCR_{NR}/(n - k)$, las dos expresiones de F coinciden. $\square$

Una consecuencia inmediata: $SCR_R \geq SCR_{NR}$, así que $F \geq 0$. Y si $R\hat{\beta} = r$ (el estimador sin restringir ya cumple la restricción), $\tilde{\beta} = \hat{\beta}$ y $F = 0$.

8. Resumen

- Bajo normalidad, $\hat{\beta} \mid X \sim N(\beta, \sigma^2 (X'X)^{-1})$, $(n - k)s^2 / \sigma^2 \sim \chi_{n-k}^2$, y ambos son independientes (Teorema 4.1).
- La herramienta clave: $z'Az \sim \chi_r^2$ si $z \sim N(0, I)$ y A es simétrica idempotente de rango r (Lema 3.1).
- $t_j = (\hat{\beta}_j - \beta_j^0) / ee(\hat{\beta}_j) \sim t_{n-k}$ exactamente (Teorema 5.1). Es pivotal.
- Para $H_0 : R\beta = r$, $F \sim F_{q, n-k}$ (Teorema 6.1), y $F = \frac{(SCR_R - SCR_{NR})/q}{SCR_{NR}/(n-k)}$ (Teorema 6.2).

9. Ejercicios

Ejercicio 5.1. En una regresión con $n = 40$ y $k = 4$ (incluida la constante) se obtiene $R^2 = 0,30$. Testea la significancia global al 5 %. (El cuantil 0,95 de la $F_{3,36}$ es aproximadamente 2,87.)

💡 Solución 5.1

$F = \frac{0,30/3}{0,70/36} = \frac{0,10}{0,01944} \approx 5,14 > 2,87$. Se rechaza que todos los coeficientes (salvo la constante) sean cero.

Ejercicio 5.2. Sea $z \sim N(0, I_n)$ y $M^0 = I - \frac{1}{n}u'u$. Demuestra que $\sum_i (z_i - \bar{z})^2 \sim \chi_{n-1}^2$ y que es independiente de $\bar{z}$. Deduce que, para una muestra i.i.d. $N(\mu, \sigma^2)$, $\sqrt{n}(\bar{x} - \mu)/S \sim t_{n-1}$, con S^2 la varianza muestral.

💡 Solución 5.2

$\sum (z_i - \bar{z})^2 = z'M^0 z$ y M^0 es simétrica idempotente de rango $n - 1$ (Clase 1): es χ_{n-1}^2 por Lema 3.1. $\bar{z} = \frac{1}{n}1'z$ y $\text{Cov}(\frac{1}{n}1'z, M^0 z) = \frac{1}{n}1'M^0 = 0$, así que son independientes. Es el caso $X = \iota$ de Teorema 4.1. Para la muestra, $z_i = (x_i - \mu)/\sigma$, y $\sqrt{n}(\bar{x} - \mu)/S = \frac{\sqrt{n}\bar{z}}{\sqrt{z'M^0 z/(n-1)}}$, cociente de una $N(0, 1)$ y la raíz de una $\chi_{n-1}^2/(n-1)$ independiente.

Ejercicio 5.3. Escribe R y r para testear, en $\log Q = \beta_1 + \beta_2 \log K + \beta_3 \log L + u$, la hipótesis de rendimientos constantes a escala. Muestra que el modelo restringido se puede estimar por MCO con una variable transformada.

💡 Solución 5.3

$R = (0 \ 1 \ 1)$, $r = 1$. Bajo H_0 , $\beta_3 = 1 - \beta_2$ y $\log Q - \log L = \beta_1 + \beta_2(\log K - \log L) + u$: se regresa $\log(Q/L)$ sobre una constante y $\log(K/L)$. Su SCR es SCR_R (ojo: la variable dependiente cambió, pero los residuos son los del modelo original restringido, así que la SCR es comparable).

Ejercicio 5.4. Demuestra que si $T \sim t_r$, entonces $T^2 \sim F_{1,r}$, y usa esto para mostrar que el test F de $H_0 : \beta_j = 0$ y el test t bilateral rechazan exactamente en los mismos casos.

💡 Solución 5.4

$T = Z/\sqrt{V/r}$ con $Z \sim N(0, 1)$ indep. de $V \sim \chi_r^2$. $T^2 = (Z^2/1)/(V/r)$ con $Z^2 \sim \chi_1^2$ independiente de V : es $F_{1,r}$. Si c es el cuantil $1 - \alpha/2$ de la t_r , entonces c^2 es el cuantil $1 - \alpha$ de la $F_{1,r}$, porque $P(T^2 \leq c^2) = P(|T| \leq c) = 1 - \alpha$. Luego $|t_j| > c \Leftrightarrow t_j^2 = F > c^2$.

Ejercicio 5.5. ¿Por qué no se puede usar el test F con sumas de residuos para comparar $y = \beta_1 + \beta_2 x + u$ con $\log y = \gamma_1 + \gamma_2 x + v$?

💡 Solución 5.5

Porque no son modelos anidados: ninguno es una restricción lineal del otro, y las variables dependientes son distintas, así que las SCR están en unidades distintas. El test F exige que el modelo restringido sea el sin restringir con $R\beta = r$ impuesto.

Ejercicio 5.6 ★. Usa la función característica $\varphi_z(t) = \mathbb{E}[e^{it'z}] = \exp(it'\mu - \frac{1}{2}t'\Sigma t)$ de la $N(\mu, \Sigma)$ para demostrar Teorema 2.2 sin suponer $\Sigma \succ 0$.

💡 Solución 5.6 ★

Con $t = (t'_1, t'_2)'$ y $\Sigma_{12} = 0$: $t'\Sigma t = t'_1 \Sigma_{11} t_1 + t'_2 \Sigma_{22} t_2$ y $t'\mu = t'_1 \mu_1 + t'_2 \mu_2$, así que $\varphi_z(t) = \varphi_{z_1}(t_1) \varphi_{z_2}(t_2)$. La función característica conjunta se factoriza, lo que (por la unicidad de la función característica) equivale a independencia. La fórmula de φ_z vale aunque Σ sea singular: por la definición, $t'z \sim N(t'\mu, t'\Sigma t)$, y la función característica de una normal escalar evaluada en 1 da $\exp(it'\mu - \frac{1}{2}t'\Sigma t)$.

Ejercicio 5.7 ★. (Región de confianza.) Demuestra que el conjunto $\{b \in \mathbb{R}^k : (\hat{\beta} - b)'X'X(\hat{\beta} - b) \leq k s^2 c\}$, con c el cuantil $1 - \alpha$ de la $F_{k, n-k}$, es una región de confianza de nivel exacto $1 - \alpha$ para β . ¿Qué forma geométrica tiene?

💡 Solución 5.7 ★

Con $R = I_k$, $r = \beta$, el estadístico $F = (\hat{\beta} - \beta)'X'X(\hat{\beta} - \beta)/(ks^2) \sim F_{k,n-k}$. Luego $P(F \leq c) = 1 - \alpha$, que es exactamente $P(\beta \in \text{región})$. La región es un elipsoide centrado en $\hat{\beta}$ con ejes en las direcciones de los vectores propios de $X'X$: es más angosto en las direcciones en que los datos tienen más variación. Con regresores muy correlacionados, el elipsoide es muy alargado: esa es la cara geométrica de la multicolinealidad (Clase 8).