

Clase 6 · Teoría asintótica

Convergencia, ley de los grandes números y teorema central del límite

Contenido

1	¿Por qué pensar en $n \rightarrow \infty$?	2
2	Convergencia en probabilidad	2
2.1	Dos desigualdades	3
2.2	La ley de los grandes números	4
2.3	El teorema de la función continua	5
3	Convergencia en distribución	6
3.1	El teorema central del límite	6
3.2	Slutsky y la función continua (en distribución) . .	7
4	El método delta	9
5	★ Postgrado: notación O_p, Slutsky y el TCL demostrados	10
5.1	Órdenes estocásticos	10
5.2	Una parte de Slutsky	11
5.3	Demostración del TCL	12
6	Resumen	13
7	Ejercicios	14

1. ¿Por qué pensar en $n \rightarrow \infty$?

La Clase 5 obtuvo distribuciones exactas, pero a un precio alto: supusimos que los errores son normales. En la práctica, casi nunca lo son. Los salarios tienen colas largas, las ventas son asimétricas, las variables binarias ni siquiera son continuas. ¿Qué hacemos?

La respuesta de la econometría moderna es: **aproximar**. En lugar de preguntar “¿cuál es la distribución exacta de $\hat{\beta}$ con $n = 500$?”, que no podemos responder sin conocer la distribución de los errores, preguntamos “¿a qué se parece la distribución de $\hat{\beta}$ cuando n es grande?”. La sorpresa, y es de las grandes sorpresas de la matemática,¹ es que la respuesta **casi no depende** de la distribución de los errores. Siempre se parece a una normal.

Esta clase construye las herramientas. La Clase 7 las aplica a MCO. Aviso: esta es la clase más “de análisis real” del curso, y es donde más se nota el estilo de demostraciones con ε .

¹ De verdad. Tómame un segundo para apreciar lo raro que es. Suma variables que siguen *cualquier* distribución (asimétrica, discreta, con forma de camello) y el resultado siempre tiende a la misma campana. Francis Galton decía que el TCL “habría sido personificado por los griegos y deificado, si lo hubieran conocido”.

2. Convergencia en probabilidad

Definición 2.1 (Convergencia en probabilidad). Una sucesión de variables aleatorias $\{Z_n\}$ **converge en probabilidad** a una constante c , y escribimos $Z_n \xrightarrow{p} c$ o $\text{plim } Z_n = c$, si para todo $\varepsilon > 0$,

$$\lim_{n \rightarrow \infty} P(|Z_n - c| > \varepsilon) = 0.$$

Para vectores o matrices, se exige lo mismo para cada coordenada (equivalentemente, con la norma euclidiana). Un estimador $\hat{\theta}_n$ es **consistente** para θ si $\hat{\theta}_n \xrightarrow{p} \theta$.

En palabras: para cualquier margen de error ε que elijas, por pequeño que sea, la probabilidad de que Z_n se aleje de c más que ε se hace despreciable cuando n crece. Consistencia es el requisito mínimo de un estimador: con infinitos datos, debería acertar.

2.1. Dos desigualdades

Para probar convergencia en probabilidad hay que acotar probabilidades de colas. La herramienta básica es sorprendentemente simple.

Lema 2.1 (Desigualdad de Markov). Si $W \geq 0$ y $a > 0$, entonces $P(W \geq a) \leq \frac{\mathbb{E}[W]}{a}$.

Borrador

Si W es no negativa y tiene media $\mathbb{E}W$, no puede ser “muy grande con mucha probabilidad”, porque eso subiría la media. ¿Cómo lo formalizo? Comparo W con una variable más chica cuya esperanza sea fácil: la función que vale a cuando $W \geq a$ y 0 si no. Es decir, $a \cdot \mathbb{1}\{W \geq a\}$. Siempre es $\leq W$ (dibújalo), y su esperanza es $a P(W \geq a)$.

Demostración. Para todo resultado posible, $a \mathbb{1}\{W \geq a\} \leq W$: si $W \geq a$, el lado izquierdo es $a \leq W$; si $W < a$, el lado izquierdo es $0 \leq W$. Tomando esperanza (que preserva desigualdades),

$$a P(W \geq a) = \mathbb{E}[a \mathbb{1}\{W \geq a\}] \leq \mathbb{E}[W].$$

Dividiendo por $a > 0$ se obtiene el resultado. $\square$

Lema 2.2 (Desigualdad de Chebyshev). Si $\mathbb{E}[Z^2] < \infty$ y $\varepsilon > 0$, entonces $P(|Z - c| > \varepsilon) \leq \frac{\mathbb{E}[(Z - c)^2]}{\varepsilon^2}$ para toda constante c . En particular, $P(|Z - \mathbb{E}Z| > \varepsilon) \leq \text{Var}(Z)/\varepsilon^2$.

Demostración. $|Z - c| > \varepsilon$ implica $(Z - c)^2 \geq \varepsilon^2$. Por Markov con $W = (Z - c)^2$ y $a = \varepsilon^2$,

$$P(|Z - c| > \varepsilon) \leq P((Z - c)^2 \geq \varepsilon^2) \leq \frac{\mathbb{E}[(Z - c)^2]}{\varepsilon^2}.$$

$\square$

2.2. La ley de los grandes números

Teorema 2.1 (Ley débil de los grandes números). Sean $Z_1, Z_2, \dots$ i.i.d. con $\mathbb{E}[Z_i] = \mu$ y $\text{Var}(Z_i) = \sigma^2 < \infty$. Entonces

$$\bar{Z}_n = \frac{1}{n} \sum_{i=1}^n Z_i \xrightarrow{p} \mu.$$

Demostración. Por linealidad, $\mathbb{E}[\bar{Z}_n] = \mu$. Por independencia (las covarianzas cruzadas son cero),

$$\text{Var}(\bar{Z}_n) = \frac{1}{n^2} \sum_{i=1}^n \text{Var}(Z_i) = \frac{n\sigma^2}{n^2} = \frac{\sigma^2}{n}.$$

Sea $\varepsilon > 0$. Por Chebyshev,

$$P(|\bar{Z}_n - \mu| > \varepsilon) \leq \frac{\sigma^2}{n\varepsilon^2} \xrightarrow{n \rightarrow \infty} 0.$$

□

La demostración es tan corta que parece trampa. La clave es que la varianza del promedio es σ^2/n : **promediar reduce la varianza al ritmo $1/n$** . El supuesto de varianza finita se puede debilitar: la LGN de Khinchine solo pide $\mathbb{E}|Z_i| < \infty$, pero su demostración requiere un argumento de truncamiento que omitimos.² También se pueden relajar “idénticamente distribuidas” e incluso “independientes”: en la demostración solo usamos que la varianza del promedio tiende a cero.

La demostración anterior en realidad prueba algo más fuerte, que merece nombre propio.

Teorema 2.2 (Convergencia en media cuadrática implica convergencia en probabilidad). Si $\mathbb{E}[(Z_n - c)^2] \rightarrow 0$, entonces $Z_n \xrightarrow{p} c$. En particular, si $\mathbb{E}[Z_n] \rightarrow c$ y $\text{Var}(Z_n) \rightarrow 0$, entonces $Z_n \xrightarrow{p} c$.

Demostración. La primera afirmación es Chebyshev: $P(|Z_n - c| > \varepsilon) \leq \mathbb{E}[(Z_n - c)^2]/\varepsilon^2 \rightarrow 0$. Para la segunda, $\mathbb{E}[(Z_n - c)^2] = \text{Var}(Z_n) + (\mathbb{E}Z_n - c)^2 \rightarrow 0 + 0$. □

² Esa versión es la que realmente usa la econometría, porque en la Clase 7 queremos aplicar la LGN a $x_i x_i' u_i^2$, y pedirle segundo momento a eso sería pedir cuartos momentos de los datos. El truncamiento es una idea preciosa: se corta la variable en un nivel que crece con n y se controla por separado el pedazo cortado.

Esta es la herramienta más práctica para probar consistencia: **si un estimador es asintóticamente insesgado y su varianza tiende a cero, es consistente.**

2.3. El teorema de la función continua

La LGN nos da la convergencia de promedios. Pero los estimadores no son promedios: $\hat{\beta}$ es una *inversa* de un promedio por otro promedio. Necesitamos saber que la convergencia se preserva al aplicar funciones.

Teorema 2.3 (Teorema de la función continua (en probabilidad)). Si $Z_n \xrightarrow{p} c$ (vectores en $\mathbb{R}^m$) y $g : \mathbb{R}^m \rightarrow \mathbb{R}^p$ es continua en c , entonces $g(Z_n) \xrightarrow{p} g(c)$.

Borrador

Continuidad en c dice: para cada ε existe δ tal que “ $\|z - c\| \leq \delta \Rightarrow \|g(z) - g(c)\| \leq \varepsilon$ ”. Tomando contrapositiva: “ $\|g(z) - g(c)\| > \varepsilon \Rightarrow \|z - c\| > \delta$ ”. Es decir, **el evento malo para $g(Z_n)$ está contenido en un evento malo para Z_n** . Y la probabilidad del evento malo para Z_n tiende a cero. ¡Es literalmente la definición de continuidad escrita en eventos!

Demostración. Sea $\varepsilon > 0$. Por continuidad de g en c , existe $\delta > 0$ tal que $\|z - c\| \leq \delta$ implica $\|g(z) - g(c)\| \leq \varepsilon$. Por contrapositiva, $\|g(Z_n) - g(c)\| > \varepsilon$ implica $\|Z_n - c\| > \delta$, es decir,

$$\{\|g(Z_n) - g(c)\| > \varepsilon\} \subseteq \{\|Z_n - c\| > \delta\}.$$

Por monotonía de la probabilidad y porque $Z_n \xrightarrow{p} c$,

$$P(\|g(Z_n) - g(c)\| > \varepsilon) \leq P(\|Z_n - c\| > \delta) \xrightarrow[n \rightarrow \infty]{} 0.$$

□

Consecuencias inmediatas: si $A_n \xrightarrow{p} A$ y $b_n \xrightarrow{p} b$, entonces $A_n + b_n \xrightarrow{p} A + b$, $A_n b_n \xrightarrow{p} Ab$ y, si A es invertible, $A_n^{-1} \xrightarrow{p} A^{-1}$ (la inversión de matrices es continua en las matrices invertibles, porque las entradas de la inversa son cocientes de polinomios con denominador $\det A \neq 0$). Esto es lo que hará funcionar la consistencia de MCO en la Clase 7.

3. Convergencia en distribución

Consistencia dice que $\hat{\theta}_n$ se acerca a θ . Pero para hacer inferencia necesitamos saber **cómo** se acerca: la forma de la distribución de $\hat{\theta}_n - \theta$, reescalada para que no colapse a cero.

Definición 3.1 (Convergencia en distribución). Z_n **converge en distribución** a Z , $Z_n \xrightarrow{d} Z$, si $\lim_{n \rightarrow \infty} P(Z_n \leq z) = P(Z \leq z)$ para todo z en que la función de distribución $F_Z(z) = P(Z \leq z)$ es continua. (Para vectores, con la desigualdad coordenada a coordenada.)

La cláusula “donde F_Z es continua” es un tecnicismo necesario: sin ella, $Z_n = 1/n$ no convergería en distribución a $Z = 0$, porque $P(Z_n \leq 0) = 0 \nrightarrow 1 = P(Z \leq 0)$. En los casos que nos interesan, el límite es normal y su F es continua en todas partes, así que la cláusula no molesta.

3.1. El teorema central del límite

Teorema 3.1 (Teorema central del límite (Lindeberg-Lévy)). Sean $Z_1, Z_2, \dots$ i.i.d. con $\mathbb{E}[Z_i] = \mu$ y $0 < \text{Var}(Z_i) = \sigma^2 < \infty$. Entonces

$$\sqrt{n}(\bar{Z}_n - \mu) \xrightarrow{d} N(0, \sigma^2).$$

Versión multivariada: si los $Z_i \in \mathbb{R}^m$ son i.i.d. con media μ y varianza Σ finita, entonces $\sqrt{n}(\bar{Z}_n - \mu) \xrightarrow{d} N(0, \Sigma)$.




Figura 1: Densidad de $\sqrt{n}(\bar{X}_n - \mu)/\sigma$ para datos exponenciales (muy asimétricos), estimada por simulación. Con $n = 50$ ya es difícil distinguirla de la normal.

La normalización $\sqrt{n}$ es la correcta: $\text{Var}(\bar{Z}_n - \mu) = \sigma^2/n$, así que $\text{Var}(\sqrt{n}(\bar{Z}_n - \mu)) = \sigma^2$, que ni explota ni colapsa. La LGN dice que $\bar{Z}_n - \mu$ tiende a cero; el TCL dice **a qué velocidad** ($1/\sqrt{n}$) y **con qué forma** (normal). La demostración está en la sección ★. La versión multivariada se deduce de la escalar con el siguiente truco.

Teorema 3.2 (Cramér–Wold). $Z_n \xrightarrow{d} Z$ en $\mathbb{R}^m$ si y solo si $a'Z_n \xrightarrow{d} a'Z$ para todo $a \in \mathbb{R}^m$.

(Lo aceptamos sin demostración: requiere funciones características.) Con él, el TCL multivariado es inmediato: para a fijo, los $a'Z_i$ son i.i.d. escalares con media $a'\mu$ y varianza $a'\Sigma a$, así que $a'\sqrt{n}(\bar{Z}_n - \mu) \xrightarrow{d} N(0, a'\Sigma a)$, que es la distribución de $a'W$ con $W \sim N(0, \Sigma)$.

3.2. Slutsky y la función continua (en distribución)

Teorema 3.3 (Teorema de la función continua (en distribución)).

Si $Z_n \xrightarrow{d} Z$ y g es continua, entonces $g(Z_n) \xrightarrow{d} g(Z)$.

Teorema 3.4 (Slutsky). Si $Z_n \xrightarrow{d} Z$ y $W_n \xrightarrow{p} c$ (constante), entonces:

1. $Z_n + W_n \xrightarrow{d} Z + c$;
2. $W_n Z_n \xrightarrow{d} cZ$;
3. $Z_n/W_n \xrightarrow{d} Z/c$ si $c \neq 0$.

Lo mismo vale con vectores y matrices de dimensiones compatibles (por ejemplo, $W_n^{-1} Z_n \xrightarrow{d} C^{-1} Z$ si $W_n \xrightarrow{p} C$ invertible).

Slutsky es el caballo de batalla de la econometría asintótica. Dice que **las piezas que convergen en probabilidad a constantes se pueden reemplazar por sus límites**. Demostramos la parte (1) en la sección ★ para ver cómo funcionan estos argumentos.

Ejemplo 3.1 (El estadístico t sin normalidad). Sean $x_1, \dots, x_n$ i.i.d. con media μ y varianza $0 < \sigma^2 < \infty$, **sin suponer normalidad**. Sea $S^2 = \frac{1}{n-1} \sum_i (x_i - \bar{x})^2$. Entonces

$$T_n = \frac{\sqrt{n}(\bar{x} - \mu)}{S} \xrightarrow{d} N(0, 1).$$

Demostración. Por el TCL, $\sqrt{n}(\bar{x} - \mu) \xrightarrow{d} N(0, \sigma^2)$. Para el denominador, escribimos

$$S^2 = \frac{n}{n-1} \left(\frac{1}{n} \sum_i x_i^2 - \bar{x}^2 \right).$$

Por la LGN (aplicada a x_i^2 , que tiene media $\sigma^2 + \mu^2$; si solo suponemos segundos momentos finitos, se usa la LGN de Khinchine) y a x_i , $\frac{1}{n} \sum x_i^2 \xrightarrow{p} \sigma^2 + \mu^2$ y $\bar{x} \xrightarrow{p} \mu$. Por el teorema de la función continua, $S^2 \xrightarrow{p} 1 \cdot (\sigma^2 + \mu^2 - \mu^2) = \sigma^2$, y de nuevo por continuidad (la raíz), $S \xrightarrow{p} \sigma > 0$. Por Slutsky (3), $T_n \xrightarrow{d} N(0, \sigma^2)/\sigma = N(0, 1)$. $\square$

Moraleja: el test t de la Clase 5 es **asintóticamente válido sin normalidad**. Con n grande, usar cuantiles de la t o de la $N(0, 1)$ da prácticamente lo mismo, y ambos son correctos en el límite.

4. El método delta

A veces no nos interesa θ sino una función suya, $g(\theta)$: una elasticidad, un cociente de coeficientes, el punto máximo de una parábola. Si $\hat{\theta}_n$ es asintóticamente normal, ¿lo es $g(\hat{\theta}_n)$?

Teorema 4.1 (Método delta). Si $\sqrt{n}(\hat{\theta}_n - \theta) \xrightarrow{d} N(0, V)$ en $\mathbb{R}^m$ y $g : \mathbb{R}^m \rightarrow \mathbb{R}^p$ es continuamente diferenciable en un entorno de θ , con jacobiano $G = \frac{\partial g}{\partial \theta'}(\theta)$ ($p \times m$), entonces

$$\sqrt{n}(g(\hat{\theta}_n) - g(\theta)) \xrightarrow{d} N(0, GVG').$$

Borrador

Idea: linealizar. Cerca de θ , $g(\hat{\theta}) \approx g(\theta) + G(\hat{\theta} - \theta)$. Multiplicando por $\sqrt{n}$: $\sqrt{n}(g(\hat{\theta}) - g(\theta)) \approx G\sqrt{n}(\hat{\theta} - \theta) \rightarrow G \cdot N(0, V) = N(0, GVG')$.

Para hacerlo riguroso uso el teorema del valor medio (coordinada a coordenada, en el caso vectorial): $g(\hat{\theta}) - g(\theta) = G(\bar{\theta})(\hat{\theta} - \theta)$ para algún $\bar{\theta}$ entre $\hat{\theta}$ y θ . Necesito que $G(\bar{\theta}) \xrightarrow{p} G(\theta)$. Como $\bar{\theta}$ está “entre” $\hat{\theta}$ y θ , y $\hat{\theta} \xrightarrow{p} \theta$, también $\bar{\theta} \xrightarrow{p} \theta$, y por continuidad del jacobiano, listo. Pero ¡ojó! ¿Sé que $\hat{\theta} \xrightarrow{p} \theta$? Solo me dieron la convergencia en distribución de $\sqrt{n}(\hat{\theta} - \theta)$. Necesito un lema: si $\sqrt{n}(\hat{\theta} - \theta)$ converge en distribución, entonces $\hat{\theta} - \theta = \frac{1}{\sqrt{n}} \cdot \sqrt{n}(\hat{\theta} - \theta) \xrightarrow{p} 0$. Eso es Slutsky con $W_n = 1/\sqrt{n} \rightarrow 0$.

Demostración. (Caso escalar, $m = p = 1$; el vectorial es análogo aplicando el valor medio a cada coordenada de g .) Sea $Z_n = \sqrt{n}(\hat{\theta}_n - \theta) \xrightarrow{d} Z \sim N(0, V)$.

Paso 1: consistencia. $\hat{\theta}_n - \theta = n^{-1/2}Z_n$. Como $n^{-1/2} \rightarrow 0$ (una sucesión determinista que converge es, en particular, una sucesión que converge en probabilidad), Slutsky (2) da $\hat{\theta}_n - \theta \xrightarrow{d} 0 \cdot Z = 0$. La convergencia en distribución a una constante implica convergencia en probabilidad a ella (Ejercicio 6.5), así que $\hat{\theta}_n \xrightarrow{p} \theta$.

Paso 2: valor medio. Por el teorema del valor medio, existe $\bar{\theta}_n$ entre $\hat{\theta}_n$ y θ tal que $g(\hat{\theta}_n) - g(\theta) = g'(\bar{\theta}_n)(\hat{\theta}_n - \theta)$. Multiplicando por $\sqrt{n}$,

$$\sqrt{n}(g(\hat{\theta}_n) - g(\theta)) = g'(\bar{\theta}_n) Z_n.$$

Paso 3: el jacobiano converge. Como $|\bar{\theta}_n - \theta| \leq |\hat{\theta}_n - \theta|$, el Paso 1 da $\bar{\theta}_n \xrightarrow{p} \theta$. Como g' es continua en θ , el teorema de la función continua da $g'(\bar{\theta}_n) \xrightarrow{p} g'(\theta) = G$.

Paso 4: Slutsky. Por Slutsky (2), $g'(\bar{\theta}_n) Z_n \xrightarrow{d} GZ \sim N(0, G^2 V)$. $\square$

Ejemplo 4.1 (Elasticidad en el punto medio). Si $\sqrt{n}(\hat{\theta} - \theta) \xrightarrow{d} N(0, V)$ con $\theta = (\beta_1, \beta_2)'$ y nos interesa $g(\theta) = \beta_1/\beta_2$ (con $\beta_2 \neq 0$), entonces $G = (1/\beta_2, -\beta_1/\beta_2^2)$ y la varianza asintótica de $\sqrt{n}(\hat{\beta}_1/\hat{\beta}_2 - \beta_1/\beta_2)$ es GVG' . En la práctica se reemplaza θ por $\hat{\theta}$ en G y V por un estimador consistente (Slutsky garantiza que eso no cambia el límite).

5. ★ Postgrado: notación O_p , Slutsky y el TCL demostrados

! ★ Postgrado

Introducimos la notación de órdenes estocásticos, demostramos una parte de Slutsky y damos una demostración completa del TCL vía funciones características (tomando el teorema de continuidad de Lévy como dado).

5.1. Órdenes estocásticos

Definición 5.1 (O_p y o_p). Sea $\{a_n\}$ una sucesión positiva. Escribimos

- $Z_n = o_p(a_n)$ si $Z_n/a_n \xrightarrow{p} 0$;
- $Z_n = O_p(a_n)$ si Z_n/a_n está **acotada en probabilidad**: para todo $\varepsilon > 0$ existen $B < \infty$ y N tales que $P(|Z_n/a_n| > B) < \varepsilon$ para todo $n \geq N$.

Así, la LGN dice $\bar{Z}_n - \mu = o_p(1)$ y el TCL (vía el lema siguiente) dice $\bar{Z}_n - \mu = O_p(n^{-1/2})$: el error de estimación es “del orden de $1/\sqrt{n}$ ”.

Lema 5.1 (Convergencia en distribución implica $O_p(1)$). Si $Z_n \xrightarrow{d} Z$, entonces $Z_n = O_p(1)$.

Demostración. Sea $\varepsilon > 0$. Como $F_Z(z) \rightarrow 1$ cuando $z \rightarrow \infty$ y $F_Z(z) \rightarrow 0$ cuando $z \rightarrow -\infty$, y F_Z tiene a lo más una cantidad numerable de discontinuidades, podemos elegir $B > 0$ tal que $\pm B$ son puntos de continuidad de F_Z y $F_Z(-B) + 1 - F_Z(B) < \varepsilon/2$. Por convergencia en distribución, $P(Z_n \leq -B) + 1 - P(Z_n \leq B) \rightarrow F_Z(-B) + 1 - F_Z(B)$, así que para n grande esa suma es $< \varepsilon$. Y $P(|Z_n| > B) \leq P(Z_n \leq -B) + P(Z_n > B)$, que es esa suma. $\square$

Las reglas de cálculo son las que esperarías: $o_p(1) + o_p(1) = o_p(1)$, $O_p(1) \cdot o_p(1) = o_p(1)$, $O_p(1) + O_p(1) = O_p(1)$. Demostremos la segunda, que es la más usada: si $X_n = O_p(1)$ e $Y_n = o_p(1)$, dado $\varepsilon, \eta > 0$ elige B con $P(|X_n| > B) < \varepsilon/2$ para n grande; entonces

$$P(|X_n Y_n| > \eta) \leq P(|X_n| > B) + P(|Y_n| > \eta/B) < \varepsilon/2 + \varepsilon/2$$

para n grande, porque $\{|X_n Y_n| > \eta\} \subseteq \{|X_n| > B\} \cup \{|Y_n| > \eta/B\}$.

5.2. Una parte de Slutsky

Demostración. (de Teorema 3.4, parte 1, caso $c = 0$). Sea $Z_n \xrightarrow{d} Z$ y $W_n \xrightarrow{p} 0$. Sea z un punto de continuidad de F_Z y $\varepsilon > 0$ tal que $z \pm \varepsilon$ también son puntos de continuidad (posible porque las discontinuidades son numerables). Como $\{Z_n + W_n \leq z\} \subseteq \{Z_n \leq z + \varepsilon\} \cup \{|W_n| > \varepsilon\}$,

$$P(Z_n + W_n \leq z) \leq P(Z_n \leq z + \varepsilon) + P(|W_n| > \varepsilon) \rightarrow F_Z(z + \varepsilon).$$

Y como $\{Z_n \leq z - \varepsilon\} \subseteq \{Z_n + W_n \leq z\} \cup \{|W_n| > \varepsilon\}$,

$$P(Z_n + W_n \leq z) \geq P(Z_n \leq z - \varepsilon) - P(|W_n| > \varepsilon) \rightarrow F_Z(z - \varepsilon).$$

Luego $F_Z(z - \varepsilon) \leq \liminf P(Z_n + W_n \leq z) \leq \limsup P(Z_n + W_n \leq z) \leq F_Z(z + \varepsilon)$. Haciendo $\varepsilon \downarrow 0$ (por puntos de continuidad), la continuidad de F_Z en z da $\lim P(Z_n + W_n \leq z) = F_Z(z)$. El caso $c \neq 0$ se reduce a este escribiendo $Z_n + W_n = (Z_n + c) + (W_n - c)$ y notando que $Z_n + c \xrightarrow{d} Z + c$ trivialmente. $\square$

5.3. Demostración del TCL

Usaremos la **función característica** $\varphi_Z(t) = \mathbb{E}[e^{itZ}]$ y dos hechos que aceptamos:

- **(Lévy)** $Z_n \xrightarrow{d} Z$ si y solo si $\varphi_{Z_n}(t) \rightarrow \varphi_Z(t)$ para todo $t \in \mathbb{R}$.
- La función característica de la $N(0, 1)$ es $e^{-t^2/2}$.

Lema 5.2 (Diferencia de productos). Si $a_1, \dots, a_n, b_1, \dots, b_n$ son complejos con $|a_j|, |b_j| \leq 1$, entonces $|\prod_{j=1}^n a_j - \prod_{j=1}^n b_j| \leq \sum_{j=1}^n |a_j - b_j|$.

Demostración. Por inducción en n . El caso $n = 1$ es trivial. Para el paso inductivo,

$$\left| \prod_{j=1}^n a_j - \prod_{j=1}^n b_j \right| \leq |a_n| \left| \prod_{j=1}^{n-1} a_j - \prod_{j=1}^{n-1} b_j \right| + \left| \prod_{j=1}^{n-1} b_j \right| |a_n - b_n| \leq \sum_{j=1}^{n-1} |a_j - b_j| + |a_n - b_n|,$$

sumando y restando $a_n \prod_{j=1}^{n-1} b_j$ y usando $|a_n| \leq 1, |\prod_{j=1}^{n-1} b_j| \leq 1$ y la hipótesis inductiva. $\square$

Demostración. (del TCL, caso escalar). Sin pérdida de generalidad $\mu = 0$ y $\sigma^2 = 1$ (si no, se aplica a $(Z_i - \mu)/\sigma$). Sea φ la función característica de Z_1 y $S_n = \sqrt{n}Z_n = n^{-1/2} \sum_{i=1}^n Z_i$. Por independencia,

$$\varphi_{S_n}(t) = \mathbb{E} \left[\prod_{i=1}^n e^{itZ_i/\sqrt{n}} \right] = \prod_{i=1}^n \mathbb{E} [e^{itZ_i/\sqrt{n}}] = \varphi(t/\sqrt{n})^n.$$

Expansión de φ . Para todo real x se cumple $|e^{ix} - 1 - ix + \frac{x^2}{2}| \leq \min(|x|^3/6, x^2)$ (resto de Taylor de orden 2 y de orden 3; ver

Ejercicio 6.7). Tomando $x = sZ_1$ y esperanza, con $\mathbb{E}Z_1 = 0$ y $\mathbb{E}Z_1^2 = 1$,

$$\left| \varphi(s) - 1 + \frac{s^2}{2} \right| \leq \mathbb{E}[\min(|s|^3|Z_1|^3/6, s^2Z_1^2)] = s^2 \mathbb{E}[\min(|s||Z_1|^3/6, Z_1^2)].$$

El integrando está dominado por Z_1^2 (integrable) y tiende a cero cuando $s \rightarrow 0$, así que, por convergencia dominada, $\varphi(s) = 1 - \frac{s^2}{2} + s^2\rho(s)$ con $\rho(s) \rightarrow 0$ cuando $s \rightarrow 0$.

Comparación con el límite. Fijemos t . Para n grande, $1 - t^2/(2n) \in [0, 1]$. Aplicamos Lema 5.2 con $a_j = \varphi(t/\sqrt{n})$ y $b_j = 1 - \frac{t^2}{2n}$ (ambos de módulo ≤ 1):

$$\left| \varphi(t/\sqrt{n})^n - \left(1 - \frac{t^2}{2n}\right)^n \right| \leq n \left| \varphi(t/\sqrt{n}) - 1 + \frac{t^2}{2n} \right| = n \cdot \frac{t^2}{n} |\rho(t/\sqrt{n})| = t^2 |\rho(t/\sqrt{n})| \rightarrow 0.$$

Finalmente, $\left(1 - \frac{t^2}{2n}\right)^n \rightarrow e^{-t^2/2}$ (el límite clásico $(1 + x/n)^n \rightarrow e^x$). Luego $\varphi_{S_n}(t) \rightarrow e^{-t^2/2}$ para todo t y, por Lévy, $S_n \xrightarrow{d} N(0, 1)$. $\square$

Nota dónde se usó cada supuesto: la independencia para factorizar φ_{S_n} , la distribución idéntica para que todos los factores sean iguales, y el **segundo momento finito** para la expansión de Taylor. Sin segundo momento el TCL falla: la media de n variables Cauchy i.i.d. vuelve a ser Cauchy, para todo n .³

³ La Cauchy es el villano favorito de los cursos de probabilidad: no tiene media, así que promediar no ayuda en absoluto. Promediar un millón de observaciones Cauchy da exactamente la misma precisión que una sola. Por suerte, en econometría casi nunca aparece... excepto como cociente de dos normales, que es justamente lo que aparece en el Ejercicio 10.6 con instrumentos irrelevantes.

6. Resumen

- $Z_n \xrightarrow{p} c$: la probabilidad de alejarse de c tiende a cero. Se prueba con Chebyshev (Lema 2.2) o con “sesgo y varianza tienden a cero” (Teorema 2.2).
- LGN: $\bar{Z}_n \xrightarrow{p} \mu$ (Teorema 2.1). TCL: $\sqrt{n}(\bar{Z}_n - \mu) \xrightarrow{d} N(0, \sigma^2)$ (Teorema 3.1).
- Función continua: la convergencia se preserva por funciones continuas (Teorema 2.3, Teorema 3.3).
- Slutsky: se pueden reemplazar las piezas que convergen en probabilidad por sus límites (Teorema 3.4).
- Método delta: $\sqrt{n}(g(\hat{\theta}) - g(\theta)) \xrightarrow{d} N(0, GVG')$ (Teorema 4.1).

7. Ejercicios

Ejercicio 6.1. Sea Z_n igual a n con probabilidad $1/n$ y a 0 con probabilidad $1 - 1/n$. Demuestra que $Z_n \xrightarrow{p} 0$ pero $\mathbb{E}[Z_n] \not\rightarrow 0$. ¿Qué dice esto sobre consistencia versus insesgamiento asintótico?

Solución 6.1

Para $\varepsilon \in (0, 1)$ y $n > \varepsilon$: $P(|Z_n| > \varepsilon) = P(Z_n = n) = 1/n \rightarrow 0$. Pero $\mathbb{E}[Z_n] = n \cdot \frac{1}{n} = 1$ para todo n . Un estimador puede ser consistente y no ser asintóticamente insesgado: la convergencia en probabilidad ignora eventos raros, aunque sean enormes; la esperanza no.

Ejercicio 6.2. Sean x_i i.i.d. con $\mathbb{E}[x_i] = \mu \neq 0$ y varianza finita. Encuentra la distribución asintótica de $\sqrt{n}(\bar{x}^2 - \mu^2)$ y de $\sqrt{n}(1/\bar{x} - 1/\mu)$.

Solución 6.2

Método delta con $\sqrt{n}(\bar{x} - \mu) \xrightarrow{d} N(0, \sigma^2)$. Con $g(t) = t^2$, $g'(\mu) = 2\mu$: $N(0, 4\mu^2\sigma^2)$. Con $g(t) = 1/t$, $g'(\mu) = -1/\mu^2$: $N(0, \sigma^2/\mu^4)$.

Ejercicio 6.3. ¿Qué pasa con el método delta para $g(t) = t^2$ si $\mu = 0$? Demuestra que en ese caso $n\bar{x}^2/\sigma^2 \xrightarrow{d} \chi_1^2$.

Solución 6.3

$G = 2\mu = 0$ y el método delta da la distribución degenerada $N(0, 0)$: $\sqrt{n}\bar{x}^2 \xrightarrow{p} 0$. La escala $\sqrt{n}$ es incorrecta. Con la escala n : $n\bar{x}^2/\sigma^2 = (\sqrt{n}\bar{x}/\sigma)^2$, y como $\sqrt{n}\bar{x}/\sigma \xrightarrow{d} N(0, 1)$, por el teorema de la función continua (con $g(t) = t^2$) converge a χ_1^2 . Moraleja: cuando el jacobiano es cero, hace falta un “método delta de segundo orden”.

Ejercicio 6.4. Sean x_i i.i.d. Bernoulli(p) con $0 < p < 1$. Construye un intervalo de confianza asintótico al 95 % para p y justifica cada paso con los teoremas de esta clase.

💡 Solución 6.4

$\hat{p} = \bar{x}$. TCL: $\sqrt{n}(\hat{p} - p) \xrightarrow{d} N(0, p(1 - p))$. LGN + función continua: $\hat{p}(1 - \hat{p}) \xrightarrow{p} p(1 - p) > 0$. Slutsky: $\sqrt{n}(\hat{p} - p)/\sqrt{\hat{p}(1 - \hat{p})} \xrightarrow{d} N(0, 1)$. Luego $P(|\hat{p} - p| \leq 1,96\sqrt{\hat{p}(1 - \hat{p})/n}) \rightarrow 0,95$, y el intervalo es $\hat{p} \pm 1,96\sqrt{\hat{p}(1 - \hat{p})/n}$.

Ejercicio 6.5. Demuestra que si $Z_n \xrightarrow{d} c$ (una constante), entonces $Z_n \xrightarrow{p} c$.

💡 Solución 6.5

La distribución de la constante c es $F(z) = \mathbb{1}\{z \geq c\}$, continua en todo $z \neq c$. Para $\varepsilon > 0$, $c - \varepsilon$ y $c + \varepsilon/2$ son puntos de continuidad, así que $P(|Z_n - c| > \varepsilon) \leq P(Z_n \leq c - \varepsilon) + 1 - P(Z_n \leq c + \varepsilon/2) \rightarrow F(c - \varepsilon) + 1 - F(c + \varepsilon/2) = 0 + 1 - 1 = 0$.

Ejercicio 6.6 ★. Demuestra que $O_p(1) + o_p(1) = O_p(1)$ y que si $Z_n = O_p(n^{-1/2})$ entonces $Z_n = o_p(1)$.

💡 Solución 6.6 ★

Si $X_n = O_p(1)$, $Y_n = o_p(1)$: dado ε , elige B con $P(|X_n| > B) < \varepsilon/2$ para n grande; como $P(|Y_n| > 1) < \varepsilon/2$ para n grande, $P(|X_n + Y_n| > B + 1) < \varepsilon$. Para la segunda: $Z_n = n^{-1/2} \cdot (\sqrt{n}Z_n)$ con $\sqrt{n}Z_n = O_p(1)$ y $n^{-1/2} = o(1)$; por la regla $O_p(1)o_p(1) = o_p(1)$, $Z_n = o_p(1)$.

Ejercicio 6.7 ★. Demuestra que $|e^{ix} - 1 - ix + x^2/2| \leq \min(|x|^3/6, x^2)$ para todo x real.

💡 Solución 6.7 ★

Integrando por partes se obtiene la identidad $e^{ix} = \sum_{m=0}^k \frac{(ix)^m}{m!} + \frac{i^{k+1}}{k!} \int_0^x (x-s)^k e^{is} ds$. Con $k = 2$, el resto está acotado por $\frac{1}{2} |\int_0^x (x-s)^2 ds| = |x|^3/6$. Con $k = 1$,

el resto de orden 1 es $R_1 = i^2 \int_0^x (x-s)e^{is} ds$ y, como $\int_0^x (x-s) ds = x^2/2$, se puede escribir $e^{ix} - 1 - ix + x^2/2 = -\int_0^x (x-s)(e^{is} - 1) ds$, cuyo módulo es $\leq \left| \int_0^x |x-s| \cdot 2 ds \right| = x^2$.