

Clase 7 · MCO en muestras grandes

Consistencia, normalidad asintótica y errores estándar robustos

Contenido

1	Qué cambia	2
2	Supuestos	2
3	Consistencia	3
4	Normalidad asintótica	4
4.1	El caso homocedástico	5
5	Estimando la varianza	6
6	Inferencia asintótica	7
6.1	Hipótesis no lineales	8
6.2	Correcciones de muestra finita	8
7	★ Postgrado: demostración de la consistencia de White	9
8	Resumen	11
9	Ejercicios	11

1. Qué cambia

Hasta ahora, la teoría de MCO descansó en supuestos que rara vez se cumplen: la CEF es lineal (RL1 + RL3), los errores son homocedásticos (RL4) y normales (RL5). Hoy los botamos casi todos. A cambio, pedimos n grande y usamos las herramientas de la Clase 6. El resultado es la teoría que la econometría aplicada usa todos los días: la de los **errores estándar robustos**.

El mensaje central, que vale la pena escribir antes de empezar:

El mensaje de la clase

Con muestreo i.i.d. y momentos finitos, MCO es un estimador consistente y asintóticamente normal **del coeficiente de proyección lineal** $\beta = \mathbb{E}[xx']^{-1}\mathbb{E}[xy]$, sin importar si la CEF es lineal, si hay heterocedasticidad o si los errores son normales. Lo único que cambia es la fórmula de la varianza: hay que usar la versión “sándwich”.

2. Supuestos

Supuestos asintóticos (A)

- **A1 (muestreo):** $\{(y_i, x_i)\}_{i=1}^n$ son i.i.d.
- **A2 (proyección):** $\beta = \mathbb{E}[x_i x_i']^{-1} \mathbb{E}[x_i y_i]$ y $u_i = y_i - x_i' \beta$, de modo que $\mathbb{E}[x_i u_i] = 0$.
- **A3 (rango):** $Q = \mathbb{E}[x_i x_i']$ es finita y definida positiva.
- **A4 (momentos):** $\mathbb{E}[y_i^4] < \infty$, $\mathbb{E}\|x_i\|^4 < \infty$, y $\Omega = \mathbb{E}[u_i^2 x_i x_i']$ es definida positiva.

Compara con la Clase 4. A2 no es un supuesto de “exogeneidad” en el sentido causal: es la **definición** de β como coeficiente de proyección (Clase 2). La propiedad $\mathbb{E}[x_i u_i] = 0$ es automática. Es mucho más débil que RL3 ($\mathbb{E}[u \mid X] = 0$), que pedía que la CEF fuera lineal. A4 pide cuartos momentos, que usaremos para estimar la varianza.¹

¹ Los cuartos momentos son la forma técnica de decir “no hay outliers demasiado extremos”. Si tus datos tienen cosas tan gordas que $\mathbb{E}[y^4] = \infty$ (ingresos de multimillonarios, tamaños de ciudades, pérdidas de seguros), los errores estándar pueden ser poco confiables incluso con n grande.

3. Consistencia

Todo parte, como siempre, de la identidad del error muestral (Clase 4), ahora escrita con promedios:

$$\hat{\beta} = \left(\frac{1}{n} \sum_{i=1}^n x_i x_i' \right)^{-1} \left(\frac{1}{n} \sum_{i=1}^n x_i y_i \right) = \beta + \hat{Q}^{-1} \left(\frac{1}{n} \sum_{i=1}^n x_i u_i \right), \quad \hat{Q} = \frac{1}{n} \sum_{i=1}^n x_i x_i'. \quad (1)$$

(Multiplicar y dividir por n no cambia nada: $(X'X)^{-1}X'y = (X'X/n)^{-1}(X'y/n)$. Y la segunda igualdad es $y_i = x_i'\beta + u_i$, que vale por la definición de u_i .) Escrito así, $\hat{\beta}$ es una función continua de promedios, y los promedios son justo lo que la LGN sabe manejar.

Teorema 3.1 (Consistencia de MCO). *Bajo A1–A3 ($y \mathbb{E}[y_i^2] < \infty$), $\hat{\beta} \xrightarrow{p} \beta$.*

Borrador

$\hat{Q} \rightarrow Q$ por LGN (entrada por entrada). $\frac{1}{n} \sum x_i u_i \rightarrow \mathbb{E}[x_i u_i] = 0$ por LGN. La función $(A, b) \mapsto A^{-1}b$ es continua donde A es invertible, y Q es invertible. Función continua $\Rightarrow \hat{\beta} \rightarrow \beta + Q^{-1} \cdot 0$. Detalle: $\hat{Q}$ podría no ser invertible para algún n ; pero como $\hat{Q} \rightarrow Q$ invertible, la probabilidad de eso tiende a cero, y en ese evento podemos definir $\hat{\beta}$ como queramos sin afectar límites en probabilidad.

Demostración. Paso 1: $\hat{Q} \xrightarrow{p} Q$. La entrada (j, l) de $\hat{Q}$ es $\frac{1}{n} \sum_i x_{ij} x_{il}$, un promedio de variables i.i.d. (por A1) con media Q_{jl} , finita por A3. Por la LGN (Khinchine), converge a Q_{jl} .

Paso 2: $\frac{1}{n} \sum_i x_i u_i \xrightarrow{p} 0$. Los $x_i u_i$ son i.i.d. (funciones de (y_i, x_i)) con media $\mathbb{E}[x_i u_i] = 0$ por A2. Su esperanza existe porque $\mathbb{E}|x_{ij} u_i| \leq (\mathbb{E} x_{ij}^2)^{1/2} (\mathbb{E} u_i^2)^{1/2} < \infty$ por Cauchy-Schwarz (u_i tiene segundo momento porque y_i y x_i lo tienen). Por la LGN, el promedio converge a 0.

Paso 3: función continua. La función $g(A, b) = A^{-1}b$ es continua en todo par con A invertible, en particular en $(Q, 0)$ por A3. Por el teorema de la función continua (Clase 6),

$$\hat{\beta} - \beta = \hat{Q}^{-1} \left(\frac{1}{n} \sum_i x_i u_i \right) \xrightarrow{p} Q^{-1} \cdot 0 = 0.$$

(El evento en que $\hat{Q}$ no es invertible tiene probabilidad que tiende a cero, pues el determinante es continuo y $\det \hat{Q} \xrightarrow{p} \det Q \neq 0$.)

□

⚠ Consistente para qué

MCO es consistente para el β de la **proyección lineal**. Si la CEF es lineal, eso coincide con la CEF. Si además la CEF tiene interpretación causal, β es un efecto causal. Pero ninguna de esas dos cosas se sigue de A1–A4. La econometría no puede darte causalidad gratis; las Clases 8 y 10 tratan de cuándo β no es lo que quieres y qué hacer al respecto.

4. Normalidad asintótica

Teorema 4.1 (Distribución asintótica de MCO). *Bajo A1–A4,*

$$\sqrt{n}(\hat{\beta} - \beta) \xrightarrow{d} N(0, V), \quad V = Q^{-1} \Omega Q^{-1},$$

con $Q = \mathbb{E}[x_i x_i']$ y $\Omega = \mathbb{E}[u_i^2 x_i x_i']$.

i Borrador

Multiplico Ecuación 1 por $\sqrt{n}$:

$$\sqrt{n}(\hat{\beta} - \beta) = \hat{Q}^{-1} \cdot \frac{1}{\sqrt{n}} \sum_i x_i u_i.$$

El segundo factor es $\sqrt{n}$ por el promedio de $x_i u_i$, que tiene media cero: ¡TCL! Converge a $N(0, \text{Var}(x_i u_i))$, y $\text{Var}(x_i u_i) = \mathbb{E}[x_i x_i' u_i^2] = \Omega$ (porque la media es cero). El primer factor converge en probabilidad a Q^{-1} . Slutsky: $Q^{-1} N(0, \Omega) =$

$$N(0, Q^{-1}\Omega Q^{-1}).$$

Demostración. Por Ecuación 1,

$$\sqrt{n}(\hat{\beta} - \beta) = \hat{Q}^{-1} \frac{1}{\sqrt{n}} \sum_{i=1}^n x_i u_i.$$

El factor derecho. Los vectores $x_i u_i$ son i.i.d. con media 0 (A2) y varianza $\mathbb{E}[(x_i u_i)(x_i u_i)'] = \mathbb{E}[u_i^2 x_i x_i'] = \Omega$, que es finita: por Cauchy-Schwarz, $\mathbb{E}[u_i^2 x_{ij} x_{il}] \leq (\mathbb{E}u_i^4)^{1/2} (\mathbb{E}x_{ij}^2 x_{il}^2)^{1/2}$, y ambos factores son finitos por A4. Por el TCL multivariado,

$$\frac{1}{\sqrt{n}} \sum_{i=1}^n x_i u_i = \sqrt{n} \left(\frac{1}{n} \sum_{i=1}^n x_i u_i - 0 \right) \xrightarrow{d} Z \sim N(0, \Omega).$$

El factor izquierdo. Por el Paso 1 de Teorema 3.1 y la continuidad de la inversa, $\hat{Q}^{-1} \xrightarrow{p} Q^{-1}$.

Slutsky. Por el teorema de Slutsky (versión matricial), $\hat{Q}^{-1} \frac{1}{\sqrt{n}} \sum_{i=1}^n x_i u_i \xrightarrow{d} Q^{-1}Z$, y por la regla de transformaciones lineales de normales (Clase 5), $Q^{-1}Z \sim N(0, Q^{-1}\Omega Q^{-1}) = N(0, Q^{-1}\Omega Q^{-1})$, porque Q^{-1} es simétrica. $\square$

La matriz $V = Q^{-1}\Omega Q^{-1}$ se llama **varianza sándwich**: Q^{-1} es el pan y Ω es el relleno.² Es la versión asintótica del sándwich $(X'X)^{-1}X' \text{Var}(u | X)X(X'X)^{-1}$ de la Clase 4.

² El nombre se atribuye a Kauermann y Carroll, aunque la idea es de Huber (1967), Eicker (1963) y White (1980). Por eso a veces verás “errores estándar de Eicker-Huber-White”. Es un sándwich con tres chefs.

4.1. El caso homocedástico

Corolario 4.1 (Varianza bajo homocedasticidad). Si además $\mathbb{E}[u_i^2 | x_i] = \sigma^2$ (homocedasticidad condicional), entonces $\Omega = \sigma^2 Q$ y

$$V = \sigma^2 Q^{-1}.$$

Demostración. Por la LEI y “lo conocido sale” (Clase 2),

$$\Omega = \mathbb{E}[u_i^2 x_i x_i'] = \mathbb{E}[\mathbb{E}[u_i^2 | x_i] x_i x_i'] = \mathbb{E}[\sigma^2 x_i x_i'] = \sigma^2 Q.$$

Entonces $V = Q^{-1}\sigma^2 Q Q^{-1} = \sigma^2 Q^{-1}$. $\square$

Esta es la versión asintótica de $\sigma^2(X'X)^{-1}$: en efecto, $\frac{1}{n} \cdot \sigma^2 \hat{Q}^{-1} = \sigma^2(X'X)^{-1}$. Bajo homocedasticidad, la fórmula clásica sigue siendo correcta en muestras grandes **aunque los errores no sean normales**. Sin homocedasticidad, no.

5. Estimando la varianza

Para usar Teorema 4.1 en la práctica necesitamos estimar V . El pan es fácil: $\hat{Q} \xrightarrow{p} Q$. Para el relleno, el principio de analogía sugiere reemplazar la esperanza por un promedio y los errores (que no vemos) por los residuos.

Definición 5.1 (Estimador de White (HC0)).

$$\hat{V} = \hat{Q}^{-1} \hat{\Omega} \hat{Q}^{-1}, \quad \hat{\Omega} = \frac{1}{n} \sum_{i=1}^n \hat{u}_i^2 x_i x_i'.$$

En notación matricial, el estimador de $\text{Var}(\hat{\beta})$ es $\frac{1}{n} \hat{V} = (X'X)^{-1} \left(\sum_i \hat{u}_i^2 x_i x_i' \right) (X'X)^{-1}$.

Teorema 5.1 (Consistencia del estimador de White). *Bajo A1–A4, $\hat{\Omega} \xrightarrow{p} \Omega$ y, por lo tanto, $\hat{V} \xrightarrow{p} V$.*

La demostración está en la sección ★. La idea es simple: si usáramos los errores verdaderos, $\tilde{\Omega} = \frac{1}{n} \sum u_i^2 x_i x_i' \xrightarrow{p} \Omega$ por la LGN. La dificultad es mostrar que reemplazar u_i por $\hat{u}_i$ no importa en el límite, porque $\hat{u}_i - u_i = -x_i'(\hat{\beta} - \beta)$ y $\hat{\beta} - \beta \rightarrow 0$.

Para el caso homocedástico necesitamos estimar $\sigma^2 = \mathbb{E}[u_i^2]$:

Teorema 5.2 (Consistencia de s^2). *Bajo A1–A3 y $\mathbb{E}[y_i^2] < \infty$, $\hat{\sigma}^2 = \frac{1}{n} \sum_i \hat{u}_i^2 \xrightarrow{p} \sigma^2 = \mathbb{E}[u_i^2]$, y lo mismo vale para $s^2 = \frac{n}{n-k} \hat{\sigma}^2$.*

Demostración. Como $\hat{u}_i = y_i - x_i' \hat{\beta} = u_i - x_i'(\hat{\beta} - \beta)$,

$$\hat{u}_i^2 = u_i^2 - 2u_i x_i'(\hat{\beta} - \beta) + (\hat{\beta} - \beta)' x_i x_i' (\hat{\beta} - \beta).$$

Promediando,

$$\hat{\sigma}^2 = \underbrace{\frac{1}{n} \sum_i u_i^2}_{\xrightarrow{p} \sigma^2} - 2 \underbrace{\left(\frac{1}{n} \sum_i u_i x_i \right)'}_{\xrightarrow{p} 0} \underbrace{(\hat{\beta} - \beta)}_{\xrightarrow{p} 0} + \underbrace{(\hat{\beta} - \beta)'}_{\xrightarrow{p} 0} \underbrace{\hat{Q}}_{\xrightarrow{p} Q} \underbrace{(\hat{\beta} - \beta)}_{\xrightarrow{p} 0}.$$

Los límites indicados salen de la LGN y de Teorema 3.1. Por el teorema de la función continua, $\hat{\sigma}^2 \xrightarrow{p} \sigma^2 - 0 + 0 = \sigma^2$. Finalmente, $n/(n-k) \rightarrow 1$. $\square$

6. Inferencia asintótica

Con $\hat{V}$ en mano, todo se arma con Slutsky. Definimos el **error estándar robusto** de $\hat{\beta}_j$ como $ee_R(\hat{\beta}_j) = \sqrt{\hat{V}_{jj}/n}$.

Teorema 6.1 (Test t robusto). *Bajo A1-A4 y $H_0 : \beta_j = \beta_j^0$,*

$$t_j = \frac{\hat{\beta}_j - \beta_j^0}{ee_R(\hat{\beta}_j)} \xrightarrow{d} N(0, 1).$$

Demostración. $t_j = \frac{\sqrt{n}(\hat{\beta}_j - \beta_j^0)}{\sqrt{\hat{V}_{jj}}}$. Bajo H_0 , el numerador es la

coordenada j de $\sqrt{n}(\hat{\beta} - \beta)$, que converge a $N(0, V_{jj})$ por Teorema 4.1 y el teorema de la función continua (la proyección a una coordenada es continua). El denominador converge en probabilidad a $\sqrt{V_{jj}} > 0$ por Teorema 5.1 y continuidad de la raíz ($V_{jj} > 0$ porque $V > 0$). Por Slutsky, $t_j \xrightarrow{d} N(0, V_{jj})/\sqrt{V_{jj}} = N(0, 1)$. $\square$

Teorema 6.2 (Test de Wald). *Sea $H_0 : R\beta = r$ con R de $q \times k$ y rango q . Bajo A1-A4 y H_0 ,*

$$W = n(R\hat{\beta} - r)'(R\hat{V}R')^{-1}(R\hat{\beta} - r) \xrightarrow{d} \chi_q^2.$$

Demostración. Bajo H_0 , $\sqrt{n}(R\hat{\beta} - r) = R\sqrt{n}(\hat{\beta} - \beta) \xrightarrow{d} Z_R \sim N(0, RVR')$, por Teorema 4.1 y la función continua. Además $RVR' > 0$ (Clase 1, pues $V > 0$ y R' tiene rango columna q) y $R\hat{V}R' \xrightarrow{p} RVR'$, así que $(R\hat{V}R')^{-1} \xrightarrow{p} (RVR')^{-1}$. Escribimos

$$W = (\sqrt{n}(R\hat{\beta} - r))' (R\hat{V}R')^{-1} (\sqrt{n}(R\hat{\beta} - r)).$$

La función $(z, A) \mapsto z'Az$ es continua, así que por Slutsky y la función continua, $W \xrightarrow{d} Z_R'(RVR')^{-1}Z_R$. Por el lema de la Clase 5 (" $z \sim N(0, \Sigma) \Rightarrow z'\Sigma^{-1}z \sim \chi_q^2$ "), el límite es χ_q^2 . $\square$

Conexión con el test F . Si en lugar de $\hat{V}$ se usa el estimador homocedástico $s^2\hat{Q}^{-1}$, entonces

$$W = n(R\hat{\beta} - r)' (Rs^2(X'X/n)^{-1}R')^{-1} (R\hat{\beta} - r) = \frac{(R\hat{\beta} - r)' [R(X'X)^{-1}R']^{-1} (R\hat{\beta} - r)}{s^2} = qF.$$

Es decir, qF es exactamente el estadístico de Wald homocedástico. Como $qF_{q, n-k} \xrightarrow{d} \chi_q^2$ cuando $n \rightarrow \infty$, el test F de la Clase 5 es asintóticamente válido bajo homocedasticidad, sin normalidad. Bajo heterocedasticidad hay que usar W con $\hat{V}$ robusto.

6.1. Hipótesis no lineales

Para $H_0 : h(\beta) = 0$ con $h : \mathbb{R}^k \rightarrow \mathbb{R}^q$ diferenciable y jacobiano $H = \partial h / \partial \beta'$ de rango q , el método delta (Clase 6) da $\sqrt{n}h(\hat{\beta}) \xrightarrow{d} N(0, H\hat{V}H')$ bajo H_0 , y el mismo argumento de Teorema 6.2 muestra que

$$W = n h(\hat{\beta})' (\hat{H}\hat{V}\hat{H}')^{-1} h(\hat{\beta}) \xrightarrow{d} \chi_q^2, \quad \hat{H} = \frac{\partial h}{\partial \beta'}(\hat{\beta}).$$

6.2. Correcciones de muestra finita

HCO tiende a subestimar la varianza en muestras chicas, por la misma razón que $\hat{\sigma}^2$ subestima σ^2 : los residuos son más chicos que los errores. Las variantes usuales, que usan el leverage h_{ii} de la Clase 3, son:

Nombre	Peso de $x_i x_i'$ en $\hat{\Omega}$	Comentario
HC0	$\hat{u}_i^2$	White (1980)
HC1	$\frac{n}{n-k} \hat{u}_i^2$	Por defecto en Stata con robust
HC2	$\hat{u}_i^2 / (1 - h_{ii})$	Insensado bajo homocedasticidad
HC3	$\hat{u}_i^2 / (1 - h_{ii})^2$	Aproxima el jackknife; recomendado con n chico

Todas son asintóticamente equivalentes (porque $\max_i h_{ii} \rightarrow 0$ bajo condiciones regulares), así que Teorema 5.1 vale para todas.

7. ★ Postgrado: demostración de la consistencia de White

! ★ Postgrado

Demostramos Teorema 5.1. La dificultad es controlar la diferencia entre usar $\hat{u}_i$ y u_i en un promedio de productos de cuarto orden.

Demostración. (de Teorema 5.1). Sea $\tilde{\Omega} = \frac{1}{n} \sum_i u_i^2 x_i x_i'$. Sus entradas son promedios i.i.d. con media finita (A4), así que $\tilde{\Omega} \xrightarrow{p} \Omega$ por la LGN de Khinchine. Basta probar que $\hat{\Omega} - \tilde{\Omega} \xrightarrow{p} 0$.

Sea $\delta = \hat{\beta} - \beta$. Como $\hat{u}_i = u_i - x_i' \delta$,

$$\hat{u}_i^2 - u_i^2 = -2u_i x_i' \delta + (x_i' \delta)^2.$$

Usando la norma matricial $\|A\| = (\sum_{jl} A_{jl}^2)^{1/2}$, para la cual $\|x_i x_i'\| = \|x_i\|^2$, y la desigualdad de Cauchy-Schwarz

$$|x'_i \delta| \leq \|x_i\| \|\delta\|,$$

$$\begin{aligned} \|\hat{\Omega} - \tilde{\Omega}\| &= \left\| \frac{1}{n} \sum_i (\hat{u}_i^2 - u_i^2) x_i x'_i \right\| \leq \frac{1}{n} \sum_i |\hat{u}_i^2 - u_i^2| \|x_i\|^2 \\ &\leq 2\|\delta\| \cdot \frac{1}{n} \sum_i |u_i| \|x_i\|^3 + \|\delta\|^2 \cdot \frac{1}{n} \sum_i \|x_i\|^4. \end{aligned}$$

Ahora:

- $\frac{1}{n} \sum_i \|x_i\|^4 \xrightarrow{p} \mathbb{E}\|x_i\|^4 < \infty$ por la LGN y A4; en particular es $O_p(1)$.
- Por Hölder con exponentes 4 y 4/3, $\mathbb{E}[|u_i| \|x_i\|^3] \leq (\mathbb{E}u_i^4)^{1/4} (\mathbb{E}\|x_i\|^4)^{3/4} < \infty$ (y $\mathbb{E}u_i^4 < \infty$ porque $u_i = y_i - x'_i \beta$ y y_i, x_i tienen cuartos momentos). Luego $\frac{1}{n} \sum_i |u_i| \|x_i\|^3 = O_p(1)$ por la LGN.
- $\|\delta\| = o_p(1)$ por Teorema 3.1.

Por las reglas $o_p(1)O_p(1) = o_p(1)$ de la Clase 6, $\|\hat{\Omega} - \tilde{\Omega}\| = o_p(1)$.

Finalmente, $\hat{V} = \hat{Q}^{-1} \hat{\Omega} \hat{Q}^{-1} \xrightarrow{p} Q^{-1} \Omega Q^{-1} = V$ por la función continua. $\square$

Dos comentarios finales para el nivel de postgrado:

1. Mala especificación genera heterocedasticidad.

Si la CEF no es lineal, el error de proyección es $u_i = e_i + (m(x_i) - x'_i \beta)$, y $\mathbb{E}[u_i^2 | x_i] = \text{Var}(y_i | x_i) + (m(x_i) - x'_i \beta)^2$ depende de x_i aunque $\text{Var}(y_i | x_i)$ sea constante. Esta es una razón de fondo para usar siempre errores robustos: aun si crees que los errores son homocedásticos, la aproximación lineal casi nunca es exacta.

2. Eficiencia. Bajo heterocedasticidad, MCO sigue siendo consistente, pero ya no es eficiente: si $\mathbb{E}[u_i | x_i] = 0$ y $\sigma^2(x) = \mathbb{E}[u_i^2 | x_i = x]$ es conocida, el estimador ponderado por $1/\sigma^2(x_i)$ tiene varianza asintótica $(\mathbb{E}[x_i x'_i / \sigma^2(x_i)])^{-1} \leq Q^{-1} \Omega Q^{-1}$. Eso es mínimos cuadrados generalizados, el tema de la Clase 9.

8. Resumen

- MCO es consistente para el coeficiente de proyección lineal bajo A1–A3 (Teorema 3.1).
- $\sqrt{n}(\hat{\beta} - \beta) \xrightarrow{d} N(0, Q^{-1}\Omega Q^{-1})$ sin normalidad ni homocedasticidad (Teorema 4.1).
- Bajo homocedasticidad, $V = \sigma^2 Q^{-1}$ (Corolario 4.1).
- El estimador de White $\hat{V} = \hat{Q}^{-1}\hat{\Omega}\hat{Q}^{-1}$ es consistente (Teorema 5.1). Con él se arman tests t y de Wald asintóticos (Teorema 6.1, Teorema 6.2).
- qF es el Wald homocedástico: el test F es asintóticamente válido bajo homocedasticidad.

9. Ejercicios

Ejercicio 7.1. En la regresión simple $y_i = \alpha + \gamma z_i + u_i$ bajo A1–A4, demuestra que $\sqrt{n}(\hat{\gamma} - \gamma) \xrightarrow{d} N\left(0, \frac{\mathbb{E}[(z_i - \mu_z)^2 u_i^2]}{\text{Var}(z_i)^2}\right)$.

Solución 7.1

Por FWL, $\hat{\gamma} - \gamma = \frac{\frac{1}{n} \sum (z_i - \bar{z}) u_i}{\frac{1}{n} \sum (z_i - \bar{z})^2}$ (el término con $\bar{u}$ desaparece porque $\sum (z_i - \bar{z}) = 0$). Escribimos $\frac{1}{\sqrt{n}} \sum (z_i - \bar{z}) u_i = \frac{1}{\sqrt{n}} \sum (z_i - \mu_z) u_i - (\bar{z} - \mu_z) \sqrt{n} \bar{u}$. El primer término converge a $N(0, \mathbb{E}[(z_i - \mu_z)^2 u_i^2])$ por el TCL (media cero porque $\mathbb{E}[u_i] = 0$ y $\mathbb{E}[z_i u_i] = 0$). El segundo es $o_p(1) \cdot o_p(1) = o_p(1)$. El denominador converge a $\text{Var}(z_i)$. Slutsky.

Ejercicio 7.2. Sea $y_i = \beta x_i + u_i$ con $x_i \sim N(0, 1)$, $u_i = x_i \varepsilon_i$ y $\varepsilon_i \sim N(0, 1)$ independiente de x_i . Calcula la varianza asintótica correcta de $\sqrt{n}(\hat{\beta} - \beta)$ y la que reportaría la fórmula homocedástica. ¿Cuál es el cociente?

💡 Solución 7.2

$Q = \mathbb{E}x^2 = 1$, $\Omega = \mathbb{E}[x^2u^2] = \mathbb{E}[x^4\varepsilon^2] = 3$. Varianza correcta: 3. Homocedástica: σ^2Q^{-1} con $\sigma^2 = \mathbb{E}[u^2] = \mathbb{E}[x^2]\mathbb{E}[\varepsilon^2] = 1$: da 1. La fórmula clásica subestima la varianza a un tercio; los errores estándar clásicos son $\sqrt{3} \approx 1,73$ veces más chicos de lo que deberían. Un test “al 5 %” rechazaría H_0 verdadera con probabilidad $P(|N(0, 1)| > 1,96/\sqrt{3}) \approx P(|N(0, 1)| > 1,13) \approx 0,26$, es decir, alrededor de un 26 %.

Ejercicio 7.3. Demuestra que si $\mathbb{E}[u_i^2 \mid x_i] = \sigma^2$, entonces $V_{\text{robusta}} = V_{\text{homocedástica}}$, pero que en general ninguna domina a la otra: da un ejemplo en que la varianza robusta sea *menor* que la homocedástica.

💡 Solución 7.3

La primera parte es Corolario 4.1. Para el ejemplo, regresión sin constante con $x_i \in \{1, 3\}$ equiprobable y $\mathbb{E}[u^2 \mid x = 1] = 2$, $\mathbb{E}[u^2 \mid x = 3] = 0,5$ (varianza alta donde x es chico). $Q = (1 + 9)/2 = 5$, $\Omega = (1 \cdot 2 + 9 \cdot 0,5)/2 = 3,25$, $V_R = 3,25/25 = 0,13$. $\sigma^2 = (2 + 0,5)/2 = 1,25$, $V_H = 1,25/5 = 0,25$. La robusta es menor. La fórmula homocedástica falla en ambas direcciones.

Ejercicio 7.4. En $\log Q_i = \beta_1 + \beta_2 \log K_i + \beta_3 \log L_i + u_i$, escribe el estadístico de Wald robusto para $H_0 : \beta_2/\beta_3 = 1/2$, de dos maneras: como hipótesis no lineal y como hipótesis lineal equivalente. ¿Dan el mismo valor?

💡 Solución 7.4

No lineal: $h(\beta) = \beta_2/\beta_3 - 1/2$, $H = (0, 1/\beta_3, -\beta_2/\beta_3^2)$, $W_1 = n h(\hat{\beta})^2 / (\hat{H} \hat{V} \hat{H}')$. Lineal: $2\beta_2 - \beta_3 = 0$, $R = (0, 2, -1)$, $W_2 = n(2\hat{\beta}_2 - \hat{\beta}_3)^2 / (R \hat{V} R')$. Ambos son asintóticamente χ_1^2 bajo H_0 , pero **no** son numéricamente iguales en muestras finitas: el test de Wald no es invariante a reparametrizaciones de la hipótesis. Es un defecto conocido (Gregory y Veall, 1985); en la práctica conviene la forma lineal cuando existe.

Ejercicio 7.5 ★. Demuestra que $\max_{1 \leq i \leq n} h_{ii} \xrightarrow{p} 0$ bajo A1-A4, y deduce que HC0 y HC2 son asintóticamente equivalentes.

 Solución 7.5 ★

$$h_{ii} = \frac{1}{n} x_i' \hat{Q}^{-1} x_i \leq \frac{1}{n} \|x_i\|^2 \lambda_{\max}(\hat{Q}^{-1}). \lambda_{\max}(\hat{Q}^{-1}) \xrightarrow{p} \lambda_{\min}(Q)^{-1} < \infty. \text{ Y } \frac{1}{n} \max_i \|x_i\|^2 \xrightarrow{p} 0: \text{ para } \varepsilon > 0, \text{ por la unión y Markov, } P(\max_i \|x_i\|^2 > n\varepsilon) \leq nP(\|x_1\|^4 > n^2\varepsilon^2) \leq \mathbb{E}[\|x_1\|^4 \mathbb{1}\{\|x_1\|^4 > n^2\varepsilon^2\}]/(n\varepsilon^2) \rightarrow 0. \text{ Entonces } \|\hat{\Omega}_{HC2} - \hat{\Omega}_{HC0}\| \leq \max_i \left| \frac{1}{1-h_{ii}} - 1 \right| \cdot \frac{1}{n} \sum_i \hat{u}_i^2 \|x_i\|^2 = o_p(1) O_p(1).$$

Ejercicio 7.6 ★. Supón que la CEF es $m(x) = x^2$ con $x \sim U(-1, 2)$ y $\text{Var}(y | x) = 1$ (el ejemplo de la Clase 2). Para la proyección de y sobre $(1, x)$, calcula $\mathbb{E}[u^2 | x]$ y muestra que hay heterocedasticidad aunque $\text{Var}(y | x)$ sea constante.

 Solución 7.6 ★

La proyección es $\frac{1}{2} + x$ (Clase 2). $u = e + x^2 - x - \frac{1}{2}$, con $\mathbb{E}[e | x] = 0$, así que $\mathbb{E}[u^2 | x] = 1 + (x^2 - x - \frac{1}{2})^2$, que varía con x (vale 1,25 en $x = 0$ y $1 + 0,5^2 = 1,25$ en $x = 1$, pero $1 + 1,5^2 = 3,25$ en $x = 2$). El error de aproximación lineal es parte del error de proyección, y depende de x .