

Clase 8 · Errores de especificación

Variables omitidas, variables irrelevantes,
multicolinealidad y error de medida

Contenido

1	El modelo que estimas no es el que querías	2
2	Omitir variables relevantes	2
2.1	El caso de un regresor	3
2.2	Versión asintótica	4
3	Incluir variables irrelevantes	4
3.1	El dilema sesgo-varianza	5
4	Multicolinealidad	6
5	Error de medida	7
5.1	En la variable dependiente	7
5.2	En un regresor: el sesgo de atenuación	7
6	★ Postgrado: atenuación con varios regresores y el test RESET	9
6.1	Error de medida en regresión múltiple	10
6.2	El test RESET	10
7	Resumen	11
8	Ejercicios	11

1. El modelo que estimas no es el que querías

Hasta ahora supusimos que sabíamos qué regresores poner. En la vida real, la lista de regresores es una decisión, y se puede equivocar de cuatro formas:

1. **Omitir** una variable que importa.
2. **Incluir** una variable que no importa.
3. Incluir variables que están **muy correlacionadas** entre sí.
4. Medir mal una variable.

Esta clase estudia qué le pasa a MCO en cada caso. Spoiler: (1) y (4) producen **sesgo**, que no desaparece con más datos; (2) y (3) producen **varianza**, que sí desaparece con más datos. Casi todo el arte de la econometría aplicada consiste en preocuparse más de lo primero que de lo segundo.¹

Usaremos la partición $X = [X_1 \ X_2]$ con X_1 de $n \times k_1$ (las variables que nos interesan) y X_2 de $n \times k_2$, y la notación $M_2 = I - X_2(X_2'X_2)^{-1}X_2'$ de la Clase 3.

¹ Una vez un colega me dijo: “la varianza es un problema de muestra; el sesgo es un problema de ideas”. Con más datos resuelves el primero. Con más datos, el segundo solo te da más confianza en la respuesta equivocada.

2. Omitir variables relevantes

Supongamos que el modelo verdadero es

$$y = X_1\beta_1 + X_2\beta_2 + u, \quad \mathbb{E}[u \mid X] = 0,$$

(es decir, RL1–RL3 con los dos bloques) pero el investigador regresa y solo sobre X_1 y obtiene el estimador “corto”

$$\tilde{\beta}_1 = (X_1'X_1)^{-1}X_1'y.$$

Teorema 2.1 (Sesgo por variable omitida). *Bajo RL1–RL3 para el modelo largo y $\text{rango}(X_1) = k_1$,*

$$\mathbb{E}[\tilde{\beta}_1 \mid X] = \beta_1 + \underbrace{(X_1'X_1)^{-1}X_1'X_2}_{=\hat{\Pi}} \beta_2,$$

donde $\hat{\Pi}$ ($k_1 \times k_2$) es la matriz de coeficientes de MCO de regresar cada columna de X_2 sobre X_1 .

Demostración. Sustituyendo el modelo verdadero,

$$\tilde{\beta}_1 = (X_1'X_1)^{-1}X_1'(X_1\beta_1 + X_2\beta_2 + u) = \beta_1 + (X_1'X_1)^{-1}X_1'X_2\beta_2 + (X_1'X_1)^{-1}X_1'u.$$

Tomando esperanza condicional en X (que incluye a X_1 y X_2), el último término tiene esperanza cero por RL3, y los dos primeros son funciones de X . $\square$

El sesgo es $\hat{\Pi}\beta_2$: el **producto** de dos cosas:

- β_2 : cuánto afecta la variable omitida a y .
- $\hat{\Pi}$: cuánto se relaciona la variable omitida con las incluidas.

El sesgo desaparece solo si una de las dos es cero: o la variable omitida no importa ($\beta_2 = 0$), o no está correlacionada en la muestra con las incluidas ($X_1'X_2 = 0$, el caso del corolario de regresores ortogonales de la Clase 3).

2.1. El caso de un regresor

Con un regresor de interés x , una constante y una variable omitida w , el modelo verdadero es $y = \alpha + \beta x + \gamma w + u$ y el sesgo del coeficiente de la regresión corta es

$$\mathbb{E}[\tilde{\beta} | X] - \beta = \gamma \hat{\delta}, \quad \hat{\delta} = \frac{\sum_i (x_i - \bar{x})(w_i - \bar{w})}{\sum_i (x_i - \bar{x})^2},$$

donde $\hat{\delta}$ es la pendiente de regresar w sobre x . Su signo sigue una tabla que vale la pena memorizar:

	$\text{Corr}(x, w) > 0$	$\text{Corr}(x, w) < 0$
$\gamma > 0$	sesgo positivo	sesgo negativo
$\gamma < 0$	sesgo negativo	sesgo positivo

Ejemplo 2.1 (El retorno a la educación y la habilidad). En $\log(\text{salario}) = \alpha + \beta \text{educ} + \gamma \text{habilidad} + u$, la habilidad no se observa. Es razonable pensar que $\gamma > 0$ (la habilidad sube el salario) y que habilidad y educación están positivamente correlacionadas (a quien le va bien estudiando, estudia más). La

tabla dice: **el MCO corto sobreestima el retorno a la educación**. Parte de lo que atribuimos a la educación es en realidad habilidad. Esta es probablemente la discusión más famosa de la economía laboral, y la motivación de la Clase 10.²

2.2. Versión asintótica

Con muestreo i.i.d. (Clase 7), el sesgo no desaparece con n . Si $y_i = x'_{1i}\beta_1 + x'_{2i}\beta_2 + u_i$ con $\mathbb{E}[x_i u_i] = 0$, entonces

$$\tilde{\beta}_1 \xrightarrow{p} \beta_1 + \mathbb{E}[x_{1i}x'_{1i}]^{-1}\mathbb{E}[x_{1i}x'_{2i}]\beta_2 = \beta_1 + \Pi\beta_2,$$

por la LGN y la función continua aplicadas a $\tilde{\beta}_1 = \beta_1 + \hat{Q}_{11}^{-1}\hat{Q}_{12}\beta_2 + \hat{Q}_{11}^{-1}\frac{1}{n}\sum_i x_{1i}u_i$. El estimador corto es **inconsistente** para β_1 : converge, con toda seguridad, al número equivocado. (Lo que sí estima consistentemente es el coeficiente de la proyección *corta*, que es un objeto distinto; ver el Ejercicio 2.6.)

² Lo curioso es que cuando se usan variables instrumentales (Clase 10), las estimaciones del retorno a la educación suelen salir *mayores* que las de MCO, no menores. Card (1999) discute por qué. Resulta que el sesgo por habilidad no es el único en juego: también hay error de medida en la educación, que sesga hacia abajo (lo vemos más adelante en esta clase).

3. Incluir variables irrelevantes

Ahora el caso opuesto: el modelo verdadero es $y = X_1\beta_1 + u$ (es decir, $\beta_2 = 0$), pero el investigador incluye X_2 de todos modos. El estimador largo $\hat{\beta}_1$ (el bloque de X_1 en la regresión sobre $[X_1 \ X_2]$) sigue siendo insesgado: el modelo largo es correcto, solo que con $\beta_2 = 0$. ¿Cuál es el costo? La varianza.

Teorema 3.1 (El precio de las variables irrelevantes). *Supongamos RL1–RL4 para el modelo largo con $\beta_2 = 0$, y $X = [X_1 \ X_2]$ de rango completo. Sean $\tilde{\beta}_1$ (corto) y $\hat{\beta}_1$ (largo). Ambos son insesgados y*

$$\text{Var}(\hat{\beta}_1 | X) = \sigma^2(X'_1 M_2 X_1)^{-1} \geq \sigma^2(X'_1 X_1)^{-1} = \text{Var}(\tilde{\beta}_1 | X).$$

Borrador

El insesgamiento del corto sale de Teorema 2.1 con $\beta_2 = 0$. La varianza del largo sale de FWL (Clase 3): $\hat{\beta}_1$ es MCO de $M_2 y$ sobre $M_2 X_1$, con matriz $(X'_1 M_2 X_1)^{-1}$. (También es

el bloque (1, 1) de $(X'X)^{-1}$ por la inversa particionada de la Clase 1.) Para comparar varianzas necesito comparar las **inversas** de $X_1'M_2X_1$ y $X_1'X_1$. Primero comparo las matrices sin invertir: $X_1'X_1 - X_1'M_2X_1 = X_1'P_2X_1 \geq 0$. Y luego uso el resultado ★ de la Clase 1: “si $A \geq B > 0$ entonces $B^{-1} \geq A^{-1}$ ”.

Demostración. Inssegamiento. El corto es inssegado por Teorema 2.1 con $\beta_2 = 0$; el largo, por la Clase 4.

Varianza del corto. Con $\beta_2 = 0$, $\tilde{\beta}_1 = \beta_1 + (X_1'X_1)^{-1}X_1'u$, y por RL4, $\text{Var}(\tilde{\beta}_1 | X) = \sigma^2(X_1'X_1)^{-1}$.

Varianza del largo. Por FWL, $\hat{\beta}_1 = (X_1'M_2X_1)^{-1}X_1'M_2y$. Como $M_2X_2 = 0$ y $\beta_2 = 0$, $M_2y = M_2X_1\beta_1 + M_2u$, así que $\hat{\beta}_1 = \beta_1 + (X_1'M_2X_1)^{-1}X_1'M_2u$ y

$$\text{Var}(\hat{\beta}_1 | X) = (X_1'M_2X_1)^{-1}X_1'M_2(\sigma^2 I)M_2X_1(X_1'M_2X_1)^{-1} = \sigma^2(X_1'M_2X_1)^{-1},$$

usando $M_2M_2 = M_2$.

Comparación. Sean $A = X_1'X_1$ y $B = X_1'M_2X_1$. Como $I = P_2 + M_2$,

$$A - B = X_1'P_2X_1 = (P_2X_1)'(P_2X_1) \geq 0.$$

Además $B > 0$ (en la demostración de FWL vimos que M_2X_1 tiene rango columna completo). Luego $A \geq B > 0$ y, por el orden de las inversas (Clase 1, sección ★), $B^{-1} \geq A^{-1}$. Multiplicando por $\sigma^2 > 0$ se obtiene el resultado. $\square$

La diferencia es cero si y solo si $P_2X_1 = 0$, es decir, si X_1 y X_2 son ortogonales. **Incluir una variable irrelevante cuesta varianza en la medida en que esté correlacionada con las relevantes.** Si no lo está, es gratis (salvo un grado de libertad en s^2).

3.1. El dilema sesgo-varianza

Juntando Teorema 2.1 y Teorema 3.1: si dudas de si incluir X_2 ,

- Si la incluyes y era irrelevante: pagas varianza.
- Si la omites y era relevante: pagas sesgo.

Con una sola variable de interés, el error cuadrático medio del estimador corto es $ECM(\tilde{\beta}_1) = \text{Var}(\tilde{\beta}_1) + (\text{sesgo})^2$, y puede ser menor que el del largo si β_2 es chico. Pero como el sesgo no desaparece con n y la varianza sí, **en muestras grandes siempre gana incluir**. Esto justifica la regla práctica de ser generoso con los controles, con una excepción importante: los **malos controles**, variables que son ellas mismas resultado del regresor de interés (Ejercicio 8.5).

4. Multicolinealidad

La multicolinealidad es el caso en que los regresores están muy correlacionados entre sí. Hay que distinguir dos versiones.

Perfecta: una columna de X es combinación lineal exacta de otras. Entonces $\text{rango}(X) < k$, $X'X$ no es invertible (Clase 1) y MCO no está definido. Los coeficientes no están **identificados**: hay infinitos b que dan el mismo Xb . La solución es eliminar la redundancia.

Imperfecta: las columnas son “casi” dependientes. MCO está definido y sigue siendo insesgado y MELI. El problema es solo de precisión. La fórmula de la Clase 4 lo dice todo:

$$\text{Var}(\hat{\beta}_j | X) = \frac{\sigma^2}{\text{SCT}_j(1 - R_j^2)} = \frac{\sigma^2}{\text{SCT}_j} \cdot \underbrace{\frac{1}{1 - R_j^2}}_{\text{VIF}_j}.$$

El **factor de inflación de varianza** VIF_j mide cuánto se multiplica la varianza de $\hat{\beta}_j$ respecto del caso en que x_j no estuviera correlacionado con los demás regresores. Con $R_j^2 = 0,9$, $\text{VIF} = 10$; con $R_j^2 = 0,99$, $\text{VIF} = 100$ y los errores estándar se multiplican por 10.

 La multicolinealidad no es una violación de supuestos

Es tentador tratar la multicolinealidad como una “enfermedad” que hay que curar. No lo es. Todos los teoremas de las Clases 4, 5 y 7 siguen valiendo; los errores estándar grandes son **correctos**: reflejan que los datos no traen suficiente in-

formación para separar los efectos de x_j y de los regresores con que se mueve. Goldberger se burlaba de esta confusión llamándola “micronumerosidad”: el problema es tener pocos datos (o datos con poca variación independiente), y a nadie se le ocurre hacer tests para detectar la micronumerosidad.¹ Las “soluciones” como eliminar un regresor correlacionado cambian la pregunta y, por Teorema 2.1, introducen sesgo.

Un detalle interesante: la multicolinealidad afecta a los coeficientes individuales, pero **no** necesariamente a combinaciones de ellos. Si x_2 y x_3 son casi idénticos, $\hat{\beta}_2$ y $\hat{\beta}_3$ son muy imprecisos, pero $\hat{\beta}_2 + \hat{\beta}_3$ puede estimarse con gran precisión (la covarianza entre $\hat{\beta}_2$ y $\hat{\beta}_3$ es muy negativa). Los datos saben el efecto conjunto; lo que no saben es cómo repartirlo.

5. Error de medida

5.1. En la variable dependiente

Si observamos $y = y^* + v$ en lugar de y^* , con v un error de medida con media cero no correlacionado con x , entonces $y = x'\beta + (u + v)$. El error compuesto $u + v$ sigue cumpliendo $\mathbb{E}[x(u + v)] = 0$, así que MCO sigue siendo consistente. El único costo es más varianza ($\text{Var}(u + v) > \text{Var}(u)$ si u y v no están correlacionados). **El error de medida en y es inocuo (salvo por precisión).**

5.2. En un regresor: el sesgo de atenuación

El caso interesante es cuando el regresor está mal medido. Consideremos el modelo con un regresor:

$$y_i = \alpha + \beta x_i^* + u_i,$$

¹El capítulo 23 de *A Course in Econometrics* de Goldberger (1991) es una parodia perfecta: toma cada frase de los libros sobre multicolinealidad y la reescribe cambiando “multicolinealidad” por “micronumerosidad”. “Los síntomas de la micronumerosidad incluyen errores estándar grandes...” Si tienes acceso al libro, léelo. Son dos páginas.

pero no observamos x_i^* sino $x_i = x_i^* + v_i$, donde v_i es el error de medida.

Supuestos del error de medida clásico

(x_i^*, u_i, v_i) i.i.d., con $\mathbb{E}[u_i] = \mathbb{E}[v_i] = 0$, $\text{Var}(x_i^*) = \sigma_*^2 > 0$, $\text{Var}(v_i) = \sigma_v^2$, y u_i, v_i, x_i^* mutuamente no correlacionados.

Teorema 5.1 (Sesgo de atenuación). *Bajo los supuestos anteriores, la pendiente de MCO de y sobre $(1, x)$ satisface*

$$\hat{\beta} \xrightarrow{p} \lambda\beta, \quad \lambda = \frac{\sigma_*^2}{\sigma_*^2 + \sigma_v^2} \in (0, 1].$$

Borrador

Sustituyo $x^* = x - v$ en el modelo: $y = \alpha + \beta x + (u - \beta v)$. El nuevo “error” es $u - \beta v$, y ahí está el problema: v está dentro de x y dentro del error. Así que el regresor está correlacionado con el error: $\text{Cov}(x, u - \beta v) = \text{Cov}(x^* + v, u - \beta v) = -\beta\sigma_v^2$.

Para el límite, uso que la pendiente converge a $\text{Cov}(x, y)/\text{Var}(x)$ (la pendiente de la proyección lineal, Clases 2 y 7). $\text{Cov}(x, y) = \text{Cov}(x^* + v, \alpha + \beta x^* + u) = \beta\sigma_*^2$ y $\text{Var}(x) = \sigma_*^2 + \sigma_v^2$.

Demostración. La pendiente de MCO es $\hat{\beta} = \widehat{\text{Cov}}(x, y)/\widehat{\text{Var}}(x)$ (Clase 3). Por la LGN y la función continua (como en la Clase 7), $\hat{\beta} \xrightarrow{p} \text{Cov}(x_i, y_i)/\text{Var}(x_i)$, siempre que $\text{Var}(x_i) > 0$. Calculamos, usando bilinealidad de la covarianza y los supuestos de no correlación:

$$\text{Cov}(x_i, y_i) = \text{Cov}(x_i^* + v_i, \alpha + \beta x_i^* + u_i) = \beta \text{Var}(x_i^*) + \text{Cov}(x_i^*, u_i) + \beta \text{Cov}(v_i, x_i^*) + \text{Cov}(v_i, u_i) = \beta\sigma_*^2,$$

$$\text{Var}(x_i) = \text{Var}(x_i^*) + \text{Var}(v_i) + 2 \text{Cov}(x_i^*, v_i) = \sigma_*^2 + \sigma_v^2.$$

$$\text{Luego } \hat{\beta} \xrightarrow{p} \beta\sigma_*^2/(\sigma_*^2 + \sigma_v^2) = \lambda\beta. \quad \square$$

El factor λ es la **razón señal-ruído** (o *fiabilidad*) de x : la fracción de la varianza de x que es señal. Como $0 < \lambda \leq 1$, el estimador está sesgado **hacia cero**: tiene el signo correcto, pero es más




Figura 1: Con error de medida clásico en el regresor, la pendiente estimada se aplana. Aquí $\sigma_v^2 = \sigma_*^2$, así que $\lambda = 1/2$.

chico en valor absoluto. Por eso se llama sesgo de *atenuación*. La intuición visual de la figura: el ruido esparce los puntos horizontalmente, y una nube más ancha con la misma variación vertical tiene una pendiente más plana.

Un comentario sobre el contraste con el error en y : el error de medida es inocuo en y y dañino en x porque MCO trata asimétricamente a y y a x . Minimiza distancias **verticales**; el ruido vertical se promedia, el horizontal no.

6. ★ Postgrado: atenuación con varios regresores y el test RESET

! ★ Postgrado

Con varios regresores, el error de medida en uno contamina a todos. Además, presentamos el test RESET de forma funcional como un test de Wald.

6.1. Error de medida en regresión múltiple

Supongamos $y_i = \beta x_i^* + w_i' \gamma + u_i$, con w_i (que incluye la constante) bien medido y $x_i = x_i^* + v_i$ con error de medida clásico (v_i no correlacionado con x_i^*, w_i, u_i). Por FWL, el coeficiente de x en la regresión de y sobre (x, w) converge a $\text{Cov}(\tilde{x}_i, y_i) / \text{Var}(\tilde{x}_i)$, donde $\tilde{x}_i$ es el residuo de la proyección lineal de x_i sobre w_i . Sea $\tilde{x}_i^*$ el residuo de proyectar x_i^* sobre w_i . Como v_i no está correlacionado con w_i , la proyección de $x_i = x_i^* + v_i$ sobre w_i es la de x_i^* , y $\tilde{x}_i = \tilde{x}_i^* + v_i$. Entonces

$$\hat{\beta} \xrightarrow{p} \beta \frac{\text{Var}(\tilde{x}_i^*)}{\text{Var}(\tilde{x}_i^*) + \sigma_v^2} = \beta \lambda_w, \quad \lambda_w = \frac{\sigma_*^2(1 - \rho^2)}{\sigma_*^2(1 - \rho^2) + \sigma_v^2} \leq \lambda,$$

donde ρ^2 es el R^2 poblacional de proyectar x^* sobre w . (Para el numerador: $\text{Cov}(\tilde{x}_i, y_i) = \text{Cov}(\tilde{x}_i^* + v_i, \beta x_i^* + w_i' \gamma + u_i) = \beta \text{Var}(\tilde{x}_i^*)$, porque $\tilde{x}_i^*$ es ortogonal a w_i y $\text{Cov}(\tilde{x}_i^*, x_i^*) = \text{Var}(\tilde{x}_i^*)$.) Dos lecciones:

1. **Agregar controles empeora la atenuación.** Los controles se llevan parte de la señal de x^* (la parte predecible por w), pero nada del ruido. La razón señal-ruido del residuo es menor. Esto es especialmente grave en regresiones con efectos fijos (Econometría 2): al restar medias por individuo se elimina mucha señal y poco ruido.
2. **El sesgo se contagia.** Los coeficientes de w también quedan sesgados: parte del efecto de x^* que x no logra capturar es absorbida por las variables de w correlacionadas con x^* (Ejercicio 8.7).

6.2. El test RESET

Si la CEF no es lineal, la regresión lineal es solo una aproximación (Clase 2). Ramsey (1969) propuso un test simple de mala especificación de forma funcional: agregar potencias de los valores ajustados y testear si importan. Se estima

$$y_i = x_i' \beta + \delta_1 \hat{y}_i^2 + \delta_2 \hat{y}_i^3 + \text{error}$$

y se testea $H_0 : \delta_1 = \delta_2 = 0$ con un test F (o de Wald robusto, Clase 7). La lógica: si la CEF fuera $x' \beta$, ninguna función no lineal de

x debería ayudar a predecir y (por la descomposición de la CEF de la Clase 2, el error de la CEF no está correlacionado con *ninguna* función de x). El test tiene poder contra muchas alternativas, pero no dice cuál es la forma correcta: detecta el problema, no lo arregla.

7. Resumen

- Omitir X_2 sesga $\tilde{\beta}_1$ en $\hat{\Pi}\beta_2$ (Teorema 2.1): el efecto de la omitida por su relación con las incluidas. El sesgo no desaparece con n .
- Incluir X_2 irrelevante no sesga, pero aumenta la varianza (Teorema 3.1), salvo si $X_2 \perp X_1$.
- Multicolinealidad imperfecta: varianza inflada por $VIF_j = 1/(1 - R_j^2)$. No viola supuestos.
- Error de medida clásico en x : $\hat{\beta} \xrightarrow{p} \lambda\beta$ con $\lambda = \sigma_u^2/(\sigma_u^2 + \sigma_v^2)$ (Teorema 5.1). En y es inocuo.

8. Ejercicios

Ejercicio 8.1. Modelo verdadero: $y = \beta_0 + \beta_1 x + \beta_2 w + u$ con $\beta_1 = 2$, $\beta_2 = -3$. En la población, $\text{Var}(x) = 4$, $\text{Cov}(x, w) = 1$. ¿A qué converge la pendiente de la regresión de y sobre $(1, x)$?

Solución 8.1

$\delta = \text{Cov}(x, w) / \text{Var}(x) = 1/4$. Límite: $\beta_1 + \beta_2 \delta = 2 - 3/4 = 1,25$. Sesgo negativo, como predice la tabla ($\beta_2 < 0$, correlación positiva).

Ejercicio 8.2. Demuestra que si x y w tienen correlación muestral cero, entonces el coeficiente de x es el mismo en la regresión de y sobre $(1, x)$ y sobre $(1, x, w)$, pero su error estándar puede cambiar. ¿En qué dirección, típicamente?

💡 Solución 8.2

Por FWL con la constante, basta ver las variables en desvíos, que son ortogonales; por el corolario de regresores ortogonales (Clase 3), el coeficiente no cambia. El error estándar es $s\sqrt{1/\text{SCT}_x}$ en ambos casos (pues $R_x^2 = 0$), pero s cambia: si w explica parte de y , el s de la regresión larga es menor. Típicamente el error estándar **baja**: agregar un control no correlacionado con x pero que predice y mejora la precisión. (Es la lógica de agregar controles en experimentos aleatorios.)

Ejercicio 8.3. Con $R_j^2 = 0,95$, ¿por cuánto se multiplican los errores estándar de $\hat{\beta}_j$ respecto del caso sin correlación? ¿Cuántas veces más observaciones harían falta para compensarlo (suponiendo que SCT_j crece proporcionalmente a n)?

💡 Solución 8.3

$\text{VIF} = 20$, los errores estándar se multiplican por $\sqrt{20} \approx 4,47$. Como la varianza es proporcional a $1/n$, harían falta 20 veces más observaciones. Esa es la “micronumerosidad” de Goldberger en números.

Ejercicio 8.4. En el modelo de error de medida clásico, suponga que un estudio previo informa que la fiabilidad de la variable x es $\lambda = 0,8$. Si la pendiente de MCO es 0,4, ¿cuál es una estimación consistente de β ? ¿Qué pasa con el intercepto?

💡 Solución 8.4

$\hat{\beta}/\lambda = 0,5$. El intercepto converge a $\mathbb{E}[y] - \lambda\beta\mathbb{E}[x] = \alpha + \beta\mu_* - \lambda\beta\mu_* = \alpha + (1 - \lambda)\beta\mu_*$: también está sesgado (salvo si $\mu_* = 0$), en dirección opuesta a la pendiente, porque la recta sigue pasando por las medias.

Ejercicio 8.5. (Malos controles.) Un programa de capacitación D (asignado al azar) sube el salario y en parte porque permite acceder a mejores ocupaciones O . Explica por qué la regresión de y sobre D y O no estima el efecto total del programa, aunque O sea un predictor de y .

💡 Solución 8.5

O es un resultado de D (un “mediador”). Al controlar por O , se compara a tratados y no tratados *dentro* de la misma ocupación, lo que elimina el canal ocupacional del efecto: el coeficiente de D estima, a lo más, un efecto “directo”. Peor aún, si la ocupación depende también de habilidades no observadas, condicionar en O rompe la aleatorización (quienes llegan a una buena ocupación *sin* el programa son distintos de quienes llegan *con* él) e introduce sesgo de selección. Angrist y Pischke (2009, sección 3.2.3) llaman a esto “bad control”.

Ejercicio 8.6 ★. Demuestra Teorema 3.1 sin usar el orden de las inversas, calculando directamente $\text{Var}(\hat{\beta}_1 | X) - \text{Var}(\tilde{\beta}_1 | X)$ con Gauss–Markov.

💡 Solución 8.6 ★

Con $\beta_2 = 0$, el modelo *corto* satisface RL1–RL4 con regresores X_1 . $\hat{\beta}_1 = (X_1' M_2 X_1)^{-1} X_1' M_2 y$ es lineal en y y es insesgado para β_1 en el modelo corto: $(X_1' M_2 X_1)^{-1} X_1' M_2 X_1 = I$. Por Gauss–Markov aplicado al modelo corto, su varianza es mayor o igual que la del MCO corto $\tilde{\beta}_1$. ¡El teorema sale de Gauss–Markov en una línea!

Ejercicio 8.7 ★. En $y = \beta x^* + \gamma w + u$ (variables con media cero, sin constante), con $x = x^* + v$ y error de medida clásico, demuestra que el coeficiente de w en la regresión de y sobre (x, w) converge a $\gamma + \beta(1 - \lambda_w)\pi$, donde $\pi = \text{Cov}(x^*, w) / \text{Var}(w)$.

💡 Solución 8.7 ★

Escribe $y = \beta x + \gamma w + (u - \beta v)$. Los coeficientes límite (b_x, b_w) resuelven $\mathbb{E}[(x, w)'(y - b_x x - b_w w)] = 0$. Sabemos que $b_x = \lambda_w \beta$. La ecuación de w : $\mathbb{E}[wy] = b_x \mathbb{E}[wx] + b_w \mathbb{E}[w^2]$. Con $\mathbb{E}[wy] = \beta \mathbb{E}[wx^*] + \gamma \mathbb{E}[w^2]$ y $\mathbb{E}[wx] = \mathbb{E}[wx^*]$: $b_w \mathbb{E}[w^2] = \gamma \mathbb{E}[w^2] + \beta(1 - \lambda_w) \mathbb{E}[wx^*]$. Dividiendo, $b_w = \gamma + \beta(1 - \lambda_w)\pi$. El coeficiente de w absorbe la parte del efecto de x^* que la x ruidosa no captura.