

Clase 9 · Mínimos cuadrados generalizados

Heterocedasticidad, autocorrelación y el teorema de Aitken

Contenido

1	Cuando los errores no son esféricos	2
2	Qué le pasa a MCO	2
3	El estimador de MCG	3
4	Heterocedasticidad: mínimos cuadrados ponderados	5
5	Autocorrelación: errores AR(1)	6
5.1	La transformación de Prais-Winsten	7
6	MCG factible	7
7	Detectar el problema: tests	8
7.1	Heterocedasticidad: Breusch-Pagan y White . . .	8
7.2	Autocorrelación: Durbin-Watson	9
8	★ Postgrado: cuánto pierde MCO, y cuándo no pierde nada	10
9	Resumen	11
10	Ejercicios	12

1. Cuando los errores no son esféricos

En la Clase 4, el supuesto RL4 decía $\text{Var}(u | X) = \sigma^2 I$: todos los errores con la misma varianza y sin correlación entre ellos. Hay dos formas típicas de romperlo:

- **Heterocedasticidad:** $\text{Var}(u_i | X)$ cambia con i . El gasto en alimentación varía mucho más entre familias ricas que entre familias pobres; el error de pronóstico de las ventas es mayor en empresas grandes.
- **Autocorrelación:** $\text{Cov}(u_t, u_s | X) \neq 0$ para $t \neq s$. En series de tiempo, un shock que eleva el PIB este trimestre suele seguir elevándolo el próximo.

En la Clase 7 vimos una respuesta: seguir usando MCO pero corregir los errores estándar (White). Es una respuesta segura pero conformista: MCO sigue siendo insesgado y consistente, pero **ya no es el mejor**. Esta clase estudia la respuesta ambiciosa: usar la estructura de la varianza para construir un estimador más eficiente.

A lo largo de la clase supondremos:

Modelo de regresión generalizado

- **RL1–RL3** como en la Clase 4.
- **RL4'**: $\text{Var}(u | X) = \sigma^2 \Omega$, con Ω una matriz $n \times n$ **conocida** (puede depender de X), simétrica y definida positiva.

El “conocida” es irreal. Lo relajaremos al final (MCG factible), pero primero hay que entender el caso ideal.

2. Qué le pasa a MCO

Teorema 2.1 (MCO bajo errores no esféricos). *Bajo RL1–RL3 y RL4':*

1. $\hat{\beta} = (X'X)^{-1}X'y$ sigue siendo insesgado.
2. $\text{Var}(\hat{\beta} | X) = \sigma^2 (X'X)^{-1}X'\Omega X(X'X)^{-1}$.

3. $\mathbb{E}[s^2 \mid X] = \sigma^2 \text{tr}(M\Omega)/(n - k)$, que en general es distinto de σ^2 .

Demostración.

- (1) El insesgamiento de la Clase 4 solo usó RL1–RL3.
- (2) $\hat{\beta} - \beta = (X'X)^{-1}X'u$, así que por la regla de la varianza de transformaciones lineales, $\text{Var}(\hat{\beta} \mid X) = (X'X)^{-1}X'(\sigma^2\Omega)X(X'X)^{-1}$.
- (3) $(n - k)s^2 = u'Mu$ y, por la esperanza de una forma cuadrática (Clase 1), $\mathbb{E}[u'Mu \mid X] = \text{tr}(M\sigma^2\Omega)$.

□

Así que la fórmula de manual $s^2(X'X)^{-1}$ está doblemente equivocada: la forma de la matriz es incorrecta (falta el sándwich) y s^2 está sesgado. Los tests t y F de la Clase 5 dejan de tener la distribución que dicen tener.

3. El estimador de MCG

La idea es simple y bonita: **transformar el modelo para que los errores se vuelvan esféricos, y después aplicar MCO**. Como $\Omega > 0$, existe su raíz cuadrada inversa $\Omega^{-1/2}$ (Clase 1, sección ★), simétrica, con $\Omega^{-1/2}\Omega\Omega^{-1/2} = I$ y $\Omega^{-1/2}\Omega^{-1/2} = \Omega^{-1}$. Premultiplicando el modelo por ella:

$$\underbrace{\Omega^{-1/2}y}_{y^*} = \underbrace{\Omega^{-1/2}X}_{X^*}\beta + \underbrace{\Omega^{-1/2}u}_{u^*}.$$

El modelo transformado $y^* = X^*\beta + u^*$ cumple todos los supuestos clásicos:

- $\mathbb{E}[u^* \mid X] = \Omega^{-1/2}\mathbb{E}[u \mid X] = 0$;
- $\text{Var}(u^* \mid X) = \Omega^{-1/2}(\sigma^2\Omega)\Omega^{-1/2} = \sigma^2I$;
- $\text{rango}(X^*) = \text{rango}(X) = k$, porque $\Omega^{-1/2}$ es invertible.

¡Es un modelo de regresión clásico con los mismos β ! Su estimador MCO es

$$\tilde{\beta} = (X^{*'}X^*)^{-1}X^{*'}y^* = (X'\Omega^{-1/2}\Omega^{-1/2}X)^{-1}X'\Omega^{-1/2}\Omega^{-1/2}y = (X'\Omega^{-1}X)^{-1}X'\Omega^{-1}y.$$

Definición 3.1 (Mínimos cuadrados generalizados). El estimador de **MCG** (o GLS, por *generalized least squares*) es

$$\tilde{\beta} = (X' \Omega^{-1} X)^{-1} X' \Omega^{-1} y.$$

Equivalentemente, minimiza la suma de cuadrados ponderada $(y - Xb)' \Omega^{-1} (y - Xb)$.

La equivalencia se ve porque $(y^* - X^*b)'(y^* - X^*b) = (y - Xb)' \Omega^{-1/2} \Omega^{-1/2} (y - Xb) = (y - Xb)' \Omega^{-1} (y - Xb)$. Nota además que $\tilde{\beta}$ no depende de la raíz cuadrada elegida: cualquier matriz P con $P'P = \Omega^{-1}$ da el mismo estimador (lo usaremos con Prais-Winsten).

Teorema 3.1 (Aitken). *Bajo RL1–RL3 y RL4':*

1. $\tilde{\beta}$ es insesgado y $\text{Var}(\tilde{\beta} | X) = \sigma^2 (X' \Omega^{-1} X)^{-1}$.
2. $\tilde{\beta}$ es el mejor estimador lineal insesgado: para todo estimador lineal insesgado $\hat{\beta} = Ay$, $\text{Var}(\hat{\beta} | X) \geq \text{Var}(\tilde{\beta} | X)$.
3. En particular, $\text{Var}(\hat{\beta}_{MCO} | X) \geq \text{Var}(\tilde{\beta} | X)$.

Borrador

Todo sale de Gauss–Markov en el modelo transformado. (1) es la Clase 4 aplicada a (y^*, X^*) : insesgado con varianza $\sigma^2 (X^{*'} X^*)^{-1} = \sigma^2 (X' \Omega^{-1} X)^{-1}$.

Para (2), el truco es ver que **cualquier estimador lineal en y también es lineal en y^*** : como $y = \Omega^{1/2} y^*$, se tiene $Ay = (A\Omega^{1/2})y^*$. Y si es insesgado en un modelo, lo es en el otro (son el mismo modelo escrito de otra forma). Así que compite en el torneo de Gauss–Markov del modelo transformado, y ahí gana MCO transformado, que es MCG.

Demostración.

- (1) El modelo transformado satisface RL1–RL4 (lo verificamos arriba), y $\tilde{\beta}$ es su estimador de MCO. Por la Clase 4, $\tilde{\beta}$ es insesgado y $\text{Var}(\tilde{\beta} | X) = \sigma^2 (X^{*'} X^*)^{-1} = \sigma^2 (X' \Omega^{-1} X)^{-1}$.

(2) Sea $\tilde{\beta} = Ay$ lineal (con A función de X) e insesgado. Como $y = \Omega^{1/2}y^*$, se tiene $\tilde{\beta} = (A\Omega^{1/2})y^*$, que es un estimador lineal en y^* con matriz $A^* = A\Omega^{1/2}$ que depende solo de X . Es insesgado (la esperanza de $\tilde{\beta}$ no depende de cómo lo escribamos). Por Gauss–Markov en el modelo transformado, cuyo MCO es $\tilde{\beta}$, $\text{Var}(\tilde{\beta} | X) \geq \text{Var}(\tilde{\beta} | X)$.

(3) MCO es lineal e insesgado; se aplica (2).

□

En la sección ★ damos una demostración directa de (3) que muestra *cuánto* se pierde con MCO.

4. Heterocedasticidad: mínimos cuadrados ponderados

El caso más simple: $\Omega = \text{diag}(\omega_1, \dots, \omega_n)$, es decir, errores no correlacionados con $\text{Var}(u_i | X) = \sigma^2 \omega_i$. Entonces $\Omega^{-1/2} = \text{diag}(\omega_i^{-1/2})$ y la transformación es dividir cada observación por $\sqrt{\omega_i}$:

$$\frac{y_i}{\sqrt{\omega_i}} = \frac{x_i'}{\sqrt{\omega_i}}\beta + \frac{u_i}{\sqrt{\omega_i}}.$$

El estimador resultante minimiza $\sum_i (y_i - x_i'b)^2 / \omega_i$ y se llama **mínimos cuadrados ponderados** (MCP, o WLS). Cada observación pesa inversamente a su varianza: **las observaciones ruidosas cuentan menos**. Tiene todo el sentido: si una medición es poco confiable, no deberías darle el mismo peso que a una precisa.¹

Ejemplo 4.1 (Varianza proporcional a un regresor). Si $\text{Var}(u_i | x_i) = \sigma^2 z_i$ con $z_i > 0$ observado (por ejemplo, el ingreso en una regresión de gasto), entonces $\omega_i = z_i$ y se divide todo por $\sqrt{z_i}$. En el modelo $y_i = \alpha + \beta z_i + u_i$, el transformado es

$$\frac{y_i}{\sqrt{z_i}} = \alpha \frac{1}{\sqrt{z_i}} + \beta \sqrt{z_i} + u_i^*,$$

una regresión **sin constante** sobre dos regresores nuevos. Un error común es olvidar que la constante original se transforma en $1/\sqrt{z_i}$.

¹ Esta es exactamente la misma idea que usarías para combinar dos termómetros, uno bueno y uno malo: promediar las lecturas dándole más peso al bueno. El promedio óptimo pondera por $1/\text{varianza}$. MCP es eso con regresores.

5. Autocorrelación: errores AR(1)

En series de tiempo ($i = t = 1, \dots, T$), el modelo de autocorrelación más usado es el **autorregresivo de orden 1**:

$$u_t = \rho u_{t-1} + \varepsilon_t, \quad |\rho| < 1,$$

donde $\{\varepsilon_t\}$ son no correlacionados entre sí, con media cero y varianza σ_ε^2 , y ε_t no está correlacionado con $u_{t-1}, u_{t-2}, \dots$. Suponemos además que el proceso es **estacionario**: $\text{Var}(u_t)$ no depende de t (todo condicional en X , que omitimos de la notación).

Lema 5.1 (Covarianzas del AR(1)). *Bajo los supuestos anteriores, para todo t y $s \geq 0$,*

$$\text{Var}(u_t) = \frac{\sigma_\varepsilon^2}{1 - \rho^2}, \quad \text{Cov}(u_t, u_{t-s}) = \rho^s \frac{\sigma_\varepsilon^2}{1 - \rho^2}.$$

Es decir, $\text{Var}(u) = \sigma_\varepsilon^2 \Omega$ con $\Omega_{ts} = \rho^{|t-s|} / (1 - \rho^2)$.

Demostración. Varianza. Sea $\gamma_0 = \text{Var}(u_t)$, igual para todo t por estacionariedad. Como ε_t no está correlacionado con u_{t-1} ,

$$\gamma_0 = \text{Var}(\rho u_{t-1} + \varepsilon_t) = \rho^2 \text{Var}(u_{t-1}) + \text{Var}(\varepsilon_t) = \rho^2 \gamma_0 + \sigma_\varepsilon^2.$$

Despejando (posible porque $\rho^2 < 1$), $\gamma_0 = \sigma_\varepsilon^2 / (1 - \rho^2)$.

Covarianzas, por inducción en s . Para $s = 0$ es lo anterior. Si vale para $s - 1$, entonces, como ε_t no está correlacionado con u_{t-s} (para $s \geq 1$),

$$\text{Cov}(u_t, u_{t-s}) = \text{Cov}(\rho u_{t-1} + \varepsilon_t, u_{t-s}) = \rho \text{Cov}(u_{t-1}, u_{(t-1)-(s-1)}) = \rho \cdot \rho^{s-1} \gamma_0 = \rho^s \gamma_0.$$

□

La correlación entre errores separados por s períodos es ρ^s : decae geométricamente. Con $\rho = 0,9$, dos errores separados por 10 trimestres todavía tienen correlación 0,35.

5.1. La transformación de Prais-Winsten

Calcular $\Omega^{-1/2}$ para una matriz $T \times T$ no es necesario. Basta con cualquier P tal que $\text{Var}(Pu) = \sigma_\varepsilon^2 I$ (entonces $P\Omega P' = I$, luego $P'P = \Omega^{-1}$ y el estimador es el mismo). Para el AR(1) hay una P muy natural:

$$(Pu)_1 = \sqrt{1 - \rho^2} u_1, \quad (Pu)_t = u_t - \rho u_{t-1} \quad (t \geq 2).$$

Teorema 5.1 (Prais-Winsten). *Con la P anterior, $\text{Var}(Pu) = \sigma_\varepsilon^2 I_T$. Por lo tanto, MCG en el modelo AR(1) es MCO en el modelo transformado*

$$\sqrt{1 - \rho^2} y_1 = \sqrt{1 - \rho^2} x_1' \beta + \text{error}, \quad y_t - \rho y_{t-1} = (x_t - \rho x_{t-1})' \beta + \varepsilon_t \quad (t \geq 2).$$

Demostración. Para $t \geq 2$, $(Pu)_t = u_t - \rho u_{t-1} = \varepsilon_t$, con varianza σ_ε^2 . Para $t = 1$, $\text{Var}(\sqrt{1 - \rho^2} u_1) = (1 - \rho^2) \gamma_0 = \sigma_\varepsilon^2$ por Lema 5.1. Covarianzas: para $2 \leq s < t$, $\text{Cov}(\varepsilon_t, \varepsilon_s) = 0$ por supuesto. Para $t \geq 2$, $\text{Cov}(\varepsilon_t, u_1) = 0$ porque ε_t no está correlacionado con los errores pasados $u_{t-1}, u_{t-2}, \dots$, entre los que está u_1 . Luego $\text{Var}(Pu) = \sigma_\varepsilon^2 I$. Como P es invertible (es triangular inferior con diagonal no nula), $P\Omega P' = I$ implica $\Omega^{-1} = P'P$, y MCO sobre (Py, PX) es $(X'P'PX)^{-1}X'P'Py = (X'\Omega^{-1}X)^{-1}X'\Omega^{-1}y$. $\square$

La versión que descarta la primera observación se llama **Cochrane-Orcutt**. Es más simple, pero pierde eficiencia (a veces bastante, si T es chico o los regresores tienen tendencia).

6. MCG factible

En la práctica Ω no es conocida. El procedimiento de **MCG factible** (MCGF) es:

1. Estimar el modelo por MCO y obtener los residuos $\hat{u}$.
2. Usar $\hat{u}$ para estimar los parámetros de Ω (por ejemplo, $\hat{\rho}$ regresando $\hat{u}_t$ sobre $\hat{u}_{t-1}$; o una función $\hat{\omega}_i$ regresando $\log \hat{u}_i^2$ sobre variables z_i).
3. Calcular $\hat{\beta}_{\text{MCGF}} = (X'\hat{\Omega}^{-1}X)^{-1}X'\hat{\Omega}^{-1}y$.

MCGF **no** es lineal ni, en general, insesgado ($\hat{\Omega}$ depende de y), así que Aitken no se aplica. Su justificación es asintótica: bajo condiciones de regularidad (que el modelo para Ω esté bien especificado y sus parámetros se estimen consistentemente), MCGF tiene la misma distribución asintótica que MCG con Ω conocida (sección ★).

⚠ MCG versus MCO robusto: la práctica moderna

Si el modelo para Ω está mal especificado, MCGF sigue siendo consistente (bajo exogeneidad estricta) pero sus errores estándar “de manual” son incorrectos, y la ganancia de eficiencia puede desaparecer. Por eso la práctica moderna suele preferir **MCO con errores estándar robustos** (Clase 7): renuncia a la eficiencia a cambio de no depender de un modelo para la varianza. Una solución intermedia, recomendada por Romano y Wolf (2017), es usar MCP con pesos estimados y errores estándar robustos: si el modelo de pesos es bueno ganas eficiencia, y si es malo la inferencia sigue siendo válida.

Hay además un peligro específico en series de tiempo: MCG con errores AR(1) usa y_{t-1} y x_{t-1} , y requiere exogeneidad estricta. Si x_t está correlacionado con u_{t-1} (por ejemplo, si x_t es un rezago de y), MCG puede ser inconsistente aunque MCO no lo sea.

7. Detectar el problema: tests

7.1. Heterocedasticidad: Breusch-Pagan y White

Si $\text{Var}(u_i | x_i) = \sigma^2 h(\alpha_0 + z_i' \alpha)$ para alguna función h y variables z_i (de dimensión p), la hipótesis de homocedasticidad es $H_0 : \alpha = 0$. El test de **Breusch-Pagan** (en la versión de Koenker, robusta a no normalidad) es:

1. Estimar por MCO y obtener $\hat{u}_i$.
2. Regresar $\hat{u}_i^2$ sobre $(1, z_i)$ y obtener el R^2 de esa regresión auxiliar.
3. Rechazar si $LM = nR^2$ supera el cuantil de la χ_p^2 .

La lógica: bajo H_0 , $\mathbb{E}[u_i^2 \mid z_i]$ no depende de z_i , así que z_i no debería predecir $\hat{u}_i^2$. El test de **White** es el caso particular en que z_i contiene los regresores, sus cuadrados y sus productos cruzados, y así detecta cualquier heterocedasticidad correlacionada con los segundos momentos de x_i , que es justamente la que invalida los errores estándar clásicos (Clase 7).

7.2. Autocorrelación: Durbin-Watson

El estadístico clásico de **Durbin-Watson** es

$$d = \frac{\sum_{t=2}^T (\hat{u}_t - \hat{u}_{t-1})^2}{\sum_{t=1}^T \hat{u}_t^2}.$$

Expandiendo el numerador,

$$d = \frac{\sum_{t=2}^T \hat{u}_t^2 + \sum_{t=2}^T \hat{u}_{t-1}^2 - 2 \sum_{t=2}^T \hat{u}_t \hat{u}_{t-1}}{\sum_{t=1}^T \hat{u}_t^2} \approx 2 - 2\hat{\rho} = 2(1 - \hat{\rho}),$$

donde $\hat{\rho} = \sum_{t=2}^T \hat{u}_t \hat{u}_{t-1} / \sum_{t=1}^T \hat{u}_t^2$ y la aproximación es que las dos primeras sumas del numerador difieren del denominador en un solo término cada una ($\hat{u}_1^2$ y $\hat{u}_T^2$), despreciable con T grande. Así, $d \approx 2$ indica ausencia de autocorrelación de primer orden, $d \approx 0$ autocorrelación positiva fuerte y $d \approx 4$ negativa fuerte. Su distribución exacta depende de X (por eso las tablas de Durbin-Watson traen cotas inferior y superior), y no es válido si hay variables dependientes rezagadas entre los regresores. Hoy suele preferirse el test de Breusch-Godfrey: regresar $\hat{u}_t$ sobre x_t y $\hat{u}_{t-1}, \dots, \hat{u}_{t-p}$, y usar $nR^2 \sim \chi_p^2$ asintóticamente.

8. ★ Postgrado: cuánto pierde MCO, y cuándo no pierde nada

! ★ Postgrado

Una demostración directa de la ineficiencia de MCO que da una fórmula explícita para la pérdida, el teorema de Kruskal sobre cuándo MCO y MCG coinciden, y el enunciado de la equivalencia asintótica de MCGF.

Teorema 8.1 (La pérdida de eficiencia de MCO). Sean $G = (X'\Omega^{-1}X)^{-1}X'\Omega^{-1}$ (MCG) y $A_0 = (X'X)^{-1}X'$ (MCO), y $D = A_0 - G$. Entonces $DX = 0$ y

$$\text{Var}(\hat{\beta}_{MCO} | X) = \text{Var}(\tilde{\beta} | X) + \sigma^2 D \Omega D'.$$

Demostración. $DX = A_0X - GX = I - I = 0$. Como $\hat{\beta}_{MCO} = A_0y = Gy + Dy$,

$$\text{Var}(A_0y | X) = \text{Var}(Gy | X) + \text{Var}(Dy | X) + \text{Cov}(Gy, Dy | X) + \text{Cov}(Dy, Gy | X).$$

La covarianza cruzada es

$$\text{Cov}(Gy, Dy | X) = G(\sigma^2\Omega)D' = \sigma^2(X'\Omega^{-1}X)^{-1}X'\Omega^{-1}\Omega D' = \sigma^2(X'\Omega^{-1}X)^{-1}(DX)' = 0.$$

$$Y \text{Var}(Dy | X) = \sigma^2 D \Omega D' \geq 0. \quad \square$$

Es la misma estructura que en la demostración de Gauss–Markov de la Clase 4: MCO es MCG más una perturbación no correlacionada con MCG. MCO no pierde nada exactamente cuando $D\Omega D' = 0$, es decir (como $\Omega > 0$), cuando $D = 0$.

Teorema 8.2 (Kruskal). MCO y MCG coinciden para todo y si y solo si $\text{col}(\Omega X) \subseteq \text{col}(X)$, es decir, si $\Omega X = XC$ para alguna matriz C de $k \times k$.

Demostración. ($\Leftarrow$) Supongamos $\Omega X = XC$. Como Ω es invertible, $\text{rango}(\Omega X) = k$, y como $\text{rango}(XC) \leq \text{rango}(C)$, C tiene rango k

y es invertible. Entonces $X = \Omega^{-1}XC$, es decir, $\Omega^{-1}X = XC^{-1}$, y trasponiendo (con Ω simétrica), $X'\Omega^{-1} = C^{-1'}X'$. Luego

$$\tilde{\beta} = (C^{-1'}X'X)^{-1}C^{-1'}X'y = (X'X)^{-1}C'C^{-1'}X'y = (X'X)^{-1}X'y.$$

($\Rightarrow$) Si $G = A_0$, entonces $(X'\Omega^{-1}X)^{-1}X'\Omega^{-1} = (X'X)^{-1}X'$. Trasponiendo, $\Omega^{-1}X(X'\Omega^{-1}X)^{-1} = X(X'X)^{-1}$, así que $\Omega^{-1}X = X(X'X)^{-1}(X'\Omega^{-1}X) = XB$ con B invertible, y $\Omega X = XB^{-1}$. $\square$

Ejemplo 8.1 (Errores equicorrelacionados). Si todos los errores tienen varianza σ^2 y correlación común r ($\Omega = (1 - r)I + ru'$, un modelo típico de “efecto de grupo”) y X incluye una constante, entonces $\Omega X = (1 - r)X + r\iota(\iota'X)$. El segundo término está en $\text{col}(X)$ porque ι es una columna de X . Por Kruskal, **MCO es MCG**: no hay nada que ganar. (Pero ¡cuidado!: los errores estándar de MCO siguen siendo incorrectos, porque $\text{Var}(\hat{\beta} | X) = \sigma^2(X'X)^{-1}X'\Omega X(X'X)^{-1} \neq \sigma^2(X'X)^{-1}$. Esta es la raíz del problema de los “errores agrupados”, Moulton, 1990.)

Equivalencia asintótica de MCGF. Supongamos $\Omega = \Omega(\theta)$ con θ de dimensión fija, $\hat{\theta} \xrightarrow{p} \theta$, y condiciones de regularidad que garanticen $\frac{1}{n}X'\hat{\Omega}^{-1}X - \frac{1}{n}X'\Omega^{-1}X \xrightarrow{p} 0$ y $\frac{1}{\sqrt{n}}X'(\hat{\Omega}^{-1} - \Omega^{-1})u \xrightarrow{p} 0$. Entonces

$$\sqrt{n}(\hat{\beta}_{\text{MCGF}} - \tilde{\beta}) \xrightarrow{p} 0,$$

y MCGF hereda la distribución asintótica $N(0, \sigma^2 \text{plim}(X'\Omega^{-1}X/n)^{-1})$ de MCG. La segunda condición es la delicada: necesita que el error de estimación de $\hat{\theta}$ no esté “demasiado” correlacionado con u , lo que típicamente se verifica con una expansión de Taylor de $\hat{\Omega}^{-1}$ en torno a θ y la exogeneidad estricta. Los detalles están en Amemiya (1985, cap. 6) o Hansen (2022, cap. 17).

9. Resumen

- Con $\text{Var}(u | X) = \sigma^2\Omega$, MCO es insesgado pero no eficiente, y sus errores estándar clásicos son incorrectos (Teorema 2.1).

- $MCG = (X'\Omega^{-1}X)^{-1}X'\Omega^{-1}y$ es MCO en el modelo transformado por $\Omega^{-1/2}$ y es MELI (Teorema 3.1).
- Heterocedasticidad: MCP pondera por $1/\omega_i$. AR(1): Prais-Winsten (Teorema 5.1).
- MCGF estima Ω primero; su justificación es asintótica.
- Tests: Breusch-Pagan/White (nR^2) para heterocedasticidad; Durbin-Watson ($d \approx 2(1 - \hat{\rho})$) y Breusch-Godfrey para autocorrelación.

10. Ejercicios

Ejercicio 9.1. En el modelo sin constante $y_i = \beta x_i + u_i$ con $\text{Var}(u_i | x) = \sigma^2 x_i^2$ ($x_i > 0$), encuentra el estimador de MCP y muestra que es el promedio de los cocientes y_i/x_i . Calcula su varianza y compárala con la de MCO.

Solución 9.1

Dividiendo por x_i : $y_i/x_i = \beta + u_i/x_i$, con errores homocedásticos. MCO del transformado sobre una constante es $\tilde{\beta} = \frac{1}{n} \sum_i y_i/x_i$, con varianza σ^2/n . MCO original: $\text{Var} = \sum x_i^2 \sigma^2 x_i^2 / (\sum x_i^2)^2 = \sigma^2 \sum x_i^4 / (\sum x_i^2)^2$. Por Cauchy-Schwarz, $(\sum x_i^2)^2 \leq n \sum x_i^4$, así que $\sigma^2 \sum x_i^4 / (\sum x_i^2)^2 \geq \sigma^2/n$, con igualdad solo si todos los x_i son iguales.

Ejercicio 9.2. Verifica numéricamente el Lema 5.1 para $\rho = 0,5$ y $\sigma_\varepsilon^2 = 1$: escribe la matriz $\text{Var}(u)$ para $T = 3$ y comprueba que $P \text{Var}(u) P' = I$ con la P de Prais-Winsten.

Solución 9.2

$$\gamma_0 = 1/0,75 = 4/3. \text{Var}(u) = \frac{4}{3} \begin{pmatrix} 1 & 0,5 & 0,25 \\ 0,5 & 1 & 0,5 \\ 0,25 & 0,5 & 1 \end{pmatrix}.$$

$$P = \begin{pmatrix} \sqrt{0,75} & 0 & 0 \\ -0,5 & 1 & 0 \\ 0 & -0,5 & 1 \end{pmatrix}. \text{ Por ejemplo, entrada } (2,2) \text{ de}$$

$$P \text{Var}(u) P' : \frac{4}{3} [(-0,5)^2 \cdot 1 + 2(-0,5)(1)(0,5) + 1] = \frac{4}{3} [0,25 -$$

$0,5 + 1] = 1$. Entrada (1, 2): $\frac{4}{3}\sqrt{0,75}[1 \cdot (-0,5) + 0,5 \cdot 1] = 0$.
Las demás se verifican igual.

Ejercicio 9.3. Demuestra que el estimador de MCG minimiza $(y - Xb)' \Omega^{-1} (y - Xb)$ completando el cuadrado, como en la Clase 3.

💡 Solución 9.3

Sea $\tilde{u} = y - X\tilde{\beta}$; entonces $X' \Omega^{-1} \tilde{u} = 0$ (ecuaciones normales generalizadas). Para cualquier b : $y - Xb = \tilde{u} + X(\tilde{\beta} - b)$ y $(y - Xb)' \Omega^{-1} (y - Xb) = \tilde{u}' \Omega^{-1} \tilde{u} + (\tilde{\beta} - b)' X' \Omega^{-1} X (\tilde{\beta} - b)$, pues el término cruzado es $2(\tilde{\beta} - b)' X' \Omega^{-1} \tilde{u} = 0$. Como $X' \Omega^{-1} X \succ 0$, el mínimo es único en $b = \tilde{\beta}$.

Ejercicio 9.4. En el Ejemplo 4.1, supón que por error el investigador divide por z_i en lugar de por $\sqrt{z_i}$. ¿Sigues siendo insesgado el estimador? ¿Es eficiente?

💡 Solución 9.4

Dividir por z_i es MCP con pesos $1/z_i^2$ en vez de $1/z_i$. Sigue siendo lineal e insesgado (cualquier MCP con pesos que dependan solo de X lo es, bajo RL3), pero no es el MELI: el error transformado u_i/z_i tiene varianza σ^2/z_i , que no es constante. Por Aitken, su varianza es mayor o igual que la de MCG.

Ejercicio 9.5. ¿Por qué el test de Durbin–Watson no es válido en el modelo $y_t = \alpha + \gamma y_{t-1} + \beta x_t + u_t$ con u_t AR(1)? ¿Qué le pasa a MCO en ese modelo?

💡 Solución 9.5

Con y_{t-1} como regresor y $u_t = \rho u_{t-1} + \varepsilon_t$, se tiene $\text{Cov}(y_{t-1}, u_t) = \rho \text{Cov}(y_{t-1}, u_{t-1}) \neq 0$ si $\rho \neq 0$: el regresor está correlacionado con el error contemporáneo. MCO es **inconsistente**, y sus residuos subestiman la autocorrelación, sesgando d hacia 2. Durbin propuso para este caso el estadístico h ; hoy se usa Breusch–Godfrey, que es válido con regresores rezagados.

Ejercicio 9.6 ★. Usa Teorema 8.1 para mostrar que, en la regresión sobre una constante ($X = \iota$) con $\Omega = \text{diag}(\omega_i)$, la varianza de la media muestral excede la del promedio ponderado óptimo en $\sigma^2 \left(\frac{\sum \omega_i}{n^2} - \frac{1}{\sum 1/\omega_i} \right)$, y verifica que esto es ≥ 0 .

 Solución 9.6 ★

MCO: $\bar{y}$, varianza $\sigma^2 \sum \omega_i / n^2$. MCG: $\sum (y_i / \omega_i) / \sum (1 / \omega_i)$, varianza $\sigma^2 / \sum (1 / \omega_i)$. La diferencia es la del enunciado. Es ≥ 0 porque $\frac{1}{n} \sum \omega_i \geq \frac{n}{\sum 1/\omega_i}$: la media aritmética es mayor o igual que la media armónica.

Ejercicio 9.7 ★. Usa Kruskal para mostrar que si $\Omega = \text{diag}(\omega_1 I_{n_1}, \omega_2 I_{n_2})$ (dos grupos con varianzas distintas) y X contiene dummies de cada grupo *interactuadas* con todos los regresores, entonces MCO = MCG. Interpreta.

 Solución 9.7 ★

Con $X = \text{diag}(X_1, X_2)$ (regresiones separadas por grupo, que es lo que producen las interacciones completas), $\Omega X = \text{diag}(\omega_1 X_1, \omega_2 X_2) = XC$ con $C = \text{diag}(\omega_1 I, \omega_2 I)$. Interpretación: si estimas un modelo separado para cada grupo, dentro de cada grupo los errores son homocedásticos y no hay nada que ponderar. MCG solo gana cuando la ponderación cambia cómo se combina información *entre* observaciones con varianzas distintas que comparten parámetros.