

Clase 10 · Endogeneidad y variables instrumentales

Cuando el regresor está correlacionado con el error

Contenido

1	El supuesto que no se puede probar	2
2	Tres fuentes de endogeneidad	2
3	El estimador de variables instrumentales	3
3.1	El caso simple	3
3.2	El caso general: exactamente identificado	4
4	Mínimos cuadrados en dos etapas	5
5	Propiedades asintóticas	7
6	Instrumentos débiles	9
7	★ Postgrado: optimalidad de MC2E, Hausman y sobreidentificación	10
7.1	MC2E es el mejor uso lineal de los instrumentos .	10
7.2	El test de Hausman	11
7.3	Restricciones de sobreidentificación	12
8	Resumen	12
9	Ejercicios	12

1. El supuesto que no se puede probar

Durante nueve clases hemos visto que MCO es consistente para el coeficiente de proyección lineal $\beta = \mathbb{E}[xx']^{-1}\mathbb{E}[xy]$. Eso es un hecho matemático, sin condiciones. Pero muchas veces **ese no es el β que nos interesa**. Queremos el efecto *causal* de la educación sobre el salario, el efecto de un precio sobre la cantidad demandada, el efecto de la policía sobre el crimen. Y el coeficiente de proyección no tiene por qué coincidir con esos efectos.

Formalmente, escribimos un **modelo estructural**

$$y_i = x_i'\beta + u_i,$$

donde ahora β es el parámetro causal y u_i son todos los demás determinantes de y_i . Decimos que el regresor x_{ij} es **endógeno** si $\mathbb{E}[x_{ij}u_i] \neq 0$ y **exógeno** si $\mathbb{E}[x_{ij}u_i] = 0$. Cuando algún regresor es endógeno, el β estructural y el de proyección son distintos, y MCO estima el equivocado.

Esta clase trata de cómo recuperar el β estructural con ayuda externa: una variable, el **instrumento**, que mueve a x pero no está relacionada con u .¹

2. Tres fuentes de endogeneidad

1. Variables omitidas. Si el modelo verdadero es $y = x'\beta + \gamma w + e$ con $\mathbb{E}[xe] = 0$ pero w no se observa, entonces $u = \gamma w + e$ y $\mathbb{E}[xu] = \gamma\mathbb{E}[xw] \neq 0$ si w está correlacionada con x . Es el sesgo por variable omitida de la Clase 8 (habilidad y educación).

2. Error de medida. Si $x = x^* + v$ con error clásico, vimos en la Clase 8 que $y = \beta x + (u - \beta v)$ y $\text{Cov}(x, u - \beta v) = -\beta\sigma_v^2 \neq 0$.

3. Simultaneidad. Cuando y y x se determinan juntos. El ejemplo canónico es la oferta y la demanda:

$$\text{Demanda: } q_i = \alpha_d + \beta_d p_i + u_i^d, \quad \text{Oferta: } q_i = \alpha_s + \beta_s p_i + u_i^s.$$

$$\text{El precio de equilibrio resuelve el sistema: } p_i = \frac{\alpha_s - \alpha_d + u_i^s - u_i^d}{\beta_d - \beta_s}.$$

El precio depende de los shocks de demanda, así que en la

¹ Las variables instrumentales fueron inventadas por Philip Wright en 1928, en un apéndice de un libro sobre... aranceles a los aceites vegetales. El apéndice contenía la primera solución al problema de identificar oferta y demanda. Durante décadas hubo un debate sobre si lo había escrito Philip o su hijo Sewall, el famoso genetista que inventó el análisis de senderos. Un análisis estilométrico de 2003 (Stock y Trebbi) concluyó que fue Philip. La econometría resolviendo sus propios misterios.

ecuación de demanda el regresor p está correlacionado con el error u^d . Regresar q sobre p no estima ni la oferta ni la demanda: estima una mezcla de ambas (Ejercicio 10.1).

Teorema 2.1 (Inconsistencia de MCO con endogeneidad). Si $y_i = x_i' \beta + u_i$ con (y_i, x_i) i.i.d., $Q = \mathbb{E}[x_i x_i'] > 0$ y momentos finitos, entonces

$$\hat{\beta}_{MCO} \xrightarrow{p} \beta + Q^{-1} \mathbb{E}[x_i u_i].$$

En particular, MCO es inconsistente para el β estructural si $\mathbb{E}[x_i u_i] \neq 0$.

Demostración. Es la demostración de consistencia de la Clase 7, sin usar $\mathbb{E}[x_i u_i] = 0$: $\hat{\beta} = \beta + \hat{Q}^{-1} \frac{1}{n} \sum_i x_i u_i \xrightarrow{p} \beta + Q^{-1} \mathbb{E}[x_i u_i]$ por la LGN y la función continua. $\square$

3. El estimador de variables instrumentales

3.1. El caso simple

Empecemos con un regresor endógeno y una constante: $y_i = \alpha + \beta x_i + u_i$ con $\mathbb{E}[u_i] = 0$ y $\text{Cov}(x_i, u_i) \neq 0$. Supongamos que tenemos una variable z_i que cumple:

Condiciones de un instrumento válido

- **Exogeneidad (o exclusión):** $\text{Cov}(z_i, u_i) = 0$. El instrumento no está relacionado con los determinantes no observados de y ; solo afecta a y a través de x .
- **Relevancia:** $\text{Cov}(z_i, x_i) \neq 0$. El instrumento efectivamente mueve al regresor.

Con esto, β queda determinado por los momentos poblacionales. Tomando covarianza con z_i en ambos lados del modelo,

$$\text{Cov}(z_i, y_i) = \beta \text{Cov}(z_i, x_i) + \text{Cov}(z_i, u_i) = \beta \text{Cov}(z_i, x_i),$$

y, por relevancia,

$$\beta = \frac{\text{Cov}(z_i, y_i)}{\text{Cov}(z_i, x_i)}. \quad (1)$$

Esta es una **fórmula de identificación**: escribe el parámetro causal en términos de momentos de variables observables. El principio de analogía hace el resto:

$$\hat{\beta}_{VI} = \frac{\sum_i (z_i - \bar{z})(y_i - \bar{y})}{\sum_i (z_i - \bar{z})(x_i - \bar{x})}.$$

Compara con MCO, que es $\widehat{\text{Cov}}(x, y)/\widehat{\text{Var}}(x)$: VI reemplaza “ x consigo mismo” por “ x con z ” en el denominador, y “ x con y ” por “ z con y ” en el numerador. Solo usa la variación de x que viene de z , que por exogeneidad está “limpia” de u .

Hay otra forma de escribir Ecuación 1 que da mucha intuición. Dividiendo numerador y denominador por $\text{Var}(z)$,

$$\beta = \frac{\text{Cov}(z, y)/\text{Var}(z)}{\text{Cov}(z, x)/\text{Var}(z)} = \frac{\text{efecto de } z \text{ en } y \text{ (forma reducida)}}{\text{efecto de } z \text{ en } x \text{ (primera etapa)}}.$$

Si el instrumento sube x en 2 unidades y sube y en 1 unidad, y solo afecta a y a través de x , entonces cada unidad de x sube y en $1/2$. Es una regla de tres.

Ejemplo 3.1 (El estimador de Wald). Si $z_i \in \{0, 1\}$ es binario (por ejemplo, haber sido sorteado para recibir un voucher escolar), entonces (Ejercicio 10.3)

$$\beta = \frac{\mathbb{E}[y \mid z = 1] - \mathbb{E}[y \mid z = 0]}{\mathbb{E}[x \mid z = 1] - \mathbb{E}[x \mid z = 0]}.$$

Angrist (1990) usó el sorteo de reclutamiento para Vietnam como instrumento del servicio militar: los números de sorteo bajos aumentaban la probabilidad de ir a la guerra, y el sorteo era literalmente aleatorio. El cociente entre la diferencia de ingresos y la diferencia en la probabilidad de haber servido estima el efecto del servicio militar sobre los ingresos.

3.2. El caso general: exactamente identificado

Con k regresores en x_i (algunos exógenos, que sirven como sus propios instrumentos, y algunos endógenos) y k instrumentos en z_i , las condiciones son:

🔥 Supuestos de VI (exactamente identificado)

- **VI1:** (y_i, x_i, z_i) i.i.d. y $y_i = x_i'\beta + u_i$.
- **VI2 (exogeneidad):** $\mathbb{E}[z_i u_i] = 0$.
- **VI3 (relevancia):** $Q_{zx} = \mathbb{E}[z_i x_i']$ ($k \times k$) es invertible.

De VI2, $\mathbb{E}[z_i(y_i - x_i'\beta)] = 0$, es decir, $\mathbb{E}[z_i y_i] = Q_{zx}\beta$, y por VI3,

$$\beta = Q_{zx}^{-1} \mathbb{E}[z_i y_i], \quad \hat{\beta}_{VI} = \left(\sum_i z_i x_i' \right)^{-1} \sum_i z_i y_i = (Z'X)^{-1} Z'y.$$

Con $z_i = x_i$ (todos los regresores exógenos), esto es MCO. MCO es el caso particular de VI en que cada regresor es su propio instrumento.

4. Mínimos cuadrados en dos etapas

¿Qué pasa si tenemos **más instrumentos que regresores endógenos**? Por ejemplo, para la educación podríamos usar la distancia a la universidad más cercana y el trimestre de nacimiento. Con $\ell > k$ instrumentos, $Z'X$ es $\ell \times k$ y no se puede invertir. Tenemos más ecuaciones ($\mathbb{E}[z_i u_i] = 0$ son ℓ ecuaciones) que incógnitas (k). El modelo está **sobreidentificado**.

🔥 Supuestos de MC2E

- **VI1** como antes, con $z_i \in \mathbb{R}^\ell$, $\ell \geq k$.
- **VI2:** $\mathbb{E}[z_i u_i] = 0$.
- **VI3' (condición de rango):** $Q_{zz} = \mathbb{E}[z_i z_i'] > 0$ y $Q_{zx} = \mathbb{E}[z_i x_i']$ ($\ell \times k$) tiene rango k .

La condición de rango implica la **condición de orden** $\ell \geq k$: se necesitan al menos tantos instrumentos como regresores (contando los exógenos, que son sus propios instrumentos). Equivalentemente: al menos un instrumento excluido por cada regresor endógeno.

La idea de MC2E es combinar los ℓ instrumentos en k “instrumentos óptimos”: las **proyecciones de los regresores sobre los instrumentos**.

Definición 4.1 (MC2E). Sea $P_Z = Z(Z'Z)^{-1}Z'$. El estimador de mínimos cuadrados en dos etapas es

$$\hat{\beta}_{MC2E} = (X'P_ZX)^{-1}X'P_Zy.$$

El nombre viene de la siguiente interpretación, que es un teorema:

Teorema 4.1 (MC2E son dos regresiones). Sea $\hat{X} = P_ZX$ la matriz de valores ajustados de regresar cada columna de X sobre Z (*primera etapa*). Entonces:

1. $\hat{\beta}_{MC2E} = (\hat{X}'\hat{X})^{-1}\hat{X}'y$: es MCO de y sobre $\hat{X}$ (*segunda etapa*).
2. $\hat{\beta}_{MC2E} = (\hat{X}'X)^{-1}\hat{X}'y$: es VI con instrumentos $\hat{X}$.
3. Si $\ell = k$ y $Z'X$ es invertible, $\hat{\beta}_{MC2E} = (Z'X)^{-1}Z'y = \hat{\beta}_{VI}$.

Borrador

Todo sale de que P_Z es simétrica e idempotente (Clase 1). (1): $\hat{X}'\hat{X} = X'P_Z'P_ZX = X'P_ZX$ y $\hat{X}'y = X'P_Zy$. (2): $\hat{X}'X = X'P_Z'X = X'P_ZX$. (3): con $\ell = k$, las matrices $Z'X$ y $X'Z$ son cuadradas e invertibles, así que puedo separar la inversa de un producto en producto de inversas y cancelar.

Demostración. Como P_Z es simétrica e idempotente, $\hat{X}'\hat{X} = X'P_ZP_ZX = X'P_ZX$, $\hat{X}'X = X'P_ZX$ y $\hat{X}'y = X'P_Zy$. Sustituyendo en la definición se obtienen (1) y (2).

- (3) Si $\ell = k$ y $Z'X$ es invertible (y por lo tanto también $X'Z = (Z'X)'$), usando $(ABC)^{-1} = C^{-1}B^{-1}A^{-1}$ para matrices cuadradas invertibles,

$$(X'Z(Z'Z)^{-1}Z'X)^{-1}X'Z(Z'Z)^{-1}Z'y = (Z'X)^{-1}(Z'Z)(X'Z)^{-1}X'Z(Z'Z)^{-1}Z'y = (Z'X)^{-1}Z'y.$$

□

⚠ No hagas las dos etapas a mano

Aunque (1) dice que MC2E es “regresar y sobre $\hat{X}$ ”, los **errores estándar** de esa segunda regresión hecha a mano son incorrectos: el programa calcula los residuos como $y - \hat{X}\hat{\beta}$, cuando los correctos son $y - X\hat{\beta}$ (con los regresores originales). Usa siempre el comando de VI/MC2E de tu software.

5. Propiedades asintóticas

A diferencia de MCO, **VI no es insesgado** en muestras finitas (ni siquiera tiene media finita en el caso exactamente identificado con un instrumento, bajo normalidad). Su justificación es enteramente asintótica.

Teorema 5.1 (Consistencia de MC2E). *Bajo VI1, VI2, VI3' y momentos finitos, $\hat{\beta}_{MC2E} \xrightarrow{p} \beta$.*

Demostración. Sustituyendo $y = X\beta + u$,

$$\hat{\beta}_{MC2E} = \beta + (X'P_ZX)^{-1}X'P_Zu.$$

Escribimos todo en promedios, con $\hat{Q}_{xz} = \frac{1}{n}X'Z$, $\hat{Q}_{zz} = \frac{1}{n}Z'Z$, $\hat{Q}_{zx} = \frac{1}{n}Z'X$:

$$\hat{\beta}_{MC2E} - \beta = (\hat{Q}_{xz}\hat{Q}_{zz}^{-1}\hat{Q}_{zx})^{-1}\hat{Q}_{xz}\hat{Q}_{zz}^{-1}\left(\frac{1}{n}\sum_i z_i u_i\right).$$

(Los factores n se cancelan: $X'P_ZX = n\hat{Q}_{xz}\hat{Q}_{zz}^{-1}\hat{Q}_{zx}$ y $X'P_Zu = n\hat{Q}_{xz}\hat{Q}_{zz}^{-1}\frac{1}{n}Z'u$.) Por la LGN, $\hat{Q}_{xz} \xrightarrow{p} Q_{xz}$, $\hat{Q}_{zz} \xrightarrow{p} Q_{zz}$, $\hat{Q}_{zx} \xrightarrow{p} Q_{zx}$ y $\frac{1}{n}\sum_i z_i u_i \xrightarrow{p} \mathbb{E}[z_i u_i] = 0$ por VI2.

La matriz $Q_{xz}Q_{zz}^{-1}Q_{zx}$ es invertible: es de la forma $C'AC$ con $A = Q_{zz}^{-1} > 0$ y $C = Q_{zx}$ de rango columna completo k (VI3'), así que es definida positiva (Clase 1). Por el teorema de la función continua,

$$\hat{\beta}_{MC2E} - \beta \xrightarrow{p} (Q_{xz}Q_{zz}^{-1}Q_{zx})^{-1}Q_{xz}Q_{zz}^{-1} \cdot 0 = 0.$$

□

Nota exactamente dónde entra cada supuesto: **exogeneidad** hace que el último factor tienda a cero; **relevancia** (la condición de rango) hace que la inversa del frente exista en el límite. Si el instrumento es irrelevante, estamos dividiendo por algo que tiende a cero, y todo se descontrola (sección de instrumentos débiles).

Teorema 5.2 (Distribución asintótica de MC2E). *Bajo los supuestos anteriores, con $\Omega_z = \mathbb{E}[u_i^2 z_i z_i']$ finita,*

$$\sqrt{n}(\hat{\beta}_{MC2E} - \beta) \xrightarrow{d} N(0, V), \quad V = A \Omega_z A', \quad A = (Q_{xz} Q_{zz}^{-1} Q_{zx})^{-1} Q_{xz} Q_{zz}^{-1}.$$

Bajo homocedasticidad ($\mathbb{E}[u_i^2 \mid z_i] = \sigma^2$), $\Omega_z = \sigma^2 Q_{zz}$ y $V = \sigma^2 (Q_{xz} Q_{zz}^{-1} Q_{zx})^{-1}$.

Demostración. De la demostración anterior, $\sqrt{n}(\hat{\beta}_{MC2E} - \beta) = \hat{A} \cdot \frac{1}{\sqrt{n}} \sum_i z_i u_i$ con $\hat{A} = (\hat{Q}_{xz} \hat{Q}_{zz}^{-1} \hat{Q}_{zx})^{-1} \hat{Q}_{xz} \hat{Q}_{zz}^{-1} \xrightarrow{p} A$. Los $z_i u_i$ son i.i.d. con media cero (VI2) y varianza Ω_z , así que por el TCL, $\frac{1}{\sqrt{n}} \sum_i z_i u_i \xrightarrow{d} N(0, \Omega_z)$. Por Slutsky, $\sqrt{n}(\hat{\beta} - \beta) \xrightarrow{d} N(0, A \Omega_z A')$.

Bajo homocedasticidad, por la LEI, $\Omega_z = \mathbb{E}[\mathbb{E}[u_i^2 \mid z_i] z_i z_i'] = \sigma^2 Q_{zz}$. Sea $H = Q_{xz} Q_{zz}^{-1} Q_{zx}$. Entonces

$$A \Omega_z A' = \sigma^2 H^{-1} Q_{xz} Q_{zz}^{-1} Q_{zz} Q_{zz}^{-1} Q_{zx} H^{-1} = \sigma^2 H^{-1} H H^{-1} = \sigma^2 H^{-1}.$$

□

La varianza se estima por analogía, con $\hat{u}_i = y_i - x_i' \hat{\beta}_{MC2E}$ (¡con x_i , no con $\hat{x}_i$!) y $\hat{\sigma}^2 = \frac{1}{n} \sum \hat{u}_i^2$, o con la versión robusta $\hat{\Omega}_z = \frac{1}{n} \sum \hat{u}_i^2 z_i z_i'$. En la práctica, con $\ell = k = 1$ y constante, la varianza homocedástica de la pendiente es $\sigma^2 \text{Var}(z) / \text{Cov}(z, x)^2 = \frac{\sigma^2}{\text{Var}(x) \rho_{xz}^2}$: es la varianza de MCO **dividida por la correlación al cuadrado entre instrumento y regresor**. Con $\rho_{xz} = 0,1$, la varianza es 100 veces la de MCO. **VI es caro.**

6. Instrumentos débiles

La fórmula anterior ya advierte el problema: si $\text{Cov}(z, x)$ es chica, VI es muy impreciso. Pero el problema es peor que una varianza grande: **la aproximación asintótica deja de funcionar**. Con un instrumento débil, en muestras de tamaño realista:

- MC2E está **sesgado hacia MCO**. Con muchos instrumentos débiles, el sesgo puede ser casi tan grande como el de MCO.
- La distribución de $\hat{\beta}$ está lejos de ser normal, con colas muy gordas.
- Los tests t rechazan con probabilidad mucho mayor que el nivel nominal.




Figura 1: Distribución de VI simulada con un instrumento fuerte y uno débil, junto con MCO. Con el instrumento débil, VI está desplazado hacia MCO y extremadamente disperso.

La intuición del sesgo hacia MCO: la primera etapa $\hat{X} = P_Z X$ se estima con error. Cuando el instrumento es débil, la mayor parte de la variación de $\hat{X}$ es ruido de estimación, y ese ruido es un ajuste de X que incluye la parte endógena. En el extremo en que el instrumento es completamente irrelevante, $\hat{X}$ es “puro ajuste por azar” de X , y MC2E se comporta como MCO.

Diagnóstico. Con un regresor endógeno, se reporta el estadístico F de la primera etapa (el test de que los coeficientes de los instru-

mentos excluidos son cero en la regresión de x sobre z). La regla práctica de Staiger y Stock (1997) es desconfiar si $F < 10$. Trabajos más recientes (Lee, McCrary, Moreira y Porter, 2022) muestran que, para que un test t al 5 % tenga el tamaño correcto con la regla usual de $\pm 1,96$, el umbral debería ser mucho mayor (del orden de 104), y proponen ajustar los valores críticos en función del F . Con instrumentos débiles conviene usar procedimientos robustos, como el test de Anderson–Rubin, cuyo tamaño es correcto sin importar la fuerza del instrumento.

7. ★ Postgrado: optimalidad de MC2E, Hausman y sobreidentificación

! ★ Postgrado

Mostramos que MC2E es el mejor estimador de VI bajo homocedasticidad, construimos el test de Hausman de endogeneidad y el test de Sargan de restricciones de sobreidentificación.

7.1. MC2E es el mejor uso lineal de los instrumentos

Con $\ell > k$ instrumentos, cualquier combinación lineal $W'z_i$ (con W fija de $\ell \times k$ y $W'Q_{zx}$ invertible) da un instrumento válido de dimensión k . El estimador de VI correspondiente, $\hat{\beta}_W = (W'Z'X)^{-1}W'Z'y$, es consistente y, bajo homocedasticidad, su varianza asintótica es (mismo argumento que Teorema 5.2)

$$V_W = \sigma^2(W'Q_{zx})^{-1}W'Q_{zz}W(Q_{xz}W)^{-1}.$$

Teorema 7.1 (Optimalidad de MC2E). *Bajo homocedasticidad, $V_W \geq \sigma^2(Q_{xz}Q_{zz}^{-1}Q_{zx})^{-1}$ para toda W admisible, con igualdad si $W = Q_{zz}^{-1}Q_{zx}$ (que es la W implícita en MC2E).*

Demostración. Sea $G = Q_{zz}^{1/2}W(Q_{xz}W)^{-1}$ ($\ell \times k$) y $F = Q_{zz}^{-1/2}Q_{zx}$ ($\ell \times k$). Entonces $V_W/\sigma^2 = G'G$ (usando que $(W'Q_{zx})^{-1} =$

$$((Q_{xz}W)^{-1})', F'F = Q_{xz}Q_{zz}^{-1}Q_{zx} \text{ y}$$

$$F'G = Q_{xz}Q_{zz}^{-1/2}Q_{zz}^{1/2}W(Q_{xz}W)^{-1} = I_k.$$

Sea $P_F = F(F'F)^{-1}F'$, la proyección sobre $\text{col}(F)$. Como $I - P_F$ es simétrica e idempotente,

$$0 \leq G'(I - P_F)G = G'G - G'F(F'F)^{-1}F'G = G'G - (F'F)^{-1},$$

usando $G'F = (F'G)' = I$. Luego $V_W/\sigma^2 = G'G \geq (F'F)^{-1} = (Q_{xz}Q_{zz}^{-1}Q_{zx})^{-1}$. Si $W = Q_{zz}^{-1}Q_{zx}$, entonces $G = Q_{zz}^{-1/2}Q_{zx}(F'F)^{-1} = F(F'F)^{-1} \in \text{col}(F)$ y la desigualdad es igualdad. $\square$

Es, una vez más, la estructura de Gauss–Markov: una proyección ortogonal y un término semidefinido positivo que sobra.

7.2. El test de Hausman

¿Cómo sabemos si x es endógeno? Si es exógeno, MCO y MC2E son ambos consistentes, y MCO es más eficiente (bajo homocedasticidad, MCO es el caso de MC2E con los instrumentos “óptimos” x). Si es endógeno, solo MC2E es consistente. Hausman (1978) propuso comparar ambos:

$$H = n(\hat{\beta}_{\text{MC2E}} - \hat{\beta}_{\text{MCO}})'(\hat{V}_{\text{MC2E}} - \hat{V}_{\text{MCO}})^- (\hat{\beta}_{\text{MC2E}} - \hat{\beta}_{\text{MCO}}) \xrightarrow{d} \chi_r^2$$

bajo H_0 (exogeneidad), donde $(\cdot)^-$ es una inversa generalizada y r el número de regresores endógenos sospechosos. La razón de que la varianza de la diferencia sea la **diferencia** de varianzas es un resultado general, el “lema de Hausman”: si $\hat{\theta}_e$ es asintóticamente eficiente y $\hat{\theta}_c$ es otro estimador consistente, entonces $\text{Cov}_a(\hat{\theta}_e, \hat{\theta}_c - \hat{\theta}_e) = 0$; si no lo fuera, alguna combinación de ambos le ganaría a $\hat{\theta}_e$ (Ejercicio 10.7). Así, $\text{Var}_a(\hat{\theta}_c - \hat{\theta}_e) = \text{Var}_a(\hat{\theta}_c) - \text{Var}_a(\hat{\theta}_e)$.

Una versión equivalente y más práctica (el **test de regresión aumentada** de Durbin–Wu–Hausman): estimar la primera etapa, guardar sus residuos $\hat{v}$, agregarlos como regresor en la ecuación estructural estimada por MCO, y testear (con errores robustos) si su coeficiente es cero. La lógica: $\hat{v}$ es la parte de x no explicada por los instrumentos, que es la parte potencialmente endógena.

7.3. Restricciones de sobreidentificación

Con $\ell > k$, tenemos $\ell - k$ condiciones de momentos “de sobra”, y podemos testear si son compatibles entre sí. El **test de Sargan** (homocedástico) es: regresar los residuos de MC2E $\hat{u}$ sobre todos los instrumentos Z y calcular

$$S = nR^2 \xrightarrow{d} \chi^2_{\ell-k}$$

bajo $H_0 : \mathbb{E}[z_i u_i] = 0$. (La versión robusta es el test J de Hansen, que veremos en Econometría 2 con el método generalizado de momentos.) **Advertencia importante:** el test solo tiene poder si algunos instrumentos son válidos y otros no, y *supone* que al menos k son válidos. Si todos los instrumentos son inválidos de la misma manera, el test no lo detecta. No reemplaza al argumento económico sobre la exogeneidad, que es, al final del día, lo que hace creíble a un instrumento.²

8. Resumen

- Si $\mathbb{E}[x_i u_i] \neq 0$, MCO converge a $\beta + Q^{-1} \mathbb{E}[x_i u_i]$ (Teorema 2.1). Fuentes: omitidas, error de medida, simultaneidad.
- Un instrumento debe ser exógeno ($\mathbb{E}[z u] = 0$) y relevante (rango $\mathbb{E}[z z'] = k$).
- Caso simple: $\beta = \text{Cov}(z, y) / \text{Cov}(z, x)$ = forma reducida / primera etapa.
- MC2E = $(X' P_Z X)^{-1} X' P_Z y$: MCO de y sobre $\hat{X} = P_Z X$ (Teorema 4.1).
- MC2E es consistente y asintóticamente normal (Teorema 5.1, Teorema 5.2), pero no insesgado; con instrumentos débiles, la aproximación asintótica falla.

9. Ejercicios

Ejercicio 10.1. En el modelo de oferta y demanda de esta clase, con u^d y u^s no correlacionados de varianzas σ_d^2 y σ_s^2 , demuestra

² Esta es la lección más importante de la clase y quizás del curso. La exogeneidad de un instrumento **no se puede testear** con los datos (con $\ell = k$ es literalmente imposible: el estimador fuerza $\frac{1}{n} \sum z_i \hat{u}_i = 0$). Se defiende con conocimiento del problema: por qué el sorteo es aleatorio, por qué la distancia a la universidad no afecta el salario por otras vías, por qué la lluvia afecta la oferta de café pero no su demanda. La econometría te da la matemática; la credibilidad la pones tú.

que la pendiente de MCO de q sobre p converge a

$$\frac{\beta_d \sigma_s^2 + \beta_s \sigma_d^2}{\sigma_s^2 + \sigma_d^2}.$$

Interpreta los casos $\sigma_d^2 = 0$ y $\sigma_s^2 = 0$.

💡 Solución 10.1

Sea $\Delta = \beta_d - \beta_s$. Entonces $p = (\text{cte} + u^s - u^d)/\Delta$ y $\text{Var}(p) = (\sigma_s^2 + \sigma_d^2)/\Delta^2$. Usando la ecuación de demanda, $\text{Cov}(p, q) = \beta_d \text{Var}(p) + \text{Cov}(p, u^d) = \beta_d \text{Var}(p) - \sigma_d^2/\Delta$. Luego el límite es $\beta_d - \frac{\sigma_d^2/\Delta}{(\sigma_s^2 + \sigma_d^2)/\Delta^2} = \beta_d - \frac{\sigma_d^2(\beta_d - \beta_s)}{\sigma_s^2 + \sigma_d^2} = \frac{\beta_d \sigma_s^2 + \beta_s \sigma_d^2}{\sigma_s^2 + \sigma_d^2}$.

Si $\sigma_d^2 = 0$ (solo se mueve la oferta), los equilibrios trazan la curva de demanda y MCO estima β_d . Si $\sigma_s^2 = 0$, estima la oferta. En general, un promedio ponderado. Por eso un instrumento para la demanda es un “desplazador de la oferta” (lluvia, costos): mueve la oferta a lo largo de una demanda fija.

Ejercicio 10.2. Demuestra que en el caso simple con constante, $\hat{\beta}_{\text{VI}} \xrightarrow{p} \beta + \frac{\text{Cov}(z, u)}{\text{Cov}(z, x)}$ si se relaja la exogeneidad. Compara con el sesgo de MCO, $\text{Cov}(x, u)/\text{Var}(x)$, y argumenta por qué un instrumento “casi exógeno” pero débil puede ser peor que MCO.

💡 Solución 10.2

Por la LGN, $\hat{\beta}_{\text{VI}} \xrightarrow{p} \text{Cov}(z, y)/\text{Cov}(z, x) = \beta + \text{Cov}(z, u)/\text{Cov}(z, x)$. Escribiendo en correlaciones: sesgo de VI = $\frac{\rho_{zu}}{\rho_{zx}} \frac{\sigma_u}{\sigma_x}$ y sesgo de MCO = $\rho_{xu} \frac{\sigma_u}{\sigma_x}$. VI tiene menor sesgo asintótico solo si $|\rho_{zu}/\rho_{zx}| < |\rho_{xu}|$. Con ρ_{zx} chico (instrumento débil), una violación minúscula de la exogeneidad se amplifica enormemente. Por ejemplo, con $\rho_{zu} = 0,02$, $\rho_{zx} = 0,05$ y $\rho_{xu} = 0,3$: VI tiene sesgo proporcional a 0,4 y MCO a 0,3.

Ejercicio 10.3. Demuestra la fórmula del estimador de Wald (Ejemplo 3.1) a partir de Ecuación 1.

💡 Solución 10.3

Con z binaria y $p = P(z = 1)$: $\text{Cov}(z, y) = E[zy] - E[z]E[y] = p E[y | z = 1] - p(p E[y | z = 1] + (1 - p) E[y | z = 0]) = p(1 - p)(E[y | z = 1] - E[y | z = 0])$. Lo mismo con x . El factor $p(1 - p)$ se cancela en el cociente.

Ejercicio 10.4. En $y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + u$, con x_1 exógeno, x_2 endógeno, y dos instrumentos excluidos z_1, z_2 : ¿cuál es la matriz Z ? ¿Cuántas restricciones de sobreidentificación hay? Escribe la primera etapa.

💡 Solución 10.4

$Z = [\iota \ x_1 \ z_1 \ z_2]$ ($\ell = 4$), $X = [\iota \ x_1 \ x_2]$ ($k = 3$). Hay $\ell - k = 1$ restricción de sobreidentificación. La primera etapa relevante es $x_2 = \pi_0 + \pi_1 x_1 + \pi_2 z_1 + \pi_3 z_2 + v$: los exógenos incluidos **siempre** van en la primera etapa. (Las columnas ι y x_1 de X se “proyectan” sobre sí mismas.) La relevancia exige $(\pi_2, \pi_3) \neq (0, 0)$.

Ejercicio 10.5. Muestra que si en la primera etapa se omite el regresor exógeno x_1 (es decir, se regresa x_2 solo sobre $(1, z_1, z_2)$) y luego se hace la segunda etapa de y sobre $(1, x_1, \hat{x}_2)$, el estimador resultante es en general inconsistente. (Es el error de la “regresión prohibida” en su versión más simple.)

💡 Solución 10.5

Sea $\hat{x}_2$ la proyección sobre $(1, z_1, z_2)$ y $x_2 = \hat{x}_2 + \hat{v}$. La ecuación es $y = \beta_0 + \beta_1 x_1 + \beta_2 \hat{x}_2 + (\beta_2 \hat{v} + u)$. Para consistencia, el nuevo error debe ser ortogonal a x_1 . Pero $\hat{v}$ es ortogonal a $(1, z_1, z_2)$, **no** a x_1 : si x_1 y x_2 están correlacionados después de controlar por los z , entonces $E[x_1 \hat{v}] \neq 0$ y el estimador es inconsistente. Con x_1 en la primera etapa, $\hat{v}$ es ortogonal a x_1 por construcción.

Ejercicio 10.6 ★. Supón que el instrumento es **irrelevante**: $\text{Cov}(z, x) = 0$. Con $y = \beta x + u$, $x = \pi z + v$ con $\pi = 0$, y (z_i, u_i, v_i) normales con z independiente de (u, v) , $\text{Var}(z) = \text{Var}(u) = \text{Var}(v) = 1$ y $\text{Corr}(u, v) = \rho$, muestra que

$\hat{\beta}_{VI} - \beta$ converge en distribución a un cociente de normales, centrado en ρ (el sesgo de MCO).

💡 Solución 10.6 ★

$$\hat{\beta}_{VI} - \beta = \frac{n^{-1/2} \sum z_i u_i}{n^{-1/2} \sum z_i x_i} = \frac{n^{-1/2} \sum z_i u_i}{n^{-1/2} \sum z_i v_i} \text{ (sin constante, por simplicidad).}$$
 Por el TCL, $(n^{-1/2} \sum z_i u_i, n^{-1/2} \sum z_i v_i) \xrightarrow{d} (\xi_u, \xi_v)$ normal bivariada con varianzas 1 y correlación ρ . Por la función continua (el cociente es continuo salvo en un conjunto de probabilidad cero), $\hat{\beta}_{VI} - \beta \xrightarrow{d} \xi_u / \xi_v$. Escribiendo $\xi_u = \rho \xi_v + \sqrt{1 - \rho^2} \eta$ con η independiente, $\xi_u / \xi_v = \rho + \sqrt{1 - \rho^2} \eta / \xi_v$: el sesgo de MCO más una **Cauchy** escalada. No converge a β , está centrado (en mediana) en el sesgo de MCO, y no tiene media. Es el villano de la Clase 6.

Ejercicio 10.7 ★. (Lema de Hausman.) Sean $\hat{\theta}_e$ y $\hat{\theta}_c$ dos estimadores escalares con $\sqrt{n}(\hat{\theta}_e - \theta, \hat{\theta}_c - \theta)$ asintóticamente normal, y $\hat{\theta}_e$ con la menor varianza asintótica entre todas las combinaciones $\hat{\theta}_\lambda = \hat{\theta}_e + \lambda(\hat{\theta}_c - \hat{\theta}_e)$. Demuestra que $\text{Cov}_a(\hat{\theta}_e, \hat{\theta}_c - \hat{\theta}_e) = 0$.

💡 Solución 10.7 ★

Sea $d = \hat{\theta}_c - \hat{\theta}_e$. $\text{Var}_a(\hat{\theta}_\lambda) = \text{Var}_a(\hat{\theta}_e) + 2\lambda \text{Cov}_a(\hat{\theta}_e, d) + \lambda^2 \text{Var}_a(d)$. Es una parábola en λ con mínimo en $\lambda = 0$ (por eficiencia de $\hat{\theta}_e$), así que su derivada en 0, $2 \text{Cov}_a(\hat{\theta}_e, d)$, debe ser cero. (Si fuera positiva, un λ negativo pequeño reduciría la varianza; si fuera negativa, uno positivo.) Todos los $\hat{\theta}_\lambda$ son consistentes, así que compiten legítimamente con $\hat{\theta}_e$.