

Clase 1 · Estimación por extremos

Consistencia y normalidad asintótica de los
M-estimadores

Contenido

1	Una sola demostración para casi todo	1
2	Ejemplos: ya conoces a la familia	2
3	Consistencia	3
4	Normalidad asintótica	4
5	Estimación de la varianza y tests	7
6	Cuando la información importa: un adelanto	8
7	★ Postgrado: demostración del lema de LGN uniforme	8
8	Resumen	10
9	Ejercicios	10

1. Una sola demostración para casi todo

En Econometría 1 demostramos que MCO es consistente y asintóticamente normal. Después vino la pregunta incómoda: ¿tengo que repetir toda la demostración para cada estimador nuevo? Para probit, para mínimos cuadrados no lineales, para la mediana,

para GMM... La respuesta es que **no**. Casi todos los estimadores de la econometría son, en el fondo, el mismo objeto:

$$\hat{\theta} = \arg \max_{\theta \in \Theta} \hat{Q}_n(\theta), \quad \hat{Q}_n(\theta) = \frac{1}{n} \sum_{i=1}^n m(w_i, \theta). \quad (1)$$

Aquí w_i son los datos de la observación i (por ejemplo (y_i, x_i)), $\theta \in \Theta \subset \mathbb{R}^p$ es el parámetro, y m es una función **criterio** que el economista elige. Hacemos la teoría una vez, para un m cualquiera, y después cada estimador es un caso particular: basta calcular dos matrices.¹

Notación y supuesto de muestreo

En todo el curso, $\{w_i\}_{i=1}^n$ son i.i.d. salvo que se diga lo contrario (los paneles de la Clase 9 y las series de tiempo de Econometría 3 relajan esto). Escribimos ∇ para el gradiente en θ ($p \times 1$) y ∇^2 para el hessiano ($p \times p$). Maximizamos; para minimizar, cambia el signo de m . Usaremos sin demostrar lo de Econometría 1: LGN, TCL, Slutsky y método delta (Clase 6).

¹ La idea es de Peter Huber (1964, 1967), que estudiaba estimadores robustos y quería una teoría que cubriera la mediana, la media y todo lo que hubiera entre ambas. La “M” es de *maximum-likelihood-type*. Los economistas los llaman también *estimadores por extremos* (Amemiya, 1985), que suena más serio y menos a nombre de producto de limpieza.

2. Ejemplos: ya conoces a la familia

Ejemplo 2.1 (Algunos M-estimadores).

1. **Media:** $m(w, \theta) = -(w - \theta)^2$. El máximo de $\hat{Q}_n$ es $\bar{w}$.
2. **MCO:** $m(w, \theta) = -\frac{1}{2}(y - x'\theta)^2$, con $w = (y, x)$.
3. **Mínimos cuadrados no lineales:** $m(w, \theta) = -\frac{1}{2}(y - g(x, \theta))^2$.
4. **Máxima verosimilitud:** $m(w, \theta) = \log f(w; \theta)$ (Clase 2).
5. **Mediana:** $m(w, \theta) = -|w - \theta|$. ¡Ojo! Esta no es derivable: es la Clase 12.
6. **GMM:** el criterio es $-\frac{1}{2}\bar{g}(\theta)'W\bar{g}(\theta)$ con $\bar{g} = \frac{1}{n}\sum g(w_i, \theta)$. No es un promedio, pero la teoría de esta clase se adapta (Clase 4).

3. Consistencia

La idea es la misma de toda la teoría asintótica: la muestra imita a la población. Si $\hat{Q}_n(\theta)$ se parece (para todo θ a la vez) a su **análogo poblacional** $Q_0(\theta) = \mathbb{E}[m(w, \theta)]$, entonces los maximizadores también deberían parecerse. Para esto necesitamos dos cosas: que la convergencia sea **uniforme** y que Q_0 tenga un único máximo.

Supuestos de consistencia (C)

- **C1 (compacidad):** Θ es compacto.
- **C2 (continuidad y dominancia):** $m(w, \cdot)$ es continua en Θ con probabilidad uno, y $\mathbb{E}[\sup_{\theta \in \Theta} |m(w, \theta)|] < \infty$.
- **C3 (identificación):** existe un único $\theta_0 \in \Theta$ que maximiza $Q_0(\theta) = \mathbb{E}[m(w, \theta)]$.

C3 es el supuesto con contenido económico: dice que los **datos distinguen** al parámetro verdadero de cualquier otro. Si falla, ningún tamaño de muestra te salva (Ejercicio 1.4). C1 y C2 son técnicos: C1 se puede relajar (si $\hat{Q}_n$ es cóncava, por ejemplo) y C2 se verifica casi siempre sin esfuerzo.

Lema 3.1 (Ley de los grandes números uniforme). *Bajo C1, C2 y muestreo i.i.d., Q_0 es continua y $\sup_{\theta \in \Theta} |\hat{Q}_n(\theta) - Q_0(\theta)| \xrightarrow{p} 0$.*

La LGN de Econometría 1 dice que, **para cada θ fijo**, $\hat{Q}_n(\theta) \rightarrow Q_0(\theta)$. Pero $\hat{\theta}$ es un punto *aleatorio* que se mueve con la muestra, así que necesitamos la convergencia simultánea en todo Θ . Demostramos el lema en la sección ★; por ahora lo usamos.

Teorema 3.1 (Consistencia de M-estimadores). *Bajo C1–C3 y muestreo i.i.d., $\hat{\theta} \xrightarrow{p} \theta_0$.*

Borrador

Quiero mostrar que, para cualquier vecindad N de θ_0 , $\hat{\theta} \in N$ con probabilidad que tiende a uno. Fuera de N , el máximo de

Q_0 está *estrictamente* por debajo de $Q_0(\theta_0)$: es aquí donde entran la identificación (único máximo) y la compacidad (el sup se alcanza en algún punto). Digamos que la brecha es $\varepsilon > 0$. Cuando $\hat{Q}_n$ está a menos de $\varepsilon/2$ de Q_0 en todas partes, ningún punto fuera de N puede ganarle a θ_0 en $\hat{Q}_n$, así que el maximizador de $\hat{Q}_n$ tiene que estar dentro de N . Y el lema dice que “estar a menos de $\varepsilon/2$ en todas partes” ocurre con probabilidad que tiende a uno.

Demostración. Sea N una vecindad abierta de θ_0 . El conjunto $\Theta \setminus N$ es compacto (cerrado dentro de un compacto) y Q_0 es continua (Lema 3.1), así que si $\Theta \setminus N$ no es vacío alcanza su máximo en algún $\theta^* \in \Theta \setminus N$. Como $\theta^* \neq \theta_0$, C3 implica $Q_0(\theta^*) < Q_0(\theta_0)$. Sea $\varepsilon = Q_0(\theta_0) - Q_0(\theta^*) > 0$.

Definamos el evento $E_n = \{\sup_{\Theta} |\hat{Q}_n - Q_0| < \varepsilon/2\}$. Por Lema 3.1, $P(E_n) \rightarrow 1$. En E_n , para todo $\theta \in \Theta \setminus N$:

$$\hat{Q}_n(\theta) < Q_0(\theta) + \frac{\varepsilon}{2} \leq Q_0(\theta^*) + \frac{\varepsilon}{2} = Q_0(\theta_0) - \frac{\varepsilon}{2} < \hat{Q}_n(\theta_0).$$

Luego ningún $\theta \notin N$ puede maximizar $\hat{Q}_n$ (pues θ_0 lo supera), es decir, $\hat{\theta} \in N$ en E_n . Entonces $P(\hat{\theta} \in N) \geq P(E_n) \rightarrow 1$. Como N era una vecindad arbitraria, $\hat{\theta} \xrightarrow{p} \theta_0$. $\square$

Esta demostración funciona igual si $\hat{\theta}$ no maximiza exactamente $\hat{Q}_n$ sino que cumple $\hat{Q}_n(\hat{\theta}) \geq \sup_{\Theta} \hat{Q}_n - o_p(1)$. Es importante en la práctica: los optimizadores numéricos paran en una tolerancia, no en el máximo exacto.

4. Normalidad asintótica

Con $\hat{\theta} \rightarrow_p \theta_0$ en mano, miramos más de cerca. Si θ_0 es interior a Θ , entonces (con probabilidad que tiende a uno) $\hat{\theta}$ también lo es, y satisface la **condición de primer orden** $\nabla \hat{Q}_n(\hat{\theta}) = 0$. La idea: linealizar esa condición alrededor de θ_0 , como hicimos con el método delta.

🔥 Supuestos de normalidad asintótica (N)

- **N1:** $\hat{\theta} \xrightarrow{p} \theta_0$ y θ_0 es un punto interior de Θ .
- **N2:** $m(w, \cdot)$ es dos veces continuamente diferenciable en una vecindad $\mathcal{N}$ de θ_0 .
- **N3:** $\mathbb{E} \|\nabla m(w, \theta_0)\|^2 < \infty$, y definimos $B = \mathbb{E} [\nabla m(w, \theta_0) \nabla m(w, \theta_0)']$.
- **N4:** $\mathbb{E} [\sup_{\theta \in \mathcal{N}} \|\nabla^2 m(w, \theta)\|] < \infty$, y $A = \mathbb{E} [\nabla^2 m(w, \theta_0)]$ es **invertible**.

La matriz A (el hessiano esperado) mide **cuánta curvatura** tiene el criterio en el máximo; B (la varianza del gradiente, o *score*) mide **cuánto ruido** hay en la condición de primer orden. Ya adivinas el resultado: la varianza es “ruido sobre curvatura al cuadrado”.

Teorema 4.1 (Normalidad asintótica de M-estimadores). *Bajo C1–C3 y N1–N4,*

$$\sqrt{n}(\hat{\theta} - \theta_0) \xrightarrow{d} N(0, A^{-1}BA^{-1}).$$

i Borrador

Escribo la condición de primer orden $0 = \nabla \hat{Q}_n(\hat{\theta})$ y expando alrededor de θ_0 con el teorema del valor medio: $0 = \nabla \hat{Q}_n(\theta_0) + \nabla^2 \hat{Q}_n(\bar{\theta})(\hat{\theta} - \theta_0)$. Despejo: $\sqrt{n}(\hat{\theta} - \theta_0) = -[\nabla^2 \hat{Q}_n(\bar{\theta})]^{-1} \sqrt{n} \nabla \hat{Q}_n(\theta_0)$. Dos piezas. El gradiente en θ_0 es un promedio i.i.d.; si tiene media cero, el TCL le da una normal. El hessiano está evaluado en un punto intermedio $\bar{\theta}$ entre $\hat{\theta}$ y θ_0 , que por consistencia converge a θ_0 ; si el hessiano es “continuo en promedio”, converge a A . Slutsky pega las dos piezas. Falta una cosa: que el gradiente tenga media cero. Eso es la condición de primer orden *poblacional*.

Primero, ese paso pendiente.

Lema 4.1 (El score tiene media cero). *Bajo N1–N4 y C3,* $\mathbb{E}[\nabla m(w, \theta_0)] = 0$.

Demostración. θ_0 maximiza $Q_0(\theta) = \mathbb{E}[m(w, \theta)]$ y es interior, así que $\nabla Q_0(\theta_0) = 0$ siempre que Q_0 sea derivable. Por N4, $\|\nabla m(w, \theta)\|$ está dominado en $\mathcal{N}$ (integrando el hessiano a lo largo de un segmento y usando N3), así que se puede derivar dentro de la esperanza (teorema de convergencia dominada): $\nabla Q_0(\theta_0) = \mathbb{E}[\nabla m(w, \theta_0)]$. Por lo tanto la esperanza del score es cero. $\square$

Demostración. (del Teorema 4.1). Por N1, la probabilidad de que $\hat{\theta}$ esté en el interior de $\mathcal{N}$ tiende a uno, y en ese evento $\nabla \hat{Q}_n(\hat{\theta}) = 0$. Aplicando el teorema del valor medio a cada componente del gradiente, existen puntos $\bar{\theta}_j$ en el segmento entre $\hat{\theta}$ y θ_0 tales que

$$0 = \nabla \hat{Q}_n(\theta_0) + \tilde{H}_n(\hat{\theta} - \theta_0),$$

donde $\tilde{H}_n$ es la matriz cuya fila j es la fila j de $\nabla^2 \hat{Q}_n(\bar{\theta}_j)$.

Paso 1: $\tilde{H}_n \xrightarrow{p} A$. Cada $\bar{\theta}_j \xrightarrow{p} \theta_0$ porque está entre $\hat{\theta}$ y θ_0 . Por N2 y N4, el lema de ley de los grandes números uniforme (Lema 3.1 aplicado a las entradas de $\nabla^2 m$ en una vecindad compacta de θ_0) da $\sup_{\theta \in \mathcal{N}'} \|\nabla^2 \hat{Q}_n(\theta) - \mathbb{E}[\nabla^2 m(w, \theta)]\| \xrightarrow{p} 0$ y la función $\theta \mapsto \mathbb{E}[\nabla^2 m(w, \theta)]$ es continua en θ_0 . Entonces $\nabla^2 \hat{Q}_n(\bar{\theta}_j) \xrightarrow{p} A$ (distancia a $\mathbb{E}[\nabla^2 m(\bar{\theta}_j)]$ chica por la uniformidad; esta a su vez cercana a A por continuidad), y lo mismo ocurre con la matriz $\tilde{H}_n$.

Paso 2: $\sqrt{n} \nabla \hat{Q}_n(\theta_0) \xrightarrow{d} N(0, B)$. Tenemos $\sqrt{n} \nabla \hat{Q}_n(\theta_0) = \sqrt{n} \cdot \frac{1}{n} \sum_i \nabla m(w_i, \theta_0)$. Los sumandos son i.i.d., con media cero (Lema 4.1) y varianza B finita (N3). Aplica el TCL multivariado.

Paso 3. Como A es invertible y $\tilde{H}_n \rightarrow_p A$, $\tilde{H}_n$ es invertible con probabilidad que tiende a uno y $\tilde{H}_n^{-1} \rightarrow_p A^{-1}$ (función continua). Despejando,

$$\sqrt{n}(\hat{\theta} - \theta_0) = -\tilde{H}_n^{-1} \sqrt{n} \nabla \hat{Q}_n(\theta_0) \xrightarrow{d} -A^{-1} N(0, B) = N(0, A^{-1} B A^{-1'}),$$

por Slutsky y el teorema de transformaciones lineales. Como A es simétrica, $A^{-1'} = A^{-1}$. $\square$

Dos observaciones sobre el resultado. Primero, $A^{-1} B A^{-1}$ se llama **varianza sándwich**: B es el “relleno” entre dos “panes” A^{-1} .

Segundo, es la misma estructura de la Clase 7 de Econometría 1, como veremos ahora.

⚠ ¿Es A negativa definida?

Como θ_0 es un *máximo* de Q_0 , A es semidefinida negativa; con A invertible, es definida negativa. El signo no importa en la varianza ($A^{-1}BA^{-1}$ es invariante a $A \rightarrow -A$), pero sí importa en la práctica: si tu hessiano numérico en $\hat{\theta}$ **no** es definido negativo, el optimizador no encontró un máximo y la matriz de varianzas que reportas no tiene sentido.

5. Estimación de la varianza y tests

Para hacer inferencia estimamos A y B con sus análogos muestrales evaluados en $\hat{\theta}$:

$$\hat{A} = \frac{1}{n} \sum_{i=1}^n \nabla^2 m(w_i, \hat{\theta}), \quad \hat{B} = \frac{1}{n} \sum_{i=1}^n \nabla m(w_i, \hat{\theta}) \nabla m(w_i, \hat{\theta})', \quad \widehat{\text{Avar}}(\hat{\theta}) = \frac{1}{n} \hat{A}^{-1} \hat{B} \hat{A}^{-1}.$$

La consistencia de $\hat{A}$ y $\hat{B}$ se demuestra igual que la de $\hat{Q}$ y $\hat{\Omega}$ en la Clase 7 de Econometría 1: LGN uniforme más el hecho de que $\hat{\theta} \rightarrow_p \theta_0$. Con ella, todo lo de inferencia sigue sin cambios: el error estándar de $\hat{\theta}_j$ es la raíz del elemento (j, j) de $\widehat{\text{Avar}}$, y para $H_0 : h(\theta_0) = 0$, con h de dimensión q y jacobiano $H(\theta) = \partial h / \partial \theta'$ de rango q , el **test de Wald**

$$W = n h(\hat{\theta})' [H(\hat{\theta}) \hat{A}^{-1} \hat{B} \hat{A}^{-1} H(\hat{\theta})']^{-1} h(\hat{\theta}) \xrightarrow{d} \chi_q^2$$

(método delta de la Clase 6 de Econometría 1, más el lema de la χ^2 con la inversa de la varianza de la Clase 5).

Ejemplo 5.1 (MCO es un caso particular). Con $m(w, \theta) = -\frac{1}{2}(y - x'\theta)^2$ tenemos $\nabla m = x(y - x'\theta)$ y $\nabla^2 m = -xx'$. En $\theta_0 = \beta$, el coeficiente de proyección lineal, $\nabla m = xu$. Entonces

$$A = -\mathbb{E}[xx'], \quad B = \mathbb{E}[u^2 xx'], \quad A^{-1}BA^{-1} = \mathbb{E}[xx']^{-1} \mathbb{E}[u^2 xx'] \mathbb{E}[xx']^{-1}.$$

Es exactamente la varianza sándwich de la Clase 7 de Econometría 1, y $\hat{A}^{-1} \hat{B} \hat{A}^{-1}$ es la fórmula de White. Todo lo que demostramos allí a mano era un caso del Teorema 4.1.

Ejemplo 5.2 (Mínimos cuadrados no lineales). Con $m = -\frac{1}{2}(y - g(x, \theta))^2$ y $u = y - g(x, \theta_0)$:

$$\nabla m = u \nabla g, \quad \nabla^2 m = -\nabla g \nabla g' + u \nabla^2 g.$$

Si el modelo está bien especificado en la media, $\mathbb{E}[u \mid x] = 0$, entonces $\mathbb{E}[u \nabla^2 g] = 0$ y $A = -\mathbb{E}[\nabla g \nabla g']$, $B = \mathbb{E}[u^2 \nabla g \nabla g']$. Es el mismo sándwich de MCO con el regresor x reemplazado por el **gradiente** $\nabla g(x, \theta_0)$: MCNL es “MCO sobre el modelo linealizado”.

6. Cuando la información importa: un adelanto

En los dos ejemplos de arriba, A y B eran matrices distintas y el sándwich no se simplificaba. Pero hay un caso, central en la econometría, donde $B = -A$ y el sándwich colapsa a $-A^{-1} = B^{-1}$: la **máxima verosimilitud bien especificada**. La Clase 2 demuestra esa igualdad (la *igualdad de la información*) y usa B^{-1} como cota para la varianza de cualquier estimador.

Por ahora quédate con esto: **el sándwich es el default honesto**, que vale aunque el criterio m sea un modelo equivocado de los datos. Colapsar el sándwich es una ganancia que se *paga* con el supuesto de que el modelo está bien especificado.

7. ★ Postgrado: demostración del lema de LGN uniforme

! ★ Postgrado

Demostramos Lema 3.1. Es un argumento de recubrimiento finito: la compacidad convierte un problema “para todo θ ” en un problema con finitos puntos.

i Borrador

Para cada $\theta \in \Theta$ miro una bolita de radio δ y mido la mayor oscilación de $m(w, \cdot)$ dentro de ella: $\Delta(w, \theta, \delta)$. Por continuidad, la oscilación se achica a cero cuando $\delta \rightarrow 0$, y como está dominada por $2 \sup |m|$ (integrable), también su esperanza va a cero. Elijo δ_θ para que la esperanza de la oscilación sea menor que ε . Las bolitas cubren Θ y, por compacidad, bastan finitas. Dentro de cada bolita, $\hat{Q}_n$ y Q_0 se mueven poco; en el centro, la LGN ordinaria las acerca. Tres cotas y un finito, y listo.

Demostración. Para $\theta \in \Theta$ y $\delta > 0$ sea

$$\Delta(w, \theta, \delta) = \sup_{\theta' \in \Theta: \|\theta' - \theta\| < \delta} |m(w, \theta') - m(w, \theta)|.$$

Por C2, $\Delta(w, \theta, \delta) \rightarrow 0$ cuando $\delta \rightarrow 0$ con probabilidad uno (continuidad en θ), y $\Delta \leq 2 \sup_\Theta |m(w, \cdot)|$, que es integrable. Por convergencia dominada, $\mathbb{E}[\Delta(w, \theta, \delta)] \rightarrow 0$ cuando $\delta \rightarrow 0$.

Q_0 es continua. $|Q_0(\theta') - Q_0(\theta)| \leq \mathbb{E} \Delta(w, \theta, \delta) \rightarrow 0$ si $\|\theta' - \theta\| < \delta \rightarrow 0$.

Convergencia uniforme. Fija $\varepsilon > 0$. Para cada $\theta \in \Theta$ elige $\delta_\theta > 0$ con $\mathbb{E} \Delta(w, \theta, \delta_\theta) < \varepsilon$. Las bolas abiertas $B(\theta, \delta_\theta)$ cubren Θ , que es compacto: existen $\theta_1, \dots, \theta_J$ con $\Theta \subset \bigcup_j B(\theta_j, \delta_j)$. Si $\theta \in B(\theta_j, \delta_j)$,

$$|\hat{Q}_n(\theta) - Q_0(\theta)| \leq \underbrace{|\hat{Q}_n(\theta) - \hat{Q}_n(\theta_j)|}_{\leq \frac{1}{n} \sum_i \Delta(w_i, \theta_j, \delta_j)} + \underbrace{|\hat{Q}_n(\theta_j) - Q_0(\theta_j)| + |Q_0(\theta_j) - Q_0(\theta)|}_{\leq \mathbb{E} \Delta(w, \theta_j, \delta_j) < \varepsilon}.$$

Entonces

$$\sup_{\theta \in \Theta} |\hat{Q}_n(\theta) - Q_0(\theta)| \leq \max_{1 \leq j \leq J} \left\{ \frac{1}{n} \sum_i \Delta(w_i, \theta_j, \delta_j) + |\hat{Q}_n(\theta_j) - Q_0(\theta_j)| \right\} + \varepsilon.$$

Como J es finito, la LGN ordinaria (aplicada a las $2J$ cantidades) da que el máximo converge en probabilidad a $\max_j \{\mathbb{E} \Delta(w, \theta_j, \delta_j)\} < \varepsilon$ (el segundo sumando converge a 0). Luego $P(\sup |\hat{Q}_n - Q_0| > 3\varepsilon) \rightarrow 0$ para todo $\varepsilon > 0$, que es la convergencia uniforme en probabilidad. $\square$

8. Resumen

- Un **M-estimador** maximiza $\hat{Q}_n(\theta) = \frac{1}{n} \sum m(w_i, \theta)$. MCO, MCNL, MV, la mediana y GMM son casos particulares.
- **Consistencia** (Teorema 3.1): compacidad + continuidad con dominancia + **identificación** (único máximo de Q_0). La herramienta es la LGN uniforme (Lema 3.1).
- **Normalidad** (Teorema 4.1): $\sqrt{n}(\hat{\theta} - \theta_0) \rightarrow N(0, A^{-1}BA^{-1})$ con $A = \mathbb{E}[\nabla^2 m]$ (“curvatura”) y $B = \mathbb{E}[\nabla m \nabla m']$ (“ruido del score”).
- Para cada estimador nuevo el trabajo se reduce a calcular A y B y verificar los supuestos.
- Si el modelo es verosímil y está bien especificado, $B = -A$ y el sándwich colapsa (Clase 2).

9. Ejercicios

Ejercicio 1.1. Muestra que la media muestral es un M-estimador con $m(w, \theta) = -(w - \theta)^2$, calcula A y B y verifica que la varianza asintótica es $\text{Var}(w)$.

Solución 1.1

$\nabla m = 2(w - \theta)$ y $\nabla^2 m = -2$. En $\theta_0 = \mathbb{E}[w]$: $A = -2$ y $B = \mathbb{E}[4(w - \theta_0)^2] = 4 \text{Var}(w)$. Entonces $A^{-1}BA^{-1} = \frac{1}{4} \cdot 4 \text{Var}(w) = \text{Var}(w)$. Es el TCL de siempre. Nota que m no es una verosimilitud (para eso habría que suponer una distribución) y aun así obtuvimos la varianza correcta sin suponer normalidad.

Ejercicio 1.2. Sea w exponencial con densidad $f(w; \theta) = \theta e^{-\theta w}$, $w > 0$. Toma $m(w, \theta) = \log \theta - \theta w$. Calcula el estimador, A , B y la varianza asintótica. Comprueba el resultado con el método delta aplicado a $\hat{\theta} = 1/\bar{w}$.

 Solución 1.2

$\hat{Q}_n = \log \theta - \theta \bar{w}$ se maximiza en $\hat{\theta} = 1/\bar{w}$. $\nabla m = 1/\theta - w$, $\nabla^2 m = -1/\theta^2$. En θ_0 , $\mathbb{E}[w] = 1/\theta_0$ y $\text{Var}(w) = 1/\theta_0^2$. Luego $A = -1/\theta_0^2$ y $B = \text{Var}(w) = 1/\theta_0^2 = -A$ (¡igualdad de la información!). La varianza asintótica es $A^{-1}BA^{-1} = \theta_0^4 \cdot \theta_0^{-2} = \theta_0^2$. Método delta: $\sqrt{n}(\bar{w} - 1/\theta_0) \rightarrow N(0, 1/\theta_0^2)$ y $g(x) = 1/x$ tiene $g'(1/\theta_0) = -\theta_0^2$, así que la varianza es $\theta_0^4 \cdot \theta_0^{-2} = \theta_0^2$. Coinciden.

Ejercicio 1.3. (Especificación incorrecta.) Los datos son i.i.d. con $\mathbb{E}[w] = \mu_0$ y $\text{Var}(w) = \sigma^2$ (distribución desconocida). Un economista ajusta $N(\mu, 1)$ por máxima verosimilitud, es decir, $m(w, \mu) = -\frac{1}{2}(w - \mu)^2$ (omitimos constantes). ¿A qué converge $\hat{\mu}$? ¿Cuál es su varianza asintótica verdadera? ¿Qué reportaría el programa si usara la fórmula “de manual” $-A^{-1}$?

 Solución 1.3

$\hat{\mu} = \bar{w} \rightarrow_p \mu_0$ (el *valor pseudo-verdadero*, el que maximiza Q_0 : $Q_0(\mu) = -\frac{1}{2}(\sigma^2 + (\mu_0 - \mu)^2)$). $A = -1$, $B = \mathbb{E}[(w - \mu_0)^2] = \sigma^2$. La varianza verdadera es $A^{-1}BA^{-1} = \sigma^2$. La fórmula de manual dice $-A^{-1} = 1$ (la varianza supuesta). Si $\sigma^2 = 4$ los errores estándar reportados serían la mitad de los verdaderos y el test al 5 % rechazaría mucho más del 5 % de las veces. Moraleja: el sándwich protege contra la especificación incorrecta de la **varianza**; la consistencia aquí sobrevivió porque la media sí estaba bien especificada.

Ejercicio 1.4. (Falla de identificación.) Considera $y = \theta_1\theta_2x + u$ con $\mathbb{E}[xu] = 0$ y $\mathbb{E}[x^2] > 0$, y $m = -\frac{1}{2}(y - \theta_1\theta_2x)^2$. Muestra que C3 falla. ¿Qué parámetro sí está identificado?

 Solución 1.4

$Q_0(\theta) = -\frac{1}{2}\mathbb{E}[(u + (\theta_{1,0}\theta_{2,0} - \theta_1\theta_2)x)^2] = -\frac{1}{2}(\mathbb{E}u^2 + (\theta_{1,0}\theta_{2,0} - \theta_1\theta_2)^2\mathbb{E}x^2)$ (el término cruzado es cero por $\mathbb{E}[xu] = 0$). Es máxima en **todo el conjunto** $\{\theta : \theta_1\theta_2 = \theta_{1,0}\theta_{2,0}\}$, una hipérbola: el máximo no es único. Solo el **pro-**

ducto $\theta_1\theta_2$ está identificado. $\hat{\theta}$ no converge a un punto, y el hessiano en cualquier punto de la hipérbola es singular (viola N4). El programa reportará errores estándar enormes o un hessiano no invertible.

Ejercicio 1.5. Para $y = \exp(\theta x) + u$ con $\mathbb{E}[u | x] = 0$ y $\text{Var}(u | x) = \sigma^2$, calcula la varianza asintótica del MCNL escalar. ¿Se parece a la de MCO?

 Solución 1.5

$g(x, \theta) = e^{\theta x}$, $\nabla g = x e^{\theta x}$. Por Ejemplo 5.2, $A = -\mathbb{E}[x^2 e^{2\theta_0 x}]$ y $B = \sigma^2 \mathbb{E}[x^2 e^{2\theta_0 x}]$. Entonces $\text{Avar} = \sigma^2 / \mathbb{E}[x^2 e^{2\theta_0 x}]$. Es la fórmula de MCO con homocedasticidad, $\sigma^2 / \mathbb{E}[x^2]$, reemplazando x por el regresor linealizado $\nabla g = x e^{\theta_0 x}$.

Ejercicio 1.6. Escribe el test de Wald para $H_0 : \theta_1/\theta_2 = 1$ en un M-estimador con $\theta \in \mathbb{R}^2$. ¿Qué jacobiano usas? ¿Por qué podría ser preferible testear $\theta_1 - \theta_2 = 0$ si θ_2 está cerca de cero?

 Solución 1.6

$h(\theta) = \theta_1/\theta_2 - 1$ y $H(\theta) = (1/\theta_2, -\theta_1/\theta_2^2)$. $W = n h(\hat{\theta})^2 / (H(\hat{\theta}) \hat{V} H(\hat{\theta})') \rightarrow \chi_1^2$ con $\hat{V} = \hat{A}^{-1} \hat{B} \hat{A}^{-1}$. En realidad el test del cociente es *peor* si $\theta_2 \approx 0$: el método delta linealiza h y la linealización es mala cuando θ_2 está cerca de cero (la derivada explota). Mejor reescribir la hipótesis como $\theta_1 - \theta_2 = 0$, que es lineal: el test de Wald **no es invariante a reparametrizaciones** (problema que la Clase 3 resuelve con el test de razón de verosimilitud).

Ejercicio 1.7 ★. Demuestra que si $m(w, \cdot)$ es cóncava para todo w y θ_0 es interior, se puede reemplazar C1 por que θ_0 sea el único maximizador de Q_0 en Θ convexo y $\mathbb{E}|m(w, \theta)| < \infty$ para todo θ . Da la idea: ¿por qué la concavidad compensa la falta de compacidad?

💡 Solución 1.7 ★

Idea (Newey y McFadden, 1994, Teorema 2.7). Para cada θ fijo, la LGN da $\hat{Q}_n(\theta) \rightarrow_p Q_0(\theta)$ y Q_0 es cóncava y estrictamente máxima en θ_0 . Sea $N = \{\|\theta - \theta_0\| \leq \delta\}$. Si $\hat{\theta}$ estuviera fuera de N , el segmento de θ_0 a $\hat{\theta}$ cruza la frontera de N en un punto θ_δ . Por concavidad de $\hat{Q}_n$ y por $\hat{Q}_n(\hat{\theta}) \geq \hat{Q}_n(\theta_0)$, se cumple $\hat{Q}_n(\theta_\delta) \geq \hat{Q}_n(\theta_0)$. Pero la frontera de N es compacta, y la convergencia puntual de funciones cóncavas implica convergencia **uniforme sobre compactos** (resultado clásico de análisis convexo). Con eso, $\hat{Q}_n(\theta_\delta) < \hat{Q}_n(\theta_0)$ con probabilidad que tiende a uno, contradicción. La concavidad “controla” lo que ocurre lejos usando solo lo que ocurre en la frontera de una vecindad compacta. Es por esto que probit, logit y MCO tienen consistencia sin pedir Θ compacto.