

Clase 2 · Máxima verosimilitud

Identificación, información de Fisher, cota de Cramér–Rao y eficiencia

Contenido

1	De “un criterio” al criterio	1
2	Identificación: la desigualdad de Gibbs	2
3	La igualdad de la información	3
4	Normalidad asintótica y eficiencia	5
4.1	¿Por qué esa varianza es la mejor?	5
5	Cuando el modelo está mal: cuasi-verosimilitud	7
6	★ Postgrado: la superioridad de Hodges y la eficiencia regular	8
7	Resumen	9
8	Ejercicios	10

1. De “un criterio” al criterio

La Clase 1 nos dio un teorema para cualquier criterio m . La pregunta natural: ¿cuál m es **el mejor**? Si estamos dispuestos a decir cómo se generan los datos, o sea a suponer una familia de densidades $f(w; \theta)$, hay una respuesta clásica: $m(w, \theta) = \log f(w; \theta)$.

Es la **máxima verosimilitud** (MV), y hoy veremos tres razones para quererla.

1. Identifica correctamente el parámetro (la desigualdad de Gibbs).
2. Tiene la varianza asintótica más simple posible (la igualdad de la información).
3. Esa varianza es la más chica que se puede lograr (la cota de Cramér-Rao).¹

Marco

Los datos $w_1, \dots, w_n$ son i.i.d. con densidad (o función de probabilidad) $f(w; \theta_0)$, para algún $\theta_0 \in \Theta \subset \mathbb{R}^p$. Es decir, el **modelo está bien especificado**; al final de la clase soltamos este supuesto. La *log-verosimilitud* es $\ell_n(\theta) = \sum_i \log f(w_i; \theta)$, el **score** es $s(w; \theta) = \nabla_{\theta} \log f(w; \theta)$ y la **matriz de información** es $\mathcal{I}(\theta) = \mathbb{E}_{\theta}[s(w; \theta)s(w; \theta)']$. El estimador MV es $\hat{\theta} = \arg \max \ell_n(\theta)$.

¹ Ronald Fisher propuso la MV en 1912 y 1922, pero no la inventó: Gauss, Laplace y Daniel Bernoulli ya habían maximizado verosimilitudes sin ponerles nombre. Fisher le dio el nombre, la teoría de la información y una pelea pública con Karl Pearson que duró décadas. De las peleas académicas se aprende poco; de la teoría, mucho.

2. Identificación: la desigualdad de Gibbs

En la Clase 1 vimos que la consistencia necesita que θ_0 sea el **único** maximizador de $Q_0(\theta) = \mathbb{E}_{\theta_0}[\log f(w; \theta)]$. Para MV esto es casi gratis.

Definición 2.1 (Identificación del parámetro). El modelo $\{f(\cdot; \theta)\}$ está **identificado** si para todo $\theta \neq \theta_0$ en Θ , las densidades $f(\cdot; \theta)$ y $f(\cdot; \theta_0)$ difieren en un conjunto de probabilidad positiva bajo $f(\cdot; \theta_0)$.

Teorema 2.1 (Desigualdad de Gibbs (o de la información)). Si el modelo está identificado, para todo $\theta \neq \theta_0$,

$$\mathbb{E}_{\theta_0}[\log f(w; \theta)] < \mathbb{E}_{\theta_0}[\log f(w; \theta_0)].$$

Es decir, θ_0 es el único maximizador de Q_0 .

Borrador

Quiero comparar dos esperanzas de logaritmos, o sea una esperanza de $\log \frac{f(w;\theta)}{f(w;\theta_0)}$. Una esperanza de un logaritmo está acotada por el logaritmo de la esperanza: Jensen, con log cóncava. Y la esperanza (bajo θ_0) de la razón de densidades es $\int \frac{f(\theta)}{f(\theta_0)} f(\theta_0) = \int f(\theta) \leq 1$. El logaritmo de algo ≤ 1 es ≤ 0 . La estrictez viene de que la razón no es constante cuando las densidades difieren, y Jensen es estricto para funciones estrictamente cóncavas con variables no degeneradas.

Demostración. Sea $\rho(w) = f(w; \theta)/f(w; \theta_0)$, definida donde $f(w; \theta_0) > 0$ (casi seguramente bajo θ_0). Si ρ fuera constante casi seguramente, esa constante sería 1 (porque ambas densidades integran 1), y las densidades coincidirían en un conjunto de probabilidad uno bajo θ_0 , contradiciendo la identificación. Luego ρ no es degenerada y, como log es estrictamente cóncava, la desigualdad de Jensen estricta da

$$\mathbb{E}_{\theta_0}[\log \rho(w)] < \log \mathbb{E}_{\theta_0}[\rho(w)] = \log \int_{\{f(\cdot; \theta_0) > 0\}} f(w; \theta) dw \leq \log 1 = 0.$$

Pero $\mathbb{E}_{\theta_0}[\log \rho] = Q_0(\theta) - Q_0(\theta_0)$. □

La cantidad $KL(\theta_0 \parallel \theta) = Q_0(\theta_0) - Q_0(\theta) \geq 0$ es la **divergencia de Kullback-Leibler**: “qué tan lejos” está $f(\cdot; \theta)$ de la verdad. Maximizar la log-verosimilitud muestral equivale a **minimizar la divergencia KL estimada**. Con la Definición 2.1, la Clase 1 se aplica: bajo compacidad y dominancia, $\hat{\theta} \xrightarrow{p} \theta_0$.

3. La igualdad de la información

Ahora las propiedades del score. Necesitamos que se pueda **derivar dentro de la integral**: que el soporte de $f(\cdot; \theta)$ no dependa de θ y que haya dominancia suficiente. (Falla, por ejemplo, para $w \sim U[0, \theta]$.) Llamamos a esto condiciones de regularidad (R).

Teorema 3.1 (Media cero del score e igualdad de la información). *Bajo (R), con θ_0 el valor verdadero:*

1. $\mathbb{E}_{\theta_0}[s(w; \theta_0)] = 0$.
2. $\mathcal{J}(\theta_0) = \mathbb{E}[s s'] = -\mathbb{E}[\nabla_{\theta} s(w; \theta_0)] = -\mathbb{E}[\nabla^2 \log f(w; \theta_0)]$.

Borrador

Como f integra a uno para todo θ , la derivada de $\int f(w; \theta) dw$ es cero. Derivando dentro de la integral aparece $\int \nabla f = \int s f = \mathbb{E}[s] = 0$ (usando $\nabla f = s f$). Para la segunda parte, derivó *otra vez* la identidad $\int s(w; \theta) f(w; \theta) dw = 0$: sale $\int (\nabla s) f + \int s \nabla' f = 0$, y $\nabla' f = s' f$.

Demostración.

- (1) Como $\int f(w; \theta) dw = 1$ para todo θ , derivando en θ y pasando la derivada dentro de la integral, $0 = \int \nabla f(w; \theta) dw = \int s(w; \theta) f(w; \theta) dw$, usando $\nabla f = f \nabla \log f = f s$. Evaluando en θ_0 , $\mathbb{E}_{\theta_0}[s(w; \theta_0)] = 0$. En realidad la identidad vale para todo θ con la esperanza tomada bajo ese mismo θ .
- (2) Derivando la identidad $\int s(w; \theta) f(w; \theta) dw = 0$ otra vez en θ' (pasando la derivada dentro de la integral):

$$0 = \int \nabla_{\theta'} s(w; \theta) f(w; \theta) dw + \int s(w; \theta) \nabla_{\theta'} f(w; \theta) dw = \mathbb{E}[\nabla s] + \int s s' f dw = \mathbb{E}[\nabla s] + \mathbb{E}[s s'].$$

$$\text{Luego } \mathbb{E}[s s'] = -\mathbb{E}[\nabla s].$$

□

Dos lecturas útiles. La parte (1) recupera el lema de la Clase 1 por otra vía: allí el score tenía media cero porque θ_0 maximiza Q_0 ; aquí basta con que f integre a uno. La parte (2) dice que la **curvatura** de la log-verosimilitud ($-A$) y su **ruido** (B) son la misma matriz: $B = -A = \mathcal{J}(\theta_0)$. Se cumple *solo* si el modelo está bien especificado.

4. Normalidad asintótica y eficiencia

Teorema 4.1 (Normalidad asintótica del estimador MV). *Bajo las condiciones de consistencia de la Clase 1, (R) y $\mathcal{I}(\theta_0)$ invertible,*

$$\sqrt{n}(\hat{\theta} - \theta_0) \xrightarrow{d} N(0, \mathcal{I}(\theta_0)^{-1}).$$

Demostración. Es el teorema de normalidad asintótica de la Clase 1 con $m = \log f$. Por el Teorema 3.1, $A = -\mathcal{I}(\theta_0)$ y $B = \mathcal{I}(\theta_0)$. Entonces $A^{-1}BA^{-1} = \mathcal{I}^{-1}\mathcal{I}\mathcal{I}^{-1} = \mathcal{I}^{-1}$. $\square$

Esa es la varianza asintótica del MV. Hay tres formas consistentes de estimarla, y todas son equivalentes si el modelo está bien especificado:

Estimador	Fórmula	Nombre
Hessiano	$\left[-\frac{1}{n} \sum \nabla s(w_i; \hat{\theta})\right]^{-1}$	de la información observada
Producto externo	$\left[\frac{1}{n} \sum s(w_i; \hat{\theta})s(w_i; \hat{\theta})'\right]^{-1}$	OPG o BHHH
Sándwich	$\hat{A}^{-1}\hat{B}\hat{A}^{-1}$	robusto (White)

Si el modelo está **mal** especificado, solo el sándwich es consistente para la varianza correcta (más abajo).

4.1. ¿Por qué esa varianza es la mejor?

Ahora demostramos que $\mathcal{I}^{-1}$ no se puede superar: la **cota de Cramér-Rao**. La versión de muestras finitas es la más fácil de probar; la asintótica sigue la misma idea.

Teorema 4.2 (Cota de Cramér-Rao). *Sea $T = T(w_1, \dots, w_n)$ un estimador insesgado de θ : $\mathbb{E}_\theta[T] = \theta$ para todo θ en una vecindad de θ_0 . Bajo (R) ,*

$$\text{Var}_{\theta_0}(T) \geq [n \mathcal{I}(\theta_0)]^{-1}.$$

i Borrador

La varianza de T no puede ser menor que algo, y ese “algo” debería involucrar a la información. La conexión entre T y el score total $S_n = \sum_i s(w_i; \theta_0)$ la da el insesgamiento: derivando $\mathbb{E}_\theta[T] = \theta$ en θ aparece $\mathbb{E}[T S'_n] = I_p$. Ahora tengo un vector aleatorio (T, S_n) con matriz de covarianza conocida a bloques (conozco $\text{Var}(S_n) = n\mathcal{J}$ y la covarianza cruzada). Una matriz de covarianza siempre es semidefinida positiva, y exigir que la matriz de bloques lo sea me da la desigualdad (complemento de Schur).

Demostración. Sea $f_n(w_{1:n}; \theta) = \prod_i f(w_i; \theta)$ la densidad conjunta, cuyo score es $S_n = \nabla \log f_n = \sum_i s(w_i; \theta)$. Como los datos son i.i.d., $\mathbb{E}[S_n] = 0$ y $\text{Var}(S_n) = n\mathcal{J}(\theta_0)$ (varianza de una suma de i.i.d. con media cero).

Derivando el insesgamiento $\theta = \int T f_n dw_{1:n}$ en θ y pasando la derivada dentro de la integral:

$$I_p = \int T \nabla' f_n dw_{1:n} = \int T S'_n f_n dw_{1:n} = \mathbb{E}[T S'_n] = \text{Cov}(T, S_n),$$

la última igualdad porque $\mathbb{E}[S_n] = 0$.

La matriz de covarianza del vector $(T', S'_n)'$ es semidefinida positiva:

$$\begin{pmatrix} \text{Var}(T) & I_p \\ I_p & n\mathcal{J} \end{pmatrix} \succeq 0.$$

Para todo $a \in \mathbb{R}^p$, tomando el vector $(a', -a'(n\mathcal{J})^{-1})$ y multiplicando por la izquierda y por la derecha:

$$0 \leq a' \text{Var}(T) a - 2a'(n\mathcal{J})^{-1} a + a'(n\mathcal{J})^{-1} (n\mathcal{J}) (n\mathcal{J})^{-1} a = a' [\text{Var}(T) - (n\mathcal{J})^{-1}] a.$$

Como a es arbitrario, $\text{Var}(T) \succeq (n\mathcal{J})^{-1}$. □

El $\hat{\theta}$ de MV **no** es insesgado en general, así que la cota no se le aplica en muestras finitas. Pero asintóticamente sí: $\text{Avar}(\hat{\theta}) = \mathcal{J}^{-1}$ coincide con la cota $(n\mathcal{J})^{-1}$ escalada por n . Decimos que el MV es **asintóticamente eficiente**: ningún estimador “regular” (que no se comporte raro localmente) tiene varianza asintótica menor. La sección ★ muestra por qué hay que decir “regular”.

Ejemplo 4.1 (El modelo lineal normal). $y \mid x \sim N(x'\beta, \sigma^2)$, con $\theta = (\beta', \sigma^2)'$. La log-verosimilitud de una observación es $-\frac{1}{2} \log(2\pi\sigma^2) - (y - x'\beta)^2/(2\sigma^2)$, con score

$$s_\beta = \frac{xu}{\sigma^2}, \quad s_{\sigma^2} = -\frac{1}{2\sigma^2} + \frac{u^2}{2\sigma^4}, \quad u = y - x'\beta.$$

Maximizar en β equivale a minimizar $\sum (y_i - x_i'\beta)^2$, así que $\hat{\beta}_{MV} = \hat{\beta}_{MCO}$. En σ^2 : $\hat{\sigma}^2 = \frac{1}{n} \sum \hat{u}_i^2$, que es el MCO sin corregir por grados de libertad: sesgado, pero consistente (y asintóticamente equivalente a s^2).

La información es **diagonal por bloques**: $\mathcal{I}_{\beta\beta} = \mathbb{E}[xx']/\sigma^2$, $\mathcal{I}_{\sigma^2\sigma^2} = 1/(2\sigma^4)$ y $\mathcal{I}_{\beta\sigma^2} = 0$ (usando $\mathbb{E}[u \mid x] = \mathbb{E}[u^3 \mid x] = 0$, $\mathbb{E}[u^2 \mid x] = \sigma^2$ y $\mathbb{E}[u^4 \mid x] = 3\sigma^4$). Así, $\text{Avar}(\hat{\beta}) = \sigma^2 \mathbb{E}[xx']^{-1}$: la fórmula de MCO.

Consecuencia notable: **bajo normalidad, MCO alcanza la cota de Cramér–Rao** (asintóticamente). En Econometría 1 (Clase 4) vimos Gauss–Markov, que lo hacía mejor que cualquier estimador *lineal insesgado*. Con normalidad es mejor que *cualquier* estimador regular, lineal o no.

5. Cuando el modelo está mal: cuasi-verosimilitud

Suponer que conocemos la familia $f(w; \theta)$ es exigente. ¿Qué ocurre si maximizamos una verosimilitud que es **incorrecta**? Sea g la densidad verdadera, que no pertenece a $\{f(\cdot; \theta)\}$. El M-estimador $\hat{\theta}$ es el **estimador de cuasi-máxima verosimilitud** (QMV). La Clase 1 sigue valiendo con $m = \log f$, pero el límite cambia:

$$\hat{\theta} \xrightarrow{p} \theta^* = \arg \max_{\theta} \mathbb{E}_g[\log f(w; \theta)] = \arg \min_{\theta} \text{KL}(g \parallel f(\cdot; \theta)).$$

El **valor pseudo-verdadero** θ^* es la mejor aproximación de g dentro de la familia, en el sentido de KL.² Lo notable es que la va-

² Halbert White (1982) demostró esto en “Maximum likelihood estimation of misspecified models”, el artículo que popularizó el sándwich y el término *pseudo-verdadero*. White es más conocido por sus errores estándar robustos y su test de heterocedasticidad, ambos en un artículo de 1980 que está entre los más citados de la econometría.

rianza ya **no** es $\mathcal{I}^{-1}$: $B \neq -A$, y la distribución es la del sándwich de la Clase 1,

$$\sqrt{n}(\hat{\theta} - \theta^*) \xrightarrow{d} N(0, A^{-1}BA^{-1}), \quad A = \mathbb{E}_g[\nabla^2 \log f(w; \theta^*)], \quad B = \mathbb{E}_g[ss'].$$

Hay dos situaciones prácticas. Si θ^* **tiene el significado que te interesa** (por ejemplo, es la media condicional correcta aunque la distribución esté mal), entonces la QMV da inferencia válida usando el sándwich: esto ocurre, por ejemplo, para el **Poisson** con la media condicional bien especificada (Clase 7) o para MCO bajo no normalidad. Si θ^* **no** tiene ese significado (por ejemplo, un probit con heterocedasticidad en el error latente, Clase 5), $\hat{\theta}$ converge a algo que no te interesa y ni el sándwich lo salva.

La **prueba de la igualdad de la información** de White se basa en esto: bajo especificación correcta, $A = -B$; la prueba chequea si $\hat{A} + \hat{B}$ es cero. Que no se cumpla es síntoma de mala especificación.

6. ★ Postgrado: la superioridad de Hodges y la eficiencia regular

! ★ Postgrado

¿Es cierto que ningún estimador tiene varianza asintótica menor a $\mathcal{I}^{-1}$? No sin una condición adicional. El **estimador de Hodges** (1951) la rompe, y por eso se define eficiencia entre estimadores *regulares*.

Sea $w_i \sim N(\theta, 1)$ i.i.d., con $\mathcal{I}(\theta) = 1$, y $\bar{w}$ el MV. Definimos

$$\hat{\theta}_H = \begin{cases} \bar{w} & \text{si } |\bar{w}| > n^{-1/4}, \\ 0 & \text{si } |\bar{w}| \leq n^{-1/4}. \end{cases}$$

Proposición 6.1 (El estimador de Hodges).

1. Si $\theta \neq 0$, $\sqrt{n}(\hat{\theta}_H - \theta) \xrightarrow{d} N(0, 1)$.

2. Si $\theta = 0$, $\sqrt{n}\hat{\theta}_H \xrightarrow{p} 0$: varianza asintótica **cero**, menor que $1/J$.
3. Pero para $\theta_n = h/\sqrt{n}$ con $h \neq 0$: $\sqrt{n}(\hat{\theta}_H - \theta_n) \xrightarrow{p} -h$, que **no** está acotado cuando h crece.

Demostración. $\bar{w} \sim N(\theta, 1/n)$, es decir, $\bar{w} = \theta + z/\sqrt{n}$ con $z \sim N(0, 1)$.

- (1) Si $\theta \neq 0$, $P(|\bar{w}| \leq n^{-1/4}) \rightarrow 0$ (porque $\bar{w} \rightarrow_p \theta$ y $n^{-1/4} \rightarrow 0$). Entonces con probabilidad que tiende a uno $\hat{\theta}_H = \bar{w}$ y la distribución límite es la del MV.
- (2) Si $\theta = 0$, $|\bar{w}| = |z|/\sqrt{n} \leq n^{-1/4}$ equivale a $|z| \leq n^{1/4}$, que ocurre con probabilidad que tiende a uno. Luego $\hat{\theta}_H = 0$ con probabilidad que tiende a uno y $\sqrt{n}\hat{\theta}_H = 0$ en ese evento.
- (3) Con $\theta_n = h/\sqrt{n}$: $\bar{w} = (h + z)/\sqrt{n}$ y $|\bar{w}| \leq n^{-1/4}$ equivale a $|h + z| \leq n^{1/4}$, de nuevo con probabilidad que tiende a uno. Luego $\hat{\theta}_H = 0$ y $\sqrt{n}(\hat{\theta}_H - \theta_n) = -h$.

□

En $\theta = 0$ Hodges “gana” al MV, pero es un espejismo: en una vecindad de tamaño $n^{-1/2}$ alrededor de 0 (que no podemos distinguir de 0 con n observaciones) su error es arbitrariamente grande. El **teorema de convolución** de Hájek-Le Cam formaliza la salida: entre estimadores *regulares* (cuya distribución límite no cambia bajo perturbaciones locales $\theta_n = \theta + h/\sqrt{n}$), cualquier límite es $N(0, J^{-1})$ convolucionado con otra distribución, y por lo tanto con varianza $\geq J^{-1}$. El MV es regular y alcanza el piso.

7. Resumen

- Para MV, $m = \log f$. **Identificación** (Teorema 2.1): por Jensen, θ_0 maximiza $\mathbb{E} \log f(w; \theta)$ de manera única. La diferencia es la divergencia KL.
- **Igualdad de la información** (Teorema 3.1): bajo especificación correcta, $\mathbb{E}[s] = 0$ y $\mathbb{E}[ss'] = -\mathbb{E}[\nabla s]$. Por eso $A = -B$.

- **Normalidad** (Teorema 4.1): $\sqrt{n}(\hat{\theta} - \theta_0) \rightarrow N(0, \mathcal{I}^{-1})$.
- **Cramér-Rao** (Teorema 4.2): ningún estimador insesgado tiene varianza menor que $(n\mathcal{I})^{-1}$; el MV la alcanza asintóticamente.
- Con el modelo **mal** especificado, el QMV converge al pseudo-verdadero y la varianza es el sándwich.

8. Ejercicios

Ejercicio 2.1. Para $w \sim \text{Bernoulli}(\theta)$ calcula el MV, el score, la información $\mathcal{I}(\theta)$ y la varianza asintótica. Verifica que $\mathbb{E}[ss'] = -\mathbb{E}[\nabla s]$.

💡 Solución 2.1

$\log f = w \log \theta + (1 - w) \log(1 - \theta)$; $\hat{\theta} = \bar{w}$. Score: $s = w/\theta - (1 - w)/(1 - \theta) = \frac{w - \theta}{\theta(1 - \theta)}$. $\mathbb{E}[s^2] = \frac{\text{Var}(w)}{\theta^2(1 - \theta)^2} = \frac{1}{\theta(1 - \theta)}$. Derivada del score: $\nabla s = -w/\theta^2 - (1 - w)/(1 - \theta)^2$, con esperanza $-1/\theta - 1/(1 - \theta) = -\frac{1}{\theta(1 - \theta)}$. Coinciden con signo opuesto. Varianza asintótica: $\mathcal{I}^{-1} = \theta(1 - \theta)$, el resultado clásico del TCL.

Ejercicio 2.2. Sea $w \sim \text{Poisson}(\lambda)$. Calcula el MV y su varianza asintótica. Muestra que alcanza la cota de Cramér-Rao *exactamente* (en muestras finitas).

💡 Solución 2.2

$\log f = w \log \lambda - \lambda - \log w!$. $s = w/\lambda - 1$, $\hat{\lambda} = \bar{w}$. $\mathcal{I}(\lambda) = \text{Var}(w)/\lambda^2 = 1/\lambda$. Cota: $\text{Var}(T) \geq \lambda/n$. Pero $\text{Var}(\bar{w}) = \lambda/n$ y $\bar{w}$ es insesgado: alcanza la cota exacta. (Es un caso de familia exponencial: el estimador insesgado de varianza mínima coincide con el MV.)

Ejercicio 2.3. Verifica la información del Ejemplo 4.1 para σ^2 : calcula $\mathbb{E}[s_{\sigma^2}^2]$ y $-\mathbb{E}[\partial s_{\sigma^2}/\partial \sigma^2]$ y comprueba que son iguales a $1/(2\sigma^4)$. ¿Qué momento de u necesitaste para la primera?

💡 Solución 2.3

$s_{\sigma^2} = \frac{u^2 - \sigma^2}{2\sigma^4}$, así que $E[s^2] = \frac{\text{Var}(u^2)}{4\sigma^8} = \frac{Eu^4 - \sigma^4}{4\sigma^8} = \frac{3\sigma^4 - \sigma^4}{4\sigma^8} = \frac{1}{2\sigma^4}$; aquí se usó $E[u^4] = 3\sigma^4$ (cuarto momento de la normal). Por otro lado, $\partial s / \partial \sigma^2 = \frac{1}{2\sigma^4} - \frac{u^2}{\sigma^6}$, con esperanza $\frac{1}{2\sigma^4} - \frac{1}{\sigma^4} = -\frac{1}{2\sigma^4}$. Coinciden. Si u no es normal, $E[u^4] \neq 3\sigma^4$, la igualdad de la información **falla** para σ^2 y el MV de σ^2 tendría varianza sándwich distinta (aunque $\hat{\beta}$ siga bien).

Ejercicio 2.4. Un investigador ajusta por QMV un modelo $N(\mu, 1)$ a datos con media μ_0 y varianza σ^2 desconocida. Calcula A , B y el sándwich. ¿Cuándo el sándwich coincide con $-A^{-1}$? (Es el Ejercicio 1.3 desde el punto de vista de esta clase.)

💡 Solución 2.4

$m = -\frac{1}{2}(w - \mu)^2$: $A = -1$, $B = \sigma^2$, sándwich = σ^2 . Coincide con $-A^{-1} = 1$ solo si $\sigma^2 = 1$, es decir, cuando la varianza supuesta es la verdadera. En general $A + B = \sigma^2 - 1 \neq 0$ y el test de igualdad de la información rechaza: está detectando que la especificación de la varianza es incorrecta.

Ejercicio 2.5. (Invarianza del MV.) Si $\hat{\theta}$ es el MV de θ y $\gamma = g(\theta)$ con g biyectiva, muestra que $g(\hat{\theta})$ es el MV de γ y que su varianza asintótica es $G J^{-1} G'$, con $G = \partial g / \partial \theta'$.

💡 Solución 2.5

La log-verosimilitud en γ es $\tilde{\ell}(\gamma) = \ell(g^{-1}(\gamma))$, cuyo máximo se alcanza en $\hat{\gamma} = g(\hat{\theta})$ porque g^{-1} es biyección. La normalidad asintótica sigue del método delta (Clase 6 de Econometría 1): $\sqrt{n}(g(\hat{\theta}) - g(\theta_0)) \rightarrow N(0, G J^{-1} G')$. Alternativamente se llega igual con la información de γ : $\tilde{J}(\gamma) = G^{-1'} J G^{-1}$ y su inversa es $G J^{-1} G'$.

Ejercicio 2.6. Sea $w \sim U[0, \theta]$. Calcula el MV y muestra que $n(\theta -$

$\hat{\theta}$) converge a una exponencial (no a una normal). ¿Qué condición de (R) falla?

 Solución 2.6

$f(w; \theta) = 1/\theta$ si $0 \leq w \leq \theta$. La verosimilitud θ^{-n} es decreciente en θ y solo es positiva si $\theta \geq \max_i w_i$: $\hat{\theta} = \max_i w_i$. $P(n(\theta - \hat{\theta}) > t) = P(\hat{\theta} < \theta - t/n) = (1 - t/(n\theta))^n \rightarrow e^{-t/\theta}$. La tasa es n , no $\sqrt{n}$, y la distribución es exponencial. Falla la condición de que el soporte no dependa de θ (no se puede derivar dentro de la integral): la verosimilitud no es derivable en el máximo.

Ejercicio 2.7 ★. Demuestra la cota de Cramér–Rao para estimar una función $g(\theta)$ escalar con un estimador insesgado T de $g(\theta)$: $\text{Var}(T) \geq \nabla g'(n\mathcal{I})^{-1} \nabla g$.

 Solución 2.7 ★

Derivando $\mathbb{E}_\theta[T] = g(\theta)$: $\text{Cov}(T, S_n) = \nabla g(\theta)'$ (fila). La matriz de covarianza de $(T, S_n)'$ es $\begin{pmatrix} \text{Var}(T) & \nabla g' \\ \nabla g & n\mathcal{I} \end{pmatrix} \geq 0$. Multiplicando por el vector $(1, -\nabla g'(n\mathcal{I})^{-1})$ por la izquierda y su transpuesta por la derecha: $0 \leq \text{Var}(T) - 2\nabla g'(n\mathcal{I})^{-1} \nabla g + \nabla g'(n\mathcal{I})^{-1} \nabla g = \text{Var}(T) - \nabla g'(n\mathcal{I})^{-1} \nabla g$. Con $g(\theta) = a'\theta$ se recupera la prueba del teorema.