

Clase 3 · Los tres tests de la trinidad

Wald, razón de verosimilitud y multiplicador de Lagrange

Contenido

1	Tres maneras de hacer la misma pregunta	1
2	Los tres estadísticos	2
2.1	Hipótesis simple: $H_0 : \theta = \theta_0$	3
2.2	Hipótesis compuesta: restricciones lineales	4
3	En el modelo lineal normal: $W \geq LR \geq LM$	6
4	El test LM como nR^2	7
5	Cuál usar: tres criterios prácticos	8
6	★ Postgrado: potencia local	9
7	Resumen	9
8	Ejercicios	10

1. Tres maneras de hacer la misma pregunta

Queremos testear una hipótesis $H_0 : h(\theta_0) = 0$ con q restricciones sobre un modelo estimado por MV. Hay tres caminos natu-

rales, y cada uno mira una parte distinta de la log-verosimilitud $\ell_n(\theta)$:

- **Wald:** estima el modelo **sin** restricciones y mira si $h(\hat{\theta})$ está lejos de cero. Pregunta: *¿qué tan lejos están las restricciones de cumplirse en el estimador?*
- **Razón de verosimilitud (LR):** estima **ambos** modelos y compara el valor de ℓ_n . Pregunta: *¿cuánta verosimilitud perdemos al imponer la restricción?*
- **Multiplicador de Lagrange (LM, o test de score):** estima **solo el restringido** y mira si el gradiente de ℓ_n ahí es cercano a cero. Pregunta: *¿cuánto quisiera moverse el estimador restringido si lo dejáramos?*

Los tres son la misma pregunta en tres lenguajes (distancia, altura y pendiente) y la teoría dice que, bajo H_0 y para n grande, dan **lo mismo**. Por eso se llaman la *trinidad*.¹

🔥 Notación

Trabajamos con el modelo bien especificado de la Clase 2. $\hat{\theta}$ es el MV sin restringir, $\tilde{\theta}$ el MV sujeto a $h(\theta) = 0$, $\mathcal{I} = \mathcal{I}(\theta_0)$, $H(\theta) = \partial h / \partial \theta'$ ($q \times p$, rango q) y $\hat{J}, \tilde{J}$ son estimadores consistentes de $\mathcal{I}$ evaluados en $\hat{\theta}$ y $\tilde{\theta}$. El **score total** es $S(\theta) = \nabla \ell_n(\theta) = \sum_i s(w_i; \theta)$.

¹ Wald (1943), Wilks (1938) y Rao (1948) los propusieron por separado, y Silvey (1959) descubrió que el test de Rao es en realidad el multiplicador de Lagrange del problema restringido. Un *trío* de resultados independientes que resultan ser uno solo: es lo más parecido que tiene la estadística a una doctrina religiosa. (Y como en toda trinidad, el misterio consiste en que son tres y son uno.)

2. Los tres estadísticos

Definición 2.1 (Wald, LR y LM).

$$W = n h(\hat{\theta})' [H(\hat{\theta}) \hat{J}^{-1} H(\hat{\theta})']^{-1} h(\hat{\theta}),$$

$$LR = 2[\ell_n(\hat{\theta}) - \ell_n(\tilde{\theta})], \quad LM = \frac{1}{n} S(\tilde{\theta})' \tilde{J}^{-1} S(\tilde{\theta}).$$

Nota el patrón. W solo usa el estimador **sin** restringir; LM solo el **restringido**; LR necesita ambos. En la práctica esto importa mucho: si el modelo restringido es fácil de estimar y el sin restringir es difícil (o el revés), uno de los tres test es mucho más barato.

Teorema 2.1 (Equivalencia asintótica de la trinidad). *Bajo las condiciones de regularidad de las Clases 1 y 2 y H_0 verdadera,*

$$W \xrightarrow{d} \chi_q^2, \quad LR \xrightarrow{d} \chi_q^2, \quad LM \xrightarrow{d} \chi_q^2,$$

y las diferencias entre ellos son $o_p(1)$: $W - LR = o_p(1)$ y $LR - LM = o_p(1)$.

Vamos primero con el caso más simple y luego el general.

2.1. Hipótesis simple: $H_0 : \theta = \theta_0$

Aquí $q = p$, el modelo “restringido” no tiene parámetros libres, $\tilde{\theta} = \theta_0$ y los tres estadísticos son

$$W = n(\hat{\theta} - \theta_0)' \hat{J}(\hat{\theta} - \theta_0), \quad LR = 2[\ell_n(\hat{\theta}) - \ell_n(\theta_0)], \quad LM = \frac{1}{n} S(\theta_0)' J^{-1} S(\theta_0).$$

Borrador

Todo se reduce a la expansión de Taylor de ℓ_n que ya usamos para la normalidad asintótica: cerca de $\hat{\theta}$ (donde el gradiente es cero), ℓ_n es una parábola con curvatura $-nJ$. En una parábola, “qué tan lejos estoy del máximo” (Wald), “cuánta altura perdí” (LR) y “qué tan empinada es la ladera en θ_0 ” (LM) son **la misma cantidad** vista desde tres lados: distancia² $\times$ curvatura, altura = $\frac{1}{2} \times$ eso, pendiente² $\div$ curvatura. Hay que dar cuenta del error de aproximación de Taylor, pero es de orden menor.

Demostración. Sea $\mathcal{S}_n = n^{-1/2} S(\theta_0) \xrightarrow{d} N(0, J)$ por el TCL (el score tiene media cero y varianza J).

Wald y LM. De la demostración del teorema de normalidad asintótica (Clase 1), $\sqrt{n}(\hat{\theta} - \theta_0) = J^{-1} \mathcal{S}_n + o_p(1)$ (con $A = -J$). Como $\hat{J} \rightarrow_p J$ y $\mathcal{S}_n = O_p(1)$,

$$W = \mathcal{S}_n' J^{-1} J J^{-1} \mathcal{S}_n + o_p(1) = \mathcal{S}_n' J^{-1} \mathcal{S}_n + o_p(1) = LM + o_p(1).$$

Como $\mathcal{S}_n \rightarrow_d N(0, J)$, por el lema de la χ^2 con la inversa de la varianza (Clase 5 de Econometría 1) y el teorema de la función

continua, $S'_n J^{-1} S_n \rightarrow_d \chi_p^2$. Luego W y LM tienen el mismo límite χ_p^2 .

LR. Expandimos $\ell_n(\theta_0)$ alrededor de $\hat{\theta}$ con el teorema del valor medio (resto de segundo orden): como $\nabla \ell_n(\hat{\theta}) = 0$,

$$\ell_n(\theta_0) = \ell_n(\hat{\theta}) + \frac{1}{2}(\theta_0 - \hat{\theta})' \nabla^2 \ell_n(\bar{\theta})(\theta_0 - \hat{\theta})$$

con $\bar{\theta}$ entre $\hat{\theta}$ y θ_0 . Entonces

$$LR = 2[\ell_n(\hat{\theta}) - \ell_n(\theta_0)] = n(\hat{\theta} - \theta_0)' \left[-\frac{1}{n} \nabla^2 \ell_n(\bar{\theta}) \right] (\hat{\theta} - \theta_0).$$

Como $-\frac{1}{n} \nabla^2 \ell_n(\bar{\theta}) \rightarrow_p J$ (Clase 1, paso 1) y $\sqrt{n}(\hat{\theta} - \theta_0) = O_p(1)$, resulta $LR = n(\hat{\theta} - \theta_0)' J(\hat{\theta} - \theta_0) + o_p(1) = W + o_p(1)$. $\square$

2.2. Hipótesis compuesta: restricciones lineales

Para $q < p$ la idea es la misma, pero ahora hay que tratar con el estimador restringido. Para fijar ideas, tomamos restricciones **lineales** $H_0 : R\theta = r$, con R de $q \times p$ y rango q . (El caso no lineal $h(\theta) = 0$ sigue igual linealizando h en θ_0 : método delta.)

Borrador

$\tilde{\theta}$ resuelve un problema con restricciones, así que el gradiente ahí **no** es cero: es una combinación de las filas de R (el multiplicador de Lagrange): $S(\tilde{\theta}) = R'\tilde{\lambda}$. Quiero relacionar $\tilde{\theta}$ con $\hat{\theta}$ usando de nuevo la parábola. Expando el score restringido alrededor de $\hat{\theta}$, donde el score es cero: $S(\tilde{\theta}) \approx -nJ(\tilde{\theta} - \hat{\theta})$. De ahí sale $\hat{\theta} - \tilde{\theta} \approx J^{-1}R'\tilde{\lambda}/n$. Multiplico por R (sabiendo que $R\hat{\theta} = r$) y despejo el multiplicador. Con eso los tres estadísticos se escriben como la **misma** forma cuadrática en $R\hat{\theta} - r$.

Demostración. (del Teorema 2.1, caso lineal). Supongamos que $\tilde{\theta}$ es consistente y que $\sqrt{n}(\tilde{\theta} - \theta_0) = O_p(1)$ (el estimador restringido es un M-estimador en un espacio más chico y vale la Clase 1). Sea $\tilde{\lambda}$ el multiplicador de Lagrange, de modo que $S(\tilde{\theta}) = R'\tilde{\lambda}$ y $R\tilde{\theta} = r$. Escribimos $\Lambda = n^{-1/2}\tilde{\lambda}$ para que $n^{-1/2}S(\tilde{\theta}) = R'\Lambda$.

Paso 1: relación entre $\hat{\theta}$ y $\tilde{\theta}$. Expandimos el score en $\tilde{\theta}$ alrededor de $\hat{\theta}$, donde $S(\hat{\theta}) = 0$:

$$\frac{1}{\sqrt{n}}S(\tilde{\theta}) = \frac{1}{\sqrt{n}}S(\hat{\theta}) + \left[\frac{1}{n}\nabla^2 \ell_n(\tilde{\theta}) \right] \sqrt{n}(\tilde{\theta} - \hat{\theta}) = -J\sqrt{n}(\tilde{\theta} - \hat{\theta}) + o_p(1).$$

(usando $\frac{1}{n}\nabla^2 \ell_n(\tilde{\theta}) \rightarrow_p -J$ y que $\sqrt{n}(\tilde{\theta} - \hat{\theta}) = O_p(1)$). Por lo tanto

$$\sqrt{n}(\hat{\theta} - \tilde{\theta}) = J^{-1}R'\Lambda + o_p(1). \quad (1)$$

Paso 2: el multiplicador. Multiplicando Ecuación 1 por R y usando $R\hat{\theta} = r$, $R\sqrt{n}(\hat{\theta} - \tilde{\theta}) = \sqrt{n}(R\hat{\theta} - r)$. Luego

$$\sqrt{n}(R\hat{\theta} - r) = RJ^{-1}R'\Lambda + o_p(1) \quad \Rightarrow \quad \Lambda = (RJ^{-1}R')^{-1}\sqrt{n}(R\hat{\theta} - r) + o_p(1). \quad (2)$$

Paso 3: los tres estadísticos.

LM. $LM = \frac{1}{n}S(\tilde{\theta})'J^{-1}S(\tilde{\theta}) = \Lambda'RJ^{-1}R'\Lambda + o_p(1)$, y por Ecuación 2,

$$LM = n(R\hat{\theta} - r)'(RJ^{-1}R')^{-1}(R\hat{\theta} - r) + o_p(1) = W + o_p(1).$$

LR. Expandiendo $\ell_n(\tilde{\theta})$ alrededor de $\hat{\theta}$ (con $S(\hat{\theta}) = 0$), $2[\ell_n(\hat{\theta}) - \ell_n(\tilde{\theta})] = n(\hat{\theta} - \tilde{\theta})' \left[-\frac{1}{n}\nabla^2 \ell_n(\tilde{\theta}) \right] (\hat{\theta} - \tilde{\theta})$, que por Ecuación 1 es

$$LR = \Lambda'RJ^{-1}J^{-1}R'\Lambda + o_p(1) = \Lambda'RJ^{-1}R'\Lambda + o_p(1) = LM + o_p(1).$$

Distribución. Bajo H_0 , $R\theta_0 = r$ y $\sqrt{n}(R\hat{\theta} - r) = R\sqrt{n}(\hat{\theta} - \theta_0) \rightarrow_d N(0, RJ^{-1}R')$ (Clase 2 más el teorema de transformaciones lineales). Por el lema de la χ^2 con la inversa de la varianza, $W \rightarrow_d \chi_q^2$. Como los otros dos difieren de W en $o_p(1)$, tienen el mismo límite. $\square$

El resultado clave sobre el *multiplicador*: $\tilde{\lambda}$ mide el “precio sombra” de la restricción, o sea cuánto subiría ℓ_n si la relajáramos un poco. Si H_0 es cierta, el precio sombra es cercano a cero, y el LM test es precisamente un test de que el precio sombra es cero.

3. En el modelo lineal normal:

$$W \geq LR \geq LM$$

Asintóticamente los tres son iguales; en muestras finitas no. Hay un caso donde se puede calcular todo en forma cerrada y la ordenación es exacta.

Considera $y = X\beta + u$, $u \sim N(0, \sigma^2 I_n)$ y $H_0 : R\beta = r$ con q restricciones. Sean SCR_{NR} y SCR_R las sumas de residuos al cuadrado sin y con restricciones (Clase 5 de Econometría 1). El MV de σ^2 es SCR/n en cada modelo.

Teorema 3.1 (Desigualdad de Berndt-Savin). Con $x = SCR_R/SCR_{NR} \geq 1$,

$$W = n(x - 1), \quad LR = n \log x, \quad LM = n(1 - 1/x),$$

y en consecuencia $W \geq LR \geq LM$ siempre.

Demostración. La log-verosimilitud concentrada en σ^2 es $\ell(\hat{\beta}, \hat{\sigma}^2) = -\frac{n}{2} \log(2\pi\hat{\sigma}^2) - \frac{n}{2}$ con $\hat{\sigma}^2 = SCR/n$. Entonces

$$LR = 2[\ell_{NR} - \ell_R] = n \log \frac{SCR_R}{SCR_{NR}} = n \log x.$$

Para Wald, la identidad de la Clase 5 de Econometría 1 da $(R\hat{\beta} - r)'[R(X'X)^{-1}R']^{-1}(R\hat{\beta} - r) = SCR_R - SCR_{NR}$, y la varianza asintótica de $\hat{\beta}$ se estima con $\hat{\sigma}_{NR}^2 = SCR_{NR}/n$:

$$W = \frac{(R\hat{\beta} - r)'[R(X'X)^{-1}R']^{-1}(R\hat{\beta} - r)}{\hat{\sigma}_{NR}^2} = n \frac{SCR_R - SCR_{NR}}{SCR_{NR}} = n(x - 1).$$

Para LM, el score en β del modelo restringido es $X'\tilde{u}/\tilde{\sigma}^2$ (con $\tilde{u}$ los residuos restringidos, $\tilde{\sigma}^2 = SCR_R/n$), y la información en β es $X'X/\tilde{\sigma}^2$, así que $LM = \tilde{u}'X(X'X)^{-1}X'\tilde{u}/\tilde{\sigma}^2$. Por la identidad de los mínimos cuadrados restringidos (Clase 5 de Econometría 1, sección ★), $\tilde{u}'P_X\tilde{u} = SCR_R - SCR_{NR}$ (los residuos restringidos se descomponen en residuos sin restringir más el desvío $X(\hat{\beta} - \tilde{\beta})$, ortogonales). Entonces $LM = n(SCR_R - SCR_{NR})/SCR_R = n(1 - 1/x)$.

Finalmente, para $x \geq 1$: $\log x \leq x - 1$ (la recta tangente a $\log$ en 1 queda por encima de la curva), y $\log x = -\log(1/x) \geq -(1/x -$

1) = $1 - 1/x$ (aplicando lo mismo a $1/x$). Multiplicando por n se tiene $W \geq LR \geq LM$. $\square$

⚠ Una consecuencia incómoda

Como $W \geq LR \geq LM$, el Wald **rechaza más** que el LR y este más que el LM en muestras pequeñas, aunque los tres sean asintóticamente χ^2_q . Con n chico, el Wald tiende a sobre-rechazar (tamaño real mayor que el nominal) y el LM a sub-rechazar. Si el resultado de tu investigación depende de cuál de los tres usas, no tienes un resultado robusto.

Además, relacionando con el estadístico F de Econometría 1: $W = \frac{nq}{n-k} F$. El Wald de MCO es el F multiplicado por $nq/(n-k)$, y por eso $W/q \approx F$ para n grande.

4. El test LM como nR^2

El LM suele calcularse con una **regresión auxiliar**, lo que explica por qué es tan popular en tests de especificación (Breusch–Pagan de la Clase 9 de Econometría 1, Breusch–Godfrey para autocorrelación, y muchos más).

Proposición 4.1 (LM como nR^2_u). Sea $\tilde{s}_i = s(w_i; \tilde{\theta})$ el score de la observación i en el estimador restringido, e ι el vector de unos. Si usamos el estimador OPG de la información, $\tilde{J} = \frac{1}{n} \sum_i \tilde{s}_i \tilde{s}'_i$, entonces

$$LM = \iota' \tilde{S} (\tilde{S}' \tilde{S})^{-1} \tilde{S}' \iota = n \cdot R^2_u,$$

con $\tilde{S}$ la matriz $n \times p$ con filas $\tilde{s}'_i$ y R^2_u el R^2 **no centrado** de regesar el vector de unos ι sobre $\tilde{S}$.

Demostración. $S(\tilde{\theta}) = \sum_i \tilde{s}_i = \tilde{S}' \iota$ y $n\tilde{J} = \tilde{S}' \tilde{S}$. Reemplazando en la definición, $LM = \frac{1}{n} (\tilde{S}' \iota)' \left(\frac{1}{n} \tilde{S}' \tilde{S} \right)^{-1} (\tilde{S}' \iota) = \iota' \tilde{S} (\tilde{S}' \tilde{S})^{-1} \tilde{S}' \iota$. Pero $\iota' P_{\tilde{S}} \iota$ es la suma explicada de cuadrados de la regresión de ι sobre $\tilde{S}$, y la suma total no centrada es $\iota' \iota = n$. Entonces $R^2_u = \iota' P_{\tilde{S}} \iota / n$ y $LM = nR^2_u$. $\square$

Cuándo usarlo: si el modelo restringido es fácil (por ejemplo, MCO) y tienes los scores a la mano, el LM te evita estimar el modelo sin restringir. Es útil para preguntas como “¿debería agregar estas variables?”, donde estimar el modelo ampliado es costoso o inestable.

5. Cuál usar: tres criterios prácticos

	Wald	LR	LM
Estima	solo sin restringir	ambos	solo restringido
Invariante a reparametrización	no	sí	sí (con J esperada)
Se puede hacer robusto (sándwich)	sí	no (necesita MV)	sí
Se usa mucho para	reportar coeficientes	comparar modelos anidados	tests de especificación

La **no invarianza** del Wald es seria. Si testearas $H_0 : \theta = 1$ o $H_0 : \theta^{-1} = 1$, que son *la misma hipótesis*, obtienes valores distintos del estadístico (Ejercicio 3.3). El LR no sufre esto, porque compara valores de ℓ_n , que no dependen de cómo parametrices el modelo. Y **solo el Wald (y el LM) tienen versión robusta a mala especificación**: el LR se apoya en la igualdad de la información ($B = -A$) y pierde su distribución χ^2 si esta falla.

6. ★ Postgrado: potencia local

! ★ Postgrado

Bajo H_0 los tres tienen la misma distribución. Para compararlos como *tests* nos importa también qué hacen bajo la **alternativa**. Como n crece, cualquier alternativa fija se rechaza con probabilidad uno, así que miramos alternativas **locales** que se acercan a H_0 a tasa $\sqrt{n}$.

Sea $H_0 : \theta = \theta_0$ y la secuencia de alternativas $\theta_n = \theta_0 + h/\sqrt{n}$. Bajo θ_n el score en θ_0 **ya no** tiene media cero. Con un TCL para arreglos triangulares (o el tercer lema de Le Cam) se obtiene

$$\mathcal{S}_n = n^{-1/2} S(\theta_0) \xrightarrow{d} N(\mathcal{I}h, \mathcal{I}),$$

por lo que $LM = \mathcal{S}'_n \mathcal{I}^{-1} \mathcal{S}_n \rightarrow_d \chi_p^2(\delta)$, una χ^2 **no central** con parámetro de no centralidad $\delta = h' \mathcal{I} h$. La idea del cálculo: bajo θ_n , $\mathbb{E}[\mathcal{S}_n] = \sqrt{n} \mathbb{E}_{\theta_n}[s(w; \theta_0)]$, y la función $\theta \mapsto \mathbb{E}_{\theta}[s(w; \theta_0)] = \int s(w; \theta_0) f(w; \theta) dw$ vale cero en θ_0 y tiene derivada $\int s s' f = \mathcal{I}$ ahí. Luego $\mathbb{E}_{\theta_n}[s(w; \theta_0)] \approx \mathcal{I}h/\sqrt{n}$ y $\mathbb{E}[\mathcal{S}_n] \rightarrow \mathcal{I}h$. Como W y LR difieren de LM en $o_p(1)$ también bajo la secuencia local (contigüidad), los tres tienen la misma $\chi_p^2(\delta)$. **Los tres tests son localmente igual de potentes.** ¿Son además los mejores? Con $p = 1$ y alternativa bilateral, sí: en el experimento límite gaussiano son el test más potente entre los insesgados (Neyman–Pearson). Con $p > 1$ no existe un test uniformemente más potente contra todas las direcciones h , y la optimalidad de la trinidad es más modesta: es la más potente entre los tests cuya potencia depende de h solo a través de $h' \mathcal{I} h$. Las diferencias entre ellos son de orden superior, y es el terreno de la teoría de Edgeworth.

7. Resumen

- W mira la **distancia** $h(\hat{\theta})$, LR la **altura** perdida, LM la **pendiente** en el restringido. Los tres $\rightarrow \chi_q^2$ bajo H_0 (Teorema 2.1).
- La demostración es una sola idea: la log-verosimilitud es localmente una **parábola** con curvatura $n\mathcal{I}$.

- En el modelo lineal normal, $W = n(x - 1)$, $LR = n \log x$, $LM = n(1 - 1/x)$, con $W \geq LR \geq LM$ (Teorema 3.1).
- $LM = nR_u^2$ de una regresión auxiliar de unos sobre los scores restringidos (Proposición 4.1).
- El **Wald** no es invariante a reparametrizaciones; el **LR** sí, pero no tiene versión robusta.

8. Ejercicios

Ejercicio 3.1. Sea $w \sim \text{Bernoulli}(\theta)$ y $H_0 : \theta = \theta_0$. Calcula W , LR y LM (usa $\mathcal{I}(\theta) = 1/[\theta(1 - \theta)]$). ¿Dónde se evalúa la información en cada uno?

Solución 3.1

Con $\hat{\theta} = \bar{w}$:

$$W = n \frac{(\bar{w} - \theta_0)^2}{\bar{w}(1 - \bar{w})} \text{ (información en } \hat{\theta}\text{)}.$$

$$LM = n \frac{(\bar{w} - \theta_0)^2}{\theta_0(1 - \theta_0)} \text{ (score } S(\theta_0) = n(\bar{w} - \theta_0)/[\theta_0(1 - \theta_0)], \text{ información en } \theta_0; LM = \frac{1}{n} S^2/\mathcal{I}\text{)}.$$

$$LR = 2n \left[\bar{w} \log \frac{\bar{w}}{\theta_0} + (1 - \bar{w}) \log \frac{1 - \bar{w}}{1 - \theta_0} \right].$$

El numerador es el mismo en W y LM ; solo cambia la varianza del denominador: *estimada* en Wald (más chica si $\bar{w}$ está lejos de θ_0 hacia los extremos), *bajo* H_0 en LM. Este LM es el test z clásico de una proporción, que usa la varianza bajo la nula.

Ejercicio 3.2. En un modelo lineal normal con $n = 50$ y $x = \text{SCR}_R/\text{SCR}_{NR} = 1,2$, calcula W , LR y LM y comprueba el orden. Con $q = 1$ y un valor crítico $\chi_{1,0,95}^2 = 3,84$, ¿qué concluyes? ¿Y con $q = 2$ y crítico 5,99?

Solución 3.2

$W = 50(0,2) = 10$; $LR = 50 \log 1,2 = 50(0,1823) = 9,12$; $LM = 50(1 - 1/1,2) = 50(0,1667) = 8,33$. Orden: $10 > 9,12 > 8,33$. Los tres superan 3,84 y 5,99: se rechaza H_0

con cualquiera. La diferencia entre ellos se haría relevante si el estadístico estuviera cerca del crítico. Con $n = 20$ y el mismo x : $W = 4$, $LR = 3,65$, $LM = 3,33$: el Wald rechaza (para $q = 1$) y el LR y LM no.

Ejercicio 3.3. (No invarianza del Wald.) Sea w exponencial con tasa θ ($\mathbb{E}[w] = 1/\theta$), y la hipótesis $H_0 : \theta = 1$, que es equivalente a $H_0 : \mu = 1$ con $\mu = 1/\theta$. Calcula el Wald en cada parametrización y el LR. Evalúa para $n = 100$, $\bar{w} = 2$.

Solución 3.3

Del Ejercicio 1.2: $\hat{\theta} = 1/\bar{w}$ y $\text{Avar}(\hat{\theta}) = \theta^2$, estimada con $\hat{\theta}^2 = 1/\bar{w}^2$. $W_\theta = n(\hat{\theta} - 1)^2/\hat{\theta}^2 = n(1 - \bar{w})^2$. Para μ : $\hat{\mu} = \bar{w}$ y $\text{Avar}(\hat{\mu}) = \text{Var}(w) = \mu^2$, estimada con $\bar{w}^2$. $W_\mu = n(\bar{w} - 1)^2/\bar{w}^2$. Con $n = 100$ y $\bar{w} = 2$: $W_\theta = 100$ y $W_\mu = 100/4 = 25$. **La misma hipótesis, distintos estadísticos** (100 vs 25). LR: $\ell(\theta) = n(\log \theta - \theta \bar{w})$, $\ell(\hat{\theta}) = n(\log 0,5 - 1) = -1,693n$, $\ell(1) = -2n$, $LR = 2(0,307)(100) = 61,4$, único, porque no depende de la parametrización. El LR cae entre los dos Wald.

Ejercicio 3.4. Para el modelo lineal normal con $H_0 : \beta_2 = 0$, demuestra que el LM (con información esperada) es igual a $n \cdot R^2$ de regresar los **residuos restringidos** $\tilde{u}$ sobre todos los regresores X .

Solución 3.4

Del Teorema 3.1: $LM = \tilde{u}' P_X \tilde{u} / \tilde{\sigma}^2$ con $\tilde{\sigma}^2 = \tilde{u}' \tilde{u} / n$. Entonces $LM = n \frac{\tilde{u}' P_X \tilde{u}}{\tilde{u}' \tilde{u}}$, que es la suma explicada sobre la suma total (no centrada) de la regresión de $\tilde{u}$ sobre X : $LM = nR_u^2$. Si el modelo incluye constante, $\tilde{u}$ tiene media cero y el R_u^2 coincide con el R^2 usual. La misma receta “ nR^2 de una regresión auxiliar” da el test de Breusch–Godfrey (agregando rezagos de $\tilde{u}$ como regresores) y, con $\tilde{u}^2$ como variable dependiente, el de Breusch–Pagan (Clase 9 de Econometría 1).

Ejercicio 3.5. Muestra que si ℓ_n es exactamente cuadrática en θ (modelo lineal normal con σ^2 **conocida**) y la restricción es lineal,

entonces $W = LR = LM$ **exactamente**, en cualquier n .

💡 Solución 3.5

Con σ^2 conocida, $\ell_n(\beta) = c - \frac{1}{2\sigma^2} \|y - X\beta\|^2$, cuadrática con hessiano constante $-X'X/\sigma^2$. Las expansiones de Taylor del proof del Teorema 2.1 no tienen resto, así que valen con igualdad. Por ejemplo, $LR = 2[\ell(\hat{\beta}) - \ell(\tilde{\beta})] = (SCR_R - SCR_{NR})/\sigma^2$, y $W = (R\hat{\beta} - r)'[\sigma^2 R(X'X)^{-1}R']^{-1}(R\hat{\beta} - r) = (SCR_R - SCR_{NR})/\sigma^2$ por la identidad de la Clase 5 de Econometría 1. Igual con LM. La diferencia entre los tres en el Teorema 3.1 proviene únicamente de que σ^2 se estima, de distinta manera en cada uno.

Ejercicio 3.6. ¿Por qué el LR no es válido si el modelo está mal especificado? ¿Qué distribución tiene en lugar de χ_q^2 ?

💡 Solución 3.6

La demostración de $LR \approx W$ usó que la curvatura de ℓ_n ($-A$) y la varianza del score (B) coinciden: $\hat{\theta} - \theta^* \approx -A^{-1}\mathcal{S}_n$ con $\mathcal{S}_n \sim N(0, B)$, mientras que $LR \approx n(\hat{\theta} - \theta^*)'(-A)(\hat{\theta} - \theta^*) = \mathcal{S}_n'(-A)^{-1}\mathcal{S}_n$. Con $\mathcal{S}_n = B^{1/2}z$, $z \sim N(0, I)$, queda $z'B^{1/2}(-A)^{-1}B^{1/2}z = \sum_j \lambda_j z_j^2$, una **combinación ponderada de χ_1^2** con pesos λ_j los valores propios de $(-A)^{-1}B$. Es una χ_q^2 solo si todos los $\lambda_j = 1$, o sea $B = -A$. Existen correcciones (Rothschild-Jewell, Satorra-Bentler) que reescalan el LR, pero no es tan simple como “usar errores robustos”.

Ejercicio 3.7 ★. Considera $\theta \in \mathbb{R}$ y $H_0 : \theta = 0$ con la alternativa unilateral $\theta > 0$. ¿Qué cambia si el parámetro está en la frontera del espacio ($\Theta = [0, \infty)$ y $H_0 : \theta = 0$)? Describe la distribución asintótica del LR y la corrección al valor crítico.

💡 Solución 3.7 ★

Si $\theta_0 = 0$ está en la frontera, $\sqrt{n}\hat{\theta} \rightarrow_d \max\{0, Z\}$ con $Z \sim N(0, \mathcal{I}^{-1})$ (el estimador queda pegado a 0 cuando el MV sin restricciones sería negativo, lo que ocurre con probabilidad 1/2). El LR converge a $\max\{0, Z'\}^2$, con $Z' \sim N(0, 1)$:

una mezcla $\frac{1}{2}\chi_0^2 + \frac{1}{2}\chi_1^2$ (χ_0^2 es una masa en cero). Entonces $P(LR > c) = \frac{1}{2}P(\chi_1^2 > c)$. Para tamaño 5 % el crítico es el cuantil 0,90 de la χ_1^2 , igual a 2,71, **no** 3,84. Usar el crítico habitual de χ_1^2 da un test conservador (tamaño real 2,5 %). Es la situación típica de un test de varianza cero de un efecto aleatorio (Clase 9). (Chernoff, 1954; Self y Liang, 1987.)