

Clase 5 · Elección discreta I

Probit, logit y efectos marginales

Contenido

1	Una variable que solo dice sí o no	2
2	El modelo de variable latente	2
2.1	La escala no está identificada	3
3	Estimación por máxima verosimilitud	3
3.1	Distribución asintótica	5
4	Efectos marginales	6
4.1	Errores estándar por el método delta	7
5	Tres trampas de interpretación	7
5.1	Trampa 1: los coeficientes dependen de qué más incluyas	7
5.2	Trampa 2: el modelo mal especificado es inconsistente	8
5.3	Trampa 3: términos de interacción	8
6	¿Y el modelo lineal?	9
7	Ajuste y comparación	9
8	★ Postgrado: concavidad del probit	9
9	Resumen	10
10	Ejercicios	11

1. Una variable que solo dice sí o no

Muchas decisiones económicas son binarias: trabajar o no, comprar o no, caer en mora o no. Sea $y \in \{0, 1\}$. Como y solo toma dos valores, su distribución condicional queda completamente determinada por una cosa:

$$\mathbb{E}[y \mid x] = P(y = 1 \mid x) =: p(x).$$

La CEF es la probabilidad. Y como y es Bernoulli con parámetro $p(x)$, la varianza condicional también es función de $p(x)$:

$$\text{Var}(y \mid x) = p(x)(1 - p(x)).$$

Esto nos dice dos cosas sobre el **modelo de probabilidad lineal** (MPL, $p(x) = x'\beta$ estimado por MCO). Primero, es *necesariamente heterocedástico* (salvo que p sea constante), así que hay que usar errores robustos. Segundo, nada obliga a $x'\beta$ a quedar entre 0 y 1: para valores extremos de x las predicciones son “probabilidades” de $-0,2$ o $1,3$. Buscamos un modelo con $p(x) \in (0, 1)$ siempre.

2. El modelo de variable latente

La respuesta estándar viene de la teoría de la decisión. Hay una **utilidad neta latente** y^* que no observamos, y observamos solo su signo:

$$y^* = x'\beta + \varepsilon, \quad y = \mathbf{1}\{y^* > 0\}, \quad \varepsilon \mid x \sim F,$$

con F una función de distribución continua y simétrica alrededor de cero. Entonces

$$P(y = 1 \mid x) = P(\varepsilon > -x'\beta \mid x) = 1 - F(-x'\beta) = F(x'\beta), \quad (1)$$

usando la simetría de F . Dos elecciones de F dan los dos modelos clásicos:

Modelo	$F(\eta)$	Densidad $f(\eta)$
Probit	$\Phi(\eta)$ (normal estándar)	$\phi(\eta)$
Logit	$\Lambda(\eta) = \frac{e^\eta}{1 + e^\eta}$ (logística)	$\Lambda(\eta)(1 - \Lambda(\eta))$

Ambas son curvas en S: crecientes, simétricas, con límites 0 y 1. Se parecen tanto que en la práctica es difícil distinguirlas con datos; la logística tiene colas algo más gordas.¹

2.1. La escala no está identificada

Hay una sutileza que no existe en MCO. Si $\varepsilon \sim N(0, \sigma^2)$ en lugar de $N(0, 1)$, entonces $P(y = 1 \mid x) = P(\varepsilon/\sigma > -x'\beta/\sigma) = \Phi(x'\beta/\sigma)$. Los datos solo dependen de β/σ .

Proposición 2.1 (Normalización de escala). *En el modelo $y^* = x'\beta + \varepsilon$, $y = \mathbf{1}\{y^* > 0\}$, los parámetros (β, σ) no están identificados por separado: solo se identifica β/σ . Por eso se **normaliza** $\sigma = 1$ (probit) o la varianza de ε a la de la logística, $\pi^2/3$ (logit).*

La razón es que *multiplicar y^* por una constante positiva no cambia $\mathbf{1}\{y^* > 0\}$* . Las β de un probit están en “unidades de desviación estándar del error”, y las de un logit en “unidades de la logística” ($\sqrt{\pi^2/3} \approx 1,81$ desviaciones estándar). De ahí la regla empírica $\hat{\beta}_{\text{logit}} \approx 1,6 \hat{\beta}_{\text{probit}}$ (Amemiya sugiere 1,6 por ajuste de las curvas; 1,81 sería el cociente exacto de desviaciones estándar). **Los coeficientes de un probit y de un logit no son comparables directamente**, ni tampoco entre dos probits con distintas variables incluidas (más sobre esto abajo).

¹ “Probit” viene de *probability unit*, acuñado por Chester Bliss (1934) para analizar la mortalidad de insectos expuestos a pesticidas en distintas dosis. Dudamos que los insectos hayan sido consultados. “Logit” lo acuñó Joseph Berkson (1944) por analogía. Berkson defendió el logit frente al probit durante décadas, aunque en la práctica los dos dan casi lo mismo.

3. Estimación por máxima verosimilitud

La observación i es Bernoulli con parámetro $F(x'_i\beta)$, así que

$$\ell_n(\beta) = \sum_{i=1}^n \left[y_i \log F(x'_i\beta) + (1 - y_i) \log (1 - F(x'_i\beta)) \right].$$

Derivando, el **score** de una observación es

$$s_i(\beta) = \frac{y_i - F(x'_i\beta)}{F(x'_i\beta)(1 - F(x'_i\beta))} f(x'_i\beta) x_i. \quad (2)$$

(Se obtiene derivando $y \log F + (1 - y) \log(1 - F)$ respecto de $\eta = x'\beta$ y multiplicando por $\partial\eta/\partial\beta = x$.) La condición de primer orden $\sum_i s_i(\hat{\beta}) = 0$ **no tiene solución en forma cerrada**: se resuelve numéricamente (Newton–Raphson). Y aquí aparece una sorpresa para el logit: como $f = F(1 - F)$, el score se simplifica a

$$s_i^{\text{logit}}(\beta) = (y_i - \Lambda(x'_i\beta))x_i,$$

las “ecuaciones normales” de MCO con $\Lambda(x'\beta)$ como valor ajustado. Los residuos $y_i - \hat{p}_i$ son ortogonales a los regresores. (Ejercicio 5.3.)

Teorema 3.1 (Concavidad del logit). *La log-verosimilitud del logit es **globalmente cóncava**: su hessiano es*

$$\nabla^2 \ell_n(\beta) = - \sum_{i=1}^n \Lambda(x'_i\beta)(1 - \Lambda(x'_i\beta))x_i x'_i,$$

que es definido negativo para todo β si $X'X$ es invertible. Por lo tanto, si el MV existe es **único**, y Newton–Raphson converge desde cualquier punto de partida razonable.

Demostración. Derivando el score del logit respecto de β' : $\partial[(y_i - \Lambda(x'_i\beta))x_i]/\partial\beta' = -\Lambda'(x'_i\beta)x_i x'_i$ y $\Lambda' = \Lambda(1 - \Lambda) \in (0, \frac{1}{4}]$. Para cualquier $a \neq 0$,

$$a' \nabla^2 \ell_n(\beta) a = - \sum_i \Lambda_i(1 - \Lambda_i)(x'_i a)^2 < 0$$

porque los pesos son estrictamente positivos y no todos los $x'_i a$ son cero (pues $X'X$ es invertible, $Xa \neq 0$). Una función con hessiano definido negativo en todas partes es estrictamente cóncava, y tiene a lo más un máximo. $\square$

El probit también es globalmente cóncavo (porque Φ y $1 - \Phi$ son log-cóncavas; Ejercicio 5.7), así que ninguno de los dos presenta problemas de máximos locales. Eso no es cierto para los modelos de elección más complejos (Clase 6).

⚠ El MV puede no existir: separación

Si existe β con $x'_i\beta > 0$ cuando $y_i = 1$ y $x'_i\beta < 0$ cuando $y_i = 0$ para **todo** i (las dos clases están separadas por un hiperplano), la verosimilitud crece sin límite al escalar $\beta \rightarrow c\beta, c \rightarrow \infty$: el máximo se “escapa al infinito”. Los programas reportan coeficientes enormes y errores estándar absurdos, o un aviso de “separación perfecta”. Suele ocurrir con una dummy rara que predice perfectamente. Es un problema de **existencia**, no de identificación (Ejercicio 5.4).

3.1. Distribución asintótica

Aplicamos las Clases 1 y 2 con $m = \log f(y | x; \beta)$ (la verosimilitud condicional; la distribución marginal de x no depende de β y se cancela). La información es $\mathcal{I} = \mathbb{E}[s s']$. Condicional en $x, y - F$ tiene media cero y varianza $F(1 - F)$, así que

$$\mathbb{E}[s s' | x] = \frac{\text{Var}(y | x) f^2}{F^2(1 - F)^2} x x' = \frac{f(x'\beta)^2}{F(x'\beta)(1 - F(x'\beta))} x x'.$$

Teorema 3.2 (Normalidad asintótica de probit y logit). *Con el modelo bien especificado, $\mathbb{E}\|x\|^2 < \infty$, $\mathbb{E}[x x']$ definida positiva y β_0 en el interior,*

$$\sqrt{n}(\hat{\beta} - \beta_0) \xrightarrow{d} N(0, \mathcal{I}^{-1}), \quad \mathcal{I} = \mathbb{E}\left[\frac{f(x'\beta_0)^2}{F(x'\beta_0)(1 - F(x'\beta_0))} x x'\right].$$

Para el logit, $\mathcal{I} = \mathbb{E}[\Lambda(x'\beta_0)(1 - \Lambda(x'\beta_0)) x x']$.

Demostración. Es el resultado de la Clase 2 (MV bien especificado). Para el logit, la concavidad global del Teorema 3.1 evita pedir compacidad (Ejercicio 1.7 de la Clase 1). La expresión de $\mathcal{I}$ es la que acabamos de calcular, y para el logit $f = F(1 - F)$ simplifica $f^2/[F(1 - F)] = F(1 - F)$. $\square$

En la práctica, $\widehat{\text{Avar}}(\hat{\beta}) = [\sum_i \hat{w}_i x_i x'_i]^{-1}$ con pesos $\hat{w}_i = f(x'_i \hat{\beta})^2 / [\hat{F}_i(1 - \hat{F}_i)]$. Es una “MCP” donde los pesos son mayores para las observaciones con probabilidad predicha cercana a 0,5 (que son las más informativas: una observación con $p \approx 0,99$ casi no tiene incertidumbre sobre y y por lo tanto casi no informa).

4. Efectos marginales

El coeficiente β_j **no** es el efecto de x_j sobre la probabilidad: eso solo es cierto en el modelo lineal. Como $p(x) = F(x'\beta)$ es no lineal,

$$\frac{\partial P(y = 1 | x)}{\partial x_j} = f(x'\beta) \beta_j. \quad (3)$$

Tres cosas importantes. (i) El **signo** del efecto marginal coincide con el de β_j (porque $f > 0$). (ii) La **magnitud** depende de x a través de $f(x'\beta)$: es máxima cuando $x'\beta = 0$ ($p = 0,5$, donde la densidad es la más alta) y se achica en las colas. (iii) Para una variable binaria d , el efecto es una **diferencia discreta** $F(x'\beta + \beta_d) - F(x'\beta)$, no una derivada.

Como el efecto depende de x , hay que elegir **dónde** evaluarlo:

- **Efecto marginal promedio (AME):** $\widehat{AME}_j = \hat{\beta}_j \cdot \frac{1}{n} \sum_i f(x'_i \hat{\beta})$. Responde: ¿cuál es el efecto promedio sobre la población? Es el que más se parece al coeficiente de un MPL.
- **Efecto marginal en la media (MEM):** $f(\bar{x}' \hat{\beta}) \hat{\beta}_j$. Evalúa en un individuo “promedio”, que puede no existir (¿cuál es la proporción promedio de mujeres?).
- **Efecto marginal en un valor representativo:** para el caso o escenario que interesa.

El AME es lo que suele recomendarse: no depende de inventar un individuo ficticio.

Ejemplo 4.1 (Un ejemplo numérico). Sea $P(y = 1 | x) = F(-1 + 0,5x)$ y evaluamos en $x = 2$, donde el índice vale $\eta = 0$. En el **logit**, $f(0) = \Lambda(0)(1 - \Lambda(0)) = 0,25$ y el efecto es $0,25 \times 0,5 = 0,125$: un punto más de x sube la probabilidad en 12,5 puntos porcentuales. En el **probit** con los mismos coeficientes, $f(0) = \phi(0) \approx 0,399$ y el efecto sería 0,199. Pero los coeficientes no son comparables: un probit con $\beta_{\text{probit}} \approx \beta_{\text{logit}}/1,6$ tendría $0,399 \times 0,5/1,6 \approx 0,125$: **los efectos marginales de logit y probit casi coinciden**, aunque los coeficientes difieran en un factor 1,6. Por eso conviene comparar efectos marginales y no coeficientes.

4.1. Errores estándar por el método delta

Los efectos marginales son funciones de $\hat{\beta}$, así que su varianza se obtiene con el método delta (Clase 6 de Econometría 1). Para $ME_j(x) = f(x'\beta)\beta_j$, el gradiente respecto de β es

$$\frac{\partial ME_j(x)}{\partial \beta} = f(x'\beta) e_j + \beta_j f'(x'\beta) x,$$

con e_j el j -ésimo vector canónico. En el probit, $f' = \phi' = -\eta\phi$; en el logit, $f' = f(1 - 2\lambda)$. Entonces $\widehat{Var}(\widehat{ME}_j(x)) = \hat{D}' \widehat{Avar}(\hat{\beta}) \hat{D}$, donde $\hat{D}$ es el gradiente evaluado en $\hat{\beta}$.

Para el AME hay una sutileza: el promedio sobre la muestra tiene dos fuentes de variación (la de $\hat{\beta}$ y la de los x_i mismos). El tratamiento correcto estima todo en un solo sistema de momentos (GMM de la Clase 4 con los momentos del score y el del promedio). En muestras grandes y con $\hat{\beta}$ dominando, el delta sobre $\hat{\beta}$ con x_i fijos es una buena aproximación.

5. Tres trampas de interpretación

5.1. Trampa 1: los coeficientes dependen de qué más incluyas

En un modelo lineal, agregar un regresor ortogonal a x_1 no cambia el coeficiente de x_1 . En un probit **sí lo cambia**, aunque el regresor omitido sea independiente de x_1 .

Proposición 5.1 (Atenuación por heterogeneidad omitida). Sea $y^* = \beta_1 x_1 + \beta_2 x_2 + \varepsilon$, con $\varepsilon \sim N(0, 1)$, $x_2 \sim N(0, \tau^2)$, y (x_1, ε, x_2) independientes entre sí. Si se estima un probit de y sobre x_1 **sin** x_2 , el estimador converge a

$$\beta_1^\dagger = \frac{\beta_1}{\sqrt{1 + \beta_2^2 \tau^2}},$$

que es menor en valor absoluto que β_1 si $\beta_2 \neq 0$.

Demostración. Sin x_2 , el error compuesto es $\varepsilon + \beta_2 x_2 \sim N(0, 1 + \beta_2^2 \tau^2)$, independiente de x_1 . Entonces $P(y = 1 \mid x_1) = P(\varepsilon + \beta_2 x_2 > -\beta_1 x_1) = \Phi(\beta_1 x_1 / \sqrt{1 + \beta_2^2 \tau^2})$, que es un probit con coeficiente $\beta_1^\dagger$. Como ese modelo reducido está bien especificado, el probit converge a $\beta_1^\dagger$ (Clase 2). $\square$

Esto es la Proposición 2.1 en acción: agregar x_2 reduce la varianza del error residual y por lo tanto “reescala” los coeficientes. **No puedes comparar coeficientes entre modelos probit con distintos controles** ni, con más razón, entre grupos con distintas varianzas de ε (mismo modelo, dos países: ¿los coeficientes difieren por diferencias reales o por distinta varianza residual?). Esto obliga a comparar *efectos marginales*, que sí están en unidades de probabilidad.

5.2. Trampa 2: el modelo mal especificado es inconsistente

En MCO, una CEF no lineal igual deja un coeficiente de proyección con sentido (Clase 2 de Econometría 1). En probit, **no**: si ε es heterocedástico (por ejemplo, $\varepsilon \mid x \sim N(0, \sigma(x)^2)$), entonces $P(y = 1 \mid x) = \Phi(x' \beta / \sigma(x)) \neq \Phi(x' \beta)$ y el estimador de MV converge al pseudo-verdadero de la Clase 2, que no es β ni tiene interpretación estructural. Es la diferencia fundamental entre estimadores cuyo sentido sobrevive (MCO, Poisson) y los que no (probit, logit). Se puede testear con un LM (Clase 3): probit heterocedástico $\Phi(x' \beta / \exp(z' \gamma))$ y $H_0 : \gamma = 0$.

5.3. Trampa 3: términos de interacción

En un modelo lineal, el coeficiente de la interacción $x_1 x_2$ **es** el efecto cruzado. En un modelo no lineal, el efecto cruzado $\partial^2 p / \partial x_1 \partial x_2$ **no** es $\beta_{12} f(\cdot)$: incluye además términos como $\beta_1 \beta_2 f'(\cdot)$, que no se anulan aunque $\beta_{12} = 0$ (Ai y Norton, 2003). Un efecto cruzado puede ser distinto de cero, y hasta cambiar de signo según x , sin que el coeficiente de interacción lo diga.

6. ¿Y el modelo lineal?

Con todo esto, ¿para qué usar MPL? Porque (a) si los regresores son **saturados** (todas las variables son dummies y se incluyen todas las interacciones), la CEF es lineal *por construcción* y el MPL reproduce $p(x)$ exactamente; (b) con regresores continuos, el MPL estima la mejor aproximación lineal a $p(x)$ (el coeficiente de proyección, Clase 2 de Econometría 1), y suele dar efectos marginales promedio muy parecidos a los del probit; (c) no tiene problemas de existencia, ni de escala, ni de interacción. Angrist y Pischke (2009) lo recomiendan de partida. Por otro lado, es un mal predictor de probabilidades individuales (sale de $[0, 1]$) y poco confiable con p cerca de 0 o de 1 (eventos raros). La elección entre MPL y probit/logit **no es de corrección** sino de qué cantidad te interesa y qué tan lejos de $[0, 1]$ viven tus datos.

7. Ajuste y comparación

El análogo del R^2 es el **pseudo- R^2 de McFadden**, $1 - \ell_n(\hat{\beta})/\ell_n(\hat{\beta}_0)$, con $\hat{\beta}_0$ el modelo con solo constante. No es una proporción de varianza explicada: valores de 0,2 a 0,4 se consideran un muy buen ajuste. Para testear hipótesis sobre β se usa la trinidad de la Clase 3: el LR compara el modelo completo contra el restringido, y el LM permite testear variables omitidas sin estimarlas. Las **tablas de clasificación** (porcentaje de aciertos con regla $\hat{p} > 0,5$) son malas: un modelo que siempre predice “0” acierta 90 % si 90 % son ceros. Mejor evaluar la calibración y el área bajo la curva ROC.

8. ★ Postgrado: concavidad del probit

! ★ Postgrado

Demostramos que ℓ_n del probit es cóncava. Una función F tal que $\log F$ y $\log(1 - F)$ son cóncavas garantiza la concavidad de ℓ_n .

Proposición 8.1 (Concavidad de la log-verosimilitud con F log-cóncava). Si $\log F$ y $\log(1 - F)$ son funciones cóncavas de η , entonces $\ell_n(\beta)$ es cóncava en β . Si además son estrictamente cóncavas, ℓ_n lo es (dado que $X'X$ es invertible).

Demostración. $\ell_n(\beta) = \sum_i [y_i \log F(x_i'\beta) + (1 - y_i) \log(1 - F(x_i'\beta))]$ es una suma de funciones de la forma $\psi_i(x_i'\beta)$, con $\psi_i = \log F$ o $\log(1 - F)$ según y_i . La composición de una función cóncava con una función lineal (afín) es cóncava, y una suma de cóncavas es cóncava. Si cada ψ_i es estrictamente cóncava y $Xa \neq 0$ para $a \neq 0$, la suma lo es estrictamente. $\square$

Para el probit: $\log \Phi$ es cóncava, pues $(\log \Phi)'' = \lambda'(\eta)$ con $\lambda = \phi/\Phi$ la razón inversa de Mills, que cumple $\lambda'(\eta) = -\lambda(\eta)(\eta + \lambda(\eta)) < 0$ (se sigue de $\Phi(\eta) < -\phi(\eta)/\eta$ para $\eta < 0$, la desigualdad de Mills; Ejercicio 5.7). Como $1 - \Phi(\eta) = \Phi(-\eta)$, $\log(1 - \Phi)$ también es cóncava. En el logit, $(\log \Lambda)'' = -\Lambda(1 - \Lambda) < 0$ y $(\log(1 - \Lambda))'' = -\Lambda(1 - \Lambda) < 0$, lo que reproduce el Teorema 3.1.

9. Resumen

- En un modelo binario la CEF es la probabilidad: $p(x) = F(x'\beta)$ con F una distribución simétrica (normal: probit; logística: logit). Sale de un modelo de variable latente.
- La **escala** no está identificada: ε se normaliza, y los coeficientes están en unidades arbitrarias (Proposición 2.1).
- El MV se resuelve numéricamente; el logit tiene score $\sum(y - \Lambda)x$ y es **globalmente cóncavo** (Teorema 3.1); puede no existir si hay separación perfecta.
- $\sqrt{n}(\hat{\beta} - \beta) \rightarrow N(0, \mathcal{I}^{-1})$ (Teorema 3.2).
- Los **efectos marginales** $f(x'\beta)\beta_j$ dependen de x ; reporta AME o MEM con errores estándar por método delta. Comparar efectos marginales, no coeficientes.
- **Trampas:** coeficientes que cambian con los controles (Proposición 5.1), inconsistencia bajo heterocedasticidad, interacciones.

10. Ejercicios

Ejercicio 5.1. Muestra que en el modelo de variable latente con $\varepsilon \sim N(0, 1)$ simétrica, $P(y = 1 | x) = \Phi(x'\beta)$, y que la verosimilitud de una observación es $\Phi(x'\beta)^y \Phi(-x'\beta)^{1-y}$.

Solución 5.1

$P(y = 1 | x) = P(x'\beta + \varepsilon > 0) = P(\varepsilon > -x'\beta) = 1 - \Phi(-x'\beta) = \Phi(x'\beta)$ por simetría. Luego $P(y = 0 | x) = 1 - \Phi(x'\beta) = \Phi(-x'\beta)$ y la función de probabilidad de y dado x es $\Phi(x'\beta)^y \Phi(-x'\beta)^{1-y}$ para $y \in \{0, 1\}$. Su log es $y \log \Phi(x'\beta) + (1 - y) \log \Phi(-x'\beta)$.

Ejercicio 5.2. En un logit con $\beta = (-1; 0,5)$ (constante, x), calcula el efecto marginal de x en $x = 0$ y en $x = 4$ y compara con el efecto en $x = 2$ (calculado en el Ejemplo 4.1). ¿Qué patrón ves?

Solución 5.2

En $x = 0$: $\eta = -1$, $\Lambda(-1) = 0,2689$, $f = 0,2689 \times 0,7311 = 0,1966$, efecto = $0,1966 \times 0,5 = 0,098$. En $x = 4$: $\eta = 1$, $\Lambda(1) = 0,7311$, $f = 0,1966$, efecto $0,098$ (simetría). En $x = 2$: $0,125$. El efecto es **máximo en el centro** ($p = 0,5$) y se achica hacia las colas, de forma simétrica. Un mismo coeficiente $\beta_x = 0,5$ produce efectos marginales de 9,8 a 12,5 puntos porcentuales según el punto donde se evalúe.

Ejercicio 5.3. En un logit con constante entre los regresores, demuestra que $\sum_i \hat{p}_i = \sum_i y_i$ (la probabilidad predicha promedio coincide con la proporción muestral de unos). Si hay una dummy d_i , ¿qué más se cumple?

Solución 5.3

Las CPO del logit son $\sum_i (y_i - \hat{p}_i)x_i = 0$. La fila correspondiente a la constante da $\sum_i (y_i - \hat{p}_i) = 0$. La fila de la dummy da $\sum_i (y_i - \hat{p}_i)d_i = 0$: en el grupo $d = 1$, la suma de probabilidades predichas es igual a la suma de y . Más en general, **para todo regresor incluido, los residuos $y - \hat{p}$ son or-**

ortogonales a él. Esta propiedad no la tiene el probit.

Ejercicio 5.4. (Separación.) Sea x escalar sin constante, con datos (x_i, y_i) tales que $y_i = 1$ si y solo si $x_i > 0$. Muestra que el logit no tiene MV finito.

 Solución 5.4

Para cada i , $y_i \log \Lambda(\beta x_i) + (1 - y_i) \log(1 - \Lambda(\beta x_i))$: si $x_i > 0$ ($y_i = 1$), el término es $\log \Lambda(\beta x_i)$, creciente en β y que tiende a 0 cuando $\beta \rightarrow \infty$; si $x_i < 0$ ($y_i = 0$), es $\log(1 - \Lambda(\beta x_i)) = \log \Lambda(-\beta x_i)$, también creciente en β (porque $-\beta x_i > 0$ crece con β) y con límite 0. Cada término es estrictamente creciente en β y acotado por cero: $\ell_n(\beta) \uparrow 0$ cuando $\beta \rightarrow \infty$ sin alcanzarlo. El supremo no se alcanza. La separación es perfecta y el estimador “es” $+\infty$.

Ejercicio 5.5. Calcula el gradiente de $ME_j(x) = \phi(x'\beta)\beta_j$ del probit respecto de β y úsalo para dar la varianza del efecto marginal en x en términos de $Avar(\hat{\beta})$.

 Solución 5.5

Usando $\phi'(\eta) = -\eta\phi(\eta)$: $\frac{\partial ME_j}{\partial \beta} = \phi(x'\beta)e_j - (x'\beta)\phi(x'\beta)\beta_j x = \phi(x'\beta)[e_j - (x'\beta)\beta_j x]$. Con $D = \phi(x'\beta)[e_j - (x'\beta)\beta_j x]$, $Var(\hat{ME}_j) \approx D' Avar(\hat{\beta}) D/n$. En $x'\beta = 0$ el segundo término se anula y el gradiente es $\phi(0)e_j$: el error estándar del efecto marginal es $\phi(0) \cdot ee(\hat{\beta}_j) \approx 0,4 ee(\hat{\beta}_j)$.

Ejercicio 5.6. Dos grupos (hombres y mujeres) estiman el mismo probit de participación laboral y obtienen $\hat{\beta}_{educ} = 0,20$ y $0,30$, respectivamente. ¿Puedes concluir que la educación importa más para las mujeres?

 Solución 5.6

No directamente. Por la Proposición 2.1, cada coeficiente es β/σ_g con σ_g la desviación estándar del error latente en el

grupo g . Si el error de las mujeres tiene menor varianza ($\sigma_M < \sigma_H$), $\hat{\beta}/\sigma$ es mayor aun si β fuera igual. Hay que comparar **efectos marginales** (en unidades de probabilidad), o testear explícitamente heterocedasticidad entre grupos (Allison, 1999, propone el probit heterocedástico con σ_g libre).

Ejercicio 5.7 ★. Demuestra que $\lambda(\eta) = \phi(\eta)/\Phi(\eta)$ cumple $\lambda'(\eta) = -\lambda(\eta)(\eta + \lambda(\eta))$, y que $\log \Phi$ es cóncava si $\eta + \lambda(\eta) > 0$ para todo η .

💡 Solución 5.7 ★

$(\log \Phi)' = \phi/\Phi = \lambda$. $\lambda' = \frac{\phi'\Phi - \phi^2}{\Phi^2} = \frac{-\eta\phi\Phi - \phi^2}{\Phi^2} = -\lambda\eta - \lambda^2 = -\lambda(\eta + \lambda)$. Como $\lambda > 0$, la concavidad de $\log \Phi$ es equivalente a $\eta + \lambda(\eta) > 0$, es decir $\phi(\eta) > -\eta\Phi(\eta)$. Para $\eta \geq 0$ es trivial (el lado derecho es $\leq 0 < \phi$). Para $\eta < 0$, hay que probar $\Phi(\eta) < \phi(\eta)/|\eta|$, la **desigualdad de Mills**: $\Phi(\eta) = \int_{-\infty}^{\eta} \phi(t) dt$. Para $t < \eta < 0$ se cumple $t/\eta > 1$, así que $\int_{-\infty}^{\eta} \phi(t) dt < \frac{1}{\eta} \int_{-\infty}^{\eta} t \phi(t) dt = \frac{1}{\eta} [-\phi(\eta)] = \phi(\eta)/|\eta|$ (usando $\int t\phi(t) dt = -\phi(t)$). Luego $\Phi(\eta)|\eta| < \phi(\eta)$, o sea $\eta + \lambda(\eta) > 0$.