

# Clase 5 · Elección discreta I

## Probit, logit y efectos marginales

### Contenido

|           |                                                                   |           |
|-----------|-------------------------------------------------------------------|-----------|
| <b>1</b>  | <b>Una variable que solo dice sí o no</b>                         | <b>2</b>  |
| <b>2</b>  | <b>El modelo de variable latente</b>                              | <b>2</b>  |
| 2.1       | La escala no está identificada . . . . .                          | 3         |
| <b>3</b>  | <b>Estimación por máxima verosimilitud</b>                        | <b>3</b>  |
| 3.1       | Distribución asintótica . . . . .                                 | 5         |
| <b>4</b>  | <b>Efectos marginales</b>                                         | <b>6</b>  |
| 4.1       | Errores estándar por el método delta . . . . .                    | 7         |
| <b>5</b>  | <b>Tres trampas de interpretación</b>                             | <b>7</b>  |
| 5.1       | Trampa 1: los coeficientes dependen de qué más incluyas . . . . . | 7         |
| 5.2       | Trampa 2: el modelo mal especificado es inconsistente . . . . .   | 8         |
| 5.3       | Trampa 3: términos de interacción . . . . .                       | 8         |
| <b>6</b>  | <b>¿Y el modelo lineal?</b>                                       | <b>9</b>  |
| <b>7</b>  | <b>Ajuste y comparación</b>                                       | <b>9</b>  |
| <b>8</b>  | <b>★ Postgrado: concavidad del probit</b>                         | <b>9</b>  |
| <b>9</b>  | <b>Resumen</b>                                                    | <b>10</b> |
| <b>10</b> | <b>Ejercicios</b>                                                 | <b>11</b> |

## 1. Una variable que solo dice sí o no

Muchas decisiones económicas son binarias: trabajar o no, comprar o no, caer en mora o no. Sea  $y \in \{0, 1\}$ . Como  $y$  solo toma dos valores, su distribución condicional queda completamente determinada por una cosa:

$$\mathbb{E}[y \mid x] = P(y = 1 \mid x) =: p(x).$$

La CEF es la probabilidad. Y como  $y$  es Bernoulli con parámetro  $p(x)$ , la varianza condicional también es función de  $p(x)$ :

$$\text{Var}(y \mid x) = p(x)(1 - p(x)).$$

Esto nos dice dos cosas sobre el **modelo de probabilidad lineal** (MPL,  $p(x) = x'\beta$  estimado por MCO). Primero, es *necesariamente heterocedástico* (salvo que  $p$  sea constante), así que hay que usar errores robustos. Segundo, nada obliga a  $x'\beta$  a quedar entre 0 y 1: para valores extremos de  $x$  las predicciones son “probabilidades” de  $-0,2$  o  $1,3$ . Buscamos un modelo con  $p(x) \in (0, 1)$  siempre.

## 2. El modelo de variable latente

La respuesta estándar viene de la teoría de la decisión. Hay una **utilidad neta latente**  $y^*$  que no observamos, y observamos solo su signo:

$$y^* = x'\beta + \varepsilon, \quad y = \mathbf{1}\{y^* > 0\}, \quad \varepsilon \mid x \sim F,$$

con  $F$  una función de distribución continua y simétrica alrededor de cero. Entonces

$$P(y = 1 \mid x) = P(\varepsilon > -x'\beta \mid x) = 1 - F(-x'\beta) = F(x'\beta), \quad (1)$$

usando la simetría de  $F$ . Dos elecciones de  $F$  dan los dos modelos clásicos:

| Modelo        | $F(\eta)$                                               | Densidad $f(\eta)$                 |
|---------------|---------------------------------------------------------|------------------------------------|
| <b>Probit</b> | $\Phi(\eta)$ (normal estándar)                          | $\phi(\eta)$                       |
| <b>Logit</b>  | $\Lambda(\eta) = \frac{e^\eta}{1 + e^\eta}$ (logística) | $\Lambda(\eta)(1 - \Lambda(\eta))$ |

Ambas son curvas en S: crecientes, simétricas, con límites 0 y 1. Se parecen tanto que en la práctica es difícil distinguirlas con datos; la logística tiene colas algo más gordas.<sup>1</sup>

## 2.1. La escala no está identificada

Hay una sutileza que no existe en MCO. Si  $\varepsilon \sim N(0, \sigma^2)$  en lugar de  $N(0, 1)$ , entonces  $P(y = 1 \mid x) = P(\varepsilon/\sigma > -x'\beta/\sigma) = \Phi(x'\beta/\sigma)$ . Los datos solo dependen de  $\beta/\sigma$ .

**Proposición 2.1** (Normalización de escala). *En el modelo  $y^* = x'\beta + \varepsilon$ ,  $y = \mathbf{1}\{y^* > 0\}$ , los parámetros  $(\beta, \sigma)$  no están identificados por separado: solo se identifica  $\beta/\sigma$ . Por eso se **normaliza**  $\sigma = 1$  (probit) o la varianza de  $\varepsilon$  a la de la logística,  $\pi^2/3$  (logit).*

La razón es que *multiplicar  $y^*$  por una constante positiva no cambia  $\mathbf{1}\{y^* > 0\}$* . Las  $\beta$  de un probit están en “unidades de desviación estándar del error”, y las de un logit en “unidades de la logística” ( $\sqrt{\pi^2/3} \approx 1,81$  desviaciones estándar). De ahí la regla empírica  $\hat{\beta}_{\text{logit}} \approx 1,6 \hat{\beta}_{\text{probit}}$  (Amemiya sugiere 1,6 por ajuste de las curvas; 1,81 sería el cociente exacto de desviaciones estándar). **Los coeficientes de un probit y de un logit no son comparables directamente**, ni tampoco entre dos probits con distintas variables incluidas (más sobre esto abajo).

<sup>1</sup> “Probit” viene de *probability unit*, acuñado por Chester Bliss (1934) para analizar la mortalidad de insectos expuestos a pesticidas en distintas dosis. Dudamos que los insectos hayan sido consultados. “Logit” lo acuñó Joseph Berkson (1944) por analogía; Berkson defendió toda su vida que el logit era mejor que el probit, y la profesión se dividió durante años en dos bandos con la intensidad de los hinchas de fútbol, hasta que ambos descubrieron que daban casi lo mismo.

## 3. Estimación por máxima verosimilitud

La observación  $i$  es Bernoulli con parámetro  $F(x'_i\beta)$ , así que

$$\ell_n(\beta) = \sum_{i=1}^n \left[ y_i \log F(x'_i\beta) + (1 - y_i) \log (1 - F(x'_i\beta)) \right].$$

Derivando, el **score** de una observación es

$$s_i(\beta) = \frac{y_i - F(x'_i\beta)}{F(x'_i\beta)(1 - F(x'_i\beta))} f(x'_i\beta) x_i. \quad (2)$$

(Se obtiene derivando  $y \log F + (1 - y) \log(1 - F)$  respecto de  $\eta = x'\beta$  y multiplicando por  $\partial\eta/\partial\beta = x$ .) La condición de primer orden  $\sum_i s_i(\hat{\beta}) = 0$  **no tiene solución en forma cerrada**: se resuelve numéricamente (Newton–Raphson). Y aquí aparece una sorpresa para el logit: como  $f = F(1 - F)$ , el score se simplifica a

$$s_i^{\text{logit}}(\beta) = (y_i - \Lambda(x'_i\beta))x_i,$$

las “ecuaciones normales” de MCO con  $\Lambda(x'\beta)$  como valor ajustado. Los residuos  $y_i - \hat{p}_i$  son ortogonales a los regresores. (Ejercicio 5.3.)

**Teorema 3.1** (Concavidad del logit). *La log-verosimilitud del logit es **globalmente cóncava**: su hessiano es*

$$\nabla^2 \ell_n(\beta) = - \sum_{i=1}^n \Lambda(x'_i\beta)(1 - \Lambda(x'_i\beta))x_i x'_i,$$

*que es definido negativo para todo  $\beta$  si  $X'X$  es invertible. Por lo tanto, si el MV existe es **único**, y Newton–Raphson converge desde cualquier punto de partida razonable.*

*Demostración.* Derivando el score del logit respecto de  $\beta'$ :  $\partial[(y_i - \Lambda(x'_i\beta))x_i]/\partial\beta' = -\Lambda'(x'_i\beta)x_i x'_i$  y  $\Lambda' = \Lambda(1 - \Lambda) \in (0, \frac{1}{4}]$ . Para cualquier  $a \neq 0$ ,

$$a' \nabla^2 \ell_n(\beta) a = - \sum_i \Lambda_i(1 - \Lambda_i)(x'_i a)^2 < 0$$

porque los pesos son estrictamente positivos y no todos los  $x'_i a$  son cero (pues  $X'X$  es invertible,  $Xa \neq 0$ ). Una función con hessiano definido negativo en todas partes es estrictamente cóncava, y tiene a lo más un máximo.  $\square$

El probit también es globalmente cóncavo (porque  $\Phi$  y  $1 - \Phi$  son log-cóncavas; Ejercicio 5.7), así que ninguno de los dos presenta problemas de máximos locales. Eso no es cierto para los modelos de elección más complejos (Clase 6).

⚠ El MV puede no existir: separación

Si existe  $\beta$  con  $x'_i\beta > 0$  cuando  $y_i = 1$  y  $x'_i\beta < 0$  cuando  $y_i = 0$  para **todo**  $i$  (las dos clases están separadas por un hiperplano), la verosimilitud crece sin límite al escalar  $\beta \rightarrow c\beta, c \rightarrow \infty$ : el máximo se “escapa al infinito”. Los programas reportan coeficientes enormes y errores estándar absurdos, o un aviso de “separación perfecta”. Suele ocurrir con una dummy rara que predice perfectamente. Es un problema de **existencia**, no de identificación (Ejercicio 5.4).

### 3.1. Distribución asintótica

Aplicamos las Clases 1 y 2 con  $m = \log f(y | x; \beta)$  (la verosimilitud condicional; la distribución marginal de  $x$  no depende de  $\beta$  y se cancela). La información es  $\mathcal{I} = \mathbb{E}[s s']$ . Condicional en  $x, y - F$  tiene media cero y varianza  $F(1 - F)$ , así que

$$\mathbb{E}[s s' | x] = \frac{\text{Var}(y | x) f^2}{F^2(1 - F)^2} x x' = \frac{f(x'\beta)^2}{F(x'\beta)(1 - F(x'\beta))} x x'.$$

**Teorema 3.2** (Normalidad asintótica de probit y logit). *Con el modelo bien especificado,  $\mathbb{E}\|x\|^2 < \infty$ ,  $\mathbb{E}[x x']$  definida positiva y  $\beta_0$  en el interior,*

$$\sqrt{n}(\hat{\beta} - \beta_0) \xrightarrow{d} N(0, \mathcal{I}^{-1}), \quad \mathcal{I} = \mathbb{E}\left[\frac{f(x'\beta_0)^2}{F(x'\beta_0)(1 - F(x'\beta_0))} x x'\right].$$

Para el logit,  $\mathcal{I} = \mathbb{E}[\Lambda(x'\beta_0)(1 - \Lambda(x'\beta_0)) x x']$ .

*Demostración.* Es el resultado de la Clase 2 (MV bien especificado). Para el logit, la concavidad global del Teorema 3.1 evita pedir compacidad (Ejercicio 1.7 de la Clase 1). La expresión de  $\mathcal{I}$  es la que acabamos de calcular, y para el logit  $f = F(1 - F)$  simplifica  $f^2/[F(1 - F)] = F(1 - F)$ .  $\square$

En la práctica,  $\widehat{\text{Avar}}(\hat{\beta}) = [\sum_i \hat{w}_i x_i x'_i]^{-1}$  con pesos  $\hat{w}_i = f(x'_i \hat{\beta})^2 / [\hat{F}_i(1 - \hat{F}_i)]$ . Es una “MCP” donde los pesos son mayores para las observaciones con probabilidad predicha cercana a 0,5 (que son las más informativas: una observación con  $p \approx 0,99$  casi no tiene incertidumbre sobre  $y$  y por lo tanto casi no informa).

## 4. Efectos marginales

El coeficiente  $\beta_j$  **no** es el efecto de  $x_j$  sobre la probabilidad: eso solo es cierto en el modelo lineal. Como  $p(x) = F(x'\beta)$  es no lineal,

$$\frac{\partial P(y = 1 | x)}{\partial x_j} = f(x'\beta) \beta_j. \quad (3)$$

Tres cosas importantes. (i) El **signo** del efecto marginal coincide con el de  $\beta_j$  (porque  $f > 0$ ). (ii) La **magnitud** depende de  $x$  a través de  $f(x'\beta)$ : es máxima cuando  $x'\beta = 0$  ( $p = 0,5$ , donde la densidad es la más alta) y se achica en las colas. (iii) Para una variable binaria  $d$ , el efecto es una **diferencia discreta**  $F(x'\beta + \beta_d) - F(x'\beta)$ , no una derivada.

Como el efecto depende de  $x$ , hay que elegir **dónde** evaluarlo:

- **Efecto marginal promedio (AME):**  $\widehat{AME}_j = \hat{\beta}_j \cdot \frac{1}{n} \sum_i f(x'_i \hat{\beta})$ . Responde: ¿cuál es el efecto promedio sobre la población? Es el que más se parece al coeficiente de un MPL.
- **Efecto marginal en la media (MEM):**  $f(\bar{x}' \hat{\beta}) \hat{\beta}_j$ . Evalúa en un individuo “promedio”, que puede no existir (¿cuál es la proporción promedio de mujeres?).
- **Efecto marginal en un valor representativo:** para el caso o escenario que interesa.

El AME es lo que suele recomendarse: no depende de inventar un individuo ficticio.

**Ejemplo 4.1** (Un ejemplo numérico). Sea  $P(y = 1 | x) = F(-1 + 0,5x)$  y evaluamos en  $x = 2$ , donde el índice vale  $\eta = 0$ . En el **logit**,  $f(0) = \Lambda(0)(1 - \Lambda(0)) = 0,25$  y el efecto es  $0,25 \times 0,5 = 0,125$ : un punto más de  $x$  sube la probabilidad en 12,5 puntos porcentuales. En el **probit** con los mismos coeficientes,  $f(0) = \phi(0) \approx 0,399$  y el efecto sería 0,199. Pero los coeficientes no son comparables: un probit con  $\beta_{\text{probit}} \approx \beta_{\text{logit}}/1,6$  tendría  $0,399 \times 0,5/1,6 \approx 0,125$ : **los efectos marginales de logit y probit casi coinciden**, aunque los coeficientes difieran en un factor 1,6. Por eso conviene comparar efectos marginales y no coeficientes.

#### 4.1. Errores estándar por el método delta

Los efectos marginales son funciones de  $\hat{\beta}$ , así que su varianza se obtiene con el método delta (Clase 6 de Econometría 1). Para  $ME_j(x) = f(x'\beta)\beta_j$ , el gradiente respecto de  $\beta$  es

$$\frac{\partial ME_j(x)}{\partial \beta} = f(x'\beta) e_j + \beta_j f'(x'\beta) x,$$

con  $e_j$  el  $j$ -ésimo vector canónico. En el probit,  $f' = \phi' = -\eta\phi$ ; en el logit,  $f' = f(1 - 2\lambda)$ . Entonces  $\widehat{Var}(\widehat{ME}_j(x)) = \hat{D}' \widehat{Avar}(\hat{\beta}) \hat{D}$ , donde  $\hat{D}$  es el gradiente evaluado en  $\hat{\beta}$ .

Para el AME hay una sutileza: el promedio sobre la muestra tiene dos fuentes de variación (la de  $\hat{\beta}$  y la de los  $x_i$  mismos). El tratamiento correcto estima todo en un solo sistema de momentos (GMM de la Clase 4 con los momentos del score y el del promedio). En muestras grandes y con  $\hat{\beta}$  dominando, el delta sobre  $\hat{\beta}$  con  $x_i$  fijos es una buena aproximación.

### 5. Tres trampas de interpretación

#### 5.1. Trampa 1: los coeficientes dependen de qué más incluyas

En un modelo lineal, agregar un regresor ortogonal a  $x_1$  no cambia el coeficiente de  $x_1$ . En un probit **sí lo cambia**, aunque el regresor omitido sea independiente de  $x_1$ .

**Proposición 5.1** (Atenuación por heterogeneidad omitida). Sea  $y^* = \beta_1 x_1 + \beta_2 x_2 + \varepsilon$ , con  $\varepsilon \sim N(0, 1)$ ,  $x_2 \sim N(0, \tau^2)$ , y  $(x_1, \varepsilon, x_2)$  independientes entre sí. Si se estima un probit de  $y$  sobre  $x_1$  **sin**  $x_2$ , el estimador converge a

$$\beta_1^\dagger = \frac{\beta_1}{\sqrt{1 + \beta_2^2 \tau^2}},$$

que es menor en valor absoluto que  $\beta_1$  si  $\beta_2 \neq 0$ .

*Demostración.* Sin  $x_2$ , el error compuesto es  $\varepsilon + \beta_2 x_2 \sim N(0, 1 + \beta_2^2 \tau^2)$ , independiente de  $x_1$ . Entonces  $P(y = 1 \mid x_1) = P(\varepsilon + \beta_2 x_2 > -\beta_1 x_1) = \Phi(\beta_1 x_1 / \sqrt{1 + \beta_2^2 \tau^2})$ , que es un probit con coeficiente  $\beta_1^\dagger$ . Como ese modelo reducido está bien especificado, el probit converge a  $\beta_1^\dagger$  (Clase 2).  $\square$

Esto es la Proposición 2.1 en acción: agregar  $x_2$  reduce la varianza del error residual y por lo tanto “reescala” los coeficientes. **No puedes comparar coeficientes entre modelos probit con distintos controles** ni, con más razón, entre grupos con distintas varianzas de  $\varepsilon$  (mismo modelo, dos países: ¿los coeficientes difieren por diferencias reales o por distinta varianza residual?). Esto obliga a comparar *efectos marginales*, que sí están en unidades de probabilidad.

## 5.2. Trampa 2: el modelo mal especificado es inconsistente

En MCO, una CEF no lineal igual deja un coeficiente de proyección con sentido (Clase 2 de Econometría 1). En probit, **no**: si  $\varepsilon$  es heterocedástico (por ejemplo,  $\varepsilon \mid x \sim N(0, \sigma(x)^2)$ ), entonces  $P(y = 1 \mid x) = \Phi(x' \beta / \sigma(x)) \neq \Phi(x' \beta)$  y el estimador de MV converge al pseudo-verdadero de la Clase 2, que no es  $\beta$  ni tiene interpretación estructural. Es la diferencia fundamental entre estimadores cuyo sentido sobrevive (MCO, Poisson) y los que no (probit, logit). Se puede testear con un LM (Clase 3): probit heterocedástico  $\Phi(x' \beta / \exp(z' \gamma))$  y  $H_0 : \gamma = 0$ .

## 5.3. Trampa 3: términos de interacción

En un modelo lineal, el coeficiente de la interacción  $x_1 x_2$  **es** el efecto cruzado. En un modelo no lineal, el efecto cruzado  $\partial^2 p / \partial x_1 \partial x_2$  **no** es  $\beta_{12} f(\cdot)$ : incluye además términos como  $\beta_1 \beta_2 f'(\cdot)$ , que no se anulan aunque  $\beta_{12} = 0$  (Ai y Norton, 2003). Un efecto cruzado puede ser distinto de cero, y hasta cambiar de signo según  $x$ , sin que el coeficiente de interacción lo diga.

## 6. ¿Y el modelo lineal?

Con todo esto, ¿para qué usar MPL? Porque (a) si los regresores son **saturados** (todas las variables son dummies y se incluyen todas las interacciones), la CEF es lineal *por construcción* y el MPL reproduce  $p(x)$  exactamente; (b) con regresores continuos, el MPL estima la mejor aproximación lineal a  $p(x)$  (el coeficiente de proyección, Clase 2 de Econometría 1), y suele dar efectos marginales promedio muy parecidos a los del probit; (c) no tiene problemas de existencia, ni de escala, ni de interacción. Angrist y Pischke (2009) lo recomiendan de partida. Por otro lado, es un mal predictor de probabilidades individuales (sale de  $[0, 1]$ ) y poco confiable con  $p$  cerca de 0 o de 1 (eventos raros). La elección entre MPL y probit/logit **no es de corrección** sino de qué cantidad te interesa y qué tan lejos de  $[0, 1]$  viven tus datos.

## 7. Ajuste y comparación

El análogo del  $R^2$  es el **pseudo- $R^2$  de McFadden**,  $1 - \ell_n(\hat{\beta})/\ell_n(\hat{\beta}_0)$ , con  $\hat{\beta}_0$  el modelo con solo constante. No es una proporción de varianza explicada: valores de 0,2 a 0,4 se consideran un muy buen ajuste. Para testear hipótesis sobre  $\beta$  se usa la trinidad de la Clase 3: el LR compara el modelo completo contra el restringido, y el LM permite testear variables omitidas sin estimarlas. Las **tablas de clasificación** (porcentaje de aciertos con regla  $\hat{p} > 0,5$ ) son malas: un modelo que siempre predice “0” acierta 90 % si 90 % son ceros. Mejor evaluar la calibración y el área bajo la curva ROC.

## 8. ★ Postgrado: concavidad del probit

### ! ★ Postgrado

Demostramos que  $\ell_n$  del probit es cóncava. Una función  $F$  tal que  $\log F$  y  $\log(1 - F)$  son cóncavas garantiza la concavidad de  $\ell_n$ .

**Proposición 8.1** (Concavidad de la log-verosimilitud con  $F$  log--cóncava). Si  $\log F$  y  $\log(1 - F)$  son funciones cóncavas de  $\eta$ , entonces  $\ell_n(\beta)$  es cóncava en  $\beta$ . Si además son estrictamente cóncavas,  $\ell_n$  lo es (dado que  $X'X$  es invertible).

*Demostración.*  $\ell_n(\beta) = \sum_i [y_i \log F(x_i' \beta) + (1 - y_i) \log(1 - F(x_i' \beta))]$  es una suma de funciones de la forma  $\psi_i(x_i' \beta)$ , con  $\psi_i = \log F$  o  $\log(1 - F)$  según  $y_i$ . La composición de una función cóncava con una función lineal (afín) es cóncava, y una suma de cóncavas es cóncava. Si cada  $\psi_i$  es estrictamente cóncava y  $Xa \neq 0$  para  $a \neq 0$ , la suma lo es estrictamente.  $\square$

Para el probit:  $\log \Phi$  es cóncava, pues  $(\log \Phi)'' = \lambda'(\eta)$  con  $\lambda = \phi/\Phi$  la razón inversa de Mills, que cumple  $\lambda'(\eta) = -\lambda(\eta)(\eta + \lambda(\eta)) < 0$  (se sigue de  $\Phi(\eta) > -\phi(\eta)/\eta$  para  $\eta < 0$ , la desigualdad de Mills). Como  $1 - \Phi(\eta) = \Phi(-\eta)$ ,  $\log(1 - \Phi)$  también es cóncava. En el logit,  $(\log \Lambda)'' = -\Lambda(1 - \Lambda) < 0$  y  $(\log(1 - \Lambda))'' = -\Lambda(1 - \Lambda) < 0$ , lo que reproduce el Teorema 3.1.

## 9. Resumen

- En un modelo binario la CEF es la probabilidad:  $p(x) = F(x' \beta)$  con  $F$  una distribución simétrica (normal: probit; logística: logit). Sale de un modelo de variable latente.
- La **escala** no está identificada:  $\varepsilon$  se normaliza, y los coeficientes están en unidades arbitrarias (Proposición 2.1).
- El MV se resuelve numéricamente; el logit tiene score  $\sum (y - \Lambda)x$  y es **globalmente cóncavo** (Teorema 3.1); puede no existir si hay separación perfecta.
- $\sqrt{n}(\hat{\beta} - \beta) \rightarrow N(0, \mathcal{I}^{-1})$  (Teorema 3.2).
- Los **efectos marginales**  $f(x' \beta) \beta_j$  dependen de  $x$ ; reporta AME o MEM con errores estándar por método delta. Comparar efectos marginales, no coeficientes.
- **Trampas:** coeficientes que cambian con los controles (Proposición 5.1), inconsistencia bajo heterocedasticidad, interacciones.

## 10. Ejercicios

**Ejercicio 5.1.** Muestra que en el modelo de variable latente con  $\varepsilon \sim N(0, 1)$  simétrica,  $P(y = 1 | x) = \Phi(x'\beta)$ , y que la verosimilitud de una observación es  $\Phi(x'\beta)^y \Phi(-x'\beta)^{1-y}$ .

### Solución 5.1

$P(y = 1 | x) = P(x'\beta + \varepsilon > 0) = P(\varepsilon > -x'\beta) = 1 - \Phi(-x'\beta) = \Phi(x'\beta)$  por simetría. Luego  $P(y = 0 | x) = 1 - \Phi(x'\beta) = \Phi(-x'\beta)$  y la función de probabilidad de  $y$  dado  $x$  es  $\Phi(x'\beta)^y \Phi(-x'\beta)^{1-y}$  para  $y \in \{0, 1\}$ . Su log es  $y \log \Phi(x'\beta) + (1 - y) \log \Phi(-x'\beta)$ .

**Ejercicio 5.2.** En un logit con  $\beta = (-1; 0,5)$  (constante,  $x$ ), calcula el efecto marginal de  $x$  en  $x = 0$  y en  $x = 4$  y compara con el efecto en  $x = 2$  (calculado en el Ejemplo 4.1). ¿Qué patrón ves?

### Solución 5.2

En  $x = 0$ :  $\eta = -1$ ,  $\Lambda(-1) = 0,2689$ ,  $f = 0,2689 \times 0,7311 = 0,1966$ , efecto  $= 0,1966 \times 0,5 = 0,098$ . En  $x = 4$ :  $\eta = 1$ ,  $\Lambda(1) = 0,7311$ ,  $f = 0,1966$ , efecto  $0,098$  (simetría). En  $x = 2$ :  $0,125$ . El efecto es **máximo en el centro** ( $p = 0,5$ ) y se achica hacia las colas, de forma simétrica. Un mismo coeficiente  $\beta_x = 0,5$  produce efectos marginales de 9,8 a 12,5 puntos porcentuales según el punto donde se evalúe.

**Ejercicio 5.3.** En un logit con constante entre los regresores, demuestra que  $\sum_i \hat{p}_i = \sum_i y_i$  (la probabilidad predicha promedio coincide con la proporción muestral de unos). Si hay una dummy  $d_i$ , ¿qué más se cumple?

### Solución 5.3

Las CPO del logit son  $\sum_i (y_i - \hat{p}_i)x_i = 0$ . La fila correspondiente a la constante da  $\sum_i (y_i - \hat{p}_i) = 0$ . La fila de la dummy da  $\sum_i (y_i - \hat{p}_i)d_i = 0$ : en el grupo  $d = 1$ , la suma de probabilidades predichas es igual a la suma de  $y$ . Más en general, **para todo regresor incluido, los residuos  $y - \hat{p}$  son or-**

**ortogonales a él.** Esta propiedad no la tiene el probit.

**Ejercicio 5.4.** (Separación.) Sea  $x$  escalar sin constante, con datos  $(x_i, y_i)$  tales que  $y_i = 1$  si y solo si  $x_i > 0$ . Muestra que el logit no tiene MV finito.

 Solución 5.4

Para cada  $i$ ,  $y_i \log \Lambda(\beta x_i) + (1 - y_i) \log(1 - \Lambda(\beta x_i))$ : si  $x_i > 0$  ( $y_i = 1$ ), el término es  $\log \Lambda(\beta x_i)$ , creciente en  $\beta$  y que tiende a 0 cuando  $\beta \rightarrow \infty$ ; si  $x_i < 0$  ( $y_i = 0$ ), es  $\log(1 - \Lambda(\beta x_i)) = \log \Lambda(-\beta x_i)$ , también creciente en  $\beta$  (porque  $-\beta x_i > 0$  crece con  $\beta$ ) y con límite 0. Cada término es estrictamente creciente en  $\beta$  y acotado por cero:  $\ell_n(\beta) \uparrow 0$  cuando  $\beta \rightarrow \infty$  sin alcanzarlo. El supremo no se alcanza. La separación es perfecta y el estimador “es”  $+\infty$ .

**Ejercicio 5.5.** Calcula el gradiente de  $ME_j(x) = \phi(x'\beta)\beta_j$  del probit respecto de  $\beta$  y úsalo para dar la varianza del efecto marginal en  $x$  en términos de  $Avar(\hat{\beta})$ .

 Solución 5.5

Usando  $\phi'(\eta) = -\eta\phi(\eta)$ :  $\frac{\partial ME_j}{\partial \beta} = \phi(x'\beta)e_j - (x'\beta)\phi(x'\beta)\beta_j x = \phi(x'\beta)[e_j - (x'\beta)\beta_j x]$ . Con  $D = \phi(x'\beta)[e_j - (x'\beta)\beta_j x]$ ,  $Var(\hat{ME}_j) \approx D' Avar(\hat{\beta}) D/n$ . En  $x'\beta = 0$  el segundo término se anula y el gradiente es  $\phi(0)e_j$ : el error estándar del efecto marginal es  $\phi(0) \cdot ee(\hat{\beta}_j) \approx 0,4 ee(\hat{\beta}_j)$ .

**Ejercicio 5.6.** Dos grupos (hombres y mujeres) estiman el mismo probit de participación laboral y obtienen  $\hat{\beta}_{educ} = 0,20$  y  $0,30$ , respectivamente. ¿Puedes concluir que la educación importa más para las mujeres?

 Solución 5.6

No directamente. Por la Proposición 2.1, cada coeficiente es  $\beta/\sigma_g$  con  $\sigma_g$  la desviación estándar del error latente en el

grupo  $g$ . Si el error de las mujeres tiene menor varianza ( $\sigma_M < \sigma_H$ ),  $\hat{\beta}/\sigma$  es mayor aun si  $\beta$  fuera igual. Hay que comparar **efectos marginales** (en unidades de probabilidad), o testear explícitamente heterocedasticidad entre grupos (Allison, 1999, propone el probit heterocedástico con  $\sigma_g$  libre).

**Ejercicio 5.7 ★.** Demuestra que  $\lambda(\eta) = \phi(\eta)/\Phi(\eta)$  cumple  $\lambda'(\eta) = -\lambda(\eta)(\eta + \lambda(\eta))$ , y que  $\log \Phi$  es cóncava si  $\eta + \lambda(\eta) > 0$  para todo  $\eta$ .

💡 Solución 5.7 ★

$(\log \Phi)' = \phi/\Phi = \lambda$ .  $\lambda' = \frac{\phi'\Phi - \phi^2}{\Phi^2} = \frac{-\eta\phi\Phi - \phi^2}{\Phi^2} = -\lambda\eta - \lambda^2 = -\lambda(\eta + \lambda)$ . Como  $\lambda > 0$ , la concavidad de  $\log \Phi$  es equivalente a  $\eta + \lambda(\eta) > 0$ , es decir  $\phi(\eta) > -\eta\Phi(\eta)$ . Para  $\eta \geq 0$  es trivial (el lado derecho es  $\leq 0 < \phi$ ). Para  $\eta < 0$ , hay que probar  $\Phi(\eta) < \phi(\eta)/|\eta|$ , la **desigualdad de Mills**:  $\Phi(\eta) = \int_{-\infty}^{\eta} \phi(t) dt$ . Para  $t < \eta < 0$  se cumple  $t/\eta > 1$ , así que  $\int_{-\infty}^{\eta} \phi(t) dt < \frac{1}{\eta} \int_{-\infty}^{\eta} t \phi(t) dt = \frac{1}{\eta} [-\phi(\eta)] = \phi(\eta)/|\eta|$  (usando  $\int t\phi(t) dt = -\phi(t)$ ). Luego  $\Phi(\eta)|\eta| < \phi(\eta)$ , o sea  $\eta + \lambda(\eta) > 0$ .