

Clase 7 · Conteo y duración

Poisson, binomial negativa, QMLE, función de riesgo y modelo de Cox

Contenido

1	Dos tipos de variable que MCO no entiende	2
2	Parte A: variables de conteo	2
2.1	El modelo de Poisson	2
2.2	El problema: equidispersión	3
2.3	Poisson como estimador de cuasi-máxima verosimilitud	3
2.4	Binomial negativa	4
2.5	Otros modelos de conteo	5
3	Parte B: duraciones	5
3.1	Función de supervivencia y de riesgo	5
3.2	Censura y verosimilitud	6
3.3	Riesgos proporcionales y el modelo de Cox	7
4	★ Postgrado: Cox como verosimilitud perfilada	9
5	Resumen	10
6	Ejercicios	10

1. Dos tipos de variable que MCO no entiende

Hay dos clases de variables dependientes que son siempre no negativas y que se prestan mal al modelo lineal:

- **Conteos:** $y \in \{0, 1, 2, \dots\}$. Número de patentes de una empresa, visitas al médico en un año, accidentes en una intersección.
- **Duraciones:** $T > 0$ continuo. Tiempo que dura un desempleo, tiempo hasta que un crédito cae en mora, tiempo de supervivencia de una empresa.

Con un conteo, la media condicional debe ser **positiva** (no tiene sentido una predicción de $-0,3$ patentes), y la varianza crece con la media. Con una duración, la distribución es asimétrica y, peor, hay **censura**: al terminar la observación, algunos individuos todavía no experimentan el evento (siguen desempleados, el crédito sigue al día) y solo sabemos que $T > t_{\text{obs}}$. Hoy desarrollamos las herramientas para ambos.

2. Parte A: variables de conteo

2.1. El modelo de Poisson

La distribución natural para un conteo es la de Poisson: $P(y = k) = e^{-\mu} \mu^k / k!$, con $\mathbb{E}[y] = \text{Var}(y) = \mu$. Para incorporar regresores, necesitamos que $\mu(x) > 0$ siempre, así que se toma la forma exponencial:

$$\mu(x) = \mathbb{E}[y | x] = \exp(x' \beta).$$

La log-verosimilitud, el score y el hessiano son

$$\ell_n(\beta) = \sum_i [y_i x_i' \beta - e^{x_i' \beta} - \log y_i!], \quad S(\beta) = \sum_i (y_i - \mu_i) x_i, \quad \nabla^2 \ell_n = - \sum_i \mu_i x_i x_i'.$$

El hessiano es definido negativo (como en el logit): ℓ_n es globalmente cóncava y Newton-Raphson funciona sin problemas. La interpretación es muy natural: $\partial \log \mu / \partial x_j = \beta_j$. El coeficiente

es una **semielasticidad**: una unidad más de x_j multiplica la media por e^{β_j} , lo que equivale, aproximadamente, a un cambio porcentual de $100\beta_j$ (si β_j es chico). El efecto marginal en niveles es $\partial\mu/\partial x_j = \mu\beta_j$, que depende de x .

La condición de primer orden $\sum_i (y_i - \hat{\mu}_i)x_i = 0$ implica, con una constante, $\sum \hat{\mu}_i = \sum y_i$ (el promedio ajustado coincide con el promedio de los datos), y lo mismo grupo a grupo para cada dummy incluida.

2.2. El problema: equidispersión

El modelo de Poisson impone $\text{Var}(y \mid x) = \mathbb{E}[y \mid x]$ (**equidispersión**). En los datos reales casi siempre ocurre **sobredispersión**, $\text{Var} > \mathbb{E}$, porque hay heterogeneidad no observada: dos individuos con las mismas x no tienen la misma media. Si ignoramos esto, ¿qué se rompe? Veamos que **menos de lo que se cree**.

2.3. Poisson como estimador de cuasi-máxima verosimilitud

Teorema 2.1 (Consistencia del QMLE de Poisson). *Si $\mathbb{E}[y \mid x] = \exp(x'\beta_0)$ (la media está bien especificada), el estimador de Poisson $\hat{\beta}$ es consistente para β_0 y asintóticamente normal **sin importar cuál sea la distribución de y condicional en x** :*

$$\sqrt{n}(\hat{\beta} - \beta_0) \xrightarrow{d} N(0, A^{-1}BA^{-1}), \quad A = -\mathbb{E}[\mu x x'], \quad B = \mathbb{E}[\text{Var}(y \mid x) x x'],$$

con $\mu = \exp(x'\beta_0)$.

Borrador

Por la Clase 1 solo tengo que verificar que el score tenga media cero en β_0 (consistencia, vía identificación) y calcular A y B . El score es $(y - \mu)x$, con esperanza condicional $(\mathbb{E}[y \mid x] - \mu)x = 0$ si la media está bien especificada. **No hace falta que y sea Poisson**: la verosimilitud de Poisson es “mala” pero su condición de primer orden poblacional solo depen-

de de la media. Eso es lo que hace que sea un buen QMLE.
Para B , basta calcular $\mathbb{E}[(y - \mu)^2 x x'] = \mathbb{E}[\text{Var}(y | x) x x']$.

Demostración. El criterio $m(y, x, \beta) = yx'\beta - e^{x'\beta}$ cumple $\nabla m = (y - e^{x'\beta})x$ y $\nabla^2 m = -e^{x'\beta}xx'$.

Media cero del score en β_0 : $\mathbb{E}[(y - \mu)x] = \mathbb{E}[x \mathbb{E}[y - \mu | x]] = 0$ pues la media condicional es μ por supuesto.

Identificación: $Q_0(\beta) = \mathbb{E}[yx'\beta - e^{x'\beta}] = \mathbb{E}[\mu x'\beta - e^{x'\beta}]$, que es estrictamente cóncava en β (si $\mathbb{E}[xx'] > 0$) y tiene derivada cero en β_0 (el score tiene media cero ahí): β_0 es su único maximizador.

Sándwich: $A = \mathbb{E}[\nabla^2 m] = -\mathbb{E}[\mu xx']$ y $B = \mathbb{E}[(y - \mu)^2 xx'] = \mathbb{E}[\text{Var}(y | x)xx']$. El resto es el teorema de normalidad asintótica de la Clase 1, que vale con la concavidad global (Ejercicio 1.7 de la Clase 1) en lugar de compacidad. $\square$

Si además se cumple equidispersión, $\text{Var}(y | x) = \mu$ y $B = -A$: se recupera la varianza usual $\mathcal{I}^{-1}$. Si no, la varianza correcta es el sándwich y **los errores estándar “de manual” están mal** (típicamente subestimados). Es la misma lección de la Clase 2: la consistencia depende de la media; la inferencia, de la varianza.

Recomendación práctica

Usa **siempre** errores estándar robustos (sándwich) con Poisson. Y no te limites a conteos: el QMLE de Poisson sirve para **cualquier variable no negativa** con media exponencial (ingresos, ventas, flujos comerciales), incluyendo variables con muchos ceros. Es el estimador que se prefiere hoy para las *ecuaciones de gravedad* del comercio internacional (Santos Silva y Tenreyro, 2006).

2.4. Binomial negativa

Para modelar la sobredispersión explícitamente se agrega heterogeneidad no observada multiplicativa. Sea $y | x, v \sim \text{Poisson}(\mu v)$, con $\mu = e^{x'\beta}$ y v independiente de x , con $\mathbb{E}[v] = 1$ y $\text{Var}(v) = \alpha$ (típicamente gamma). Entonces:

- $\mathbb{E}[y | x] = \mathbb{E}[\mathbb{E}[y | x, v]] = \mu \mathbb{E}[v] = \mu$.
- Por la ley de la varianza total, $\text{Var}(y | x) = \mathbb{E}[\mu v] + \text{Var}(\mu v) = \mu + \alpha \mu^2$.

Con $v \sim \text{Gamma}$, integrando v queda la distribución **binomial negativa** (NB2), con $\text{Var} = \mu(1 + \alpha\mu)$. Si $\alpha = 0$ se vuelve Poisson. El parámetro α se estima por MV junto con β . Observa algo importante: el score para β en NB2 es $\frac{y - \mu}{1 + \alpha\mu}x$, que tiene media cero **siempre que** $\mathbb{E}[y | x] = \mu$, **para cualquier valor de** α . Entonces la NB2 también es un QMLE consistente para β aunque la distribución sea incorrecta, y gana eficiencia sobre Poisson si el término de varianza $\mu + \alpha\mu^2$ es correcto.

Test de sobredispersión (Cameron-Trivedi). Bajo $H_0 : \alpha = 0$ y alternativa $\text{Var}(y | x) = \mu + \alpha\mu^2$: $\mathbb{E}[(y - \mu)^2 - y | x] = \alpha\mu^2$. Se estima Poisson, se calcula $\hat{\mu}_i$, y se regresa por MCO (sin constante) $\frac{(y_i - \hat{\mu}_i)^2 - y_i}{\hat{\mu}_i}$ sobre $\hat{\mu}_i$; el test t del coeficiente contrasta $\alpha = 0$.

2.5. Otros modelos de conteo

Muchos ceros (“más ceros de los que Poisson permite”): **modelo de ceros inflados** (una mezcla entre una masa en cero y una Poisson) o **modelo de barrera** (*hurdle*: primero un probit de si $y > 0$, luego una Poisson truncada en cero para los positivos). Distintas ideas, mismas herramientas: MV de una densidad bien definida (Clases 1–3). Para exposición variable (cada unidad observada en períodos distintos), se agrega un **offset**: $\mu_i = t_i \exp(x_i' \beta)$, con $\log t_i$ como regresor de coeficiente fijo en uno.

3. Parte B: duraciones

3.1. Función de supervivencia y de riesgo

Sea $T > 0$ una duración con densidad f y distribución F . Definimos:

- **Función de supervivencia:** $S(t) = P(T > t) = 1 - F(t)$.

- **Función de riesgo (hazard):** $\lambda(t) = \lim_{h \downarrow 0} \frac{P(t \leq T < t+h \mid T \geq t)}{h} = \frac{f(t)}{S(t)}$.
- **Riesgo acumulado:** $\Lambda(t) = \int_0^t \lambda(s) ds$.

El riesgo responde: *dado que el evento no ha ocurrido hasta t , ¿con qué intensidad ocurre ahora?* (la probabilidad instantánea de salir del desempleo, dado que sigues desempleado). Es el objeto natural porque condiciona en la información disponible.

Proposición 3.1 (Identidades de supervivencia). $\lambda(t) = -\frac{d \log S(t)}{dt}$, y por lo tanto $S(t) = \exp(-\Lambda(t))$ y $f(t) = \lambda(t) \exp(-\Lambda(t))$.

Demostración. Como $f = -S'$, $\lambda = f/S = -S'/S = -(\log S)'$. Integrando desde 0 con $S(0) = 1$: $\log S(t) = -\int_0^t \lambda = -\Lambda(t)$. Luego $f = \lambda S = \lambda e^{-\Lambda}$. $\square$

Tres ejemplos: **exponencial**, $\lambda(t) = \lambda$ constante (“sin memoria”; $S = e^{-\lambda t}$); **Weibull**, $\lambda(t) = \lambda \alpha t^{\alpha-1}$ (creciente si $\alpha > 1$, decreciente si $\alpha < 1$; $S = e^{-\lambda t^\alpha}$); y **riesgo no monótono** (log-logística, que sube y luego baja).

3.2. Censura y verosimilitud

Con censura por la derecha observamos $t_i = \min(T_i, C_i)$ (donde C_i es el momento de censura) y el indicador $\delta_i = \mathbf{1}\{T_i \leq C_i\}$ (1 si vimos el evento, 0 si fue censurado). Suponemos que la censura es **no informativa** (independiente de T_i dado x_i). Cada observación aporta:

- si $\delta_i = 1$: la densidad $f(t_i)$;
- si $\delta_i = 0$: solo sabemos que $T_i > t_i$, o sea $S(t_i)$.

Entonces $L = \prod_i f(t_i)^{\delta_i} S(t_i)^{1-\delta_i}$ y, usando la Proposición 3.1,

$$\ell_n = \sum_i [\delta_i \log \lambda(t_i) - \Lambda(t_i)]. \quad (1)$$

(Porque $\log f = \log \lambda - \Lambda$ y $\log S = -\Lambda$.) Una observación censurada **no se descarta** (eso sesgaría hacia duraciones cortas) ni se trata como si el evento hubiera ocurrido en t_i : aporta información parcial, que es exactamente $S(t_i)$.

Ejemplo 3.1 (La exponencial censurada es una Poisson). Con riesgo exponencial $\lambda(t | x) = \exp(x'\beta)$, $\Lambda(t) = t e^{x'\beta}$ y Ecuación 1 queda $\ell_n = \sum_i [\delta_i x_i'\beta - t_i e^{x_i'\beta}]$. Esto es *exactamente* la log-verosimilitud de Poisson de la Parte A con variable dependiente δ_i y *exposición* t_i (offset $\log t_i$), salvo constantes. Por lo tanto, el score es $\sum_i (\delta_i - t_i e^{x_i'\beta}) x_i$ y todo el aparato de Poisson (incluida la concavidad) se aplica. La exponencial con censura es un modelo de conteo de eventos por unidad de tiempo expuesto.

Para la exponencial *sin* regresores, con $d = \sum \delta_i$ eventos y tiempo total expuesto $\sum t_i$, el MV es $\hat{\lambda} = d / \sum t_i$: **eventos por unidad de tiempo en riesgo** (Ejercicio 7.5).

3.3. Riesgos proporcionales y el modelo de Cox

El modelo de regresión más usado para duraciones es el de **riesgos proporcionales** (Cox, 1972):

$$\lambda(t | x) = \lambda_0(t) \exp(x'\beta),$$

donde $\lambda_0(t)$ es un riesgo **base** que depende solo del tiempo y las covariables **escalan** el riesgo multiplicativamente. Si x_j sube una unidad, el riesgo se multiplica por e^{β_j} (la **razón de riesgos**, *hazard ratio*) en **todo** t . Con $\beta_j = 0,4$, $e^{0,4} = 1,49$: el riesgo es 49 % mayor.

Si elegimos una forma paramétrica para λ_0 (constante, Weibull) usamos MV con Ecuación 1. Pero la forma de λ_0 rara vez interesa y es fácil equivocarse. La idea brillante de Cox: **estimar β sin especificar λ_0** .

Borrador

Ordeno los eventos observados: $t_{(1)} < t_{(2)} < \dots < t_{(J)}$ (sin empates). En $t_{(j)}$ hay un **conjunto en riesgo** R_j (los individuos que aún no han tenido el evento ni han sido censu-

rados). Pregunto: sabiendo que *alguien* en R_j tiene el evento en $t_{(j)}$, ¿cuál es la probabilidad de que sea justamente el individuo $i_{(j)}$ que observamos? Es el cociente de su riesgo sobre la suma de los riesgos en R_j . Pero cada riesgo es $\lambda_0(t_{(j)})e^{x'_i\beta}$, y $\lambda_0(t_{(j)})$ **aparece en el numerador y en cada término del denominador y se cancela**. Queda una probabilidad que depende solo de β .

La probabilidad condicional es

$$P(\text{falla } i_{(j)} \mid \text{falla alguien de } R_j \text{ en } t_{(j)}) = \frac{\lambda_0(t_{(j)})e^{x'_{(j)}\beta}}{\sum_{l \in R_j} \lambda_0(t_{(j)})e^{x'_l\beta}} = \frac{e^{x'_{(j)}\beta}}{\sum_{l \in R_j} e^{x'_l\beta}},$$

y la **verosimilitud parcial de Cox** es el producto sobre los eventos:

$$L_p(\beta) = \prod_{j=1}^J \frac{\exp(x'_{(j)}\beta)}{\sum_{l \in R_j} \exp(x'_l\beta)}, \quad S_p(\beta) = \sum_{j=1}^J \left[x_{(j)} - \sum_{l \in R_j} w_{jl}(\beta) x_l \right], \quad w_{jl} = \frac{e^{x'_l\beta}}{\sum_{m \in R_j} e^{x'_m\beta}}.$$

El score es una suma de “covariable observada **menos** covariable esperada bajo β en el conjunto en riesgo”: una condición de ortogonalidad idéntica en espíritu a MCO. Cox (1975) mostró que $\hat{\beta}$, el maximizador de L_p , es consistente y asintóticamente normal con varianza dada por el inverso de la información parcial, aunque L_p **no es una verosimilitud** (no es la densidad de nada) y los factores no son independientes; la demostración rigurosa usa la teoría de martingalas y procesos de conteo (Andersen y Gill, 1982), que supera el nivel del curso.¹ Los empates (varios eventos en el mismo instante) se manejan con aproximaciones (Breslow, Efron). Las covariables que varían en el tiempo se incorporan sin dificultad porque L_p solo evalúa x_l en cada tiempo de evento.

Una vez estimado $\hat{\beta}$ se puede recuperar el riesgo base acumulado con el estimador de **Breslow**, $\hat{\Lambda}_0(t) = \sum_{t_{(j)} \leq t} \left[\sum_{l \in R_j} e^{x'_l\hat{\beta}} \right]^{-1}$, que da curvas de supervivencia $\hat{S}(t \mid x) = \exp(-\hat{\Lambda}_0(t)e^{x'\hat{\beta}})$.

¹ El artículo de Cox de 1972, “Regression Models and Life-Tables”, es uno de los más citados de toda la estadística. El método llegó antes que su justificación completa: Cox formalizó la verosimilitud parcial en 1975 y la teoría general de martingalas llegó recién con Andersen y Gill en 1982. Es el orden inverso del ideal, pero bastante habitual en la historia de la estadística.

4. ★ Postgrado: Cox como verosimilitud perfilada

! ★ Postgrado

La verosimilitud parcial de Cox no es un truco: es la verosimilitud completa en la que **se concentra el riesgo base** (se maximiza sobre él, dejando β libre).

Proposición 4.1 (Cox = verosimilitud perfilada sobre el riesgo base). *Supón que λ_0 es una función escalonada que solo puede saltar en los tiempos de evento, con valores $\lambda_j = \lambda_0(t_{(j)})$, y sin empates. Entonces el máximo de Ecuación 1 respecto de $\lambda_1, \dots, \lambda_J$, con β fijo, es $\log L_p(\beta) - J$.*

Demostración. Con riesgo acumulado individual $\Lambda(t_i) = e^{x'_i \beta} \sum_{j: t_{(j)} \leq t_i} \lambda_j$ (el riesgo base sólo acumula en los tiempos de evento) y $\log \lambda(t_i) = \log \lambda_0(t_i) + x'_i \beta$, Ecuación 1 es

$$\ell_n = \sum_{j=1}^J [\log \lambda_j + x'_{(j)} \beta] - \sum_i \sum_{j: t_{(j)} \leq t_i} \lambda_j e^{x'_i \beta}.$$

La doble suma, intercambiando el orden, es $\sum_j \lambda_j D_j$ con $D_j = \sum_{i: t_i \geq t_{(j)}} e^{x'_i \beta} = \sum_{l \in R_j} e^{x'_l \beta}$. Entonces $\ell_n = \sum_j [\log \lambda_j + x'_{(j)} \beta - \lambda_j D_j]$, y cada λ_j aparece solo en su propio término. La CPO es $1/\lambda_j = D_j$, o sea $\hat{\lambda}_j = 1/D_j$ (¡el estimador de Breslow!). Reemplazando, $\ell_n^{\text{perfil}} = \sum_j [-\log D_j + x'_{(j)} \beta - 1] = \sum_j [x'_{(j)} \beta - \log \sum_{l \in R_j} e^{x'_l \beta}] - J = \log L_p(\beta) - J$. $\square$

Por eso, maximizar L_p equivale a maximizar la verosimilitud completa respecto de β y de un riesgo base completamente libre. Es la forma moderna de ver el resultado de Cox: la verosimilitud parcial es “la verosimilitud con el riesgo base perfilado”.

5. Resumen

- **Conteos:** $\mathbb{E}[y \mid x] = e^{x'\beta}$; el score de Poisson $\sum (y - \mu)x$ tiene media cero si la **media** está bien especificada: Poisson es un QMLE consistente aunque la distribución sea falsa (Teorema 2.1). Usa errores robustos.
- **Sobredispersión:** $\text{Var} = \mu + \alpha\mu^2$ (binomial negativa); el test de Cameron-Trivedi usa una regresión auxiliar.
- **Duraciones:** el riesgo $\lambda(t)$ determina todo: $S = e^{-\Lambda}$, $f = \lambda e^{-\Lambda}$ (Proposición 3.1). La censura se maneja con $\ell = \sum [\delta \log \lambda - \Lambda]$.
- La exponencial censurada es una Poisson con *offset* (Ejemplo 3.1).
- **Cox:** $\lambda = \lambda_0(t)e^{x'\beta}$; la **verosimilitud parcial** elimina λ_0 y su máximo coincide con la verosimilitud perfilada (Proposición 4.1).

6. Ejercicios

Ejercicio 7.1. En una regresión de Poisson con constante y una dummy d , demuestra que $\hat{\mu}$ promedio en cada grupo ($d = 0$ y $d = 1$) coincide con la media muestral de y en ese grupo. ¿Cuánto vale $e^{\hat{\beta}_d}$?

Solución 7.1

Las CPO son $\sum_i (y_i - \hat{\mu}_i)x_i = 0$ con $x_i = (1, d_i)'$: $\sum_i (y_i - \hat{\mu}_i) = 0$ y $\sum_{d_i=1} (y_i - \hat{\mu}_i) = 0$. Como $\hat{\mu}_i$ solo toma dos valores (uno por grupo), $\hat{\mu}_{(d)} = \bar{y}_{(d)}$, el promedio del grupo. Entonces $e^{\hat{\beta}_0} = \bar{y}_{(0)}$ y $e^{\hat{\beta}_0 + \hat{\beta}_d} = \bar{y}_{(1)}$, así que $e^{\hat{\beta}_d} = \bar{y}_{(1)}/\bar{y}_{(0)}$, la **razón de promedios**.

Ejercicio 7.2. Los datos tienen $\mathbb{E}[y] = \mu$ y $\text{Var}(y) = 2\mu$ (sobredispersión de factor 2), sin regresores salvo la constante. Estima por Poisson: $\hat{\beta}_0 = \log \bar{y}$. Calcula la varianza asintótica verdadera de $\hat{\beta}_0$ y la que reportaría el programa si usa errores “de manual”. ¿Por cuánto se subestima el error estándar?

💡 Solución 7.2

Con $x = 1$: $A = -\mu$, $B = \text{Var}(y) = 2\mu$. Varianza verdadera: $A^{-1}BA^{-1} = 2\mu/\mu^2 = 2/\mu$. La de manual es $-A^{-1} = 1/\mu$. El error estándar de manual es $\sqrt{1/\mu}$ y el verdadero $\sqrt{2/\mu}$: **se subestima en un factor** $\sqrt{2} \approx 1,41$ (el error estándar real es 41 % mayor). Como los t salen $\sqrt{2}$ veces más grandes de lo que deberían, un coeficiente con $t = 1,6$ (no significativo) se vería como $t = 2,3$ (significativo). Por eso conviene siempre usar errores robustos.

Ejercicio 7.3. Calcula $\text{Var}(y)$ para el modelo de heterogeneidad multiplicativa con $\mu = 2$ y $\alpha = 0,5$, y compara con Poisson. ¿Cuántas veces mayor es la varianza?

💡 Solución 7.3

$\text{Var}(y) = \mu + \alpha\mu^2 = 2 + 0,5 \cdot 4 = 4$. En Poisson sería $\text{Var} = \mu = 2$: la varianza es **el doble**. Con $\mu = 10$ y el mismo α , $\text{Var} = 10 + 50 = 60$, seis veces la de Poisson: la sobredispersión de NB2 crece con la media.

Ejercicio 7.4. Para el riesgo de Weibull $\lambda(t) = \lambda\alpha t^{\alpha-1}$, calcula $\Lambda(t)$, $S(t)$ y $f(t)$. Describe la forma del riesgo según α .

💡 Solución 7.4

$\Lambda(t) = \int_0^t \lambda\alpha s^{\alpha-1} ds = \lambda t^\alpha$. $S(t) = e^{-\lambda t^\alpha}$, $f(t) = \lambda\alpha t^{\alpha-1} e^{-\lambda t^\alpha}$. Si $\alpha = 1$ es la exponencial (riesgo constante); si $\alpha > 1$ el riesgo **crece** con t (envejecimiento: componentes que se desgastan); si $\alpha < 1$ **decrece** (mortalidad infantil: el que sobrevive los primeros meses mejora sus chances).

Ejercicio 7.5. (Exponencial censurada.) Se observan 20 individuos durante un total de 50 años-persona, con 5 eventos y 15 censurados. Calcula el MV de λ y su error estándar.

💡 Solución 7.5

$\ell(\lambda) = d \log \lambda - \lambda \sum t_i$ con $d = 5$, $\sum t_i = 50$. CPO: $d/\lambda = \sum t_i \Rightarrow \hat{\lambda} = 5/50 = 0,10$ eventos por año-persona. Segunda derivada: $-d/\lambda^2$; información observada = $d/\hat{\lambda}^2$; Avar = $\hat{\lambda}^2/d = 0,01/5 = 0,002$ y el error estándar es 0,0447. Nótese que el error estándar depende de d (el número de **eventos**), no de n : las observaciones censuradas contribuyen solo a través del tiempo total. Una IC de 95 % aproximado: $0,10 \pm 1,96 \cdot 0,0447 = (0,012; 0,188)$, muy ancho con apenas 5 eventos.

Ejercicio 7.6. En un modelo de Cox para el riesgo de **salir del empleo**, el coeficiente de educación es $\hat{\beta}_{\text{educ}} = -0,08$ (por año adicional). Interpreta $e^{\hat{\beta}}$ y el efecto de 4 años más de educación.

💡 Solución 7.6

$e^{-0,08} = 0,923$: cada año adicional de educación **multiplica por 0,923** el riesgo instantáneo de dejar el empleo, es decir lo reduce 7,7 %, en todo momento de la duración (supuesto de riesgos proporcionales). Cuatro años más: $e^{-0,32} = 0,726$: el riesgo cae 27 %. Esto no dice que “la duración media aumente en 27 %”: con riesgos proporcionales el efecto sobre la duración esperada depende de la forma de λ_0 .

Ejercicio 7.7 ★. (Logaritar no es Poisson.) Sea $y = \exp(x'\beta)\eta$ con $\mathbb{E}[\eta \mid x] = 1$. Muestra que, en general, la regresión por MCO de $\log y$ sobre x **no** es consistente para los coeficientes de pendiente β si $\text{Var}(\eta \mid x)$ depende de x , mientras que el QMLE de Poisson sí lo es.

💡 Solución 7.7 ★

$\log y = x'\beta + \log \eta$, así que $\mathbb{E}[\log y \mid x] = x'\beta + \mathbb{E}[\log \eta \mid x]$. Por la desigualdad de Jensen, $\mathbb{E}[\log \eta \mid x] < \log \mathbb{E}[\eta \mid x] = 0$, y en una aproximación de segundo orden, $\mathbb{E}[\log \eta \mid x] \approx -\frac{1}{2} \text{Var}(\eta \mid x)$. Si la varianza de η depende de x , también el sesgo $\mathbb{E}[\log \eta \mid x]$, y la regresión lineal de $\log y$ sobre x captura $x'\beta + c(x)$ en lugar de $x'\beta$: las pendientes quedan ses-

gadas. Con $\text{Var}(\eta \mid x)$ constante, solo el intercepto se sesga y las pendientes sobreviven. En cambio, Poisson solo necesita $\mathbb{E}[y \mid x] = e^{x'\beta}$, que se cumple porque $\mathbb{E}[\eta \mid x] = 1$ (Teorema 2.1). Este es el argumento de Santos Silva y Tenreiro (2006) contra la práctica de linealizar con logaritmos las ecuaciones de gravedad. Además, $\log y$ no está definido si $y = 0$.