

Clase 8 · Datos censurados y selección

El modelo tobit y el modelo de Heckman

Contenido

1	Cuando la muestra no es la población	1
2	El modelo tobit	2
2.1	¿Por qué MCO falla?	2
2.2	Efectos marginales: tres preguntas distintas	3
2.3	Estimación por máxima verosimilitud	4
3	El modelo de selección de Heckman	5
3.1	Estimador en dos pasos	7
3.2	La restricción de exclusión	7
3.3	Máxima verosimilitud completa	8
4	★ Postgrado: concavidad del tobit	8
5	Resumen	9
6	Ejercicios	9

1. Cuando la muestra no es la población

Hasta ahora supusimos que observábamos y tal cual. Pero a menudo el mecanismo de observación **distorsiona** los datos. Hay tres situaciones que conviene distinguir:

- **Censura:** observamos al individuo, pero y está “cortada” en un umbral. Ejemplo: horas trabajadas. Mucha gente trabaja cero horas, no porque su “oferta de trabajo deseada” sea cero, sino porque la oferta deseada es negativa a los salarios disponibles y el dato se corta en cero. Sabemos cuántos están en cero y conocemos sus x .
- **Truncamiento:** ni siquiera observamos a los individuos que quedaron fuera del umbral. Ejemplo: una encuesta solo a hogares pobres (ingreso bajo cierto nivel). Los no pobres no están en la base de datos.
- **Selección muestral (truncamiento incidental):** y solo se observa para quienes pasan un filtro que depende de **otra** variable, correlacionada con y . Ejemplo: el salario solo se observa para quienes trabajan, y quién trabaja depende de variables que también afectan el salario.

Las tres producen **sesgo en MCO**. Las dos primeras se resuelven con el modelo **tobit**; la tercera, con el modelo de **Heckman**. En ambos casos el problema es, en el fondo, una pregunta de especificación: qué hay que modelar además de la ecuación de interés.¹

2. El modelo tobit

Tobin (1958) estudió el gasto de los hogares en bienes durables: muchos hogares gastan cero y el resto gasta cantidades positivas.² Su modelo (llamado *tobit* por el apodo, “Tobin’s probit”) supone una variable latente y un corte en cero:

$$y^* = x'\beta + u, \quad u | x \sim N(0, \sigma^2), \quad y = \max(0, y^*). \quad (1)$$

Se observa y y x para todos; y^* es lo que el individuo “demandaría” si no hubiera restricción de no negatividad. La interpretación estructural interesa a β (el efecto sobre la variable **latente**).

2.1. ¿Por qué MCO falla?

Hay dos regresiones tentadoras, ambas incorrectas:

¹ James Heckman recibió el Nobel de Economía en 2000, junto con McFadden, precisamente por su trabajo sobre selección muestral. Su artículo de 1979, “Sample selection bias as a specification error”, nació de estudiar los salarios de las mujeres casadas, que solo se observan para las que trabajan, y generó el concepto de *selección sobre inobservables*: si las personas que entran a la muestra se *autoseleccionan* por razones que también afectan el resultado, MCO captura una mezcla del efecto de las x y de esa selección.

² El nombre “tobit” (Tobin + probit) lo acuñó Arthur Goldberger en 1964, y desde entonces la familia “-it” (probit, logit, tobit) no ha dejado de crecer. Goldberger es también el de la “micro-numerosidad” de la Clase 8 de Econometría 1.

1. **MCO sobre todos** (incluyendo los ceros). Mezcla la masa en cero con la parte continua, y la media condicional $\mathbb{E}[y \mid x]$ **no es lineal** en x (veremos su forma exacta).
2. **MCO solo sobre los positivos**. Elimina los ceros y por lo tanto selecciona sobre el valor de u : solo quedan los que tienen $u > -x'\beta$. Esto sesga.

Calculemos exactamente lo que ocurre.

Lema 2.1 (Medias del tobit). Sea $c = x'\beta/\sigma$ y $\lambda(c) = \phi(c)/\Phi(c)$ la **razón inversa de Mills**. Bajo Ecuación 1:

$$\mathbb{E}[y^* \mid x, y^* > 0] = x'\beta + \sigma\lambda(c), \quad \mathbb{E}[y \mid x] = \Phi(c)x'\beta + \sigma\phi(c).$$

Demostración. Con $u = \sigma z$, $z \sim N(0, 1)$: $y^* > 0 \Leftrightarrow z > -c$. Entonces

$$\mathbb{E}[u \mid u > -x'\beta] = \sigma \mathbb{E}[z \mid z > -c] = \sigma \frac{\int_{-c}^{\infty} z\phi(z) dz}{P(z > -c)} = \sigma \frac{\phi(-c)}{\Phi(c)} = \sigma\lambda(c),$$

porque $\int_a^{\infty} z\phi(z) dz = \phi(a)$ y ϕ es simétrica. Luego $\mathbb{E}[y^* \mid y^* > 0] = x'\beta + \sigma\lambda(c)$. Para la segunda fórmula, $y = 0$ con probabilidad $\Phi(-c) = 1 - \Phi(c)$ y $y = y^* > 0$ con probabilidad $\Phi(c)$:

$$\mathbb{E}[y \mid x] = 0 \cdot P(y = 0) + P(y^* > 0) \mathbb{E}[y^* \mid y^* > 0] = \Phi(c)[x'\beta + \sigma\lambda(c)] = \Phi(c)x'\beta + \sigma\phi(c).$$

□

Dos consecuencias importantes. Primero, regresar y sobre x solo con los positivos **omite el término** $\sigma\lambda(c)$, que depende de x y se correlaciona con x : es un clásico caso de *variable omitida*. Segundo, ambas medias son **no lineales** en x , por lo que ni MCO sobre todos ni sobre positivos pueden recuperar β .

2.2. Efectos marginales: tres preguntas distintas

Hay tres efectos marginales distintos, y hay que saber cuál se pregunta.

Proposición 2.1 (Efectos marginales del tobit). Con $c = x'\beta/\sigma$:

1. **Sobre la variable latente:** $\partial \mathbb{E}[y^* | x] / \partial x_j = \beta_j$.
2. **Sobre la media observada (incondicional):** $\partial \mathbb{E}[y | x] / \partial x_j = \Phi(c) \beta_j$.
3. **Sobre la media entre los positivos:** $\partial \mathbb{E}[y | x, y > 0] / \partial x_j = \beta_j [1 - \lambda(c)(c + \lambda(c))]$.

Demostración.

(1) es inmediato. (2) Derivando $\Phi(c)x'\beta + \sigma\phi(c)$ con $\partial c / \partial x_j = \beta_j / \sigma$ y $\phi'(c) = -c\phi(c)$:

$$\phi(c) \frac{\beta_j}{\sigma} x'\beta + \Phi(c) \beta_j + \sigma(-c\phi(c)) \frac{\beta_j}{\sigma} = c\phi\beta_j + \Phi\beta_j - c\phi\beta_j = \Phi(c)\beta_j,$$

donde usamos $x'\beta / \sigma = c$. (3) Derivando $x'\beta + \sigma\lambda(c)$: $\beta_j + \sigma\lambda'(c)\beta_j / \sigma = \beta_j(1 + \lambda'(c))$, y $\lambda'(c) = -\lambda(c)(c + \lambda(c))$ (Clase 5, ejercicio 5.7).

□

Observaciones. El efecto sobre $\mathbb{E}[y | x]$ es β_j **escalado por la probabilidad de ser positivo**, $\Phi(c) \in (0, 1)$, y por lo tanto menor que β_j en valor absoluto. Ninguna de las dos regresiones por MCO recupera el parámetro estructural β_j : la de todos los datos estima, aproximadamente, un promedio de efectos del tipo $\Phi(c)\beta_j$ (que es el efecto sobre la media observada, no sobre la latente), y la de los positivos tiene pendiente $\beta_j[1 - \lambda(c + \lambda)]$, atenuada porque $0 < \lambda(c + \lambda) < 1$ (Ejercicio 8.2). Los tres efectos responden preguntas distintas: el primero, qué haría la demanda deseada; el segundo, qué pasa con el promedio observado; el tercero, qué pasa con quienes ya participan. La descomposición de McDonald–Moffitt separa el segundo en dos canales: el efecto sobre la probabilidad de participar y el efecto sobre el monto entre los que participan.

2.3. Estimación por máxima verosimilitud

La observación con $y = 0$ aporta $P(y^* \leq 0 | x) = \Phi(-x'\beta / \sigma)$; la con $y > 0$, la densidad de $y^* = y$, que es $\frac{1}{\sigma}\phi((y - x'\beta) / \sigma)$.

Entonces

$$\ell_n(\beta, \sigma) = \sum_{y_i=0} \log \Phi\left(-\frac{x_i'\beta}{\sigma}\right) + \sum_{y_i>0} \left[-\log \sigma + \log \phi\left(\frac{y_i - x_i'\beta}{\sigma}\right)\right]. \quad (2)$$

Esta es una **mezcla de dos tipos de observación** (una parte tipo probit, otra tipo regresión lineal). Con $\gamma = \beta/\sigma$ y $h = 1/\sigma$ (la reparametrización de Olsen, 1978), ℓ_n resulta **globalmente cóncava** en (γ, h) , de modo que el MV es único y se calcula sin dificultad (sección ★). El estimador es consistente y asintóticamente normal por las Clases 1 y 2.

⚠ El tobit es frágil

A diferencia de MCO (donde la consistencia solo exige $E[xu] = 0$), la consistencia del tobit **exige la distribución completa**: normalidad y *homocedasticidad* de u . Si $\text{Var}(u | x)$ depende de x o u no es normal, $\hat{\beta}$ es **inconsistente**: el modelo no es un QMLE (el score de Ecuación 2 no tiene media cero fuera de la especificación correcta). Además, supone que **el mismo** β gobierna la decisión de participar y la cantidad. Si no (por ejemplo, el ingreso afecta la decisión de gastar pero no cuánto), conviene un modelo en **dos partes** (*hurdle*, Clase 7) o el de selección de Heckman, que separa ambas decisiones. Alternativas robustas: el **LAD censurado** de Powell (1984), que solo exige que la *mediana* de u sea cero.

3. El modelo de selección de Heckman

Considera una ecuación de interés (por ejemplo, el salario) y una ecuación de **selección** (participar en el mercado laboral):

$$y = x'\beta + u \quad (\text{observado solo si } s = 1), \quad s = \mathbf{1}\{z'\gamma + v > 0\},$$

con $(u, v) | (x, z)$ **normal bivariada** con medias cero, $\text{Var}(u) = \sigma^2$, $\text{Var}(v) = 1$ (normalización de escala, como en el probit) y $\text{Corr}(u, v) = \rho$. Aquí z contiene a x y quizá otras variables. Observamos s y z para todos, pero y solo cuando $s = 1$.

El **parámetro clave** es ρ . Si $\rho = 0$, la selección es **ignorable** (los no observables que afectan la participación no afectan el salario) y MCO sobre los seleccionados es consistente. Si $\rho \neq 0$, quienes participan lo hacen *por razones que también afectan su salario*, y los salarios observados no son una muestra aleatoria de los potenciales.

Proposición 3.1 (La media condicional con selección).

$$\mathbb{E}[y \mid x, z, s = 1] = x'\beta + \rho\sigma \lambda(z'\gamma),$$

con $\lambda(a) = \phi(a)/\Phi(a)$ la razón inversa de Mills.

Borrador

Necesito $\mathbb{E}[u \mid v > -z'\gamma]$. Como (u, v) es normal conjunta, puedo descomponer u en una parte lineal en v y un residuo independiente de v : $u = \rho\sigma v + e$, con $e \perp v$. La parte de e no está afectada por condicionar en v (independencia), así que solo sobrevive $\rho\sigma \mathbb{E}[v \mid v > -z'\gamma]$, que es justo una media truncada de una normal estándar. Y eso lo calculamos arriba.

Demostración. Por normalidad conjunta, la proyección de u sobre v es $\mathbb{E}[u \mid v] = \frac{\text{Cov}(u, v)}{\text{Var}(v)}v = \rho\sigma v$. Sea $e = u - \rho\sigma v$; entonces $\text{Cov}(e, v) = 0$ y, siendo conjuntamente normales, e y v son independientes (Clase 5 de Econometría 1). Así

$$\mathbb{E}[u \mid x, z, s = 1] = \mathbb{E}[u \mid v > -z'\gamma] = \rho\sigma \mathbb{E}[v \mid v > -z'\gamma] + \mathbb{E}[e] = \rho\sigma \lambda(z'\gamma),$$

pues $v \sim N(0, 1)$ y, como en el Lema 2.1, $\mathbb{E}[v \mid v > -a] = \phi(a)/\Phi(a) = \lambda(a)$. Luego $\mathbb{E}[y \mid x, z, s = 1] = x'\beta + \rho\sigma \lambda(z'\gamma)$. $\square$

Este resultado explica el sesgo de MCO en la muestra seleccionada: la regresión de y sobre x **omite** $\lambda(z'\gamma)$, y esa variable omitida está correlacionada con x (porque $x \subset z$). Y sugiere la solución.

3.1. Estimador en dos pasos

Procedimiento de Heckman (1979)

1. **Probit** de s sobre z con **toda** la muestra: obtén $\hat{\gamma}$ y calcula $\hat{\lambda}_i = \lambda(z_i' \hat{\gamma})$.
2. **MCO** de y_i sobre x_i y $\hat{\lambda}_i$, usando **solo** las observaciones con $s_i = 1$. El coeficiente de $\hat{\lambda}_i$ estima $\theta = \rho\sigma$.

Por la Proposición 3.1, el paso 2 es una regresión con la variable omitida incluida: $y_i = x_i' \beta + \theta \lambda(z_i' \gamma) + e_i$ con $E[e_i | x_i, z_i, s_i = 1] = 0$. Sustituir λ por $\hat{\lambda}$ introduce un **error de estimación** del primer paso, pero ese error desaparece asintóticamente porque $\hat{\gamma} \rightarrow_p \gamma$; por eso $\hat{\beta}$ es consistente. El **test de selección** es $H_0 : \theta = 0$ (equivalentemente $\rho = 0$): el t del coeficiente de $\hat{\lambda}$.

Los errores estándar de MCO del paso 2 son incorrectos por dos razones: (i) $\hat{\lambda}_i$ es un **regresor generado**, con error de estimación que se propaga, y (ii) el error e_i es heterocedástico: $\text{Var}(y_i | x_i, z_i, s_i = 1) = \sigma^2 [1 - \rho^2 \delta_i]$ con $\delta_i = \lambda_i(\lambda_i + z_i' \gamma)$. La corrección es un caso de **M-estimación en dos pasos**: se expande el momento del segundo paso alrededor del verdadero γ_0 ,

$$\sqrt{n} \bar{g}_2(\beta_0, \hat{\gamma}) = \sqrt{n} \bar{g}_2(\beta_0, \gamma_0) + G_\gamma \sqrt{n}(\hat{\gamma} - \gamma_0) + o_p(1),$$

y el segundo término es una suma i.i.d. (función de influencia del probit) que se suma a la del primero; la varianza resultante se estima por sándwich (Newey y McFadden, 1994). En la práctica se usa el *bootstrap* o la corrección analítica que traen los programas.

3.2. La restricción de exclusión

El estimador de Heckman está *identificado* por la no linealidad de $\lambda(\cdot)$ aun si $z = x$. Pero esto es **frágil**. Sobre un rango amplio de valores, $\lambda(a)$ es casi lineal en a : $\lambda(-1) = 1,53$, $\lambda(0) = 0,80$, $\lambda(1) = 0,29$, con una pendiente que va de $-0,73$ a $-0,51$. Si $z = x$, $\lambda(x' \gamma)$ es casi una **combinación lineal de x** , y en el paso 2 hay **multicolinealidad casi perfecta** entre x y $\hat{\lambda}$: los errores estándar explotan y la estimación es inestable (Clase 8 de Econometría 1).

La salida estándar es una **restricción de exclusión**: incluir en z al menos una variable que **afecta la participación pero no el salario** directamente (el número de hijos pequeños afecta la decisión de trabajar, pero ¿no el salario por hora de quien trabaja?). Esa variable actúa como un **instrumento para la selección** y hace que λ varíe independientemente de x . Es una de las decisiones de identificación más importantes, y más debatibles, en cualquier aplicación de Heckman: la validez de la exclusión es un juicio económico que los datos no pueden confirmar.

3.3. Máxima verosimilitud completa

Alternativamente se estima todo por MV (FIML). Una observación con $s = 0$ aporta $P(s = 0) = \Phi(-z'\gamma)$. Una con $s = 1$ aporta $f(y, s = 1) = f(y)P(s = 1 | y)$. Como $y | x \sim N(x'\beta, \sigma^2)$ y, condicional en $u, v \sim N(\rho u/\sigma, 1 - \rho^2)$:

$$\ell_n = \sum_{s_i=0} \log \Phi(-z_i'\gamma) + \sum_{s_i=1} \left[\log \frac{1}{\sigma} \phi\left(\frac{y_i - x_i'\beta}{\sigma}\right) + \log \Phi\left(\frac{z_i'\gamma + \rho(y_i - x_i'\beta)/\sigma}{\sqrt{1 - \rho^2}}\right) \right].$$

Es más eficiente que dos pasos si la normalidad conjunta es cierta, pero comparte (y agrava) la fragilidad: sin normalidad, es inconsistente. Una solución es no paramétrica: la corrección de selección se modela con una función flexible $\kappa(z'\gamma)$ en lugar de $\rho\sigma\lambda$, lo que exige de nuevo una variable de exclusión.

4. ★ Postgrado: concavidad del tobit

! ★ Postgrado

La log-verosimilitud Ecuación 2 **no** es cóncava en (β, σ) , pero sí lo es en la reparametrización $(\gamma, h) = (\beta/\sigma, 1/\sigma)$.

Proposición 4.1 (Concavidad de Olsen). *En términos de $\gamma = \beta/\sigma$ y $h = 1/\sigma > 0$, la log-verosimilitud del tobit es una función cóncava de (γ, h) .*

Demostración. Para $y_i > 0$, el término es $-\log \sigma + \log \phi((y_i - x_i' \beta)/\sigma) = \log h - \frac{1}{2}(hy_i - x_i' \gamma)^2 - \frac{1}{2} \log 2\pi$, pues $(y_i - x_i' \beta)/\sigma = hy_i - x_i' \gamma$. Es suma de $\log h$ (cóncava en h) y de menos el cuadrado de una función **lineal** de (γ, h) (cóncava). Para $y_i = 0$, el término es $\log \Phi(-x_i' \gamma)$, composición de la función cóncava $\log \Phi$ (Clase 5, sección ★) con una función lineal de γ : cóncava. La suma de funciones cóncavas es cóncava. $\square$

Entonces el MV del tobit se calcula de forma robusta con cualquier algoritmo de gradiente (y el máximo local es global), y de $(\hat{\gamma}, \hat{h})$ se recupera $\hat{\sigma} = 1/\hat{h}$ y $\hat{\beta} = \hat{\gamma}/\hat{h}$, con errores estándar por el método delta.

5. Resumen

- **Censura** (valores cortados en un umbral), **truncamiento** (individuos excluidos) y **selección** (se observa y solo si pasa un filtro correlacionado con y) sesgan MCO.
- **Tobit**: $y = \max(0, y^*)$. $\mathbb{E}[y \mid x] = \Phi(c)x' \beta + \sigma \phi(c)$ (Lema 2.1). Efecto marginal sobre $\mathbb{E}[y \mid x]$: $\Phi(c)\beta_j$ (Proposición 2.1). Se estima por MV (cóncava en la parametrización de Olsen).
- El tobit exige **normalidad y homocedasticidad** y un solo mecanismo para participar y para el monto.
- **Heckman**: $\mathbb{E}[y \mid x, s = 1] = x' \beta + \rho \sigma \lambda(z' \gamma)$ (Proposición 3.1). Dos pasos: probit y luego MCO con $\hat{\lambda}$; t de $\hat{\lambda}$ testea selección ($\rho = 0$).
- **Exclusión**: hace falta una variable en z fuera de x ; sin ella, la identificación depende solo de la forma funcional de λ .

6. Ejercicios

Ejercicio 8.1. En un tobit con $x' \beta = 1$ y $\sigma = 2$, calcula $P(y = 0 \mid x)$, $\mathbb{E}[y \mid y > 0, x]$ y $\mathbb{E}[y \mid x]$. (Usa $\Phi(0,5) = 0,691$ y $\phi(0,5) = 0,352$.) Si $\beta_j = 0,5$, ¿cuánto vale el efecto marginal sobre $\mathbb{E}[y \mid x]$?

 Solución 8.1

$c = x'\beta/\sigma = 0,5$. $P(y = 0) = \Phi(-0,5) = 1 - 0,691 = 0,309$. $\lambda(0,5) = 0,352/0,691 = 0,509$ y $\mathbb{E}[y \mid y > 0] = 1 + 2(0,509) = 2,018$. $\mathbb{E}[y \mid x] = \Phi(c)x'\beta + \sigma\phi(c) = 0,691 + 2(0,352) = 1,395$ (comprobación: $\Phi \cdot \mathbb{E}[y \mid y > 0] = 0,691 \times 2,018 = 1,395$). Efecto marginal: $\Phi(c)\beta_j = 0,691 \times 0,5 = 0,346$, menor que el efecto latente 0,5.

Ejercicio 8.2. Demuestra que $0 < \lambda(c)(c + \lambda(c)) < 1$ y concluye que la regresión por MCO sobre los positivos subestima la pendiente β_j en valor absoluto (atenuación).

 Solución 8.2

La cota inferior es la desigualdad de Mills de la Clase 5 ($c + \lambda(c) > 0$) y $\lambda > 0$. Para la cota superior, $\text{Var}(z \mid z > -c) = 1 - \lambda(c)(c + \lambda(c))$ es la varianza de una normal estándar truncada en $-c$, que es **positiva**; luego $\lambda(c + \lambda) < 1$. (Directamente: $\mathbb{E}[z^2 \mid z > -c] = 1 - c\lambda$ y $\mathbb{E}[z \mid z > -c] = \lambda$, de donde $\text{Var} = 1 - c\lambda - \lambda^2$.) Por la parte (3) de la Proposición 2.1, la pendiente de $\mathbb{E}[y \mid y > 0, x]$ es $\beta_j[1 - \lambda(c + \lambda)] \in (0, \beta_j)$ si $\beta_j > 0$. Recortar la muestra a los positivos **atenúa** los coeficientes hacia cero.

Ejercicio 8.3. En una regresión de Heckman para salarios (logaritmo) de mujeres, el coeficiente del término de Mills es $-0,20$ y $\hat{\sigma} = 0,40$. Calcula $\hat{\rho}$ e interpreta el signo.

 Solución 8.3

$\hat{\theta} = \hat{\rho}\hat{\sigma} = -0,20 \Rightarrow \hat{\rho} = -0,20/0,40 = -0,5$. $\rho < 0$: las mujeres con características no observables que **aumentan la probabilidad de trabajar** (alta motivación, bajo costo de oportunidad en el hogar) tienen **salarios más bajos** que lo que sugieren sus x : selección **negativa**: $\mathbb{E}[u \mid s = 1] = \rho\sigma\lambda < 0$, de modo que los salarios observados quedan, en promedio, **por debajo** de lo que sus x predicen. MCO sin corrección estimaría entonces un salario más bajo que el de una muestra aleatoria de la población. La historia económi-

ca detrás de ese signo es un juicio del investigador; el dato solo entrega el signo y la magnitud de ρ .

Ejercicio 8.4. Muestra que si (u, v) es normal bivariada con $\text{Var}(v) = 1$ y $\text{Cov}(u, v) = \rho\sigma$, entonces $\mathbb{E}[u \mid v > -a] = \rho\sigma\lambda(a)$, y que este resultado vale con $\rho = 0$ y con $\rho = 1$ como casos extremos. ¿Qué modelo es el caso $\rho = 1, z = x$?

Solución 8.4

Es la Proposición 3.1. Con $\rho = 0$, $\mathbb{E}[u \mid v > -a] = 0$: la selección es ignorable. Con $\rho = 1$ y $u = \sigma v$: $\mathbb{E}[u \mid v > -a] = \sigma\lambda(a)$, la media truncada del tobit del Lema 2.1. En efecto, el tobit es el caso particular del modelo de selección donde **selección y resultado vienen del mismo shock** ($u = \sigma v$, $z = x$, $\gamma = \beta/\sigma$): participar y cuánto se participa dependen de la misma latente y^* . Heckman generaliza al permitir shocks distintos y correlacionados.

Ejercicio 8.5. Evalúa la razón de Mills $\lambda(a) = \phi(a)/\Phi(a)$ en $a = -1, 0, 1$ y calcula la pendiente promedio entre puntos. ¿Qué implica para el paso 2 de Heckman si $z = x$?

Solución 8.5

$\lambda(-1) = 0,242/0,159 = 1,525$; $\lambda(0) = 0,399/0,5 = 0,798$; $\lambda(1) = 0,242/0,841 = 0,288$. Pendientes: $(0,798 - 1,525)/1 = -0,727$ y $(0,288 - 0,798)/1 = -0,510$: casi constante. En ese rango, $\lambda(x'\gamma) \approx a + b x'\gamma$: una función **ca-si lineal** de x , perfectamente colineal con x salvo por la curvatura. En el paso 2, el coeficiente de $\hat{\lambda}$ y los de x no se pueden separar con precisión: errores estándar enormes. Con una variable de exclusión en z ($z \neq x$), $\hat{\lambda}$ varía además con ella y la colinealidad se rompe.

Ejercicio 8.6. Un investigador estima el efecto de la educación sobre el salario con el método de Heckman, y usa como variable de exclusión la edad. ¿Es una buena elección? ¿Y el número de hijos menores de 6 años?

💡 Solución 8.6

La edad **no** es buena exclusión: afecta tanto la participación como el salario (a través de la experiencia). La restricción de exclusión exige $\text{Corr}(z_{\text{excl}}, u) = 0$ (no afecta el salario más que por la selección) y z_{excl} relevante para la participación. Los hijos pequeños son el ejemplo clásico: afectan fuertemente la decisión de trabajar y es defendible (aunque debatible) que no afectan el salario por hora de quien trabaja. Pero si las mujeres con hijos pequeños eligen empleos más flexibles y peor pagados, la exclusión falla. La validez es un supuesto económico que los datos no pueden verificar.

Ejercicio 8.7 ★. Obtén la media condicional $\mathbb{E}[y^* \mid x, y^* > 0]$ para un error con distribución general (no normal) con densidad g y distribución G , y explica por qué el tobit es inconsistente si el error es, digamos, t de Student con pocos grados de libertad.

💡 Solución 8.7 ★

$$\mathbb{E}[u \mid u > -x'\beta] = \frac{\int_{-x'\beta}^{\infty} u g(u) du}{1 - G(-x'\beta)}.$$
 Con $g = \sigma^{-1}\phi(\cdot/\sigma)$ da $\sigma\lambda(c)$; con otra g la función cambia. El MV del tobit maximiza una verosimilitud que **supone** $\sigma\lambda(c)$ y $\Phi(c)$ como correctos; con una t de pocos grados de libertad (colas más gordas), el score del tobit no tiene media cero evaluado en β_0 : el máximo de Q_0 está en un pseudo-verdadero $\beta^* \neq \beta_0$ (Clase 2). A diferencia del probit con error mal especificado (donde al menos el signo suele sobrevivir), en el tobit la inconsistencia afecta también la magnitud. Alternativas semiparamétricas: LAD censurado de Powell, que solo exige mediana cero del error (conexión con la regresión cuantílica, Clase 12).