

Clase 9 · Datos de panel I

Efectos fijos, efectos aleatorios y el test de Hausman

Contenido

1	Observar lo mismo varias veces	1
2	MCO agrupado y errores por clúster	2
3	Efectos fijos: el estimador intra-grupos	3
3.1	Qué se pierde y qué se paga	4
3.2	Primeras diferencias	5
4	Efectos aleatorios	6
4.1	¿Cuál usar? El test de Hausman	7
5	La aproximación de Mundlak y su test robusto	9
6	★ Postgrado: equivalencia de Mundlak	9
7	Resumen	10
8	Ejercicios	10

1. Observar lo mismo varias veces

Un **panel** sigue a las mismas N unidades (personas, empresas, países) durante T períodos. Su gran ventaja sobre un corte transversal es que permite controlar por todo lo que **no cambia** en el tiempo y que no observamos: la habilidad innata de un trabajador, la cultura de una empresa, la geografía de un país. Eso es lo

que llamamos **heterogeneidad no observada**, y es la razón de ser de la mayoría de los estudios de panel.¹

El modelo es

$$y_{it} = x'_{it}\beta + c_i + u_{it}, \quad i = 1, \dots, N, \quad t = 1, \dots, T. \quad (1)$$

Aquí c_i es el **efecto individual** (constante en t , no observado) y u_{it} el error **idiosincrático**. Trabajamos con N **grande** y T **fijo** (paneles “cortos”, típicos de encuestas de hogares), y todo el límite es en $N \rightarrow \infty$. Las N unidades son i.i.d., pero **dentro de cada unidad** las T observaciones están relacionadas por c_i . Para cada i , escribimos $y_i = (y_{i1}, \dots, y_{iT})' (T \times 1)$, $X_i (T \times k)$, y similarmente u_i .

Supuesto de exogeneidad estricta

$\mathbb{E}[u_{it} \mid x_{i1}, \dots, x_{iT}, c_i] = 0$ para todo t . Es decir, el error de hoy es independiente de las x de **todos** los períodos (pasados y futuros), dado c_i .

La exogeneidad estricta es más fuerte que la exogeneidad contemporánea de MCO: **descarta** que el error de hoy afecte a las x de mañana (por ejemplo, un regresor que sea una variable dependiente rezagada). La Clase 10 trata justo el caso en que se viola.

El problema central: c_i está en el error compuesto $v_{it} = c_i + u_{it}$, y puede estar **correlacionado con** x_{it} (la habilidad correlaciona con la educación). Dos filosofías, según qué se suponga sobre c_i .

2. MCO agrupado y errores por clúster

Ignorar c_i y correr MCO sobre las NT observaciones (**MCO agrupado, pooled**) es consistente si y solo si

$$\mathbb{E}[x_{it}(c_i + u_{it})] = 0 \Leftrightarrow \mathbb{E}[x_{it}c_i] = 0,$$

es decir, si c_i es **no correlacionado** con los regresores. Si c_i afecta a x , es una variable omitida clásica (Clase 8 de Econometría 1). Pero incluso si es consistente, la inferencia usual es incorrecta:

¹ El panel más famoso es el PSID (*Panel Study of Income Dynamics*), que desde 1968 sigue a las mismas familias estadounidenses, y a sus hijos y a los hijos de sus hijos. Algunos de sus participantes llevan más años en la base de datos que muchos econométristas en su carrera. Un panel es, en cierto sentido, un experimento natural en el que cada individuo es su propio control.

v_{it} **está correlacionado en el tiempo** dentro de cada i (comparten c_i): $\text{Cov}(v_{it}, v_{is}) = \sigma_c^2 > 0$. MCO supone independencia entre observaciones; aquí hay N clústeres independientes de T observaciones dependientes.

Es una situación de M-estimación (Clase 1) con **la unidad i como observación independiente**. El score del clúster es $X_i'v_i$ (suma sobre t), y la varianza **robusta por clúster** (Liang-Zeger, Arellano) es el sándwich

$$\widehat{\text{Avar}}(\hat{\beta}_{\text{pool}}) = \left(\sum_i X_i'X_i \right)^{-1} \left(\sum_i X_i' \hat{v}_i \hat{v}_i' X_i \right) \left(\sum_i X_i'X_i \right)^{-1},$$

que es válida con $N \rightarrow \infty$, sea cual sea la correlación dentro de i (serial, heterocedástica). Ignorarla da errores estándar demasiado pequeños: con T períodos y correlación intraclase ρ del error, la varianza del promedio queda multiplicada por el **efecto de diseño** $1 + (T-1)\rho$ (Ejercicio 9.6), de modo que con $T = 5$ y $\rho = 0,5$ el error estándar verdadero es $\sqrt{3} \approx 1,7$ veces el reportado. **En paneles, siempre se usan errores estándar agrupados por individuo.**

3. Efectos fijos: el estimador intra-grupos

La idea de efectos fijos (FE) es **eliminar** c_i sin suponer nada sobre su relación con x . Promediando Ecuación 1 sobre t para cada i : $\bar{y}_i = \bar{x}_i'\beta + c_i + \bar{u}_i$. Restando,

$$\underbrace{y_{it} - \bar{y}_i}_{\tilde{y}_{it}} = \underbrace{(x_{it} - \bar{x}_i)'}_{\tilde{x}_{it}} \beta + \underbrace{(u_{it} - \bar{u}_i)}_{\tilde{u}_{it}}. \quad (2)$$

c_i **desaparece**. El estimador de efectos fijos (o **intra-grupos**, *within*) es MCO sobre Ecuación 2:

$$\hat{\beta}_{FE} = \left(\sum_i \sum_t \tilde{x}_{it} \tilde{x}_{it}' \right)^{-1} \sum_i \sum_t \tilde{x}_{it} \tilde{y}_{it}.$$

En notación matricial, con $Q = I_T - \frac{1}{T}u'u'$ la matriz que resta la media temporal, $\hat{\beta}_{FE} = \left(\sum_i X_i'QX_i \right)^{-1} \sum_i X_i'Qy_i$. (Es una proyección idempotente de la Clase 1 de Econometría 1.)

Teorema 3.1 (Consistencia y normalidad de efectos fijos). *Bajo exogeneidad estricta, muestreo i.i.d. entre unidades, $\mathbb{E}[\ddot{x}_{it}\ddot{x}'_{it}]$ su-
mada sobre t definida positiva (rango completo: **cada regresor
varía en el tiempo**) y momentos finitos, $\hat{\beta}_{FE} \xrightarrow{p} \beta$ y*

$$\sqrt{N}(\hat{\beta}_{FE} - \beta) \xrightarrow{d} N(0, A^{-1}BA^{-1}), \quad A = \mathbb{E}[X_i'QX_i], B = \mathbb{E}[X_i'Qu_iu_i'QX_i].$$

No se exige ninguna restricción sobre $\text{Cov}(c_i, x_{it})$.

Demostración. Reemplazando $\ddot{y}_{it}, \hat{\beta}_{FE} - \beta = \left(\frac{1}{N} \sum_i X_i'QX_i\right)^{-1} \frac{1}{N} \sum_i X_i'Qu_i$,
porque $Qy_i = QX_i\beta + Qc_i + Qu_i$ y $Q\iota = 0$ (aquí desaparece c_i). Los términos $X_i'QX_i$ y $X_i'Qu_i$ son i.i.d. entre i . Por la LGN,
 $\frac{1}{N} \sum X_i'QX_i \rightarrow_p A$. Para el numerador, $\mathbb{E}[X_i'Qu_i] = \sum_t \mathbb{E}[\ddot{x}_{it}u_{it}] =$
 $\sum_t \mathbb{E}[\ddot{x}_{it} \mathbb{E}[u_{it} | X_i, c_i]] = 0$ por exogeneidad estricta (la esperan-
za condicional de u_{it} dado **todas** las x_{is} , que forman $\ddot{x}_{it}$, es cero).
Por el TCL, $N^{-1/2} \sum X_i'Qu_i \rightarrow_d N(0, B)$, con $B = \mathbb{E}[X_i'Qu_iu_i'QX_i]$.
El resultado sigue por Slutsky. $\square$

Observa dónde se usó la exogeneidad **estricta**: $\ddot{x}_{it}$ contiene $\bar{x}_i$,
que depende de las x de todos los períodos. Con solo exogeneidad
contemporánea ($\mathbb{E}[u_{it} | x_{it}] = 0$) el estimador FE sería inconsis-
tente.

3.1. Qué se pierde y qué se paga

- **Variables invariantes en el tiempo** (género, raza, país de origen) tienen $\ddot{x}_{it} = 0$ y **no se pueden estimar**: se absorben en c_i . FE identifica solo efectos de variables que cambian dentro de cada unidad. Esto es el precio de no suponer nada sobre c_i .
- **Se “usa” menos variación**: solo la variación *dentro* de las unidades. Si el regresor casi no varía en el tiempo (ejemplo: una institución estable), $\ddot{x}$ es pequeño y el estimador es impreciso.
- Los c_i no se pueden estimar consistentemente con T fijo (cada uno se estima con T observaciones), pero β **sí**. Es el famoso **problema de los parámetros incidentales**, benigno en el modelo lineal, pero grave en los no lineales (Clase 11).

Proposición 3.1 (FE es MCO con dummies). $\hat{\beta}_{FE}$ coincide con el coeficiente de x en la regresión de y sobre x y N **variables dummy** (una por unidad). (Es el estimador LSDV)

Demostración. Sea D la matriz $NT \times N$ de dummies de unidad. Por el teorema de Frisch–Waugh–Lovell (Clase 3 de Econometría 1), el coeficiente de x en la regresión con D se obtiene regresando $M_D y$ sobre $M_D X$, donde $M_D = I - D(D'D)^{-1}D'$. Pero $D(D'D)^{-1}D'$ promedia cada variable sobre las T observaciones de su unidad, así que $M_D z$ es z menos su media de unidad: la transformación intra-grupos. $\square$

Un detalle práctico importante. Los programas de LSDV y de “within” dan el mismo $\hat{\beta}$, pero **la estimación de σ_u^2 requiere cuidado**: los residuos $\hat{u}_{it}$ suman cero dentro de cada i (T residuos, $T - 1$ libres), así que $\mathbb{E}[\sum_{it} \hat{u}_{it}^2] = \sigma_u^2 N(T - 1)$. Luego

$$\hat{\sigma}_u^2 = \frac{1}{N(T - 1) - k} \sum_{i,t} \hat{u}_{it}^2,$$

y **no** $1/(NT - k)$: dividir por $NT - k$ subestima σ_u^2 en un factor $(T - 1)/T$ (Ejercicio 9.2). Los programas bien hechos lo corrigen; los hechos a mano, no.

3.2. Primeras diferencias

Otra forma de eliminar c_i es **diferenciar**: $\Delta y_{it} = \Delta x'_{it} \beta + \Delta u_{it}$ para $t = 2, \dots, T$. MCO sobre esto es el estimador de **primeras diferencias** (FD). Con $T = 2$ coincide exactamente con FE (Ejercicio 9.3). Con $T > 2$ son distintos: FE es más eficiente si los u_{it} son i.i.d. (porque Δu_{it} está correlacionado serialmente de manera negativa, $\text{Corr}(\Delta u_{it}, \Delta u_{i,t-1}) = -\frac{1}{2}$), y FD es más eficiente si u_{it} es una caminata aleatoria. Ambos requieren exogeneidad estricta.

4. Efectos aleatorios

Si el investigador está dispuesto a **suponer** que c_i no se correlaciona con las x , se puede hacer mejor que FE, aprovechando **toda** la variación (también la entre unidades) y estimando variables invariantes en el tiempo.

Supuestos de efectos aleatorios (RE)

- **RE1:** exogeneidad estricta de u_{it} (como antes).
- **RE2:** $\mathbb{E}[c_i | x_{i1}, \dots, x_{iT}] = 0$ (el efecto individual es **no correlacionado** con los regresores de todos los períodos).
- **RE3 (estructura de varianza):** $\text{Var}(c_i) = \sigma_c^2$, $\text{Var}(u_{it}) = \sigma_u^2$, u_{it} no correlacionado en t y con c_i , homocedásticos.

Con RE3 el error compuesto $v_i = c_i + u_i$ tiene varianza

$$\Omega = \text{Var}(v_i) = \sigma_u^2 I_T + \sigma_c^2 u',$$

(todas las covarianzas fuera de la diagonal valen σ_c^2 ; la diagonal, $\sigma_u^2 + \sigma_c^2$). Con $\Omega \neq \sigma^2 I$ MCO agrupado es consistente (por RE2) pero **ineficiente**: la respuesta es **MCG** (Aitken, Clase 9 de Econometría 1), que se calcula así. Sea $P = \frac{1}{T} u' u$ (promedio temporal), de modo que $Q = I - P$.

Proposición 4.1 (RE es un MCG con cuasi-diferencias). Con $\omega^2 = \sigma_u^2 + T\sigma_c^2$, $\Omega = \sigma_u^2 Q + \omega^2 P$ y $\Omega^{-1/2} = \sigma_u^{-1}(I_T - \theta P)$ con

$$\theta = 1 - \frac{\sigma_u}{\sqrt{\sigma_u^2 + T\sigma_c^2}} \in [0, 1).$$

Por lo tanto el estimador RE (MCG) es MCO sobre las variables **cuasi-promediadas** $y_{it} - \theta \bar{y}_i$ y $x_{it} - \theta \bar{x}_i$.

Demostración. Como $u' = TP$, $\Omega = \sigma_u^2 I + \sigma_c^2 TP = \sigma_u^2(Q + P) + T\sigma_c^2 P = \sigma_u^2 Q + \omega^2 P$. Q y P son proyecciones ortogonales complementarias ($QP = 0$, $Q + P = I$), así que $\Omega^{-1/2} = \sigma_u^{-1}Q + \omega^{-1}P = \sigma_u^{-1}[Q + (\sigma_u/\omega)P] = \sigma_u^{-1}[I - (1 - \sigma_u/\omega)P] = \sigma_u^{-1}(I - \theta P)$. El MCG es MCO sobre los datos transformados por $\Omega^{-1/2}$ (Aitken, Clase 9 de Econometría 1), y $(I - \theta P)z_i$ tiene componentes $z_{it} - \theta \bar{z}_i$. $\square$

La **interpretación de θ** es reveladora:

- $\theta = 0$ ($\sigma_c^2 = 0$, no hay efecto individual): RE = MCO agrupado.
- $\theta \rightarrow 1$ ($T \rightarrow \infty$ o $\sigma_c^2 \gg \sigma_u^2$): RE $\rightarrow$ FE (se resta la media completa).
- Intermedio: RE sustrae **una fracción** de la media, y combina variación intra y entre unidades. De hecho, $\hat{\beta}_{RE}$ es un promedio matricial ponderado del estimador intra-grupos y el estimador *between* (MCO sobre las medias $\bar{y}_i$ y $\bar{x}_i$).

Con $\sigma_u^2 = \sigma_c^2 = 1$ y $T = 4$: $\omega^2 = 5$, $\theta = 1 - 1/\sqrt{5} = 0,553$ (Ejercicio 9.4).

En la práctica σ_u^2 y σ_c^2 no se conocen: se estiman en un primer paso (Swamy-Arora, usando los residuos de FE y del estimador *between*) y se aplica **MCG factible (FGLS)**, con la misma distribución asintótica por la Clase 9 de Econometría 1.

4.1. ¿Cuál usar? El test de Hausman

La elección entre FE y RE es una elección entre **robustez** (FE: consistente aun si c_i correlaciona con x) y **eficiencia** (RE: usa más variación y estima efectos de variables invariantes, pero es inconsistente si RE2 falla). Es un contexto ideal para el test de Hausman (1978), que compara dos estimadores:

- Bajo H_0 (RE2 cierto): $\hat{\beta}_{FE}$ y $\hat{\beta}_{RE}$ son consistentes; RE es **eficiente**.
- Bajo H_1 : solo $\hat{\beta}_{FE}$ es consistente. La diferencia $\hat{\beta}_{FE} - \hat{\beta}_{RE}$ **no tiende a cero**.

Teorema 4.1 (Lema y test de Hausman). Sea $\hat{\beta}_E$ un estimador asintóticamente eficiente bajo H_0 y $\hat{\beta}$ otro consistente bajo H_0 . Entonces, bajo H_0 , $\text{Avar}(\hat{\beta} - \hat{\beta}_E) = \text{Avar}(\hat{\beta}) - \text{Avar}(\hat{\beta}_E)$. En consecuencia,

$$H = (\hat{\beta}_{FE} - \hat{\beta}_{RE})' [\widehat{\text{Var}}(\hat{\beta}_{FE}) - \widehat{\text{Var}}(\hat{\beta}_{RE})]^{-1} (\hat{\beta}_{FE} - \hat{\beta}_{RE}) \xrightarrow{d} \chi_k^2$$

bajo H_0 (con k el número de coeficientes de variables que cambian en el tiempo).

Borrador

La clave es que la covarianza entre el estimador eficiente y la *diferencia* es cero. Si no lo fuera, podría mezclar los dos estimadores con un peso pequeño y obtener algo con **menor** varianza que el eficiente, lo cual es imposible. Una vez que $\text{Cov}(\hat{\beta}_E, \hat{\beta} - \hat{\beta}_E) = 0$, la varianza de $\hat{\beta} = \hat{\beta}_E + (\hat{\beta} - \hat{\beta}_E)$ es la suma de las varianzas, y de ahí despejo la varianza de la diferencia.

Demostración. Sea $\Delta = \hat{\beta} - \hat{\beta}_E$ y, para un vector a fijo y un escalar ϵ , consideremos el estimador consistente $\hat{\beta}_E + \epsilon\Delta$ (consistente bajo H_0 porque ambos lo son). Su varianza asintótica para la combinación lineal $a' \cdot$ es

$$a' \text{Var}(\hat{\beta}_E)a + 2\epsilon a' \text{Cov}(\hat{\beta}_E, \Delta)a + \epsilon^2 a' \text{Var}(\Delta)a.$$

Como $\hat{\beta}_E$ es eficiente, esto debe ser $\geq a' \text{Var}(\hat{\beta}_E)a$ para **todo** ϵ (positivo y negativo): $2\epsilon c + \epsilon^2 d \geq 0$ con $c = a' \text{Cov}(\hat{\beta}_E, \Delta)a$ y $d = a' \text{Var}(\Delta)a$. Para ϵ chico del signo opuesto a c , el término lineal domina y la desigualdad falla salvo que $c = 0$. Luego $\text{Cov}(\hat{\beta}_E, \Delta) = 0$ (para todo a ; con cuidado, la matriz simetrizada). Entonces $\text{Var}(\hat{\beta}) = \text{Var}(\hat{\beta}_E + \Delta) = \text{Var}(\hat{\beta}_E) + \text{Var}(\Delta)$, es decir, $\text{Var}(\Delta) = \text{Var}(\hat{\beta}) - \text{Var}(\hat{\beta}_E)$. El estadístico H es entonces una forma cuadrática χ^2 de un vector asintóticamente normal con media cero bajo H_0 (lema de la χ^2 con la inversa de la varianza, Clase 5 de Econometría 1). $\square$

Tres advertencias prácticas. (1) El lema requiere que RE sea **eficiente** bajo H_0 , lo que exige la estructura RE3 (homocedasticidad, sin correlación serial de u_{it}). **Si usas errores robustos por clúster, RE ya no es eficiente** y el test de Hausman clásico es inválido (puede incluso dar una varianza diferencia no positiva). La solución es la versión de **Mundlak** más abajo, que es robusta. (2) El test es sobre *toda* la diferencia: un rechazo dice que $\hat{\beta}_{FE}$ y $\hat{\beta}_{RE}$ difieren, no cuál coeficiente causa la diferencia. (3) Con T fijo y N moderado el test es poco potente.

5. La aproximación de Mundlak y su test robusto

Mundlak (1978) propuso modelar explícitamente la correlación entre c_i y las x : $c_i = \bar{x}_i' \delta + a_i$, con a_i **no correlacionado** con las x . Sustituyendo,

$$y_{it} = x_{it}' \beta + \bar{x}_i' \delta + a_i + u_{it}. \quad (3)$$

Esta ecuación **sí** satisface la condición de efectos aleatorios para el nuevo efecto a_i . Se puede estimar por MCO agrupado con errores por clúster (o por RE). Dos resultados notables:

1. **$\hat{\beta}$ de Ecuación 3 coincide con $\hat{\beta}_{FE}$** (probado abajo): incluir las medias $\bar{x}_i$ como controles reproduce el estimador intra-grupos.
2. **Test de Hausman robusto:** $H_0 : \delta = 0$ en Ecuación 3, con un test de Wald usando varianza por clúster. Si $\delta = 0$, c_i no está correlacionado con las x (RE2), y la versión es válida bajo heterocedasticidad y correlación serial, porque no usa el lema de eficiencia.

6. ★ Postgrado: equivalencia de Mundlak

Proposición 6.1 (MCO agrupado con medias = FE). *El coeficiente de x_{it} en la regresión agrupada de y_{it} sobre $(1, x_{it}, \bar{x}_i)$ es exactamente $\hat{\beta}_{FE}$.*

Demostración. Por Frisch-Waugh-Lovell, el coeficiente de x_{it} es el de la regresión de y_{it} sobre los **residuos** r_{it} de regresar x_{it} sobre $(1, \bar{x}_i)$ (pooled). Como $\bar{x}_i$ es el promedio de x_{it} en t , la regresión de x_{it} sobre $\bar{x}_i$ y una constante tiene coeficiente igual a la identidad en $\bar{x}_i$ (y cero en la constante): en efecto $\sum_{i,t} \bar{x}_i (x_{it} - \bar{x}_i)' = \sum_i \bar{x}_i \sum_t (x_{it} - \bar{x}_i)' = 0$, de modo que $x_{it} - \bar{x}_i$ es ortogonal a $(1, \bar{x}_i)$ y $\bar{x}_i$ es el ajuste. Luego $r_{it} = x_{it} - \bar{x}_i = \check{x}_{it}$ y el coeficiente es $(\sum \check{x}_{it} \check{x}_{it}')^{-1} \sum \check{x}_{it} y_{it} = \hat{\beta}_{FE}$ (usando $\sum_{it} \check{x}_{it} y_{it} = \sum_{it} \check{x}_{it} \check{y}_{it}$, porque $\sum_t \check{x}_{it} = 0$). $\square$

Es una forma elegante de ver que **FE** = “**controlar por la media individual de cada regresor**”: la variación identificadora es la que queda tras quitar lo que se puede predecir con $\bar{x}_i$. Y da el puente natural al modelo de **efectos correlacionados** de Chamberlain (Clase 11), que generaliza $c_i = \bar{x}_i' \delta + a_i$ a $c_i = \sum_t x_{it}' \delta_t + a_i$.

7. Resumen

- Panel: $y_{it} = x_{it}' \beta + c_i + u_{it}$; el problema es c_i , posiblemente correlacionado con x_{it} . Bajo **exogeneidad estricta** hay dos estrategias.
- **MCO agrupado** es consistente solo si $c_i \perp x$; en cualquier caso hay que usar **errores por clúster**.
- **Efectos fijos** (intra-grupos): resta medias por unidad, elimina c_i y es consistente sin restricciones sobre c_i (Teorema 3.1); no estima variables invariantes. Equivale a MCO con dummies (Proposición 3.1).
- **Efectos aleatorios** (MCG con cuasi-diferencias, $\theta = 1 - \sigma_u / \sqrt{\sigma_u^2 + T \sigma_c^2}$, Proposición 4.1): más eficiente, pero exige $c_i \perp x$.
- **Hausman** (Teorema 4.1): compara FE y RE; con errores robustos hay que usar la **regresión de Mundlak** ($\hat{\beta}$ de Ecuación 3 coincide con FE, Proposición 6.1).

8. Ejercicios

Ejercicio 9.1. Dos unidades, tres períodos. Unidad 1: $x = (1, 2, 3)$, $y = (1, 2, 6)$. Unidad 2: $x = (4, 5, 6)$, $y = (5, 5, 8)$. Calcula $\hat{\beta}_{FE}$ y el MCO agrupado (con constante).

Solución 9.1

Medias: unidad 1, $\bar{x} = 2$, $\bar{y} = 3$; unidad 2, $\bar{x} = 5$, $\bar{y} = 6$. Desvíos de x : $(-1, 0, 1)$ en ambas. Desvíos de y : unidad 1 $(-2, -1, 3)$; unidad 2 $(-1, -1, 2)$. $\sum \ddot{x}^2 = 2 + 2 = 4$; $\sum \ddot{x} \ddot{y} = (2+3) + (1+2) = 8$. $\hat{\beta}_{FE} = 8/4 = 2$. MCO agrupado: $\bar{x} = 3,5$,

$\bar{y} = 4,5$; $S_{xx} = 17,5$ y $S_{xy} = 21,5$, luego $\hat{\beta}_{pool} = 1,23$. Los dos difieren porque la relación *entre* unidades (la unidad 2 tiene x e y más altos, pero con pendiente ~ 1) pesa en el agrupado pero no en FE, que solo usa la variación dentro de cada unidad.

Ejercicio 9.2. Con $T = 2$, $N = 500$ y $k = 3$, ¿por cuánto se subestima σ_u^2 si se divide la suma de residuos intra-grupos por $NT - k$ en lugar de $N(T - 1) - k$?

 Solución 9.2

$E[SCR_{within}] \approx \sigma_u^2 [N(T - 1) - k] = \sigma_u^2 \cdot 497$. Dividir por $NT - k = 997$ da $\sigma_u^2 \cdot 497/997 \approx 0,50\sigma_u^2$: **la mitad**. Con $T = 2$ el factor $(T - 1)/T = \frac{1}{2}$ es exacto en el límite. Los errores estándar (que usan $\hat{\sigma}_u^2$) quedarían subestimados en un factor $\sqrt{0,5} \approx 0,71$. Intuición: cada unidad pierde un grado de libertad por la media estimada, y con $T = 2$ eso es la mitad de la información.

Ejercicio 9.3. Demuestra que con $T = 2$, $\hat{\beta}_{FE} = \hat{\beta}_{FD}$.

 Solución 9.3

Con $T = 2$, $\ddot{x}_{i1} = x_{i1} - \frac{x_{i1} + x_{i2}}{2} = -\frac{1}{2}\Delta x_i$ y $\ddot{x}_{i2} = +\frac{1}{2}\Delta x_i$, con $\Delta x_i = x_{i2} - x_{i1}$; análogo para y . Entonces $\sum_t \ddot{x}_{it} \ddot{x}'_{it} = \frac{1}{2} \Delta x_i \Delta x'_i$ y $\sum_t \ddot{x}_{it} \ddot{y}_{it} = \frac{1}{2} \Delta x_i \Delta y_i$. El factor $\frac{1}{2}$ se cancela en $\hat{\beta}_{FE} = (\sum \frac{1}{2} \Delta x \Delta x')^{-1} \sum \frac{1}{2} \Delta x \Delta y = (\sum \Delta x \Delta x')^{-1} \sum \Delta x \Delta y = \hat{\beta}_{FD}$.

Ejercicio 9.4. Calcula θ para $\sigma_u^2 = 1$, $\sigma_c^2 = 1$ con $T = 4$ y $T = 10$. ¿Qué pasa con $T \rightarrow \infty$? ¿Y si $\sigma_c^2 = 0$?

 Solución 9.4

$T = 4$: $\theta = 1 - 1/\sqrt{1+4} = 1 - 0,447 = 0,553$. $T = 10$: $\theta = 1 - 1/\sqrt{11} = 0,698$. $T \rightarrow \infty$: $\theta \rightarrow 1$ y RE $\rightarrow$ FE: con muchos períodos la media individual $\bar{y}_i$ estima bien c_i , y restarla completa es casi óptimo. Con $\sigma_c^2 = 0$: $\theta = 0$ y

RE = MCO agrupado, porque no hay efecto individual que eliminar.

Ejercicio 9.5. En una aplicación, $\hat{\beta}_{FE} = 0,50$ con error estándar 0,20 y $\hat{\beta}_{RE} = 0,30$ con error estándar 0,10. Calcula el estadístico de Hausman y concluye al 5 %.

 Solución 9.5

$\text{Var}(\hat{\beta}_{FE}) - \text{Var}(\hat{\beta}_{RE}) = 0,04 - 0,01 = 0,03$. $H = (0,50 - 0,30)^2 / 0,03 = 0,04 / 0,03 = 1,33$. Con $\chi^2_{1,0,95} = 3,84$: **no se rechaza** H_0 . Datos compatibles con c_i no correlacionado con x ; RE es válido y más eficiente. Nota que la diferencia (0,20) es *grande* en tamaño económico, pero FE es tan impreciso que no puede distinguirla de cero: potencia baja.

Ejercicio 9.6. (Efecto de diseño.) Para un clúster de T observaciones con varianza σ^2 y correlación ρ entre cada par, muestra que $\text{Var}(\bar{y}_i) = \frac{\sigma^2}{T} [1 + (T - 1)\rho]$. Calcula el factor sobre el error estándar con $T = 5$ y $\rho = 0,5$.

 Solución 9.6

$\text{Var}(\sum_t y_{it}) = T\sigma^2 + T(T - 1)\rho\sigma^2$, así que $\text{Var}(\bar{y}_i) = \frac{1}{T^2} [T\sigma^2 + T(T - 1)\rho\sigma^2] = \frac{\sigma^2}{T} [1 + (T - 1)\rho]$. Si las observaciones fueran independientes ($\rho = 0$), la varianza sería σ^2/T . El factor de varianza es $1 + (T - 1)\rho = 1 + 4(0,5) = 3$ y el del error estándar $\sqrt{3} = 1,73$. Ignorar la correlación intra-clúster subestima el error estándar en 42 % ($1/1,73 = 0,58$): se sobre-rechaza la nula.

Ejercicio 9.7 ★. Demuestra que $\hat{\beta}_{RE}$ es un promedio ponderado de $\hat{\beta}_W$ (intra-grupos) y $\hat{\beta}_B$ (entre unidades). (Pista: usa $\Omega^{-1} = \sigma_u^{-2}Q + \omega^{-2}P$.)

 Solución 9.7 ★

MCG: $\hat{\beta}_{RE} = (\sum X_i' \Omega^{-1} X_i)^{-1} \sum X_i' \Omega^{-1} y_i$. Con $\Omega^{-1} = \sigma_u^{-2}Q +$

$\omega^{-2}P: \sum X_i' \Omega^{-1} X_i = \sigma_u^{-2} S_{xx}^W + \omega^{-2} T S_{xx}^B$, donde $S_{xx}^W = \sum X_i' Q X_i$ y $T S_{xx}^B = \sum X_i' P X_i$ (con S^B la matriz de las medias). Análogo para $X_i' \Omega^{-1} y_i$. Como $\hat{\beta}_W = (S_{xx}^W)^{-1} S_{xy}^W$ y $\hat{\beta}_B = (S_{xx}^B)^{-1} S_{xy}^B$,

$$\hat{\beta}_{RE} = \Lambda \hat{\beta}_W + (I - \Lambda) \hat{\beta}_B, \quad \Lambda = [\sigma_u^{-2} S_{xx}^W + \omega^{-2} T S_{xx}^B]^{-1} \sigma_u^{-2} S_{xx}^W.$$

Cada estimador pesa según su precisión relativa: si σ_c^2 es grande, ω^2 es grande, el peso de $\hat{\beta}_B$ cae (la variación entre unidades está contaminada por c_i) y RE se acerca a FE. Si $\sigma_c^2 = 0$, $\omega^2 = \sigma_u^2$ y se vuelve MCO agrupado.