

Clase 11 · Paneles no lineales

Parámetros incidentales, logit condicional y el enfoque de Chamberlain

Contenido

1	Lo que funcionaba con MCO deja de funcionar	1
2	El problema de los parámetros incidentales	2
3	Logit con efectos fijos: verosimilitud condicional	3
4	Poisson con efectos fijos: la excepción feliz	5
5	El enfoque de Chamberlain: efectos correlacionados	6
5.1	Efectos marginales promedio	7
6	Qué enfoque elegir	8
7	★ Postgrado: la demostración del factor 2	9
8	Resumen	10
9	Ejercicios	10

1. Lo que funcionaba con MCO deja de funcionar

En la Clase 9, efectos fijos era trivial: restar medias elimina c_i de un modelo lineal. Con modelos no lineales (probit, logit, tobit) no hay “restar medias” que valga: c_i está dentro de una función no

lineal, $\Phi(x'_{it}\beta + c_i)$, y no se separa. La reacción natural es tratar los c_i como N **parámetros** y estimarlos junto con β (agregando N dummies, como en LSDV). Pero esto **falla**, de manera instructiva.

Consideremos el modelo binario de panel

$$y_{it} = \mathbf{1}\{x'_{it}\beta + c_i + u_{it} > 0\}, \quad t = 1, \dots, T,$$

con u_{it} logístico (o normal) i.i.d. e independiente de (x_i, c_i) (exogeneidad estricta). Hay tres estrategias, y la clase las recorre:

1. **Tratar los c_i como parámetros** (efectos fijos “ingenuos”): inconsistente con T fijo.
2. **Eliminar c_i por condicionamiento** (solo para algunos modelos: logit, Poisson).
3. **Modelar la relación entre c_i y x** (efectos correlacionados de Chamberlain), a cambio de un supuesto paramétrico sobre c_i .

2. El problema de los parámetros incidentales

El problema, nombrado por Neyman y Scott (1948), es que cuando el número de parámetros **crece con N** (un c_i por unidad) y cada uno se estima con solo T observaciones, los errores de estimación de $\hat{c}_i$ **no se promedian a cero** al aumentar N , y contaminan a $\hat{\beta}$. El ejemplo original es el más claro.

Ejemplo 2.1 (Neyman–Scott: la varianza con medias incidentales). Sean $y_{it} \sim N(\mu_i, \sigma^2)$ independientes, $t = 1, \dots, T$, con una media distinta μ_i por unidad. El MV estima cada $\hat{\mu}_i = \bar{y}_i$ y

$$\hat{\sigma}_{MV}^2 = \frac{1}{NT} \sum_{i=1}^N \sum_{t=1}^T (y_{it} - \bar{y}_i)^2.$$

Como $\sum_t (y_{it} - \bar{y}_i)^2 / \sigma^2 \sim \chi_{T-1}^2$, $\mathbb{E}[\hat{\sigma}_{MV}^2] = \sigma^2(T-1)/T$ y por la LGN (en N), $\hat{\sigma}_{MV}^2 \xrightarrow{p} \sigma^2 \frac{T-1}{T}$. Con $T = 2$, **converge a la mitad** de

σ^2 , por mucho que crezca N . Es el mismo $(T - 1)/T$ de la Clase 9: usar NT y no $N(T - 1)$ en el denominador.

En el modelo lineal este problema es trivial de corregir (cambiando el denominador) y, **para β , no existe**: el estimador intra-grupos de β es consistente. Pero en modelos no lineales, el problema alcanza a β mismo, y de manera grave. El caso más simple y limpio es el logit con $T = 2$.

Proposición 2.1 (Logit con efectos fijos “ingenuos” y $T = 2$). *Sea $T = 2$, $x_{i1} = 0$ y $x_{i2} = 1$ para todo i (un indicador de “tratamiento” en el segundo período), y u_{it} logístico. Si se estima el logit por MV con N dummies de unidad, $\hat{\beta}_{MV} \xrightarrow{p} 2\beta_0$ cuando $N \rightarrow \infty$.*

El estimador **no es consistente**: converge al *doble* del valor verdadero. La demostración está en la sección ★; la idea es que solo las unidades que **cambian** de respuesta ($y_{i1} \neq y_{i2}$) tienen información sobre β (las que tienen $y = (0, 0)$ o $(1, 1)$ llevan $\hat{c}_i \rightarrow \mp\infty$ y no aportan), y que la estimación de c_i con apenas 2 observaciones infla el efecto. En general el sesgo es de orden $1/T$ (Hahn y Newey, 2004): moderado para $T \geq 10$ pero **grande** en los paneles cortos típicos de microdatos.

3. Logit con efectos fijos: verosimilitud condicional

Para el logit existe un truco notable: hay un **estadístico suficiente** para c_i , la suma $S_i = \sum_t y_{it}$. Si condicionamos en S_i , c_i **desaparece de la verosimilitud**. Esta idea es de Rasch (1960) y Andersen (1970), y fue extendida a econometría por Chamberlain (1980).

Teorema 3.1 (Logit condicional (Chamberlain)). *En el logit de panel con u_{it} i.i.d. logístico y exogeneidad estricta, la distribución de $y_i = (y_{i1}, \dots, y_{iT})$ condicional en x_i, c_i y $S_i = s$ **no depende de c_i** :*

$$P(y_i \mid x_i, c_i, S_i = s) = \frac{\exp(\sum_t y_{it} x'_{it} \beta)}{\sum_{d \in B_s} \exp(\sum_t d_t x'_{it} \beta)}, \quad B_s = \left\{ d \in \{0, 1\}^T : \sum_t d_t = s \right\}.$$

Por lo tanto $\hat{\beta}_{CL} = \arg \max \sum_i \log P(y_i | x_i, S_i)$ es consistente y asintóticamente normal para T fijo y $N \rightarrow \infty$, sin restricciones sobre la relación entre c_i y x_i .

Borrador

La probabilidad de una secuencia particular es un producto de logits. En ese producto c_i aparece de una forma muy específica: cada $y_{it} = 1$ aporta un factor e^{c_i} en el numerador, y por lo tanto el numerador contiene $e^{c_i S_i}$. La probabilidad de que la suma sea s es la suma de las probabilidades de todas las secuencias con esa suma, y **todas** comparten el mismo factor $e^{c_i s}$. Al dividir, c_i se cancela, y el denominador común (los $1 + e^{\cdot}$) también.

Demostración. La probabilidad de una secuencia $d \in \{0, 1\}^T$ es, con Λ la logística,

$$P(y_i = d | x_i, c_i) = \prod_t \frac{\exp(d_t(x'_{it}\beta + c_i))}{1 + \exp(x'_{it}\beta + c_i)} = \frac{\exp(c_i \sum_t d_t) \exp(\sum_t d_t x'_{it}\beta)}{D_i}, \quad D_i = \prod_t (1 + e^{x'_{it}\beta + c_i}).$$

Para una secuencia con $\sum_t d_t = s$, el factor $e^{c_i s}$ es el mismo en todas. Entonces $P(S_i = s | x_i, c_i) = \frac{e^{c_i s}}{D_i} \sum_{d \in B_s} \exp(\sum_t d_t x'_{it}\beta)$ y el cociente es

$$P(y_i = d | x_i, c_i, S_i = s) = \frac{e^{c_i s} e^{\sum_t d_t x'_{it}\beta} / D_i}{e^{c_i s} \sum_{B_s} e^{\sum_t d_t x'_{it}\beta} / D_i} = \frac{\exp(\sum_t d_t x'_{it}\beta)}{\sum_{B_s} \exp(\sum_t d_t x'_{it}\beta)},$$

sin c_i . La log-verosimilitud condicional es la suma sobre i de logs de estas probabilidades, que es un “logit condicional” estándar (una verosimilitud genuina para cada i) y que satisface las condiciones de la Clase 2. Los argumentos de la Clase 1 y 2 dan consistencia y normalidad (con T fijo, $N \rightarrow \infty$). $\square$

Observaciones importantes:

- **Con** $T = 2$ el estimador es simplemente un logit de $\mathbf{1}\{y_{i2} = 1\}$ sobre Δx_i , usando solo las unidades que cambian ($y_{i1} \neq y_{i2}$). En el ejemplo anterior, $\hat{\beta}_{CL} = \log(n_{01}/n_{10})$ (Ejercicio 11.2): **la mitad** del MV ingenuo, como debe ser.

- **Las unidades con $S_i = 0$ o $S_i = T$ no aportan** (hay una sola secuencia posible; probabilidad condicional uno). Es la contraparte de efectos fijos en el modelo lineal, donde las unidades sin variación en x no aportan.
- **Solo vale para el logit.** La razón es que la logística tiene la propiedad algebraica de que $P(1)/P(0) = e^{x'\beta+c}$ es **log-lineal en c** . Con el probit, no existe estadístico suficiente para c_i (Ejercicio 11.7), y por lo tanto no hay verosimilitud condicional.
- **Limitación grave: no se pueden calcular efectos marginales.** $P(y_{it} = 1 \mid x_{it}, c_i) = \Lambda(x'_{it}\beta + c_i)$ y su derivada depende de c_i , que **no se identifica**. Solo se estima β (la dirección del efecto y la importancia relativa de las variables), no los efectos sobre probabilidades. Tampoco hay variables invariantes en el tiempo ni rezagos de y (estrictamente exógeno).
- **Poca variación = poca información.** Si pocas unidades cambian de estado, $\hat{\beta}_{CL}$ es muy impreciso.

4. Poisson con efectos fijos: la excepción feliz

En el modelo de Poisson con efectos multiplicativos, el problema de parámetros incidentales **no existe**.

Proposición 4.1 (Poisson con efectos fijos). *Supón $\mathbb{E}[y_{it} \mid x_i, c_i] = c_i \exp(x'_{it}\beta)$ (efecto multiplicativo, exogeneidad estricta). El estimador de Poisson con N dummies para los efectos (que maximiza la verosimilitud de Poisson sobre β y c_i) es **consistente para β con T fijo** y no necesita que y sea Poisson. Es el MV condicional en $\sum_t y_{it}$, que es una verosimilitud **multinomial** con probabilidades $p_{it}(\beta) = \frac{e^{x'_{it}\beta}}{\sum_s e^{x'_{is}\beta}}$.*

Demostración. Para β fijo, la CPO en c_i de $\sum_t [y_{it} \log(c_i e^{x'_{it}\beta}) - c_i e^{x'_{it}\beta}]$ es $\sum_t y_{it}/c_i = \sum_t e^{x'_{it}\beta}$, es decir $\hat{c}_i(\beta) = y_{i\cdot} / \sum_s e^{x'_{is}\beta}$, con

$y_{i\cdot} = \sum_t y_{it}$. Sustituyendo en el score de β , $\sum_t (y_{it} - c_i e^{x'_{it}\beta}) x_{it}$, queda

$$\sum_i \sum_t [y_{it} - p_{it}(\beta) y_{i\cdot}] x_{it} = 0, \quad p_{it} = \frac{e^{x'_{it}\beta}}{\sum_s e^{x'_{is}\beta}}.$$

Basta verificar que, en β_0 , la esperanza condicional de cada término es cero: $\mathbb{E}[y_{it} - p_{it} y_{i\cdot} \mid x_i, c_i] = c_i e^{x'_{it}\beta_0} - p_{it} c_i \sum_s e^{x'_{is}\beta_0} = c_i e^{x'_{it}\beta_0} - c_i e^{x'_{it}\beta_0} = 0$. Esa condición de media cero del score depende solo de la **media** condicional (como en el QMLE de Poisson, Clase 7), no de la distribución de y . Por la Clase 1, $\hat{\beta}$ es consistente y, con el sándwich, asintóticamente normal. $\square$

Es un resultado afortunado: el Poisson (y cualquier modelo con media exponencial) con efectos fijos es robusto a los parámetros incidentales y a la distribución. Es el estimador estándar en paneles de conteo y de variables no negativas (por ejemplo, patentes por empresa en T años, o flujos de comercio entre pares de países).

5. El enfoque de Chamberlain: efectos correlacionados

Cuando la verosimilitud condicional no existe (probit, tobit, o cuando se quieren efectos marginales), el enfoque alternativo es **modelar la relación entre c_i y los regresores**. Mundlak (1978) (Clase 9) propuso $c_i = \bar{x}'_i \xi + a_i$. Chamberlain (1980) lo generalizó: c_i depende de **todos** los valores de x_i , $c_i = \psi + \sum_t x'_{it} \xi_t + a_i$, y en la versión simple de Mundlak, $c_i = \psi + \bar{x}'_i \xi + a_i$, con $a_i \mid x_i \sim N(0, \sigma_a^2)$.

Proposición 5.1 (Probit con efectos correlacionados). *Sea $y_{it} = \mathbf{1}\{x'_{it}\beta + c_i + u_{it} > 0\}$ con $u_{it} \sim N(0, 1)$ independiente de (x_i, c_i) y $c_i = \psi + \bar{x}'_i \xi + a_i$ con $a_i \mid x_i \sim N(0, \sigma_a^2)$. Entonces*

$$P(y_{it} = 1 \mid x_i) = \Phi(x'_{it}\beta_a + \psi_a + \bar{x}'_i \xi_a),$$

con $\beta_a = \beta / \sqrt{1 + \sigma_a^2}$, y análogamente ψ_a, ξ_a (todos "reescalados" por el mismo factor).

Demostración. $y_{it}^* = x'_{it}\beta + \psi + \bar{x}'_i\xi + (a_i + u_{it})$. El error compuesto $a_i + u_{it}$ es $N(0, 1 + \sigma_a^2)$ e independiente de x_i . Dividiendo por $\sqrt{1 + \sigma_a^2}$ se obtiene un probit con error $N(0, 1)$ y coeficientes divididos por ese factor (como en la normalización de escala y la atenuación por heterogeneidad omitida de la Clase 5). $\square$

La ecuación es **un probit pooled con $\bar{x}_i$ como regresor adicional**. Se estima por MV con errores agrupados por individuo (el score de cada i es una suma sobre t y las observaciones del mismo i no son independientes, así que la verosimilitud “pooled” es una **cuasi-verosimilitud**; Clase 2). Alternativamente se estima un **probit de efectos aleatorios** que integra explícitamente sobre a_i con cuadratura de Gauss–Hermite: $P(y_i | x_i) = \int \prod_t \Phi(q_{it}(x'_{it}\beta + \psi + \bar{x}'_i\xi + a)) \frac{1}{\sigma_a} \phi(a/\sigma_a) da$, con $q_{it} = 2y_{it} - 1$.

5.1. Efectos marginales promedio

Aunque c_i no se identifica, el **efecto marginal promedio** sí, bajo el supuesto de Chamberlain–Mundlak. Para x_{itj} continua, la **función de estructura promediada** (Blundell y Powell, 2003) es $\mathbb{E}_c[\Phi(x'\beta + c)]$, y su derivada es el efecto promediado sobre la distribución de c_i (poblacional). Con Proposición 5.1,

$$\text{AME}_j = \mathbb{E}\left[\frac{\partial P(y_{it} = 1 | x_i)}{\partial x_{itj}}\right] = \beta_{a,j} \mathbb{E}[\phi(x'_{it}\beta_a + \psi_a + \bar{x}'_i\xi_a)],$$

que se estima por el análogo muestral con los coeficientes reescalados. **No hace falta identificar β ni σ_a^2 por separado**: los coeficientes con escala $1/\sqrt{1 + \sigma_a^2}$ producen directamente los AME. Es el equivalente en no lineales del hecho de que, en la Clase 5, los efectos marginales sí se pueden comparar aunque los coeficientes no.

Este es el estándar moderno (Wooldridge, 2005, 2019): **efectos correlacionados + AME**. Funciona con probit, logit, tobit y otros, permite variables invariantes en el tiempo y rezagos de y (con cuidado), y entrega efectos en las unidades relevantes. El costo es **un supuesto paramétrico** sobre $c_i | x_i$: normalidad, y una dependencia lineal en $\bar{x}_i$ (más flexible: agregar términos cuadráticos o interacciones de $\bar{x}_i$).

6. Qué enfoque elegir

Enfoque	Qué estima	T fijo	Efectos marginales	Supuesto sobre c_i
FE “ingenuo” (con dummies)	β	inconsistente	no	ninguno
Logit condicional	β (escala logit)	sí	no	ninguno
Poisson con FE	β	sí	semielasticidad sí	efecto multiplicativo
Corrección de sesgo ($1/T$)	β	aproximado	parcial	ninguno (T moderado)
Efectos correlacionados (Chamberlain)	β_a y AME	sí	sí	$c_i \mid x_i$ normal
Efectos aleatorios	β, σ_c	sí	sí	$c_i \perp x_i$ (fuerte)

La elección depende de lo que se quiere estimar. Para el **efecto sobre la probabilidad** hay que modelar c_i (Chamberlain). Para **solo el signo y las magnitudes relativas** bajo una exogeneidad “sin supuestos”, el logit condicional. Y para modelos de conteo, Poisson con FE.

7. ★ Postgrado: la demostración del factor 2

! ★ Postgrado

Demostramos la Proposición 2.1: el logit con N dummies y $T = 2$ converge a $2\beta_0$.

Demostración. La contribución de la unidad i es $\ell_i(\beta, c_i) = \sum_{t=1}^2 [y_{it}(\beta x_{it} + c_i) - \log(1 + e^{\beta x_{it} + c_i})]$ con $x_{i1} = 0, x_{i2} = 1$. Se maximiza en c_i para cada β .

Unidades con $y_i = (0, 0)$ o $(1, 1)$. La verosimilitud es creciente (o decreciente) en c_i sin cota, de modo que $\hat{c}_i \rightarrow -\infty (+\infty)$ y $\ell_i \rightarrow 0$ para todo β . No aportan información sobre β en el límite.

Unidades que cambian, $y_i = (0, 1)$ o $(1, 0)$. La CPO en c_i es $y_{i1} + y_{i2} = 1 = \Lambda(c_i) + \Lambda(\beta + c_i)$. Con $a = e^{c_i}$ y $b = e^\beta$: $\frac{a}{1+a} + \frac{ab}{1+ab} = 1 \Rightarrow a(1+ab) + ab(1+a) = (1+a)(1+ab) \Rightarrow a^2b = 1$, o sea $\hat{c}_i(\beta) = -\beta/2$. Sustituyendo en ℓ_i , con $\gamma = \beta/2$:

$$\ell_i^{(0,1)} = 2\gamma - 2\log(1 + e^\gamma), \quad \ell_i^{(1,0)} = -2\log(1 + e^\gamma)$$

(se usa $\log(1 + e^{-\gamma}) = \log(1 + e^\gamma) - \gamma$). Sea n_{01} y n_{10} los números de unidades que cambian de 0 a 1 y de 1 a 0. La verosimilitud perfilada es

$$\ell(\beta) = 2\gamma n_{01} - 2(n_{01} + n_{10}) \log(1 + e^\gamma),$$

y su CPO en γ es $n_{01} = (n_{01} + n_{10})\Lambda(\gamma)$, de modo que $\Lambda(\hat{\gamma}) = \frac{n_{01}}{n_{01} + n_{10}}$ y $\hat{\gamma} = \log(n_{01}/n_{10})$, es decir, $\hat{\beta}_{MV} = 2\log(n_{01}/n_{10})$.

Límite. Por la LGN, $n_{01}/n_{10} \rightarrow \frac{P(0,1)}{P(1,0)}$ (probabilidades de las secuencias, promediando sobre c_i). La razón $P(0,1 | c)/P(1,0 | c) = \frac{[1 - \Lambda(c)]\Lambda(\beta_0 + c)}{\Lambda(c)[1 - \Lambda(\beta_0 + c)]} = e^{\beta_0}$ no depende de c . Luego, promediando sobre c_i , $P(0,1)/P(1,0) = e^{\beta_0}$ y $\hat{\beta}_{MV} \rightarrow 2\beta_0$. $\square$

El mismo cálculo prueba que el **logit condicional** es el estimador correcto: condicional en que hay un cambio,

$P(y = (0, 1) \mid \text{cambio}) = e^{\beta_0} / (1 + e^{\beta_0}) = \Lambda(\beta_0)$, y su MV es $\hat{\beta}_{CL} = \log(n_{01}/n_{10})$, que converge a β_0 .

8. Resumen

- En modelos no lineales, estimar c_i como parámetros con T fijo causa el **problema de los parámetros incidentales**: $\hat{\beta}$ es **inconsistente** (ejemplo de Neyman–Scott, y logit $T = 2$: converge a $2\beta_0$).
- **Logit condicional** (Teorema 3.1): condicionando en $S_i = \sum_t y_{it}$, c_i desaparece. Consistente con T fijo, pero **no da efectos marginales**, y solo existe para logit.
- **Poisson con FE** (Proposición 4.1) funciona siempre: la condición de media del score no depende de la distribución.
- **Chamberlain–Mundlak**: modelar $c_i = \psi + \bar{x}_i' \xi + a_i$; el probit con $\bar{x}_i$ entrega coeficientes reescalados y **efectos marginales promedio** (Proposición 5.1).
- La elección entre enfoques depende de si se quieren efectos en probabilidades (modelar c_i) o sólo coeficientes (condicional).

9. Ejercicios

Ejercicio 11.1. En el ejemplo de Neyman–Scott con $\sigma^2 = 4$, calcula el límite de $\hat{\sigma}_{MV}^2$ para $T = 2, 3, 5$. ¿Qué corrección da un estimador consistente?

Solución 11.1

$\hat{\sigma}_{MV}^2 \rightarrow \sigma^2(T-1)/T$: $T = 2$: $4 \cdot \frac{1}{2} = 2$; $T = 3$: $4 \cdot \frac{2}{3} = 2,67$; $T = 5$: $4 \cdot \frac{4}{5} = 3,2$. La corrección es multiplicar por $T/(T-1)$ (dividir por $N(T-1)$ en lugar de NT): $\tilde{\sigma}^2 = \frac{1}{N(T-1)} \sum \sum (y_{it} - \bar{y}_i)^2$, que es el MV **condicional** (o restringido). Para β en el modelo lineal el sesgo del MV no existe, pero la varianza lo tiene.

Ejercicio 11.2. En un panel de $N = 1000$ individuos con $T = 2$, se observan $n_{00} = 400$, $n_{11} = 400$, $n_{01} = 120$ y $n_{10} = 80$ (indicador de tratamiento en $t = 2$). Calcula el logit condicional, su error estándar y compara con el MV ingenuo.

 Solución 11.2

Solo importan los que cambian: $n_{01} + n_{10} = 200$.
 $\hat{\beta}_{CL} = \log(120/80) = \log 1,5 = 0,405$. Error estándar:
 $\sqrt{1/n_{01} + 1/n_{10}} = \sqrt{1/120 + 1/80} = \sqrt{0,0208} = 0,144$
 (es el de un logit binario con 200 observaciones y $\hat{p} = 0,6$:
 $1/(200 \cdot 0,6 \cdot 0,4) = 0,0208$). El MV ingenuo (Proposi-
 ción 2.1) da $2 \times 0,405 = 0,811$: **el doble**. Las 800 unidades
 que no cambian ($n_{00} + n_{11}$) no aportan información sobre
 β en el logit condicional.

Ejercicio 11.3. Para $T = 3$ y $S_i = 1$, escribe la probabilidad con-
 dicional de la secuencia $(1, 0, 0)$ y la del conjunto B_1 .

 Solución 11.3

$B_1 = \{(1, 0, 0), (0, 1, 0), (0, 0, 1)\}$. $P((1, 0, 0) \mid S_i = 1) =$
 $\frac{e^{x'_{i1}\beta}}{e^{x'_{i1}\beta} + e^{x'_{i2}\beta} + e^{x'_{i3}\beta}}$: un **logit multinomial** donde la “al-
 ternativa” es el período en que ocurre el único $y = 1$ (Clase
 6). Si x no cambia entre períodos, las tres probabilidades
 son iguales ($\frac{1}{3}$) y la unidad no aporta información sobre β .

Ejercicio 11.4. Demuestra que si $y_{it} \mid c_i, x_i$ son Poisson inde-
 pendientes con medias $\lambda_{it} = c_i e^{x'_{it}\beta}$, entonces condicional en
 $y_{i\cdot} = \sum_t y_{it}$, el vector $(y_{i1}, \dots, y_{iT})$ es **multinomial** con probabili-
 dades $p_{it} = \lambda_{it} / \sum_s \lambda_{is}$, que no dependen de c_i .

 Solución 11.4

La probabilidad conjunta es $\prod_t e^{-\lambda_{it}} \lambda_{it}^{y_{it}} / y_{it}!$ y la de la su-
 ma, $y_{i\cdot} \sim \text{Poisson}(\sum_t \lambda_{it})$, es $e^{-\Lambda} \Lambda^n / n!$ con $\Lambda = \sum_t \lambda_{it}$,
 $n = y_{i\cdot}$. El cociente: $\frac{\prod_t \lambda_{it}^{y_{it}} / y_{it}!}{\Lambda^n / n!} = \frac{n!}{\prod_t y_{it}!} \prod_t \left(\frac{\lambda_{it}}{\Lambda}\right)^{y_{it}}$, que
 es la función de probabilidad multinomial. Como $\lambda_{it} / \Lambda =$

$\frac{c_i e^{x'_{it}\beta}}{c_i \sum_s e^{x'_{is}\beta}} = p_{it}(\beta)$, c_i se cancela. Es la misma verosimilitud condicional que aparece en la demostración de la Proposición 4.1.

Ejercicio 11.5. En un probit con efectos correlacionados, con $\sigma_a^2 = 3$, el coeficiente reescalado es $\hat{\beta}_a = 0,30$ y el promedio de $\phi(\cdot)$ en la muestra es 0,32. Calcula el AME y el coeficiente “estructural” β implícito.

 Solución 11.5

AME = $\beta_a \cdot \bar{\phi} = 0,30 \times 0,32 = 0,096$: casi 10 puntos porcentuales por unidad de x . Como $\beta_a = \beta / \sqrt{1 + \sigma_a^2}$ y $\sqrt{1 + 3} = 2$, $\beta = 2 \times 0,30 = 0,60$. Pero **no necesitamos β para obtener el AME**: los coeficientes reescalados ya producen directamente el efecto promedio. El efecto marginal en una persona *específica* con un c_i dado (por ejemplo $c_i = 0$) usaría $\beta = 0,60$ y daría en general un valor distinto, pero no se identifica porque no conocemos c_i de nadie.

Ejercicio 11.6. Explica por qué un investigador que estima un logit con efectos fijos condicional **no** puede decir “un año más de educación aumenta en 5 puntos porcentuales la probabilidad de empleo”.

 Solución 11.6

Porque el efecto sobre la probabilidad es $\partial P / \partial x = \Lambda'(x'\beta + c_i)\beta$, que **depende de c_i** , y el logit condicional no estima ni identifica los c_i (esa fue la gracia: se eliminaron). Sin la distribución de c_i no se puede promediar. Solo es lícito reportar $\hat{\beta}$ en términos de *log-odds* (la razón de chances condicional en c_i cambia en $e^{\hat{\beta}}$ por unidad de x : eso **sí** es independiente de c_i) y el signo. Para el efecto en probabilidades hay que pasar a efectos correlacionados y suponer algo de $c_i \mid x_i$.

Ejercicio 11.7 ★. Demuestra que en el probit con $T = 2$ la razón $P(y = (0, 1) \mid c) / P(y = (1, 0) \mid c)$ **depende de c** (salvo casos

triviales), y concluye que S_i no es suficiente para c_i .

💡 Solución 11.7 ★

Con $x_{i1} = 0$ y $x_{i2} = 1$: $\frac{P(0, 1 | c)}{P(1, 0 | c)} = \frac{\Phi(-c) \Phi(\beta + c)}{\Phi(c) \Phi(-\beta - c)}$. En el logit, $\Lambda(-c)/\Lambda(c) = e^{-c}$ y $\Lambda(\beta + c)/\Lambda(-\beta - c) = e^{\beta + c}$, de modo que la razón es e^β , **independiente de c** . En el probit, tomemos $\beta = 1$: con $c = 0$, la razón es $\frac{0,5 \cdot \Phi(1)}{0,5 \cdot \Phi(-1)} = \frac{0,841}{0,159} = 5,30$; con $c = -0,5$: $\frac{\Phi(0,5)\Phi(0,5)}{\Phi(-0,5)\Phi(-0,5)} = \frac{0,691^2}{0,309^2} = 5,02$. Valores distintos: la distribución condicional en el cambio depende de c , así que el estadístico S_i **no** agota la información sobre c_i y no hay verosimilitud condicional libre de c_i . La propiedad algebraica que usa el logit (log-linealidad de las chances en c) es una propiedad exclusiva de la logística.