

Clase 12 · Regresión cuantílica

La función check, un M-estimador no suave y normalidad asintótica sin diferenciabilidad

Contenido

1	Más allá de la media	1
2	Los cuantiles como solución a un problema de optimización	2
3	Por qué es interesante: heterogeneidad	3
4	Equivarianza y robustez	4
5	El problema técnico: un criterio sin derivadas	5
5.1	La demostración	6
6	Estimación de la varianza	8
7	Notas prácticas	8
8	★ Postgrado: por qué funciona el lema de convexidad	9
9	Resumen	10
10	Ejercicios	10

1. Más allá de la media

Toda la econometría hasta aquí modeló $\mathbb{E}[y \mid x]$. Pero la media condicional resume una distribución entera en un solo número. Si

queremos saber cómo la educación afecta al **salario de los más pobres** o al de los más ricos, o cómo un programa de nutrición afecta a los niños en el **extremo inferior** de la distribución de peso al nacer, la media no responde. Un efecto puede ser grande en la cola izquierda y nulo en el centro, o tener signos distintos en distintas partes de la distribución, y todo eso se pierde al promediar.

La **regresión cuantílica** (Koenker y Bassett, 1978) modela directamente los cuantiles condicionales $Q_\tau(y \mid x)$, para $\tau \in (0, 1)$. Y tiene una segunda virtud: es **robusta a valores extremos** (como la mediana lo es frente a la media). Su teoría es, además, un excelente ejercicio para la Clase 1, porque el criterio **no es derivable** y aun así se obtiene normalidad asintótica.

2. Los cuantiles como solución a un problema de optimización

El cuantil τ de una variable y con distribución F es $q_\tau = \inf\{q : F(q) \geq \tau\}$. La mediana ($\tau = \frac{1}{2}$) es el caso más conocido. Lo no tan conocido es que los cuantiles son **minimizadores**, igual que la media (que minimiza $\mathbb{E}(y - q)^2$).

Definición 2.1 (La función check). $\rho_\tau(u) = u(\tau - \mathbf{1}\{u < 0\})$, es decir, $\rho_\tau(u) = \tau u$ si $u \geq 0$ y $\rho_\tau(u) = (\tau - 1)u = (1 - \tau)|u|$ si $u < 0$.

Es una “V asimétrica”: penaliza los errores positivos ($y > q$, subestimar) con peso τ y los negativos con peso $1 - \tau$. Con $\tau = \frac{1}{2}$ es $\frac{1}{2}|u|$, la pérdida absoluta. Con $\tau = 0,9$, subestimar cuesta nueve veces más que sobrestimar: el q óptimo queda tan arriba que solo el 10 % de los datos lo supera.

Teorema 2.1 (El cuantil minimiza la pérdida check). *Sea y con distribución F y $\mathbb{E}|y| < \infty$. Entonces $q \mapsto \mathbb{E}[\rho_\tau(y - q)]$ es convexa, y q_τ (cualquier solución de $F(q^-) \leq \tau \leq F(q)$) la minimiza.*

Demostración. Escribimos $\mathbb{E}\rho_\tau(y - q) = \tau \int_{y>q} (y - q) dF + (1 - \tau) \int_{y<q} (q - y) dF$. Derivando respecto de q (la derivada de la parte donde y cruza q se anula, porque el integrando vale cero en $y = q$):

$$\frac{d}{dq} \mathbb{E}\rho_\tau(y - q) = -\tau P(y > q) + (1 - \tau) P(y < q) = -\tau(1 - F(q)) + (1 - \tau)F(q) = F(q) - \tau.$$

La derivada es no decreciente en q (porque F lo es), así que la función es convexa, y se anula cuando $F(q) = \tau$: el mínimo está en el cuantil τ . (Si F tiene saltos o zonas planas, la derivada cambia de signo en el cuantil, con el mismo resultado.) $\square$

Esto sugiere el análogo de MCO. MCO: $\mathbb{E}[y | x] = \arg \min_g \mathbb{E}(y - g(x))^2$, y si la media condicional es lineal, $\hat{\beta} = \arg \min \sum (y_i - x_i' b)^2$. Cuantílica: si $Q_\tau(y | x) = x' \beta(\tau)$, entonces

$$\hat{\beta}(\tau) = \arg \min_{b \in \mathbb{R}^k} \frac{1}{n} \sum_{i=1}^n \rho_\tau(y_i - x_i' b). \quad (1)$$

Es un M-estimador (Clase 1) con $m(y, x, b) = -\rho_\tau(y - x' b)$. Se resuelve por **programación lineal** (sin derivadas) y es único con probabilidad uno si y es continua. Con $\tau = \frac{1}{2}$ es **LAD** (*least absolute deviations*).

3. Por qué es interesante: heterogeneidad

Con un modelo de MCO con errores homocedásticos todas las rectas de cuantiles serían **paralelas** (mismas pendientes, intercepto distinto). La regresión cuantílica interesa precisamente cuando **no lo son**.

Ejemplo 3.1 (Modelo de locación y escala). Sea $y = \beta_0 + \beta_1 x + (1 + \gamma x)u$ con $u \sim F_u$ independiente de x y $1 + \gamma x > 0$. Como $1 + \gamma x > 0$ la transformación es creciente en u , y

$$Q_\tau(y | x) = \beta_0 + \beta_1 x + (1 + \gamma x)q_\tau(u) = [\beta_0 + q_\tau(u)] + [\beta_1 + \gamma q_\tau(u)]x,$$

con $q_\tau(u)$ el cuantil τ de u . La **pendiente** depende de τ : $\beta_1(\tau) = \beta_1 + \gamma q_\tau(u)$. Con $\beta_1 = 2, \gamma = 0.5, u \sim N(0, 1)$: $\beta_1(0.1) = 2 -$

$0,5(1,28) = 1,36$, $\beta_1(0,5) = 2$, $\beta_1(0,9) = 2,64$. El efecto de x es **el doble** de grande en la cola superior que en la inferior, y MCO (que estima el efecto en la media, 2) no lo ve.

La heterocedasticidad deja de ser una molestia de la que hay que corregirse (la Clase 9 de Econometría 1) para ser **información**: la dependencia de $\beta_1(\tau)$ en τ mide cómo x cambia la dispersión de y .

⚠ Qué significa $\beta(\tau)$

$\beta_j(\tau)$ es el efecto de x_j sobre el cuantil τ **condicional** de y . No es el efecto sobre una persona que está en el percentil τ (eso exigiría suponer que el individuo mantiene su posición en la distribución al cambiar x : *invarianza del rango*). Y tampoco es el efecto sobre el cuantil **incondicional** de y : la mediana de salarios de los hombres con educación universitaria no es la del conjunto. Para efectos sobre cuantiles incondicionales existen otros métodos (regresión RIF, Firpo–Fortin–Lemieux, 2009).

4. Equivarianza y robustez

La regresión cuantílica tiene una propiedad que MCO no tiene, y que explica su atractivo en trabajo aplicado.

Proposición 4.1 (Equivarianza a transformaciones monótonas). Si h es **estrictamente creciente**, entonces $Q_\tau(h(y) \mid x) = h(Q_\tau(y \mid x))$.

Demostración. $P(h(y) \leq h(q) \mid x) = P(y \leq q \mid x)$ por la monotonía de h . Si $q = Q_\tau(y \mid x)$ cumple $P(y \leq q \mid x) = \tau$, entonces $h(q)$ es el cuantil τ de $h(y)$. $\square$

Esto contrasta con la media: $\mathbb{E}[\log y \mid x] \neq \log \mathbb{E}[y \mid x]$ (desigualdad de Jensen). Si regresas log del salario sobre x por cuantiles, los coeficientes son los del cuantil del **salario** en logaritmos: puedes volver a niveles exponenciando sin sesgo. En MCO, volver de

logs a niveles requiere un factor de corrección (y conocer la distribución del error, Ejercicio 7.7 de la Clase 7). También es **robusta** a valores atípicos de y : cambiar el valor de una observación sin cruzar el cuantil no cambia $\hat{\beta}(\tau)$ (la función check tiene gradiente acotado).

Otra consecuencia importante: para **datos censurados**. Si $y = \max(0, y^*)$ y $Q_\tau(y^* | x) = x'\beta(\tau)$, por equivarianza (la función $\max(0, \cdot)$ es no decreciente) $Q_\tau(y | x) = \max(0, x'\beta(\tau))$. De ahí sale el estimador de **LAD censurado** de Powell (1984) mencionado en la Clase 8, **consistente sin normalidad ni homocedasticidad**: solo requiere que el cuantil (la mediana) del error sea cero. Es la alternativa robusta al tobit.

5. El problema técnico: un criterio sin derivadas

El teorema de normalidad de la Clase 1 se apoyaba en la condición de primer orden $\nabla \hat{Q}_n(\hat{\theta}) = 0$ y en el hessiano. Aquí la función ρ_τ tiene un **quiebre** en 0, el gradiente no existe ahí y el hessiano es cero casi en todas partes. La regresión cuantílica es el ejemplo clásico de que la derivabilidad no es necesaria.

La condición poblacional correcta se obtiene derivando la **esperanza** del criterio, que **sí es suave** (porque promedia el quiebre). Sea $u = y - x'\beta(\tau)$, de modo que el cuantil τ condicional de u dado x es cero, y sea $f(\cdot | x)$ su densidad condicional. Entonces la pseudo-derivada de ρ_τ es $\psi_\tau(u) = \tau - \mathbf{1}\{u < 0\}$, y

$$\mathbb{E}[x \psi_\tau(u)] = 0, \quad \text{con } \mathbb{E}[\psi_\tau(u) | x] = \tau - P(u < 0 | x) = 0.$$

Es la condición de ortogonalidad de la regresión cuantílica, el análogo de $\mathbb{E}[xu] = 0$ de MCO. Y la varianza condicional del “score” es $\text{Var}(\psi_\tau | x) = \tau(1 - \tau)$.

Teorema 5.1 (Normalidad asintótica de la regresión cuantílica). *Sea (y_i, x_i) i.i.d., $Q_\tau(y | x) = x'\beta_0$, $J = \mathbb{E}[xx'] > 0$, la densidad condicional $f(\cdot | x)$ de $u = y - x'\beta_0$ continua y acotada cerca de 0, y $D = \mathbb{E}[f(0 | x)xx'] > 0$. Entonces $\hat{\beta}(\tau) \rightarrow_p \beta_0$ y*

$$\sqrt{n}(\hat{\beta}(\tau) - \beta_0) \xrightarrow{d} N(0, \tau(1 - \tau) D^{-1} J D^{-1}).$$

Observa la **forma de sándwich** $A^{-1}BA^{-1}$ de la Clase 1, con “curvatura” $A = D$ (la densidad de u en cero, ponderada por xx') y “ruido” $B = \tau(1 - \tau)J$. Si el error es independiente de x con densidad f_u en el cuantil, $D = f_u(0)J$ y $V = \frac{\tau(1 - \tau)}{f_u(0)^2}J^{-1}$. Para la mediana de una $N(0, 1)$, $f(0) = 1/\sqrt{2\pi}$, y $V = \frac{1}{4} \cdot 2\pi = \pi/2 \approx 1,57$ (Ejercicio 12.4): la mediana es 1,57 veces menos eficiente que la media bajo normalidad, y más eficiente bajo colas gordas (Laplace, t con pocos grados de libertad).

Borrador

No puedo expandir el gradiente porque no existe. Pero puedo hacer algo equivalente: miro el criterio **reescalado** alrededor de la solución verdadera. Defino $\delta = \sqrt{n}(b - \beta_0)$ y estudio $Z_n(\delta) = \sum_i [\rho_\tau(u_i - x'_i \delta / \sqrt{n}) - \rho_\tau(u_i)]$, cuyo mínimo es $\hat{\delta} = \sqrt{n}(\hat{\beta} - \beta_0)$. La clave es una **identidad algebraica** (de Knight) que separa Z_n en un término lineal en δ , aleatorio, que satisface un TCL, y un término cuadrático, que converge a una constante. Con un criterio “lineal más cuadrático” el mínimo se calcula de forma explícita, y como Z_n es **convexo** en δ , la convergencia del criterio implica la de los mínimos.

5.1. La demostración

Lema 5.1 (Identidad de Knight). *Para todo $u, v \in \mathbb{R}$,*

$$\rho_\tau(u - v) - \rho_\tau(u) = -v\psi_\tau(u) + \int_0^v (\mathbf{1}\{u < s\} - \mathbf{1}\{u < 0\}) ds.$$

Demostración. Como ρ_τ es absolutamente continua, con derivada $\psi_\tau(w) = \tau - \mathbf{1}\{w < 0\}$ salvo en $w = 0$, $\rho_\tau(u - v) - \rho_\tau(u) = -\int_0^v \psi_\tau(u - s) ds = -\int_0^v (\tau - \mathbf{1}\{u < s\}) ds = -\tau v + \int_0^v \mathbf{1}\{u < s\} ds$. Y $-v\psi_\tau(u) = -\tau v + v\mathbf{1}\{u < 0\} = -\tau v + \int_0^v \mathbf{1}\{u < 0\} ds$. Restando, la diferencia es $\int_0^v (\mathbf{1}\{u < s\} - \mathbf{1}\{u < 0\}) ds$ (la derivada de ρ_τ no existe solo en $w = 0$, un conjunto de medida cero para la integral en s). $\square$

Demostración. (del Teorema 5.1). Sea $u_i = y_i - x_i' \beta_0$ y $\delta = \sqrt{n}(b - \beta_0)$. Aplicando el Lema 5.1 con $v = x_i' \delta / \sqrt{n}$:

$$Z_n(\delta) = \sum_i \left[\rho_\tau \left(u_i - \frac{x_i' \delta}{\sqrt{n}} \right) - \rho_\tau(u_i) \right] = -\delta' W_n + B_n(\delta),$$

$$W_n = \frac{1}{\sqrt{n}} \sum_i x_i \psi_\tau(u_i), \quad B_n(\delta) = \sum_i \int_0^{x_i' \delta / \sqrt{n}} (\mathbf{1}\{u_i < s\} - \mathbf{1}\{u_i < 0\}) ds.$$

El término lineal. Los $x_i \psi_\tau(u_i)$ son i.i.d., con media cero ($\mathbb{E}[\psi_\tau(u) | x] = 0$) y varianza $\mathbb{E}[x \psi_\tau(u)^2 x'] = \tau(1 - \tau)J$, pues $\mathbb{E}[\psi_\tau^2 | x] = \tau(1 - \tau)$. Por el TCL, $W_n \rightarrow_d N(0, \tau(1 - \tau)J)$.

El término cuadrático. Condicional en x_i , $\mathbb{E}[\mathbf{1}\{u_i < s\} - \mathbf{1}\{u_i < 0\} | x_i] = F(s | x_i) - F(0 | x_i) \approx f(0 | x_i) s$ para s chico. Integrando, $\int_0^v f(0 | x) s ds = \frac{1}{2} f(0 | x) v^2$ con $v = x_i' \delta / \sqrt{n}$. Entonces

$$\mathbb{E}[B_n(\delta)] \rightarrow \frac{1}{2} \delta' \mathbb{E}[f(0 | x) x x'] \delta = \frac{1}{2} \delta' D \delta,$$

y la varianza de $B_n(\delta)$ tiende a cero: cada sumando está acotado en valor absoluto por $|v| \mathbf{1}\{|u_i| \leq |v|\}$ con $v = x_i' \delta / \sqrt{n}$, así que su cuadrado tiene esperanza de orden $n^{-3/2}$, y la suma de n términos independientes tiene varianza de orden $n^{-1/2}$. Luego $B_n(\delta) \rightarrow_p \frac{1}{2} \delta' D \delta$ para cada δ .

Convergencia del mínimo. Entonces $Z_n(\delta) \rightarrow_d Z(\delta) = -\delta' W + \frac{1}{2} \delta' D \delta$ con $W \sim N(0, \tau(1 - \tau)J)$, y Z tiene un único minimizador, $\delta^* = D^{-1}W$. Como cada Z_n es **convexa** en δ (suma de funciones convexas), el lema de convexidad (Lema 5.2 abajo) implica que $\hat{\delta} = \arg \min Z_n \rightarrow_d \delta^* = D^{-1}W \sim N(0, \tau(1 - \tau)D^{-1}JD^{-1})$. $\square$

El lema de convexidad hace en este caso el papel de la LGN uniforme y el teorema del valor medio: reemplaza “criterio derivable” por “criterio convexo”.

Lema 5.2 (Lema de convexidad (Pollard, 1991)). *Si $Z_n(\delta)$ son funciones convexas aleatorias que convergen (en distribución, puntualmente) a una función $Z(\delta)$ con un **único** minimizador δ^* , entonces cualquier minimizador $\hat{\delta}_n$ de Z_n converge a δ^* (en distribución, si δ^* es aleatorio).*

En la sección ★ demostramos la versión determinística, que contiene la idea clave.

6. Estimación de la varianza

El problema práctico es $D = \mathbb{E}[f(0 | x)xx']$: requiere estimar la **densidad** del error en cero, un objeto no paramétrico. Tres soluciones:

1. **Bootstrap por pares** (remuestrear (y_i, x_i) con reemplazo y recalcular $\hat{\beta}(\tau)$): la más usada, simple y robusta a heterocedasticidad.
2. **Estimador de Powell** (con kernel): $\hat{D} = \frac{1}{nh} \sum_i K(\hat{u}_i/h) x_i x_i'$ y $\hat{V} = \tau(1 - \tau)\hat{D}^{-1}\hat{J}\hat{D}^{-1}$.
3. **Hendricks-Koenker**: estima la *función de dispersión* $1/f(F^{-1}(\tau))$ con diferencias de cuantiles estimados en $\tau \pm h$.

Para inferencia conjunta sobre varios cuantiles (¿son iguales las pendientes en $\tau = 0,25$ y $0,75$?), el bootstrap sobre todos los cuantiles a la vez es lo estándar.

7. Notas prácticas

- **Cruce de cuantiles.** Con $\tau_1 < \tau_2$ la teoría exige $Q_{\tau_1}(y | x) \leq Q_{\tau_2}(y | x)$ para todo x , pero las rectas estimadas por separado pueden **cruzarse** en las colas de x (especialmente en muestras chicas). Es señal de especificación lineal inadecuada o escasez de datos; existen correcciones por reordenamiento (Chernozhukov, Fernández-Val y Galichon, 2010).
- **Cuantiles extremos.** Para τ cerca de 0 o 1, la teoría normal es mala (pocos datos en la cola); hay teoría de valores extremos (Chernozhukov, 2005).
- **Variable endógena.** La regresión cuantílica con variables instrumentales (Chernozhukov-Hansen, 2005) permite estimar efectos heterogéneos con endogeneidad.

- **Con paneles**, la eliminación de efectos fijos no funciona como en MCO (el cuantil de una diferencia no es la diferencia de cuantiles); ver Koenker (2004), Canay (2011).

8. ★ Postgrado: por qué funciona el lema de convexidad

! ★ Postgrado

La convexidad convierte la convergencia puntual en convergencia de los mínimos. Mostramos la versión determinística: si funciones convexas convergen puntualmente a una función estrictamente convexa, sus minimizadores convergen.

Proposición 8.1 (Convergencia de minimizadores de convexas). Sean $Z_n : \mathbb{R}^k \rightarrow \mathbb{R}$ convexas con $Z_n(\delta) \rightarrow Z(\delta)$ para todo δ , y Z con un único minimizador δ^* . Entonces todo minimizador $\hat{\delta}_n$ de Z_n cumple $\hat{\delta}_n \rightarrow \delta^*$.

Demostración. Fija $\varepsilon > 0$ y sea $S = \{\delta : \|\delta - \delta^*\| = \varepsilon\}$ la esfera de radio ε . Como Z tiene un único minimizador y es continua (límite puntual de convexas, que es convexa y por tanto continua), $\eta = \min_S Z - Z(\delta^*) > 0$. Por convergencia puntual y convexidad, la convergencia es **uniforme en compactos** (resultado clásico de análisis convexo), así que para n grande $Z_n(\delta) > Z_n(\delta^*)$ para todo $\delta \in S$ (la brecha η no desaparece). Ahora tomemos un punto δ fuera de la bola, con $\|\delta - \delta^*\| > \varepsilon$. El segmento de δ^* a δ cruza la esfera en un punto $\delta_S = (1 - \lambda)\delta^* + \lambda\delta$ con $\lambda \in (0, 1)$. Por convexidad, $Z_n(\delta_S) \leq (1 - \lambda)Z_n(\delta^*) + \lambda Z_n(\delta)$, es decir

$$Z_n(\delta) \geq Z_n(\delta^*) + \frac{Z_n(\delta_S) - Z_n(\delta^*)}{\lambda} > Z_n(\delta^*),$$

pues $Z_n(\delta_S) > Z_n(\delta^*)$ y $\lambda > 0$. Luego ningún punto fuera de la bola puede ser mínimo: $\|\hat{\delta}_n - \delta^*\| \leq \varepsilon$ para n grande. Como ε es arbitrario, $\hat{\delta}_n \rightarrow \delta^*$. $\square$

Esta es la misma idea del Ejercicio 1.7 de la Clase 1 (concavidad en lugar de compacidad), y es lo que permite que los M-estimadores **no suaves** tengan teoría asintótica completa. Pollard (1991) la extiende a convergencia en distribución, que es lo que se usa en la demostración.

9. Resumen

- El cuantil τ minimiza $\mathbb{E}\rho_\tau(y - q)$ con $\rho_\tau(u) = u(\tau - \mathbf{1}\{u < 0\})$ (Teorema 2.1). La **regresión cuantílica** es $\hat{\beta}(\tau) = \arg \min \sum \rho_\tau(y_i - x_i' b)$, un M-estimador sin derivadas, resuelto por programación lineal.
- Interesa cuando los efectos son **heterogéneos** a lo largo de la distribución (Ejemplo 3.1); es **equivariante** a transformaciones monótonas y robusta a atípicos.
- **Normalidad** (Teorema 5.1): $\sqrt{n}(\hat{\beta}(\tau) - \beta_0) \rightarrow N(0, \tau(1 - \tau)D^{-1}JD^{-1})$, con $D = \mathbb{E}[f(0 | x)xx']$. La demostración usa la **identidad de Knight** y el **lema de convexidad**, no el hessiano.
- La varianza exige estimar la densidad del error: se usa **bootstrap**.
- El LAD censurado de Powell generaliza al tobit sin supuestos distribucionales.

10. Ejercicios

Ejercicio 12.1. Para la muestra $\{1, 2, 10\}$, calcula $\sum |y_i - q|$ en $q = 2$ (mediana) y en $q = 4,33$ (media). Verifica que la mediana minimiza la pérdida absoluta.

Solución 12.1

$q = 2$: $|1 - 2| + |2 - 2| + |10 - 2| = 1 + 0 + 8 = 9$.
 $q = 13/3 = 4,33$: $3,33 + 2,33 + 5,67 = 11,33$. La mediana tiene menor pérdida absoluta. Además, $q \mapsto \sum |y_i - q|$ es lineal por tramos con pendiente $\#\{y_i < q\} - \#\{y_i > q\}$. Para $q < 1$ la pendiente es -3 ; entre 1 y 2 es -1 ; entre 2 y

10 es +1; sobre 10 es +3. Cambia de signo justo en el dato central, $q = 2$: ahí está el mínimo.

Ejercicio 12.2. Con $\tau = 0,9$, calcula $\rho_\tau(u)$ para $u = -2$ y $u = +2$. ¿Qué implica sobre dónde se coloca el ajuste?

 Solución 12.2

$\rho_{0,9}(2) = 0,9 \cdot 2 = 1,8$ y $\rho_{0,9}(-2) = (0,9 - 1)(-2) = 0,2$. Un residuo positivo (y por encima del ajuste) cuesta **9 veces más** que uno negativo de igual magnitud. Para minimizar la pérdida total, el ajuste se sube hasta que dejar los puntos por arriba cuesta tanto como dejarlos por debajo: ocurre cuando solo el 10 % de los puntos queda por encima (condición de primer orden $F(q) = \tau = 0,9$).

Ejercicio 12.3. En el Ejemplo 3.1 con $\beta_1 = 2$, $\gamma = 0,5$ y $u \sim N(0, 1)$, calcula la diferencia entre la pendiente en $\tau = 0,9$ y en $\tau = 0,1$. ¿Cómo testearías $H_0 : \gamma = 0$ (homocedasticidad) usando regresión cuantílica?

 Solución 12.3

$\beta_1(0,9) - \beta_1(0,1) = \gamma[q_{0,9}(u) - q_{0,1}(u)] = 0,5 \times 2,56 = 1,28$. Si $\gamma = 0$, todas las pendientes son iguales ($\beta_1(\tau) = \beta_1$ para todo τ): se testea $H_0 : \beta_1(0,9) = \beta_1(0,1)$ con una prueba de Wald (bootstrap para la varianza de la diferencia). Es una prueba **de homocedasticidad más general que las de la Clase 9 de Econometría 1**, porque detecta cualquier cambio de la pendiente a lo largo de la distribución, no solo cambios de varianza.

Ejercicio 12.4. Para un error i.i.d. $N(0, 1)$, calcula la varianza asintótica de $\sqrt{n}(\hat{m} - m)$ para la mediana muestral y compárala con la de la media. ¿Y si el error es Laplace con densidad $\frac{1}{2}e^{-|u|}$?

 Solución 12.4

Mediana: $V = \tau(1 - \tau)/f(0)^2 = \frac{1}{4}/f(0)^2$. Normal: $f(0) =$

$1/\sqrt{2\pi}$, $V = \frac{1}{4} \cdot 2\pi = \pi/2 = 1,571$. La media tiene varian-
za 1: la mediana tiene un **57 % más** de varianza (eficiencia
relativa $1/1,57 \approx 0,64$; bajo normalidad el MV es la media).
Laplace: $f(0) = \frac{1}{2}$, $V = \frac{1}{4}/\frac{1}{4} = 1$, y su varianza es 2 (la de
Laplace con escala 1 es 2): la mediana tiene varianza asin-
tótica 1 y la media 2. **Bajo Laplace la mediana gana por
factor 2** (es el MV).

Ejercicio 12.5. Demuestra con un ejemplo que $\mathbb{E}[\log y] \neq \log \mathbb{E}[y]$ pero $\text{mediana}(\log y) = \log \text{mediana}(y)$. Usa y con valores $\{1, e, e^4\}$ equiprobables.

 Solución 12.5

$\mathbb{E}[y] = (1 + 2,718 + 54,6)/3 = 19,44$ y $\log \mathbb{E}[y] = 2,97$.
 $\mathbb{E}[\log y] = (0 + 1 + 4)/3 = 1,67 \neq 2,97$. Mediana de y :
 $e = 2,718$ y su log vale 1. Mediana de $\log y$: valores $\{0, 1, 4\}$,
mediana 1. **Coinciden**. La media no pasa por transformacio-
nes no lineales; la mediana (y cualquier cuantil) sí.

Ejercicio 12.6. Si $y = \max(0, y^*)$ y $Q_\tau(y^* | x) = x'\beta(\tau)$, demues-
tra que $Q_\tau(y | x) = \max(0, x'\beta(\tau))$. ¿Cómo se estima $\beta(\tau)$ con
esto?

 Solución 12.6

Hay dos casos. (i) Si $x'\beta(\tau) > 0$: para $q > 0$, $P(y \leq q | x) = P(y^* \leq q | x)$ (porque $y = y^*$ cuando $y^* > 0$), así que el cuantil τ de y coincide con el de y^* , que es $x'\beta(\tau)$. (ii) Si $x'\beta(\tau) \leq 0$: como el cuantil τ de y^* es ≤ 0 , $P(y^* \leq 0 | x) \geq \tau$, y por lo tanto $P(y = 0 | x) = P(y^* \leq 0 | x) \geq \tau$: el cuantil τ de y es 0. En ambos casos $Q_\tau(y | x) = \max(0, x'\beta(\tau))$. El estimador **LAD censurado** minimiza $\sum \rho_\tau(y_i - \max(0, x_i'b))$; no es convexo, pero es consistente sin suponer normalidad ni homocedasticidad: solo hace falta que el cuantil τ del error sea cero. Es la alternativa semiparamétrica a la Clase 8.

Ejercicio 12.7 ★. Calcula el gradiente y el hessiano de $Q_0(b) = \mathbb{E} \rho_\tau(y - x'b)$ en $b = \beta_0$, y comprueba que el hessiano es $D =$

$\mathbb{E}[f(0 \mid x)xx']$.

💡 Solución 12.7 ★

Condiciona en x , por el Teorema 2.1 con $q = x'b$:
 $\frac{\partial}{\partial q} \mathbb{E}[\rho_\tau(y - q) \mid x] = F_y(q \mid x) - \tau$. Con la regla de la cadena, $\nabla Q_0(b) = \mathbb{E}[x (F_y(x'b \mid x) - \tau)]$. En $b = \beta_0$, $F_y(x'\beta_0 \mid x) = \tau$ y el gradiente es cero. Derivando otra vez, $\nabla^2 Q_0(b) = \mathbb{E}[f_y(x'b \mid x)xx']$, que en β_0 es $\mathbb{E}[f(0 \mid x)xx'] = D$, con $f(0 \mid x)$ la densidad de $u = y - x'\beta_0$ en cero (la densidad de y en $x'\beta_0$ coincide con la de u en cero). Aunque el criterio *muestral* no es derivable, **su esperanza sí tiene hessiano**: ese es el A del sándwich.