

Clase 1 · Procesos estocásticos y estacionariedad

Autocovarianza, ergodicidad y la ley de los grandes números con dependencia

Contenido

1	El problema de una sola historia	2
2	Procesos estocásticos	2
2.1	La función de autocovarianza	4
2.2	Ejemplos	4
3	Ergodicidad y la ley de los grandes números	5
3.1	La varianza del promedio	6
3.2	Ergodicidad	7
4	Estimación de la media, de la autocovarianza y de la ACF	9
4.1	La ACF de un ruido blanco	10
5	★ Postgrado: la densidad espectral	11
6	Resumen	12
7	Ejercicios	12

1. El problema de una sola historia

En Econometría 1 y 2 trabajamos con muestras de n observaciones **independientes** de una misma distribución. Cada observación era una nueva “tirada”, y la ley de los grandes números decía que promediar tiradas recupera la esperanza. Una serie de tiempo es otra cosa. Observamos $y_1, \dots, y_T$: el PIB de Chile trimestre a trimestre, el tipo de cambio día a día. Esas observaciones **no son independientes** (el PIB de hoy se parece al de ayer) y, además, el mundo no repite la historia: tenemos **una sola realización** del proceso que generó los datos. No podemos “volver a correr” 2008 para ver otra trayectoria.

Para hacer inferencia con una sola trayectoria necesitamos dos ideas:

1. **Estacionariedad:** las propiedades del proceso no dependen de la fecha. Sin esto, cada observación vendría de una distribución distinta y no habría nada que promediar.
2. **Ergodicidad:** los promedios *a lo largo del tiempo* (de una sola trayectoria) convergen a las esperanzas *de ensamble* (sobre todas las trayectorias posibles). Es el sustituto de la ley de los grandes números.

Esta clase define ambas, calcula las cantidades básicas (autocovarianzas, varianza del promedio) y muestra qué cambia respecto del mundo i.i.d. El mensaje: **la dependencia no impide aprender, pero cambia la varianza** de todo lo que se estima.¹

2. Procesos estocásticos

Definición 2.1 (Proceso estocástico). Un **proceso estocástico** es una colección de variables aleatorias $\{y_t\}_{t \in \mathbb{Z}}$ definidas sobre un mismo espacio de probabilidad. Una **serie de tiempo** es una **realización** (una trayectoria) del proceso, observada en $t = 1, \dots, T$.

Cada y_t es una variable aleatoria con su propia distribución, y para describir el proceso hay que describir las distribuciones **conjuntas** de $(y_{t_1}, \dots, y_{t_k})$ para cualquier colección de fechas. En la

¹ George Box y Gwilym Jenkins publicaron en 1970 *Time Series Analysis: Forecasting and Control*, el libro que convirtió el análisis de series de tiempo en una metodología sistemática para la práctica (identificar, estimar, diagnosticar, pronosticar). Gran parte de lo que estudiaremos en las Clases 2 a 4 se llama aún “metodología Box-Jenkins”.

práctica nos conformamos con los dos primeros momentos:

$$\mu_t = \mathbb{E}[y_t], \quad \gamma(t, s) = \text{Cov}(y_t, y_s) = \mathbb{E}[(y_t - \mu_t)(y_s - \mu_s)].$$

Sin restricciones, un proceso tendría una media distinta en cada fecha y una covarianza distinta para cada par (t, s) : infinitos parámetros y una sola observación de cada uno. La estacionariedad es la restricción que lo hace manejable.

Definición 2.2 (Estacionariedad).

- $\{y_t\}$ es **estrictamente estacionario** si para todo k , toda colección de fechas $t_1, \dots, t_k$ y todo desplazamiento h , la distribución conjunta de $(y_{t_1}, \dots, y_{t_k})$ es la misma que la de $(y_{t_1+h}, \dots, y_{t_k+h})$.
- $\{y_t\}$ es **débilmente estacionario** (o *estacionario en covarianza*) si $\mathbb{E}[y_t^2] < \infty$, $\mathbb{E}[y_t] = \mu$ no depende de t , y $\text{Cov}(y_t, y_{t+h}) = \gamma(h)$ depende **solo del rezago** h , no de t .

La estacionariedad estricta dice que *toda* la distribución es invariante a traslaciones temporales; la débil, que lo son los dos primeros momentos. Si hay segundos momentos finitos, **estricta implica débil** (una distribución que no cambia tiene momentos que no cambian). El recíproco es falso en general (se puede tener media y covarianzas constantes con colas que cambian en el tiempo), salvo en un caso importante.

Proposición 2.1 (Débil implica estricta si el proceso es gaussiano). *Si $\{y_t\}$ es un proceso gaussiano (toda colección finita es normal multivariada) y débilmente estacionario, entonces es estrictamente estacionario.*

Demostración. La distribución normal multivariada queda determinada por su vector de medias y su matriz de covarianzas. Para $(y_{t_1}, \dots, y_{t_k})$ las medias son μ y las covarianzas $\gamma(t_i - t_j)$; para $(y_{t_1+h}, \dots, y_{t_k+h})$ son las mismas. Dos normales con los mismos parámetros son la misma distribución. $\square$

De aquí en adelante, “estacionario” significará **débilmente estacionario**, salvo que se indique otra cosa. Es lo que se necesita para casi toda la teoría de estimación lineal.

2.1. La función de autocovarianza

Para un proceso estacionario, la **función de autocovarianza** es $\gamma(h) = \text{Cov}(y_t, y_{t+h})$ y la **función de autocorrelación** (ACF) es $\rho(h) = \gamma(h)/\gamma(0)$. Ambas satisfacen propiedades que usaremos todo el curso.

Proposición 2.2 (Propiedades de la autocovarianza). *Sea $\gamma(\cdot)$ la autocovarianza de un proceso estacionario. Entonces:*

1. $\gamma(0) = \text{Var}(y_t) \geq 0$.
2. $|\gamma(h)| \leq \gamma(0)$ para todo h (así $|\rho(h)| \leq 1$).
3. $\gamma(h) = \gamma(-h)$ (simetría).
4. γ es **semidefinida positiva**: para todo n y todo $a \in \mathbb{R}^n$, $\sum_{i,j} a_i a_j \gamma(i-j) \geq 0$; es decir, la matriz de Toeplitz $\Gamma_n = [\gamma(i-j)]_{i,j=1}^n$ es semidefinida positiva.

Demostración.

- (1) es una varianza. (2) Por Cauchy-Schwarz, $|\text{Cov}(y_t, y_{t+h})| \leq \sqrt{\text{Var}(y_t) \text{Var}(y_{t+h})} = \gamma(0)$. (3) $\gamma(h) = \text{Cov}(y_t, y_{t+h}) = \text{Cov}(y_{t-h}, y_t) = \gamma(-h)$, pues la covarianza es simétrica y el valor no depende de t . (4) Con $a = (a_1, \dots, a_n)'$, $0 \leq \text{Var}(\sum_i a_i y_i) = \sum_{i,j} a_i a_j \text{Cov}(y_i, y_j) = a' \Gamma_n a$.

□

La propiedad (4) es más profunda de lo que parece: **no toda función simétrica con $\gamma(0) \geq |\gamma(h)|$ es una autocovarianza**. Por ejemplo, $\gamma(0) = 1$, $\gamma(\pm 1) = 0.9$, $\gamma(\pm 2) = 0$ viola la semidefinición positiva (Ejercicio 1.7). La sección ★ muestra que esa condición es suficiente para que exista un proceso.

2.2. Ejemplos

Ejemplo 2.1 (Un zoológico mínimo).

1. **Ruido blanco:** ε_t con media cero, varianza σ^2 y $\text{Cov}(\varepsilon_t, \varepsilon_s) = 0$ para $t \neq s$ (escribimos $\varepsilon_t \sim WN(0, \sigma^2)$). Es estacionario con $\gamma(0) = \sigma^2$ y $\gamma(h) = 0$ si $h \neq 0$. Un i.i.d. es un caso particular, pero el ruido blanco *solo* exige no correlación, no independencia.
2. **Media móvil de orden 1, MA(1):** $y_t = \varepsilon_t + \theta \varepsilon_{t-1}$ con $\varepsilon_t \sim WN(0, \sigma^2)$. Entonces $\gamma(0) = \sigma^2(1 + \theta^2)$, $\gamma(\pm 1) = \theta\sigma^2$ y $\gamma(h) = 0$ para $|h| \geq 2$. La autocorrelación es $\rho(1) = \theta/(1 + \theta^2)$, que **no puede superar** $\frac{1}{2}$ (el máximo se alcanza en $\theta = 1$).
3. **Caminata aleatoria:** $y_t = y_{t-1} + \varepsilon_t$, $y_0 = 0$. Entonces $y_t = \sum_{s=1}^t \varepsilon_s$ tiene $\text{Var}(y_t) = t\sigma^2$, que depende de t : **no es estacionario** (es el tema de la Clase 6).
4. **Tendencia más ruido:** $y_t = a + bt + \varepsilon_t$ tiene $\mathbb{E}[y_t] = a + bt$, no constante: no es estacionario, pero $y_t - bt$ sí lo es (**estacionario en tendencia**).
5. **Un nivel aleatorio:** $y_t = Z$ para todo t , con Z aleatoria de media cero y varianza σ^2 . Es estacionario con $\gamma(h) = \sigma^2$ para todo h : la “memoria” nunca se olvida. Como veremos, es el ejemplo de un proceso **no ergódico**.

Del ejemplo 2 sale una observación útil para la Clase 13 de Econometría 2: los valores θ y $1/\theta$ dan **la misma autocorrelación** $\rho(1) = \theta/(1 + \theta^2)$ (porque $\frac{1/\theta}{1+1/\theta^2} = \frac{\theta}{\theta^2+1}$). Con solo la ACF no podemos distinguir un MA(1) con $\theta = 0,5$ de uno con $\theta = 2$. De ahí la elección de la raíz *invertible* en esa clase (Clase 2 de este curso).

3. Ergodicidad y la ley de los grandes números

Con una sola trayectoria, lo que podemos calcular es el **promedio temporal** $\bar{y}_T = \frac{1}{T} \sum_{t=1}^T y_t$. Lo que nos interesa es la **media de ensamble** $\mu = \mathbb{E}[y_t]$. ¿Cuándo $\bar{y}_T \rightarrow \mu$? En el caso i.i.d. basta la LGN; con dependencia, la respuesta tiene dos caras: una elemental, en media cuadrática, y una general, el teorema ergódico.

3.1. La varianza del promedio

El primer paso es calcular la varianza de $\bar{y}_T$ para un proceso estacionario. Como $\text{Var}(\sum_t y_t) = \sum_{t,s} \gamma(t-s)$, y hay $T - |h|$ pares (t, s) con $t - s = h$,

$$\text{Var}(\bar{y}_T) = \frac{1}{T^2} \sum_{t,s=1}^T \gamma(t-s) = \frac{1}{T} \sum_{h=-(T-1)}^{T-1} \left(1 - \frac{|h|}{T}\right) \gamma(h). \quad (1)$$

En el caso i.i.d., $\gamma(h) = 0$ para $h \neq 0$ y esto es $\gamma(0)/T$. Con dependencia, hay términos adicionales. Cuando las autocovarianzas son **absolutamente sumables**, el efecto de la dependencia se resume en un solo número.

Teorema 3.1 (LGN en media cuadrática y varianza de largo plazo). *Sea $\{y_t\}$ estacionario con $\gamma(h) \rightarrow 0$ cuando $h \rightarrow \infty$. Entonces $\bar{y}_T \rightarrow \mu$ en media cuadrática (y por lo tanto en probabilidad). Si además $\sum_{h=-\infty}^{\infty} |\gamma(h)| < \infty$, entonces*

$$T \text{Var}(\bar{y}_T) \rightarrow \sigma_{LR}^2 = \sum_{h=-\infty}^{\infty} \gamma(h) = \gamma(0) + 2 \sum_{h=1}^{\infty} \gamma(h).$$

Borrador

De Ecuación 1, $\text{Var}(\bar{y}_T)$ es un promedio ponderado de $\gamma(h)$ con pesos $(1 - |h|/T)/T$. Para que tienda a cero basta que los $\gamma(h)$ lejanos sean chicos: la contribución de la parte “cercana” es del orden $1/T$ por el número finito de rezagos, y la de la parte “lejana” es chica porque $\gamma(h) \rightarrow 0$. Para el segundo resultado, multiplico por T : queda $\sum_h (1 - |h|/T) \gamma(h)$, y cada término converge a $\gamma(h)$ (porque $1 - |h|/T \rightarrow 1$), con una cota sumable que me deja intercambiar límite y suma (convergencia dominada).

Demostración. (Primera parte.) De Ecuación 1, $\text{Var}(\bar{y}_T) \leq \frac{1}{T} \sum_{|h| < T} |\gamma(h)| = \frac{1}{T} \left[|\gamma(0)| + 2 \sum_{h=1}^{T-1} |\gamma(h)| \right]$. Como $\gamma(h) \rightarrow 0$, la media de Cesàro $\frac{1}{T} \sum_{h=1}^{T-1} |\gamma(h)| \rightarrow 0$ (el promedio de los primeros T términos de una sucesión que tiende a cero tiende a cero).

Luego $\text{Var}(\bar{y}_T) \leq \frac{\gamma(0)}{T} + \frac{2}{T} \cdot \left[\sum_{h=1}^{T-1} |\gamma(h)| \right] \rightarrow 0$. Como $\mathbb{E}[\bar{y}_T] = \mu$, $\mathbb{E}(\bar{y}_T - \mu)^2 = \text{Var}(\bar{y}_T) \rightarrow 0$, y la convergencia en media cuadrática implica convergencia en probabilidad (desigualdad de Chebyshev).

(Segunda parte.) Multiplicando Ecuación 1 por T , $T \text{Var}(\bar{y}_T) = \sum_h \mathbf{1}\{|h| < T\} (1 - |h|/T) \gamma(h)$. Cada término converge a $\gamma(h)$ y está acotado en valor absoluto por $|\gamma(h)|$, que es sumable. Por el teorema de convergencia dominada (para series), el límite es $\sum_h \gamma(h)$. $\square$

El número $\sigma_{LR}^2 = \sum_h \gamma(h)$ es la **varianza de largo plazo** del proceso. Es lo que reemplaza a $\gamma(0)$ en la varianza de $\bar{y}_T$: $\text{Var}(\bar{y}_T) \approx \sigma_{LR}^2/T$. Con **autocorrelación positiva** ($\gamma(h) > 0$), $\sigma_{LR}^2 > \gamma(0)$: **hay menos información** de la que hay en una muestra i.i.d. del mismo tamaño, y los errores estándar que ignoran la dependencia son demasiado chicos. Es exactamente el mismo problema de la Clase 9 de Econometría 2 (efecto de diseño con clusters), aquí en el tiempo.

Ejemplo 3.1 (La varianza de largo plazo del MA(1)). Para $y_t = \varepsilon_t + \theta \varepsilon_{t-1}$: $\sigma_{LR}^2 = \gamma(0) + 2\gamma(1) = \sigma^2(1 + \theta^2) + 2\theta\sigma^2 = \sigma^2(1 + \theta)^2$. Con $\theta = 0,5$ y $\sigma^2 = 1$, $\sigma_{LR}^2 = 2,25$, frente a $\gamma(0) = 1,25$. Con $T = 100$, el error estándar correcto de $\bar{y}_T$ es $\sqrt{2,25/100} = 0,15$, y el que se obtendría ignorando la dependencia es $\sqrt{1,25/100} = 0,112$: **25 % demasiado chico**. Con $\theta = -1$ ocurre lo contrario: $\sigma_{LR}^2 = 0$ (el promedio converge más rápido que $1/\sqrt{T}$). Es una *sobrediferencia*, un fenómeno que reaparece en la Clase 7.

3.2. Ergodicidad

La LGN en media cuadrática exige que las autocovarianzas se desvanezcan. Pero lo que realmente queremos, al estimar cualquier cosa por promedios temporales (no solo la media: autocovarianzas, momentos para GMM, scores de MV), es una propiedad más general.

Definición 3.1 (Proceso ergódico). Un proceso estrictamente estacionario $\{y_t\}$ es **ergódico** si para toda función f medible con

$$\mathbb{E}|f(y_t, \dots, y_{t+k})| < \infty,$$

$$\frac{1}{T} \sum_{t=1}^T f(y_t, \dots, y_{t+k}) \xrightarrow{c.s.} \mathbb{E}[f(y_t, \dots, y_{t+k})].$$

(La definición formal usa conjuntos invariantes bajo el desplazamiento temporal; esta es la consecuencia que importa. Que el proceso sea *ergódico* equivale a que sus promedios temporales de **todas** las funciones integrables converjan a la constante $\mathbb{E}[f]$, no a una variable aleatoria.)

Teorema 3.2 (Teorema ergódico (Birkhoff) — se toma prestado). *Si $\{y_t\}$ es estrictamente estacionario y $\mathbb{E}|y_t| < \infty$, entonces $\bar{y}_T$ converge casi seguramente a una variable aleatoria $\bar{y}$ con $\mathbb{E}[\bar{y}] = \mu$. Si además $\{y_t\}$ es **ergódico**, $\bar{y} = \mu$ es constante.*

El teorema dice que, **sin ergodicidad**, el promedio temporal converge, pero **a una variable aleatoria**, no a μ : la trayectoria particular que nos tocó determina el límite. Con ergodicidad, el promedio temporal de una sola trayectoria *sí* aprende la media de ensamble. Es la condición que cumple todo lo que usaremos.

Ejemplo 3.2 (Un proceso estacionario no ergódico). En $y_t = Z$ para todo t (Ejemplo 2.1, 5), el proceso es estrictamente estacionario con $\mu = 0$, pero $\bar{y}_T = Z$ para todo T : converge a la variable aleatoria Z , **no** a 0. Por mucho que observes la serie, solo ves una “tirada” de Z y nunca aprendes μ . Aquí $\gamma(h) = \sigma^2 \not\rightarrow 0$, que es exactamente la condición del Teorema 3.1 que falla.

Dos hechos prácticos, que se toman prestados:

- **Condición suficiente:** un proceso estacionario que es **mezclante** (*mixing*: la dependencia entre y_t e y_{t+h} se desvanece cuando $h \rightarrow \infty$) es ergódico. Los procesos ARMA estacionarios con innovaciones i.i.d. lo son (Clase 2).
- **En el caso gaussiano** hay caracterizaciones exactas: un proceso estacionario es mezclante si y solo si $\gamma(h) \rightarrow 0$, y es ergódico si y solo si $\frac{1}{T} \sum_{h=1}^T \gamma(h)^2 \rightarrow 0$ (su distribución espectral no tiene átomos). En particular, para gaussianos

la condición $\gamma(h) \rightarrow 0$ del Teorema 3.1 ya **garantiza** ergodicidad.

 Por qué esto importa para todo el curso

La **teoría de M-estimadores de Econometría 2 (Clase 1)** se extiende a **procesos estacionarios y ergódicos** reemplazando “i.i.d.” por “estacionario y ergódico” en la ley de los grandes números (incluida la versión uniforme). La consistencia de MCO, MV y GMM sigue funcionando. Lo que **no** se extiende directamente es la **normalidad asintótica**: el TCL para sumas de variables dependientes necesita condiciones adicionales y cambia la varianza (de $\gamma(0)$ a σ_{LR}^2). Eso es la Clase 5.

4. Estimación de la media, de la autocovarianza y de la ACF

Dado $y_1, \dots, y_T$ de un proceso estacionario, los estimadores naturales son

$$\bar{y}_T = \frac{1}{T} \sum_{t=1}^T y_t, \quad \hat{\gamma}(h) = \frac{1}{T} \sum_{t=1}^{T-h} (y_t - \bar{y}_T)(y_{t+h} - \bar{y}_T), \quad \hat{\rho}(h) = \frac{\hat{\gamma}(h)}{\hat{\gamma}(0)}, \quad 0 \leq h < T.$$

Por la ergodicidad, bajo condiciones leves $\hat{\gamma}(h) \rightarrow_p \gamma(h)$ y $\hat{\rho}(h) \rightarrow_p \rho(h)$ para cada h fijo. Hay un detalle sutil: el divisor de $\hat{\gamma}(h)$ es T , **no** $T - h$ (que daría un estimador insesgado, aproximadamente). Se usa T porque garantiza que la matriz $\hat{\Gamma}_n = [\hat{\gamma}(i - j)]$ sea **semidefinida positiva**, como la verdadera.

Proposición 4.1 (La autocovarianza muestral es semidefinida positiva). *Para todo $n \leq T$, la matriz $\hat{\Gamma}_n = [\hat{\gamma}(i - j)]_{i,j=1}^n$ es semidefinida positiva.*

Demostración. Sea $\tilde{y}_t = y_t - \bar{y}_T$. Construimos la matriz M de $n \times (T + n - 1)$ cuya fila i es $(0, \dots, 0, \tilde{y}_1, \dots, \tilde{y}_T, 0, \dots, 0)$ con $i - 1$ ceros a la izquierda (cada fila es la serie desplazada). Entonces $(MM')_{ij} = \sum_t \tilde{y}_{t-i+1} \tilde{y}_{t-j+1}$, que es $\sum_t \tilde{y}_t \tilde{y}_{t+(i-j)}$ sumado sobre

los índices válidos, es decir $T\hat{\gamma}(i - j)$. Luego $\hat{\Gamma}_n = \frac{1}{T}MM'$, que es semidefinida positiva (de la forma AA'). $\square$

Con el divisor $T - h$ esa propiedad se pierde, y se pueden obtener “autocovarianzas” estimadas que no corresponden a ningún proceso (varianzas negativas en predicciones). Es el motivo del divisor T .

4.1. La ACF de un ruido blanco

Un primer uso práctico: testear si una serie (o los residuos de un modelo) es ruido blanco, mirando si sus autocorrelaciones muestrales son cero.

Proposición 4.2 (Autocorrelaciones muestrales de un ruido blanco). *Si $\{y_t\}$ es i.i.d. con $\mathbb{E}[y_t^2] < \infty$ y varianza positiva, entonces para cada $h \geq 1$ fijo, $\sqrt{T}\hat{\rho}(h) \xrightarrow{d} N(0, 1)$ y, para $h \neq k$, $\hat{\rho}(h)$ y $\hat{\rho}(k)$ son asintóticamente independientes.*

Demostración. (Esquema; el detalle usa un TCL para sucesiones dependientes, que veremos en la Clase 5.) Con $\mu = 0$ por simplicidad, $\sqrt{T}\hat{\gamma}(h) = T^{-1/2} \sum_t y_t y_{t+h} + o_p(1)$. Los términos $y_t y_{t+h}$ tienen media cero (independencia), varianza $\mathbb{E}[y_t^2] \mathbb{E}[y_{t+h}^2] = \sigma^4$, y son **no correlacionados** entre sí: $\text{Cov}(y_t y_{t+h}, y_s y_{s+h}) = 0$ si $t \neq s$ (algún y queda sin pareja). Son una diferencia de martingala, y el TCL de la Clase 5 da $\sqrt{T}\hat{\gamma}(h) \rightarrow_d N(0, \sigma^4)$. Como $\hat{\gamma}(0) \rightarrow_p \sigma^2$, por Slutsky $\sqrt{T}\hat{\rho}(h) \rightarrow_d N(0, 1)$. La independencia asintótica entre rezagos sigue de que los términos de h y de k son también no correlacionados. $\square$

De aquí sale la **banda estándar** de los correlogramas: bajo ruido blanco, el 95 % de los $\hat{\rho}(h)$ deben caer en $\pm 1,96/\sqrt{T}$. Con $T = 100$, la banda es $\pm 0,196$; con 20 rezagos, se espera que **uno** salga de ella por azar (Ejercicio 1.6). Una única autocorrelación “significativa” entre muchas no es evidencia de dependencia. Para testear **conjuntamente** muchos rezagos se usa el estadístico de Ljung–Box (Clase 4).

5. ★ Postgrado: la densidad espectral

! ★ Postgrado

La autocovarianza admite una representación en el dominio de las frecuencias. Es la forma natural de ver **por qué** la varianza de largo plazo σ_{LR}^2 es la que gobierna al promedio, y la base del estimador HAC de la Clase 5.

Si $\sum_h |\gamma(h)| < \infty$, definimos la **densidad espectral**

$$f(\lambda) = \frac{1}{2\pi} \sum_{h=-\infty}^{\infty} \gamma(h) e^{-ih\lambda}, \quad \lambda \in [-\pi, \pi].$$

Es una función continua (la serie converge uniformemente) y, por la simetría $\gamma(h) = \gamma(-h)$, **real**: $f(\lambda) = \frac{1}{2\pi} [\gamma(0) + 2 \sum_{h \geq 1} \gamma(h) \cos(h\lambda)]$. Por inversión de Fourier, $\gamma(h) = \int_{-\pi}^{\pi} e^{ih\lambda} f(\lambda) d\lambda$. La varianza de largo plazo es la densidad espectral **en cero**: $\sigma_{LR}^2 = 2\pi f(0)$.

Proposición 5.1 (La densidad espectral es no negativa). Si $\sum_h |\gamma(h)| < \infty$, entonces $f(\lambda) \geq 0$ para todo λ .

Demostración. Para λ fijo, sea $S_T(\lambda) = \sum_{t=1}^T y_t e^{-it\lambda}$ (la transformada de Fourier discreta de la serie, con $\mu = 0$ por simplicidad). Entonces

$$0 \leq \frac{1}{T} \mathbb{E} |S_T(\lambda)|^2 = \frac{1}{T} \sum_{t,s=1}^T \gamma(t-s) e^{-i(t-s)\lambda} = \sum_{|h| < T} \left(1 - \frac{|h|}{T}\right) \gamma(h) e^{-ih\lambda}.$$

Es el mismo cálculo de Ecuación 1, con el factor $e^{-ih\lambda}$. Por convergencia dominada (como en el Teorema 3.1), el lado derecho tiende a $2\pi f(\lambda)$ cuando $T \rightarrow \infty$, y el límite de números no negativos es no negativo. $\square$

Con $\lambda = 0$ esto es el Teorema 3.1: $\frac{1}{T} \mathbb{E} |\sum y_t|^2 = T \text{Var}(\bar{y}_T) \rightarrow 2\pi f(0)$. La densidad espectral generaliza esa cantidad a todas las frecuencias y dice **cuánta varianza aporta cada ciclo** (frecuencia λ corresponde a un período de $2\pi/\lambda$ observaciones). Para un

MA(1), $f(\lambda) = \frac{\sigma^2}{2\pi}(1 + \theta^2 + 2\theta \cos \lambda)$, que con $\theta > 0$ concentra la varianza en frecuencias bajas (series “suaves”) y con $\theta < 0$ en frecuencias altas (series “dentadas”).

El **teorema de Herglotz** (que se toma prestado) completa el cuadro: una función γ es la autocovarianza de algún proceso estacionario **si y solo si** es simétrica y semidefinida positiva, y entonces $\gamma(h) = \int e^{ih\lambda} dF(\lambda)$ para una medida F no negativa (la **distribución espectral**). Eso resuelve el aviso que dimos tras la Proposición 2.2: la semidefinición positiva no es una restricción cosmética sino el criterio exacto de qué funciones son autocovarianzas.

6. Resumen

- Una serie de tiempo es **una realización** de un proceso estocástico. Para aprender de ella hace falta **estacionariedad** (Definición 2.2) y **ergodicidad** (Definición 3.1).
- La función de autocovarianza $\gamma(h)$ es simétrica, acotada por $\gamma(0)$ y **semidefinida positiva** (Proposición 2.2). Ruido blanco, MA(1), caminata aleatoria y tendencia son los ejemplos de referencia.
- $\text{Var}(\bar{y}_T) = \frac{1}{T} \sum_{|h| < T} (1 - |h|/T) \gamma(h)$. Si $\gamma(h) \rightarrow 0$, $\bar{y}_T \rightarrow \mu$ (Teorema 3.1), y con autocovarianzas sumables, $T \text{Var}(\bar{y}_T) \rightarrow \sigma_{LR}^2 = \sum_h \gamma(h)$: la **varianza de largo plazo** reemplaza a $\gamma(0)$.
- El **teorema ergódico** (Teorema 3.2) es la LGN general: para procesos ergódicos, los promedios temporales convergen a las esperanzas de ensamble. Sin ergodicidad convergen a una variable aleatoria (Ejemplo 3.2).
- $\hat{\gamma}(h)$ (divisor T) es semidefinida positiva (Proposición 4.1). Bajo ruido blanco, $\sqrt{T} \hat{\rho}(h) \rightarrow N(0, 1)$ (Proposición 4.2).

7. Ejercicios

Ejercicio 1.1. Determina si cada proceso es débilmente estacionario y calcula $\gamma(h)$ cuando corresponda. (a) $y_t = \varepsilon_t + \varepsilon_{t-1}$, $\varepsilon_t \sim WN(0, 1)$. (b) $y_t = (-1)^t Z$ con Z de media cero y varianza 1. (c) $y_t = t \varepsilon_t$.

 Solución 1.1

(a) MA(1) con $\theta = 1$, $\sigma^2 = 1$: estacionario, $\gamma(0) = 2$, $\gamma(\pm 1) = 1$, $\gamma(h) = 0$ si $|h| \geq 2$; $\rho(1) = 0,5$ (el máximo posible). (b) $\mathbb{E}[y_t] = 0$ y $\text{Cov}(y_t, y_{t+h}) = (-1)^{2t+h} \text{Var}(Z) = (-1)^h$: depende solo de h , estacionario, con $\gamma(h) = (-1)^h$ (oscila entre +1 y -1). Curiosamente $\bar{y}_T = Z \cdot \frac{1}{T} \sum_t (-1)^t \rightarrow 0 = \mu$, pero el proceso **no** es ergódico: el promedio temporal de y_t^2 es Z^2 para todo T , no $\mathbb{E}[y_t^2] = 1$. (c) $\text{Var}(y_t) = t^2$ depende de t : no estacionario (heterocedasticidad creciente).

Ejercicio 1.2. Calcula $\rho(1)$ de un MA(1) con $\theta = 0,5$ y con $\theta = 2$. ¿Qué observas? ¿Por qué no se puede distinguir un caso del otro con la ACF?

 Solución 1.2

$\theta = 0,5$: $\rho(1) = 0,5/1,25 = 0,4$. $\theta = 2$: $\rho(1) = 2/5 = 0,4$. **Es la misma.** En general, $\theta/(1+\theta^2)$ es invariante a $\theta \rightarrow 1/\theta$. Como la ACF (y la autocovarianza, con la varianza σ^2 ajustada: $\sigma^2(1+\theta^2)$ debe coincidir, o sea $\sigma_{(2)}^2 = \sigma_{(0,5)}^2 \cdot 0,25$) es lo único que identifican los dos primeros momentos, ambos modelos generan la **misma ley de segundo orden**. Se resuelve eligiendo la parametrización *invertible* $|\theta| < 1$ (Clase 2).

Ejercicio 1.3. Para un MA(1) con $\theta = 0,5$ y $\sigma^2 = 1$, calcula $T \text{Var}(\bar{y}_T)$ exacto para $T = 10$ y compáralo con el límite σ_{LR}^2 .

 Solución 1.3

$T \text{Var}(\bar{y}_T) = \gamma(0) + 2(1 - \frac{1}{T})\gamma(1) = 1,25 + 2(0,9)(0,5) = 1,25 + 0,9 = 2,15$. El límite es $\sigma_{LR}^2 = (1 + \theta)^2 = 2,25$. Para $T = 10$ ya está a 4 % del límite, y converge a tasa $1/T$ (el término $2\gamma(1)/T$ es la corrección). Con i.i.d. se habría calculado 1,25: un error de 42 %.

Ejercicio 1.4. Un proceso $y_t = \mu + Z$ (nivel aleatorio con

$\text{Var}(Z) = 4$) se observa en $T = 1000$ períodos. ¿Cuál es la distribución de $\bar{y}_T$ y cuál el error de estimar μ ? Compara con un ruido blanco de varianza 4.

💡 Solución 1.4

$\bar{y}_T = \mu + Z$ para todo T (promedio de T copias de lo mismo): $\text{Var}(\bar{y}_T) = 4$, **independiente de T** . Con 1000 observaciones el error estándar sigue siendo 2, no mejora. Con un ruido blanco de varianza 4, $\text{Var}(\bar{y}_T) = 4/1000$ (error estándar 0,063). La diferencia es la ergodicidad: la serie con nivel aleatorio contiene una sola realización de Z , y no hay “información nueva” en cada observación. $\gamma(h) = 4$ constante: $T \text{Var}(\bar{y}_T) = 4T \rightarrow \infty$.

Ejercicio 1.5. Un proceso estacionario cumple $y_t = \phi y_{t-1} + \varepsilon_t$ con $|\phi| < 1$, $\varepsilon_t \sim WN(0, \sigma^2)$ no correlacionado con y_{t-s} para $s \geq 1$. Deduce $\gamma(h)$ y la varianza de largo plazo. Para $\phi = 0,8$, ¿por cuánto se subestima la varianza de $\bar{y}_T$ si se usa $\gamma(0)/T$?

💡 Solución 1.5

$\gamma(0) = \phi^2 \gamma(0) + \sigma^2 \Rightarrow \gamma(0) = \sigma^2 / (1 - \phi^2)$. Para $h \geq 1$, multiplicando por y_{t-h} y tomando esperanza, $\gamma(h) = \phi \gamma(h-1)$ (el término $\mathbb{E}[\varepsilon_t y_{t-h}] = 0$), luego $\gamma(h) = \phi^{|h|} \gamma(0)$. La suma: $\sigma_{LR}^2 = \gamma(0) \sum_h \phi^{|h|} = \gamma(0) \frac{1 + \phi}{1 - \phi} = \frac{\sigma^2}{(1 - \phi)^2}$. Con $\phi = 0,8$: $\gamma(0) = \sigma^2 / 0,36 = 2,78 \sigma^2$ y $\sigma_{LR}^2 = 25 \sigma^2$. El cociente $\sigma_{LR}^2 / \gamma(0) = (1 + \phi) / (1 - \phi) = 9$: **ignorar la dependencia subestima la varianza de $\bar{y}_T$ en un factor 9** (el error estándar, en 3). Una serie con $\phi = 0,8$ de $T = 100$ observaciones equivale, para estimar la media, a solo $100/9 \approx 11$ observaciones independientes.

Ejercicio 1.6. Con $T = 100$, ¿cuál es la banda del 95 % para la ACF muestral de un ruido blanco? Si se miran 20 rezagos, ¿cuántos se esperan fuera de la banda y cuál es la probabilidad de que **al menos uno** salga?

 Solución 1.6

Banda: $\pm 1,96/\sqrt{100} = \pm 0,196$. Con 20 rezagos asintóticamente independientes, se esperan $20 \times 0,05 = 1$ fuera de la banda. $P(\text{al menos uno}) = 1 - 0,95^{20} = 1 - 0,358 = 0,64$.

Hay 64 % de probabilidad de ver al menos una autocorrelación “significativa” en un ruido blanco puro. Por eso no se interpreta un solo rezago aislado, y se usan pruebas conjuntas (Ljung–Box, Clase 4).

Ejercicio 1.7 ★. (a) Muestra que $\gamma(0) = 1, \gamma(\pm 1) = 0,9, \gamma(h) = 0$ para $|h| \geq 2$ **no** es una función de autocovarianza. (b) ¿Para qué valores de $\rho(1)$ y $\gamma(h) = 0$ si $|h| \geq 2$ sí lo es?

 Solución 1.7 ★

(a) Con $\rho(1) = 0,9 > \frac{1}{2}$ y $\rho(h) = 0$ para $|h| \geq 2$: la matriz de Toeplitz $3 \times 3 \begin{pmatrix} 1 & 0,9 & 0 \\ 0,9 & 1 & 0,9 \\ 0 & 0,9 & 1 \end{pmatrix}$ tiene determinante $1 - 2(0,81) = -0,62 < 0$, así que no es semidefinida positiva: con $a = (1, -\sqrt{2}, 1)'$ se obtiene $a' \Gamma a = 4 - 4\sqrt{2}(0,9) \approx -1,09 < 0$. Ninguna varianza puede ser negativa. (b) La densidad espectral $f(\lambda) = \frac{1}{2\pi} [1 + 2\rho(1) \cos \lambda]$ debe ser no negativa (Proposición 5.1): $1 + 2\rho(1) \cos \lambda \geq 0$ para todo λ , es decir $|\rho(1)| \leq \frac{1}{2}$. Es exactamente la cota del MA(1) (Ejemplo 2.1): una autocorrelación de primer orden mayor que $\frac{1}{2}$ con todas las demás nulas es imposible.