

Clase 2 · Procesos lineales: MA, AR y ARMA

Operador de rezago, causalidad, invertibilidad y funciones de autocorrelación

Contenido

1 Modelos para la dependencia	2
2 El operador de rezago y los procesos lineales	2
2.1 ¿Es una restricción pensar en procesos lineales?	
El teorema de Wold	4
3 Procesos autorregresivos	4
3.1 El AR(1)	4
3.2 El AR(p) y la condición de estacionariedad	6
4 Media móvil e invertibilidad	6
5 ARMA(p, q)	7
6 Autocorrelación y autocorrelación parcial	9
6.1 Las ecuaciones de Yule-Walker	9
7 ★ Postgrado: la función generatriz y la factorización espectral	10
8 Resumen	11
9 Ejercicios	12

1. Modelos para la dependencia

La Clase 1 dejó claro qué hace falta para aprender de una sola serie: estacionariedad y ergodicidad. Ahora necesitamos **modelos**: familias de procesos estacionarios con pocos parámetros, que capturen la dependencia observada y permitan estimar y pronosticar. La familia más usada son los **procesos lineales**, que escriben y_t como una combinación lineal de **innovaciones** ε_t (ruido blanco): “lo nuevo que llegó en t ”.

Hay tres formas de generar dependencia a partir de ruido blanco, y todas combinadas dan los modelos ARMA:

- **Media móvil (MA)**: y_t es un promedio de las últimas innovaciones. Memoria **finita**: después de q períodos, la dependencia se corta.
- **Autorregresivo (AR)**: y_t depende de sus propios valores pasados. Memoria **infinita** (que decae).
- **ARMA**: ambas a la vez, con pocos parámetros.

Un tema recorre toda la clase: las condiciones de **causalidad** (¿se puede escribir y_t en función del pasado de ε ?) e **invertibilidad** (¿se puede recuperar ε_t del pasado de y ?). Sin ellas, el mismo proceso se escribe de varias maneras y los parámetros no se identifican (Clase 1: θ y $1/\theta$ daban la misma ACF).

2. El operador de rezago y los procesos lineales

El **operador de rezago** L desplaza una serie un período: $Ly_t = y_{t-1}$, y $L^j y_t = y_{t-j}$. Con él, un polinomio $\phi(L) = 1 - \phi_1 L - \dots - \phi_p L^p$ es un operador: $\phi(L)y_t = y_t - \phi_1 y_{t-1} - \dots - \phi_p y_{t-p}$. Los polinomios en L se multiplican e invierten igual que los polinomios en un número z (mientras las series converjan).

Definición 2.1 (Proceso lineal). Sea $\varepsilon_t \sim WN(0, \sigma^2)$ y $\{\psi_j\}_{j \geq 0}$ una sucesión con $\sum_j |\psi_j| < \infty$ (absolutamente sumable). El **pro-**

ceso lineal es

$$y_t = \mu + \sum_{j=0}^{\infty} \psi_j \varepsilon_{t-j} = \mu + \psi(L) \varepsilon_t, \quad \psi(L) = \sum_{j=0}^{\infty} \psi_j L^j.$$

La suma infinita es un límite, y hay que decir en qué sentido existe.

Proposición 2.1 (Un proceso lineal está bien definido y es estacionario). *La serie $\sum_j \psi_j \varepsilon_{t-j}$ converge en media cuadrática y casi seguramente. El proceso resultante es estacionario con media μ y*

$$\gamma(h) = \sigma^2 \sum_{j=0}^{\infty} \psi_j \psi_{j+|h|}, \quad \sum_h |\gamma(h)| < \infty, \quad \sigma_{LR}^2 = \sigma^2 \psi(1)^2.$$

Demostración. Convergencia. Sea $S_{m,n} = \sum_{m < j \leq n} \psi_j \varepsilon_{t-j}$. Como los ε son no correlacionados, $\mathbb{E}[S_{m,n}^2] = \sigma^2 \sum_{m < j \leq n} \psi_j^2 \leq \sigma^2 (\sum_{m < j \leq n} |\psi_j|)^2 \rightarrow 0$ cuando $m, n \rightarrow \infty$ (cola de una serie convergente). Las sumas parciales forman una sucesión de Cauchy en L^2 , que converge porque L^2 es completo. (Casi segura: $\mathbb{E} \sum_j |\psi_j| |\varepsilon_{t-j}| \leq \sigma \sum_j |\psi_j| < \infty$, así que la serie converge absolutamente con probabilidad uno.)

Momentos. Por continuidad del producto interno en L^2 , $\mathbb{E}[y_t] = \mu$ y $\text{Cov}(y_t, y_{t+h}) = \sum_{j,k} \psi_j \psi_k \mathbb{E}[\varepsilon_{t-j} \varepsilon_{t+h-k}] = \sigma^2 \sum_j \psi_j \psi_{j+h}$ (solo sobreviven los términos con $k = j + h$). Esto no depende de t . La sumabilidad: $\sum_h |\gamma(h)| \leq \sigma^2 \sum_h \sum_j |\psi_j| |\psi_{j+|h|}| \leq 2\sigma^2 (\sum_j |\psi_j|)^2 < \infty$. Finalmente, por el teorema de la LGN en media cuadrática de la Clase 1, $\sigma_{LR}^2 = \sum_h \gamma(h) = \sigma^2 (\sum_j \psi_j)^2 = \sigma^2 \psi(1)^2$ (cada par (j, k) aparece una vez en el producto $(\sum \psi_j)(\sum \psi_k)$). $\square$

El resultado final es muy útil: **la varianza de largo plazo de un proceso lineal es $\sigma^2 \psi(1)^2$** , el cuadrado de la suma de los coeficientes. Reproduce lo de la Clase 1: para el MA(1), $\psi(1) = 1 + \theta$ y $\sigma_{LR}^2 = \sigma^2 (1 + \theta)^2$; para el AR(1), $\psi(1) = 1/(1 - \phi)$ y $\sigma_{LR}^2 = \sigma^2 / (1 - \phi)^2$.

2.1. ¿Es una restricción pensar en procesos lineales? El teorema de Wold

Podría parecer que los procesos lineales son una familia particular. El **teorema de Wold** (1938) dice que, en cuanto a los dos primeros momentos, **no lo son**.

Teorema 2.1 (Descomposición de Wold — se toma prestado). *Todo proceso débilmente estacionario $\{y_t\}$ con media cero y **puramente no determinístico** (sin componente perfectamente predecible a partir de su pasado) puede escribirse como*

$$y_t = \sum_{j=0}^{\infty} \psi_j \varepsilon_{t-j}, \quad \psi_0 = 1, \quad \sum_j \psi_j^2 < \infty,$$

donde ε_t es el **error de pronóstico lineal** de y_t dado su pasado, un ruido blanco (no necesariamente i.i.d.), y ψ_j son coeficientes únicos.

En la Clase 3 veremos de dónde sale ε_t (es la proyección residual). La conclusión práctica: **los modelos ARMA no pierden generalidad en segundo orden**: cualquier proceso estacionario tiene una representación $MA(\infty)$, y ARMA aproxima ese $\psi(L)$ con un cociente de polinomios de pocos parámetros. (Ojo: Wold no dice que ε_t sea i.i.d. ni que el proceso sea *lineal en distribución*; un GARCH, Clase 12, tiene representación de Wold y es muy no lineal.)

3. Procesos autorregresivos

3.1. El AR(1)

$$y_t = \phi y_{t-1} + \varepsilon_t, \quad \varepsilon_t \sim WN(0, \sigma^2). \quad (1)$$

Es una ecuación en diferencias estocástica: no define un proceso hasta que decimos **cuál solución** queremos. La respuesta depende de $|\phi|$.

Teorema 3.1 (Soluciones estacionarias del AR(1)).

1. Si $|\phi| < 1$, Ecuación 1 tiene una **única** solución estacionaria, $y_t = \sum_{j=0}^{\infty} \phi^j \varepsilon_{t-j}$, que es **causal** (depende solo de $\varepsilon_t, \varepsilon_{t-1}, \dots$).
2. Si $|\phi| > 1$, hay una única solución estacionaria, pero **no causal**: $y_t = -\sum_{j=1}^{\infty} \phi^{-j} \varepsilon_{t+j}$ (depende del futuro).
3. Si $|\phi| = 1$, **no existe** solución estacionaria.

Borrador

Itero la ecuación hacia atrás: $y_t = \phi y_{t-1} + \varepsilon_t = \phi^2 y_{t-2} + \phi \varepsilon_{t-1} + \varepsilon_t = \dots = \phi^n y_{t-n} + \sum_{j<n} \phi^j \varepsilon_{t-j}$. Si $|\phi| < 1$, el término $\phi^n y_{t-n}$ se desvanece (el pasado lejano se olvida) y queda la suma. Si $|\phi| > 1$, ese término explota, y la salida es iterar hacia **adelante**: $y_t = \phi^{-1} y_{t+1} - \phi^{-1} \varepsilon_{t+1}$. Con $|\phi| = 1$ no hay ni olvido ni explosión: la varianza crece linealmente (caminata aleatoria).

Demostración.

- (1) *Existencia*: $\sum_j |\phi^j| < \infty$, así que por la Proposición 2.1 $y_t = \sum_j \phi^j \varepsilon_{t-j}$ está bien definido y es estacionario. Verificación: $y_t - \phi y_{t-1} = \sum_{j \geq 0} \phi^j \varepsilon_{t-j} - \sum_{j \geq 0} \phi^{j+1} \varepsilon_{t-1-j} = \varepsilon_t$. *Unicidad*: si $\{y_t\}$ es cualquier solución estacionaria, iterando n veces, $y_t - \sum_{j<n} \phi^j \varepsilon_{t-j} = \phi^n y_{t-n}$, cuyo segundo momento es $\phi^{2n}(\gamma(0) + \mu^2) \rightarrow 0$. Luego $y_t = \sum_j \phi^j \varepsilon_{t-j}$ en media cuadrática.
- (2) Despejando, $y_t = \phi^{-1} y_{t+1} - \phi^{-1} \varepsilon_{t+1}$, y como $|\phi^{-1}| < 1$ el mismo argumento hacia adelante da $y_t = -\sum_{j \geq 1} \phi^{-j} \varepsilon_{t+j}$ como única solución estacionaria. Verificación: $y_t - \phi y_{t-1} = -\sum_{j \geq 1} \phi^{-j} \varepsilon_{t+j} + \sum_{j \geq 1} \phi^{1-j} \varepsilon_{t-1+j} = -\sum_{j \geq 1} \phi^{-j} \varepsilon_{t+j} + \sum_{k \geq 0} \phi^{-k} \varepsilon_{t+k} = \varepsilon_t$.
- (3) Con $\phi = 1$, iterando, $y_t - y_{t-n} = \sum_{j<n} \varepsilon_{t-j}$ con varianza $n\sigma^2$. Pero si y_t fuera estacionario, $\text{Var}(y_t - y_{t-n}) \leq 4\gamma(0)$ para todo n : contradicción. (El caso $\phi = -1$ es análogo con $y_t - (-1)^n y_{t-n}$.)

□

La solución no causal del caso (2) es matemáticamente legítima pero **inútil como modelo**: pide que el proceso de hoy dependa de shocks que aún no ocurren. Por convención se trabaja con la solución causal, y se pide $|\phi| < 1$. Además, el caso $|\phi| > 1$ **no agrega nada**: tiene la misma autocovarianza que un AR(1) causal con parámetro $1/\phi$ y otra varianza de innovación (como el MA(1) con θ y $1/\theta$). Bajo $|\phi| < 1$, la autocovarianza es $\gamma(h) = \sigma^2 \phi^{|h|} / (1 - \phi^2)$ (Ejercicio 1.5 de la Clase 1). Con $\phi > 0$ la serie es “suave” y persistente (la ACF decae geométricamente); con $\phi < 0$ oscila.

3.2. El AR(p) y la condición de estacionariedad

$$\phi(L)y_t = \varepsilon_t, \quad \phi(z) = 1 - \phi_1 z - \cdots - \phi_p z^p.$$

La generalización natural del $|\phi| < 1$ es que **todas las raíces del polinomio $\phi(z)$ estén fuera del círculo unitario**: $\phi(z) \neq 0$ para $|z| \leq 1$. (Para $p = 1$, la única raíz es $1/\phi$, y $|1/\phi| > 1 \Leftrightarrow |\phi| < 1$.) Es el contenido del teorema general que sigue. Condiciones para $p = 2$ en el Ejercicio 2.5.

4. Media móvil e invertibilidad

El MA(q) es $y_t = \theta(L)\varepsilon_t$ con $\theta(z) = 1 + \theta_1 z + \cdots + \theta_q z^q$. Siempre es estacionario (suma finita). El problema es otro: **la identificación**.

Proposición 4.1 (Invertibilidad del MA(1)). Sea $y_t = \varepsilon_t + \theta \varepsilon_{t-1}$.

1. Si $|\theta| < 1$, $\varepsilon_t = \sum_{j=0}^{\infty} (-\theta)^j y_{t-j}$: el proceso es **invertible** (las innovaciones se recuperan del pasado de y).
2. Si $|\theta| > 1$, ε_t no es una función del pasado de y . Pero existe una **representación invertible equivalente**: $y_t = \varepsilon_t^* + \theta^* \varepsilon_{t-1}^*$ con $\theta^* = 1/\theta$ y $\sigma^{*2} = \theta^2 \sigma^2$, que tiene **exactamente la misma autocovarianza**.

Demostración.

- (1) Despejando, $\varepsilon_t = y_t - \theta \varepsilon_{t-1}$ e iterando, $\varepsilon_t = \sum_{j < n} (-\theta)^j y_{t-j} + (-\theta)^n \varepsilon_{t-n}$. El último término tiene segundo momento $\theta^{2n} \sigma^2 \rightarrow 0$ si $|\theta| < 1$, y $\varepsilon_t = \sum_j (-\theta)^j y_{t-j}$ en media cuadrática. (2) Calculamos las autocovarianzas del proceso con (θ^*, σ^{*2}) : $\gamma^*(0) = \sigma^{*2}(1 + \theta^{*2}) = \theta^2 \sigma^2(1 + \theta^{-2}) = \sigma^2(\theta^2 + 1) = \gamma(0)$ y $\gamma^*(1) = \theta^* \sigma^{*2} = \theta^{-1} \theta^2 \sigma^2 = \theta \sigma^2 = \gamma(1)$. Mismos momentos de segundo orden.

□

La conclusión de (2) es importante: sin la condición de invertibilidad, **los parámetros no están identificados** a partir de la ley de segundo orden. Se **elige** la raíz invertible, $|\theta| \leq 1$, como convención (es lo que hicimos con $\hat{\theta} = 0,5$ y no 2 en la Clase 13 de Econometría 2). Para el invertible, ε_t coincide con el **error de pronóstico lineal** de la representación de Wold; con la no invertible, en cambio, ε_t no es una innovación “genuina”. Además, invertibilidad permite escribir el $MA(q)$ como un $AR(\infty)$, lo que justifica el pronóstico con datos pasados (Clase 3).

5. ARMA(p, q)

Definición 5.1 (Proceso ARMA). $\{y_t\}$ es un proceso **ARMA(p, q)** si es estacionario y satisface

$$\phi(L)y_t = \theta(L)\varepsilon_t, \quad \varepsilon_t \sim WN(0, \sigma^2),$$

con $\phi(z) = 1 - \phi_1 z - \dots - \phi_p z^p$ y $\theta(z) = 1 + \theta_1 z + \dots + \theta_q z^q$ sin raíces comunes.

La condición “sin raíces comunes” evita una redundancia trivial: $(1 - \phi L)y_t = (1 - \phi L)\varepsilon_t$ es ruido blanco, no un $ARMA(1,1)$ genuino (Ejercicio 2.6).

Teorema 5.1 (Causalidad e invertibilidad del ARMA). Sea $\phi(L)y_t = \theta(L)\varepsilon_t$ con ϕ y θ sin raíces comunes.

1. Si $\phi(z) \neq 0$ para todo $|z| \leq 1$, existe una **única** solución estacionaria, y es causal: $y_t = \psi(L)\varepsilon_t$, con $\psi(z) = \theta(z)/\phi(z) = \sum_{j \geq 0} \psi_j z^j$ y $|\psi_j| \leq K r^j$ para algún $r < 1$ (decaimiento **geométrico**).

2. Si además $\theta(z) \neq 0$ para todo $|z| \leq 1$, el proceso es **invertible**: $\varepsilon_t = \pi(L)y_t$ con $\pi(z) = \phi(z)/\theta(z) = \sum_{j \geq 0} \pi_j z^j$ también con decaimiento geométrico.

Demostración.

- (1) Como ϕ es un polinomio sin raíces en el disco cerrado $|z| \leq 1$, la función $1/\phi(z)$ es analítica en un disco **más grande** $|z| < R$, con $R > 1$ (la raíz más cercana al origen tiene módulo mayor que 1). Su serie de Taylor $\sum_j \xi_j z^j$ converge en ese disco, de modo que $|\xi_j| \leq Kr^j$ para algún $r \in (1/R, 1)$ (criterio de Cauchy-Hadamard). Entonces $\xi(L) = 1/\phi(L)$ tiene coeficientes absolutamente sumables. Multiplicando por $\theta(z)$ (polinomio de grado q), $\psi(z) = \theta(z)\xi(z)$ conserva el decaimiento geométrico. Por la Proposición 2.1, $y_t = \psi(L)\varepsilon_t$ es estacionario, y satisface la ecuación porque $\phi(L)\psi(L) = \theta(L)$ como series de potencias. *Unicidad*: si $\{y_t\}$ es otra solución estacionaria, aplicamos el operador $\xi(L)$ (de coeficientes sumables, que preserva la estacionariedad) a $\phi(L)y_t = \theta(L)\varepsilon_t$ y obtenemos $y_t = \xi(L)\theta(L)\varepsilon_t = \psi(L)\varepsilon_t$.
- (2) Es el mismo argumento intercambiando los papeles de ϕ y θ : $1/\theta(z)$ es analítica en un disco mayor que el unitario, y $\varepsilon_t = \theta(L)^{-1}\phi(L)y_t$.

□

Los coeficientes ψ_j (la **respuesta a un impulso**: efecto en y_{t+j} de una innovación unitaria en t) se calculan **recursivamente** igualando coeficientes en $\phi(z)\psi(z) = \theta(z)$: $\psi_0 = 1$ y $\psi_j = \theta_j + \sum_{k=1}^{\min(j,p)} \phi_k \psi_{j-k}$ (con $\theta_j = 0$ para $j > q$).

Ejemplo 5.1 (El ARMA(1,1)). Para $(1 - \phi L)y_t = (1 + \theta L)\varepsilon_t$, $\psi(z) = \frac{1 + \theta z}{1 - \phi z} = \sum_j \phi^j z^j + \theta \sum_j \phi^j z^{j+1}$, de donde $\psi_0 = 1$ y $\psi_j = \phi^{j-1}(\phi + \theta)$ para $j \geq 1$. El efecto de un shock decae geométricamente a tasa ϕ , pero **parte** de un nivel distinto ($\phi + \theta$ en lugar de ϕ en el primer rezago): el MA permite flexibilizar la respuesta en los primeros períodos. La varianza de largo plazo es $\sigma^2 \psi(1)^2 = \sigma^2 \left(\frac{1 + \theta}{1 - \phi} \right)^2$.

6. Autocorrelación y autocorrelación parcial

El análisis Box–Jenkins elige el modelo mirando dos funciones. La primera es la ACF, $\rho(h)$. La segunda es la **autocorrelación parcial**.

Definición 6.1 (Autocorrelación parcial (PACF)). La PACF en el rezago h , $\alpha(h)$, es la correlación entre y_t e y_{t-h} **después de quitar el efecto lineal de los valores intermedios** $y_{t-1}, \dots, y_{t-h+1}$. Equivalentemente, es el último coeficiente ϕ_{hh} de la mejor predicción lineal de y_t sobre $y_{t-1}, \dots, y_{t-h}$ (la proyección de la Clase 3).

Las dos funciones tienen firmas características que dan el nombre al método de identificación.

Modelo	ACF $\rho(h)$	PACF $\alpha(h)$
MA(q)	se corta a cero para $h > q$	decae (geométrica o mezcla de oscilaciones)
AR(p)	decae geométricamente	se corta a cero para $h > p$
ARMA(p, q)	decae geométricamente desde $h > q - p$	decae desde $h > p - q$

Para el **MA(q)**, la Proposición 2.1 da $\gamma(h) = \sigma^2 \sum_j \theta_j \theta_{j+h} = 0$ si $h > q$. Para el **AR(p)**, la PACF se corta porque, si el proceso es **AR(p)**, la mejor predicción lineal de y_t sobre los últimos $h \geq p$ valores usa exactamente los coeficientes $(\phi_1, \dots, \phi_p, 0, \dots, 0)$, y el último coeficiente es cero para $h > p$.

6.1. Las ecuaciones de Yule–Walker

Para un **AR(p)** causal podemos obtener la ACF sin calcular ψ_j . Multiplicando $y_t = \sum_{k=1}^p \phi_k y_{t-k} + \varepsilon_t$ por y_{t-h} y tomando esperanza (con $\mu = 0$), usando $\mathbb{E}[\varepsilon_t y_{t-h}] = 0$ si $h \geq 1$ (causalidad) y

$= \sigma^2$ si $h = 0$:

$$\gamma(h) = \sum_{k=1}^p \phi_k \gamma(h-k) \quad (h \geq 1), \quad \gamma(0) = \sum_{k=1}^p \phi_k \gamma(k) + \sigma^2. \quad (2)$$

Son las **ecuaciones de Yule-Walker**. Con $\gamma(0), \dots, \gamma(p)$ se pueden resolver para $(\phi_1, \dots, \phi_p, \sigma^2)$ y, al revés, dados los parámetros, determinan las autocovarianzas. Son la base del estimador de Yule-Walker (Clase 4).

Ejemplo 6.1 (ACF de un AR(2)). Dividiendo Ecuación 2 por $\gamma(0)$ para $h = 1, 2$: $\rho(1) = \phi_1 + \phi_2 \rho(1)$, es decir $\rho(1) = \frac{\phi_1}{1 - \phi_2}$, y $\rho(2) = \phi_1 \rho(1) + \phi_2$; para $h \geq 3$, $\rho(h) = \phi_1 \rho(h-1) + \phi_2 \rho(h-2)$. Con $\phi_1 = 0,5$ y $\phi_2 = 0,3$: $\rho(1) = 0,5/0,7 = 0,714$, $\rho(2) = 0,5(0,714) + 0,3 = 0,657$, $\rho(3) = 0,5(0,657) + 0,3(0,714) = 0,543$. La ACF decae lentamente, y la PACF vale $\alpha(1) = \rho(1) = 0,714$, $\alpha(2) = \phi_2 = 0,3$ y se anula para $h \geq 3$.

7. ★ Postgrado: la función generatriz y la factorización espectral

! ★ Postgrado

Todo proceso lineal tiene una densidad espectral que se calcula **directamente** del polinomio $\psi(z)$, y esto explica por qué la elección de la raíz invertible no pierde generalidad.

Para $y_t = \psi(L)\varepsilon_t$ con $\sum |\psi_j| < \infty$ definimos la **función generatriz de autocovarianzas** $g(z) = \sum_h \gamma(h)z^h$. De $\gamma(h) = \sigma^2 \sum_j \psi_j \psi_{j+|h|}$ (Proposición 2.1),

$$g(z) = \sigma^2 \sum_{j,k} \psi_j \psi_k z^{k-j} = \sigma^2 \psi(z) \psi(z^{-1}), \quad f(\lambda) = \frac{1}{2\pi} g(e^{-i\lambda}) = \frac{\sigma^2}{2\pi} |\psi(e^{-i\lambda})|^2.$$

Con $z = 1$ se recupera $\sigma_{LR}^2 = \sigma^2 \psi(1)^2 = 2\pi f(0)$.

Proposición 7.1 (Reflejar una raíz no cambia la densidad espectral). Sea $|a| < 1$ (de modo que el factor $(1 - aL)$ tiene su raíz $1/a$ fuera del círculo unitario). Entonces, para todo λ ,

$$|1 - a^{-1}e^{-i\lambda}|^2 \cdot |a|^2 = |1 - ae^{-i\lambda}|^2.$$

En consecuencia, reemplazar un factor $(1 - a^{-1}L)$ (raíz **dentro** del círculo) por $(1 - aL)$ y multiplicar la varianza de la innovación por $|a|^{-2}$ deja intacta la densidad espectral, y por tanto la autocovarianza.

Demostración. Sea $z = e^{-i\lambda}$, con $|z| = 1$ y $\bar{z} = 1/z$. Entonces $|a| |1 - a^{-1}z| = |a - z| = |z| |a\bar{z} - 1| = |1 - a\bar{z}| = |1 - ae^{i\lambda}|$. Para a real, el módulo de un complejo y el de su conjugado coinciden, y el conjugado de $1 - ae^{i\lambda}$ es $1 - ae^{-i\lambda}$; luego $|1 - ae^{i\lambda}| = |1 - ae^{-i\lambda}|$ y elevando al cuadrado queda la igualdad enunciada. (Para a complejo, las raíces de un polinomio con coeficientes reales vienen en pares conjugados $a, \bar{a}$, y el producto de los dos factores correspondientes cumple la misma identidad.) $\square$

La proposición es la versión general de $\theta \leftrightarrow 1/\theta$: **todo ARMA con raíces de $\theta(z)$ dentro del círculo unitario tiene un ARMA invertible con el mismo espectro** (sustituir cada raíz z_k con $|z_k| < 1$ por $1/\bar{z}_k$ y reescalar σ^2). Como la ley de segundo orden es lo único que los datos pueden identificar (mientras no se suponga no normalidad), **no se pierde nada al imponer invertibilidad**. Lo que sí se pierde, si el verdadero proceso es no invertible y no gaussiano, es la capacidad de recuperar las innovaciones *estructurales* (un problema serio en el análisis de VAR estructurales, Clase 10).

8. Resumen

- Un **proceso lineal** $y_t = \psi(L)\varepsilon_t$ con $\sum |\psi_j| < \infty$ está bien definido, es estacionario, con $\gamma(h) = \sigma^2 \sum_j \psi_j \psi_{j+h}$ y $\sigma_{LR}^2 = \sigma^2 \psi(1)^2$ (Proposición 2.1).
- **Wold** (Teorema 2.1): todo proceso estacionario no determinístico es lineal en segundo orden: los ARMA no pierden generalidad.

- **AR(1)**: causal y estacionario si y solo si $|\phi| < 1$ (Teorema 3.1). **MA(1)**: invertible si $|\theta| < 1$; θ y $1/\theta$ dan la misma ACF (Proposición 4.1).
- **ARMA(p,q)**: raíces de ϕ fuera del círculo unitario $\Rightarrow$ estacionario causal con $\psi = \theta/\phi$ (Teorema 5.1); raíces de θ fuera $\Rightarrow$ invertible.
- **Identificación Box-Jenkins**: MA(q) tiene ACF que se corta; AR(p) tiene PACF que se corta. Las **ecuaciones de Yule-Walker** (Ecuación 2) ligan parámetros y autocovarianzas.

9. Ejercicios

Ejercicio 2.1. Determina si cada ecuación tiene solución estacionaria causal: (a) $y_t = 0,9y_{t-1} + \varepsilon_t$; (b) $y_t = -1,2y_{t-1} + \varepsilon_t$; (c) $y_t = y_{t-1} + \varepsilon_t$; (d) $y_t = 0,5y_{t-1} + 0,3y_{t-2} + \varepsilon_t$.

Solución 2.1

(a) $|\phi| = 0,9 < 1$: sí. (b) $|\phi| = 1,2 > 1$: solo la solución **no causal** (adelantada). (c) $\phi = 1$: no hay solución estacionaria (caminata aleatoria). (d) $\phi(z) = 1 - 0,5z - 0,3z^2$; las raíces de $0,3z^2 + 0,5z - 1 = 0$ son $z = \frac{-0,5 \pm \sqrt{0,25 + 1,2}}{0,6} = \frac{-0,5 \pm 1,204}{0,6}$, es decir $z_1 = 1,173$ y $z_2 = -2,840$, ambas con $|z| > 1$: sí es estacionario y causal.

Ejercicio 2.2. Para un ARMA(1,1) con $\phi = 0,5$ y $\theta = 0,4$, calcula $\psi_1, \psi_2, \psi_3, \gamma(0)/\sigma^2$ y σ_{LR}^2/σ^2 .

Solución 2.2

$\psi_j = \phi^{j-1}(\phi + \theta)$: $\psi_1 = 0,9$, $\psi_2 = 0,45$, $\psi_3 = 0,225$.
 $\gamma(0)/\sigma^2 = \sum_j \psi_j^2 = 1 + \frac{(\phi + \theta)^2}{1 - \phi^2} = 1 + \frac{0,81}{0,75} = 2,08$.
 $\psi(1) = \frac{1 + \theta}{1 - \phi} = \frac{1,4}{0,5} = 2,8$ (también $1 + \sum_{j \geq 1} \psi_j = 1 + 0,9/0,5 = 2,8$) y $\sigma_{LR}^2/\sigma^2 = 7,84$. La varianza de largo plazo es casi cuatro veces $\gamma(0)$: la serie es muy persistente.

Ejercicio 2.3. Un MA(1) tiene $\theta = -1,5$ y $\sigma^2 = 1$. Encuentra la representación invertible equivalente y verifica que da las mismas autocovarianzas.

 Solución 2.3

$\theta^* = 1/\theta = -2/3$ y $\sigma^{*2} = \theta^2 \sigma^2 = 2,25$. Original: $\gamma(0) = \sigma^2(1 + \theta^2) = 3,25$ y $\gamma(1) = \theta \sigma^2 = -1,5$. Invertible: $\gamma^*(0) = 2,25(1 + 4/9) = 2,25 \cdot 13/9 = 3,25$ y $\gamma^*(1) = (-2/3)(2,25) = -1,5$. Coinciden. Si el investigador estima un MA(1) por máxima verosimilitud gaussiana, obtendrá $\hat{\theta} = -2/3$ (en la región invertible) aunque el “verdadero” generador fuera $-1,5$.

Ejercicio 2.4. Para el AR(2) del Ejemplo 6.1 calcula $\rho(4)$ y la varianza $\gamma(0)/\sigma^2$ usando Ecuación 2.

 Solución 2.4

$\rho(4) = 0,5\rho(3) + 0,3\rho(2) = 0,5(0,543) + 0,3(0,657) = 0,271 + 0,197 = 0,469$. Varianza: $\gamma(0) = \phi_1\gamma(1) + \phi_2\gamma(2) + \sigma^2 = \gamma(0)[\phi_1\rho(1) + \phi_2\rho(2)] + \sigma^2$, así que $\gamma(0)/\sigma^2 = 1/[1 - \phi_1\rho(1) - \phi_2\rho(2)] = 1/[1 - 0,357 - 0,197] = 1/0,446 = 2,24$.

Ejercicio 2.5. Verifica con las raíces que el AR(2) con $\phi_1 = 1,2$ y $\phi_2 = -0,5$ es estacionario, y calcula el período aproximado de su ciclo. (Pista: escribe $\phi(z) = (1 - \lambda_1 z)(1 - \lambda_2 z)$, de modo que $\phi_1 = \lambda_1 + \lambda_2$, $\phi_2 = -\lambda_1 \lambda_2$; la condición es $|\lambda_i| < 1$.)

 Solución 2.5

$\lambda^2 - 1,2\lambda + 0,5 = 0$ da $\lambda = 0,6 \pm \frac{1}{2}\sqrt{1,44 - 2}i = 0,6 \pm 0,374i$ (raíces complejas conjugadas). $|\lambda| = \sqrt{0,36 + 0,14} = \sqrt{0,5} = 0,707 < 1$: estacionario (en general, para raíces complejas $|\lambda|^2 = -\phi_2 < 1$). El argumento es $\arctan(0,374/0,6) = 0,558$ rad, y el período del ciclo estocástico es $2\pi/0,558 \approx 11,3$ períodos. La ACF oscila amortiguada con ese período. Las condiciones generales de estacionariedad del AR(2) (el “triángulo”) son $\phi_1 + \phi_2 < 1$,

$\phi_2 - \phi_1 < 1$ y $|\phi_2| < 1$; aquí $0,7 < 1$, $-1,7 < 1$ y $0,5 < 1$ se cumplen.

Ejercicio 2.6. Muestra que $(1 - 0,5L)y_t = (1 - 0,5L)\varepsilon_t$ es simplemente ruido blanco, y explica el problema de **redundancia de parámetros** en el ARMA(1,1) cuando $\theta = -\phi$.

 Solución 2.6

El factor $(1 - 0,5L)$ aparece en ambos lados y es invertible (la raíz $z = 2$ está fuera del círculo unitario): $y_t = \varepsilon_t$. En general, con $\theta = -\phi$, $\psi(z) = (1 - \phi z)/(1 - \phi z) = 1$: la autocovarianza es la del ruido blanco cualquiera sea ϕ . Entonces la verosimilitud es **constante en la recta** $\theta = -\phi$: no hay información para identificar ϕ (y θ por separado), y los errores estándar de un ARMA(1,1) ajustado a datos que son casi ruido blanco son enormes. Es la razón por la que se exige “sin raíces comunes” y por la que sobreajustar el orden (p, q) degrada la estimación.

Ejercicio 2.7 ★. Calcula la densidad espectral de un MA(1) con θ y con $1/\theta$ (con σ^2 ajustada) y comprueba que son iguales. ¿Para qué θ se maximiza $f(0)$ relativa a $\gamma(0)$?

 Solución 2.7 ★

$$f(\lambda) = \frac{\sigma^2}{2\pi} |1 + \theta e^{-i\lambda}|^2 = \frac{\sigma^2}{2\pi} (1 + \theta^2 + 2\theta \cos \lambda).$$
 Con $\theta^* = 1/\theta$ y $\sigma^{*2} = \theta^2 \sigma^2$:
$$\frac{\theta^2 \sigma^2}{2\pi} (1 + \theta^{-2} + 2\theta^{-1} \cos \lambda) = \frac{\sigma^2}{2\pi} (\theta^2 + 1 + 2\theta \cos \lambda):$$
 idéntica. El cociente $2\pi f(0)/\gamma(0) = \sigma_{LR}^2/\gamma(0) = (1+\theta)^2/(1+\theta^2) = 1+2\rho(1) \leq 2$, con máximo 2 en $\theta = 1$ (que corresponde a $\rho(1) = 0,5$) y mínimo 0 en $\theta = -1$ (donde $\rho(1) = -0,5$ y la varianza de largo plazo es cero: la serie “sobrediferenciada”).