

# Clase 3 · Pronóstico

El mejor predictor lineal, las innovaciones y la  
evaluación de pronósticos

## Contenido

|          |                                                                 |           |
|----------|-----------------------------------------------------------------|-----------|
| <b>1</b> | <b>Para qué sirven los modelos de series de tiempo</b>          | <b>1</b>  |
| <b>2</b> | <b>El predictor óptimo</b>                                      | <b>2</b>  |
| 2.1      | El $AR(p)$ y la PACF . . . . .                                  | 3         |
| <b>3</b> | <b>Las innovaciones y el pronóstico con pasado infinito</b>     | <b>4</b>  |
| 3.1      | Pronósticos con una media móvil . . . . .                       | 6         |
| <b>4</b> | <b>Evaluar y comparar pronósticos</b>                           | <b>6</b>  |
| <b>5</b> | <b>★ Postgrado: Durbin-Levinson y la descomposición de Wold</b> | <b>8</b>  |
| 5.1      | Demostración de Durbin-Levinson . . . . .                       | 8         |
| 5.2      | Esbozo de la demostración de Wold . . . . .                     | 9         |
| <b>6</b> | <b>Resumen</b>                                                  | <b>9</b>  |
| <b>7</b> | <b>Ejercicios</b>                                               | <b>10</b> |

## 1. Para qué sirven los modelos de series de tiempo

Buena parte de la econometría de series de tiempo existe para **pronosticar**: la inflación del próximo trimestre, la demanda de electricidad de mañana, el valor en riesgo de un portafolio. Un

modelo ARMA tiene un uso inmediato: dado el pasado de la serie, produce un pronóstico y una medida de su incertidumbre. En esta clase respondemos tres preguntas:

1. ¿**Cuál** es el mejor pronóstico (lineal) y cómo se calcula?
2. ¿Qué **error** comete, y cómo crece con el horizonte?
3. Si tengo dos pronósticos competidores, ¿cómo decido **cuál es mejor**?

La respuesta a la primera es una **proyección**: la misma geometría de mínimos cuadrados de la Clase 3 de Econometría 1, ahora en el espacio de variables aleatorias.

## 2. El predictor óptimo

Sea  $I_T = \{y_T, y_{T-1}, \dots\}$  la información disponible en  $T$  y queremos pronosticar  $y_{T+h}$  con un predictor  $\hat{y}_{T+h|T}$  función de  $I_T$ . Con pérdida **cuadrática**, el mejor predictor es la **esperanza condicional**:  $\hat{y}_{T+h|T} = \mathbb{E}[y_{T+h} | I_T]$  (el mismo resultado de la Clase 2 de Econometría 1: la CEF minimiza el error cuadrático medio). Pero calcularla exige conocer **toda la distribución** conjunta del proceso. Con solo los dos primeros momentos (lo que identifica un modelo ARMA), podemos obtener el **mejor predictor lineal**.

**Definición 2.1** (Mejor predictor lineal (BLP)). El mejor predictor lineal de  $y_{n+1}$  dado  $y_1, \dots, y_n$  en un proceso estacionario de media cero es  $\hat{y}_{n+1} = \sum_{j=1}^n \phi_{n,j} y_{n+1-j}$ , con coeficientes  $\phi_n = (\phi_{n,1}, \dots, \phi_{n,n})'$  que minimizan el error cuadrático medio (ECM)  $\mathbb{E}[(y_{n+1} - \sum_j a_j y_{n+1-j})^2]$  sobre  $a \in \mathbb{R}^n$ .

**Teorema 2.1** (Ecuaciones normales del BLP). Si  $\Gamma_n = [\gamma(i-j)]_{i,j=1}^n$  es invertible, el BLP tiene coeficientes y ECM

$$\phi_n = \Gamma_n^{-1} \gamma_n, \quad v_n = \gamma(0) - \gamma_n' \Gamma_n^{-1} \gamma_n, \quad \gamma_n = (\gamma(1), \dots, \gamma(n))'.$$

Además, el error  $y_{n+1} - \hat{y}_{n+1}$  es **ortogonal** (no correlacionado) con  $y_1, \dots, y_n$ .

*Demostración.* El ECM es  $\mathbb{E}[(y_{n+1} - a'z)^2]$  con  $z = (y_n, \dots, y_1)'$ , que se expande en  $\gamma(0) - 2a'\gamma_n + a'\Gamma_n a$  (usando  $\text{Cov}(z) = \Gamma_n$  y  $\text{Cov}(z, y_{n+1}) = \gamma_n$ ). Es una forma cuadrática estrictamente convexa (si  $\Gamma_n \succ 0$ ) en  $a$ , y la CPO  $-2\gamma_n + 2\Gamma_n a = 0$  da  $a = \Gamma_n^{-1}\gamma_n$ . Sustituyendo, el ECM mínimo es  $\gamma(0) - \gamma_n'\Gamma_n^{-1}\gamma_n$ . La CPO es  $\mathbb{E}[z(y_{n+1} - a'z)] = \gamma_n - \Gamma_n a = 0$ : ortogonalidad del error y los regresores.  $\square$

Es **exactamente MCO**, con  $\Gamma_n$  y  $\gamma_n$  en lugar de  $X'X/n$  y  $X'y/n$ . La ortogonalidad del error con los datos usados es la *definición* de proyección (Clase 3 de Econometría 1), aquí en el espacio de variables aleatorias de segundo momento finito,  $L^2$ . Para calcular  $\phi_n$  para cada  $n$  sin invertir una matriz  $n \times n$  cada vez se usa el algoritmo de **Durbin-Levinson** (sección ★), que además entrega la **PACF**:

**Proposición 2.1** (Durbin-Levinson). *El último coeficiente  $\phi_{n,n}$  es la autocorrelación parcial:  $\alpha(n) = \phi_{n,n}$ . Se calcula recursivamente con  $v_0 = \gamma(0)$  y*

$$\phi_{n,n} = \frac{\gamma(n) - \sum_{j=1}^{n-1} \phi_{n-1,j}\gamma(n-j)}{v_{n-1}}, \quad \phi_{n,j} = \phi_{n-1,j} - \phi_{n,n}\phi_{n-1,n-j}, \quad v_n = v_{n-1}(1 - \phi_{n,n}^2).$$

La última fórmula es reveladora: **cada rezago adicional reduce el ECM en el factor  $1 - \alpha(n)^2$** . La PACF mide cuánto mejora de predicción aporta el rezago  $n$  una vez usados los  $n - 1$  anteriores.

## 2.1. El AR( $p$ ) y la PACF

La propiedad de la Clase 2 (la PACF de un AR( $p$ ) se corta en  $p$ ) se demuestra ahora.

**Proposición 2.2** (La PACF de un AR( $p$ ) se anula para  $h > p$ ). *Si  $\{y_t\}$  es un AR( $p$ ) causal, para  $n \geq p$  el BLP de  $y_{n+1}$  es  $\hat{y}_{n+1} = \sum_{k=1}^p \phi_k y_{n+1-k}$  con ECM  $\sigma^2$ . En particular  $\alpha(h) = 0$  para  $h > p$  y  $\alpha(p) = \phi_p$ .*

*Demostración.* Sea  $\tilde{y}_{n+1} = \sum_{k=1}^p \phi_k y_{n+1-k}$ . El error es  $y_{n+1} - \tilde{y}_{n+1} = \varepsilon_{n+1}$ , que por causalidad es **no correlacionado** con  $y_s$  para todo  $s \leq n$ , o sea con el pasado entero. Cumple las condiciones de ortogonalidad del Teorema 2.1, y como la solución a las ecuaciones normales es única, es el BLP. Sus coeficientes son  $(\phi_1, \dots, \phi_p, 0, \dots, 0)$ , de modo que  $\phi_{n,n} = 0$  para  $n > p$ , y  $\phi_{p,p} = \phi_p$ . El ECM es  $\mathbb{E}[\varepsilon_{n+1}^2] = \sigma^2$ .  $\square$

Observa que **el pronóstico a un paso de un AR( $p$ ) es exacto con  $p$  rezagos**: más historia no ayuda. Con un MA o un ARMA la historia lejana sí importa (porque los  $\varepsilon$  pasados se “recuperan” mediante invertibilidad y esa recuperación mejora con más datos).

### 3. Las innovaciones y el pronóstico con pasado infinito

Es más cómodo analizar el pronóstico con **todo el pasado** disponible,  $H_t = \overline{\text{sp}}\{y_s : s \leq t\}$  (el cierre en  $L^2$  del espacio de combinaciones lineales de los datos hasta  $t$ ). Para  $T$  grande, la diferencia con usar solo  $y_1, \dots, y_T$  es despreciable en procesos ARMA (el error decae geométricamente).

**Definición 3.1** (Innovación). La **innovación** de  $y_t$  es el error de pronóstico lineal a un paso con todo el pasado:  $\varepsilon_t = y_t - P_{H_{t-1}} y_t$ , donde  $P_{H_{t-1}}$  denota la proyección ortogonal sobre  $H_{t-1}$ . Su varianza es el **error cuadrático medio de pronóstico a un paso**,  $\sigma^2 = \mathbb{E}[\varepsilon_t^2]$ .

Dos propiedades inmediatas: (i)  $\varepsilon_t \perp H_{t-1}$  por construcción de la proyección, y (ii)  $\varepsilon_s \in H_s \subset H_{t-1}$  para  $s < t$ . Entonces  $\varepsilon_t$  es **no correlacionado** con  $\varepsilon_s$  para  $s < t$ : la sucesión de innovaciones es un ruido blanco, **con varianza constante por estacionariedad**. Ese ruido blanco es el  $\varepsilon_t$  de la descomposición de Wold de la Clase 2. Para un proceso invertible, la innovación coincide con el  $\varepsilon_t$  del modelo ARMA; para uno no invertible, no (Ejercicio 3.7).

**Teorema 3.1** (Pronóstico a  $h$  pasos en un proceso causal e invertible). Sea  $y_t = \sum_{j \geq 0} \psi_j \varepsilon_{t-j}$  (con  $\psi_0 = 1$ ) un proceso causal e invertible, de modo que  $\varepsilon_t \in H_t$  y  $H_t = \overline{\text{span}}\{\varepsilon_s : s \leq t\}$ . Entonces

$$\hat{y}_{T+h|T} = \sum_{j=h}^{\infty} \psi_j \varepsilon_{T+h-j}, \quad e_{T+h|T} = y_{T+h} - \hat{y}_{T+h|T} = \sum_{j=0}^{h-1} \psi_j \varepsilon_{T+h-j}, \quad \text{ECM}(h) = \sigma^2 \sum_{j=0}^{h-1} \psi_j^2.$$

El ECM es **creciente en  $h$**  y converge a  $\gamma(0) = \sigma^2 \sum_j \psi_j^2$  (la varianza incondicional) cuando  $h \rightarrow \infty$ , mientras  $\hat{y}_{T+h|T} \rightarrow \mu = 0$ .

*Demostración.* Escribimos  $y_{T+h} = \sum_{j=0}^{h-1} \psi_j \varepsilon_{T+h-j} + \sum_{j \geq h} \psi_j \varepsilon_{T+h-j}$ . El segundo sumando pertenece a  $H_T$  (involucra solo  $\varepsilon_s$  con  $s \leq T$ ). El primero es una combinación de  $\varepsilon_{T+1}, \dots, \varepsilon_{T+h}$ , que son no correlacionados con  $H_T$  (cada  $\varepsilon_s$  con  $s > T$  es ortogonal a  $H_{s-1} \supset H_T$ ). Por la caracterización de la proyección por ortogonalidad, el segundo sumando es  $P_{H_T} y_{T+h}$  y el primero es el error. Su varianza es  $\sigma^2 \sum_{j < h} \psi_j^2$  por la ortogonalidad entre los  $\varepsilon$ . El límite de  $\text{ECM}(h)$  es  $\gamma(0)$  por la proposición de procesos lineales de la Clase 2, y  $\hat{y}_{T+h|T} \rightarrow 0$  porque su varianza  $\sigma^2 \sum_{j \geq h} \psi_j^2 \rightarrow 0$ .  $\square$

Interpretación: el pronóstico a corto plazo aprovecha la **memoria** del proceso; a largo plazo, el pasado se olvida, el pronóstico **revierte a la media** y el error se vuelve tan grande como la varianza de la serie. Con un proceso **no estacionario** (raíz unitaria) esto cambia drásticamente: el ECM crece sin cota (Clase 6).

**Ejemplo 3.1** (Pronóstico del AR(1)). Para  $y_t = \phi y_{t-1} + \varepsilon_t$ :  $\psi_j = \phi^j$ , de modo que  $\hat{y}_{T+h|T} = \phi^h y_T$  (decae geométricamente hacia 0) y

$$\text{ECM}(h) = \sigma^2 \sum_{j=0}^{h-1} \phi^{2j} = \sigma^2 \frac{1 - \phi^{2h}}{1 - \phi^2}.$$

Con  $\phi = 0,8$ ,  $\sigma^2 = 1$  y  $y_T = 2$ :  $\hat{y}_{T+1} = 1,6$ ,  $\hat{y}_{T+2} = 1,28$ ,  $\hat{y}_{T+3} = 1,024$ , con ECM 1, 1,64 y 2,05, que tiende a  $\gamma(0) = 1/0,36 = 2,78$ . Bajo normalidad, el intervalo de pronóstico al 95 % a dos pasos es  $1,28 \pm 1,96\sqrt{1,64} = 1,28 \pm 2,51$ .

En la práctica los parámetros se **estiman**, y se usa el *pronóstico plug-in*  $\hat{y}_{T+h|T}(\hat{\theta})$ . El error de estimación agrega un término de orden  $1/T$  al ECM (que desaparece asintóticamente), pero en muestras pequeñas los intervalos que ignoran esto resultan demasiado angostos.

### 3.1. Pronósticos con una media móvil

**Ejemplo 3.2** (Pronóstico del MA(2)). Para  $y_t = \varepsilon_t + 0,6\varepsilon_{t-1} + 0,3\varepsilon_{t-2}$ :  $\hat{y}_{T+1|T} = 0,6\varepsilon_T + 0,3\varepsilon_{T-1}$ ,  $\hat{y}_{T+2|T} = 0,3\varepsilon_T$  y  $\hat{y}_{T+h|T} = 0$  para  $h \geq 3$  (el pasado deja de importar tras  $q = 2$  pasos). ECM:  $\sigma^2, 1,36\sigma^2, 1,45\sigma^2 = \gamma(0)$  para  $h \geq 3$ . En la práctica los  $\varepsilon_T, \varepsilon_{T-1}$  no se observan: se reconstruyen de los datos con la inversión  $\varepsilon_t = \sum_j \pi_j y_{t-j}$  (invertibilidad).

## 4. Evaluar y comparar pronósticos

Un modelo con buen ajuste dentro de la muestra puede pronosticar mal fuera de ella (sobreajuste). La evaluación honesta usa **pronósticos fuera de muestra**: se estima con datos hasta  $\tau$ , se pronostica  $y_{\tau+h}$ , se avanza  $\tau$  (ventana creciente o rodante) y se acumulan los errores  $e_{\tau+h|\tau}$  para  $\tau = R, \dots, T - h$ , con  $P = T - h - R + 1$  pronósticos.

Con dos pronósticos competidores y errores  $e_t^{(1)}, e_t^{(2)}$ , y una función de pérdida  $L$  (cuadrática, absoluta, asimétrica), el **diferencial de pérdida** es  $d_t = L(e_t^{(1)}) - L(e_t^{(2)})$ . La hipótesis de **igual precisión predictiva** es  $H_0 : \mathbb{E}[d_t] = 0$ .

**Proposición 4.1** (Test de Diebold–Mariano). Si  $\{d_t\}$  es estacionario y ergódico con varianza de largo plazo  $\sigma_d^2 > 0$ , bajo  $H_0$ ,

$$DM = \frac{\bar{d}}{\sqrt{\hat{\sigma}_d^2/P}} \xrightarrow{d} N(0, 1), \quad \bar{d} = \frac{1}{P} \sum_t d_t,$$

con  $\hat{\sigma}_d^2$  un estimador consistente de la **varianza de largo plazo** de  $d_t$  (por ejemplo, Newey–West, Clase 5).

La demostración es el TCL para procesos dependientes (Clase 5):  $\sqrt{P}\bar{d} \rightarrow N(0, \sigma_d^2)$  donde  $\sigma_d^2 = \sum_h \gamma_d(h)$  es la varianza de largo plazo de la Clase 1, y Slutsky hace el resto. El punto esencial es **por qué hay que usar la varianza de largo plazo y no la simple**: los errores de pronóstico a  $h$  pasos son un **MA**( $h - 1$ ) (por el Teorema 3.1), de modo que  $d_t$  tiene autocorrelación hasta el rezago  $h - 1$ . Para  $h = 1$  puede ser razonable ignorarla; para  $h > 1$  **ignorarla subestima la varianza y sobrerrechaza**.

**Ejemplo 4.1** (Una aplicación numérica). Se comparan dos modelos con  $P = 100$  pronósticos a un paso, pérdida cuadrática.  $\bar{d} = 0,05$  (el modelo 2 es algo mejor) y  $\hat{\sigma}_d = 0,40$ . Entonces  $DM = 0,05/(0,40/\sqrt{100}) = 1,25 < 1,96$ : **no se rechaza** igual precisión. Hay que notar que  $\bar{d} > 0$  no es evidencia de mejor pronóstico: con diferencias de ese tamaño y esa variabilidad, la diferencia es compatible con el azar.

Dos advertencias. (i) La teoría del test supone que los **modelos no están anidados** y que los parámetros se estiman en una ventana de tamaño fijo (rodante); con modelos anidados y ventana creciente, el  $DM$  ingenuo tiene distribución no estándar y es conservador (se usa el test de Clark–West). (ii) La elección de la **función de pérdida** importa: un pronosticador puede ser mejor en ECM y peor en error absoluto.

Una verificación relacionada es el test de **eficiencia** de Mincer–Zarnowitz: regresar el valor realizado sobre el pronóstico,  $y_{t+h} = a + b \hat{y}_{t+h|t} + u_t$ , y testear  $H_0 : a = 0, b = 1$  (un pronóstico óptimo no deja predictibilidad en el error), con errores estándar HAC por la misma razón.

#### Pronosticar el nivel, pronosticar la varianza

El mejor predictor **lineal** puede ser pobre cuando la dinámica relevante no es lineal. En un proceso con volatilidad cambiante (GARCH, Clase 12),  $y_t$  puede ser **no correlacionado** con su pasado (el pronóstico lineal del nivel es 0) y, sin embargo, su **varianza condicional** es muy predecible. El BLP no ve eso: solo usa los dos primeros momentos incondicionales. Para pronósticos de **densidad** o de riesgo hay que modelar la distribución condicional completa.

## 5. ★ Postgrado: Durbin–Levinson y la descomposición de Wold

### ! ★ Postgrado

Demostramos la recursión de Durbin–Levinson (Proposición 2.1) y esbozamos la demostración del teorema de Wold con la geometría de proyecciones.

### 5.1. Demostración de Durbin–Levinson

Sea  $M = \text{sp}\{y_2, \dots, y_n\}$ . El espacio  $\text{sp}\{y_1, \dots, y_n\}$  es la suma ortogonal de  $M$  y la recta generada por el **error de pronóstico hacia atrás**  $b = y_1 - P_M y_1$ . Entonces

$$P_{\text{sp}\{y_1, \dots, y_n\}} y_{n+1} = P_M y_{n+1} + a b, \quad a = \frac{\mathbb{E}[(y_{n+1} - P_M y_{n+1}) b]}{\mathbb{E}[b^2]}.$$

Por estacionariedad, el problema de proyectar  $y_{n+1}$  sobre  $(y_2, \dots, y_n)$  ( $n - 1$  rezagos) es idéntico al de proyectar  $y_n$  sobre  $(y_1, \dots, y_{n-1})$  desplazado en un período:  $P_M y_{n+1} = \sum_{j=1}^{n-1} \phi_{n-1,j} y_{n+1-j}$  con ECM  $v_{n-1}$ . Y como  $\gamma(h) = \gamma(-h)$ , el proceso invertido en el tiempo tiene las mismas autocovarianzas, de modo que la proyección **hacia atrás** de  $y_1$  sobre  $(y_2, \dots, y_n)$  usa los mismos coeficientes:  $P_M y_1 = \sum_{j=1}^{n-1} \phi_{n-1,j} y_{1+j}$ , con el mismo ECM  $\mathbb{E}[b^2] = v_{n-1}$ . El numerador de  $a$  es  $\mathbb{E}[y_{n+1} b] = \gamma(n) - \sum_{j=1}^{n-1} \phi_{n-1,j} \gamma(n-j)$  (porque  $P_M y_{n+1}$  es ortogonal a  $b$ ). Luego  $a = \phi_{n,n}$  es el coeficiente de la recursión. Para el resto de los coeficientes, sustituyendo  $b$ :

$$\sum_{j=1}^n \phi_{n,j} y_{n+1-j} = \sum_{j=1}^{n-1} \phi_{n-1,j} y_{n+1-j} + \phi_{n,n} \left( y_1 - \sum_{j=1}^{n-1} \phi_{n-1,j} y_{1+j} \right),$$

y comparando coeficientes de  $y_{n+1-j}$  (el término  $y_{1+k}$  es  $y_{n+1-(n-k)}$ ):  $\phi_{n,j} = \phi_{n-1,j} - \phi_{n,n} \phi_{n-1,n-j}$ . Para el ECM,  $v_n = \mathbb{E}[(y_{n+1} - P_M y_{n+1})^2] - a^2 \mathbb{E}[b^2] = v_{n-1} - \phi_{n,n}^2 v_{n-1}$ , por el teorema de Pitágoras en la suma ortogonal.

## 5.2. Esbozo de la demostración de Wold

Sea  $H_t$  como antes y  $H_{-\infty} = \bigcap_t H_t$  (la parte “infinitamente remota” del pasado). Las innovaciones  $\varepsilon_t = y_t - P_{H_{t-1}} y_t$  son un ruido blanco. Proyectando  $y_t$  sobre el sistema ortogonal  $\{\varepsilon_t, \varepsilon_{t-1}, \dots, \varepsilon_{t-n+1}\}$  y sobre  $H_{t-n}$  (que es ortogonal a todos ellos),

$$y_t = \sum_{j=0}^{n-1} \psi_j \varepsilon_{t-j} + P_{H_{t-n}} y_t, \quad \psi_j = \frac{\mathbb{E}[y_t \varepsilon_{t-j}]}{\sigma^2}.$$

Los  $\psi_j$  **no dependen de  $t$**  (por estacionariedad), y por la desigualdad de Bessel  $\sigma^2 \sum_{j < n} \psi_j^2 \leq \gamma(0)$  para todo  $n$ , así que  $\sum_j \psi_j^2 < \infty$ . Por lo tanto  $\sum_j \psi_j \varepsilon_{t-j}$  converge en  $L^2$ , y el resto  $P_{H_{t-n}} y_t$  converge a  $P_{H_{-\infty}} y_t =: V_t$ , que es el **componente determinístico**: perfectamente predecible desde el pasado remoto. Entonces  $y_t = \sum_j \psi_j \varepsilon_{t-j} + V_t$  con  $V_t \perp \varepsilon_s$  para todo  $s$ . Si  $H_{-\infty} = \{0\}$  (proceso **puramente no determinístico**),  $V_t = 0$  y queda la representación de Wold. La parte que requiere cuidado técnico (que  $\psi_0 = 1$  y que el sistema de  $\varepsilon_t$  no se degenera) usa  $\sigma^2 > 0$  y se omite aquí.

## 6. Resumen

- El mejor predictor **lineal** de  $y_{n+1}$  sobre los datos resuelve las **ecuaciones normales**  $\Gamma_n \phi_n = \gamma_n$  (Teorema 2.1): es una proyección en  $L^2$ , el MCO del mundo de procesos.
- **Durbin-Levinson** (Proposición 2.1) lo calcula recursivamente;  $\phi_{n,n} = \alpha(n)$  es la PACF y  $v_n = v_{n-1}(1 - \alpha(n)^2)$ . La PACF de un  $AR(p)$  se corta en  $p$  (Proposición 2.2).
- La **innovación** es el error de pronóstico a un paso con todo el pasado: es un ruido blanco y es la innovación de Wold.
- En un proceso causal e invertible, el error a  $h$  pasos es  $\sum_{j < h} \psi_j \varepsilon_{T+h-j}$ , un **MA( $h-1$ )**, con ECM  $\sigma^2 \sum_{j < h} \psi_j^2$  creciente hasta  $\gamma(0)$  (Teorema 3.1). Los pronósticos **revierten a la media**.
- **Diebold-Mariano** (Proposición 4.1) compara pronósticos usando la **varianza de largo plazo** del diferencial de pérdida.

## 7. Ejercicios

**Ejercicio 3.1.** Para un AR(1) con  $\gamma(h) = \phi^h \gamma(0)$ , resuelve las ecuaciones normales con  $n = 2$  y comprueba que el BLP de  $y_3$  sobre  $(y_2, y_1)$  es  $\phi y_2$ , con ECM  $\sigma^2 = \gamma(0)(1 - \phi^2)$ .

### Solución 3.1

$$\Gamma_2 = \gamma(0) \begin{pmatrix} 1 & \phi \\ \phi & 1 \end{pmatrix}, \gamma_2 = \gamma(0)(\phi, \phi^2)'. \phi_2 = \Gamma_2^{-1} \gamma_2 = \frac{1}{1 - \phi^2} \begin{pmatrix} 1 & -\phi \\ -\phi & 1 \end{pmatrix} \begin{pmatrix} \phi \\ \phi^2 \end{pmatrix} = \frac{1}{1 - \phi^2} \begin{pmatrix} \phi - \phi^3 \\ -\phi^2 + \phi^2 \end{pmatrix} = \begin{pmatrix} \phi \\ 0 \end{pmatrix}.$$

El BLP es  $\phi y_2$  (el segundo rezago tiene coeficiente cero:  $\alpha(2) = 0$ ). ECM:  $v_2 = \gamma(0) - \gamma_2' \phi_2 = \gamma(0)(1 - \phi \cdot \phi) = \gamma(0)(1 - \phi^2) = \sigma^2$  (pues  $\gamma(0) = \sigma^2/(1 - \phi^2)$ ).

**Ejercicio 3.2.** Con un MA(1) con  $\theta = 0,5$  y  $\sigma^2 = 1$  ( $\gamma(0) = 1,25$ ,  $\gamma(1) = 0,5$ ,  $\gamma(h) = 0$  si  $h \geq 2$ ), usa Durbin-Levinson para calcular  $\phi_{1,1}$ ,  $v_1$ ,  $\phi_{2,2}$  y  $v_2$ . Compara con el ECM con pasado infinito.

### Solución 3.2

$v_0 = 1,25$ .  $\phi_{1,1} = \gamma(1)/v_0 = 0,4$  y  $v_1 = 1,25(1 - 0,16) = 1,05$ .  $\phi_{2,2} = [\gamma(2) - \phi_{1,1}\gamma(1)]/v_1 = (0 - 0,2)/1,05 = -0,1905$  y  $v_2 = 1,05(1 - 0,0363) = 1,0119$ . Con pasado infinito el ECM es  $\sigma^2 = 1$  (la innovación). Con  $n = 1$  el ECM es 5 % mayor, con  $n = 2$  solo 1,2 % mayor: converge a  $\sigma^2$  geométricamente (a tasa  $\theta^2$ ). La PACF del MA(1) **no** se corta:  $\alpha(1) = 0,4$ ,  $\alpha(2) = -0,19$ , y así sigue alternando y decayendo.

**Ejercicio 3.3.** Para el AR(1) con  $\phi = 0,8$ ,  $\sigma^2 = 1$  y  $y_T = 2$ , calcula el pronóstico a  $h = 4$  pasos, su ECM y el intervalo de pronóstico al 95 %. Compara el ECM con la varianza incondicional.

### Solución 3.3

$\hat{y}_{T+4} = 0,8^4 \cdot 2 = 0,4096 \cdot 2 = 0,819$ . ECM(4) =  $(1 - 0,8^8)/0,36 = (1 - 0,168)/0,36 = 2,311$ . Intervalo:  $0,819 \pm 1,96\sqrt{2,311} = 0,819 \pm 2,98$ . La varianza incondicional es

2,78: ya a  $h = 4$  el ECM es el 83 % del máximo posible, y el pronóstico puntual casi es la media. El dato  $y_T = 2$  ya aporta poca información a cuatro pasos con  $\phi = 0,8$ .

**Ejercicio 3.4.** Para el ARMA(1,1) con  $\phi = 0,5$  y  $\theta = 0,4$  (Clase 2, ejercicio 2.2), calcula el ECM para  $h = 1, 2, 3$  y el límite.

 Solución 3.4

$\psi_0 = 1, \psi_1 = 0,9, \psi_2 = 0,45$ . ECM(1) =  $\sigma^2$ , ECM(2) =  $\sigma^2(1 + 0,81) = 1,81\sigma^2$ , ECM(3) =  $\sigma^2(1 + 0,81 + 0,2025) = 2,0125\sigma^2$ . Límite:  $\gamma(0) = 2,08\sigma^2$ . Cerca del límite ya a  $h = 3$ .

**Ejercicio 3.5.** Verifica los pronósticos y ECM del Ejemplo 3.2 (MA(2)) y calcula  $\gamma(0)$  directamente.

 Solución 3.5

$y_{T+1} = \varepsilon_{T+1} + 0,6\varepsilon_T + 0,3\varepsilon_{T-1}$ : el único término impredecible es  $\varepsilon_{T+1}$ , así que el ECM es  $\sigma^2$ .  $y_{T+2} = \varepsilon_{T+2} + 0,6\varepsilon_{T+1} + 0,3\varepsilon_T$ : impredecibles los dos primeros, ECM  $(1 + 0,36)\sigma^2 = 1,36\sigma^2$ . Para  $h \geq 3$ , los tres términos son futuros: ECM =  $(1 + 0,36 + 0,09)\sigma^2 = 1,45\sigma^2$  y el pronóstico es la media 0. Directamente,  $\gamma(0) = \sigma^2(1 + 0,6^2 + 0,3^2) = 1,45\sigma^2$ . Coincide: cuando el horizonte excede  $q$ , el pronóstico no puede mejorar a la media incondicional.

**Ejercicio 3.6.** Con  $P = 120$  pronósticos a  $h = 3$  pasos,  $\bar{d} = -0,03$  y  $\hat{\sigma}_d = 0,25$  (varianza de largo plazo estimada con 2 rezagos), calcula el DM. ¿Por qué usar 2 rezagos? ¿Qué pasaría si se usara la varianza simple  $\hat{\gamma}_d(0) = 0,04$ ?

 Solución 3.6

$DM = -0,03/(0,25/\sqrt{120}) = -0,03/0,0228 = -1,31$ : no se rechaza. Se usan  $h - 1 = 2$  rezagos porque los errores de pronóstico a 3 pasos son un MA(2) y por tanto  $d_t$  tiene autocorrelaciones hasta el rezago 2 (Newey-West con ventana  $\geq h - 1$ ). Con la varianza simple  $\sqrt{0,04} = 0,2$

en lugar de 0,25 (menor si hay autocorrelación positiva),  $DM = -0,03/(0,2/\sqrt{120}) = -1,64$ : más cerca del rechazo. Aunque aquí no cruzaría 1,96, **el sesgo de ignorar la dependencia es hacia el sobrerrechazo.**

**Ejercicio 3.7 ★.** Sea  $y_t = \varepsilon_t + 2\varepsilon_{t-1}$  con  $\varepsilon_t \sim WN(0, 1)$  (MA(1) **no invertible**). Encuentra la innovación de Wold y calcula el ECM de pronóstico a un paso con todo el pasado. ¿Es 1?

 Solución 3.7 ★

La representación invertible equivalente es  $y_t = \varepsilon_t^* + \frac{1}{2}\varepsilon_{t-1}^*$  con  $\sigma^{*2} = \theta^2\sigma^2 = 4$  (Clase 2). Como es invertible,  $\varepsilon_t^* \in H_t$  y es el error de pronóstico lineal con todo el pasado: **la innovación de Wold es  $\varepsilon_t^*$** , con varianza 4. El ECM a un paso óptimo es 4, **no** 1. El  $\varepsilon_t$  original (varianza 1) no es una función lineal de los  $y$  pasados y presentes (no pertenece a  $H_t$ ): sería un “oráculo” que usa información que el econometrista no tiene. Moraleja: para pronosticar (y para recuperar choques por identificación estructural) **la representación invertible es la que corresponde**; si la economía “verdadera” tiene una representación no invertible, los choques estructurales no se pueden recuperar de la historia observada de  $y$  (problema de *fundamentality* en VAR, Clase 10).