

Clase 3 · Pronóstico

El mejor predictor lineal, las innovaciones y la
evaluación de pronósticos

Contenido

1	Para qué sirven los modelos de series de tiempo	1
2	El predictor óptimo	2
2.1	El $AR(p)$ y la PACF	3
3	Las innovaciones y el pronóstico con pasado infinito	4
3.1	Pronósticos con una media móvil	6
4	Evaluar y comparar pronósticos	6
5	★ Postgrado: Durbin–Levinson y la descomposición de Wold	8
5.1	Demostración de Durbin–Levinson	8
5.2	Esbozo de la demostración de Wold	9
6	Resumen	9
7	Ejercicios	10

1. Para qué sirven los modelos de series de tiempo

Buena parte de la econometría de series de tiempo existe para **pronosticar**: la inflación del próximo trimestre, la demanda de electricidad de mañana, el valor en riesgo de un portafolio. Un

modelo ARMA tiene un uso inmediato: dado el pasado de la serie, produce un pronóstico y una medida de su incertidumbre. En esta clase respondemos tres preguntas:

1. ¿**Cuál** es el mejor pronóstico (lineal) y cómo se calcula?
2. ¿Qué **error** comete, y cómo crece con el horizonte?
3. Si tengo dos pronósticos competidores, ¿cómo decido **cuál es mejor**?

La respuesta a la primera es una **proyección**: la misma geometría de mínimos cuadrados de la Clase 3 de Econometría 1, ahora en el espacio de variables aleatorias.

2. El predictor óptimo

Sea $I_T = \{y_T, y_{T-1}, \dots\}$ la información disponible en T y queremos pronosticar y_{T+h} con un predictor $\hat{y}_{T+h|T}$ función de I_T . Con pérdida **cuadrática**, el mejor predictor es la **esperanza condicional**: $\hat{y}_{T+h|T} = \mathbb{E}[y_{T+h} | I_T]$ (el mismo resultado de la Clase 2 de Econometría 1: la CEF minimiza el error cuadrático medio). Pero calcularla exige conocer **toda la distribución** conjunta del proceso. Con solo los dos primeros momentos (lo que identifica un modelo ARMA), podemos obtener el **mejor predictor lineal**.

Definición 2.1 (Mejor predictor lineal (BLP)). El mejor predictor lineal de y_{n+1} dado $y_1, \dots, y_n$ en un proceso estacionario de media cero es $\hat{y}_{n+1} = \sum_{j=1}^n \phi_{n,j} y_{n+1-j}$, con coeficientes $\phi_n = (\phi_{n,1}, \dots, \phi_{n,n})'$ que minimizan el error cuadrático medio (ECM) $\mathbb{E}[(y_{n+1} - \sum_j a_j y_{n+1-j})^2]$ sobre $a \in \mathbb{R}^n$.

Teorema 2.1 (Ecuaciones normales del BLP). Si $\Gamma_n = [\gamma(i-j)]_{i,j=1}^n$ es invertible, el BLP tiene coeficientes y ECM

$$\phi_n = \Gamma_n^{-1} \gamma_n, \quad v_n = \gamma(0) - \gamma_n' \Gamma_n^{-1} \gamma_n, \quad \gamma_n = (\gamma(1), \dots, \gamma(n))'.$$

Además, el error $y_{n+1} - \hat{y}_{n+1}$ es **ortogonal** (no correlacionado) con $y_1, \dots, y_n$.

Demostración. El ECM es $\mathbb{E}[(y_{n+1} - a'z)^2]$ con $z = (y_n, \dots, y_1)'$, que se expande en $\gamma(0) - 2a'\gamma_n + a'\Gamma_n a$ (usando $\text{Cov}(z) = \Gamma_n$ y $\text{Cov}(z, y_{n+1}) = \gamma_n$). Es una forma cuadrática estrictamente convexa (si $\Gamma_n \succ 0$) en a , y la CPO $-2\gamma_n + 2\Gamma_n a = 0$ da $a = \Gamma_n^{-1}\gamma_n$. Sustituyendo, el ECM mínimo es $\gamma(0) - \gamma_n'\Gamma_n^{-1}\gamma_n$. La CPO es $\mathbb{E}[z(y_{n+1} - a'z)] = \gamma_n - \Gamma_n a = 0$: ortogonalidad del error y los regresores. $\square$

Es **exactamente MCO**, con Γ_n y γ_n en lugar de $X'X/n$ y $X'y/n$. La ortogonalidad del error con los datos usados es la *definición* de proyección (Clase 3 de Econometría 1), aquí en el espacio de variables aleatorias de segundo momento finito, L^2 . Para calcular ϕ_n para cada n sin invertir una matriz $n \times n$ cada vez se usa el algoritmo de **Durbin-Levinson** (sección ★), que además entrega la **PACF**:

Proposición 2.1 (Durbin-Levinson). *El último coeficiente $\phi_{n,n}$ es la autocorrelación parcial: $\alpha(n) = \phi_{n,n}$. Se calcula recursivamente con $v_0 = \gamma(0)$ y*

$$\phi_{n,n} = \frac{\gamma(n) - \sum_{j=1}^{n-1} \phi_{n-1,j}\gamma(n-j)}{v_{n-1}}, \quad \phi_{n,j} = \phi_{n-1,j} - \phi_{n,n}\phi_{n-1,n-j}, \quad v_n = v_{n-1}(1 - \phi_{n,n}^2).$$

La última fórmula es reveladora: **cada rezago adicional reduce el ECM en el factor $1 - \alpha(n)^2$** . La PACF mide cuánto mejora de predicción aporta el rezago n una vez usados los $n - 1$ anteriores.

2.1. El AR(p) y la PACF

La propiedad de la Clase 2 (la PACF de un AR(p) se corta en p) se demuestra ahora.

Proposición 2.2 (La PACF de un AR(p) se anula para $h > p$). *Si $\{y_t\}$ es un AR(p) causal, para $n \geq p$ el BLP de y_{n+1} es $\hat{y}_{n+1} = \sum_{k=1}^p \phi_k y_{n+1-k}$ con ECM σ^2 . En particular $\alpha(h) = 0$ para $h > p$ y $\alpha(p) = \phi_p$.*

Demostración. Sea $\tilde{y}_{n+1} = \sum_{k=1}^p \phi_k y_{n+1-k}$. El error es $y_{n+1} - \tilde{y}_{n+1} = \varepsilon_{n+1}$, que por causalidad es **no correlacionado** con y_s para todo $s \leq n$, o sea con el pasado entero. Cumple las condiciones de ortogonalidad del Teorema 2.1, y como la solución a las ecuaciones normales es única, es el BLP. Sus coeficientes son $(\phi_1, \dots, \phi_p, 0, \dots, 0)$, de modo que $\phi_{n,n} = 0$ para $n > p$, y $\phi_{p,p} = \phi_p$. El ECM es $\mathbb{E}[\varepsilon_{n+1}^2] = \sigma^2$. $\square$

Observa que **el pronóstico a un paso de un AR(p) ya es óptimo con p rezagos**: más historia no ayuda. Con un MA o un ARMA la historia lejana sí importa (porque los ε pasados se “recuperan” mediante invertibilidad y esa recuperación mejora con más datos).

3. Las innovaciones y el pronóstico con pasado infinito

Es más cómodo analizar el pronóstico con **todo el pasado** disponible, $H_t = \overline{\text{sp}}\{y_s : s \leq t\}$ (el cierre en L^2 del espacio de combinaciones lineales de los datos hasta t). Para T grande, la diferencia con usar solo $y_1, \dots, y_T$ es despreciable en procesos ARMA (el error decae geométricamente).

Definición 3.1 (Innovación). La **innovación** de y_t es el error de pronóstico lineal a un paso con todo el pasado: $\varepsilon_t = y_t - P_{H_{t-1}} y_t$, donde $P_{H_{t-1}}$ denota la proyección ortogonal sobre H_{t-1} . Su varianza es el **error cuadrático medio de pronóstico a un paso**, $\sigma^2 = \mathbb{E}[\varepsilon_t^2]$.

Dos propiedades inmediatas: (i) $\varepsilon_t \perp H_{t-1}$ por construcción de la proyección, y (ii) $\varepsilon_s \in H_s \subset H_{t-1}$ para $s < t$. Entonces ε_t es **no correlacionado** con ε_s para $s < t$: la sucesión de innovaciones es un ruido blanco, **con varianza constante por estacionariedad**. Ese ruido blanco es el ε_t de la descomposición de Wold de la Clase 2. Para un proceso invertible, la innovación coincide con el ε_t del modelo ARMA; para uno no invertible, no (Ejercicio 3.7).

Teorema 3.1 (Pronóstico a h pasos en un proceso causal e invertible). Sea $y_t = \sum_{j \geq 0} \psi_j \varepsilon_{t-j}$ (con $\psi_0 = 1$) un proceso causal e invertible, de modo que $\varepsilon_t \in H_t$ y $H_t = \overline{\text{span}}\{\varepsilon_s : s \leq t\}$. Entonces

$$\hat{y}_{T+h|T} = \sum_{j=h}^{\infty} \psi_j \varepsilon_{T+h-j}, \quad e_{T+h|T} = y_{T+h} - \hat{y}_{T+h|T} = \sum_{j=0}^{h-1} \psi_j \varepsilon_{T+h-j}, \quad \text{ECM}(h) = \sigma^2 \sum_{j=0}^{h-1} \psi_j^2.$$

El ECM es **creciente en h** y converge a $\gamma(0) = \sigma^2 \sum_j \psi_j^2$ (la varianza incondicional) cuando $h \rightarrow \infty$, mientras $\hat{y}_{T+h|T} \rightarrow \mu = 0$.

Demostración. Escribimos $y_{T+h} = \sum_{j=0}^{h-1} \psi_j \varepsilon_{T+h-j} + \sum_{j \geq h} \psi_j \varepsilon_{T+h-j}$. El segundo sumando pertenece a H_T (involucra solo ε_s con $s \leq T$). El primero es una combinación de $\varepsilon_{T+1}, \dots, \varepsilon_{T+h}$, que son no correlacionados con H_T (cada ε_s con $s > T$ es ortogonal a $H_{s-1} \supset H_T$). Por la caracterización de la proyección por ortogonalidad, el segundo sumando es $P_{H_T} y_{T+h}$ y el primero es el error. Su varianza es $\sigma^2 \sum_{j < h} \psi_j^2$ por la ortogonalidad entre los ε . El límite de $\text{ECM}(h)$ es $\gamma(0)$ por la proposición de procesos lineales de la Clase 2, y $\hat{y}_{T+h|T} \rightarrow 0$ porque su varianza $\sigma^2 \sum_{j \geq h} \psi_j^2 \rightarrow 0$. $\square$

Interpretación: el pronóstico a corto plazo aprovecha la **memoria** del proceso; a largo plazo, el pasado se olvida, el pronóstico **revierte a la media** y el error se vuelve tan grande como la varianza de la serie. Con un proceso **no estacionario** (raíz unitaria) esto cambia drásticamente: el ECM crece sin cota (Clase 6).

Ejemplo 3.1 (Pronóstico del AR(1)). Para $y_t = \phi y_{t-1} + \varepsilon_t$: $\psi_j = \phi^j$, de modo que $\hat{y}_{T+h|T} = \phi^h y_T$ (decae geométricamente hacia 0) y

$$\text{ECM}(h) = \sigma^2 \sum_{j=0}^{h-1} \phi^{2j} = \sigma^2 \frac{1 - \phi^{2h}}{1 - \phi^2}.$$

Con $\phi = 0,8$, $\sigma^2 = 1$ y $y_T = 2$: $\hat{y}_{T+1} = 1,6$, $\hat{y}_{T+2} = 1,28$, $\hat{y}_{T+3} = 1,024$, con ECM 1, 1,64 y 2,05, que tiende a $\gamma(0) = 1/0,36 = 2,78$. Bajo normalidad, el intervalo de pronóstico al 95 % a dos pasos es $1,28 \pm 1,96\sqrt{1,64} = 1,28 \pm 2,51$.

En la práctica los parámetros se **estiman**, y se usa el *pronóstico plug-in* $\hat{y}_{T+h|T}(\hat{\theta})$. El error de estimación agrega un término de orden $1/T$ al ECM (que desaparece asintóticamente), pero en muestras pequeñas los intervalos que ignoran esto resultan demasiado angostos.

3.1. Pronósticos con una media móvil

Ejemplo 3.2 (Pronóstico del MA(2)). Para $y_t = \varepsilon_t + 0,6\varepsilon_{t-1} + 0,3\varepsilon_{t-2}$: $\hat{y}_{T+1|T} = 0,6\varepsilon_T + 0,3\varepsilon_{T-1}$, $\hat{y}_{T+2|T} = 0,3\varepsilon_T$ y $\hat{y}_{T+h|T} = 0$ para $h \geq 3$ (el pasado deja de importar tras $q = 2$ pasos). ECM: $\sigma^2, 1,36\sigma^2, 1,45\sigma^2 = \gamma(0)$ para $h \geq 3$. En la práctica los $\varepsilon_T, \varepsilon_{T-1}$ no se observan: se reconstruyen de los datos con la inversión $\varepsilon_t = \sum_j \pi_j y_{t-j}$ (invertibilidad).

4. Evaluar y comparar pronósticos

Un modelo con buen ajuste dentro de la muestra puede pronosticar mal fuera de ella (sobreajuste). La evaluación honesta usa **pronósticos fuera de muestra**: se estima con datos hasta τ , se pronostica $y_{\tau+h}$, se avanza τ (ventana creciente o rodante) y se acumulan los errores $e_{\tau+h|\tau}$ para $\tau = R, \dots, T - h$, con $P = T - h - R + 1$ pronósticos.

Con dos pronósticos competidores y errores $e_t^{(1)}, e_t^{(2)}$, y una función de pérdida L (cuadrática, absoluta, asimétrica), el **diferencial de pérdida** es $d_t = L(e_t^{(1)}) - L(e_t^{(2)})$. La hipótesis de **igual precisión predictiva** es $H_0 : \mathbb{E}[d_t] = 0$.

Proposición 4.1 (Test de Diebold–Mariano). Si $\{d_t\}$ es estacionario y ergódico con varianza de largo plazo $\sigma_d^2 > 0$, bajo H_0 ,

$$DM = \frac{\bar{d}}{\sqrt{\hat{\sigma}_d^2/P}} \xrightarrow{d} N(0, 1), \quad \bar{d} = \frac{1}{P} \sum_t d_t,$$

con $\hat{\sigma}_d^2$ un estimador consistente de la **varianza de largo plazo** de d_t (por ejemplo, Newey–West, Clase 5).

La demostración es el TCL para procesos dependientes (Clase 5): $\sqrt{P}\bar{d} \rightarrow N(0, \sigma_d^2)$ donde $\sigma_d^2 = \sum_h \gamma_d(h)$ es la varianza de largo plazo de la Clase 1, y Slutsky hace el resto. El punto esencial es **por qué hay que usar la varianza de largo plazo y no la simple**: los errores de pronóstico a h pasos son un **MA**($h - 1$) (por el Teorema 3.1), de modo que d_t tiene autocorrelación hasta el rezago $h - 1$. Para $h = 1$ puede ser razonable ignorarla; para $h > 1$ **ignorarla subestima la varianza y sobrerrechaza**.

Ejemplo 4.1 (Una aplicación numérica). Se comparan dos modelos con $P = 100$ pronósticos a un paso, pérdida cuadrática. $\bar{d} = 0,05$ (el modelo 2 es algo mejor) y $\hat{\sigma}_d = 0,40$. Entonces $DM = 0,05/(0,40/\sqrt{100}) = 1,25 < 1,96$: **no se rechaza** igual precisión. Hay que notar que $\bar{d} > 0$ no es evidencia de mejor pronóstico: con diferencias de ese tamaño y esa variabilidad, la diferencia es compatible con el azar.

Dos advertencias. (i) La teoría del test supone que los **modelos no están anidados** y que los parámetros se estiman en una ventana de tamaño fijo (rodante); con modelos anidados y ventana creciente, el DM ingenuo tiene distribución no estándar y es conservador (se usa el test de Clark–West). (ii) La elección de la **función de pérdida** importa: un pronosticador puede ser mejor en ECM y peor en error absoluto.

Una verificación relacionada es el test de **eficiencia** de Mincer–Zarnowitz: regresar el valor realizado sobre el pronóstico, $y_{t+h} = a + b \hat{y}_{t+h|t} + u_t$, y testear $H_0 : a = 0, b = 1$ (un pronóstico óptimo no deja predictibilidad en el error), con errores estándar HAC por la misma razón.

Pronosticar el nivel, pronosticar la varianza

El mejor predictor **lineal** puede ser pobre cuando la dinámica relevante no es lineal. En un proceso con volatilidad cambiante (GARCH, Clase 12), y_t puede ser **no correlacionado** con su pasado (el pronóstico lineal del nivel es 0) y, sin embargo, su **varianza condicional** es muy predecible. El BLP no ve eso: solo usa los dos primeros momentos incondicionales. Para pronósticos de **densidad** o de riesgo hay que modelar la distribución condicional completa.

5. ★ Postgrado: Durbin–Levinson y la descomposición de Wold

! ★ Postgrado

Demostramos la recursión de Durbin–Levinson (Proposición 2.1) y esbozamos la demostración del teorema de Wold con la geometría de proyecciones.

5.1. Demostración de Durbin–Levinson

Sea $M = \text{sp}\{y_2, \dots, y_n\}$. El espacio $\text{sp}\{y_1, \dots, y_n\}$ es la suma ortogonal de M y la recta generada por el **error de pronóstico hacia atrás** $b = y_1 - P_M y_1$. Entonces

$$P_{\text{sp}\{y_1, \dots, y_n\}} y_{n+1} = P_M y_{n+1} + a b, \quad a = \frac{\mathbb{E}[(y_{n+1} - P_M y_{n+1}) b]}{\mathbb{E}[b^2]}.$$

Por estacionariedad, el problema de proyectar y_{n+1} sobre $(y_2, \dots, y_n)$ ($n - 1$ rezagos) es idéntico al de proyectar y_n sobre $(y_1, \dots, y_{n-1})$ desplazado en un período: $P_M y_{n+1} = \sum_{j=1}^{n-1} \phi_{n-1,j} y_{n+1-j}$ con ECM v_{n-1} . Y como $\gamma(h) = \gamma(-h)$, el proceso invertido en el tiempo tiene las mismas autocovarianzas, de modo que la proyección **hacia atrás** de y_1 sobre $(y_2, \dots, y_n)$ usa los mismos coeficientes: $P_M y_1 = \sum_{j=1}^{n-1} \phi_{n-1,j} y_{1+j}$, con el mismo ECM $\mathbb{E}[b^2] = v_{n-1}$. El numerador de a es $\mathbb{E}[y_{n+1} b] = \gamma(n) - \sum_{j=1}^{n-1} \phi_{n-1,j} \gamma(n-j)$ (porque $P_M y_{n+1}$ es ortogonal a b). Luego $a = \phi_{n,n}$ es el coeficiente de la recursión. Para el resto de los coeficientes, sustituyendo b :

$$\sum_{j=1}^n \phi_{n,j} y_{n+1-j} = \sum_{j=1}^{n-1} \phi_{n-1,j} y_{n+1-j} + \phi_{n,n} \left(y_1 - \sum_{j=1}^{n-1} \phi_{n-1,j} y_{1+j} \right),$$

y comparando coeficientes de y_{n+1-j} (el término y_{1+k} es $y_{n+1-(n-k)}$): $\phi_{n,j} = \phi_{n-1,j} - \phi_{n,n} \phi_{n-1,n-j}$. Para el ECM, $v_n = \mathbb{E}[(y_{n+1} - P_M y_{n+1})^2] - a^2 \mathbb{E}[b^2] = v_{n-1} - \phi_{n,n}^2 v_{n-1}$, por el teorema de Pitágoras en la suma ortogonal.

5.2. Esbozo de la demostración de Wold

Sea H_t como antes y $H_{-\infty} = \bigcap_t H_t$ (la parte “infinitamente remota” del pasado). Las innovaciones $\varepsilon_t = y_t - P_{H_{t-1}} y_t$ son un ruido blanco. Proyectando y_t sobre el sistema ortogonal $\{\varepsilon_t, \varepsilon_{t-1}, \dots, \varepsilon_{t-n+1}\}$ y sobre H_{t-n} (que es ortogonal a todos ellos),

$$y_t = \sum_{j=0}^{n-1} \psi_j \varepsilon_{t-j} + P_{H_{t-n}} y_t, \quad \psi_j = \frac{\mathbb{E}[y_t \varepsilon_{t-j}]}{\sigma^2}.$$

Los ψ_j **no dependen de t** (por estacionariedad), y por la desigualdad de Bessel $\sigma^2 \sum_{j < n} \psi_j^2 \leq \gamma(0)$ para todo n , así que $\sum_j \psi_j^2 < \infty$. Por lo tanto $\sum_j \psi_j \varepsilon_{t-j}$ converge en L^2 , y el resto $P_{H_{t-n}} y_t$ converge a $P_{H_{-\infty}} y_t =: V_t$, que es el **componente determinístico**: perfectamente predecible desde el pasado remoto. Entonces $y_t = \sum_j \psi_j \varepsilon_{t-j} + V_t$ con $V_t \perp \varepsilon_s$ para todo s . Si $H_{-\infty} = \{0\}$ (proceso **puramente no determinístico**), $V_t = 0$ y queda la representación de Wold. La parte que requiere cuidado técnico (que $\psi_0 = 1$ y que el sistema de ε_t no se degenera) usa $\sigma^2 > 0$ y se omite aquí.

6. Resumen

- El mejor predictor **lineal** de y_{n+1} sobre los datos resuelve las **ecuaciones normales** $\Gamma_n \phi_n = \gamma_n$ (Teorema 2.1): es una proyección en L^2 , el MCO del mundo de procesos.
- **Durbin-Levinson** (Proposición 2.1) lo calcula recursivamente; $\phi_{n,n} = \alpha(n)$ es la PACF y $v_n = v_{n-1}(1 - \alpha(n)^2)$. La PACF de un $AR(p)$ se corta en p (Proposición 2.2).
- La **innovación** es el error de pronóstico a un paso con todo el pasado: es un ruido blanco y es la innovación de Wold.
- En un proceso causal e invertible, el error a h pasos es $\sum_{j < h} \psi_j \varepsilon_{T+h-j}$, un **MA($h-1$)**, con ECM $\sigma^2 \sum_{j < h} \psi_j^2$ creciente hasta $\gamma(0)$ (Teorema 3.1). Los pronósticos **revierten a la media**.
- **Diebold-Mariano** (Proposición 4.1) compara pronósticos usando la **varianza de largo plazo** del diferencial de pérdida.

7. Ejercicios

Ejercicio 3.1. Para un AR(1) con $\gamma(h) = \phi^h \gamma(0)$, resuelve las ecuaciones normales con $n = 2$ y comprueba que el BLP de y_3 sobre (y_2, y_1) es ϕy_2 , con ECM $\sigma^2 = \gamma(0)(1 - \phi^2)$.

Solución 3.1

$$\Gamma_2 = \gamma(0) \begin{pmatrix} 1 & \phi \\ \phi & 1 \end{pmatrix}, \gamma_2 = \gamma(0)(\phi, \phi^2)'. \phi_2 = \Gamma_2^{-1} \gamma_2 = \frac{1}{1 - \phi^2} \begin{pmatrix} 1 & -\phi \\ -\phi & 1 \end{pmatrix} \begin{pmatrix} \phi \\ \phi^2 \end{pmatrix} = \frac{1}{1 - \phi^2} \begin{pmatrix} \phi - \phi^3 \\ -\phi^2 + \phi^2 \end{pmatrix} = \begin{pmatrix} \phi \\ 0 \end{pmatrix}.$$

El BLP es ϕy_2 (el segundo rezago tiene coeficiente cero: $\alpha(2) = 0$). ECM: $v_2 = \gamma(0) - \gamma_2' \phi_2 = \gamma(0)(1 - \phi \cdot \phi) = \gamma(0)(1 - \phi^2) = \sigma^2$ (pues $\gamma(0) = \sigma^2/(1 - \phi^2)$).

Ejercicio 3.2. Con un MA(1) con $\theta = 0,5$ y $\sigma^2 = 1$ ($\gamma(0) = 1,25$, $\gamma(1) = 0,5$, $\gamma(h) = 0$ si $h \geq 2$), usa Durbin-Levinson para calcular $\phi_{1,1}$, v_1 , $\phi_{2,2}$ y v_2 . Compara con el ECM con pasado infinito.

Solución 3.2

$v_0 = 1,25$. $\phi_{1,1} = \gamma(1)/v_0 = 0,4$ y $v_1 = 1,25(1 - 0,16) = 1,05$. $\phi_{2,2} = [\gamma(2) - \phi_{1,1}\gamma(1)]/v_1 = (0 - 0,2)/1,05 = -0,1905$ y $v_2 = 1,05(1 - 0,0363) = 1,0119$. Con pasado infinito el ECM es $\sigma^2 = 1$ (la innovación). Con $n = 1$ el ECM es 5 % mayor, con $n = 2$ solo 1,2 % mayor: converge a σ^2 geométricamente (a tasa θ^2). La PACF del MA(1) **no** se corta: $\alpha(1) = 0,4$, $\alpha(2) = -0,19$, y así sigue alternando y decayendo.

Ejercicio 3.3. Para el AR(1) con $\phi = 0,8$, $\sigma^2 = 1$ y $y_T = 2$, calcula el pronóstico a $h = 4$ pasos, su ECM y el intervalo de pronóstico al 95 %. Compara el ECM con la varianza incondicional.

Solución 3.3

$\hat{y}_{T+4} = 0,8^4 \cdot 2 = 0,4096 \cdot 2 = 0,819$. ECM(4) = $(1 - 0,8^8)/0,36 = (1 - 0,168)/0,36 = 2,311$. Intervalo: $0,819 \pm 1,96\sqrt{2,311} = 0,819 \pm 2,98$. La varianza incondicional es

2,78: ya a $h = 4$ el ECM es el 83 % del máximo posible, y el pronóstico puntual casi es la media. El dato $y_T = 2$ ya aporta poca información a cuatro pasos con $\phi = 0,8$.

Ejercicio 3.4. Para el ARMA(1,1) con $\phi = 0,5$ y $\theta = 0,4$ (Clase 2, ejercicio 2.2), calcula el ECM para $h = 1, 2, 3$ y el límite.

 Solución 3.4

$\psi_0 = 1, \psi_1 = 0,9, \psi_2 = 0,45$. ECM(1) = σ^2 , ECM(2) = $\sigma^2(1 + 0,81) = 1,81\sigma^2$, ECM(3) = $\sigma^2(1 + 0,81 + 0,2025) = 2,0125\sigma^2$. Límite: $\gamma(0) = 2,08\sigma^2$. Cerca del límite ya a $h = 3$.

Ejercicio 3.5. Verifica los pronósticos y ECM del Ejemplo 3.2 (MA(2)) y calcula $\gamma(0)$ directamente.

 Solución 3.5

$y_{T+1} = \varepsilon_{T+1} + 0,6\varepsilon_T + 0,3\varepsilon_{T-1}$: el único término impredecible es ε_{T+1} , así que el ECM es σ^2 . $y_{T+2} = \varepsilon_{T+2} + 0,6\varepsilon_{T+1} + 0,3\varepsilon_T$: impredecibles los dos primeros, ECM $(1 + 0,36)\sigma^2 = 1,36\sigma^2$. Para $h \geq 3$, los tres términos son futuros: ECM = $(1 + 0,36 + 0,09)\sigma^2 = 1,45\sigma^2$ y el pronóstico es la media 0. Directamente, $\gamma(0) = \sigma^2(1 + 0,6^2 + 0,3^2) = 1,45\sigma^2$. Coincide: cuando el horizonte excede q , el pronóstico no puede mejorar a la media incondicional.

Ejercicio 3.6. Con $P = 120$ pronósticos a $h = 3$ pasos, $\bar{d} = -0,03$ y $\hat{\sigma}_d = 0,25$ (varianza de largo plazo estimada con 2 rezagos), calcula el DM. ¿Por qué usar 2 rezagos? ¿Qué pasaría si se usara la varianza simple $\hat{\gamma}_d(0) = 0,04$?

 Solución 3.6

$DM = -0,03/(0,25/\sqrt{120}) = -0,03/0,0228 = -1,31$: no se rechaza. Se usan $h - 1 = 2$ rezagos porque los errores de pronóstico a 3 pasos son un MA(2) y por tanto d_t tiene autocorrelaciones hasta el rezago 2 (Newey-West con ventana $\geq h - 1$). Con la varianza simple $\sqrt{0,04} = 0,2$

en lugar de 0,25 (menor si hay autocorrelación positiva), $DM = -0,03/(0,2/\sqrt{120}) = -1,64$: más cerca del rechazo. Aunque aquí no cruzaría 1,96, **el sesgo de ignorar la dependencia es hacia el sobrerrechazo**.

Ejercicio 3.7 ★. Sea $y_t = \varepsilon_t + 2\varepsilon_{t-1}$ con $\varepsilon_t \sim WN(0, 1)$ (MA(1) **no invertible**). Encuentra la innovación de Wold y calcula el ECM de pronóstico a un paso con todo el pasado. ¿Es 1?

 Solución 3.7 ★

La representación invertible equivalente es $y_t = \varepsilon_t^* + \frac{1}{2}\varepsilon_{t-1}^*$ con $\sigma^{*2} = \theta^2\sigma^2 = 4$ (Clase 2). Como es invertible, $\varepsilon_t^* \in H_t$ y es el error de pronóstico lineal con todo el pasado: **la innovación de Wold es ε_t^*** , con varianza 4. El ECM a un paso óptimo es 4, **no 1**. El ε_t original (varianza 1) no es una función lineal de los y pasados y presentes (no pertenece a H_t): sería un “oráculo” que usa información que el economista no tiene. Moraleja: para pronosticar (y para recuperar choques por identificación estructural) **la representación invertible es la que corresponde**; si la economía “verdadera” tiene una representación no invertible, los choques estructurales no se pueden recuperar de la historia observada de y (problema de *fundamentality* en VAR, Clase 10).