

Clase 4 · Estimación e inferencia en modelos ARMA

MCO, Yule–Walker, máxima verosimilitud gaussiana, selección de orden y diagnóstico

Contenido

1	De la teoría a los datos	1
2	Autorregresivos: MCO	2
2.1	El sesgo de muestras finitas	4
2.2	El estimador de Yule–Walker	4
3	Máxima verosimilitud gaussiana	5
3.1	Cuasi-máxima verosimilitud	6
3.2	Distribución asintótica	6
4	Selección del orden	7
5	Diagnóstico	8
6	★ Postgrado: la información de Fisher del ARMA	9
7	Resumen	10
8	Ejercicios	11

1. De la teoría a los datos

La Clase 2 describió la familia ARMA y la Clase 3 mostró cómo pronosticar **si se conocen los parámetros**. En la práctica no se

conocen. Dada una serie $y_1, \dots, y_T$ hay que: (1) **elegir** el orden (p, q) , (2) **estimar** $\beta = (\phi_1, \dots, \phi_p, \theta_1, \dots, \theta_q)$ y σ^2 , y (3) **diagnosticar** si el modelo describe bien los datos. Es el ciclo de Box y Jenkins. Hoy lo recorreremos con la maquinaria de Econometría 1 y 2: MCO y su teoría asintótica, y máxima verosimilitud (como M-estimador, Clases 1 y 2 de Econometría 2), con la novedad de que los datos son **dependientes**.

Supondremos que la serie viene de un $\text{ARMA}(p, q)$ **causal e invertible** con innovaciones ε_t i.i.d. $(0, \sigma^2)$, salvo que se diga lo contrario, y que ya se restó la media (o se incluye una constante).

2. Autorregresivos: MCO

El $\text{AR}(p)$ tiene una ventaja decisiva: es un **modelo de regresión**. Con $x_t = (y_{t-1}, \dots, y_{t-p})'$,

$$y_t = x_t' \phi + \varepsilon_t, \quad \hat{\phi} = \left(\sum_{t=p+1}^T x_t x_t' \right)^{-1} \sum_{t=p+1}^T x_t y_t.$$

Es MCO usando las observaciones $t = p + 1, \dots, T$ (la **verosimilitud condicional** en los primeros p valores, como veremos). Pero hay un problema que ya conocemos: los regresores son **rezagos** de la variable dependiente, de modo que el supuesto de exogeneidad estricta RL3 de Econometría 1 **falla** (Clase 4 de Econometría 1). Eso no destruye la consistencia, que solo necesita ortogonalidad contemporánea, y lo que se pierde es el **insesgamiento**.

Teorema 2.1 (MCO en el $\text{AR}(p)$). *Sea $y_t = x_t' \phi + \varepsilon_t$ un $\text{AR}(p)$ causal con innovaciones que forman una **diferencia de martingala**: $\mathbb{E}[\varepsilon_t | \mathcal{F}_{t-1}] = 0$ y $\mathbb{E}[\varepsilon_t^2 | \mathcal{F}_{t-1}] = \sigma^2$, con $\mathcal{F}_{t-1} = \sigma(y_{t-1}, y_{t-2}, \dots)$ (por ejemplo, ε_t i.i.d.). Entonces $\hat{\phi} \xrightarrow{p} \phi$ y*

$$\sqrt{T}(\hat{\phi} - \phi) \xrightarrow{d} N(0, \sigma^2 \Gamma_p^{-1}), \quad \Gamma_p = \mathbb{E}[x_t x_t'] = [\gamma(i-j)]_{i,j=1}^p.$$

*El estimador de varianza usual de MCO, $\hat{\sigma}^2 (\sum x_t x_t')^{-1}$, es consistente: **la inferencia de MCO es válida asintóticamente**.*

Borrador

Es el mismo argumento de la Clase 7 de Econometría 1, con x_t en lugar de x_i : $\hat{\phi} - \phi = (\frac{1}{T} \sum x_t x_t')^{-1} \frac{1}{T} \sum x_t \varepsilon_t$. La primera parte converge a Γ_p^{-1} por la **ley de los grandes números ergódica** (Clase 1: $x_t x_t'$ es una función estacionaria ergódica de la serie). La segunda es un promedio de $x_t \varepsilon_t$, que son i.i.d. en el caso clásico pero aquí **no son independientes** (hay solapamiento de rezagos). Lo que sí tienen es que **no están correlacionados entre sí**: x_t y ε_t pertenecen a $\mathcal{F}_{t-1}$ y $\mathcal{F}_t$ respectivamente, de modo que $x_t \varepsilon_t$ es una **diferencia de martingala**, para la cual hay un TCL (Clase 5).

Demostración. Por la causalidad, $y_t = \sum_j \psi_j \varepsilon_{t-j}$ y $\{x_t\}$ es estacionario y ergódico (función de $\{\varepsilon_s\}$ i.i.d.).

Consistencia. $\frac{1}{T} \sum x_t x_t' \rightarrow_p \Gamma_p$ por el teorema ergódico de la Clase 1, con $\Gamma_p > 0$ (el proceso no es determinístico; Clase 3). Además $\mathbb{E}[x_t \varepsilon_t] = 0$ (pues $x_t \in \mathcal{F}_{t-1}$ y $\mathbb{E}[\varepsilon_t | \mathcal{F}_{t-1}] = 0$), y $\frac{1}{T} \sum x_t \varepsilon_t \rightarrow_p 0$ por el mismo teorema. Luego $\hat{\phi} - \phi \rightarrow_p \Gamma_p^{-1} \cdot 0 = 0$.

Normalidad. La sucesión $\xi_t = x_t \varepsilon_t$ es una diferencia de martingala ($\mathbb{E}[\xi_t | \mathcal{F}_{t-1}] = x_t \cdot 0 = 0$), con $\mathbb{E}[\xi_t \xi_t' | \mathcal{F}_{t-1}] = x_t x_t' \sigma^2$, cuyo promedio converge a $\sigma^2 \Gamma_p$. El TCL para diferencias de martingala (que se enuncia en la Clase 5) da $T^{-1/2} \sum \xi_t \rightarrow_d N(0, \sigma^2 \Gamma_p)$, y por Slutsky $\sqrt{T}(\hat{\phi} - \phi) \rightarrow_d \Gamma_p^{-1} N(0, \sigma^2 \Gamma_p) = N(0, \sigma^2 \Gamma_p^{-1})$. Para el estimador de varianza, $\hat{\sigma}^2 \rightarrow_p \sigma^2$ y $\frac{1}{T} \sum x_t x_t' \rightarrow_p \Gamma_p$. $\square$

Para el **AR(1)**, $\Gamma_1 = \gamma(0) = \sigma^2 / (1 - \phi^2)$, de modo que

$$\sqrt{T}(\hat{\phi} - \phi) \xrightarrow{d} N(0, 1 - \phi^2). \quad (1)$$

La varianza **no depende de σ^2** y es **menor cuanto más persistente** es la serie: con $\phi = 0,9$, $1 - \phi^2 = 0,19$. (Es la contraparte de $\text{Var}(\hat{\beta}) = \sigma^2 / \sum x^2$: una serie persistente tiene mucha variación en el regresor y_{t-1} .) En la Clase 6 veremos que **cuando $\phi \rightarrow 1$ esta fórmula falla** y la distribución límite cambia por completo.

2.1. El sesgo de muestras finitas

Aunque consistente, $\hat{\phi}$ está **sesgado** en muestras finitas. Para el AR(1) con constante, la aproximación de Kendall (1954) es (Hurwicz, 1950, obtuvo el caso sin constante, $-2\phi/T$)

$$\mathbb{E}[\hat{\phi}] - \phi \approx -\frac{1 + 3\phi}{T}.$$

Con $\phi = 0,9$ y $T = 50$: $-3,7/50 = -0,074$, el estimador subestima la persistencia en 0,074 en promedio. Este es el sesgo de la nota a pie de la Clase 4 de Econometría 1. Es un sesgo hacia abajo (menos persistencia) que importa mucho cuando se usa $\hat{\phi}$ para calcular **cuánto tarda un shock en disiparse**: la vida media $\log(0,5)/\log \phi$ es muy sensible a ϕ cerca de uno.

2.2. El estimador de Yule-Walker

Las ecuaciones de Yule-Walker (Clase 2) relacionan los parámetros del AR(p) con las autocovarianzas: $\Gamma_p \phi = \gamma_p$ y $\sigma^2 = \gamma(0) - \phi' \gamma_p$. El **estimador de Yule-Walker** las resuelve con las autocovarianzas **muestrales**:

$$\hat{\phi}_{YW} = \hat{\Gamma}_p^{-1} \hat{\gamma}_p, \quad \hat{\sigma}_{YW}^2 = \hat{\gamma}(0) - \hat{\phi}_{YW}' \hat{\gamma}_p.$$

Es un **estimador de momentos** (el método de los momentos de Econometría 2, Clase 4, con $r = p$). Tiene dos propiedades:

1. **Siempre produce un modelo causal** (se toma prestado): como $\hat{\Gamma}_p$ es semidefinida positiva (Clase 1, divisor T), las raíces de $\hat{\phi}_{YW}(z)$ quedan fuera del círculo unitario. MCO, en cambio, puede dar un AR no estacionario en muestras pequeñas.
2. **Es asintóticamente equivalente a MCO**: misma distribución límite. Difiere en muestras finitas: con raíces cerca del círculo unitario, YW tiene **mayor sesgo** que MCO porque “fuerza” la estacionariedad.

3. Máxima verosimilitud gaussiana

Para modelos con parte MA no hay forma de escribir una regresión: ε_{t-1} no se observa. La solución estándar es la **máxima verosimilitud gaussiana**: suponer $\varepsilon_t \sim N(0, \sigma^2)$ y maximizar la densidad conjunta de $(y_1, \dots, y_T) \sim N(0, \Gamma_T)$, donde $\Gamma_T = [\gamma(i-j)]$ depende de β y σ^2 :

$$\ell_T(\beta, \sigma^2) = -\frac{T}{2} \log(2\pi) - \frac{1}{2} \log \det \Gamma_T - \frac{1}{2} y' \Gamma_T^{-1} y.$$

Invertir y calcular el determinante de una matriz $T \times T$ para cada valor de los parámetros es costoso. Pero la descomposición en **errores de predicción** de la Clase 3 los simplifica.

Proposición 3.1 (Verosimilitud por innovaciones). Sean $e_t = y_t - \hat{y}_{t|t-1}$ los errores de predicción a un paso (con las $t-1$ observaciones previas) y $v_{t-1} = \mathbb{E}[e_t^2]$ sus varianzas (Durbin-Levinson, Clase 3). Entonces $\det \Gamma_T = \prod_{t=1}^T v_{t-1}$ y $y' \Gamma_T^{-1} y = \sum_{t=1}^T e_t^2 / v_{t-1}$, de modo que

$$\ell_T = -\frac{1}{2} \sum_{t=1}^T \left[\log(2\pi v_{t-1}) + \frac{e_t^2}{v_{t-1}} \right].$$

Demostración. El vector de errores de predicción es $e = Ay$ con A una matriz **triangular inferior con unos en la diagonal** (el error $e_t = y_t - \sum_{j < t} \phi_{t-1,j} y_{t-j}$ involucra solo y_t y sus valores pasados, con coeficiente 1 en y_t). Por la ortogonalidad del error de proyección con los datos pasados (Clase 3), los e_t son **no correlacionados**, con $\text{Var}(e) = D = \text{diag}(v_0, \dots, v_{T-1})$. Entonces $A \Gamma_T A' = D$, es decir $\Gamma_T = A^{-1} D A^{-'}$. Como $\det A = 1$, $\det \Gamma_T = \det D = \prod v_{t-1}$, y $y' \Gamma_T^{-1} y = (Ay)' D^{-1} (Ay) = e' D^{-1} e$. $\square$

Como $v_{t-1} = \sigma^2 r_{t-1}$ con r_{t-1} función de β solamente, se puede **concentrar** σ^2 : $\hat{\sigma}^2(\beta) = \frac{1}{T} \sum_t e_t^2 / r_{t-1}$ y se maximiza una verosimilitud perfilada en β . Con **innovaciones calculadas por el filtro de Kalman** (Clase 13) o por el algoritmo de innovaciones, esto se evalúa en $O(T)$.

Aproximaciones. Para valores iniciales: (i) la **verosimilitud condicional** (CLS) fija los primeros p datos (para el AR es exactamente MCO) y, para el MA, fija las innovaciones pre-muestra en cero y las calcula recursivamente, $\varepsilon_t = y_t - \sum_j \theta_j \varepsilon_{t-j}$; (ii) la **exacta** incluye todo. Con invertibilidad la diferencia desaparece geométricamente con T .

3.1. Cuasi-máxima verosimilitud

No se necesita **normalidad**: el estimador $\hat{\beta}$ que maximiza la verosimilitud *gaussiana* es consistente y asintóticamente normal para β aunque las innovaciones no sean gaussianas, siempre que sean i.i.d. con varianza finita (es un caso de cuasi-MV, Clase 2 de Econometría 2: la verosimilitud gaussiana depende de los datos solo a través de los dos primeros momentos, que son los que identifican a β). Eso explica por qué se usa en toda situación.

3.2. Distribución asintótica

La información de Fisher del ARMA gaussiano se calcula con dos procesos auxiliares (sección ★). Los casos básicos son:

Teorema 3.1 (Normalidad del MV gaussiano). *Para un ARMA(p, q) causal e invertible con innovaciones i.i.d., $\sqrt{T}(\hat{\beta} - \beta) \rightarrow_d N(0, V(\beta))$. En particular:*

- **AR(1)**: $V = 1 - \phi^2$.
- **MA(1)**: $V = 1 - \theta^2$.
- **ARMA(1,1)**: $V_{\phi\phi} = \frac{(1 - \phi^2)(1 + \phi\theta)^2}{(\phi + \theta)^2}$, $V_{\theta\theta} = \frac{(1 - \theta^2)(1 + \phi\theta)^2}{(\phi + \theta)^2}$
 $y V_{\phi\theta} = -\frac{(1 - \phi^2)(1 - \theta^2)(1 + \phi\theta)}{(\phi + \theta)^2}$.

Tres lecciones. **(1) Dualidad**: el MA(1) con parámetro θ se estima con la misma precisión que el AR(1) con $\phi = \theta$. **(2) Cerca de la frontera** ($|\phi|$ o $|\theta| \rightarrow 1$) la varianza se achica como $1 - \phi^2$, pero la aproximación normal es mala y la distribución es no estándar en la frontera (para un MA con $\theta = -1$, converge a tasa T y no a $\sqrt{T}$). **(3) Casi cancelación de raíces** ($\phi + \theta \rightarrow 0$): la varianza del

ARMA(1,1) **explota**: el modelo se parece a un ruido blanco y ni ϕ ni θ están bien identificados (Ejercicio 4.7).

Ejemplo 3.1 (Errores estándar en un ARMA(1,1)). Con $\phi = 0,5$, $\theta = 0,4$ y $T = 200$: $(\phi + \theta)^2 = 0,81$ y $(1 + \phi\theta)^2 = 1,44$. $V_{\phi\phi} = 0,75 \cdot 1,44/0,81 = 1,333$, error estándar $\sqrt{1,333/200} = 0,082$; $V_{\theta\theta} = 0,84 \cdot 1,44/0,81 = 1,493$, error estándar 0,086. Si el modelo fuera un AR(1) puro con $\phi = 0,5$, el error estándar sería $\sqrt{0,75/200} = 0,061$: **agregar el término MA cuesta un 34 % de precisión en $\hat{\phi}$.**

4. Selección del orden

El orden (p, q) no se conoce. Agregar parámetros siempre aumenta la verosimilitud (ajuste dentro de muestra) pero empeora el pronóstico (sobreajuste). Los **criterios de información** penalizan la complejidad: con $k = p + q$ parámetros y $\hat{\ell}$ la log-verosimilitud máxima,

$$\text{AIC} = -2\hat{\ell} + 2k, \quad \text{BIC} = -2\hat{\ell} + k \log T.$$

Se elige el modelo con **menor** valor. Para un AR(p) gaussiano, $-2\hat{\ell} \approx T \log \hat{\sigma}_p^2 + \text{cte}$.

Los dos tienen propiedades distintas, que se pueden derivar con la teoría de razón de verosimilitud (Clase 3 de Econometría 2).

Proposición 4.1 (Comportamiento asintótico de AIC y BIC). *Sea $\mathcal{M}_0$ el modelo verdadero y $\mathcal{M}_1$ uno que agrega un parámetro innecesario. Entonces la probabilidad de elegir erróneamente $\mathcal{M}_1$ converge a $P(\chi_1^2 > 2) = 0,157$ con **AIC** y a 0 con **BIC**. Si en cambio $\mathcal{M}_1$ es el verdadero y $\mathcal{M}_0$ omite un parámetro relevante, ambos criterios eligen $\mathcal{M}_1$ con probabilidad que tiende a uno.*

Demostración. Con la **razón de verosimilitud** $LR = 2(\hat{\ell}_1 - \hat{\ell}_0)$, AIC elige $\mathcal{M}_1$ si $-2\hat{\ell}_1 + 2(k+1) < -2\hat{\ell}_0 + 2k$, es decir $LR > 2$; BIC la elige si $LR > \log T$. Si $\mathcal{M}_0$ es verdadero, $LR \rightarrow_d \chi_1^2$ (Clase 3 de Econometría 2), así que $P(LR > 2) \rightarrow P(\chi_1^2 > 2) = 0,157$ (AIC), y $P(LR > \log T) \rightarrow 0$ porque $\log T \rightarrow \infty$ y la distribución límite de LR es acotada en probabilidad. Si $\mathcal{M}_1$ es verdadero y

el parámetro adicional es distinto de cero, LR crece como T (la verosimilitud de un modelo mal especificado queda a distancia KL positiva, Clase 2 de Econometría 2), así que $P(LR > 2) \rightarrow 1$ y $P(LR > \log T) \rightarrow 1$ (porque $T \gg \log T$). $\square$

Moraleja: **BIC es consistente** (selecciona el orden verdadero con probabilidad uno si está en la clase de modelos candidatos) y **AIC no** (sobreajusta con probabilidad positiva, aproximadamente 16 % por parámetro extra). Pero AIC tiene ventajas para **pronóstico**: minimiza asintóticamente el error de predicción cuando el modelo verdadero es de orden infinito o no está en la clase. La regla práctica: BIC si el objetivo es identificar la estructura; AIC si el objetivo es pronosticar.

5. Diagnóstico

Un modelo ARMA bien especificado deja residuos $\hat{\varepsilon}_t$ que parecen **ruido blanco**. Tres chequeos estándar:

1. **Gráfico de los residuos y su correlograma**: la ACF muestral de $\hat{\varepsilon}_t$ debe caer dentro de la banda $\pm 1,96/\sqrt{T}$ (Clase 1).
2. **Prueba de Ljung-Box** (conjunta, sobre m rezagos):

$$Q_{LB} = T(T+2) \sum_{k=1}^m \frac{\hat{\rho}_k^2}{T-k} \underset{a}{\sim} \chi_{m-p-q}^2 \quad \text{bajo } H_0 : \text{residuos ruido blanco.}$$

3. **Sobreajuste deliberado**: agregar un rezago AR o MA y testar su significancia (si el modelo está bien, el término extra no es significativo).

Proposición 5.1 (Distribución de Ljung-Box). *Si $\{y_t\}$ es ruido blanco i.i.d., $Q_{BP} = T \sum_{k=1}^m \hat{\rho}_k^2 \rightarrow_d \chi_m^2$. Si los $\hat{\rho}_k$ provienen de los residuos de un $ARMA(p,q)$ estimado, el límite es χ_{m-p-q}^2 .*

Demostración. (Esquema.) Sin estimación, la proposición sobre autocorrelaciones muestrales de un ruido blanco (Clase 1) da $\sqrt{T}\hat{\rho}_k \rightarrow_d N(0, 1)$ asintóticamente independientes, y la suma de m cuadrados de normales estándar independientes es χ_m^2 (Clase 5 de Econometría 1). Con residuos de un ARMA estimado, el

vector $(\hat{\rho}_1, \dots, \hat{\rho}_m)$ queda restringido por las $p + q$ **condiciones de primer orden** del estimador (los scores del MV son combinaciones lineales de los residuos), de modo que solo $m - p - q$ direcciones son libres, lo que reduce los grados de libertad en $p + q$ (el mismo argumento que quita k grados de libertad en $\hat{u}'\hat{u}/\sigma^2 \sim \chi^2_{n-k}$ de Econometría 1). Ljung-Box reemplaza $T\hat{\rho}_k^2$ por $T(T+2)\hat{\rho}_k^2/(T-k)$, que corrige $\text{Var}(\hat{\rho}_k) \approx (T-k)/[T(T+2)]$ bajo ruido blanco gaussiano: mejor aproximación en muestras pequeñas. $\square$

Si el diagnóstico falla, el modelo omite dependencia: se aumenta el orden o se cambia la familia (por ejemplo, incorporando heterocedasticidad condicional, Clase 12, o raíces unitarias, Clase 6). Si sus residuos son ruido blanco **pero no independientes** (los cuadrados están correlacionados), el test de Ljung-Box sobre $\hat{\varepsilon}_t$ no rechaza, y el de Ljung-Box sobre $\hat{\varepsilon}_t^2$ sí: es la señal de ARCH.

6. ★ Postgrado: la información de Fisher del ARMA

! ★ Postgrado

Calculamos la matriz de información del ARMA gaussiano y deducimos los casos del Teorema 3.1. La idea: las derivadas de las innovaciones respecto de los parámetros son **procesos autorregresivos** simples.

En un ARMA causal e invertible, $\varepsilon_t(\beta) = \theta(L)^{-1}\phi(L)y_t$. Derivando respecto de ϕ_k y θ_k (con y_t fijo):

$$\frac{\partial \varepsilon_t}{\partial \phi_k} = -\frac{1}{\theta(L)}y_{t-k} = -U_{t-k}, \quad \frac{\partial \varepsilon_t}{\partial \theta_k} = -\frac{\phi(L)}{\theta(L)^2}y_{t-k} = -V_{t-k},$$

donde, evaluando en el verdadero β (donde $y = \theta\phi^{-1}\varepsilon$), $U_t = \varepsilon_t/\phi(L)$ y $V_t = \varepsilon_t/\theta(L)$ son procesos AR: $\phi(L)U_t = \varepsilon_t$ y $\theta(L)V_t = \varepsilon_t$. La log-verosimilitud gaussiana (para T grande) es $-\frac{1}{2}\sum \varepsilon_t(\beta)^2/\sigma^2 + \text{cte}$, de modo que el score es

$-\sigma^{-2} \sum_t \varepsilon_t \partial \varepsilon_t / \partial \beta = \sigma^{-2} \sum_t \varepsilon_t w_t$ (con w_t definido abajo) y la información por observación es

$$J(\beta) = \frac{1}{\sigma^2} \mathbb{E}[w_t w_t'], \quad w_t = (U_{t-1}, \dots, U_{t-p}, V_{t-1}, \dots, V_{t-q})'.$$

(El score es una diferencia de martingala porque ε_t es independiente del pasado, y la información es la varianza del score; la parte de σ^2 es asintóticamente ortogonal a β .) Entonces $V(\beta) = \sigma^2 (\mathbb{E}[w_t w_t'])^{-1}$, que es **la misma fórmula del AR(p)** del Teorema 2.1 con regresores w_t en lugar de x_t .

Casos. AR(1): $w_t = U_{t-1} = y_{t-1}$, $\mathbb{E}[w^2] = \sigma^2/(1 - \phi^2)$, y $V = 1 - \phi^2$. **MA(1):** $w_t = V_{t-1} = \sum_j (-\theta)^j \varepsilon_{t-1-j}$, $\mathbb{E}[w^2] = \sigma^2/(1 - \theta^2)$, $V = 1 - \theta^2$. **ARMA(1,1):** $w_t = (U_{t-1}, V_{t-1})$ con $\mathbb{E}[U^2] = \sigma^2/(1 - \phi^2)$, $\mathbb{E}[V^2] = \sigma^2/(1 - \theta^2)$ y $\mathbb{E}[UV] = \sigma^2 \sum_j \phi^j (-\theta)^j = \sigma^2/(1 + \phi\theta)$. La matriz $\mathbb{E}[w w']/\sigma^2$ es

$$\begin{pmatrix} \frac{1}{1-\phi^2} & \frac{1}{1+\phi\theta} \\ \frac{1}{1+\phi\theta} & \frac{1}{1-\theta^2} \end{pmatrix}$$

tiene determinante $\frac{1}{(1-\phi^2)(1-\theta^2)} - \frac{1}{(1+\phi\theta)^2} = \frac{(1+\phi\theta)^2 - (1-\phi^2)(1-\theta^2)}{(1-\phi^2)(1-\theta^2)(1+\phi\theta)^2} = \frac{1+2\phi\theta+\phi^2\theta^2-1+\phi^2+\theta^2-\phi^2\theta^2}{(1-\phi^2)(1-\theta^2)(1+\phi\theta)^2} = \frac{(\phi+\theta)^2}{(1-\phi^2)(1-\theta^2)(1+\phi\theta)^2}$ (el numerador se simplifica: $1+2\phi\theta+\phi^2\theta^2-1+\phi^2+\theta^2-\phi^2\theta^2 = (\phi+\theta)^2$). Invertiendo la matriz 2×2 se obtienen las expresiones del Teorema 3.1. El determinante $(\phi+\theta)^2 \rightarrow 0$ cuando $\phi+\theta \rightarrow 0$: la información se **degenera** y la varianza explota, que es la manifestación de la cancelación de raíces de la Clase 2.

7. Resumen

- Un $\text{AR}(p)$ se estima por **MCO**: consistente y asintóticamente normal, $\sqrt{T}(\hat{\phi} - \phi) \rightarrow N(0, \sigma^2 \Gamma_p^{-1})$ (Teorema 2.1); para el $\text{AR}(1)$, $V = 1 - \phi^2$. Está sesgado en muestras finitas ($\approx -(1 + 3\phi)/T$).
- **Yule-Walker** es el estimador de momentos: siempre causal, asintóticamente equivalente a MCO.

- El **MV gaussiano** usa la descomposición por innovaciones (Proposición 3.1), sirve para cualquier ARMA y es una cuasi-MV consistente sin normalidad. Su distribución asintótica se obtiene de procesos autorregresivos auxiliares (Teorema 3.1); explota cuando $\phi + \theta \rightarrow 0$.
- **BIC** es consistente; **AIC** sobreajusta con probabilidad $\approx 0,157$ por parámetro extra pero es mejor para pronóstico (Proposición 4.1).
- **Diagnóstico**: residuos ruido blanco; **Ljung-Box** con $m - p - q$ grados de libertad (Proposición 5.1).

8. Ejercicios

Ejercicio 4.1. Se estima un AR(1) por MCO con $T = 100$ y $\hat{\phi} = 0,6$. Calcula el error estándar asintótico, un intervalo de confianza del 95 % y el sesgo aproximado de Kendall.

Solución 4.1

$\sqrt{(1 - \hat{\phi}^2)/T} = \sqrt{0,64/100} = 0,08$. IC 95 %: $0,6 \pm 1,96(0,08) = (0,443; 0,757)$. Sesgo: $-(1 + 3 \cdot 0,6)/100 = -0,028$: el valor “verdadero” probablemente está cerca de 0,63. El sesgo (0,028) es un tercio del error estándar, no determinante aquí, pero con $T = 25$ el sesgo sería $-0,112$, mayor que un error estándar ($\sqrt{0,64/25} = 0,16$).

Ejercicio 4.2. Verifica la Proposición 3.1 para un MA(1) con $\theta = 0,5$, $\sigma^2 = 1$ y $T = 2$: calcula $\det \Gamma_2$ y compáralo con $v_0 v_1$ (de la Clase 3, ejercicio 3.2).

Solución 4.2

$\Gamma_2 = \begin{pmatrix} 1,25 & 0,5 \\ 0,5 & 1,25 \end{pmatrix}$, $\det \Gamma_2 = 1,5625 - 0,25 = 1,3125$. Por otro lado $v_0 = 1,25$ y $v_1 = 1,05$, y $v_0 v_1 = 1,3125$. Coinciden. También $y' \Gamma_2^{-1} y = e_1^2/v_0 + e_2^2/v_1$ con $e_1 = y_1$ y $e_2 = y_2 - 0,4y_1$ (el BLP con $\phi_{1,1} = 0,4$). La verosimilitud exacta de una serie larga se evalúa con la misma lógica en

$O(T)$ operaciones.

Ejercicio 4.3. (a) Con AIC, ¿cuál es la probabilidad (asintótica) de elegir un $AR(p+2)$ cuando el verdadero es $AR(p)$ y se comparan solo estos dos? (b) Con BIC y $T = 100$, ¿cuál es la probabilidad de elegir un parámetro de más? ¿Y con $T = 1000$?

 Solución 4.3

- (a) El $AR(p+2)$ tiene dos parámetros extra: AIC lo elige si $LR > 4$, y $LR \rightarrow \chi^2_2$, con $P(\chi^2_2 > 4) = e^{-2} = 0,135$.
(b) Para un parámetro extra, BIC lo elige si $LR > \log T$: con $T = 100$, $\log T = 4,605$ y $P(\chi^2_1 > 4,605) = 0,032$. Con $T = 1000$, $\log T = 6,908$ y $P(\chi^2_1 > 6,908) = 0,0086$. La probabilidad de sobreajustar baja a cero con T (consistencia), pero con muestras de 100 observaciones, BIC aún se equivoca 3 % de las veces.

Ejercicio 4.4. Un $MA(1)$ estimado da $\hat{\theta} = 0,9$ con $T = 100$. Calcula el error estándar asintótico y comenta por qué no es confiable.

 Solución 4.4

$V = 1 - \theta^2 = 0,19$, error estándar $\sqrt{0,19/100} = 0,0436$. Un IC 95 % sería $0,9 \pm 0,085 = (0,81; 0,99)$. Es sospechosamente angosto: con θ cerca de la frontera de invertibilidad ($\theta = 1$), la aproximación normal es mala (la verdadera distribución de $\hat{\theta}$ es asimétrica y se acumula contra el borde, y puede incluso dar $\hat{\theta} = 1$ con probabilidad positiva). Además, un $MA(1)$ con $\theta \approx 1$ suele indicar **sobrediferenciación** de una serie que ya era estacionaria (Clase 7).

Ejercicio 4.5. Con $T = 100$, los residuos de un $AR(1)$ ajustado tienen autocorrelaciones $\hat{\rho}_1, \dots, \hat{\rho}_5 = 0,12; -0,05; 0,08; 0,02; -0,10$. Calcula Box-Pierce y Ljung-Box y concluye al 5 % (crítico $\chi^2_4 = 9,49$).

💡 Solución 4.5

$\sum \hat{\rho}_k^2 = 0,0144 + 0,0025 + 0,0064 + 0,0004 + 0,0100 = 0,0337$. Box-Pierce: $Q_{BP} = 100(0,0337) = 3,37$. Ljung-Box: $\sum \hat{\rho}_k^2 / (T - k) = 0,000145 + 0,000026 + 0,000066 + 0,000004 + 0,000105 = 0,000346$, y $Q_{LB} = 100 \cdot 102 \cdot 0,000346 = 3,53$. Grados de libertad: $m - p - q = 5 - 1 - 0 = 4$. Como $3,53 < 9,49$: **no se rechaza** que los residuos sean ruido blanco; el AR(1) es adecuado. Ljung-Box es algo mayor que Box-Pierce, como siempre.

Ejercicio 4.6. Una serie tiene $\hat{\gamma}(0) = 1$, $\hat{\rho}_1 = 0,5$ y $\hat{\rho}_2 = 0,3$. Estima un AR(2) por Yule-Walker y calcula $\hat{\sigma}^2$. ¿Es el modelo estimado causal?

💡 Solución 4.6

$\begin{pmatrix} 1 & 0,5 \\ 0,5 & 1 \end{pmatrix} \hat{\phi} = \begin{pmatrix} 0,5 \\ 0,3 \end{pmatrix}$ con determinante 0,75: $\hat{\phi}_1 = (0,5 - 0,5 \cdot 0,3)/0,75 = 0,4667$ y $\hat{\phi}_2 = (0,3 - 0,5 \cdot 0,5)/0,75 = 0,0667$. $\hat{\sigma}^2 = \hat{\gamma}(0)(1 - \hat{\phi}_1\hat{\rho}_1 - \hat{\phi}_2\hat{\rho}_2) = 1 - 0,2333 - 0,0200 = 0,7467$. Causal: $\hat{\phi}_1 + \hat{\phi}_2 = 0,533 < 1$, $\hat{\phi}_2 - \hat{\phi}_1 = -0,4 < 1$ y $|\hat{\phi}_2| < 1$ (triángulo de la Clase 2). Como dice la teoría, la solución de Yule-Walker siempre es causal.

Ejercicio 4.7 ★. Para el ARMA(1,1) con $\phi = 0,5$ y $\theta = -0,4$ y $T = 200$, calcula el error estándar asintótico de $\hat{\phi}$ y compáralo con el caso $\theta = +0,4$ del Ejemplo 3.1. ¿Qué pasa y por qué?

💡 Solución 4.7 ★

$(\phi + \theta)^2 = (0,1)^2 = 0,01$ y $1 + \phi\theta = 0,8$, $(1 + \phi\theta)^2 = 0,64$. $V_{\phi\phi} = 0,75 \cdot 0,64/0,01 = 48$ y el error estándar es $\sqrt{48/200} = 0,49$ (¡igual al valor del parámetro!). Con $\theta = +0,4$ era 0,082: **seis veces menor**. La razón: con $\phi + \theta \approx 0$ el factor $(1 - \phi L)$ casi se cancela con $(1 + \theta L)$ y el proceso es casi ruido blanco; los datos apenas contienen información sobre ϕ y θ por separado (la verosimilitud es casi plana a lo largo de la recta $\theta = -\phi$, Clase 2, ejercicio 2.6). El determinante de la información tiende a cero como $(\phi + \theta)^2$. En la

práctica, si los parámetros de un ARMA(1,1) estimado tienen errores estándar enormes y $\hat{\phi} \approx -\hat{\theta}$, hay que reducir el modelo a ruido blanco.