

Clase 5 · Asintótica con dependencia y errores HAC

TCL para series dependientes, varianza de largo plazo
y el estimador de Newey–West

Contenido

1	Lo que falta: la normalidad con dependencia	2
2	Diferencias de martingala	2
3	TCL para procesos lineales: Beveridge–Nelson	4
4	Estimación de la varianza de largo plazo	5
4.1	El estimador de Newey–West	6
4.2	Consistencia, sesgo y varianza	7
4.3	Alternativas	8
5	Usos	8
5.1	MCO con errores correlacionados	8
5.2	GMM, pronósticos y otros	9
6	★ Postgrado: por qué la suma completa de autocovarianzas no sirve	10
7	Resumen	11
8	Ejercicios	11

1. Lo que falta: la normalidad con dependencia

En la Clase 1 demostramos que, con dependencia, la **ley de los grandes números** sigue valiendo (ergodicidad), pero la **varianza** de los promedios cambia: de $\gamma(0)/T$ a σ_{LR}^2/T con $\sigma_{LR}^2 = \sum_h \gamma(h)$. En la Clase 4 usamos sin demostrar un **TCL** para $T^{-1/2} \sum x_t \varepsilon_t$. Hoy completamos el cuadro:

1. **¿Cuándo hay TCL** para sumas de variables dependientes, y con qué varianza?
2. **¿Cómo se estima** esa varianza, σ_{LR}^2 ? (No se puede con $\hat{\gamma}(0)$, ni sumando todas las autocovarianzas muestrales: veremos por qué.)
3. **¿Qué se corrige** en MCO, GMM y tests de pronóstico?

La respuesta a la tercera es la misma en todas partes: cada vez que un **score** o un **momento** ξ_t está serialmente correlacionado, la varianza del promedio es $\sigma_{LR}^2(\xi)$, y el sándwich de Econometría 1 y 2 se reemplaza por su versión **HAC** (*heteroskedasticity and autocorrelation consistent*).

2. Diferencias de martingala

Muchos scores y momentos tienen una estructura más fuerte que “estacionario”: son impredecibles dado el pasado.

Definición 2.1 (Diferencia de martingala). Sea $\{\mathcal{F}_t\}$ una filtración (información acumulada hasta t). Una sucesión $\{\xi_t\}$ adaptada a $\mathcal{F}_t$ con $\mathbb{E}|\xi_t| < \infty$ es una **diferencia de martingala** (MDS) si

$$\mathbb{E}[\xi_t \mid \mathcal{F}_{t-1}] = 0 \quad \text{para todo } t.$$

Dos hechos inmediatos. (i) Una MDS con segundo momento finito es **no correlacionada**: para $s < t$, $\mathbb{E}[\xi_s \xi_t] = \mathbb{E}[\xi_s \mathbb{E}[\xi_t \mid \mathcal{F}_{t-1}]] = 0$ (porque $\xi_s \in \mathcal{F}_s \subset \mathcal{F}_{t-1}$). Es decir, es un ruido blanco, pero **más fuerte**: no solo no hay correlación lineal con el pasado; la esperanza condicional *completa* es cero. (ii) Su varianza de largo

plazo es simplemente $\sigma_{LR}^2 = \gamma(0) = \mathbb{E}[\xi_t^2]$: sin autocovarianzas que sumar.

Ejemplo 2.1 (Ejemplos).

1. ε_t i.i.d. $(0, \sigma^2)$, con $\mathcal{F}_t = \sigma(\varepsilon_s : s \leq t)$.
2. $\xi_t = x_t \varepsilon_t$ en un AR con $x_t = (y_{t-1}, \dots)$: $x_t \in \mathcal{F}_{t-1}$ y $\mathbb{E}[\varepsilon_t | \mathcal{F}_{t-1}] = 0$, de modo que $\mathbb{E}[\xi_t | \mathcal{F}_{t-1}] = 0$ (Clase 4).
3. $\varepsilon_t = \sigma_t z_t$ en un **ARCH/GARCH** (Clase 12), con $\sigma_t \in \mathcal{F}_{t-1}$ y z_t i.i.d. $(0, 1)$: $\mathbb{E}[\varepsilon_t | \mathcal{F}_{t-1}] = 0$ aunque ε_t^2 sea predecible. Es MDS, **no** i.i.d.
4. **No toda sucesión no correlacionada es MDS**: $\varepsilon_t = \eta_t + \eta_{t-1}\eta_{t-2}$ con η_t i.i.d. $N(0, 1)$ es ruido blanco (Ejercicio 5.1) pero $\mathbb{E}[\varepsilon_t | \eta_{t-1}, \eta_{t-2}, \dots] = \eta_{t-1}\eta_{t-2} \neq 0$: hay un componente **predecible no linealmente**.

Teorema 2.1 (TCL para diferencias de martingala — se toma prestado). Sea $\{\xi_t\}$ una MDS **estrictamente estacionaria y ergódica** con $\mathbb{E}[\xi_t^2] = \sigma^2 < \infty$. Entonces

$$\frac{1}{\sqrt{T}} \sum_{t=1}^T \xi_t \xrightarrow{d} N(0, \sigma^2).$$

El resultado vale en versión vectorial (por Cramér–Wold), con σ^2 reemplazada por $\mathbb{E}[\xi_t \xi_t']$.

Es el teorema de Billingsley (1961) e Ibragimov (1963). No lo demostramos: su demostración usa la función característica y la ley de los grandes números ergódica para la **varianza condicional** $\mathbb{E}[\xi_t^2 | \mathcal{F}_{t-1}]$. La idea es que, a pesar de que los ξ_t no son independientes, **cada uno aporta una “tirada” nueva de media cero dado lo anterior**, y la acumulación de esas tiradas se comporta como una suma de normales independientes cuya varianza total es la suma de las varianzas condicionales (que el teorema ergódico lleva a $T\sigma^2$). Con él, queda justificado el uso en la Clase 4 (MCO en un AR) y en la Clase 1 (autocorrelaciones del ruido blanco).

3. TCL para procesos lineales: Beveridge–Nelson

Para series que son procesos **lineales** (ARMA, y su límite $MA(\infty)$), el TCL con dependencia fuerte se puede **demostrar completo** con un truco algebraico, la descomposición de Beveridge–Nelson, que será central en la Clase 6.

Teorema 3.1 (TCL para procesos lineales). Sea $y_t = \sum_{j=0}^{\infty} \psi_j \varepsilon_{t-j}$ con ε_t i.i.d. $(0, \sigma^2)$ y $\sum_{j=0}^{\infty} j |\psi_j| < \infty$ (**1-sumabilidad**, más fuerte que la sumabilidad absoluta). Entonces

$$\frac{1}{\sqrt{T}} \sum_{t=1}^T y_t \xrightarrow{d} N(0, \sigma^2 \psi(1)^2), \quad \psi(1) = \sum_j \psi_j.$$

La varianza límite es la varianza de largo plazo σ_{LR}^2 de la Clase 2.

Borrador

Quiero reducir $\sum_t y_t$ a $\psi(1) \sum_t \varepsilon_t$, para el cual vale el TCL i.i.d. La diferencia debería ser pequeña. Si escribo $\psi(L) = \psi(1) + (L-1)\tilde{\psi}(L)$ con coeficientes $\tilde{\psi}_j$ adecuados, entonces $y_t = \psi(1)\varepsilon_t + (L-1)\tilde{\psi}(L)\varepsilon_t = \psi(1)\varepsilon_t + \eta_{t-1} - \eta_t$ con $\eta_t = \tilde{\psi}(L)\varepsilon_t$. Y sumar $\eta_{t-1} - \eta_t$ sobre t **telescopa**: queda $\eta_0 - \eta_T$, que es $O_p(1)$ y desaparece al dividir por $\sqrt{T}$. Resta ver qué $\tilde{\psi}_j$ funciona: $\tilde{\psi}_j = \sum_{k>j} \psi_k$.

Demostración. Definimos $\tilde{\psi}_j = \sum_{k=j+1}^{\infty} \psi_k$ para $j \geq 0$. Entonces $\sum_j |\tilde{\psi}_j| \leq \sum_j \sum_{k>j} |\psi_k| = \sum_k k |\psi_k| < \infty$ por la 1-sumabilidad. Verificamos la **descomposición de Beveridge–Nelson** $\psi(L) = \psi(1) + (L-1)\tilde{\psi}(L)$ comparando coeficientes: el de L^0 es $\psi(1) - \tilde{\psi}_0 = \sum_{k \geq 0} \psi_k - \sum_{k \geq 1} \psi_k = \psi_0$, y el de L^j ($j \geq 1$) es $\tilde{\psi}_{j-1} - \tilde{\psi}_j = \psi_j$. Luego

$$y_t = \psi(1)\varepsilon_t + \eta_{t-1} - \eta_t, \quad \eta_t = \sum_{j \geq 0} \tilde{\psi}_j \varepsilon_{t-j},$$

donde η_t está bien definido (la sumabilidad de $\tilde{\psi}_j$ implica la de $\tilde{\psi}_j^2$, y la proposición de procesos lineales de la Clase 2 aplica) y es estacionario con $\text{Var}(\eta_t) = \sigma^2 \sum \tilde{\psi}_j^2 < \infty$. Sumando,

$$\frac{1}{\sqrt{T}} \sum_{t=1}^T y_t = \psi(1) \frac{1}{\sqrt{T}} \sum_{t=1}^T \varepsilon_t + \frac{\eta_0 - \eta_T}{\sqrt{T}}.$$

El último término tiene varianza $\leq 4\sigma^2 \sum \tilde{\psi}_j^2 / T \rightarrow 0$, así que es $o_p(1)$. El primero converge a $N(0, \sigma^2 \psi(1)^2)$ por el TCL i.i.d. Por Slutsky, el resultado sigue. $\square$

La descomposición, **separar un proceso en una “parte permanente”** ($\psi(1)\varepsilon_t$) **y una “parte transitoria”** ($\eta_{t-1} - \eta_t$), tiene un uso conceptual enorme: dice que **la acumulación de un proceso estacionario se comporta como la de un ruido blanco escalado por $\psi(1)$** . El efecto de la dependencia es entonces *solo* el factor $\psi(1)$ en la desviación estándar: la suma de coeficientes. Con $\psi(1) = 1/(1 - \phi)$ (AR(1)), una persistencia de $\phi = 0,8$ multiplica la desviación estándar del promedio por 5. En la Clase 6 aplicaremos la misma descomposición a un proceso integrado (donde $\psi(1) \neq 0$ hará aparecer una caminata aleatoria).

4. Estimación de la varianza de largo plazo

El TCL dice que $\sqrt{T}\bar{\xi} \rightarrow N(0, \sigma_{LR}^2)$ para un score/momento ξ_t con $\sigma_{LR}^2 = \sum_h \gamma_\xi(h)$. Para inferencia necesitamos un **estimador consistente** de σ_{LR}^2 . Dos intentos obvios fracasan.

- $\hat{\gamma}(0)$ **solo**: ignora las autocovarianzas, y es inconsistente para σ_{LR}^2 si hay dependencia.
- **La suma de todas las autocovarianzas muestrales**: $\sum_{|h|<T} \hat{\gamma}(h)$ **no** es consistente. Si los datos están centrados (restada la media muestral), esta suma vale **exactamente cero** (Ejercicio 5.4), y si no se resta la media vale $T\bar{\xi}^2 \rightarrow_d \sigma_{LR}^2 \chi_1^2$, **una variable aleatoria que no se concentra** (§★).

La razón es que las autocovarianzas de rezagos grandes se estiman con **pocas observaciones** ($T - h$) y su ruido no se promedia:

cada $\hat{\gamma}(h)$ lejano tiene varianza $O(1/T)$ pero hay $O(T)$ de ellos. La solución es **truncar o ponderar**: sumar solo hasta un rezago m que crece **más lento** que T .

4.1. El estimador de Newey–West

Definición 4.1 (Estimador HAC). Para una sucesión ξ_t con media estimada o cero,

$$\hat{\sigma}_{HAC}^2 = \sum_{h=-m}^m k\left(\frac{h}{m+1}\right) \hat{\gamma}(h), \quad \hat{\gamma}(h) = \frac{1}{T} \sum_{t=|h|+1}^T \xi_t \xi_{t-|h|},$$

con una **función kernel** $k(\cdot)$ simétrica, $k(0) = 1$, y un **ancho de banda** (o truncamiento) m . Con el **kernel de Bartlett** $k(u) = 1 - |u|$ para $|u| \leq 1$ se obtiene el estimador de **Newey y West** (1987).

Con el kernel de Bartlett, $\hat{\sigma}_{HAC}^2 = \hat{\gamma}(0) + 2 \sum_{h=1}^m \left(1 - \frac{h}{m+1}\right) \hat{\gamma}(h)$: las autocovarianzas se incluyen con **pesos decrecientes** que llegan a cero en $h = m + 1$. Elegir pesos decrecientes (en vez de truncar bruscamente, kernel uniforme) tiene una razón de fondo.

Proposición 4.1 (El estimador de Newey–West es no negativo). Con el kernel de Bartlett, $\hat{\sigma}_{HAC}^2 \geq 0$ siempre. (Con el kernel uniforme $k(u) = \mathbf{1}\{|u| \leq 1\}$ puede ser **negativo**.)

Demostración. Rellenamos $\xi_t = 0$ fuera de $1, \dots, T$ y consideramos las $T + m$ sumas móviles $B_s = \sum_{j=0}^m \xi_{s+j}$, $s = -m + 1, \dots, T$. Entonces

$$\sum_s B_s^2 = \sum_{j,k=0}^m \sum_s \xi_{s+j} \xi_{s+k} = \sum_{j,k=0}^m T \hat{\gamma}(k-j) = T \sum_{|h| \leq m} (m+1-|h|) \hat{\gamma}(h),$$

porque para cada diferencia $h = k - j$ hay $m + 1 - |h|$ pares (j, k) , y $\sum_s \xi_{s+j} \xi_{s+k} = T \hat{\gamma}(k - j)$. Dividiendo por $T(m + 1)$ queda $\hat{\sigma}_{HAC}^2 = \frac{1}{T(m+1)} \sum_s B_s^2 \geq 0$. $\square$

La no negatividad es indispensable: una “varianza” negativa produciría errores estándar imaginarios. Es el mismo motivo por el que se usa el divisor T (no $T - h$) en $\hat{\gamma}(h)$ (Clase 1).

4.2. Consistencia, sesgo y varianza

La idea de por qué el truncamiento funciona: es un **compromiso sesgo-varianza**. Con m chico, se omiten autocovarianzas relevantes (**sesgo**); con m grande, se estiman muchas con poco dato (**varianza**).

Proposición 4.2 (Sesgo del estimador de Newey–West). *Si ξ_t es estacionario con $\sum_h |h| |\gamma(h)| < \infty$ y $m \rightarrow \infty$ con $m/T \rightarrow 0$, entonces*

$$\mathbb{E}[\hat{\sigma}_{HAC}^2] \rightarrow \sigma_{LR}^2, \quad \mathbb{E}[\hat{\sigma}_{HAC}^2] - \sigma_{LR}^2 \approx -\frac{1}{m+1} \sum_{h=-\infty}^{\infty} |h| \gamma(h) + o\left(\frac{1}{m}\right).$$

Demostración. Con $\mathbb{E}[\hat{\gamma}(h)] = (1 - |h|/T)\gamma(h)$ (para datos con media cero conocida),

$$\mathbb{E}[\hat{\sigma}_{HAC}^2] - \sigma_{LR}^2 = \sum_{|h| \leq m} \left[\left(1 - \frac{|h|}{m+1}\right) \left(1 - \frac{|h|}{T}\right) - 1 \right] \gamma(h) - \sum_{|h| > m} \gamma(h).$$

El corchete es $-\frac{|h|}{m+1} - \frac{|h|}{T} + \frac{|h|^2}{(m+1)T}$, cuya magnitud es $\leq |h| \left(\frac{1}{m+1} + \frac{1}{T} \right)$. Luego el sesgo está acotado por $\left(\frac{1}{m+1} + \frac{1}{T} \right) \sum_h |h| |\gamma(h)| + \sum_{|h| > m} |\gamma(h)|$, que tiende a cero. El término dominante, $-\frac{1}{m+1} \sum_h |h| \gamma(h)$, da la aproximación. $\square$

La **varianza** de $\hat{\sigma}_{HAC}^2$ crece con m : bajo condiciones de cuarto orden (que se toman prestadas; Andrews, 1991), $\text{Var}(\hat{\sigma}_{HAC}^2) \approx \frac{4}{3} \frac{m}{T} \sigma_{LR}^4$ para el kernel de Bartlett. Entonces **el sesgo cae como $1/m$ y la varianza crece como m/T** . El ECM, $\text{sesgo}^2 + \text{varianza} \sim c_1/m^2 + c_2 m/T$, se minimiza en

$$m^* \propto T^{1/3}.$$

Con esa tasa, $\hat{\sigma}_{HAC}^2 \rightarrow \sigma_{LR}^2$ en probabilidad, a velocidad $T^{-1/3}$ (más lenta que la $T^{-1/2}$ habitual: es un problema **no paramétrico**, como una estimación de densidad). Una regla práctica (Newey y West, 1994) es $m = \lfloor 4(T/100)^{2/9} \rfloor$: da $m = 4$ para $T = 100$, 5 para $T = 500$ y 6 para $T = 1000$. (La potencia $2/9$ y no $1/3$ viene de un método basado en los datos para estimar las constantes c_1, c_2 .)

4.3. Alternativas

- **Otros kernels** (Parzen, *quadratic spectral*; Andrews, 1991): menor sesgo asintótico, no negatividad (QS), similar en la práctica.
- **Preblanqueo** (Andrews y Monahan, 1992): ajustar primero un VAR/AR a ξ_t para sacar la mayor parte de la dependencia y aplicar HAC a los residuos; mejora mucho el desempeño con serie persistente.
- **Asintótica de ancho fijo** (*fixed-b*, Kiefer y Vogelsang, 2005): se deja $m/T = b$ fijo, con una distribución límite no estándar (pero tabulada) que corrige el sobrerrechazo en muestras finitas.
- **Modelar el error** (MCGF, Cochrane–Orcutt; Clase 9 de Econometría 1): más eficiente si el modelo es correcto; HAC es **robusto** al precio de eficiencia.

5. Usos

5.1. MCO con errores correlacionados

En $y_t = x_t' \beta + u_t$ con $\mathbb{E}[x_t u_t] = 0$ pero u_t **serialmente correlacionado**, $\hat{\beta}$ sigue siendo consistente (Clase 7 de Econometría 1). La distribución cambia: $\sqrt{T}(\hat{\beta} - \beta) \rightarrow_d N(0, Q^{-1} \Omega Q^{-1})$ con $Q = \mathbb{E}[x_t x_t']$ y $\Omega = \sum_{h=-\infty}^{\infty} \mathbb{E}[x_t u_t u_{t-h} x_{t-h}']$, la **varianza de largo plazo** de $\xi_t = x_t u_t$. La estimación usa $\hat{Q} = \frac{1}{T} \sum x_t x_t'$ y $\hat{\Omega} = \text{HAC}$ de $\hat{\xi}_t = x_t \hat{u}_t$:

$$\widehat{\text{Avar}}(\hat{\beta}) = \frac{1}{T} \hat{Q}^{-1} \hat{\Omega}_{\text{HAC}} \hat{Q}^{-1}.$$

Es la fórmula de White (Clase 7 de Econometría 1) con autocovarianzas. Cuando $\hat{\Omega}$ solo incluye el término $h = 0$ ($m = 0$) se recupera exactamente White.

Ejemplo 5.1 (El costo de ignorar la dependencia). Sea $y_t = \beta x_t + u_t$ con x_t y u_t **independientes**, ambos AR(1) con coeficientes $\rho_x = \rho_u = 0,8$ (y $\beta = 0$). Entonces $\xi_t = x_t u_t$ tiene autocovarianza $\gamma_{\xi}(h) = \gamma_x(h) \gamma_u(h) = \sigma_x^2 \sigma_u^2 (\rho_x \rho_u)^{|h|}$, y su varianza de

largo plazo es $\sigma_x^2 \sigma_u^2 \frac{1 + \rho_x \rho_u}{1 - \rho_x \rho_u}$. Como $Q = \sigma_x^2$, la varianza asintótica real de $\hat{\beta}$ es $\frac{\sigma_u^2}{\sigma_x^2} \cdot \frac{1 + \rho_x \rho_u}{1 - \rho_x \rho_u}$, mientras que la fórmula de MCO “clásica” da $\sigma_u^2 / (T \sigma_x^2)$ (ignorando la dependencia). Con $\rho_x \rho_u = 0,64$ el factor es $1,64 / 0,36 = 4,56$: **los errores estándar clásicos son $\sqrt{4,56} = 2,13$ veces demasiado chicos**. Un test al 5 % con $t = \hat{\beta} / \text{ee}_{clásico}$ rechaza $H_0 : \beta = 0$ con probabilidad $2(1 - \Phi(1,96/2,13)) = 36\%$ **aunque x y y no tengan relación alguna**. Es el mismo fenómeno de las regresiones espurias, aquí en su versión estacionaria.

5.2. GMM, pronósticos y otros

- **GMM** (Clase 4 de Econometría 2) con momentos serialmente correlacionados: la matriz óptima de pesos es $W = \Omega^{-1}$ con Ω la **varianza de largo plazo** de $g_t(\theta_0)$, estimada por HAC. Es lo que se usa en finanzas (ecuaciones de Euler, Hansen–Singleton) y en macro.
- **Test de Diebold–Mariano** (Clase 3): el estadístico estandariza con la varianza de largo plazo del diferencial de pérdida d_t , estimada con Newey–West con al menos $h - 1$ rezagos.
- **Tests de predictibilidad y de eficiencia** de mercado, con errores de pronóstico $\text{MA}(h - 1)$.

Un cuidado importante: la **corrección HAC es asintótica** y en muestras pequeñas (o con series muy persistentes) tiende a **subestimar** la varianza (sesgo del $-\frac{1}{m} \sum |h| \gamma(h)$), de modo que los tests siguen **sobrerrechazando**. Por eso conviene preblanquear, usar b fijo, o bootstrap por bloques.

6. ★ Postgrado: por qué la suma completa de autocovarianzas no sirve

! ★ Postgrado

La densidad espectral en cero, $2\pi f(0) = \sigma_{LR}^2$, **no** se estima consistentemente con el periodograma: se necesita suavizar. Esta es la razón estructural del truncamiento $m \ll T$.

Sea ξ_t de media cero con $\hat{\gamma}(h)$ calculado **sin** restar la media. Entonces

$$\sum_{|h| < T} \hat{\gamma}(h) = \frac{1}{T} \sum_{t,s=1}^T \xi_t \xi_s = \frac{1}{T} \left(\sum_{t=1}^T \xi_t \right)^2 = T \bar{\xi}^2,$$

porque cada par (t, s) aparece exactamente una vez, con $|t - s| = |h|$. Es el **periodograma en frecuencia cero**, $I_T(0)$. Por el TCL, $\sqrt{T} \bar{\xi} \rightarrow_d N(0, \sigma_{LR}^2)$, así que

$$I_T(0) = T \bar{\xi}^2 \xrightarrow{d} \sigma_{LR}^2 \chi_1^2.$$

Su **esperanza** converge a σ_{LR}^2 (es asintóticamente insesgado: coincide con $T \text{Var}(\bar{\xi})$ de la Clase 1), pero su **varianza no tiende a cero**: es $2\sigma_{LR}^4$ en el límite (la de una χ_1^2 escalada). Un estimador cuya distribución asintótica es una variable aleatoria no degenerada **no es consistente**. Esto ocurre en cada frecuencia: el periodograma es un estimador insesgado pero inconsistente de la densidad espectral. Cualquier estimador consistente debe **promediar** valores del periodograma en frecuencias cercanas: $\hat{f}(0) = \frac{1}{2\pi} \sum_{|h| \leq m} k(h/(m+1)) \hat{\gamma}(h)$ es exactamente un periodograma **suavizado con una ventana** de ancho $\sim 1/m$ en el dominio de frecuencias (el kernel de Bartlett en tiempo es el **kernel de Fejér** en frecuencia, que es no negativo: otra forma de ver la Proposición 4.1). Con ancho $1/m \rightarrow 0$ pero cada ventana conteniendo $T/m \rightarrow \infty$ frecuencias de Fourier, el promedio reduce la varianza a $O(m/T)$.

7. Resumen

- Una **diferencia de martingala** es impredecible dado el pasado: es ruido blanco “fuerte”. Su TCL (Teorema 2.1, tomado prestado) justifica la inferencia en AR por MCO (Clase 4). La varianza límite es simplemente $\mathbb{E}[\xi^2]$.
- Para **procesos lineales**, el TCL se demuestra con la descomposición de **Beveridge-Nelson** (Teorema 3.1): $\psi(L) = \psi(1) + (L-1)\tilde{\psi}(L)$, de donde $T^{-1/2} \sum y_t \rightarrow N(0, \sigma^2 \psi(1)^2)$.
- La **varianza de largo plazo** $\sigma_{LR}^2 = \sum_h \gamma(h)$ se estima con **HAC** (Newey-West): $\hat{\gamma}(0) + 2 \sum_{h \leq m} (1 - \frac{h}{m+1}) \hat{\gamma}(h)$, no negativo por construcción (Proposición 4.1). Sesgo $\sim 1/m$, varianza $\sim m/T$, $m^* \propto T^{1/3}$.
- La suma completa de autocovarianzas **no** sirve: equivale al periodograma, insesgado pero inconsistente.
- **Usos**: MCO con errores correlacionados (sándwich HAC), GMM, Diebold-Mariano. Ignorar la dependencia sobrerrechaza (Ejemplo 5.1: 36 % al nominal 5 %).

8. Ejercicios

Ejercicio 5.1. Sea $\varepsilon_t = \eta_t + \eta_{t-1}\eta_{t-2}$ con η_t i.i.d. $N(0, 1)$. Muestra que es ruido blanco (calcula $\gamma(0)$ y $\gamma(1), \gamma(2)$) pero **no** es una diferencia de martingala respecto de $\mathcal{F}_t = \sigma(\eta_s : s \leq t)$.

Solución 5.1

$\mathbb{E}[\varepsilon_t] = 0$. $\gamma(0) = \mathbb{E}[\eta_t^2] + \mathbb{E}[\eta_{t-1}^2 \eta_{t-2}^2] + 2\mathbb{E}[\eta_t \eta_{t-1} \eta_{t-2}] = 1 + 1 + 0 = 2$. $\gamma(1) = \mathbb{E}[(\eta_t + \eta_{t-1}\eta_{t-2})(\eta_{t-1} + \eta_{t-2}\eta_{t-3})]$: los cuatro productos son $\eta_t \eta_{t-1}$, $\eta_t \eta_{t-2} \eta_{t-3}$, $\eta_{t-1}^2 \eta_{t-2}$, $\eta_{t-1} \eta_{t-2}^2 \eta_{t-3}$, y cada uno tiene esperanza cero (algún η aparece una sola vez con media cero). Igual para $\gamma(2) = \mathbb{E}[(\eta_t + \eta_{t-1}\eta_{t-2})(\eta_{t-2} + \eta_{t-3}\eta_{t-4})] = 0$. Para $h \geq 3$ las dos expresiones no comparten variables: 0. Es ruido blanco. Pero $\mathbb{E}[\varepsilon_t | \mathcal{F}_{t-1}] = \mathbb{E}[\eta_t] + \eta_{t-1}\eta_{t-2} = \eta_{t-1}\eta_{t-2} \neq 0$: el pasado predice el presente de manera **no lineal**. Un predictor lineal no lo ve (no hay correlación), pero la esperanza condicional sí. Esta distinción es la que hace

falta para el TCL de martingalas.

Ejercicio 5.2. Con $\hat{\gamma}(0) = 1$, $\hat{\gamma}(1) = 0,6$, $\hat{\gamma}(2) = 0,36$ (de un AR(1) con $\rho = 0,6$), calcula el estimador de Newey-West con $m = 2$ y compáralo con el valor verdadero $\sigma_{LR}^2/\gamma(0) = (1 + \rho)/(1 - \rho)$.

 Solución 5.2

Pesos de Bartlett: $w_1 = 1 - 1/3 = 2/3$, $w_2 = 1 - 2/3 = 1/3$.
 $\hat{\sigma}_{HAC}^2 = 1 + 2(2/3)(0,6) + 2(1/3)(0,36) = 1 + 0,8 + 0,24 = 2,04$. Verdadero: $(1,6)/(0,4) = 4$. El estimador captura solo la mitad. La diferencia, $4 - 2,04 = 1,96$, tiene dos partes: las autocovarianzas omitidas con $h \geq 3$ suman $2(0,6^3 + 0,6^4 + \dots) = 2 \cdot 0,216/0,4 = 1,08$, y los pesos decrecientes recortan las incluidas en $2(0,6/3) + 2(0,36 \cdot 2/3) = 0,88$. Es el sesgo $-\frac{1}{m+1} \sum |h|\gamma(h)$ de la Proposición 4.2, que con un proceso persistente exige m grande. Con $\rho = 0,6$ y $T = 100$ la regla práctica da $m = 4$, aún bajo.

Ejercicio 5.3. En el Ejemplo 5.1, calcula el factor de error estándar y la probabilidad de rechazo cuando $\rho_x = \rho_u = 0,5$. ¿Y con $\rho_x = 0,9$, $\rho_u = 0,5$?

 Solución 5.3

Factor de varianza $(1+r)/(1-r)$ con $r = \rho_x \rho_u$. Caso 0,5, 0,5: $r = 0,25$, factor $1,25/0,75 = 1,667$, error estándar $\times 1,29$; rechazo: $2(1 - \Phi(1,96/1,29)) = 2(1 - \Phi(1,52)) = 0,129$ (13 %). Caso 0,9, 0,5: $r = 0,45$, factor $1,45/0,55 = 2,636$, $\times 1,62$; rechazo $2(1 - \Phi(1,21)) = 0,226$ (23 %). El problema es **el producto** $\rho_x \rho_u$: si el error o el regresor no tienen persistencia, el efecto desaparece. En el segundo caso, basta con que un regresor muy persistente se combine con errores moderadamente persistentes.

Ejercicio 5.4. Para los datos $\xi = (1, 0, -1)$ (media muestral cero) calcula $\hat{\gamma}(0)$, $\hat{\gamma}(1)$, $\hat{\gamma}(2)$ y $\sum_{|h|<3} \hat{\gamma}(h)$. Comenta.

💡 Solución 5.4

$\hat{\gamma}(0) = (1 + 0 + 1)/3 = 0,667$; $\hat{\gamma}(1) = (1 \cdot 0 + 0 \cdot (-1))/3 = 0$; $\hat{\gamma}(2) = (1 \cdot (-1))/3 = -0,333$. Suma: $0,667 + 2(0) + 2(-0,333) = 0$. Es general: con datos centrados, $\sum_{|h|<T} \hat{\gamma}(h) = \frac{1}{T}(\sum_t \xi_t)^2 = 0$. Un estimador de σ_{LR}^2 que sume todas las autocovarianzas muestrales daría **cero**: claramente inconsistente.

Ejercicio 5.5. Con $T = 4$, $\xi = (1, -1, 1, -1)$ y $m = 1$, calcula el estimador con kernel uniforme (truncado) y el de Bartlett. ¿Qué observas?

💡 Solución 5.5

$\hat{\gamma}(0) = 4/4 = 1$ y $\hat{\gamma}(1) = [(-1) + (-1) + (-1)]/4 = -0,75$. Uniforme ($m = 1$): $\hat{\gamma}(0) + 2\hat{\gamma}(1) = 1 - 1,5 = -0,5 < 0$: **varianza estimada negativa**. Bartlett: $\hat{\gamma}(0) + 2(1 - \frac{1}{2})\hat{\gamma}(1) = 1 - 0,75 = 0,25 \geq 0$. Comprobación con las sumas móviles de la prueba: $B_s = \xi_s + \xi_{s+1}$ para $s = 0, \dots, 4$: $(1, 0, 0, 0, -1)$, con $\sum B_s^2 = 2$ y $2/(T(m+1)) = 2/8 = 0,25$. $\square$.

Ejercicio 5.6. Calcula $m = \lfloor 4(T/100)^{2/9} \rfloor$ para $T = 50, 100, 500, 2000$. ¿Por qué crece tan despacio?

💡 Solución 5.6

$T = 50$: $4(0,5)^{0,222} = 4(0,857) = 3,43 \rightarrow 3$. $T = 100$: $4(1)^{0,222} = 4(1,43) = 5,7 \rightarrow 5$. $T = 500$: $4(20)^{0,222} = 4(1,945) = 7,8 \rightarrow 7$. Crece como $T^{2/9}$, **más despacio** que el óptimo teórico $T^{1/3}$, porque la constante se escala con las propias autocorrelaciones (más baja cuando la persistencia es moderada) y porque las ganancias son pequeñas: con $T = 2000$ un m de 7 ya captura casi todo salvo series muy persistentes. Es el costo de la tasa no paramétrica $T^{-1/3}$ en la precisión de $\hat{\sigma}_{HAC}^2$.

Ejercicio 5.7 ★. Aplica la descomposición de Beveridge–Nelson a un MA(1), $\psi(L) = 1 + 0,5L$: calcula $\psi(1)$, los $\tilde{\psi}_j$, verifica $\psi(L) = \psi(1) + (L-1)\tilde{\psi}(L)$ y escribe $\sum_{t=1}^T y_t$ en términos de ε .

💡 Solución 5.7 ★

$\psi_0 = 1, \psi_1 = 0,5$: $\psi(1) = 1,5$. $\tilde{\psi}_0 = \psi_1 = 0,5$ y $\tilde{\psi}_j = 0$ para $j \geq 1$. Verificación: $1,5 + (L-1)(0,5) = 1,5 - 0,5 + 0,5L = 1 + 0,5L$ $\square$. Entonces $y_t = 1,5\varepsilon_t + 0,5\varepsilon_{t-1} - 0,5\varepsilon_t$, con $\eta_t = 0,5\varepsilon_t$. Sumando: $\sum_{t=1}^T y_t = 1,5 \sum_t \varepsilon_t + 0,5(\varepsilon_0 - \varepsilon_T)$. Comprobación directa: $\sum y_t = \sum_t \varepsilon_t + 0,5 \sum_t \varepsilon_{t-1} = \sum_{t=1}^T \varepsilon_t + 0,5(\sum_{t=1}^T \varepsilon_t + \varepsilon_0 - \varepsilon_T)$ $\square$. La parte transitoria $0,5(\varepsilon_0 - \varepsilon_T)$ es $O_p(1)$ y el resto es $1,5 \times$ una suma i.i.d.: $T \text{Var}(\bar{y}) \rightarrow 1,5^2 \sigma^2 = 2,25 \sigma^2 = \sigma^2(1 + \theta)^2$ (Clase 1, ejemplo MA(1)).