

Clase 9 · Vectores autorregresivos (VAR)

Estacionariedad, estimación, selección de rezagos y
causalidad de Granger

Contenido

1	De una serie a un sistema	2
2	El VAR(p)	2
2.1	La forma companion y la condición de estacionariedad	3
3	Estimación	4
3.1	MCO ecuación por ecuación es máxima verosimilitud	4
3.2	Distribución asintótica	5
3.3	La maldición de la dimensionalidad	6
4	Selección del número de rezagos	7
5	Causalidad de Granger	7
6	Pronóstico con un VAR	9
7	★ Postgrado: la condición del determinante y los autovalores de F	9
8	Resumen	10
9	Ejercicios	10

1. De una serie a un sistema

Hasta aquí modelamos **una** serie a la vez. Pero las preguntas macroeconómicas son casi siempre sobre **interacciones**: ¿cómo responden la inflación y el producto a la política monetaria?, ¿el tipo de cambio predice los precios, o al revés?, ¿cómo se transmiten los shocks entre países? Un enfoque con ecuaciones simultáneas exigiría una teoría detallada de la estructura del sistema. Sims (1980) propuso la alternativa que domina la macroeconometría empírica desde entonces: **dejar hablar a los datos**, modelando el vector de variables de interés como un **vector autorregresivo** (VAR) donde cada variable depende de los rezagos de todas.¹

2. El VAR(p)

Sea $y_t = (y_{1t}, \dots, y_{nt})'$ un vector de n series. El **VAR(p)** en forma reducida es

$$y_t = c + A_1 y_{t-1} + A_2 y_{t-2} + \dots + A_p y_{t-p} + u_t, \quad u_t \sim WN(0, \Sigma_u), \quad (1)$$

con A_j matrices de $n \times n$, c un vector de constantes y u_t un ruido blanco **vectorial**: $\mathbb{E}[u_t] = 0$, $\mathbb{E}[u_t u_t'] = \Sigma_u$ (definida positiva, **no necesariamente diagonal**) y $\mathbb{E}[u_t u_s'] = 0$ si $t \neq s$. Cada ecuación es una regresión de y_{it} sobre una constante y p rezagos de **todas** las variables. La covarianza contemporánea Σ_u captura que los errores de distintas ecuaciones se mueven juntos en t .

Un ejemplo bivariado, con $p = 1$: $y_t = (\pi_t, x_t)'$ (inflación y brecha del producto),

$$\begin{pmatrix} \pi_t \\ x_t \end{pmatrix} = \begin{pmatrix} 0,5 & 0,1 \\ 0,2 & 0,4 \end{pmatrix} \begin{pmatrix} \pi_{t-1} \\ x_{t-1} \end{pmatrix} + \begin{pmatrix} u_{\pi t} \\ u_{xt} \end{pmatrix}.$$

La inflación depende de la inflación pasada (coeficiente 0,5) y de la brecha pasada (0,1); la brecha, de ambas. Este ejemplo se usa a lo largo de las Clases 9 y 10 (Ejercicios 9.1 y 9.6).

¹ Christopher Sims recibió el Nobel de Economía de 2011 (junto con Thomas Sargent) por sus métodos empíricos sobre causa y efecto en la macroeconomía. Su artículo de 1980, "Macroeconomics and Reality", sostenía que las restricciones de exclusión "increíbles" de los grandes modelos de ecuaciones simultáneas eran un obstáculo, y que un VAR sin restricciones era una forma más honesta de resumir los datos. La discusión de cuánta estructura imponer sigue abierta (Clase 10).

2.1. La forma companion y la condición de estacionariedad

Todo VAR(p) se puede escribir como un VAR(1) **más grande**, apilando los rezagos. Sea $Y_t = (y'_t, y'_{t-1}, \dots, y'_{t-p+1})'$ de dimensión np :

$$Y_t = \mu + FY_{t-1} + U_t, \quad F = \begin{pmatrix} A_1 & A_2 & \cdots & A_{p-1} & A_p \\ I_n & 0 & \cdots & 0 & 0 \\ 0 & I_n & \cdots & 0 & 0 \\ \vdots & & \ddots & & \vdots \\ 0 & 0 & \cdots & I_n & 0 \end{pmatrix},$$

con $\mu = (c', 0, \dots, 0)'$ y $U_t = (u'_t, 0, \dots, 0)'$. La matriz F ($np \times np$) es la **matriz companion**. Con ella la estacionariedad se reduce a una condición sobre autovalores.

Teorema 2.1 (Estacionariedad del VAR). *Son equivalentes: (i) todos los autovalores de F tienen módulo menor que 1; (ii) $\det(I_n - A_1z - \cdots - A_pz^p) \neq 0$ para todo $|z| \leq 1$. Bajo esas condiciones el VAR tiene una **única** solución estacionaria, causal, dada por la representación $MA(\infty)$*

$$y_t = \mu_y + \sum_{j=0}^{\infty} \Psi_j u_{t-j}, \quad \Psi_0 = I_n, \quad \Psi_j = \sum_{k=1}^{\min(j,p)} A_k \Psi_{j-k},$$

con $\mu_y = (I_n - A_1 - \cdots - A_p)^{-1}c$ y $\|\Psi_j\| \leq Kr^j$ para algún $r < 1$.

Demostración. (Esquema; la equivalencia (i) $\Leftrightarrow$ (ii) se prueba en la sección ★.) Si los autovalores de F están dentro del círculo unitario, $F^j \rightarrow 0$ geométricamente (por la forma de Jordan). Iterando el VAR(1), $Y_t = \sum_{j=0}^{t-1} F^j (\mu + U_{t-j}) + F^t Y_{t-t}$, y el último término tiende a cero en media cuadrática. Luego $Y_t = (I - F)^{-1} \mu + \sum_{j \geq 0} F^j U_{t-j}$ (la suma converge absolutamente por el decaimiento geométrico), y es la única solución estacionaria (el mismo argumento de unicidad del AR(1), Clase 2). El proceso es estacionario, pues su media es constante y su covarianza depende solo del rezago (Clase 2, proceso lineal). El bloque superior de Y_t es y_t : Ψ_j es el bloque $n \times n$ superior izquierdo de F^j , y satisface la recursión enunciada (igualando coeficientes en $(I - A_1L - \cdots - A_pL^p)\Psi(L) = I$). $\square$

Esta condición generaliza la del $AR(p)$ de la Clase 2 (raíces de $\phi(z)$ fuera del círculo unitario) y es la que hay que verificar siempre después de estimar un VAR: se calculan los autovalores de $\hat{F}$ y se comprueba que el máximo módulo sea menor que uno. En el ejemplo, $A = \begin{pmatrix} 0,5 & 0,1 \\ 0,2 & 0,4 \end{pmatrix}$ tiene traza 0,9 y determinante 0,18, y sus autovalores son $\lambda = (0,9 \pm \sqrt{0,81 - 0,72})/2 = 0,6$ y $0,3$: es estacionario. La respuesta a un shock, $\Psi_1 = A$, $\Psi_2 = A^2$, etcétera, decae a tasa $0,6^j$.

Los momentos de segundo orden se obtienen de $\Gamma_Y(0) = F\Gamma_Y(0)F' + \Sigma_U$, es decir, $\text{vec } \Gamma_Y(0) = (I - F \otimes F)^{-1} \text{vec } \Sigma_U$, que existe porque F es estable.

3. Estimación

3.1. MCO ecuación por ecuación es máxima verosimilitud

Con $T + p$ observaciones, definamos $x_t = (1, y'_{t-1}, \dots, y'_{t-p})'$ ($1 + np$ regresores) y $B = [c, A_1, \dots, A_p]$ ($n \times (1 + np)$), de modo que $y_t = Bx_t + u_t$. Cada ecuación del sistema se estima por **MCO**: $\hat{B} = (\sum_t y_t x'_t)(\sum_t x_t x'_t)^{-1}$. Es un sistema de regresiones **aparentemente no relacionadas** (SUR) donde **todas las ecuaciones tienen los mismos regresores**, y en ese caso MCO coincide con MCG y con MV.

Teorema 3.1 (MCO = MV gaussiano (condicional)). Si $u_t \sim N(0, \Sigma_u)$, el estimador de máxima verosimilitud **condicional** en las primeras p observaciones es

$$\hat{B} = \sum_t y_t x'_t \left(\sum_t x_t x'_t \right)^{-1} \text{ (MCO ecuación por ecuación)}, \quad \hat{\Sigma}_u = \frac{1}{T} \sum_t \hat{u}_t \hat{u}'_t, \quad \hat{u}_t = y_t - \hat{B}x_t.$$

Borrador

La log-verosimilitud condicional es $-\frac{T}{2} \log |\Sigma_u| - \frac{1}{2} \sum_t (y_t - Bx_t)' \Sigma_u^{-1} (y_t - Bx_t)$. Para cualquier Σ_u fija, quiero mini-

minimizar la forma cuadrática $\sum (y_t - Bx_t)' \Sigma_u^{-1} (y_t - Bx_t) = \text{tr} [\Sigma_u^{-1} \sum (y_t - Bx_t)(y_t - Bx_t)']$ en B . La suma de cuadrados $\sum (y_t - Bx_t)(y_t - Bx_t)'$ admite una descomposición ortogonal alrededor de $\hat{B}$ (como $\$ \text{SCR} + \$ \text{distancia cuadrática}$, igual que en la Clase 3 de Econometría 1), y el término de distancia es **semidefinido positivo e independiente de** Σ_u . Entonces $\hat{B}$ minimiza la traza para cualquier Σ_u .

Demostración. Sea $\hat{u}_t = y_t - \hat{B}x_t$, con $\sum_t \hat{u}_t x_t' = 0$ (ortogonalidad de MCO). Para cualquier B , $y_t - Bx_t = \hat{u}_t + (\hat{B} - B)x_t$, así que

$$\sum_t (y_t - Bx_t)(y_t - Bx_t)' = \sum_t \hat{u}_t \hat{u}_t' + (\hat{B} - B) \left(\sum_t x_t x_t' \right) (\hat{B} - B)',$$

pues los términos cruzados se anulan por $\sum \hat{u}_t x_t' = 0$. El segundo término es semidefinido positivo y se anula si y solo si $B = \hat{B}$. Por lo tanto, para toda $\Sigma_u^{-1} > 0$, $\text{tr} [\Sigma_u^{-1} \sum (y_t - Bx_t)(y_t - Bx_t)'] \geq \text{tr} [\Sigma_u^{-1} \sum \hat{u}_t \hat{u}_t']$ con igualdad solo en $\hat{B}$: $\hat{B}$ maximiza la verosimilitud para **cada** Σ_u , sin importar su valor. Sustituyendo, queda $-\frac{T}{2} \log |\Sigma_u| - \frac{1}{2} \text{tr} [\Sigma_u^{-1} T \hat{\Sigma}_u]$, cuyo máximo en Σ_u es $\hat{\Sigma}_u = \frac{1}{T} \sum \hat{u}_t \hat{u}_t'$ (como en la Clase 2 de Econometría 2 para la normal multivariada). $\square$

Este es un resultado muy cómodo: **un VAR de n variables es solo n regresiones por MCO**, y no hace falta estimación simultánea. Además, no se necesita normalidad: como en la Clase 4, $\hat{B}$ es la cuasi-MV y es consistente bajo condiciones leves.

3.2. Distribución asintótica

Teorema 3.2 (Normalidad asintótica del VAR por MCO). *Sea y_t un VAR(p) estacionario con innovaciones i.i.d. $(0, \Sigma_u)$ (o diferencias de martingala con las condiciones habituales), y $Q = \mathbb{E}[x_t x_t']$ definida positiva. Entonces*

$$\sqrt{T} \text{vec} (\hat{B}' - B') \xrightarrow{d} N(0, \Sigma_u \otimes Q^{-1}), \quad \hat{\Sigma}_u \xrightarrow{p} \Sigma_u.$$

Demostración. Para la ecuación i , $\hat{b}_i - b_i = (\sum x_t x_t')^{-1} \sum x_t u_{it}$. Apilando las n ecuaciones, $\sqrt{T} \text{vec}(\hat{B}' - B') = (I_n \otimes (T^{-1} \sum x_t x_t')^{-1}) T^{-1/2} \sum_t (u_t \otimes x_t)$. Por el teorema ergódico (Clase 1), $T^{-1} \sum x_t x_t' \rightarrow_p Q$. Y $u_t \otimes x_t$ es una diferencia de martingala (porque $x_t \in \mathcal{F}_{t-1}$ y $\mathbb{E}[u_t | \mathcal{F}_{t-1}] = 0$) con varianza $\mathbb{E}[u_t u_t' \otimes x_t x_t'] = \Sigma_u \otimes Q$ (por independencia de u_t y x_t). Por el TCL para diferencias de martingala (Clase 5), $T^{-1/2} \sum u_t \otimes x_t \rightarrow_d N(0, \Sigma_u \otimes Q)$. Con Slutsky: la varianza es $(I \otimes Q^{-1})(\Sigma_u \otimes Q)(I \otimes Q^{-1}) = \Sigma_u \otimes Q^{-1}$. $\square$

Es la generalización directa de $\sigma^2 \Gamma_p^{-1}$ del AR(p) de la Clase 4. Dos consecuencias: **(i)** los errores estándar de cada coeficiente son los habituales de MCO en cada ecuación, y **(ii)** los estimadores de **distintas ecuaciones están correlacionados** (a través de Σ_u), lo que importa para tests conjuntos.

Para **restricciones** sobre los coeficientes (q restricciones lineales): el test de Wald usa la varianza anterior, o el test de razón de verosimilitud (Clase 3 de Econometría 2): $LR = T(\log |\hat{\Sigma}_R| - \log |\hat{\Sigma}_U|) \rightarrow_d \chi_q^2$, con $\hat{\Sigma}_R, \hat{\Sigma}_U$ las matrices de covarianza de residuos restringida y sin restringir. En muestras pequeñas se usa la corrección de Sims: se reemplaza T por $T - c$, con c el número de parámetros por ecuación del modelo sin restringir.

3.3. La maldición de la dimensionalidad

Un VAR(p) con n variables tiene $n(1 + np)$ coeficientes de la media y $n(n + 1)/2$ en Σ_u : crece como pn^2 . Con $n = 4$ y $p = 2$ son $36 + 10 = 46$ parámetros; con $n = 8$ y $p = 4$, son $264 + 36 = 300$. En datos macro típicos ($T = 100$ a 200) esto es demasiado: cada ecuación tiene $1 + np$ coeficientes para T observaciones (Ejercicio 9.2). La solución no es pensar que “más es mejor”. Hay tres salidas: (i) **pocas variables** (tres a seis), (ii) **VAR bayesianos** con una distribución a priori que contrae los coeficientes hacia un modelo simple (*prior de Minnesota*, Litterman), y (iii) **modelos de factores** (FAVAR) que resumen muchas series en pocos factores.

4. Selección del número de rezagos

Como en el $AR(p)$ de la Clase 4, se eligen los rezagos con **criterios de información**, que ahora usan el determinante de $\hat{\Sigma}_u(p)$:

$$AIC(p) = \log |\hat{\Sigma}_u(p)| + \frac{2pn^2}{T}, \quad BIC(p) = \log |\hat{\Sigma}_u(p)| + \frac{pn^2 \log T}{T}, \quad HQ(p) = \log |\hat{\Sigma}_u(p)| + \frac{2pn^2 \log \log T}{T}.$$

Se elige el p que minimiza el criterio, **con la misma muestra efectiva** para todos los p (usando los mismos T datos al comparar). Las propiedades son las de la proposición sobre AIC y BIC de la Clase 4: BIC (y HQ) consistentes; AIC sobreajusta pero pronostica mejor. Alternativamente, **tests de razón de verosimilitud secuenciales** (p frente a $p - 1$). Después de elegir p se verifican: (a) **estabilidad** (autovalores de $\hat{F}$); (b) **ausencia de autocorrelación residual** (versión multivariada del test de Ljung–Box, el *portmanteau* de Hosking); (c) normalidad (Jarque–Bera multivariado) si se usa inferencia exacta o simulación.

5. Causalidad de Granger

Una pregunta natural en un VAR es: ¿ayuda el pasado de una variable a pronosticar otra? Granger (1969) formalizó esa idea de **precedencia predictiva**.

Definición 5.1 (Causalidad de Granger). Sea (y_t, x_t) un par de procesos estacionarios. x **no causa en el sentido de Granger** a y si, para todo $h \geq 1$, el mejor predictor lineal de y_{t+h} basado en $\{y_s, x_s : s \leq t\}$ tiene el **mismo error cuadrático medio** que el basado solo en $\{y_s : s \leq t\}$. Es decir, el pasado de x no aporta nada a la predicción de y una vez usado el pasado de y .

En un VAR, la condición se traduce en **ceros** de coeficientes.

Proposición 5.1 (Causalidad de Granger en un VAR). Sea $(y_t, x_t)'$ un $VAR(p)$ estacionario bivariado, con la ecuación de y : $y_t = c_y + \sum_{k=1}^p (a_k^{yy} y_{t-k} + a_k^{yx} x_{t-k}) + u_{yt}$. Entonces x **no causa a Granger a** y si y solo si $a_1^{yx} = \dots = a_p^{yx} = 0$.

Demostración. ($\Leftarrow$) Si todos los $a_k^{yx} = 0$, el valor y_t depende solo del pasado de y más u_{yt} , y u_{yt} es no correlacionado con el pasado de **ambas** series. Luego $\sum_k a_k^{yy} y_{t-k}$ satisface las condiciones de ortogonalidad del mejor predictor lineal con información $\{y_s, x_s\}_{s < t}$ (Clase 3), y como esa solución es única, x no aporta. Para $h > 1$ se itera. ($\Rightarrow$) Si algún $a_k^{yx} \neq 0$, los coeficientes verdaderos (a^{yy}, a^{yx}) satisfacen las ecuaciones normales del predictor con ambos conjuntos de datos (porque u_{yt} es ortogonal a todo el pasado), y la solución es única: el mejor predictor **usa** x con coeficiente distinto de cero. Al incluir un regresor con coeficiente no nulo (y no perfectamente colineal con los otros), el ECM baja estrictamente (en $\delta' \text{Var}(x | y \text{ pasado}) \delta > 0$). $\square$

El **test** es entonces un test de Wald o F de $H_0 : a_1^{yx} = \dots = a_p^{yx} = 0$, con distribución χ_p^2 asintótica (por el Teorema 3.2). Con más de dos variables, la definición se generaliza por bloques (y la causalidad de Granger indirecta, a través de una tercera variable, requiere más cuidado).

Granger no es causalidad

El nombre es engañoso. La causalidad de Granger es **precedencia predictiva**, no causalidad estructural. Las **expectativas** pueden invertir el orden: los precios de las acciones “causan a Granger” a los dividendos futuros porque los inversionistas anticipan los dividendos; el pronóstico meteorológico “causa a Granger” las ventas de paraguas sin ser su causa; un *tercer* factor omitido puede hacer que x preceda a y sin influir sobre él. Y el concepto ignora la relación **contemporánea** (que vive en Σ_u , no en los A_k). Es una herramienta de **pronóstico**, no de identificación. Para preguntas causales hacen falta supuestos estructurales (Clase 10).

Dos cuidados técnicos. (1) Con variables $I(1)$, el test de Wald no tiene distribución χ^2 ; el truco de **Toda y Yamamoto** (1995) es estimar un VAR en niveles con $p + d_{\max}$ rezagos ($d_{\max}$ el orden máximo de integración) y testear solo las restricciones sobre los primeros p , lo que recupera la distribución χ_p^2 aun con raíces unitarias y cointegración. (2) La causalidad de Granger **depende del conjunto de información**: puede desaparecer al agregar una tercera variable.

6. Pronóstico con un VAR

Por la misma proyección de la Clase 3, el pronóstico a h pasos con un VAR estacionario es la **proyección** sobre el pasado: se calcula recursivamente, $\hat{y}_{T+h|T} = \hat{c} + \sum_{k=1}^p \hat{A}_k \hat{y}_{T+h-k|T}$ (con $\hat{y}_{T+j|T} = y_{T+j}$ si $j \leq 0$). El **error** de pronóstico y su matriz de ECM son, por la representación $MA(\infty)$ (Teorema 2.1),

$$e_{T+h|T} = \sum_{j=0}^{h-1} \Psi_j u_{T+h-j}, \quad \Sigma_y(h) = \sum_{j=0}^{h-1} \Psi_j \Sigma_u \Psi_j',$$

la versión matricial del teorema de pronóstico a h pasos de la Clase 3: crece con h y converge a la varianza incondicional Γ_0 .

7. ★ Postgrado: la condición del determinante y los autovalores de F

! ★ Postgrado

Demostramos la equivalencia (i) $\Leftrightarrow$ (ii) del Teorema 2.1: $\det(I_{np} - zF) = \det(I_n - A_1 z - \cdots - A_p z^p)$ para todo z . Los autovalores de F son entonces los **recíprocos** de las raíces del polinomio matricial.

Demostración. Para $p = 1$, $F = A_1$ y es inmediato. Para $p = 2$:

$$F = \begin{pmatrix} A_1 & A_2 \\ I & 0 \end{pmatrix} y$$

$$I_{2n} - zF = \begin{pmatrix} I - zA_1 & -zA_2 \\ -zI & I \end{pmatrix}.$$

Por el complemento de Schur respecto del bloque inferior derecho $D = I$ (invertible), $\det \begin{pmatrix} P & Q \\ R & D \end{pmatrix} = \det(D) \det(P - QD^{-1}R)$, de modo que

$$\det(I_{2n} - zF) = \det(I - zA_1 - (-zA_2)(-zI)) = \det(I - zA_1 - z^2 A_2).$$

Para p general se procede por inducción (eliminando el último bloque de filas y columnas con el complemento de Schur, que agrega el término $-A_p z^p$). Ahora, λ es autovalor de F si y solo si $\det(\lambda I - F) = 0$, es decir, con $z = 1/\lambda$ ($\lambda \neq 0$), $\det(I - zF) = 0$, o sea $\det(I - \sum A_k z^k) = 0$. Así los autovalores no nulos de F son los recíprocos de las raíces z , y $|\lambda| < 1 \Leftrightarrow |z| > 1$. $\square$

Para $n = 1$ esto es la identidad de la Clase 2: $\lambda^2 - \phi_1 \lambda - \phi_2 = 0$ si y solo si $z = 1/\lambda$ es raíz de $1 - \phi_1 z - \phi_2 z^2$ (Ejercicio 9.7). La condición del determinante es la que **generaliza** la causalidad del AR(p) escalar a sistemas.

8. Resumen

- Un **VAR(p)** modela un vector y_t con p rezagos de todas las variables. Es **estacionario** si los autovalores de la matriz companion F están dentro del círculo unitario (Teorema 2.1); entonces tiene representación MA(∞) con Ψ_j .
- **MCO ecuación por ecuación = MV gaussiano** (Teorema 3.1), porque todas las ecuaciones tienen los mismos regresores. Distribución: $\sqrt{T} \text{vec}(\hat{B}' - B') \rightarrow N(0, \Sigma_u \otimes Q^{-1})$ (Teorema 3.2).
- El número de parámetros crece como pn^2 : pocas variables, VAR bayesianos o factores.
- **Rezagos**: AIC, BIC, HQ con $\log |\hat{\Sigma}_u|$; verificar estabilidad y residuos.
- **Causalidad de Granger** (Proposición 5.1): x no causa a y si los coeficientes de x en la ecuación de y son cero. Es precedencia predictiva, **no causalidad estructural**.
- **Pronóstico**: $\text{ECM } \Sigma_y(h) = \sum_{j < h} \Psi_j \Sigma_u \Psi_j'$.

9. Ejercicios

Ejercicio 9.1. Para el VAR(1) con $A = \begin{pmatrix} 0,5 & 0,1 \\ 0,2 & 0,4 \end{pmatrix}$, verifica los autovalores 0,6 y 0,3 y calcula Ψ_1, Ψ_2 .

💡 Solución 9.1

Traza = 0,9, determinante = $0,5 \cdot 0,4 - 0,1 \cdot 0,2 = 0,18$.
 $\lambda^2 - 0,9\lambda + 0,18 = 0 \Rightarrow \lambda = (0,9 \pm \sqrt{0,81 - 0,72})/2 = (0,9 \pm 0,3)/2 = 0,6, 0,3$. Ambos con módulo menor que uno: estacionario. Para un VAR(1), $\Psi_j = A^j$: $\Psi_1 = A$ y $\Psi_2 = A^2 = \begin{pmatrix} 0,25 + 0,02 & 0,05 + 0,04 \\ 0,10 + 0,08 & 0,02 + 0,16 \end{pmatrix} = \begin{pmatrix} 0,27 & 0,09 \\ 0,18 & 0,18 \end{pmatrix}$. El efecto de un shock en u_π sobre x dos períodos después es 0,18 (por unidad).

Ejercicio 9.2. Cuenta los parámetros de la media de un VAR con $n = 4, p = 2$ y con $n = 8, p = 4$, y compara con $T = 100$ observaciones por ecuación.

💡 Solución 9.2

Por ecuación hay $1 + np$ coeficientes. $n = 4, p = 2$: 9 por ecuación, 36 en total (más 10 en Σ_u); con $T = 100$, son $100/9 \approx 11$ observaciones por parámetro: razonable. $n = 8, p = 4$: $1 + 32 = 33$ por ecuación, 264 en total (más 36); con $T = 100$ quedan $100/33 \approx 3$ observaciones por parámetro: el estimador de MCO tiene varianzas enormes y el sobreajuste es severo. El número crece como pn^2 : duplicar las variables cuadruplica los parámetros.

Ejercicio 9.3. Con $n = 2$ y $T = 200$, los determinantes de las matrices de covarianza residual son $\log |\hat{\Sigma}(1)| = -1,20$, $\log |\hat{\Sigma}(2)| = -1,30$ y $\log |\hat{\Sigma}(3)| = -1,32$. ¿Qué eligen AIC y BIC?

💡 Solución 9.3

Penalizaciones: AIC: $2pn^2/T = 0,04p$. BIC: $pn^2 \log T/T = p \cdot 4 \cdot 5,298/200 = 0,106p$. AIC: $p = 1: -1,16; p = 2: -1,22; p = 3: -1,20 \Rightarrow$ **AIC elige** $p = 2$. BIC: $p = 1: -1,094; p = 2: -1,088; p = 3: -1,002 \Rightarrow$ **BIC elige** $p = 1$. Es el patrón habitual: BIC prefiere el modelo más corto. Un LR de $p = 1$ contra $p = 2$ da $200(1,30 - 1,20) = 20$, que supera el crítico $\chi_4^2 = 9,49$ (Ejercicio 9.4): el segundo rezago es significativo.

Ejercicio 9.4. Con los datos del ejercicio anterior, calcula el test

LR de $H_0 : p = 1$ frente a $p = 2$ y la versión corregida de Sims.

💡 Solución 9.4

El VAR(2) añade $n^2 = 4$ coeficientes (una matriz A_2 de 2×2), de modo que hay $q = 4$ restricciones. $LR = T[\log |\hat{\Sigma}(1)| - \log |\hat{\Sigma}(2)|] = 200(-1,20 + 1,30) = 20,0$. Crítico $\chi^2_{4,0,95} = 9,49$: se rechaza $p = 1$. Con la corrección de Sims, $c = 1 + 2 \cdot 2 = 5$ parámetros por ecuación en el modelo sin restringir ($T - c = 195$): $195 \cdot 0,10 = 19,5$. La conclusión no cambia. Esto es consistente con AIC y contradice a BIC: la elección de p depende del criterio.

Ejercicio 9.5. En un VAR(2) bivariado, la ecuación de y tiene coeficientes de x iguales a 0,3 y $-0,1$ y el test de Wald de $H_0 : a_1^{yx} = a_2^{yx} = 0$ da $W = 11,2$. Concluye y explica qué **no** se puede concluir.

💡 Solución 9.5

$W \sim \chi^2_2$ bajo la nula, con crítico 5,99 al 5 %: $11,2 > 5,99$ y se **rechaza** la no causalidad de Granger de x hacia y : el pasado de x ayuda a predecir y . **No** se puede concluir que x cause a y en sentido estructural: puede haber una tercera variable omitida, x puede anticipar y por expectativas, etc. Tampoco se dice nada de la relación contemporánea. Para saber si y **causa a** x (causalidad inversa) hay que hacer el test análogo en la ecuación de x : puede haber causalidad en ambos sentidos (retroalimentación).

Ejercicio 9.6. Para el VAR(1) del Ejercicio 9.1 con $\Sigma_u = I_2$, calcula la matriz de ECM de pronóstico a $h = 1$ y $h = 2$ pasos.

💡 Solución 9.6

$\Sigma_y(1) = \Psi_0 \Sigma_u \Psi_0' = I_2$. $\Sigma_y(2) = I + A A'$ con $AA' = \begin{pmatrix} 0,25 + 0,01 & 0,10 + 0,04 \\ 0,10 + 0,04 & 0,04 + 0,16 \end{pmatrix} = \begin{pmatrix} 0,26 & 0,14 \\ 0,14 & 0,20 \end{pmatrix}$. Luego $\Sigma_y(2) = \begin{pmatrix} 1,26 & 0,14 \\ 0,14 & 1,20 \end{pmatrix}$. La varianza del error del primer

componente a dos pasos es 1,26 (frente a 1 a un paso). Los errores de pronóstico a dos pasos de las dos variables están correlacionados (0,14) aunque los shocks no lo estén.

Ejercicio 9.7 ★. Para un AR(2) escalar, escribe la matriz companion y muestra que sus autovalores satisfacen $\lambda^2 - \phi_1\lambda - \phi_2 = 0$ y que son los recíprocos de las raíces de $\phi(z) = 1 - \phi_1z - \phi_2z^2$.

💡 Solución 9.7 ★

$$F = \begin{pmatrix} \phi_1 & \phi_2 \\ 1 & 0 \end{pmatrix}. \det(\lambda I - F) = (\lambda - \phi_1)\lambda - \phi_2 = \lambda^2 - \phi_1\lambda - \phi_2.$$

Si $z \neq 0$ es raíz de ϕ , $1 - \phi_1z - \phi_2z^2 = 0$; dividiendo por z^2 y escribiendo $\lambda = 1/z$: $\lambda^2 - \phi_1\lambda - \phi_2 = 0$. Entonces $\lambda = 1/z$ es autovalor de F . El proceso es estacionario si y solo si $|\lambda| < 1$ para ambos, es decir $|z| > 1$ para las dos raíces: la condición de la Clase 2. Ejemplo: $\phi = (0,5, 0,3)$: $\lambda^2 - 0,5\lambda - 0,3 = 0 \Rightarrow \lambda = (0,5 \pm \sqrt{1,45})/2 = 0,852, -0,352$; sus recíprocos son 1,173 y $-2,84$, que son las raíces de $\phi(z)$ de la Clase 2 (Ejercicio 2.1).