

Clase 13 · Espacio de estados y filtro de Kalman

Estados no observados, filtrado, verosimilitud y descomposición tendencia-ciclo

Contenido

1	Cuando lo que importa no se observa	2
2	El modelo de espacio de estados	2
2.1	El modelo de nivel local	3
3	El filtro de Kalman	4
3.1	Nivel local: el filtro en forma cerrada	6
4	Verosimilitud y estimación de parámetros	6
5	El suavizador	7
6	Otros modelos como espacio de estados	8
6.1	ARMA	8
6.2	Tendencia local lineal y el filtro de Hodrick–Prescott	8
7	★ Postgrado: convergencia del filtro al estado estacionario	9
8	Resumen	10
9	Ejercicios	11

1. Cuando lo que importa no se observa

Muchas variables que interesan a la economía **no se observan**: la tendencia del producto (el PIB potencial), la inflación subyacente, el nivel “verdadero” de la tasa de interés neutral, la volatilidad de un activo (Clase 12), el estado de la economía en un modelo DSGE. Lo que se observa son **señales ruidosas** de ellas. Los **modelos de espacio de estados** son el lenguaje común para estos problemas: dos ecuaciones, una que describe cómo **evoluciona** el estado oculto y otra que dice cómo se **mide**.¹ Y el **filtro de Kalman** es el algoritmo que, a cada fecha, **estima el estado a partir de lo observado**, de manera recursiva y óptima.

2. El modelo de espacio de estados

Definición 2.1 (Modelo lineal gaussiano de espacio de estados). Sea y_t ($p \times 1$) la serie observada y α_t ($m \times 1$) el **estado** no observado:

$$y_t = Z\alpha_t + d + \varepsilon_t, \quad \varepsilon_t \sim N(0, H) \quad (\text{ecuación de medición}),$$
$$\alpha_{t+1} = T\alpha_t + c + R\eta_t, \quad \eta_t \sim N(0, Q) \quad (\text{ecuación de transición}),$$

con ε_t, η_t independientes entre sí y en el tiempo, y estado inicial $\alpha_1 \sim N(a_1, P_1)$. Las matrices Z, T, R, H, Q, d, c pueden depender de t (y de un vector de parámetros ψ a estimar).

La **ecuación de medición** dice que lo observado es una función lineal del estado más ruido. La **de transición** es un VAR(1) para el estado (cualquier proceso con más rezagos se reduce a este caso apilando, como la forma companion de la Clase 9). Con esta estructura entran como casos particulares:

- **Nivel local y tendencia local lineal** (abajo).
- **ARMA** (se escribe en espacio de estados, §).
- **Componentes no observados**: tendencia + ciclo + estacionalidad + ruido.
- **Regresión con coeficientes variables en el tiempo**: $y_t = x_t'\beta_t + \varepsilon_t$ con $\beta_{t+1} = \beta_t + \eta_t$ ($Z_t = x_t'$, estado = β_t).
- **Modelos de factores dinámicos** (pocos factores latentes que generan muchas series), y la solución linealizada de un modelo **DSGE**.

¹ Rudolf Kálmán publicó el filtro en 1960, en el contexto de ingeniería de control. Una de sus primeras aplicaciones importantes fue la navegación del programa Apolo, donde había que estimar la posición de una nave a partir de mediciones ruidosas de radar y sensores. Que el mismo algoritmo se use hoy para estimar la tendencia del PIB, o el precio de un derivado, es una muestra de lo general que resulta la idea de “estimar un estado oculto a partir de señales ruidosas”.

2.1. El modelo de nivel local

El ejemplo más simple y más instructivo es un nivel que **vaga** como caminata aleatoria, observado con ruido:

$$y_t = \mu_t + \varepsilon_t, \quad \varepsilon_t \sim N(0, \sigma_\varepsilon^2); \quad \mu_{t+1} = \mu_t + \eta_t, \quad \eta_t \sim N(0, \sigma_\eta^2). \quad (1)$$

Aquí $Z = T = R = 1, H = \sigma_\varepsilon^2, Q = \sigma_\eta^2$. El cociente $q = \sigma_\eta^2 / \sigma_\varepsilon^2$ es la **razón señal-ruido**: cuánto se mueve el nivel verdadero respecto del ruido de medición.

Proposición 2.1 (El nivel local es un ARIMA(0,1,1)). *En el modelo Ecuación 1, la serie y_t es $I(1)$ y su primera diferencia es un **MA(1)** con $\theta \in (-1, 0]$ que satisface*

$$\frac{\theta}{1 + \theta^2} = -\frac{\sigma_\varepsilon^2}{2\sigma_\varepsilon^2 + \sigma_\eta^2}, \quad \theta = \frac{-(q + 2) + \sqrt{q^2 + 4q}}{2}.$$

Demostración. $\Delta y_t = \Delta \mu_t + \Delta \varepsilon_t = \eta_{t-1} + \varepsilon_t - \varepsilon_{t-1}$. Es una suma de procesos MA estacionarios, así que es estacionario con $\gamma(0) = \sigma_\eta^2 + 2\sigma_\varepsilon^2, \gamma(1) = -\sigma_\varepsilon^2$ (el único término común entre Δy_t y Δy_{t-1} es ε_{t-1} , con signos opuestos), y $\gamma(h) = 0$ para $h \geq 2$. Un proceso estacionario con autocovarianzas que se anulan después del rezago 1 es un MA(1) (Clase 2), con $\rho(1) = \gamma(1)/\gamma(0) = -\sigma_\varepsilon^2 / (\sigma_\eta^2 + 2\sigma_\varepsilon^2) = \theta / (1 + \theta^2)$. Dividiendo numerador y denominador por σ_ε^2 : $\theta / (1 + \theta^2) = -1 / (q + 2)$, es decir $(q + 2)\theta = -(1 + \theta^2)$, o bien $\theta^2 + (q + 2)\theta + 1 = 0$. Las dos raíces de esta cuadrática son recíprocas entre sí (su producto es 1); eligiendo la invertible ($|\theta| < 1$) se obtiene $\theta = [-(q + 2) + \sqrt{(q + 2)^2 - 4}] / 2 = [-(q + 2) + \sqrt{q^2 + 4q}] / 2$. $\square$

Con $q = 1$ ($\sigma_\eta^2 = \sigma_\varepsilon^2$): $\theta = (-3 + \sqrt{5}) / 2 = -0,382$ y $\rho(1) = -1/3$. Cuando $q \rightarrow 0$ (el nivel casi no se mueve), $\theta \rightarrow -1$ (**sobrediferenciación**: Δy_t es casi un MA(1) con raíz unitaria, Clase 6); cuando $q \rightarrow \infty$ (el ruido de medición es despreciable), $\theta \rightarrow 0$ y y_t es casi una caminata aleatoria pura. El resultado dice que **un ARIMA(0,1,1) puede interpretarse como un nivel verdadero observado con error**. Y el pronóstico óptimo a un paso de un ARIMA(0,1,1) es la **media móvil exponencialmente ponderada** (EWMA): $\hat{y}_{t+1|t} = (1 + \theta)y_t - \theta\hat{y}_{t|t-1}$ (Muth, 1960), con peso $-\theta$ en el pronóstico anterior (Ejercicio 13.1).

3. El filtro de Kalman

Objetivo: dados $y_1, \dots, y_t$, calcular el mejor estimador del estado. Definimos, para el modelo Definición 2.1,

$$a_t = \mathbb{E}[\alpha_t | Y_{t-1}], \quad P_t = \text{Var}(\alpha_t | Y_{t-1}), \quad a_{t|t} = \mathbb{E}[\alpha_t | Y_t], \quad P_{t|t} = \text{Var}(\alpha_t | Y_t),$$

con $Y_t = (y_1, \dots, y_t)$. Los a_t, P_t son el estado **predicho** (usando información hasta $t-1$) y los $a_{t|t}, P_{t|t}$ el estado **filtrado** (usando también y_t). Como todo es **normal**, la distribución condicional queda determinada por media y varianza, y la recursión se obtiene del siguiente hecho.

Lema 3.1 (Condicionamiento en una normal conjunta). Si $(x', w')'$ es normal con $\mathbb{E}x = \mu_x$, $\mathbb{E}w = \mu_w$ y matrices de covarianza $\Sigma_{xx}, \Sigma_{xw}, \Sigma_{ww}$ (Σ_{ww} invertible), entonces $x | w \sim N(\mu_{x|w}, \Sigma_{x|w})$ con

$$\mu_{x|w} = \mu_x + \Sigma_{xw}\Sigma_{ww}^{-1}(w - \mu_w), \quad \Sigma_{x|w} = \Sigma_{xx} - \Sigma_{xw}\Sigma_{ww}^{-1}\Sigma_{wx}.$$

Demostración. Sea $e = x - \mu_x - \Sigma_{xw}\Sigma_{ww}^{-1}(w - \mu_w)$. Entonces $\text{Cov}(e, w) = \Sigma_{xw} - \Sigma_{xw}\Sigma_{ww}^{-1}\Sigma_{ww} = 0$. Como (e, w) son conjuntamente normales y no correlacionados, son **independientes** (Clase 5 de Econometría 1). Entonces $x = \mu_{x|w} + e$ con e independiente de w y $e \sim N(0, \Sigma_{x|w})$, donde $\text{Var}(e) = \Sigma_{xx} - \Sigma_{xw}\Sigma_{ww}^{-1}\Sigma_{wx}$. Condicionando en w queda la distribución enunciada. $\square$

Teorema 3.1 (Filtro de Kalman). Para el modelo Definición 2.1, con a_1, P_1 dados, se definen para $t = 1, \dots, T$ el **error de predicción** $v_t = y_t - Za_t - d$ con varianza $F_t = ZP_tZ' + H$, y las recursiones

$$\textbf{Actualización:} \quad a_{t|t} = a_t + P_tZ'F_t^{-1}v_t, \quad P_{t|t} = P_t - P_tZ'F_t^{-1}ZP_t,$$

$$\textbf{Predicción:} \quad a_{t+1} = Ta_{t|t} + c, \quad P_{t+1} = TP_{t|t}T' + RQR'.$$

Equivalentemente, $a_{t+1} = Ta_t + c + K_tv_t$ con la **ganancia de Kalman** $K_t = TP_tZ'F_t^{-1}$. Además, los errores de predicción v_t son **independientes** entre sí, con $v_t \sim N(0, F_t)$.

Borrador

La recursión tiene dos pasos. **Predicción:** conozco la distribución del estado hoy dado Y_{t-1} , $N(a_t, P_t)$; antes de ver y_t ya puedo predecir lo que veré: $y_t = Z\alpha_t + d + \varepsilon_t$ es normal con media $Za_t + d$ y varianza $ZP_tZ' + H$. **Actualización:** observo y_t ; el estado y la observación son conjuntamente normales (dado Y_{t-1}), con covarianza $\text{Cov}(\alpha_t, y_t) = P_tZ'$. El lema de condicionamiento me da $\alpha_t \mid y_t, Y_{t-1}$, que es la distribución filtrada. Después, la ecuación de transición pasa de α_t a α_{t+1} .

Demostración. Supongamos $\alpha_t \mid Y_{t-1} \sim N(a_t, P_t)$ (cierto para $t = 1$ por supuesto). Dado Y_{t-1} , el vector (α_t, y_t) es normal con medias $(a_t, Za_t + d)$ y covarianzas $\text{Var}(\alpha_t) = P_t$, $\text{Cov}(\alpha_t, y_t) = P_tZ'$ (porque ε_t es independiente de α_t) y $\text{Var}(y_t) = ZP_tZ' + H = F_t$. Condicionar en $Y_t = (Y_{t-1}, y_t)$ equivale a condicionar en y_t dentro de la distribución ya condicionada en Y_{t-1} , y por el Lema 3.1,

$$\mathbb{E}[\alpha_t \mid Y_t] = a_t + P_tZ'F_t^{-1}(y_t - Za_t - d), \quad \text{Var}(\alpha_t \mid Y_t) = P_t - P_tZ'F_t^{-1}ZP_t.$$

Para la predicción, $\alpha_{t+1} = T\alpha_t + c + R\eta_t$ con η_t independiente de Y_t y de α_t : $\mathbb{E}[\alpha_{t+1} \mid Y_t] = Ta_{t|t} + c$ y $\text{Var}(\alpha_{t+1} \mid Y_t) = TP_{t|t}T' + RQR'$. Ya tenemos $\alpha_{t+1} \mid Y_t \sim N(a_{t+1}, P_{t+1})$: la inducción continúa. Finalmente, $v_t = y_t - \mathbb{E}[y_t \mid Y_{t-1}]$ es el error de predicción: es independiente de Y_{t-1} (en el caso normal, no correlacionado con Y_{t-1} implica independiente) y por lo tanto de $v_1, \dots, v_{t-1}$, que son función de Y_{t-1} . $\square$

Algunas observaciones. (i) La **actualización** tiene una lectura natural: se corrige la predicción a_t con el error de predicción v_t , **ponderado** por $P_tZ'F_t^{-1}$: cuanto más confiable la medición (menor H , menor F_t), mayor la corrección. (ii) **Sin normalidad**, el filtro entrega el mejor predictor **lineal** (proyección en L^2 , Clase 3) del estado, con el mismo ECM P_t (usa solo medias y varianzas). (iii) La varianza P_t **no depende de los datos**, solo de las matrices del sistema: puede calcularse de antemano.

3.1. Nivel local: el filtro en forma cerrada

Con $Z = T = 1$, $H = \sigma_\varepsilon^2$, $Q = \sigma_\eta^2$: $F_t = P_t + \sigma_\varepsilon^2$, $K_t = P_t / (P_t + \sigma_\varepsilon^2)$
y

$$a_{t+1} = a_t + K_t(y_t - a_t) = (1 - K_t)a_t + K_ty_t, \quad P_{t+1} = \frac{P_t\sigma_\varepsilon^2}{P_t + \sigma_\varepsilon^2} + \sigma_\eta^2. \quad (2)$$

La estimación del nivel es un **promedio ponderado** del valor anterior y el dato nuevo, con peso K_t en el dato. Si P_t es grande (mucho incertidumbre previa), $K_t \rightarrow 1$: se confía en el dato; si P_t es chica, $K_t \rightarrow 0$: se confía en la estimación anterior. Con P_t en estado estacionario P (la ecuación de Riccati $P^2 - \sigma_\eta^2 P - \sigma_\eta^2 \sigma_\varepsilon^2 = 0$), la ganancia es constante $K = P / (P + \sigma_\varepsilon^2)$ y el filtro es **exactamente la EWMA**, con $1 - K = -\theta$ (Ejercicio 13.1): el filtro de Kalman del nivel local es el pronóstico del ARIMA(0,1,1).

Ejemplo 3.1 (Dos pasos numéricos). Con $\sigma_\varepsilon^2 = \sigma_\eta^2 = 1$, $a_1 = 0$, $P_1 = 10$ (muy incierto) y datos $y_1 = 1,2$, $y_2 = 0,8$. **Paso 1:** $F_1 = 11$, $v_1 = 1,2$, $K_1 = 10/11 = 0,909$; $a_2 = 0 + 0,909 \cdot 1,2 = 1,091$, $P_2 = 10/11 + 1 = 1,909$. **Paso 2:** $F_2 = 2,909$, $v_2 = 0,8 - 1,091 = -0,291$, $K_2 = 1,909/2,909 = 0,656$; $a_3 = 1,091 - 0,656 \cdot 0,291 = 0,900$, $P_3 = 1,909/2,909 + 1 = 1,656$. La incertidumbre cae de 10 a 1,66 (converge a $P = 1,618$) y la ganancia, de 0,91 a 0,66 (converge a 0,618). El filtro “aprende” cuánto confiar en los datos.

4. Verosimilitud y estimación de parámetros

Los parámetros del sistema ($\sigma_\varepsilon^2, \sigma_\eta^2$, y los de $T, Z, \dots$) se estiman por **máxima verosimilitud**. La clave es la **descomposición por errores de predicción** de la Clase 4 (proposición de verosimilitud por innovaciones): la densidad conjunta de $(y_1, \dots, y_T)$ se factoriza como producto de las densidades condicionales $y_t | Y_{t-1} \sim N(Za_t + d, F_t)$, y por lo tanto

$$\ell(\psi) = -\frac{Tp}{2} \log 2\pi - \frac{1}{2} \sum_{t=1}^T [\log |F_t| + v_t' F_t^{-1} v_t],$$

donde v_t, F_t se calculan con el filtro. Es la misma fórmula de la Clase 4 con $F_t = v_{t-1}$ (la varianza del error de predicción): **el filtro de Kalman es el algoritmo de $O(T)$** que esa clase prometía. Se maximiza numéricamente sobre ψ con el filtro como subrutina; las propiedades asintóticas son las de la MV (Clase 2 de Econometría 2), salvo en la **frontera**: si el verdadero $\sigma_\eta^2 = 0$ (nivel determinístico), el estimador se “pega” en cero con probabilidad positiva y la distribución del LR no es χ^2 (Clase 3 de Econometría 2, ejercicio 3.7). Para la inicialización con **estados no estacionarios** (como el nivel, que no tiene distribución estacionaria), se usa un a priori **difuso** ($P_1 = \kappa I$ con $\kappa \rightarrow \infty$), tratado exactamente por el filtro difuso de Koopman.

Un beneficio práctico enorme: los **datos faltantes** se manejan con naturalidad. Si y_t no se observa, se **omite el paso de actualización** y se hace solo la predicción ($a_{t+1} = Ta_t + c$, $P_{t+1} = TP_tT' + RQR'$): la incertidumbre sobre el estado **crece** durante el hueco y vuelve a bajar cuando reaparecen datos. En el ejemplo anterior, si y_2 faltara: $a_3 = a_2 = 1,091$ y $P_3 = P_2 + \sigma_\eta^2 = 2,909$ (en vez de 1,656). Esto permite trabajar con series de frecuencias mixtas (mensuales y trimestrales), con observaciones irregulares y con *nowcasting*.

5. El suavizador

El filtro usa solo **información pasada**: $a_{t|t} = \mathbb{E}[\alpha_t | Y_t]$. Para estimar el estado histórico (la tendencia de los últimos 20 años) se quiere usar **toda** la muestra: $\hat{\alpha}_t = \mathbb{E}[\alpha_t | Y_T]$. El **suavizador de Kalman** lo obtiene con una recursión hacia atrás (Rauch-Tung-Striebel; Durbin-Koopman): con $L_t = T - K_tZ$ y $r_T = 0$,

$$r_{t-1} = Z'F_t^{-1}v_t + L_t'r_t, \quad \hat{\alpha}_t = a_t + P_t r_{t-1} \quad (t = T, \dots, 1),$$

más una recursión análoga para la varianza suavizada (se toman prestadas). La intuición: r_{t-1} acumula la información **de los errores de predicción futuros** que es relevante para α_t . El estimador suavizado tiene **menor varianza** que el filtrado ($\text{Var}(\alpha_t | Y_T) \leq \text{Var}(\alpha_t | Y_t)$, porque se condiciona en más información) y es **más suave** en el tiempo; pero no es utilizable en tiempo real, y se **revisa** cada vez que llega un dato nuevo (el problema de las revisiones del PIB potencial).

6. Otros modelos como espacio de estados

6.1. ARMA

Cualquier ARMA se escribe en espacio de estados. Para el ARMA(1,1) $y_t = \phi y_{t-1} + \varepsilon_t + \theta \varepsilon_{t-1}$, tomemos el estado $\alpha_t = (y_t, \theta \varepsilon_t)'$ y

$$y_t = (1 \ 0) \alpha_t, \quad \alpha_{t+1} = \begin{pmatrix} \phi & 1 \\ 0 & 0 \end{pmatrix} \alpha_t + \begin{pmatrix} 1 \\ \theta \end{pmatrix} \varepsilon_{t+1},$$

con $H = 0$ (sin ruido de medición) y $Q = \sigma^2$. Verificación: la primera fila da $y_{t+1} = \phi y_t + \theta \varepsilon_t + \varepsilon_{t+1}$ y la segunda, $\alpha_{2,t+1} = \theta \varepsilon_{t+1}$. Esto permite evaluar la verosimilitud exacta de un ARMA con el filtro de Kalman en $O(T)$ (el cálculo que la Clase 4 llamó “por innovaciones”), y manejar ARMA con datos faltantes.

6.2. Tendencia local lineal y el filtro de Hodrick–Prescott

Una tendencia con **pendiente** que también cambia: $y_t = \mu_t + \varepsilon_t$, $\mu_{t+1} = \mu_t + \beta_t + \eta_t$, $\beta_{t+1} = \beta_t + \zeta_t$. Si $\sigma_\eta^2 = 0$, la tendencia es una **caminata aleatoria integrada** (suave: la segunda diferencia de μ_t es un ruido blanco).

El **filtro de Hodrick–Prescott** (HP) es el más usado para separar tendencia y ciclo en macroeconomía: dada la serie y_t , la tendencia τ_t minimiza $\sum_t (y_t - \tau_t)^2 + \lambda \sum_t (\Delta^2 \tau_t)^2$, con λ el parámetro de suavidad (1600 para datos trimestrales). Aparece una conexión sorprendente.

Proposición 6.1 (HP es el suavizador de Kalman de una tendencia integrada). *Sea el modelo $y_t = \tau_t + \varepsilon_t$ con $\Delta^2 \tau_{t+1} = \zeta_t$, $\varepsilon_t \sim N(0, \sigma_\varepsilon^2)$ y $\zeta_t \sim N(0, \sigma_\zeta^2)$ (tendencia local lineal con $\sigma_\eta^2 = 0$). Entonces la **tendencia suavizada** $\mathbb{E}[\tau_t | Y_T]$ coincide con la tendencia HP con $\lambda = \sigma_\varepsilon^2 / \sigma_\zeta^2$.*

Demostración. Con un a priori difuso sobre las condiciones iniciales, la **densidad conjunta** de (y_t, τ_t) es proporcional a $\exp \{ -$

$\frac{1}{2\sigma_\varepsilon^2} \sum_t (y_t - \tau_t)^2 - \frac{1}{2\sigma_\zeta^2} \sum_t (\Delta^2 \tau_t)^2$ (los ε_t y ζ_t son normales independientes). En un modelo gaussiano, la **media condicional** $\mathbb{E}[\tau | Y_T]$ coincide con la **moda** de la densidad posterior de τ dado Y_T (la normal es simétrica y unimodal), que es el minimizador de $\frac{1}{2\sigma_\varepsilon^2} \sum_t (y_t - \tau_t)^2 + \frac{1}{2\sigma_\zeta^2} \sum_t (\Delta^2 \tau_t)^2$. Multiplicando por $2\sigma_\varepsilon^2$: minimizar $\sum_t (y_t - \tau_t)^2 + (\sigma_\varepsilon^2/\sigma_\zeta^2) \sum_t (\Delta^2 \tau_t)^2$, que es el problema de HP con $\lambda = \sigma_\varepsilon^2/\sigma_\zeta^2$. $\square$

Esto da a HP una **interpretación estadística**: $\lambda = 1600$ equivale a suponer una razón $\sigma_\zeta^2/\sigma_\varepsilon^2 = 1/1600 = 0,000625$ entre la varianza del cambio de la pendiente y la del ciclo (Ejercicio 13.4). También revela sus **limitaciones**: el HP es óptimo solo si la serie sigue exactamente ese modelo (que no es el caso de una serie con raíz unitaria + ciclo persistente), y puede generar **ciclos espurios** (Cogley y Nason, 1995; Hamilton, 2018). Los modelos de **componentes no observados** de Harvey estiman $\sigma_\varepsilon^2, \sigma_\zeta^2$ y los parámetros del ciclo **por máxima verosimilitud**, en vez de fijar λ a mano.

7. ★ Postgrado: convergencia del filtro al estado estacionario

! ★ Postgrado

En el nivel local, la varianza P_t del estado converge **geométricamente** a un punto fijo P independiente de P_1 . Es una versión simple del resultado general (para sistemas **estabilizables y detectables**, la ecuación de Riccati tiene una solución estable única).

Proposición 7.1 (Convergencia de P_t en el nivel local). *La recursión $P_{t+1} = f(P_t)$ con $f(P) = \frac{P\sigma_\varepsilon^2}{P + \sigma_\varepsilon^2} + \sigma_\eta^2$ tiene un único punto fijo positivo,*

$$P = \frac{\sigma_\eta^2 + \sqrt{\sigma_\eta^4 + 4\sigma_\eta^2\sigma_\varepsilon^2}}{2},$$

y para todo $P_1 \geq 0$, $P_t \rightarrow P$ a velocidad **geométrica** de razón $f'(P) = \sigma_\varepsilon^4 / (P + \sigma_\varepsilon^2)^2 < 1$.

Demostración. La ecuación $f(P) = P$ es $P\sigma_\varepsilon^2 + \sigma_\eta^2(P + \sigma_\varepsilon^2) = P(P + \sigma_\varepsilon^2)$, es decir $P^2 - \sigma_\eta^2 P - \sigma_\eta^2 \sigma_\varepsilon^2 = 0$, con una única raíz positiva (el producto de las raíces es negativo): la expresión del enunciado. La derivada es $f'(P) = \sigma_\varepsilon^4 / (P + \sigma_\varepsilon^2)^2$, que para todo $P \geq 0$ está en $(0, 1]$ y es **estrictamente menor que 1** para $P > 0$ (porque $P + \sigma_\varepsilon^2 > \sigma_\varepsilon^2$). Como $\sigma_\eta^2 > 0$, $P_t > 0$ para $t \geq 2$, y en $[\sigma_\eta^2, \infty)$ (donde viven P_t , $t \geq 2$) $|f'| \leq \sigma_\varepsilon^4 / (\sigma_\eta^2 + \sigma_\varepsilon^2)^2 < 1$: f es una **contracción** de constante $\rho < 1$. Por el teorema del punto fijo de Banach, $|P_t - P| \leq \rho^{t-2} |P_2 - P| \rightarrow 0$ geoméricamente. $\square$

Para $\sigma_\varepsilon^2 = \sigma_\eta^2 = 1$: $P = (1 + \sqrt{5})/2 = 1,618$, $K = 0,618$, y $f'(P) = 1/(2,618)^2 = 0,146$: el error de P_t se reduce 85 % cada período (Ejercicio 13.7). Por eso en la práctica el filtro alcanza el estado estacionario en pocas observaciones y se puede usar la **ganancia constante** (EWMA). Y por eso, también, el filtro “olvida” la inicialización a_1, P_1 rápidamente.

8. Resumen

- **Espacio de estados:** $y_t = Z\alpha_t + d + \varepsilon_t$ (medición), $\alpha_{t+1} = T\alpha_t + c + R\eta_t$ (transición). Incluye ARMA, componentes no observados, regresiones con parámetros variables y factores (Definición 2.1).
- **Nivel local:** equivale a un **ARIMA(0,1,1)** con $\theta = [-(q + 2) + \sqrt{q^2 + 4q}]/2$ (Proposición 2.1); su pronóstico es la EWMA.
- **Filtro de Kalman** (Teorema 3.1): predicción más actualización con la ganancia $K_t = TP_t Z' F_t^{-1}$, derivado del condicionamiento en una normal conjunta (Lema 3.1). Sin normalidad es el mejor predictor **lineal**.
- **Verosimilitud** por errores de predicción: $\ell = -\frac{1}{2} \sum [\log |F_t| + v_t' F_t^{-1} v_t]$. Maneja **datos faltantes** (omitir la actualización).
- **Suavizador:** usa toda la muestra; menor varianza que el filtro pero con revisiones.

- **HP** es el suavizador de una tendencia integrada con $\lambda = \sigma_\varepsilon^2 / \sigma_\zeta^2$ (Proposición 6.1). P_t **converge** geométricamente (Proposición 7.1).

9. Ejercicios

Ejercicio 13.1. En el nivel local con $\sigma_\varepsilon^2 = \sigma_\eta^2 = 1$, calcula θ , $\rho(1)$ de Δy_t , el estado estacionario P , la ganancia K y comprueba que $1 - K = -\theta$.

💡 Solución 13.1

$q = 1$: $\theta = (-3 + \sqrt{1+4})/2 = (-3 + 2,236)/2 = -0,382$.
 $\rho(1) = -1/(q+2) = -1/3$; verificación: $\theta/(1+\theta^2) = -0,382/1,146 = -0,333$ ✓. Estado estacionario: $P^2 - P - 1 = 0 \Rightarrow P = (1 + \sqrt{5})/2 = 1,618$. $K = P/(P+1) = 1,618/2,618 = 0,618$. $1 - K = 0,382 = -\theta$ ✓. La EWMA del filtro asigna el peso 0,618 al dato nuevo y 0,382 a la estimación previa: coincide con el pronóstico de un ARIMA(0,1,1) con $\theta = -0,382$ (peso $-\theta$ en el pronóstico anterior).

Ejercicio 13.2. Con los datos del Ejemplo 3.1, supón que y_2 no se observa. Calcula a_3 y P_3 y compara con el caso en que sí se observa.

💡 Solución 13.2

Sin y_2 : no hay actualización, solo predicción: $a_3 = a_2 = 1,091$ y $P_3 = P_2 + \sigma_\eta^2 = 1,909 + 1 = 2,909$. Con y_2 : $a_3 = 0,900$ y $P_3 = 1,656$. El dato faltante deja la estimación en 1,091 (sin corrección) y una incertidumbre de 2,909 (frente a 1,656): se paga la falta de información con mayor varianza de la estimación, pero el filtro **no se detiene** ni requiere imputar.

Ejercicio 13.3. Calcula las contribuciones ℓ_1 y ℓ_2 a la log-verosimilitud en el Ejemplo 3.1 y su suma.

 Solución 13.3

$\ell_t = -\frac{1}{2}[\log(2\pi F_t) + v_t^2/F_t]$. $t = 1$: $F_1 = 11$, $v_1 = 1,2$: $\log(2\pi \cdot 11) = 4,236$ y $v_1^2/F_1 = 1,44/11 = 0,131$: $\ell_1 = -\frac{1}{2}(4,367) = -2,183$. $t = 2$: $F_2 = 2,909$, $v_2 = -0,291$: $\log(2\pi \cdot 2,909) = 2,906$ y $v_2^2/F_2 = 0,0846/2,909 = 0,029$: $\ell_2 = -\frac{1}{2}(2,935) = -1,467$. Suma: $-3,651$. Para estimar $\sigma_\varepsilon^2, \sigma_\eta^2$ se maximizaría esta suma (sobre todos los t de la muestra) variando los parámetros que entran en F_t y v_t .

Ejercicio 13.4. Calcula la razón $\sigma_\zeta^2/\sigma_\varepsilon^2$ implícita en $\lambda = 1600$ (trimestral) y $\lambda = 100$ (anual). ¿Cuántas desviaciones estándar del ciclo equivale la desviación estándar del cambio de la pendiente en el caso trimestral?

 Solución 13.4

$\lambda = \sigma_\varepsilon^2/\sigma_\zeta^2 \Rightarrow \sigma_\zeta^2/\sigma_\varepsilon^2 = 1/\lambda$: trimestral, $1/1600 = 0,000625$; anual, $1/100 = 0,01$. Trimestral: $\sigma_\zeta/\sigma_\varepsilon = \sqrt{0,000625} = 0,025$: el cambio de la pendiente de la tendencia tiene una desviación estándar de 2,5 % de la del ciclo (la pendiente casi no cambia: tendencia muy suave). Anual: 0,1 (más cambios, dado que λ es menor). Notar que λ **no es un parámetro con significado económico**: es la razón de dos varianzas que el econometrista no estima, sino que fija por convención.

Ejercicio 13.5. Para el ARMA(1,1) con $\phi = 0,5$ y $\theta = 0,4$ en espacio de estados, con $\alpha_t = (y_t, 0,4\varepsilon_t)'$: si $y_t = 2$, $\varepsilon_t = 1$ y llega $\varepsilon_{t+1} = 0,5$, calcula α_{t+1} y verifica que y_{t+1} coincide con la ecuación ARMA.

 Solución 13.5

$\alpha_t = (2, 0,4)'$. $\alpha_{t+1} = \begin{pmatrix} 0,5 & 1 \\ 0 & 0 \end{pmatrix} \begin{pmatrix} 2 \\ 0,4 \end{pmatrix} + \begin{pmatrix} 1 \\ 0,4 \end{pmatrix} 0,5 = \begin{pmatrix} 1 + 0,4 \\ 0 \end{pmatrix} + \begin{pmatrix} 0,5 \\ 0,2 \end{pmatrix} = \begin{pmatrix} 1,9 \\ 0,2 \end{pmatrix}$. Entonces $y_{t+1} = 1,9$. Por la ecuación ARMA: $y_{t+1} = 0,5 \cdot 2 + 0,5 + 0,4 \cdot 1 = 1 + 0,5 + 0,4 =$

1,9. La segunda componente del estado, $0,2 = 0,4 \cdot \varepsilon_{t+1}$, guarda el término MA para el período siguiente.

Ejercicio 13.6. Para $\sigma_\varepsilon^2 = 1$ y $\sigma_\eta^2 = 0,1$, calcula P , K y la “memoria efectiva” del filtro ($1/K$ observaciones). Compara con $\sigma_\eta^2 = 1$.

 Solución 13.6

$\sigma_\eta^2 = 0,1$: $P = (0,1 + \sqrt{0,01 + 0,4})/2 = (0,1 + 0,640)/2 = 0,370$. $K = 0,370/1,370 = 0,270$; memoria efectiva $1/K = 3,7$ observaciones. Con $\sigma_\eta^2 = 1$: $K = 0,618$ y memoria 1,6. Cuando el nivel se mueve poco respecto del ruido de medición (q chico), el filtro **promedia más** (mayor memoria) para sacar el ruido: razonable, porque cada dato nuevo informa poco sobre un nivel que cambia despacio.

Ejercicio 13.7 ★. Para $\sigma_\varepsilon^2 = \sigma_\eta^2 = 1$ y $P_1 = 10$, itera la recursión de P_t cuatro pasos y verifica que el error $|P_t - P|$ se reduce según la razón $f'(P) = 0,146$.

 Solución 13.7 ★

$f(P) = P/(P + 1) + 1$. $P_1 = 10$; $P_2 = 10/11 + 1 = 1,9091$; $P_3 = 1,9091/2,9091 + 1 = 1,6563$; $P_4 = 1,6563/2,6563 + 1 = 1,6235$; $P_5 = 1,6235/2,6235 + 1 = 1,6189$. Límite $P = 1,6180$. Errores: $P_2 - P = 0,2911$; $P_3 - P = 0,0383$; $P_4 - P = 0,0055$; $P_5 - P = 0,0009$. Cocientes sucesivos de errores: 0,13, 0,14, 0,14, valores cercanos a $f'(P) = 0,146$ (el primer paso, desde $P_1 = 10$, parte lejos del punto fijo y por eso reduce el error más de lo que sugiere la derivada local). En cuatro iteraciones el error cae de 8,4 a 0,001: el filtro alcanza su ganancia de estado estacionario casi inmediatamente.