

Clase 1 · Resultados potenciales y experimentos

El modelo de Rubin, el problema fundamental de la
inferencia causal y la aleatorización

Contenido

1	De la correlación a la causa	2
2	El modelo de resultados potenciales	2
2.1	Parámetros causales	3
3	La diferencia ingenua y el sesgo de selección	4
4	Aleatorización	5
4.1	Inferencia de Neyman en una población finita . . .	6
5	Regresión en un experimento	8
5.1	Estratificación	9
5.2	Potencia y tamaño muestral	9
5.3	Límites de los experimentos	9
6	★ Postgrado: el test de aleatorización de Fisher	10
7	Resumen	11
8	Ejercicios	12

1. De la correlación a la causa

En los tres cursos anteriores aprendimos a estimar **relaciones**: la esperanza condicional de y dado x , un coeficiente de proyección, un parámetro estructural de un modelo bien especificado. Pero la pregunta que motiva la mayor parte del trabajo aplicado es otra: **¿qué pasaría si cambiáramos x ?** ¿Cuánto más ganaría una persona si estudiara un año más? ¿Reduce una vacuna las hospitalizaciones? ¿Cuánto sube la matrícula si el Estado entrega becas? Son preguntas **causales**, y una correlación, por sofisticada que sea su estimación, no las responde por sí sola: las personas con más educación pueden ganar más porque estudiaron, o porque son más hábiles, o porque sus familias tienen contactos.

Esta clase introduce el lenguaje que la econometría moderna usa para plantear preguntas causales: el modelo de **resultados potenciales** (Neyman, 1923; Rubin, 1974). Su virtud es que **separa dos problemas** que suelen mezclarse: (1) *qué efecto queremos conocer* (la definición del parámetro causal) y (2) *bajo qué supuestos* los datos lo identifican. El experimento aleatorizado es el caso en que el segundo problema se resuelve por diseño. Las Clases 2 a 4 estudian qué hacer cuando no hay experimento.¹

2. El modelo de resultados potenciales

Considera una población de unidades i (personas, empresas, escuelas) y un **tratamiento binario** $D_i \in \{0, 1\}$ ($1 =$ recibe el tratamiento, $0 =$ no). Cada unidad tiene **dos resultados potenciales**:

- $Y_i(1)$: el resultado que la unidad i tendría **si fuera tratada**;
- $Y_i(0)$: el resultado que tendría **si no fuera tratada**.

El **efecto causal individual** es $\tau_i = Y_i(1) - Y_i(0)$. El resultado que **observamos** es

$$Y_i = D_i Y_i(1) + (1 - D_i) Y_i(0). \quad (1)$$

Es decir, vemos $Y_i(1)$ si $D_i = 1$ y $Y_i(0)$ si $D_i = 0$, pero **nunca ambos**.

¹ Jerzy Neyman introdujo los resultados potenciales en 1923, en una tesis sobre experimentos agrícolas, y los usó para calcular la varianza de un estimador de efectos de tratamientos en parcelas. Donald Rubin los generalizó en los años setenta a estudios observacionales, y por eso el marco lleva a veces el nombre de **modelo causal de Rubin**. La idea de que “causa” significa comparar lo que ocurrió con lo que habría ocurrido, un mundo contrafactual, es mucho más antigua en filosofía, pero Neyman y Rubin la convirtieron en un marco estadístico con nombre y apellido.

🔥 El problema fundamental de la inferencia causal (Holland, 1986)

Para cada unidad, **solo uno** de los dos resultados potenciales se observa. El efecto individual τ_i es **inobservable**, no por un problema de datos o de tamaño de muestra, sino por la naturaleza del problema: el contrafactual no existe. Toda la inferencia causal consiste en **suplir ese dato faltante** con supuestos o con diseño.

Este marco supone, de manera implícita, una condición que conviene hacer explícita.

Definición 2.1 (SUTVA (*stable unit treatment value assumption*)).

- (i) **No hay interferencia**: el resultado de la unidad i depende solo de su propio tratamiento, no del de las demás. (ii) **No hay versiones ocultas del tratamiento**: “tratado” significa lo mismo para todos.

Si SUTVA falla, los resultados potenciales no están bien definidos: $Y_i(1)$ ya no es un solo número, porque depende de quién más es tratado. Es lo que ocurre con **vacunas** (la protección de un individuo depende de cuánta gente alrededor está vacunada), con **programas de capacitación** que saturan el mercado laboral local, o con **efectos de pares** en una escuela. Se manejan redefiniendo la unidad (aleatorizar por escuela en vez de por alumno) o modelando explícitamente la interferencia. En lo que sigue, SUTVA se supone.

2.1. Parámetros causales

Como τ_i no se observa, se estudian **promedios** de efectos:

Definición 2.2 (Efectos promedio).

- **Efecto promedio del tratamiento (ATE)**: $\tau_{ATE} = \mathbb{E}[Y(1) - Y(0)]$.

- **Efecto promedio sobre los tratados (ATT):** $\tau_{ATT} = \mathbb{E}[Y(1) - Y(0) \mid D = 1]$.
- **Efecto promedio sobre los no tratados (ATU):** $\tau_{ATU} = \mathbb{E}[Y(1) - Y(0) \mid D = 0]$.
- **Efecto condicional (CATE):** $\tau(x) = \mathbb{E}[Y(1) - Y(0) \mid X = x]$.

El ATE responde “¿qué pasaría si **toda** la población fuera tratada frente a ninguna?” (relevante para una política universal); el ATT, “¿cuánto benefició el programa a quienes participaron?” (evaluación de un programa existente). Son distintos si el efecto es **heterogéneo** y los que se tratan son distintos de los que no. Con $\pi = P(D = 1)$, $\tau_{ATE} = \pi\tau_{ATT} + (1 - \pi)\tau_{ATU}$ (por la ley de esperanzas iteradas, Clase 2 de Econometría 1).

3. La diferencia ingenua y el sesgo de selección

La comparación más natural entre tratados y no tratados es la **diferencia de promedios observados**: $\mathbb{E}[Y \mid D = 1] - \mathbb{E}[Y \mid D = 0]$. ¿Qué mide?

Proposición 3.1 (Descomposición de la diferencia ingenua).

$$\underbrace{\mathbb{E}[Y \mid D = 1] - \mathbb{E}[Y \mid D = 0]}_{\text{diferencia observada}} = \underbrace{\tau_{ATT}}_{\text{efecto sobre tratados}} + \underbrace{\mathbb{E}[Y(0) \mid D = 1] - \mathbb{E}[Y(0) \mid D = 0]}_{\text{sesgo de selección}}.$$

Equivalentemente, $= \tau_{ATE} + \text{sesgo de selección} + (1 - \pi)(\tau_{ATT} - \tau_{ATU})$, donde el último término es el **sesgo de heterogeneidad**.

Demostración. Por (Ecuación 1), $\mathbb{E}[Y \mid D = 1] = \mathbb{E}[Y(1) \mid D = 1]$ y $\mathbb{E}[Y \mid D = 0] = \mathbb{E}[Y(0) \mid D = 0]$. Sumamos y restamos el término contrafactual $\mathbb{E}[Y(0) \mid D = 1]$ (que **no** es observable: es lo que los tratados habrían tenido sin tratamiento):

$$\mathbb{E}[Y(1) \mid D = 1] - \mathbb{E}[Y(0) \mid D = 0] = \{\mathbb{E}[Y(1) \mid D = 1] - \mathbb{E}[Y(0) \mid D = 1]\} + \{\mathbb{E}[Y(0) \mid D = 1] - \mathbb{E}[Y(0) \mid D = 0]\},$$

y la primera llave es τ_{ATT} . Para la segunda forma, de $\tau_{ATE} = \pi\tau_{ATT} + (1 - \pi)\tau_{ATU}$ se obtiene $\tau_{ATT} = \tau_{ATE} + (1 - \pi)(\tau_{ATT} - \tau_{ATU})$. $\square$

El **sesgo de selección** compara lo que los tratados *habrían* obtenido sin tratamiento con lo que obtienen los no tratados: si las personas que **eligen** estudiar (o recibir una terapia, o un crédito) son distintas, ese término no es cero. Típicamente quienes se tratan tienen peor (o mejor) resultado base: los pacientes que van al hospital están más enfermos que los que no van, de modo que la diferencia observada **subestima** (o hasta invierte el signo de) el efecto del hospital.

Ejemplo 3.1 (Un ejemplo numérico). Con $\mathbb{E}[Y \mid D = 1] = 70$, $\mathbb{E}[Y \mid D = 0] = 60$ y $\mathbb{E}[Y(0) \mid D = 1] = 65$ (los tratados habrían tenido 65 sin tratamiento): $\tau_{ATT} = 70 - 65 = 5$ y el sesgo de selección es $65 - 60 = 5$. La diferencia ingenua 10 **duplica** el efecto verdadero sobre los tratados. Si además $\pi = 0,4$ y $\tau_{ATU} = 3$, entonces $\tau_{ATE} = 0,4 \cdot 5 + 0,6 \cdot 3 = 3,8$ y el sesgo de heterogeneidad es $0,6(5 - 3) = 1,2$: $3,8 + 5 + 1,2 = 10$ $\square$.

4. Aleatorización

La manera más limpia de eliminar el sesgo de selección es **asignar el tratamiento al azar**.

Teorema 4.1 (Identificación en un experimento aleatorizado). Si $D \perp\!\!\!\perp (Y(0), Y(1))$ (el tratamiento se asigna independientemente de los resultados potenciales), entonces $\mathbb{E}[Y(d) \mid D = d] = \mathbb{E}[Y(d)]$ y el sesgo de selección es cero, de modo que

$$\tau_{ATE} = \tau_{ATT} = \mathbb{E}[Y \mid D = 1] - \mathbb{E}[Y \mid D = 0].$$

Demostración. Por independencia, $\mathbb{E}[Y(0) \mid D = 1] = \mathbb{E}[Y(0) \mid D = 0] = \mathbb{E}[Y(0)]$, así que el sesgo de selección en la Proposición 3.1 es cero; análogamente $\mathbb{E}[Y(1) \mid D = 1] = \mathbb{E}[Y(1)]$. Luego $\mathbb{E}[Y \mid D = 1] - \mathbb{E}[Y \mid D = 0] = \mathbb{E}[Y(1)] - \mathbb{E}[Y(0)] = \tau_{ATE}$, y por la misma razón $\tau_{ATT} = \tau_{ATU} = \tau_{ATE}$. $\square$

La aleatorización hace que **los grupos de tratamiento y control sean, en promedio, comparables en todo**: en lo observable y,

sobre todo, en lo **no observable**. Es la razón por la que el experimento aleatorizado es el “patrón oro”. Con una muestra, el estimador es

$$\hat{\tau} = \bar{Y}_1 - \bar{Y}_0, \quad \bar{Y}_d = \frac{1}{n_d} \sum_{i: D_i=d} Y_i.$$

4.1. Inferencia de Neyman en una población finita

Para hacer inferencia con $\hat{\tau}$ hay dos marcos. El **de superpoblación** (el de los cursos anteriores) supone que las unidades son una muestra aleatoria de una población grande. El **de población finita** (el de Neyman) trata los n resultados potenciales $\{(Y_i(0), Y_i(1))\}$ como **fijos**, y la **única fuente de aleatoriedad es la asignación del tratamiento**. Es el más fiel al experimento, donde las unidades son las que son y solo se sortea quién recibe qué.

Sea **aleatorización completa**: se sortean al azar n_1 unidades para el tratamiento (todas las asignaciones con n_1 tratados son igualmente probables) y $n_0 = n - n_1$ para el control. El parámetro es el **efecto promedio de la muestra** $\tau_S = \frac{1}{n} \sum_i \tau_i = \bar{Y}(1) - \bar{Y}(0)$. Definimos las varianzas **de la población finita** (con divisor $n - 1$): $S_d^2 = \frac{1}{n-1} \sum_i (Y_i(d) - \bar{Y}(d))^2$, $S_{10} = \frac{1}{n-1} \sum_i (Y_i(1) - \bar{Y}(1))(Y_i(0) - \bar{Y}(0))$ y $S_\tau^2 = \frac{1}{n-1} \sum_i (\tau_i - \tau_S)^2 = S_1^2 + S_0^2 - 2S_{10}$.

Teorema 4.2 (Inssegamiento y varianza de Neyman). *Bajo aleatorización completa, $\hat{\tau}$ es **insesgado** para τ_S y*

$$\text{Var}(\hat{\tau}) = \frac{S_1^2}{n_1} + \frac{S_0^2}{n_0} - \frac{S_\tau^2}{n}.$$

*El estimador $\hat{V} = s_1^2/n_1 + s_0^2/n_0$ (con s_d^2 las varianzas muestrales dentro de cada grupo) tiene $\mathbb{E}[\hat{V}] = S_1^2/n_1 + S_0^2/n_0 \geq \text{Var}(\hat{\tau})$: es **conservador**, y exacto si el efecto es constante ($S_\tau^2 = 0$).*

i Borrador

$\bar{Y}_1$ es el promedio de una **muestra aleatoria simple sin reemplazo** de tamaño n_1 de la población finita $\{Y_i(1)\}_{i=1}^n$: los tratados son una selección al azar. Las fórmulas de muestreo en poblaciones finitas dan su media y varianza. Lo mismo vale para $\bar{Y}_0$ con los controles. La complicación es que $\bar{Y}_1$ y $\bar{Y}_0$ **no son independientes** (si una unidad cae en el tratamiento, no cae en el control), y hay que calcular su covarianza. Como cada unidad aporta $Y_i(1)$ o $Y_i(0)$ pero no ambos, el término S_τ^2 de la varianza (que depende de la correlación **entre** $Y_i(1)$ e $Y_i(0)$) **no es estimable** de los datos: nunca vemos ambos resultados de una misma unidad.

Demostración. Sea $W_i = D_i$ el indicador de tratamiento, con $\mathbb{E}[W_i] = p = n_1/n$, $\text{Var}(W_i) = p(1-p)$ y, para $i \neq j$, $\text{Cov}(W_i, W_j) = -p(1-p)/(n-1)$ (sorteo sin reemplazo).

Insesgamiento. $\bar{Y}_1 = \frac{1}{n_1} \sum_i W_i Y_i(1)$, así que $\mathbb{E}[\bar{Y}_1] = \frac{1}{n_1} \sum_i p Y_i(1) = \bar{Y}(1)$ porque $p/n_1 = 1/n$. Análogamente $\mathbb{E}[\bar{Y}_0] = \bar{Y}(0)$ (con $1-p$ y n_0). Luego $\mathbb{E}[\hat{\tau}] = \tau_S$.

Varianza. $\text{Var}(\bar{Y}_1) = (1 - \frac{n_1}{n}) \frac{S_1^2}{n_1} = \frac{S_1^2}{n_1} - \frac{S_1^2}{n}$ (varianza de una media muestral sin reemplazo, con corrección por población finita), y $\text{Var}(\bar{Y}_0) = \frac{S_0^2}{n_0} - \frac{S_0^2}{n}$. Para la covarianza, $\text{Cov}(\bar{Y}_1, \bar{Y}_0) = \frac{1}{n_1 n_0} \sum_{i,j} Y_i(1) Y_j(0) \text{Cov}(W_i, 1 - W_j) = -\frac{1}{n_1 n_0} \sum_{i,j} Y_i(1) Y_j(0) \text{Cov}(W_i, W_j)$. Separando $i = j$ (con $\text{Cov} = p(1-p)$) e $i \neq j$,

$$\text{Cov}(\bar{Y}_1, \bar{Y}_0) = -\frac{p(1-p)}{n_1 n_0} \left[\sum_i Y_i(1) Y_i(0) - \frac{1}{n-1} \sum_{i \neq j} Y_i(1) Y_j(0) \right] = -\frac{p(1-p)}{n_1 n_0} \cdot \frac{n}{n-1} \left[\sum_i Y_i(1) Y_i(0) - n \bar{Y}(1) \bar{Y}(0) \right],$$

y como $\sum_i Y_i(1) Y_i(0) - n \bar{Y}(1) \bar{Y}(0) = (n-1) S_{10}$ y $n_1 n_0 = n^2 p(1-p)$, queda $\text{Cov}(\bar{Y}_1, \bar{Y}_0) = -S_{10}/n$. Entonces

$$\text{Var}(\hat{\tau}) = \text{Var}(\bar{Y}_1) + \text{Var}(\bar{Y}_0) - 2 \text{Cov}(\bar{Y}_1, \bar{Y}_0) = \frac{S_1^2}{n_1} + \frac{S_0^2}{n_0} - \frac{S_1^2 + S_0^2 - 2S_{10}}{n}.$$

Estimador. La varianza muestral s_1^2 de una muestra aleatoria simple es insesgada para S_1^2 (con divisor $n_1 - 1$), y lo mismo para s_0^2 . Entonces $\mathbb{E}[\hat{V}] = S_1^2/n_1 + S_0^2/n_0 = \text{Var}(\hat{\tau}) + S_\tau^2/n \geq \text{Var}(\hat{\tau})$. $\square$

En la práctica se usa $\hat{V}$ para intervalos y tests (con el TCL de poblaciones finitas, Hájek, que se toma prestado). Que sea conservador es tranquilizante: los intervalos tienen **cobertura al menos nominal**. Y la corrección $-S_\tau^2/n$ no se puede estimar, porque exigiría conocer la covarianza entre $Y(1)$ e $Y(0)$ de las mismas unidades (Ejercicio 1.2 muestra que la diferencia puede ser grande o despreciable).

5. Regresión en un experimento

Un resultado práctico conecta con Econometría 1: el estimador de Neyman es la regresión de MCO de Y sobre una constante y D .

Proposición 5.1 (La diferencia de medias es MCO). *En la regresión de Y_i sobre una constante y D_i , el coeficiente de D_i es exactamente $\bar{Y}_1 - \bar{Y}_0$ y la constante es $\bar{Y}_0$.*

Demostración. Con una dummy D_i y una constante, el espacio generado por $(1, D)$ es el de las funciones constantes por grupo. La proyección de Y sobre ese espacio asigna a cada observación el promedio de su grupo (Clase 3 de Econometría 1): ajustado = $\bar{Y}_0$ si $D = 0$ y $\bar{Y}_1$ si $D = 1$. Entonces la constante es $\bar{Y}_0$ y el coeficiente de D es $\bar{Y}_1 - \bar{Y}_0$. (Ejemplo con $Y_{D=1} = (3, 5)$ e $Y_{D=0} = (1, 2, 3)$: $\hat{\tau} = 4 - 2 = 2$, Ejercicio 1.4.) $\square$

Con la regresión, el **error estándar robusto** (HC, Clase 7 de Econometría 1) da un estimador de varianza equivalente al de Neyman. Y la regresión permite incorporar **covariables previas al tratamiento** X_i (edad, nivel inicial del resultado) para ganar **precisión**. Como el tratamiento es aleatorio, X es independiente de D y agregarla **no es necesaria para eliminar sesgo**, pero reduce la varianza residual: si X explica una fracción R^2 de la varianza del resultado, la varianza del estimador baja aproximadamente en el factor $1 - R^2$. Una advertencia (Freedman, 2008): en muestras

finitas, agregar X linealmente puede incluso **sesgar** y empeorar la precisión cuando el efecto es heterogéneo. La recomendación de Lin (2013) es regresar Y sobre D , $\bar{X}$ (covariables **centradas**: $X - \bar{X}$) y las **interacciones** $D \cdot \bar{X}$: el coeficiente de D es consistente para el ATE y **asintóticamente nunca peor** que el estimador sin covariables (se toma prestado), con errores robustos.

5.1. Estratificación

Cuando se conoce una covariable discreta G fuerte (región, sexo, línea base), se puede **aleatorizar dentro de cada estrato**: en el estrato g (n_g unidades) se sortea el tratamiento por separado. El estimador es $\hat{\tau}_{est} = \sum_g (n_g/n) \hat{\tau}_g$ con $\hat{\tau}_g$ la diferencia de medias en el estrato. Elimina la variabilidad **entre** estratos y casi siempre baja la varianza respecto de la aleatorización completa. Un cuidado: la probabilidad de tratamiento puede **diferir** entre estratos, y en ese caso hay que usar el estimador estratificado (que pondera cada $\hat{\tau}_g$ por el tamaño del estrato). Si en el estrato 1 se trata al 20 % y en el 2 al 80 %, comparar *a lo bruto* tratados y controles mezcla estratos y reintroduce el sesgo (Ejercicio 1.5).

5.2. Potencia y tamaño muestral

Para diseñar un experimento hay que decidir cuántas unidades reclutar. Con grupos iguales ($n_1 = n_0 = m$), varianza σ^2 en cada grupo y un efecto mínimo detectable δ , un test bilateral de nivel α con potencia $1 - \beta$ requiere

$$m \approx \frac{2(z_{1-\alpha/2} + z_{1-\beta})^2 \sigma^2}{\delta^2} \quad \text{por grupo.}$$

Con $\alpha = 0,05$ y potencia de 80 % ($z = 1,96$ y $0,84$): $m \approx 15,7 \sigma^2 / \delta^2$. Detectar $\delta = 0,2\sigma$ exige ≈ 392 por grupo; $\delta = 0,5\sigma$, ≈ 63 . La relación $1/\delta^2$ es la clave: **detectar un efecto la mitad de grande exige cuatro veces más datos**.

5.3. Límites de los experimentos

Un experimento identifica el ATE **de la población experimental**, bajo SUTVA y con **cumplimiento perfecto**. Fallan en la práctica

por: (i) **incumplimiento** (no todos los asignados al tratamiento lo reciben; la Clase 3 usa la asignación como instrumento); (ii) **desgaste** (se pierden datos de manera selectiva); (iii) **validez externa** (el efecto en la población del estudio puede no valer en otra); (iv) **interferencia** (violación de SUTVA); y (v) **costo y ética**: muchas preguntas (el efecto de la educación en el ingreso, de una crisis en la salud) no pueden estudiarse aleatorizando. De ahí el resto del curso.

6. ★ Postgrado: el test de aleatorización de Fisher

! ★ Postgrado

Fisher (1935) propuso un test que **no necesita supuestos de distribución ni TCL**: usa solo el mecanismo de asignación. Su validez es **exacta** en muestras finitas.

La hipótesis nula es la **nula aguda** (*sharp*): $H_0 : Y_i(1) = Y_i(0)$ para **todo** i (el tratamiento no tiene efecto sobre ninguna unidad), más fuerte que $\tau_{ATE} = 0$. Bajo H_0 se conocen **ambos** resultados potenciales de cada unidad (el observado), así que **el resultado de cada unidad no depende de la asignación**. Podemos entonces **recalcular el estadístico** $T(w, Y)$ (por ejemplo $|\bar{Y}_1 - \bar{Y}_0|$) para **cada** asignación posible $w \in \mathcal{W}$ (el conjunto de las $\binom{n}{n_1}$ asignaciones), con los Y fijos. El **p-valor** es la fracción de asignaciones con un estadístico al menos tan extremo como el observado:

$$p = \frac{1}{|\mathcal{W}|} \sum_{w \in \mathcal{W}} \mathbf{1}\{T(w, Y) \geq T(W, Y)\},$$

con W la asignación realizada.

Proposición 6.1 (Validez exacta del test de Fisher). *Bajo H_0 y aleatorización completa, $P(p \leq \alpha) \leq \alpha$ para todo $\alpha \in [0, 1]$, en cualquier tamaño de muestra.*

Demostración. Bajo H_0 , el vector Y es **fijo** y la única aleatoriedad es W , uniforme sobre $\mathcal{W}$. Sea $t_w = T(w, Y)$ el valor del estadístico

para cada asignación (números fijos). El estadístico observado es t_W con W uniforme: es un valor elegido **al azar** entre los $|\mathcal{W}|$ números $\{t_w\}$. Y $p = \#\{w : t_w \geq t_W\}/|\mathcal{W}|$ es la fracción de números de esa lista que son $\geq$ el elegido. Si ordenamos la lista de mayor a menor, $t_{(1)} \geq t_{(2)} \geq \dots$, elegir W uniforme equivale a elegir una posición k uniforme, y $p \geq k/|\mathcal{W}|$ (con igualdad si no hay empates). Luego $P(p \leq \alpha) \leq P(k/|\mathcal{W}| \leq \alpha) = \lfloor \alpha |\mathcal{W}| \rfloor / |\mathcal{W}| \leq \alpha$. $\square$

El test de Fisher es **exacto** (el tamaño es a lo más α para cualquier n), robusto a colas gordas y outliers (puede usar estadísticos de rangos), y válido para experimentos pequeños. Su limitación es que contrasta una nula **más fuerte** que la de efecto promedio nulo: puede rechazar porque hay efectos heterogéneos que se cancelan en promedio. Para el ATE con efectos heterogéneos, el enfoque de Neyman (arriba) es el apropiado.

7. Resumen

- **Resultados potenciales:** $Y_i(1)$ e $Y_i(0)$; solo se observa uno ($Y_i = D_i Y_i(1) + (1 - D_i) Y_i(0)$). **SUTVA** (sin interferencia ni versiones ocultas). El efecto individual es inobservable; se estiman promedios: **ATE, ATT, ATU, CATE**.
- **Diferencia ingenua** = **ATT** + **sesgo de selección** (Proposición 3.1) = **ATE** + sesgo de selección + sesgo de heterogeneidad.
- **Aleatorización** ($D \perp (Y(0), Y(1))$) elimina el sesgo de selección: la diferencia de medias identifica el ATE (Teorema 4.1). Coincide con **MCO** de Y sobre D (Proposición 5.1).
- **Neyman** (Teorema 4.2): $\hat{\tau}$ es insesgado, $\text{Var}(\hat{\tau}) = S_1^2/n_1 + S_0^2/n_0 - S_\tau^2/n$; el estimador $\hat{V}$ es **conservador**. Covariables (Lin) y estratificación mejoran la precisión.
- **Potencia:** $m \approx 2(z_{1-\alpha/2} + z_{1-\beta})^2 \sigma^2 / \delta^2$ por grupo.
- **Fisher** (Proposición 6.1): test exacto de la nula aguda, sin supuestos de distribución.

8. Ejercicios

Ejercicio 1.1. Con $\mathbb{E}[Y \mid D = 1] = 70$, $\mathbb{E}[Y \mid D = 0] = 60$ y $\mathbb{E}[Y(0) \mid D = 1] = 65$, calcula τ_{ATT} y el sesgo de selección. Si $\pi = 0,4$ y $\tau_{ATU} = 3$, calcula τ_{ATE} y el sesgo de heterogeneidad, y verifica la segunda forma de la descomposición.

Solución 1.1

$\tau_{ATT} = 70 - 65 = 5$; sesgo de selección = $65 - 60 = 5$; diferencia observada = 10 $\square$. $\tau_{ATE} = \pi\tau_{ATT} + (1 - \pi)\tau_{ATU} = 0,4(5) + 0,6(3) = 3,8$. Sesgo de heterogeneidad = $(1 - \pi)(\tau_{ATT} - \tau_{ATU}) = 0,6(5 - 3) = 1,2$. Suma: $\tau_{ATE} + \text{sesgo de selección} + \text{sesgo de heterogeneidad} = 3,8 + 5 + 1,2 = 10 \square$. Moraleja: la diferencia observada es 2,6 veces el ATE; ignorar la selección lleva a **sobrestimar** el efecto en más de un 160 %.

Ejercicio 1.2. En un experimento con $n = 100$ y $n_1 = n_0 = 50$, $s_1^2 = 25$, $s_0^2 = 16$ y $\hat{\tau} = 2,0$: calcula $\hat{V}$, el error estándar y un IC al 95 %. Luego, tomando $S_1 = 5$ y $S_0 = 4$, calcula la varianza verdadera si $\text{Corr}(Y(1), Y(0)) = 1$ y si es -1 .

Solución 1.2

$\hat{V} = 25/50 + 16/50 = 0,82$; error estándar = 0,906; IC: $2,0 \pm 1,96(0,906) = (0,22; 3,78)$. Varianza verdadera = $\hat{V}$ esperada $-S_{\tau}^2/n$ con $S_{\tau}^2 = S_1^2 + S_0^2 - 2S_{10}$. Si $\text{Corr} = 1$: $S_{10} = 20$ y $S_{\tau}^2 = 25 + 16 - 40 = 1$, varianza = $0,82 - 0,01 = 0,81$: el estimador conservador casi no se equivoca. Si $\text{Corr} = -1$: $S_{10} = -20$ y $S_{\tau}^2 = 25 + 16 + 40 = 81$, varianza = $0,82 - 0,81 = 0,01$: $\hat{V}$ **sobrestima 82 veces** la varianza verdadera. La correlación entre resultados potenciales no se puede estimar, de modo que el investigador no sabe en cuál de los dos casos está; por eso se usa el estimador conservador.

Ejercicio 1.3. ¿Cuántas unidades por grupo hacen falta para detectar $\delta = 0,2\sigma$ y $\delta = 0,5\sigma$ con $\alpha = 0,05$ y potencia 80 %? ¿Qué pasa si se quiere detectar $\delta = 0,1\sigma$?

Solución 1.3

$m = 2(1,96 + 0,84)^2 \sigma^2 / \delta^2 = 15,68 \sigma^2 / \delta^2$. $\delta = 0,2\sigma$: $15,68/0,04 = 392$ por grupo. $\delta = 0,5\sigma$: $15,68/0,25 = 63$ por grupo. $\delta = 0,1\sigma$: $15,68/0,01 = 1568$ por grupo. Cada vez que el efecto mínimo detectable se **divide por 2**, el tamaño muestral se **multiplica por 4**. Por eso los experimentos con efectos pequeños (educación, salud pública) requieren miles de unidades.

Ejercicio 1.4. Con tratados $Y = (3, 5)$ y controles $Y = (1, 2, 3)$, calcula $\hat{\tau}$ y la regresión de Y sobre una constante y D . Calcula también $\hat{V}$ de Neyman.

Solución 1.4

$\bar{Y}_1 = 4$, $\bar{Y}_0 = 2$, $\hat{\tau} = 2$. En la regresión, constante = $\bar{Y}_0 = 2$ y coeficiente de $D = 2$ (Proposición 5.1). Varianzas muestrales: $s_1^2 = [(3-4)^2 + (5-4)^2]/1 = 2$ y $s_0^2 = [(1-2)^2 + 0 + (3-2)^2]/2 = 1$. $\hat{V} = 2/2 + 1/3 = 1,333$ y el error estándar es 1,155. Con $t = 2/1,155 = 1,73$ no se rechaza $H_0 : \tau = 0$ (con tan pocos datos hay poca potencia).

Ejercicio 1.5. (Estratos con distinta probabilidad de tratamiento.) Hay dos estratos: el 1 con $n = 60$ y media de control 10, efecto 2; el 2 con $n = 40$, media de control 20, efecto 4. Se trata a 12 del estrato 1 y a 32 del estrato 2. Calcula el ATE de la muestra, la diferencia ingenua entre tratados y controles, y el estimador estratificado.

Solución 1.5

ATE = $0,6 \cdot 2 + 0,4 \cdot 4 = 2,8$. Medias: tratados del estrato 1 = 12, del estrato 2 = 32; controles del estrato 1 = 10, del estrato 2 = 20. Tratados: 12 del estrato 1 y 32 del 2: media = $(12 \cdot 12 + 32 \cdot 24)/44 = 912/44 = 20,73$. Controles: 10 del estrato 1 y 20 del 2: media = $(10 \cdot 10 + 20 \cdot 20)/30 = 300/30 = 10$. Diferencia ingenua = 9,73, más de **tres veces** el ATE: el estrato 2 (de mayor nivel) está **sobrerrepresentado** entre los tratados. Estratificado: $\hat{\tau}_1 = 12 - 10 = 2$ y

$\hat{\tau}_2 = 24 - 20 = 4$; $\hat{\tau}_{est} = 0,6 \cdot 2 + 0,4 \cdot 4 = 2,8$ ☐, el ATE. Es la lógica de la Clase 2: cuando la asignación depende de una covariable, hay que **condicionar** en ella.

Ejercicio 1.6. Explica por qué en un estudio de vacunación en una población con **inmunidad de rebaño** SUTVA falla, y propón una solución de diseño.

💡 Solución 1.6

La probabilidad de que un individuo se contagie depende de **cuántos de sus contactos** están vacunados, no solo de si él lo está: Y_i depende del vector completo de tratamientos $(D_1, \dots, D_n)$, y $Y_i(1)$ no es un solo número (hay muchos $Y_i(1; \text{resto})$). Además, un individuo no vacunado se beneficia indirectamente del tratamiento de otros: ese **efecto de derrame** contamina el grupo de control y subestima el efecto *directo* en una comparación individual. Solución de diseño: **aleatorizar por conglomerados** (comunidades, escuelas) en vez de por individuos, de modo que la interferencia ocurra *dentro* de cada conglomerado y el tratamiento se define a nivel de conglomerado; así los resultados potenciales de cada conglomerado dependen solo de su propio tratamiento (si no hay interferencia entre conglomerados). El costo: menos unidades efectivas (la inferencia usa errores agrupados, Clase 10) y mayor varianza.

Ejercicio 1.7 ★. (Test de Fisher.) Seis unidades, tres tratadas, con resultados tratados (10, 12, 14) y controles (6, 8, 9). Calcula el p -valor exacto, unilateral y bilateral, de la nula aguda con el estadístico $\bar{Y}_1 - \bar{Y}_0$.

💡 Solución 1.7 ★

Hay $\binom{6}{3} = 20$ asignaciones. Bajo la nula aguda los resultados son fijos: {6, 8, 9, 10, 12, 14}, con suma 59. Si la suma de los tratados es S , la diferencia es $(S - (59 - S))/3 = (2S - 59)/3$. Observado: $S = 36$, diferencia = $13/3 = 4,33$. La suma máxima posible de tres valores es $14 + 12 + 10 = 36$: **solo la asignación observada** llega a $S \geq 36$, así que el

p -valor unilateral es $1/20 = 0,05$. Bilateral: además cuenta la asignación con S mínima, $6 + 8 + 9 = 23$, diferencia $(46-59)/3 = -4,33$ (igual en valor absoluto): $2/20 = 0,10$. Con seis unidades, ni siquiera el efecto más extremo posible permite $p < 0,05$ en el test bilateral: es un ejemplo de que el test de Fisher es exacto pero **discreto**, y necesita suficientes asignaciones para tener poder.