

Clase 7 · Alta dimensión: LASSO

Regularización, dispersión y el fracaso de la inferencia post-selección

Contenido

1	Cuando hay más variables que observaciones	1
2	El modelo disperso	2
3	Ridge y LASSO	2
3.1	Condiciones de optimalidad (KKT)	3
3.2	Umbral suave (diseño ortonormal)	4
4	La desigualdad oráculo	4
4.1	Selección de variables	5
5	El problema de la inferencia después de seleccionar	6
5.1	Remedios parciales	7
6	★ Postgrado: demostración de la desigualdad oráculo	8
7	Resumen	9
8	Ejercicios	10

1. Cuando hay más variables que observaciones

En Econometría 1 supusimos $k < n$ regresores. Hoy es común lo contrario: un investigador dispone de cientos o miles de variables

candidatas (características de empresas, expresiones génicas, palabras de un texto, interacciones y términos polinómicos de unas pocas variables básicas) para n observaciones. Si $p \geq n$, $X'X$ es **singular** y MCO ni siquiera está definido (Clase 1 de Econometría 1); y aun con $p < n$ pero p comparable a n , MCO **sobreajusta**: el ajuste dentro de muestra es excelente y el pronóstico fuera de muestra, desastroso.

La respuesta de la estadística moderna es **regularizar**: imponer una restricción o una penalización que contrarreste la libertad de ajustar ruido. Esta clase estudia la más influyente, el **LASSO** (Tibshirani, 1996), y hace dos preguntas centrales: (1) ¿cuándo el LASSO **predice bien** aunque $p \gg n$? (la respuesta es la *desigualdad oráculo*); (2) ¿cuándo se puede usar para **inferencia** sobre un parámetro (la pregunta causal)? (la respuesta es: no directamente, y por eso la Clase 8).¹

2. El modelo disperso

Sea $Y = X\beta_0 + \varepsilon$ con X de $n \times p$, p posiblemente mucho mayor que n . La hipótesis estructural que hace posible el problema es la **dispersión** (*sparsity*): solo s **coeficientes son distintos de cero**, con $s \ll n$. Sea $S = \{j : \beta_{0j} \neq 0\}$ el soporte, $|S| = s$. No sabemos cuál es S : esa es la dificultad. Si lo supiéramos, bastaría una regresión de MCO sobre las s variables (el **oráculo**), con error de predicción $\approx \sigma^2 s/n$. La pregunta es cuánto se pierde por **no conocer** S .

La idea ingenua es **selección de subconjuntos** (*best subset*): minimizar $\|Y - X\beta\|^2$ sujeto a $\|\beta\|_0 \leq s$ (donde $\|\beta\|_0$ es el número de coeficientes no nulos). Es un problema **no convexo** y combinatorio ($\binom{p}{s}$ subconjuntos), computacionalmente inviable para p grande. El LASSO lo **relaja** reemplazando la norma ℓ_0 por la ℓ_1 , que es la envolvente convexa.

3. Ridge y LASSO

Ridge (Hoerl y Kennard, 1970): minimiza $\|Y - X\beta\|^2 + \lambda\|\beta\|_2^2$, con solución $\hat{\beta}_R = (X'X + \lambda I)^{-1}X'Y$, siempre definida (la suma

¹ Robert Tibshirani propuso el LASSO (*least absolute shrinkage and selection operator*) en 1996, y el acrónimo es una pequeña broma: un lazo es lo que se usa para atrapar ganado, y el LASSO “atrapa” los coeficientes que valen cero. Es uno de los artículos de estadística más citados de las últimas décadas, y el origen de una literatura entera sobre “estadística en alta dimensión”. En econometría se popularizó a partir de los trabajos de Belloni, Chernozhukov y sus coautores a partir de 2011, que mostraron cómo usarlo **sin** destruir la inferencia.

$X'X + \lambda I$ es invertible para $\lambda > 0$) y que **contrae** todos los coeficientes hacia cero. Es el estimador de Econometría 1, Clase 4 ★ (donde vimos que ridge le gana a MCO en ECM). Pero ridge **no** pone coeficientes en cero: no hace selección de variables.

Definición 3.1 (LASSO).

$$\hat{\beta}^L = \arg \min_{\beta \in \mathbb{R}^p} \frac{1}{2n} \|Y - X\beta\|_2^2 + \lambda \|\beta\|_1, \quad \|\beta\|_1 = \sum_{j=1}^p |\beta_j|.$$

La penalización ℓ_1 tiene un **vértice** en cada eje: la función $|\beta_j|$ no es diferenciable en cero, y eso hace que la solución tenga **coeficientes exactamente iguales a cero**. El problema es **convexo** (suma de una cuadrática y una norma), con solución única bajo condiciones leves, y se resuelve rápido para p en los miles (descenso por coordenadas, LARS).

3.1. Condiciones de optimalidad (KKT)

Como la función objetivo es convexa, el mínimo se caracteriza por que **cero pertenece al subdiferencial**.

Proposición 3.1 (Condiciones KKT del LASSO). $\hat{\beta}$ es solución del LASSO si y solo si, para cada j ,

$$\frac{1}{n} X_j'(Y - X\hat{\beta}) = \lambda \operatorname{sgn}(\hat{\beta}_j) \text{ si } \hat{\beta}_j \neq 0, \quad \left| \frac{1}{n} X_j'(Y - X\hat{\beta}) \right| \leq \lambda \text{ si } \hat{\beta}_j = 0.$$

Demostración. El subdiferencial de $|b|$ es $\{\operatorname{sgn}(b)\}$ si $b \neq 0$ y $[-1, 1]$ si $b = 0$. La condición de optimalidad de primer orden para una función convexa es que el gradiente de la parte suave más un elemento del subdiferencial de la penalización sea cero: $-\frac{1}{n} X_j'(Y - X\hat{\beta}) + \lambda s_j = 0$ con $s_j \in \partial|\hat{\beta}_j|$. Despejando se obtienen las dos condiciones. $\square$

La lectura es muy clara: **una variable entra en el modelo solo si su correlación (muestral) con el residuo actual es, en valor absoluto, igual a λ** ; las que tienen correlación menor que λ quedan en cero. λ es el **umbral de entrada**. Cuanto mayor es λ , menos variables entran; con $\lambda \geq \max_j |X_j'Y|/n$ todas son cero, y con $\lambda \rightarrow 0$ se recupera MCO.

3.2. Umbral suave (diseño ortonormal)

El comportamiento más transparente aparece con **regresores ortonormales** ($X'X/n = I_p$), caso en que el problema se **separa** por coordenada.

Proposición 3.2 (LASSO como umbral suave). Si $X'X/n = I_p$ y $z_j = X_j'Y/n$ es el coeficiente de MCO de j , entonces

$$\hat{\beta}_j^L = \text{sgn}(z_j)(|z_j| - \lambda)_+ = \begin{cases} z_j - \lambda & \text{si } z_j > \lambda, \\ 0 & \text{si } |z_j| \leq \lambda, \\ z_j + \lambda & \text{si } z_j < -\lambda. \end{cases}$$

Demostración. Con $X'X/n = I$, $\frac{1}{2n}\|Y - X\beta\|^2 = \frac{1}{2}\|\beta - z\|^2 + \text{cte}$ (completando cuadrados: $\frac{1}{2n}\|Y\|^2 - z'\beta + \frac{1}{2}\|\beta\|^2$), de modo que el problema es $\sum_j [\frac{1}{2}(\beta_j - z_j)^2 + \lambda|\beta_j|]$, **separable**. Para cada j , por KKT: si $\hat{\beta}_j \neq 0$, $z_j - \hat{\beta}_j = \lambda \text{sgn}(\hat{\beta}_j)$, es decir $\hat{\beta}_j = z_j - \lambda \text{sgn}(\hat{\beta}_j)$, que tiene el signo de z_j solo si $|z_j| > \lambda$; si $\hat{\beta}_j = 0$, $|z_j| \leq \lambda$. Esto es el umbral suave. $\square$

Comparación con alternativas, con la misma estimación inicial z : **MCO** deja z_j intacto; **ridge** lo **divide** por $1 + \lambda$ (contrae proporcionalmente); **umbral duro** (selección de subconjuntos) deja z_j si $|z_j| > \lambda$ y pone cero si no; el **LASSO** **resta** λ a los grandes y pone en cero a los pequeños. Observa que LASSO **introduce sesgo** en los coeficientes grandes (los reduce en λ): es el precio de la estimación estable.

4. La desigualdad oráculo

¿Qué tan bien predice el LASSO? La teoría moderna responde con una **cota no asintótica** del error de predicción, válida para cualquier n, p, s , que depende de p solo por $\log p$.

Supuestos

1. **Modelo disperso:** $Y = X\beta_0 + \varepsilon$, con soporte S , $|S| = s$.
2. **Errores sub-gaussianos:** por ejemplo ε_i i.i.d. $N(0, \sigma^2)$, y columnas normalizadas $\|X_j\|_2^2/n = 1$.
3. **Condición de autovalor restringido (RE):** existe $\phi > 0$ tal que $\|Xv\|_2^2/n \geq \phi^2 \|v_S\|_2^2$ para todo v con $\|v_{S^c}\|_1 \leq 3\|v_S\|_1$. Es una versión débil de “ $X'X/n$ es invertible”, exigida solo en un **cono** de direcciones (concentradas en S).

Teorema 4.1 (Desigualdad oráculo (Bickel, Ritov y Tsybakov, 2009)). *Bajo los supuestos, con $\lambda = 2\sigma\sqrt{2\log(2p/\delta)/n}$, con probabilidad al menos $1 - \delta$,*

$$\frac{1}{n} \|X(\hat{\beta}^L - \beta_0)\|_2^2 \leq \frac{9\lambda^2 s}{\phi^2}, \quad \|\hat{\beta}^L - \beta_0\|_1 \leq \frac{12\lambda s}{\phi^2}.$$

En particular, el error de predicción es $O(\sigma^2 s \log(p/\delta)/(n\phi^2))$.

Lo notable es la **forma**: el error es proporcional a s (el número de variables relevantes, como el oráculo) y a $\log p$ (el **costo de no conocer cuáles son**), no a p . Con $p = e^{n/10}$ variables (¡exponencialmente más variables que datos!) el error de predicción sigue siendo pequeño si s es chico. La demostración está en la sección ★.

Para **elegir** λ hay dos criterios. El **teórico** (el de arriba, o su versión robusta de Belloni, Chen, Chernozhukov y Hansen, 2012, con la desviación estándar estimada en cada variable) garantiza el evento $\|X'\varepsilon/n\|_\infty \leq \lambda/2$ con alta probabilidad. El **práctico** más usado es la **validación cruzada** de K pliegues (Clase 5): elegir el λ que minimiza el error de predicción fuera de muestra. Esta tiende a elegir un λ **menor** que el teórico, con **más variables** incluidas (buena para predecir; mala para la selección exacta).

4.1. Selección de variables

La desigualdad oráculo es sobre **predicción** y estimación, no sobre **qué variables se seleccionan**. El LASSO selecciona **exactamente** S con alta probabilidad solo bajo condiciones más fuertes:

la **condición de irrerepresentabilidad** (las variables irrelevantes no pueden estar demasiado correlacionadas con las relevantes: Zhao y Yu, 2006; Wainwright, 2009) y un **tamaño mínimo** de los coeficientes verdaderos (*beta-min*: $\min_{j \in S} |\beta_{0j}| \gg \lambda$, de modo que no se confundan con ruido). En la práctica, con regresores correlacionados, el LASSO elige una variable de un grupo correlacionado y descarta las otras de manera algo arbitraria, y su selección es **inestable** entre muestras. Variantes: el *elastic net* (mezcla ℓ_1 y ℓ_2 , agrupa regresores correlacionados), el LASSO **adaptativo** (pesa la penalización por $1/|\hat{\beta}_j^{init}|$ para reducir el sesgo) y el *group LASSO*.

5. El problema de la inferencia después de seleccionar

Para un economista, el objetivo suele ser el efecto causal de **una** variable D , controlando por un vector grande X . Una tentación natural: (1) usar el LASSO para **seleccionar** los controles relevantes, (2) correr MCO de Y sobre D y los controles seleccionados, (3) reportar los errores estándar de MCO **como si el modelo hubiera sido elegido de antemano**. Es un procedimiento **inválido**, por dos razones que se refuerzan.

(i) Sesgo por variable omitida. Si el LASSO descarta una variable X_j con un coeficiente pequeño en la ecuación de Y pero **fuertemente correlacionada con D** , la regresión sobre los controles seleccionados omite X_j y el coeficiente de D queda sesgado. El sesgo es pequeño en la ecuación de Y (por eso se descartó) pero **no** en el efecto de D (Ejercicio 7.6).

(ii) La distribución de los estimadores es no uniforme (Leeb y Pötscher, 2005). El resultado de la selección **depende de los mismos datos** que luego se usan para inferir. Para coeficientes que son **cercanos a cero en relación a $n^{-1/2}$** , el estimador post-selección tiene una distribución que **no es normal** ni siquiera asintóticamente, y que **depende del valor desconocido** del coeficiente: la teoría asintótica “habitual” (para un parámetro **fijo**) no es **uniforme**. Es el mismo fenómeno del **estimador de Hodges** (Clase 2 de Econometría 2, ★): un estimador que es “mejor”

en el punto $\theta = 0$ es pésimo en vecindades de tamaño $n^{-1/2}$ de ese punto.

Un ejemplo simple lo hace visible. Sea $\hat{\beta} \sim N(b, 1)$ (estimador estandarizado de un coeficiente b). Un investigador **conserva** la variable solo si $|\hat{\beta}| > 1,96$ (la “selecciona”) y, si la conserva, reporta el intervalo $\hat{\beta} \pm 1,96$; si la descarta, reporta $\{0\}$.

Proposición 5.1 (Cobertura del intervalo post-selección). *Para $b \neq 0$, la cobertura del procedimiento es $P(|\hat{\beta}| > 1,96, |\hat{\beta} - b| \leq 1,96)$. Para $b > 0$ y $b \leq 1,96$ vale $\Phi(1,96) - \Phi(1,96 - b)$, que tiende a cero cuando $b \rightarrow 0^+$.*

Demostración. Si $b \neq 0$, el intervalo cubre b solo si fue **seleccionado** (si no, el intervalo es $\{0\} \neq b$) y si $|\hat{\beta} - b| \leq 1,96$. Para $b > 0$ moderado, la condición $|\hat{\beta}| > 1,96$ con $\hat{\beta} \geq b - 1,96 > -1,96$ equivale a $\hat{\beta} > 1,96$; y $|\hat{\beta} - b| \leq 1,96$ a $\hat{\beta} \leq b + 1,96$. Entonces la cobertura es $P(1,96 < \hat{\beta} \leq b + 1,96) = \Phi(1,96) - \Phi(1,96 - b)$ (con $\hat{\beta} - b \sim N(0, 1)$). Para $b \rightarrow 0^+$, $\Phi(1,96) - \Phi(1,96 - b) \rightarrow 0$. $\square$

La cobertura nominal es 95 %, pero con $b = 1$ la cobertura real es $\Phi(1,96) - \Phi(0,96) = 0,975 - 0,832 = 14$ %, con $b = 2$ es 49 %, y con $b = 0,2$ solo 1,4 % (Ejercicio 7.4). **Cuanto más cerca de cero (sin serlo) está el coeficiente, peor.** Se trata de una propiedad de **cualquier** procedimiento que seleccione y luego haga inferencia con los mismos datos, y aplica al LASSO: los coeficientes pequeños pero no nulos, en la zona donde el LASSO “duda”, son los que arruinan la cobertura.

5.1. Remedios parciales

- **Post-LASSO** (Belloni y Chernozhukov, 2013): usar el LASSO **solo para seleccionar** y reestimar por MCO las variables elegidas. Elimina el **sesgo de contracción** de λ en los coeficientes grandes (Ejercicio 7.5) y mejora la predicción, pero **no** resuelve el problema de inferencia.
- **Penalización con carga por variable** (*rigorous LASSO*): $\lambda_j = \lambda \hat{\sigma}_j$ con $\hat{\sigma}_j$ estimada, robusta a heterocedasticidad (Belloni et al., 2012).

- **Doble selección** (Belloni, Chernozhukov y Hansen, 2014): para el efecto de D sobre Y controlando por X de alta dimensión, (1) LASSO de Y sobre X (selecciona controles que predicen el resultado); (2) LASSO de D sobre X (selecciona controles que predicen el tratamiento); (3) MCO de Y sobre D y la **unión** de los controles seleccionados en (1) y (2). Un control que importa para el sesgo debe estar relacionado con Y y con D ; basta que sea elegido en **alguna** de las dos ecuaciones para entrar. El resultado es un estimador $\sqrt{n}$ -**normal** del efecto de D con inferencia válida **uniforme** en el modelo: el error por omitir un control es un **producto** de dos errores pequeños (el de la ecuación de Y y el de la de D). Esa es la propiedad de **ortogonalidad de Neyman** que se desarrolla en la Clase 8 y que está detrás de todos los métodos modernos de inferencia con aprendizaje automático.

6. ★ Postgrado: demostración de la desigualdad oráculo

! ★ Postgrado

Demostramos el Teorema 4.1. El argumento tiene tres pasos: una **desigualdad básica** (el LASSO es mejor que β_0 en su propio criterio), el **cono** donde vive el error, y el uso de la condición RE.

Sea $v = \hat{\beta}^L - \beta_0$ y definamos el evento $G = \{\|X'\varepsilon\|_\infty/n \leq \lambda/2\}$.

Paso 0: el evento tiene alta probabilidad. Cada $X_j'\varepsilon/n \sim N(0, \sigma^2/n)$ (columnas normalizadas), así que $P(|X_j'\varepsilon/n| > t) \leq 2e^{-nt^2/(2\sigma^2)}$. Con $t = \lambda/2$ y la cota de la unión sobre p variables, $P(G^c) \leq 2pe^{-n\lambda^2/(8\sigma^2)} = \delta$ para $\lambda = 2\sigma\sqrt{2\log(2p/\delta)/n}$.

Paso 1: desigualdad básica. Como $\hat{\beta}^L$ minimiza el criterio, $\frac{1}{2n}\|Y - X\hat{\beta}^L\|^2 + \lambda\|\hat{\beta}^L\|_1 \leq \frac{1}{2n}\|Y - X\beta_0\|^2 + \lambda\|\beta_0\|_1$. Con $Y - X\hat{\beta}^L = \varepsilon - Xv$ y expandiendo,

$$\frac{1}{2n}\|Xv\|^2 \leq \frac{1}{n}\varepsilon'Xv + \lambda(\|\beta_0\|_1 - \|\hat{\beta}^L\|_1).$$

En $\mathcal{G}$, $|\frac{1}{n}\varepsilon'Xv| \leq \|X'\varepsilon/n\|_\infty \|v\|_1 \leq \frac{\lambda}{2}\|v\|_1$. Además, como β_0 tiene soporte S : $\|\hat{\beta}\|_1 = \|\beta_{0S} + v_S\|_1 + \|v_{S^c}\|_1 \geq \|\beta_0\|_1 - \|v_S\|_1 + \|v_{S^c}\|_1$, de modo que $\|\beta_0\|_1 - \|\hat{\beta}\|_1 \leq \|v_S\|_1 - \|v_{S^c}\|_1$. Reemplazando,

$$\frac{1}{2n}\|Xv\|^2 \leq \frac{\lambda}{2}(\|v_S\|_1 + \|v_{S^c}\|_1) + \lambda(\|v_S\|_1 - \|v_{S^c}\|_1) = \frac{3\lambda}{2}\|v_S\|_1 - \frac{\lambda}{2}\|v_{S^c}\|_1. \quad (1)$$

Paso 2: el cono. El lado izquierdo es no negativo, así que $\frac{3\lambda}{2}\|v_S\|_1 - \frac{\lambda}{2}\|v_{S^c}\|_1 \geq 0$, es decir $\|v_{S^c}\|_1 \leq 3\|v_S\|_1$: **v está en el cono** de la condición RE. Por lo tanto $\|Xv\|^2/n \geq \phi^2\|v_S\|_2^2$.

Paso 3: cota de predicción. De Ecuación 1, descartando el término negativo, $\frac{1}{2n}\|Xv\|^2 \leq \frac{3\lambda}{2}\|v_S\|_1 \leq \frac{3\lambda}{2}\sqrt{s}\|v_S\|_2 \leq \frac{3\lambda\sqrt{s}}{2\phi} \cdot \frac{\|Xv\|}{\sqrt{n}}$ (por Cauchy-Schwarz y por RE). Multiplicando por 2 y dividiendo por $\|Xv\|/\sqrt{n}$ (si es no nulo): $\|Xv\|/\sqrt{n} \leq 3\lambda\sqrt{s}/\phi$, es decir $\|Xv\|^2/n \leq 9\lambda^2s/\phi^2$.

Paso 4: error en ℓ_1 . $\|v\|_1 = \|v_S\|_1 + \|v_{S^c}\|_1 \leq 4\|v_S\|_1 \leq 4\sqrt{s}\|v_S\|_2 \leq \frac{4\sqrt{s}}{\phi} \cdot \frac{\|Xv\|}{\sqrt{n}} \leq \frac{4\sqrt{s}}{\phi} \cdot \frac{3\lambda\sqrt{s}}{\phi} = \frac{12\lambda s}{\phi^2}$. $\square$

Dos comentarios. **(i)** La condición RE es **inevitable**: sin alguna forma de identificabilidad en el cono, no hay manera de separar los coeficientes verdaderos de los espurios. **(ii)** El factor $\sqrt{s}$ en el paso 3 viene de pasar de ℓ_1 a ℓ_2 sobre S (s coordenadas), y la constante 3 del cono es consecuencia de $\lambda \geq 2\|X'\varepsilon\|_\infty/n$. Las constantes son conservadoras: en la práctica el LASSO funciona mucho mejor que lo que sugieren.

7. Resumen

- Con $p \gtrsim n$, MCO falla; se **regulariza**. **Ridge** contrae; **LASSO** (ℓ_1) contrae y selecciona (pone ceros). El LASSO es conve-xo, con **KKT**: entran las variables con $|X_j'r|/n = \lambda$ (Propo-sición 3.1).
- Con diseño ortonormal, LASSO es **umbral suave** (Proposi-ción 3.2): resta λ a los grandes y anula los pequeños; intro-duce **sesgo** en los grandes.

- **Desigualdad oráculo** (Teorema 4.1): bajo dispersión y la condición RE, el error de predicción es $\lesssim \sigma^2 s \log p / (n\phi^2)$: depende de p solo por $\log p$. Selección exacta exige irrepresentabilidad y beta-min.
- **Inferencia post-selección inválida**: sesgo por variable omitida y no uniformidad (Leeb-Pötscher); un intervalo naive tiene cobertura de **14 %** con $b = 1$ (Proposición 5.1).
- **Remedios**: post-LASSO (quita el sesgo de contracción), penalización rigurosa, y la **doble selección** (ortogonalidad de Neyman: Clase 8).

8. Ejercicios

Ejercicio 7.1. Con los coeficientes de MCO $z = (3, -1, 2, 0, 4, 0)$ y diseño ortonormal, calcula las estimaciones de LASSO, umbral duro y ridge con $\lambda = 0,5$.

💡 Solución 7.1

LASSO (umbral suave, resta 0,5 en valor absoluto): $(2,5, -0,7, 0, 0)$ (el tercero, $|0,4| < 0,5$, se anula). Umbral duro: deja z_j si $|z_j| > 0,5$: $(3, -1, 2, 0, 0)$. Ridge: $z_j / (1 + \lambda) = z_j / 1,5$: $(2,0, -0,8, 0,267, 0)$. LASSO es el único que combina **selección** (ceros) y **contracción** de los grandes; ridge no selecciona; el umbral duro selecciona pero no contrae (y su estimador es discontinuo en z).

Ejercicio 7.2. En una solución del LASSO con $\lambda = 0,3$, las correlaciones con el residuo $X_j' r / n$ son $(0,30, -0,30, 0,10)$ para $j = 1, 2, 3$. ¿Qué variables están activas? ¿Podría una solución tener $X_1' r / n = 0,5$?

💡 Solución 7.2

Por KKT, las **activas** tienen $|X_j' r / n| = \lambda = 0,3$ con signo igual al de $\hat{\beta}_j$: las variables 1 (con $\hat{\beta}_1 > 0$) y 2 (con $\hat{\beta}_2 < 0$) están activas; la 3 ($|0,10| < 0,3$) es cero. **No** puede haber una solución con $|X_1' r / n| = 0,5 > \lambda$: ninguna variable puede tener correlación con el residuo mayor que λ (si la tuviera).

ra, agregarla o aumentar su coeficiente reduciría el criterio, contradiciendo la optimalidad). Es la regla: el LASSO “agota” la correlación hasta el nivel λ .

Ejercicio 7.3. Calcula λ teórico para $n = 400$, $p = 1\,000$, $\sigma = 1$ y $\delta = 0,05$. Compara el costo $\log p$ con el oráculo para $s = 5$.

Solución 7.3

$\lambda = 2\sigma\sqrt{2\log(2p/\delta)/n} = 2\sqrt{2\ln(40\,000)/400} = 2\sqrt{2 \cdot 10,597/400} = 2\sqrt{0,0530} = 2(0,230) = 0,46$. El error del oráculo (conoce S , MCO sobre 5 variables) es $\sigma^2 s/n = 5/400 = 0,0125$. El del LASSO escala como $\sigma^2 s \log p/n = 5 \cdot 6,9/400 = 0,086$: unas 7 veces mayor: es el **precio de no conocer** el soporte entre 1 000 candidatos. Notar que ese precio crece como $\log p$: pasar de 1 000 a 1 000 000 variables lo multiplica por 2 (de 6,9 a 13,8), no por 1 000.

Ejercicio 7.4. Calcula la cobertura del intervalo post-selección de la Proposición 5.1 para $b = 0,2$, 1 , 2 y $b = 0$.

Solución 7.4

Para $0 < b \leq 1,96$: cobertura = $\Phi(1,96) - \Phi(1,96 - b)$.
 $b = 0,2$: $0,9750 - \Phi(1,76) = 0,9750 - 0,9608 = 0,014$ (1,4 %).
 $b = 1$: $0,9750 - \Phi(0,96) = 0,9750 - 0,8315 = 0,1435$ (14 %).
 $b = 2$: $P(\hat{\beta} > 1,96 \text{ y } \hat{\beta} \leq 3,96) = \Phi(1,96) - \Phi(-0,04) = 0,9750 - 0,4840 = 0,491$ (49 %).
 $b = 0$: el intervalo es $\{0\}$ cuando no se selecciona (probabilidad 0,95) y cubre $b = 0$; cuando se selecciona, no cubre: cobertura = 0,95. La cobertura es la nominal **solo** en $b = 0$ (y converge a 95 % para b grande, > 4), pero para coeficientes pequeños no nulos es **muy baja**: es la no uniformidad de Leeb-Pötscher.

Ejercicio 7.5. Con diseño ortonormal, $z = 3$ y $\lambda = 0,5$, ¿qué estima el LASSO? ¿Y el post-LASSO? ¿Por qué mejora?

💡 Solución 7.5

LASSO: $3 - 0,5 = 2,5$ (sesgo de $-0,5$, la contracción). Post-LASSO: se selecciona la variable (porque $|z| = 3 > 0,5$) y se reestima por MCO sobre ella: $\hat{\beta} = z = 3$, que es el estimador de MCO **sin contracción**. Mejora porque quita el sesgo de λ para las variables **seleccionadas** (que son las de coeficiente grande, donde la contracción es innecesaria), manteniendo la selección. El costo es que **depende** de que la selección sea buena: si se incluyó una variable irrelevante, post-LASSO la estima con la varianza completa de MCO.

Ejercicio 7.6. El modelo verdadero es $Y = 0,5D + 0,1X_5 + \varepsilon$, con $\text{Cov}(D, X_5) = 0,8$ y $\text{Var}(D) = 1$. Un LASSO de Y sobre $(D, X_1, \dots, X_{100})$ con $\lambda = 0,15$ pone en cero a X_5 . Calcula el sesgo del coeficiente de D y explica cómo la doble selección lo evita.

💡 Solución 7.6

Al omitir X_5 , el coeficiente de D en la regresión restante estima $0,5 + 0,1 \cdot \text{Cov}(D, X_5) / \text{Var}(D) = 0,5 + 0,1 \cdot 0,8 = 0,58$: sesgo de $0,08$, o 16% del efecto verdadero. El coeficiente de X_5 ($0,1$) es **menor** que el umbral $\lambda = 0,15$ y se descarta: en la ecuación de Y es “irrelevante”, pero en la de D es **muy relevante** (correlación $0,8$). La **doble selección** corre además un LASSO de D sobre X : ahí X_5 tiene un coeficiente grande y es **seleccionado**. La unión de los controles seleccionados incluye X_5 , y la regresión final de Y sobre D y esa unión elimina el sesgo. Un control que causa sesgo de variable omitida tiene que estar relacionado con **ambas** variables, y la doble selección lo captura si lo está con cualquiera de las dos.

Ejercicio 7.7 ★. En el Paso 3 de la demostración, con $\lambda = 0,2$, $s = 3$ y $\phi = 0,6$, calcula las cotas de predicción y de ℓ_1 del Teorema 4.1. ¿Por qué estas cotas son conservadoras? ¿De dónde sale la restricción $\|v_{sc}\|_1 \leq 3\|v_s\|_1$?

💡 Solución 7.7 ★

Predicción: $9\lambda^2 s/\phi^2 = 9(0,04)(3)/0,36 = 3,0$; ℓ_1 : $12\lambda s/\phi^2 = 12(0,2)(3)/0,36 = 20$. Las constantes (9 y 12) vienen de cotas sucesivas de Cauchy-Schwarz y de la triangular, y son **generosas**: en simulaciones el error es mucho menor. La restricción $\|v_{sc}\|_1 \leq 3\|v_s\|_1$ sale del

Paso 1: como $\frac{1}{2n}\|Xv\|^2 \geq 0$, de Ecuación 1 se obtiene $\frac{3\lambda}{2}\|v_s\|_1 - \frac{\lambda}{2}\|v_{sc}\|_1 \geq 0$. Los factores $\frac{3}{2}$ y $\frac{1}{2}$ provienen de combinar $\lambda/2$ (de la cota del ruido, que usa $\lambda \geq 2\|X'\varepsilon\|_\infty/n$) con λ (de la penalización): $\frac{1}{2} + 1 = \frac{3}{2}$ y $1 - \frac{1}{2} = \frac{1}{2}$, y su cociente es 3. Si se elige λ más grande ($\lambda \geq c\|X'\varepsilon\|_\infty/n$ con $c > 2$) el cono se estrecha.