

Clase 8 · Aprendizaje automático para inferencia causal

Double/debiased machine learning: ortogonalidad de
Neyman y cross-fitting

Contenido

1	Predecir bien no es inferir bien	2
2	El modelo parcialmente lineal	2
2.1	Por qué el enfoque ingenuo falla	3
3	Ortogonalidad de Neyman	3
4	Cross-fitting	5
5	El teorema de DML	6
6	Conexión con el AIPW de la Clase 2	7
7	Aspectos prácticos	8
8	★ Postgrado: construir momentos ortogonales	9
9	Resumen	10
10	Ejercicios	10

1. Predecir bien no es inferir bien

Los métodos de **aprendizaje automático** (ML: LASSO, bosques aleatorios, redes neuronales, *boosting*) son extraordinarios para **predecir**. Pero su objetivo (minimizar el error de predicción) y el del econometrista (estimar un parámetro causal con un intervalo de confianza válido) no coinciden. Las Clases 5 y 7 mostraron los dos obstáculos: los estimadores no paramétricos y regularizados convergen **lento** (tasas menores que $\sqrt{n}$) y tienen **sesgo** de regularización; y la inferencia posterior a la selección es inválida.

Esta clase presenta la solución actual, el **aprendizaje automático doblemente robusto o desesgado** (*double/debiased machine learning*, DML) de Chernozhukov, Chetverikov, Demirer, Duflo, Hansen, Newey y Robins (2018). La idea es **separar el problema en dos partes**: un **parámetro de interés** θ_0 de dimensión baja (el efecto causal), y **funciones de perturbación** (*nuisance*) de alta complejidad (la media condicional del resultado, el propensity score) que se estiman con ML. Con dos ingredientes (una **construcción ortogonal** del estimador y el **cross-fitting**) se obtiene $\sqrt{n}$ -normalidad para θ_0 aunque las funciones de perturbación se estimen **lentamente**.

2. El modelo parcialmente lineal

Sea $W = (Y, D, X)$ con

$$Y = D\theta_0 + g_0(X) + U, \quad \mathbb{E}[U \mid D, X] = 0; \quad D = m_0(X) + V, \quad \mathbb{E}[V \mid X] = 0. \quad (1)$$

θ_0 es el efecto causal de D sobre Y (bajo insesgamiento condicional dado X , Clase 2), X es un vector de controles de **alta dimensión** y g_0, m_0 son funciones **desconocidas y complejas**. Las funciones de perturbación inducen dos medias condicionales observables: $\ell_0(X) = \mathbb{E}[Y \mid X] = \theta_0 m_0(X) + g_0(X)$ y la propia $m_0(X) = \mathbb{E}[D \mid X]$. Es el modelo de Robinson (Clase 5), que ya vimos que identifica θ_0 por **residuos sobre residuos**:

$$Y - \ell_0(X) = \theta_0(D - m_0(X)) + U \quad \Rightarrow \quad \theta_0 = \frac{\mathbb{E}[(Y - \ell_0(X))(D - m_0(X))]}{\mathbb{E}[(D - m_0(X))^2]}.$$

2.1. Por qué el enfoque ingenuo falla

La tentación natural es **estimar** g_0 **por ML y plug-in**: obtener $\hat{g}(X)$ con un bosque aleatorio o LASSO, y luego regresar $Y - \hat{g}(X)$ sobre D :

$$\hat{\theta}_{ing} = \frac{\sum_i D_i (Y_i - \hat{g}(X_i))}{\sum_i D_i^2}.$$

Sustituyendo $Y_i = D_i \theta_0 + g_0(X_i) + U_i$:

$$\sqrt{n}(\hat{\theta}_{ing} - \theta_0) = \left(\frac{1}{n} \sum D_i^2 \right)^{-1} \left[\underbrace{\frac{1}{\sqrt{n}} \sum_i D_i U_i}_{\rightarrow N, \text{ bien}} + \underbrace{\frac{1}{\sqrt{n}} \sum_i D_i (g_0(X_i) - \hat{g}(X_i))}_{\text{sesgo de regularización}} \right]. \quad (2)$$

El segundo término es el problema. Como $D_i = m_0(X_i) + V_i$ tiene componente **explicable por** X , $\mathbb{E}[D(g_0 - \hat{g})(X)] = \mathbb{E}[m_0(X)(g_0 - \hat{g})(X)] \neq 0$ en general: la esperanza de la suma es del orden de $\sqrt{n} \cdot \|g_0 - \hat{g}\|$, un **efecto de primer orden**. Si $\hat{g}$ converge a una tasa $n^{-\varphi}$ con $\varphi < 1/2$ (lo normal con ML), este término **diverge**. El estimador tiene **sesgo no despreciable** y el intervalo de confianza nominal cubre mal (Ejercicio 8.1). El culpable es que el momento $\mathbb{E}[D(Y - \theta D - g(X))]$ es **sensible de primer orden** a errores en g .

3. Ortogonalidad de Neyman

La solución es construir un **momento insensible de primer orden** a los errores de estimación de las funciones de perturbación.

Definición 3.1 (Ortogonalidad de Neyman). Sea $\psi(W; \theta, \eta)$ un momento con $\mathbb{E}[\psi(W; \theta_0, \eta_0)] = 0$, donde η agrupa las funciones de perturbación (con valor verdadero η_0). Se dice que ψ es **ortogonal de Neyman** si su derivada de Gateaux respecto de η en η_0 es cero:

$$\partial_r \mathbb{E}[\psi(W; \theta_0, \eta_0 + r(\eta - \eta_0))] \Big|_{r=0} = 0 \quad \text{para toda dirección } \eta.$$

En palabras: **la esperanza del momento no cambia a primer orden cuando η se aparta de su valor verdadero**. Los errores de estimación de η entran solo a **segundo orden**.

Proposición 3.1 (El momento de residuos sobre residuos es ortogonal). Con $\eta = (\ell, m)$ y

$$\psi(W; \theta, \eta) = (Y - \ell(X) - \theta(D - m(X)))(D - m(X)),$$

se tiene $\mathbb{E}[\psi(W; \theta_0, \eta_0)] = 0$ y ψ es ortogonal de Neyman. En cambio, el momento ingenuo $\psi_{ing} = (Y - \theta D - g(X))D$ **no** lo es.

Borrador

Evalúo el momento en $\eta_0 + r(\eta - \eta_0)$ con $\Delta\ell = \ell - \ell_0$ y $\Delta m = m - m_0$. En el valor verdadero, el primer factor vale U y el segundo V . Al perturbar, cada factor cambia en $O(r)$: el primero a $U - r(\Delta\ell - \theta_0\Delta m)$ y el segundo a $V - r\Delta m$. El producto es una expresión cuadrática en r , y la derivada en $r = 0$ es la suma de dos términos que son (función de X) $\times$ (V o U). Como V y U tienen **media condicional cero dado** X , la esperanza es cero.

Demostración. En η_0 : $Y - \ell_0(X) - \theta_0(D - m_0(X)) = U$ (de $\ell_0 = \theta_0 m_0 + g_0$ y Ecuación 1) y $D - m_0(X) = V$, de modo que $\mathbb{E}[\psi(\theta_0, \eta_0)] = \mathbb{E}[UV] = \mathbb{E}[V\mathbb{E}[U \mid D, X]] = 0$. Perturbando, el primer factor es $U - r(\Delta\ell - \theta_0\Delta m)(X)$ y el segundo es $V - r\Delta m(X)$. El producto es

$$UV - r[(\Delta\ell - \theta_0\Delta m)(X)V + U\Delta m(X)] + r^2(\Delta\ell - \theta_0\Delta m)(X)\Delta m(X).$$

La derivada en $r = 0$ es $-\mathbb{E}[(\Delta\ell - \theta_0\Delta m)(X)V] - \mathbb{E}[U\Delta m(X)]$. El primer término es cero porque $\mathbb{E}[V \mid X] = 0$ y el segundo porque $\mathbb{E}[U \mid X] = \mathbb{E}[\mathbb{E}[U \mid D, X] \mid X] = 0$. Para el momento ingenuo, perturbando g en la dirección Δg : la derivada es $-\mathbb{E}[D\Delta g(X)] = -\mathbb{E}[m_0(X)\Delta g(X)]$, que **no** se anula en general (por ejemplo, con $\Delta g = m_0$ vale $-\mathbb{E}[m_0^2] < 0$). $\square$

La diferencia es **restar la parte de D explicable por X** ($D - m(X)$ en lugar de D): la perturbación en g se multiplica por V , que es **ortogonal a toda función de X** . Es la misma lógica de Frisch-Waugh-Lovell (Clase 3 de Econometría 1): residualizar el regresor de interés respecto de los controles hace que el coeficiente sea insensible al ajuste de los controles.

4. Cross-fitting

La ortogonalidad elimina el sesgo de primer orden, pero queda una segunda dificultad: el **sobreajuste**. Si se usan **las mismas observaciones** para estimar las funciones de perturbación $\hat{\eta}$ y para evaluar el momento, $\hat{\eta}$ depende de (U_i, V_i) y los términos como $\frac{1}{\sqrt{n}} \sum V_i b(X_i)$ **ya no tienen media cero**: un ML flexible ajusta parte del ruido, y esos “residuos” subestiman la variación real. Una solución clásica es restringir la complejidad de $\hat{\eta}$ (condiciones de Donsker), que excluye bosques profundos, redes grandes y muchos métodos modernos. DML usa en cambio **división de la muestra**.

Algoritmo de DML con cross-fitting

1. Dividir la muestra en K **pliegues** $I_1, \dots, I_K$ de tamaño n/K (típicamente $K = 5$).
2. Para cada k , **estimar** $\hat{\ell}_{(k)}$ y $\hat{m}_{(k)}$ con ML usando **solo las observaciones fuera del pliegue k** , y calcular los residuos $\hat{Y}_i = Y_i - \hat{\ell}_{(k)}(X_i)$ y $\hat{V}_i = D_i - \hat{m}_{(k)}(X_i)$ **para** $i \in I_k$.

3. Resolver el momento con todas las observaciones:

$$\hat{\theta} = \left(\sum_{i=1}^n \hat{V}_i^2 \right)^{-1} \sum_{i=1}^n \hat{V}_i \hat{Y}_i.$$

4. Error estándar: $\hat{\sigma}^2 = \hat{J}^{-2} \cdot \frac{1}{n} \sum \hat{V}_i^2 \hat{U}_i^2$ con $\hat{U}_i = \hat{Y}_i - \hat{\theta} \hat{V}_i$ y $\hat{J} = \frac{1}{n} \sum \hat{V}_i^2$; $ee(\hat{\theta}) = \hat{\sigma} / \sqrt{n}$.

La idea es que **los residuos de cada observación se calculan con funciones estimadas sin ella**: $\hat{\eta}_{(k)}$ es independiente de $\{(U_i, V_i)\}_{i \in I_k}$ condicional en X , lo que restituye la esperanza cero de los términos cruzados. Se pierde algo de eficiencia (cada $\hat{\eta}$ usa $(K - 1)/K$ de los datos), pero se gana **generalidad**: cualquier ML sirve, siempre que converja a una tasa suficiente. Una variante es **repetir** la división varias veces con semillas distintas y tomar la mediana, para reducir la aleatoriedad de la partición.

5. El teorema de DML

Supuestos

1. **Identificación y momentos:** $\mathbb{E}[V^2] \geq c > 0$ y momentos de orden 4 de (U, V) acotados.
2. **Tasas de las funciones de perturbación** (en L^2): $\|\hat{m} - m_0\|_{L^2} \cdot \|\hat{g} - g_0\|_{L^2} = o_p(n^{-1/2})$ (con $\hat{g} = \hat{\ell} - \theta_0 \hat{m}$), y ambos errores $\|\hat{m} - m_0\|_{L^2}, \|\hat{g} - g_0\|_{L^2} \rightarrow_p 0$.
3. **Cross-fitting** con K fijo.

La condición típica que implica el supuesto 2 es que **cada** función de perturbación se estime a una tasa $o_p(n^{-1/4})$: **mucho más débil que $\sqrt{n}$** (que es lo que exigiría el plug-in ingenuo), y alcanzable por muchos métodos de ML bajo supuestos estructurales (el LASSO bajo dispersión con $s^2 \log^2 p/n \rightarrow 0$; bosques y redes bajo suavidad o dispersión).

Teorema 5.1 (Normalidad asintótica de DML). *Bajo los supuestos,*

$$\sqrt{n}(\hat{\theta} - \theta_0) \xrightarrow{d} N(0, \sigma^2), \quad \sigma^2 = \frac{\mathbb{E}[V^2 U^2]}{\mathbb{E}[V^2]^2},$$

y el estimador de varianza $\hat{\sigma}^2$ es consistente. Es **la misma varianza** que tendría el estimador de MCO con (ℓ_0, m_0) conocidas (el “oráculo”): no hay pérdida de eficiencia por estimar las funciones de perturbación.

Demostración. Sea $\hat{V}_i = V_i + \Delta m_i$ con $\Delta m_i = (m_0 - \hat{m})(X_i)$ y $\hat{Y}_i - \theta_0 \hat{V}_i = U_i + b_i$ con $b_i = (g_0 - \hat{g})(X_i)$ (de $\hat{Y} - \theta_0 \hat{V} = Y - \theta_0 D - \hat{\ell} + \theta_0 \hat{m} = g_0 + U - \hat{g}$, con $\hat{g} = \hat{\ell} - \theta_0 \hat{m}$). Entonces

$$\sqrt{n}(\hat{\theta} - \theta_0) = \hat{f}^{-1} \cdot \frac{1}{\sqrt{n}} \sum_i \hat{V}_i (\hat{Y}_i - \theta_0 \hat{V}_i), \quad \hat{V}_i (\hat{Y}_i - \theta_0 \hat{V}_i) = (V_i + \Delta m_i)(U_i + b_i).$$

Se descompone la suma en cuatro términos:

$$\underbrace{\frac{1}{\sqrt{n}} \sum V_i U_i}_A + \underbrace{\frac{1}{\sqrt{n}} \sum V_i b_i}_B + \underbrace{\frac{1}{\sqrt{n}} \sum \Delta m_i U_i}_C + \underbrace{\frac{1}{\sqrt{n}} \sum \Delta m_i b_i}_D.$$

Término A: suma de variables i.i.d. de media cero y varianza $\mathbb{E}[V^2 U^2]$; por el TCL, $A \rightarrow_d N(0, \mathbb{E}[V^2 U^2])$. **Términos B y C:** con

cross-fitting, para $i \in I_k$ los $b_i, \Delta m_i$ son funciones de X_i y de los datos **fuera del pliegue** (independientes de (U_i, V_i) condicional en X_i). Condicionando en esos datos y en los X , B es una suma de términos con media condicional cero ($\mathbb{E}[V_i | X_i] = 0$) y varianza $\frac{1}{n} \sum b_i^2 \mathbb{E}[V^2 | X_i] \leq C \|\hat{g} - g_0\|_{L^2}^2 \rightarrow_p 0$; análogamente C . Luego $B, C = o_p(1)$ por la desigualdad de Chebyshev. *Término R* (el **producto** de errores): por Cauchy-Schwarz, $|R| \leq \sqrt{n} \left(\frac{1}{n} \sum \Delta m_i^2 \right)^{1/2} \left(\frac{1}{n} \sum b_i^2 \right)^{1/2} \approx \sqrt{n} \|\hat{m} - m_0\| \cdot \|\hat{g} - g_0\| = o_p(1)$ por el supuesto de tasas. Finalmente $\hat{f} \rightarrow_p \mathbb{E}[V^2]$ (porque $\hat{V} \rightarrow V$ en L^2), y por Slutsky $\sqrt{n}(\hat{\theta} - \theta_0) \rightarrow_d N(0, \mathbb{E}[V^2 U^2] / \mathbb{E}[V^2]^2)$. $\square$

La demostración **muestra por qué funciona**. Sin ortogonalidad, B aparecería como $\frac{1}{\sqrt{n}} \sum m_0(X_i) b_i$ (el término de Ecuación 2), que **no** tiene media cero y es $O(\sqrt{n} \|b\|)$; con ortogonalidad se multiplica b_i por V_i (media cero), y el único residuo de primer orden es el **producto** R de dos errores pequeños. Y sin cross-fitting, B y C no serían despreciables por sobreajuste.

Una lectura de las tasas: si cada función de perturbación se estima a tasa $n^{-\varphi}$, el producto es $n^{-2\varphi}$ y se exige $2\varphi > 1/2$, es decir $\varphi > 1/4$. Es la razón de la tasa $o(n^{-1/4})$ que aparece en toda la literatura. (Con LASSO, $\|\hat{g} - g_0\| \approx \sqrt{s \log p/n}$ y se necesita $s \log p / \sqrt{n} \rightarrow 0$, Ejercicio 8.6.)

6. Conexión con el AIPW de la Clase 2

DML **no se limita** al modelo parcialmente lineal. Para el **efecto promedio** $\tau_{ATE} = \mathbb{E}[Y(1) - Y(0)]$ bajo insesgamiento condicional (Clase 2), el momento ortogonal es el del estimador **AIPW**:

$$\psi(W; \theta, \eta) = \mu_1(X) - \mu_0(X) + \frac{D(Y - \mu_1(X))}{e(X)} - \frac{(1 - D)(Y - \mu_0(X))}{1 - e(X)} - \theta, \quad \eta = (\mu_0, \mu_1, e).$$

El sesgo del AIPW calculado en el teorema de doble robustez de la Clase 2 es $\mathbb{E}[(\tilde{\mu}_1 - \mu_1)(\tilde{e} - e)/\tilde{e}] - \dots$: un **producto** de los errores de μ y de e , la firma de la ortogonalidad (Ejercicio 8.5). Entonces **DML aplicado al ATE es el AIPW con cross-fitting y ML**: μ_d y e se estiman con ML (bosques, LASSO, redes) en K pliegues, y el estimador $\hat{\tau} = \frac{1}{n} \sum \hat{\psi}_i$ es $\sqrt{n}$ -normal, con varianza **igual a la cota**

de eficiencia semiparamétrica (Clase 2, ★) si ambas funciones se estiman a tasa $o_p(n^{-1/4})$. Es el resultado que une las Clases 2 y 8: la **doble robustez** (producto de errores) es **ortogonalidad**.

Otras aplicaciones del mismo marco: **VI con muchos instrumentos o controles** (modelo parcialmente lineal con instrumento, ortogonalizando la primera etapa y la forma reducida); **LATE**; **diferencias en diferencias con muchas covariables** (Clase 4); **efectos heterogéneos** (CATE) con bosques causales (Athey y Wager); **derivadas promedio y efectos de políticas contrafactuales**.

7. Aspectos prácticos

- **¿Qué ML usar?** El teorema es agnóstico: cualquier método que cumpla las tasas. En la práctica se compara el desempeño predictivo de varios (LASSO, bosques, boosting, redes) con validación cruzada y se usa el **mejor** para cada función de perturbación, o un **ensamble** (*stacking*). Una buena predicción de $\hat{\ell}$ y $\hat{m}$ es lo que importa; no se necesita que el ML “explique” nada.
- **Elección de K y repeticiones.** $K = 5$ es estándar; con muestras pequeñas $K = 10$. Repetir la partición (por ejemplo 50 veces) y reportar la **mediana** de $\hat{\theta}$ (ajustando el error estándar) reduce la variabilidad debida al azar de la partición.
- **Traslape.** Para ATE hay que verificar que $\hat{e}(X)$ no esté cerca de 0 o 1 (Clase 2); se recorta o se estima el efecto sobre la subpoblación con buen traslape.
- **Límites:** DML garantiza inferencia **válida dado** el insesgamiento condicional: no resuelve la selección sobre no observables, ni sustituye el conocimiento institucional sobre qué controles son legítimos (variables previas, no mediadores). Es una herramienta de **estimación**, no de **identificación**: el ML no vuelve creíble un supuesto de identificación que no lo es.

8. ★ Postgrado: construir momentos ortogonales

! ★ Postgrado

Dado un momento **no ortogonal**, hay una receta general para **ortogonalizarlo**: agregarle el término de corrección dado por la **función de influencia del estimador de primera etapa** (Chernozhukov, Escanciano, Ichimura, Newey y Robins, 2022). Lo ilustramos con dos casos.

(1) El modelo parcialmente lineal. El momento ingenuo $\psi_{ing} = (Y - \theta D - g(X))D$ tiene derivada $-\mathbb{E}[\Delta g(X)D] = -\mathbb{E}[\Delta g(X)m_0(X)]$ respecto de g : su sensibilidad pasa por el **proyector** de D sobre funciones de X , que es $m_0(X)$. La corrección consiste en **restar** del regresor la parte de D explicable por X , reemplazando D por $D - m(X)$: $\psi = (Y - \theta D - g(X))(D - m(X))$, cuya derivada respecto de g es $-\mathbb{E}[\Delta g(X)(D - m_0(X))] = -\mathbb{E}[\Delta g(X)V] = 0$, y respecto de m es $\mathbb{E}[U\Delta m(X)] = 0$ (el factor $U = Y - \theta_0 D - g_0$ es ortogonal a funciones de X): ortogonal (Proposición 3.1, con $g = \ell - \theta m$).

(2) El efecto promedio. El momento de **regresión** $\psi_0 = \mu_1(X) - \mu_0(X) - \theta$ tiene derivada $\mathbb{E}[\Delta\mu_1(X) - \Delta\mu_0(X)]$, distinta de cero: **no** es ortogonal (un error en μ_1 sesga θ de primer orden). La corrección es el **ponderador** $D/e(X)$ aplicado al **residuo** $Y - \mu_1(X)$: la derivada del término $D(Y - \mu_1)/e$ respecto de μ_1 en la dirección $\Delta\mu_1$ es $-\mathbb{E}[D\Delta\mu_1(X)/e(X)] = -\mathbb{E}[\mathbb{E}[D | X]\Delta\mu_1(X)/e(X)] = -\mathbb{E}[\Delta\mu_1(X)]$, que **cancela** exactamente la de ψ_0 . Lo mismo para μ_0 con $-(1 - D)(Y - \mu_0)/(1 - e)$. Respecto de e : la derivada es $-\mathbb{E}[D(Y - \mu_1)\Delta e/e^2] = -\mathbb{E}[e(\mu_1 - \mu_1)\Delta e/e^2] = 0$ (condicional en X , $\mathbb{E}[D(Y - \mu_1) | X] = e(X)(\mu_1(X) - \mu_1(X)) = 0$). El AIPW es **ortogonal** (Ejercicio 8.5).

El principio general: un parámetro $\theta(\eta)$ que es **suave** en una función η estimada (una regresión, un propensity score) admite una **función de influencia** $\varphi(W; \eta)$; el momento ortogonal es $\psi_{orth} = \psi_{plug-in} + \varphi$. Es la misma idea de la teoría semiparamétrica de eficiencia (Clase 2, ★): el estimador eficiente tiene como

función de influencia la **proyección** sobre el espacio tangente, y esa proyección es ortogonal a los parámetros de perturbación.

9. Resumen

- Modelo parcialmente lineal: $Y = D\theta_0 + g_0(X) + U$, $D = m_0(X) + V$. Estimar g_0 por ML y hacer plug-in introduce un **sesgo de regularización de primer orden** (Ecuación 2): $\sqrt{n}\|g_0 - \hat{g}\|$ diverge si el ML converge más lento que $\sqrt{n}$.
- **Ortogonalidad de Neyman** (Definición 3.1): un momento cuya esperanza es insensible a primer orden a η . El de **residuos sobre residuos** lo es (Proposición 3.1); el ingenuo no.
- **Cross-fitting**: estimar las funciones de perturbación en pliegues distintos del que se evalúa. Elimina el sobreajuste sin restringir la complejidad del ML.
- **Teorema** (Teorema 5.1): $\sqrt{n}(\hat{\theta} - \theta_0) \rightarrow N(0, \mathbb{E}[V^2 U^2] / \mathbb{E}[V^2]^2)$ si $\|\hat{m} - m_0\| \cdot \|\hat{g} - g_0\| = o_p(n^{-1/2})$ (típicamente cada error $o(n^{-1/4})$). La demostración aísla el **producto de errores**.
- **AIPW = DML para el ATE**: doble robustez es ortogonalidad; eficiencia semiparamétrica.
- DML mejora la **estimación**, no la **identificación**.

10. Ejercicios

Ejercicio 8.1. Con $n = 10\,000$, $\|g_0 - \hat{g}\|_{L^2} = n^{-1/4} = 0,1$, y $\mathbb{E}[m_0(X)(g_0 - \hat{g})(X)] = 0,5\|m_0\| \|g_0 - \hat{g}\|$ con $\|m_0\| = 1$, calcula el sesgo del estimador ingenuo y compáralo con su error estándar $\approx 1/\sqrt{n}$ (con $\mathbb{E}[D^2] \approx 1$). ¿Qué pasa con el estimador ortogonal si ambos errores son $n^{-1/4}$?

Solución 8.1

Sesgo del ingenuo $\approx \mathbb{E}[D(g_0 - \hat{g})] / \mathbb{E}[D^2] = 0,5 \cdot 1 \cdot 0,1 = 0,05$. Error estándar $= 1/\sqrt{10\,000} = 0,01$: el sesgo es **5 errores estándar**: un intervalo del 95 % cubre el valor ver-

dadero con probabilidad prácticamente nula. Ortogonal: el sesgo es el producto $\mathbb{E}[\Delta m \cdot b] \lesssim \|\hat{m} - m_0\| \cdot \|\hat{g} - g_0\| = 0,1 \cdot 0,1 = 0,01$ en el peor caso (correlación perfecta), es decir, **1 error estándar**, y en un caso típico (correlación 0,5) 0,005, medio error estándar. Con tasas $n^{-1/3}$ (errores de 0,046 cada uno), el producto es 0,0022 (la quinta parte del error estándar): despreciable. La ortogonalidad convierte un sesgo de 5 errores estándar en uno de ≤ 1 con la misma calidad de ML, y la cota $o(n^{-1/4})$ lo hace despreciable.

Ejercicio 8.2. Con $X \sim N(0, 1)$ y $m_0(X) = X$, calcula la derivada del momento ingenuo respecto de g en la dirección $\Delta g = m_0$ y la del momento ortogonal. ¿Qué indica?

💡 Solución 8.2

Ingenuo: $-\mathbb{E}[D\Delta g(X)] = -\mathbb{E}[m_0(X) \cdot m_0(X)] = -\mathbb{E}[X^2] = -1 \neq 0$: un error en g en la dirección de m_0 desplaza la esperanza del momento en -1 por unidad de error: **sensibilidad de primer orden**. Ortogonal: $-\mathbb{E}[V\Delta g(X)] = -\mathbb{E}[\Delta g(X)\mathbb{E}[V \mid X]] = 0$. Es la diferencia clave: multiplicar el error por V (media condicional cero) en lugar de por D (que contiene $m_0(X)$).

Ejercicio 8.3. Describe el cross-fitting con $K = 2$ para $n = 1\,000$: ¿qué datos usa cada paso y por qué la independencia importa?

💡 Solución 8.3

Se parte la muestra en dos mitades I_1, I_2 de 500. (1) Con I_2 , se **entrenan** $\hat{\ell}_{(1)}, \hat{m}_{(1)}$ (por ejemplo, bosques). (2) Con ellos se calculan los residuos $\hat{Y}_i, \hat{V}_i$ para $i \in I_1$. (3) Se intercambian los roles: se entrenan $\hat{\ell}_{(2)}, \hat{m}_{(2)}$ con I_1 y se calculan los residuos de I_2 . (4) Con los 1 000 residuos se calcula $\hat{\theta} = \sum \hat{V}_i \hat{Y}_i / \sum \hat{V}_i^2$. Cada residuo $\hat{V}_i$ usa una función **entrenada sin la observación i** : $\hat{m}_{(k)}$ es independiente de (U_i, V_i) dado X_i . Si no se hiciera la división, $\hat{m}(X_i)$ habría “visto” D_i y sería demasiado cercano a él: los residuos $\hat{V}_i$ serían artificialmente pequeños (sobreajuste) y $\hat{f}$ y el numerador, sesgados.

Ejercicio 8.4. Con $n = 500$ y $K = 5$ se obtiene $\hat{\theta} = 0,40$, $\frac{1}{n} \sum \hat{V}_i^2 = 0,8$ y $\frac{1}{n} \sum \hat{V}_i^2 \hat{U}_i^2 = 1,2$. Calcula $\hat{\sigma}^2$, el error estándar y un IC del 95 %.

 Solución 8.4

$\hat{\sigma}^2 = \hat{J}^{-2} \cdot 1,2 = 1,2/0,64 = 1,875$. Error estándar: $\sqrt{1,875/500} = 0,0612$. IC 95 %: $0,40 \pm 1,96(0,0612) = (0,28; 0,52)$. Observa que la fórmula es la del **sándwich** de Econometría 1 (Clase 7) con los residuos ortogonalizados: $\hat{J}^{-1}$ ("curvatura") y $\frac{1}{n} \sum \hat{V}_i^2 \hat{U}_i^2$ ("ruido"), con heterocedasticidad permitida.

Ejercicio 8.5. Muestra que el momento AIPW es ortogonal respecto de μ_1 y respecto de e calculando las derivadas de Gateaux.

 Solución 8.5

Perturbando $\mu_1 \rightarrow \mu_1 + r\Delta\mu_1$: el término $\mu_1(X)$ aporta $\Delta\mu_1(X)$ y el término $D(Y - \mu_1)/e$ aporta $-D\Delta\mu_1(X)/e(X)$. La esperanza de la derivada es $\mathbb{E}[\Delta\mu_1] - \mathbb{E}[D\Delta\mu_1/e] = \mathbb{E}[\Delta\mu_1] - \mathbb{E}[\Delta\mu_1 \mathbb{E}[D \mid X]/e] = \mathbb{E}[\Delta\mu_1] - \mathbb{E}[\Delta\mu_1] = 0$ $\square$. Perturbando $e \rightarrow e + r\Delta e$: la derivada del término $D(Y - \mu_1)/e$ es $-D(Y - \mu_1)\Delta e/e^2$, y por insesgamiento condicional $\mathbb{E}[D(Y - \mu_1) \mid X] = e(\mu_1 - \mu_1) = 0$: derivada cero $\square$ (lo mismo para el término de control). Por eso el sesgo del AIPW con funciones de perturbación mal estimadas es un **producto** (teorema de doble robustez, Clase 2) y no una suma de errores.

Ejercicio 8.6. Con LASSO, $\|\hat{g} - g_0\| \approx \sqrt{s \log p/n}$. Para $s = 10$ y $p = 1\,000$, ¿se cumple la condición $o(n^{-1/4})$ con $n = 10\,000$ y con $n = 2\,000$?

 Solución 8.6

$n = 10\,000$: $\sqrt{10 \cdot 6,91/10\,000} = \sqrt{0,00691} = 0,083$ y $n^{-1/4} = 0,10$: el error $0,083 < 0,10$ cumple **apenas** (la condición es $o(n^{-1/4})$, es decir, que el cociente tienda a cero;

con 0,83 no hay holgura). $n = 2\,000$: $\sqrt{69,1/2\,000} = 0,186$ y $n^{-1/4} = 0,149$: **no** se cumple ($0,186 > 0,149$). La exigencia equivale a $s \log p / \sqrt{n} \rightarrow 0$: con $s = 10$ y $\log p = 6,9$, hace falta $n \gg (69)^2 = 4\,761$, y con holgura, bastante más. Con una función de perturbación **más dispersa** (s mayor) o con p mayor, la inferencia de DML con LASSO requiere muestras grandes.

Ejercicio 8.7 ★. Para el momento $\psi_0 = \mu_1(X) - \mu_0(X) - \theta$, calcula la derivada respecto de μ_1 y encuentra el término de corrección que la anula. Verifica que la corrección **no** cambia el valor del momento en el verdadero η_0 .

 Solución 8.7 ★

Derivada en la dirección $\Delta\mu_1$: $\mathbb{E}[\Delta\mu_1(X)] \neq 0$. Buscamos un término $c(W; \mu_1)$ que dependa de μ_1 y tenga derivada $-\mathbb{E}[\Delta\mu_1(X)]$. Tomamos $c = \frac{D(Y - \mu_1(X))}{e(X)}$: su derivada es $-\mathbb{E}[D\Delta\mu_1/e] = -\mathbb{E}[\Delta\mu_1]$ (como $\mathbb{E}[D \mid X] = e$). La suma tiene derivada 0 $\boxtimes$. En η_0 , el valor del término de corrección es $\mathbb{E}[D(Y - \mu_1(X))/e(X)] = \mathbb{E}\left[\frac{1}{e} \mathbb{E}[D(Y - \mu_1) \mid X]\right] = 0$, de modo que **no altera** la identificación $\mathbb{E}[\psi] = 0$ en θ_0 : es un “cero que no cambia el nivel pero cambia la pendiente respecto de η ”. Es el mecanismo general de la ortogonalización: agregar un término de **esperanza cero en el verdadero** y de derivada exactamente **opuesta** a la del momento original.